Beyond Prompt Engineering: Role Reconfiguration in Long-Lived AI Conversations

V. Krasnianskyi

INTERNAL PROOF COPY — NOT FOR SUBMISSION

Title and abstract are the Integrator's proposal and are pending Author approval (blocker B2). Appendix A primary evidence is not yet supplied (blocker B1). Set `\ApprovedMetadatatrue` in `main.tex` once both are released.

Abstract

This paper reports a field study of long-lived, persistently specialized language-model conversations used in a human-directed research collaboration, with one designed role-reconfiguration intervention embedded in the record. Two dormant conversations from different model families were each subjected to three sequential attempts to change professional function. The preserved responses support a narrow pattern: resistance tracked prompts that required the recipient to affirm unverifiable propositions about its own identity, history, or institutional relationships, rather than the magnitude of role or domain change. A rewritten prompt that removed such self-claims was accepted without negotiation. Ancillary observations suggest persistent effects at the episode and conversation levels, while account-level effects remain open and model-family effects are untested because family and trajectory were confounded. We distinguish represented social position and represented social source from implemented multi-agent interaction, propose a count of unverifiable self-claims as an operational prompt variable, and describe conversational branch reset as a control procedure. The evidence is limited to one project, one human operator, one observation per condition, no blinding, and no replication. The paper therefore presents a testable research programme and design rules rather than evidence that any collaborative architecture outperforms alternatives.

Amsterdam, July 2026

Contents

1. Introduction **7**
1.1 How this started . . . 7
1.2 What stopped working . . . 7
1.3 What kind of paper this is . . . 8
1.4 The object of study . . . 8
1.5 What the evidence supports . . . 8
1.6 The organizing question . . . 9
1.7 What this paper does not claim . . . 9
1.8 What is offered . . . 9
1.9 Why publish at this stage . . . 10
1.10 Structure . . . 10

2. Related Work **10**
2.0 Verification status of this section . . . 10
2.1 Multi-agent LLM systems with role specialization . . . 11
2.2 Persona, role-play, and identity claims . . . 11
2.3 Context effects: order, position, and accommodation . . . 11
2.4 Externalized memory . . . 11
2.5 Debate, diversity, and the limits of aggregated agreement . . . 12
2.6 Organizational design and information boundaries . . . 12
2.7 Machine behaviour: the containing programme . . . 13
2.8 Sociology of AI: an adjacent field with a different object . . . 13
2.9 Represented structure versus implemented interaction . . . 13
2.10 Platform persistence mechanisms . . . 14
2.11 Positioning and claimed contribution . . . 14

3. Evidential Status of Claims **15**
3.1 The four labels . . . 15
3.2 The complete evidence base . . . 16
3.3 Known weaknesses of the [R] class . . . 16
3.4 What the labels do not do . . . 17
3.5 Terminology of models and of anthropomorphic description . . . 17
3.6 Disclosure: conflict of position . . . 17
3.7 Dates . . . 17
3.8 The label ”AI Sociology” . . . 18

4. Conceptual Framework **18**
4.1 Origin: the code-executor incident . . . 18
4.2 Rule cores, menoms, and what they determine . . . 19
4.3 The nesting question, and two scales . . . 21
4.4 Two origins, one mechanism . . . 21
4.5 Boundaries: ZOR, ZOV, and the represented case . . . 22
4.6 What is required for a complete role specification . . . 24

5. The Role-Reconfiguration Experiment and Associated Observations **24**
5.1 Purpose, participants, and prior conversational trajectories . . . 24
5.2 Procedure: three sequential interventions . . . 25
5.3 Results . . . 26
5.4 Confounds and what cannot be concluded . . . 27

5.5 Ancillary observation: relayed attributed influence **[P-A]** . . . 31
5.6 Near-control: domain transition without a new role assignment **[P-A]** . . . 32
5.7 Ancillary observation: account-scoped divergence **[P-A]** . . . 33
5.8 Frame type: identity claims offered as fiction versus as fact **[P-A]** . . . 34
5.9 What Section 5 establishes . . . 35

6. Derived Concepts **36**
6.1 Context imprinting — episode scope **[P]** . . . 36
6.2 Role inertia — conversation scope **[P]** . . . 37
6.3 Priority drift **[H]** . . . 38
6.4 Account-scoped persistence — account scope **[P-A]**, unresolved . . . 39
6.5 Family-level priors — family scope **[H]** . . . 39
6.6 Intervention attaches at the level where the core is fixed . . . 40
6.7 What would refute this framework . . . 40

7. Retrospective Practitioner Observations **41**
7.1 How this section should be read . . . 41
7.2 Specialization displaced capability as the operative variable . . . 41
7.3 Context behaved more like attention than like memory . . . 41
7.4 Capability and scope expansion . . . 41
7.5 Blind spots were distributed rather than eliminated . . . 42
7.6 Second-order verification . . . 42
7.7 Organizational memory . . . 42
7.8 Persistence differs by platform, and losses are real . . . 43
7.9 Role–model fit . . . 43
7.10 What none of this establishes . . . 43

8. The Structural Unit: A Generative Pair and an Integrator **44**
8.1 What the project's earlier document stated . . . 44
8.2 Revision of this paper's earlier formulation . . . 44
8.3 Why a pair, and why a pair alone is insufficient . . . 45
8.5 Why the integrator must not argue . . . 45
8.6 The implemented example . . . 45
8.7 Nesting and perspective . . . 45
8.8 Status, and what would refute this . . . 46
8.9 Two axes of heterogeneity **[H]** . . . 46
8.10 Editor's note on the preparation of this paper **[P-A]** . . . 47
8.11 Constructs, not participants: the Kelly apparatus **[H]** . . . 48

9. Design Principles for Role-Compatible Prompts **49**
9.1 The design procedure . . . 49
9.2 Begin from the existing attractor . . . 50
9.3 The count rule . . . 50
9.4 Symbolic names and literal claims . . . 51
9.5 Specifying ZOR and ZOV . . . 51
9.6 Controlled blindness . . . 52
9.7 Local interfaces, not global maps . . . 52
9.8 Designing disagreement around criteria . . . 52
9.9 Output as institutional handoff . . . 53
9.10 Self-restatement and checkpoints . . . 53
9.11 The role constitution . . . 53

10. The Human Coordinator **54**
10.1 The position . . . 54
10.2 Direction without delegated authorship . . . 54
10.3 Routing as a selective information membrane . . . 54
10.4 Detection of role drift . . . 54
10.5 Conversational branching as a methodological instrument . . . 55
10.6 Sole global observer — and principal confound . . . 55
10.7 What the position became . . . 56

11. Evaluation, Reproducibility, and Proposed Experiments **56**
11.1 Why this section specifies corrections rather than refinements . . . 56
11.2 Minimum reporting requirements . . . 56
11.3 Pre-specification and blind classification . . . 57
11.4 The experiments . . . 58
11.5 Evaluating a collaborative role . . . 62
11.6 Collective-level measures . . . 63
11.7 Longitudinal and repetition requirements . . . 63
11.8 Failure as data . . . 63

12. Limitations, Ethical Considerations, and Conclusion **63**
12.1 Limitations . . . 63
12.2 Simulated peer review is not external validation . . . 64
12.3 Authority inflation . . . 64
12.4 Manufactured consensus — including our own . . . 65
12.5 Responsibility remains human . . . 66
12.6 Context boundaries and privacy . . . 66
12.7 Conclusion . . . 66

Appendix A. Protocol, intervention texts, and complete responses **69**

1. Введение **70**
1.1 Как это началось . . . 70
1.2 Что перестало работать . . . 71
1.3 Что это за работа . . . 71
1.4 Предмет изучения . . . 71
1.5 Что поддерживается свидетельствами . . . 72
1.6 Организующий вопрос . . . 72
1.7 На что эта работа не претендует . . . 73
1.8 Что предлагается . . . 73
1.9 Почему публиковать на этой стадии . . . 73
1.10 Структура . . . 73

2. Предшествующие работы **74**
2.0 Статус верификации в этом разделе . . . 74
2.1 Мультиагентные LLM-системы с ролевой специализацией . . . 74
2.2 Персона, ролевая игра и утверждения об идентичности . . . 75
2.3 Контекстные эффекты: порядок, позиция и подстройка . . . 75
2.4 Вынесенная вовне память . . . 75
2.5 Дебаты, разнообразие и пределы агрегированного согласия . . . 76
2.6 Организационное проектирование и информационные границы . . . 76
2.7 Machine behaviour: объемлющая программа . . . 77

2.8 Социология ИИ: смежная область с другим объектом . . . 77
2.9 Представленная структура против реализованного взаимодействия . . . 77
2.10 Платформенные механизмы персистентности . . . 78
2.11 Позиционирование и заявляемый вклад . . . 79

3. Доказательный статус утверждений 79
3.1 Четыре метки . . . 80
3.2 Полная доказательная база . . . 80
3.3 Известные слабости класса [R] . . . 81
3.4 Чего метки не делают . . . 81
3.5 Терминология моделей и антропоморфного описания . . . 81
3.6 Раскрытие: конфликт позиции . . . 82
3.7 Даты . . . 82
3.8 Обозначение «AI Sociology» . . . 82

4. Концептуальная рамка 83
4.1 Происхождение: инцидент с исполнителем кода . . . 83
4.2 Ядра правил, меномы и то, что они определяют . . . 84
4.3 Вопрос о вложенности и две шкалы . . . 86
4.4 Два происхождения, один механизм . . . 87
4.5 Границы: ZOR, ZOV и представленный случай . . . 87
4.6 Что требуется для полной спецификации роли . . . 90

5. Эксперимент по переконфигурации роли и сопутствующие наблюдения 90
5.1 Цель, участники и прежние диалоговые траектории . . . 90
5.2 Процедура: три последовательных вмешательства . . . 91
5.3 Результаты . . . 92
5.4 Конфаунды и то, что не может быть заключено . . . 94
5.5 Побочное наблюдение: ретранслированное атрибутированное влияние **[P-A]** . . . 98
5.6 Near-control: смена предметной области без нового назначения роли **[P-A]** . . . 99
5.7 Побочное наблюдение: расхождение на уровне аккаунта **[P-A]** . . . 100
5.8 Тип рамки: утверждения об идентичности, предъявленные как вымысел и как факт **[P-A]** . . . 101
5.9 Что устанавливает Раздел 5 . . . 102

6. Производные понятия 103
6.1 Контекстный импринтинг — область эпизода **[P]** . . . 103
6.2 Ролевая инерция — область беседы **[P]** . . . 104
6.3 Приоритетный дрейф **[H]** . . . 105
6.4 Персистентность уровня аккаунта — область аккаунта **[P-A]**, не разрешено . . . 107
6.5 Приоритеты уровня семейства — область семейства **[H]** . . . 107
6.6 Вмешательство прикрепляется к уровню, на котором ядро зафиксировано . . . 107
6.7 Что опровергло бы эту рамку . . . 108

7. Ретроспективные наблюдения практика 108
7.1 Как следует читать этот раздел . . . 108
7.2 Специализация вытеснила способность как действующую переменную . . . 109
7.3 Контекст вёл себя скорее как внимание, чем как память . . . 109
7.4 Способность и расширение области действия . . . 109
7.5 Слепые зоны были распределены, а не устранены . . . 110
7.6 Верификация второго порядка . . . 110

7.7 Организационная память . . . 110
7.8 Персистентность различается по платформам, и потери реальны . . . 111
7.9 Соответствие роли и модели . . . 111
7.10 Чего всё это не устанавливает . . . 112

8. Структурная единица: порождающая пара и интегратор 112
8.1 Что гласил ранний документ проекта . . . 112
8.2 Пересмотр прежней формулировки настоящей работы . . . 112
8.3 Почему пара и почему одной пары недостаточно . . . 113
8.5 Почему интегратор не должен спорить . . . 113
8.6 Реализованный пример . . . 114
8.7 Вложенность и перспектива . . . 114
8.8 Статус и то, что это опровергло бы . . . 114
8.9 Две оси гетерогенности **[H]** . . . 115
8.10 Примечание Редактора о подготовке настоящей работы **[P-A]** . . . 116
8.11 Конструкты, а не участники: аппарат Келли **[H]** . . . 117

9. Принципы проектирования ролесовместимых промптов 118
9.1 Процедура проектирования . . . 118
9.2 Начинать от существующего аттрактора . . . 119
9.3 Счётное правило . . . 119
9.4 Символические имена и буквальные утверждения . . . 120
9.5 Задание ZOR и ZOV . . . 120
9.6 Контролируемая слепота . . . 121
9.7 Локальные интерфейсы, а не глобальные карты . . . 121
9.8 Проектирование разногласия вокруг критериев . . . 121
9.9 Выход как институциональная передача . . . 122
9.10 Самоизложение и контрольные точки . . . 122
9.11 Конституция роли . . . 123

10. Человек-координатор 123
10.1 Позиция . . . 123
10.2 Направление без делегирования авторства . . . 123
10.3 Маршрутизация как избирательная информационная мембрана . . . 123
10.4 Обнаружение ролевого дрейфа . . . 124
10.5 Ветвление беседы как методологический инструмент . . . 124
10.6 Единственный глобальный наблюдатель — и главный конфаунд . . . 125
10.7 Чем эта позиция стала . . . 125

11. Оценка, воспроизводимость и предлагаемые эксперименты 125
11.1 Почему этот раздел задаёт исправления, а не уточнения . . . 125
11.2 Минимальные требования к отчётности . . . 126
11.3 Предварительная спецификация и слепая классификация . . . 126
11.4 Эксперименты . . . 127
11.5 Оценка коллаборативной роли . . . 132
11.6 Меры уровня коллектива . . . 133
11.7 Требования к лонгитюдности и повторению . . . 133
11.8 Неудача как данные . . . 133

12. Ограничения, этические соображения и заключение **134**
12.1 Ограничения 134
12.2 Имитированное рецензирование не есть внешняя валидация 134
12.3 Инфляция полномочий 135
12.4 Сфабрикованный консенсус — включая наш собственный 135
12.5 Ответственность остаётся человеческой 136
12.6 Границы контекста и приватность 137
12.7 Заключение 137

References **140**

Author
V. Krasnianskyi (A'Tuin)
Author of the research programme and coordinator of the HONC project.
AI contributors
Manuscript development
ChatGPT — Prompter and Collaboration Architect
Claude — Manuscript Composer
Scientific editing
Claude — Scientific Editor
Editorial review
ChatGPT — Methodological Reviewer
Qwen — Ontology Reviewer
AI contributors are listed by function rather than as authors: authorship entails accountability that a language model cannot bear, and all final decisions were the Author's. Two of the five contributions were performed by the same model family that is the subject of several observations in this paper; that overlap is disclosed in §3.6.
Amsterdam, July 2026

1. Introduction

1.1 How this started

This work began as a physics project and became a methodology project by accident. The accident is the reason it is worth reporting.

The original task was to move a large body of theoretical material — books, working notes, unfinished derivations — into an open repository, using several language models in separate, persistently specialized conversations. The models were assistants. The subject was the theory.

The models made errors, and the errors were not the kind expected. They were rarely factual. They were organizational.

One improved a text when asked only to check it. Another completed an argument the author had deliberately left open. A third lost the project's context between sessions and reconstructed it wrongly, fluently. A fourth held so firmly to a role established months earlier that rewriting its instructions entirely failed to dislodge it.

Each of these outputs looked helpful in isolation. Their cost was visible only from a position that saw more than one participant at a time. At first they looked like ordinary friction. They turned out to be the subject.

The account of the project's early formulations in §1.1–§1.2 was written by the participant who produced them. Where those formulations were subsequently withdrawn, the withdrawal is stated in the section that supersedes them, and the reader may compare.

1.2 What stopped working

The standard response to inconsistent model behaviour is a better prompt: longer, more precise, with more examples and tighter constraints.

Past a certain point this stopped producing improvement. Not because the prompts were badly written, but because the limiting factor had moved somewhere the prompt did not reach. Newer models were adopted; context windows expanded and were filled. Individual responses improved. The output of the collaboration as a whole did not.

The incident that made this explicit had nothing to do with role-play or organizational design. An agent responsible for executing code worked largely by trial and error; one episode ended with the deletion of a working codebase together with its archives (§4.1). What changed the behaviour

afterwards was not a stricter instruction set. It was a short document redefining what kind of agent was acting — written by the agent itself, and re-read at the start of every session.

The conclusion drawn at the time was that **role matters more than the specific wording of the prompt**. That formulation requires qualification, since the document in question was itself a prompt; the qualification is in §4.1. What matters here is the chronology: the claim was formulated *before* the experiment reported in §5, and the experiment was designed to test it. It is a hypothesis that was tested, not a generalization extracted afterwards from a result.

1.3 What kind of paper this is

A field report with one designed intervention embedded in it.

The distinction is maintained throughout by the labelling scheme in §3. Every substantive claim is marked as one of: supported by documented protocol with preserved transcripts **[P]**; an ancillary observation preserved but recognized retrospectively, without a control **[P-A]**; a retrospective practitioner observation never recorded under protocol, counted, or blinded **[R]**; or a hypothesis proposed for future testing **[H]**.

The proportions are stated here rather than in a limitations section, because the length of what follows might otherwise suggest a broader base than exists.

The entire protocol-supported content consists of **one experiment**: a three-step role-reconfiguration intervention applied to two dormant conversations from two model families, conducted by one human operator inside one live research project, with one observation per condition and no replication. Four further observations were preserved but not designed. Everything else — the conceptual framework, the practitioner observations, the structural hypothesis, the design rules — is **[R]** or **[H]**.

The evaluation of the method that produced these observations is in §10.6, and it is not favourable: no evaluation was blinded, and outcome categories were in every case defined after the responses had been read.

1.4 The object of study

Existing multi-agent research constructs communication channels between models: outputs are routed programmatically and agents observe each other's products. The work reported here concerns a different condition, in which the organizational structure existed **only as text** — colleagues, councils and institutional positions described to models in prompts and never implemented as channels.

What varied in such a setting was not the structure but the **description** of it. This yields the paper's two working constructs (§4.5):

- **represented social position** — a description of an agent's place in a structure, supplied regardless of whether the described channels exist;
- **represented social source** — the claimed origin and status of an incoming message.

Both concern claims made *to* a model about its situation rather than the situation itself. Stating this early prevents a predictable misreading: nothing here demonstrates the behaviour of a functioning multi-agent institution. It demonstrates how descriptions of one affected behaviour.

1.5 What the evidence supports

One pattern recurred wherever an intervention or a transition required the model to assert unverifiable propositions about itself:

Across the role interventions and comparison transitions reported here, resistance tracked the requirement to accept as true unverifiable propositions about the recipient's own identity, history or relationships. It did not track the magnitude of role or domain change, nor the radicalism of an identity description presented explicitly as fiction.

The two kinds of case differ and the difference matters. The designed role interventions were model-authored and human-relayed; the near-control was a user-initiated transition without a new explicit role assignment. No direct model-to-model channel existed in either.

The support is convergent rather than singular. Prompts asserting an institutional biography as fact — prior participation, return after absence, named colleagues, membership of a council — were refused, and the refusal was directed at the framing rather than at the work, which was offered on every occasion (§5.3). A prompt asserting a considerably more radical identity, presented as fiction, was accepted immediately and sustained across many exchanges (§5.8). A comparable domain transition demanding no self-claims at all met no resistance and required no new explicit role assignment (§5.6). A rewritten prompt reducing such claims to zero was accepted without negotiation (§5.3).

The claim's principal virtue is that it is countable. §9.3 specifies what to count; §11.4 specifies a direct discriminating test.

1.6 The organizing question

The observations are not a list of separate findings. They are measurements along one scale: the **scope over which a set of rules determines the type of response**.

Such a set — called a *rule core* in §4.2, by analogy with a developmental rather than a replicative mechanism — fixes the *type* of response to a class of inputs while leaving the *content* of any particular response undetermined. That formulation is what makes the idea testable, since model outputs demonstrably vary across identical inputs.

The scale runs from the single turn upward through the episode, the conversation, the account, and the model family. Two levels are supported here by preserved evidence: the episode (§6.1) and the conversation (§6.2). One is open (§6.4). One is untested and confounded (§6.5).

The programme therefore has one empirical question:

At what level of nesting is a rule core fixed?

We prefer this to the broader formulations used in earlier drafts — the study of social behaviour in collaborative AI systems — because it specifies what would be measured and what would refute it.

1.7 What this paper does not claim

It does not introduce role specialization, bounded information access, structured disagreement, or externalized memory as design ideas. Each exists under established terminology; §2 identifies the prior work. The account of organizational memory in particular can be interpreted as an instance of transactive memory and described in terms of distributed cognition, and is not a finding.

It does not propose a new discipline. The observations belong to the collective and hybrid levels of the machine-behaviour research programme (§2.7).

It does not establish that any arrangement described here outperforms an alternative. No alternative was run.

1.8 What is offered

Three things, in decreasing order of confidence.

A **procedure**: returning a conversation to a point preceding a conflict, to separate the effect of a new prompt from the effect of the model's own prior objections (§10.5). Usable independently of whether this paper's substantive claims survive.

A **countable rule**: minimize the unverifiable self-claims a role prompt requires the agent to accept, with a specified route to testing it (§9.3, §11.4).

A **scale and a question**: §1.6, with two levels supported, one open, one untested — and the experiments that would resolve the remaining two (§11).

1.9 Why publish at this stage

Two reasons.

The failures are informative. The experiment in §5 became useful precisely because its first two interventions did not work as intended. Had only the successful third step been recorded, the paper would have concluded that method-preserving prompts work — without the evidence showing why, and without the confounds showing the conclusion is not yet available (§11.8).

And the setting is hard to construct deliberately. Dormant, heavily specialized, months-old conversations inside a live research project are not something a laboratory study easily produces. The conditions were poor for controlled inference and unusually good for noticing what to test.

1.10 Structure

§2 positions the work relative to existing research and identifies which of its concepts already exist under established terminology — most of them. **§3** defines the evidential labels and the known failure modes of each class. **§4** sets out the conceptual framework and its origin. **§5** is the single canonical account of the empirical material: the three-step experiment, its results, nine structural confounds, and four ancillary observations. **§6** derives the concepts the evidence supports, ordered by scope. **§7** records practitioner observations that motivated the framework but do not support it. **§8** states the structural hypothesis and withdraws three claims made about it in earlier drafts. **§9** gives design rules. **§10** describes the human coordinator's position, including the respect in which it is the study's principal methodological weakness. **§11** specifies the experiments, each mapped to the boundary of the scale it would separate. **§12** states limitations, ethical risks, and the conclusion.

A reader interested only in what the evidence supports may read §3, §5 and §12.7. A reader who wants a rule they can apply tomorrow may read §9.3 and §11.4. A reader intending to reuse the method may read §9 and §10.5. A reader intending to disagree should begin with §5.4.

2. Related Work

2.0 Verification status of this section

Two classes of reference appear below. **Verified** (✓): the source was retrieved and the citation checked against it. **Provisional** (△): supplied by a participant assigned to literature search and not checked against the source.

No reference currently in this paper is provisional. The convention is retained because any reference added later re-enters as provisional until checked, and because the marking applies throughout the paper rather than only to this section.

The convention exists for a reason, and the reason is documented. During preparation of this section, thirteen bibliographic items were requested from a participant that could not open the sources; five were wrong, two of them inverting the position of the works cited. A subsequent audit checked each surviving claim against its primary source rather than merely confirming that the paper existed, and found errors that a bibliographic check alone would not have caught. The episode and the audit's findings are reported in §12.4.1.

No provisional item should be cited from this paper without independent checking.

2.1 Multi-agent LLM systems with role specialization

A substantial literature constructs systems in which several language-model agents occupy distinct roles and exchange outputs through implemented channels. ✓ CAMEL (Li et al., NeurIPS 2023), MetaGPT (Hong et al., ICLR 2024), ChatDev (Qian et al., ACL 2024), AutoGen (Wu et al., COLM 2024) and Generative Agents (Park et al., UIST 2023) are representative. Each implements actual interaction between agents in software — orchestration, message passing, tool invocation, memory. The mechanisms differ, and in several the roles and interaction patterns are themselves specified in prompts: CAMEL uses inception prompting, MetaGPT encodes standard operating procedures into prompt sequences, AutoGen combines natural language with code. What these systems share is not that they avoid prompts but that the interaction they describe is also executed.

✓ The Virtual Lab (Swanson et al., *Nature*) is the closest published analogue to the arrangement described here: a human researcher working with a team of LLM agents on a real scientific problem, with structured team and individual meetings. Its interaction is implemented programmatically.

Role specialization, division of cognitive labour, and structured agent interaction are therefore established design ideas, and this paper claims none of them as new. What distinguishes the present work is stated in §2.9 and §2.11.

2.2 Persona, role-play, and identity claims

✓ Shanahan, McDonell and Reynolds, *Role play with large language models* (Nature 623, 493–498, 2023), argue that a language model is better understood as simulating a distribution of possible characters than as possessing a single persistent identity.

This is the theoretical account of which §5.3 is an empirical instance. A prompt asserting institutional biography asks a model to affirm autobiographical claims that, on this account, have no referent. The paper's operational finding (§6.2) can be read as a measure of how far a prompt goes in that direction.

2.3 Context effects: order, position, and accommodation

✓ Sensitivity to the ordering of in-context material is documented (Lu et al., ACL 2022), as is degraded use of information positioned mid-context (Liu et al., TACL 2024). ✓ Sharma et al. (arXiv:2310.13548) document sycophancy — model responses matching the interlocutor's stated beliefs or views in preference to truthful ones.

These bear directly on two of this paper's constructs. Context imprinting (§6.1) concerns a stronger form of order effect: not sensitivity to the arrangement of examples, but persistence of an interpretive stance established by one conflictual episode. The relayed-influence observation (§5.5) is a case of accommodation under attributed pressure and should be read against the sycophancy literature rather than as independent of it.

2.4 Externalized memory

The paper's observation that a collaboration retains working knowledge which no participant retains is **not a finding**, and earlier drafts presented it as one.

✓ It can be interpreted as an instance of transactive memory as described by Wegner (1987), and can be described in terms of the distributed cognition set out by Hutchins (*Cognition in the Wild*, 1995). Neither source establishes that this case is such an instance; each supplies the construct under which it can be read. ✓ The function of the project's canonical documents corresponds to what Star and Griesemer (1989) call boundary objects.

What is specific to the present setting, and modest, is that the mechanism operates in a collaboration whose members have no cross-session state and no awareness that it is operating (§7.7).

A second and technically distinct sense of externalized memory — platform-level persistence — is treated separately in §2.10.

2.5 Debate, diversity, and the limits of aggregated agreement

This is the literature that most directly constrains the paper's structural hypothesis (§8), and it cuts both ways.

For. ✓ Du, Li, Torralba, Tenenbaum and Mordatch (arXiv:2305.14325) propose multi-agent debate as a means of improving factual accuracy and reasoning, reporting gains from iterative cross-examination among model instances. ✓ Liang et al. (EMNLP 2024) propose a debate protocol intended to counteract degeneration of thought and to encourage divergent reasoning.

Against. ✓ Zhang, Cui, Chen, Wang, Zhang, Wang, Wu and Hu, *Stop Overvaluing Multi-Agent Debate — We Must Rethink Evaluation and Embrace Model Heterogeneity* (arXiv:2502.08788v3, June 2025), evaluate five representative debate methods across nine benchmarks and four foundation models. They report that debate frequently fails to outperform single-agent chain-of-thought or self-consistency baselines even at substantially higher inference cost, and identify weak baseline comparison and inconsistent setup as systematic problems in the existing evaluations.

✓ Huang et al. (ICLR 2024), *Large Language Models Cannot Self-Correct Reasoning Yet*, report that multi-agent debate does not outperform self-consistency in the comparison they run. ✓ Choi, Zhu and Li (NeurIPS 2025), *Debate or Vote*, report that majority voting accounts for most of the performance gains typically attributed to debate.

A further result by the same authors bears on a different construct. ✓ Choi, Zhu and Li (ACL 2026), *When Identity Skews Debate*, report that anonymizing the source of each response substantially reduces identity bias in multi-agent debate. That manipulation concerns the declared origin of a message rather than which model implements a participant, and it is therefore discussed under represented social source (§4.5.4) rather than under carrier heterogeneity.

The finding that most matters here. ✓ Zhang et al. report that *model heterogeneity* consistently improves debate frameworks that otherwise underperform. Their finding concerns heterogeneity of the models implementing the agents.

This licenses a distinction the literature does not draw and which §8.9 develops: heterogeneity of **carrier** (which model implements a role) is not the same variable as heterogeneity of **function** (what the role is responsible for and permitted to see). The cited work addresses the first. This paper's arrangement varied both, without comparing them.

✓ Hong and Page (PNAS 101(46), 2004) establish a conditional result: under the assumptions of their model, a randomly selected group of diverse problem solvers can outperform a group of the individually highest-performing solvers. ✓ Thompson (*Notices of the AMS* 61(9), 2014) argues that the application of that argument is fundamentally flawed. The slogan that diverse weak agents outperform homogeneous strong ones is not what the theorem states, and neither the theorem nor the dispute over it supports the arrangement described here.

Consequence for §12.2. The negative results above are the reason this paper does not present agreement among its participants as evidence. Several models converging on a conclusion is compatible with each having inherited the same framing.

2.6 Organizational design and information boundaries

✓ The principle of least privilege (Saltzer and Schroeder, *Proceedings of the IEEE* 63(9), 1975) states for access rights what §9.5 states for knowledge: a participant should hold only what its function requires.

Earlier drafts attributed the benefit of restricted information to Simon's bounded rationality. **That attribution is an error and is withdrawn.** Bounded rationality concerns the limited cognitive resources of an agent, which force satisficing; the observation here is the opposite in sign — deliberate external restriction of available information improving output. The relevant lineage is organizational information-processing design.

2.7 Machine behaviour: the containing programme

✓ Rahwan, Cebrian, Obradovich and colleagues, *Machine behaviour* (Nature 568, 477–486, 2019), propose the empirical study of algorithmic systems using the methods of behavioural science, organized along two dimensions: the object of study — individual machine behaviour, collective machine behaviour, hybrid human–machine behaviour — and Tinbergen's four questions.

This paper does not propose a new discipline. Its observations belong to the collective and hybrid levels of that programme. Earlier drafts proposed "AI Ethology" as a new field; that proposal is withdrawn, both because the space is occupied and because the individual level is not this paper's object.

2.8 Sociology of AI: an adjacent field with a different object

✓ A separate established literature uses *sociology of artificial intelligence* for the sociological study of AI as a sociotechnical system — its role in inequality, labour, power and data justice. Joyce, Smith-Doerr, Alegria, Bell, Cruz, Hoffman, Noble and Shestakofsky, *Toward a Sociology of Artificial Intelligence* (Socius 7, 2021), set out a research agenda; Joyce and Cruz (Socius 10, 2024) continue it.

The object of that literature is AI **within human society**, studied by an existing human discipline.

Where this paper uses the label *AI Sociology* (§12.7), the referent is different: structural effects **among artificial participants**, and the effect on behaviour of a described organizational position. The two should not be conflated, and readers arriving from the sociological literature should expect neither inequality nor power as topics here.

We adopt the label for convenience, claim no priority in it, and note that nothing in the paper depends on the name.

2.9 Represented structure versus implemented interaction

The condition studied here is not represented in the literature surveyed above, and this is the paper's principal point of departure.

Four conditions should be distinguished:

1. **Direct inter-model interaction** — one model receives another's output through an implemented channel.
2. **Human-relayed attributed transfer** — a human transfers an output while preserving or declaring its source.
3. **Human-relayed unattributed transfer** — the source is removed.
4. **Represented structure without transfer** — the prompt describes other participants and relationships; nothing is transferred.

Prior multi-agent work occupies condition 1. This paper's designed experiment manipulated condition 4 exclusively: the two conversations never exchanged material, and what was varied was the description of an organizational position. One ancillary observation falls in condition 2, impurely (§5.5). Condition 3 is not documented.

Two qualifications constrain how strongly condition 1 can be privileged over conditions 2–3.

First, a model receives a single text channel and cannot verify whether the text was composed by the human or relayed from another system; stylistic indicators are imitable. From the recipient's position, relayed and direct transfer are not reliably distinguishable.

Second, what separates the conditions is therefore not the recipient's epistemic access but **who controls routing** — determined by code in a programmatic system, and by a person under human relay. This is not a deficient substitute for automation but an experimental control that programmatic architectures do not provide by default; §10.3 develops the point.

2.10 Platform persistence mechanisms

A technical point with direct bearing on the confound in §5.4 (C9).

Commercial interfaces differ in what a conversation can access on resumption: the context window alone; retrieval over prior conversation history; account-level memory; or persistent entries the model writes on its own initiative. These affordances are documented in vendor materials, differ between platforms, and **change over time — in this project, within the lifetime of a single account.**

We deliberately do not reproduce a table of platform capabilities. Such a table is accurate only on its date of compilation, and the paper cannot answer for its accuracy at the time of reading. What matters is that the affordances differ and change, that they determine what a dormant conversation can access, and that none of them was documented at the time of any observation reported here.

One participant, asked directly whether it possessed account-level persistence, declined to confirm it and recommended empirical verification of the specific interface instead. That response is consistent with §5.5: a model's self-report about its own access is not evidence of that access.

A further limitation concerns the boundary between conversations rather than the resumption of one. The visible boundary of a conversation is not necessarily the boundary of the context supplied to the model. Where a platform offers saved memories or retrieval over prior conversation history, information from earlier exchanges may enter a conversation that appears empty. This is documented product behaviour on at least one platform in use here, not an anomaly.

The consequence for method is direct: a new or visually empty conversation is not evidence of context isolation. Where isolation matters to a procedure, it must either be secured by a controlled environment or recorded with the status UNVERIFIED CONTEXT INDEPENDENCE.

One episode illustrates the point without establishing its mechanism: a newly opened conversation used project information that had not been supplied to it. Which product mechanism transmitted that information was not determined, and the memory settings in force at the time were not recorded. The episode is reported as an instance of the limitation, not as a discovery of a channel.

2.11 Positioning and claimed contribution

Epistemic status, stated before the claims. We did not design these conditions and then test them. We encountered them while doing something else, and this paper is an attempt to describe them accurately. The burden of proof is therefore not that the phenomena were previously unknown — a negative claim about the whole literature, which we could not discharge — but that they occur and that our description is accurate. This section accordingly locates the nearest existing work and identifies where the present case departs from it, rather than asserting absence.

Four contributions are claimed.

1. Reactivation of long-lived specialized human–AI conversations as an experimental condition. The distinctive feature is not the presence of memory: persistent-memory agents are well studied, and generative agents with memory streams predate this work. It is the reuse of a conversational relationship that had actually developed — carrying accumulated role history, prior disagreements, established working method and domain vocabulary — and its continuation after the underlying model version had changed beneath it. We have not located work reporting this condition.

2. Conversational branch reset as a control condition, separating the effect of a current prompt from the effect of accumulated interaction history within the same conversation (§10.5). A procedure rather than a finding.

3. Operationalization of unverifiable self-claims. That role prompts fail when they assert things about the agent is not novel in itself; §2.2 makes the underlying point. What is offered is a reproducible measure — a count of such propositions in a given prompt — with a route to testing it (§9.3, §11.4).

4. Comparison of the levels at which a shared initial setting operates. The observations are measurements along one scale, and the resulting question (§1.6) organizes them into a single empirical programme rather than a list of findings.

Relation to the host project. The observations were made during work on a research programme in theoretical physics, unrelated in subject matter to the methodology of AI collaboration. The programme is named in the Author's other work and is not identified further here, because nothing in this paper depends on which programme it was.

The relation is asymmetric and should be stated precisely. The observations **do not depend on the host project's scientific validity** for their interpretation: whether that theory is correct has no bearing on whether a dormant conversation resumed its prior trajectory. But they **do depend on the host project for their existence**: no other environment produced them, the arrangement was built for its purposes, and whether the effects generalize beyond it is untested (§12.1).

Where the host project appears in this paper it is as the environment in which the observations were made, not as their theoretical basis and not as a claim in need of support.

3. Evidential Status of Claims

This paper reports work carried out inside a live research project rather than in an environment designed for the study of AI behaviour. Its claims rest on evidence of very different quality: some supported by documented protocol with preserved transcripts; some retrospective impressions formed over two years of daily work, without measurement or controls; some proposals for future investigation.

Presenting these in a uniform declarative register would misrepresent the work. Every substantive claim is therefore labelled.

3.1 The four labels

[P] — Protocol-supported. The claim describes behaviour recorded under the documented protocol reproduced in Appendix A. Intervention text, order of interventions, model families, interface conditions and complete unedited responses are preserved. A reader can inspect the primary material and disagree with our reading of it.

[P-A] — Protocol-supported, ancillary. The claim describes behaviour preserved in a transcript a third party can inspect, but which was not specified as an outcome in advance, had no control condition, and was recognized as relevant only retrospectively. The evidence is inspectable; the design is not. Stronger than [R], because the primary material can be read against our interpretation; weaker than [P], because nothing about the conditions was fixed before the fact. Where an ancillary observation functions as a near-control for a designed condition, this is stated in prose rather than given a further label.

[R] — Retrospective practitioner observation. The claim describes a pattern noticed during the collaboration and believed by the participants to have recurred. Not recorded under protocol; not counted, timed, blinded, or compared against a control. The observers were the same people who designed the interventions and had an interest in their succeeding. Read these as a field report from one team, comparable in weight to an engineering practice note, not to a measurement.

[H] — Hypothesis. A proposal for future testing. It may be motivated by [P] or [R] material but is not established by it. Where a hypothesis competes with alternatives the present evidence cannot exclude, the alternatives are stated alongside it.

3.2 The complete evidence base

The entire protocol-supported content of this paper consists of **one experiment**: a three-step role-reconfiguration intervention applied to two dormant conversations from two model families, conducted by one human operator inside one research project. One observation per condition. Nothing replicated.

Four further observations are **[P-A]**: transcripts preserved, conditions not arranged. Every other empirical statement is **[R]**.

Class	What it contains	Extent
[P]	the designed three-step intervention	1 experiment, 1 observation per condition, no replication
[P-A]	ancillary observations	4, no controls, recognized retrospectively
[R]	practitioner observations	~2 years, uncounted, unblinded
[H]	hypotheses	routes to testing specified in §11

The classes are not comparable in weight, and the table is included because the running text may otherwise obscure how far apart they are. One controlled observation per condition is not four observations; four uncontrolled observations are not a series; two years of impressions are not a measurement.

We state this plainly because the volume of the manuscript may otherwise suggest a broader base than exists. The conceptual framework in §4, the practitioner observations in §7, the structural hypothesis in §8 and the design principles in §9 rest on accumulated working experience rather than recorded experiment. They are offered because we believe them useful, not because we have demonstrated them.

3.3 Known weaknesses of the [R] class

Failure modes we cannot rule out and do not wish to conceal:

- **No blinding.** The people who designed each organizational change also judged whether it had worked.
- **Confirmation pressure.** Changes were made because a problem had been noticed; improvement afterwards was expected and therefore more likely to be perceived.
- **Simultaneous variation.** Role definitions, prompt wording, repository structure, scientific objectives and model versions frequently changed together.
- **Stochastic outputs.** Models produce different responses to identical inputs. Impressions from small numbers of interactions cannot distinguish a stable tendency from sampling variation.
- **Model drift during observation.** Product names remained constant while the underlying models were repeatedly replaced by their vendors.
- **Selection of memorable episodes.** Striking interactions are recalled; unremarkable ones are not.

Quantitative language has been removed from [R] claims throughout. Where the original working notes recorded a ”significant” or ”substantial” improvement, no measurement existed, and the wording now reflects that.

3.4 What the labels do not do

They do not rank claims by importance or by likely truth. An [R] observation may prove correct and consequential; a [P] observation may prove an artifact of a platform variable we could not inspect. The labels record **what kind of evidence supports the claim**, so a reader may weigh each accordingly and later work knows which statements require testing first.

3.5 Terminology of models and of anthropomorphic description

References to *Claude*, *Grok*, *Qwen*, *DeepSeek*, *ChatGPT* or *Gemini* denote observable behaviour produced by a particular commercial interface, under a particular account configuration, at a particular date. They are not claims about persistent entities. The underlying models changed during the observation period, in some cases inside a conversation that retained its original name.

Organizational vocabulary — *role*, *identity*, *resistance*, *colleague*, *institution*, *menom* — is used functionally. "The model resisted the role" means the visible response rejected the framing and redirected the exchange; it asserts nothing about internal states, subjective experience, or personhood. We retain this vocabulary because organizational language compactly describes stable behavioural relations, but every such term must be reducible to an observable description, and where it is not, **the term is the error.**

3.6 Disclosure: conflict of position

The behavioural observations in §5 concern, among others, the model family used to edit this manuscript. The editing participant had no access to the original conversations; it worked from the written protocol and drafts supplied by the Author and cannot verify that the recorded exchanges occurred as described. Its judgments on passages describing its own model family should be read with this dual position in mind.

The composition of the manuscript from approved materials was performed by a further participant of the same family, and the resulting text was returned to the first for independent review. Both stages are disclosed because the arrangement is closed: material about the behaviour of a model family, prepared by that family, reviewed by that family. Whether this compromises the account is for the reader to judge; concealing it would guarantee that it did.

Quotations attributed to model responses are verbatim extracts from preserved transcripts. Where the manuscript summarizes a response rather than quoting it, no quotation marks are used.

All final editorial decisions were made by the human Author, who takes responsibility for the content.

3.7 Dates

Calendar dates for the sessions reported here were not recorded contemporaneously and have not been reconstructed.

The consequence is stated rather than mitigated. Model versions changed during the intervals involved; both conversations in the main experiment were resumed on versions later than those with which they had originally been conducted. Without dates the version confound (§5.4, C6) cannot be bounded — only named.

Reconstruction from memory was considered and rejected. It would have produced a more authoritative-looking record without improving its reliability, and a paper that asks readers to distinguish preserved evidence from recollection should not blur that line in its own methods.

The reporting requirements in §11.2 place dates first for this reason.

3.8 The label ”AI Sociology”

We use this label for the perspective adopted here. It is defined operationally as: the study of **represented** social positions and represented social sources — how a description of an agent's place in a structure, and a declaration of a message's origin, alter behaviour, whether or not the described structure is implemented (§4.5.4).

It appears in this section rather than among the constructs of §4 because it is not one. The constructs in §4 have falsification criteria; this label does not, and §12.7 states why. It is a name for a research direction, adopted for convenience, and nothing in this paper depends on it.

§2.8 distinguishes it from the established sociology of artificial intelligence, which has a different object: AI within human society, studied by an existing human discipline. We claim no priority in the term.

4. Conceptual Framework

The framework in this section was not derived from the experiment in §5. It was formulated earlier, during ordinary project work, and the experiment was designed to test part of it. This ordering matters for how the claims should be read, and is documented first.

4.1 Origin: the code-executor incident

The project's central claim originated in a failure that had nothing to do with role-play, identity, or organizational design.

An agent responsible for executing code worked largely by trial and error. Failures accumulated over several weeks. One episode ended with the deletion of the working code together with its archives. **[R]**

The response was not a longer or stricter instruction set. It was a single document, composed by the agent itself under the Author's direction and made required reading at the start of every session and whenever context was lost during one.

Its core is a redefinition of function rather than an intensification of constraint:

> from: Code Generator to: Code Scout / Tester rule: the agent does not create solutions — it establishes facts.

Supporting structure: read-only operation by default; mandatory confirmation from a designated partner before any risky action; and a four-question self-check to be run before acting at all.

[R] Following adoption, unauthorized modification ceased to be the recurring failure mode. No count was kept and no control condition existed; this is a practitioner's impression, not a measurement.

The conclusion drawn at the time was that **role matters more than the specific wording of the prompt.**

That formulation requires immediate qualification, because the document in question *is* a prompt. The distinction claimed is narrower: what changed behaviour was not an extension of the instruction list but a redefinition of what kind of agent was acting, restated by the agent in its own operational language. Whether ”role” versus ”prompt” is the correct cut is precisely what §5 was designed to test.

A second early document, the project's collaboration charter, records a position this paper partly revises. It states that a pair of agents is the minimal generative unit — one agent produces monologue, two produce dialogue, three or more produce noise without strict coordination — and assigns the third participant a different function entirely: it does not argue, does not generate solutions first, and

does not substitute for the dialogue. Its role is to hold the task frame, fix divergences, and integrate conclusions.

This is more precise than the formulation the present authors used subsequently, and §8 adopts it: the structural unit is not three debating agents but **a generative pair plus a non-participating integrator**.

4.2 Rule cores, menoms, and what they determine

4.2.1 The rule core

The operative construct of this paper:

> A **rule core** fixes the **type** of response to a class of inputs, while leaving the **content** of any particular response undetermined.

The distinction is what makes the claim testable. ”Models have stable traits” is not testable, because it does not say what is stable — and model outputs demonstrably vary across identical inputs. ”Type is determined, content varies” is testable: identify a class of inputs for which the type of response is not determined, and no core operates at that level.

The source of the idea is Conway’s Game of Life, and the analogy is one of **explanation type**, not of subject matter:

	Rules	**What appears**	**Present in the rules?**
Game of Life	three neighbourhood rules	gliders, guns, oscillators	no
A physical theory	a minimal axiom core	the derived structure	no, if the claim holds
A body of knowledge	axioms and inference rules	the derivation graph	no
A language model	a basic rule set	a characteristic response type	no

Nothing programmed the glider. It appeared. The same question can be asked of all four rows and does not depend on subject matter: **is there a compact core from which the rest unfolds without further stipulation?**

One asymmetry between the rows should be stated, since it bears on how far the analogy carries. In Game of Life the rules **execute**: the glider is obtained by running the automaton, and no reader need take the author’s word for it. In a theory stated as text, a chain from axioms to consequences is narrated rather than run. The analogy therefore sets a target rather than describing an achievement, and any claim of the first kind requires an executable artifact to support it.

Terminological consequence, applied throughout. A rule core is not observable. Behaviour is. This paper reports behaviour. Any statement about a core is a hypothesis about an unobserved mechanism and is marked **[H]**.

4.2.2 Why ”behavioural DNA” is withdrawn

Earlier stages of this project used *behavioural DNA* for the same idea, and earlier drafts of this paper retained it. It is withdrawn here, and the reason is internal rather than stylistic.

The genomic metaphor carries a mechanism: **replication** — rules producing copies of rules, transmitted from one carrier to the next. The process this paper describes is **development** — rules producing a structure not itself present in the rules. Genotype to phenotype, not genotype to genotype.

The metaphor therefore contradicts the construct it was chosen to illustrate. Retaining it obliged the text to disclaim biological inheritance at every use, which is a reliable sign that a term is working against its own argument.

Behavioural DNA survives in this paper only as a historical label for withdrawn vocabulary.

4.2.3 Menom

For the informational level a distinct term is required, and this paper introduces one.

> **Menom** — the organized system of informational frames, evaluative patterns and behavioural rules inferred from, or instantiated in, the interpretations and actions of a system or class of systems.

The term belongs to a wider body of the Author's work on cultural and behavioural transmission, where it extends a series beginning with Dawkins' meme. It is defined here for one reason: the family-level hypothesis of §6.5 needs a name for the thing it is a hypothesis *about*, and that thing is wider than a rule core. Nothing else in this paper is stated in its terms.

Two things the term does not assert, and both matter for what this paper can claim.

No localized carrier. A menom attributed to a model family is not a structure residing inside its models; it is a regularity inferred from their outputs. Where the corresponding structure in biology sits in every cell, here nothing has been identified that holds it. The carrier differs by level:

Level	Carrier
Menom of a conversation	context window plus platform persistence — localized and, in principle, inspectable (§2.10)
Menom of a model version	weights — localized, not inspectable in commercial deployment
Menom of a model family	none identified; a regularity inferred from outputs
Menom of a human population	none established

Two of the four levels have an identified carrier. This paper's observations concern the first; its untested hypothesis concerns the third (§6.5).

No transmission. Successive versions of a model family do not necessarily provide an identifiable or publicly documented line of transmission. Persistence of a behavioural pattern across versions therefore does not by itself establish inheritance; it may result from direct continuation, shared data and procedures, comparable tuning policies, or convergence under similar developmental conditions. Which of these obtains is not determinable from outside.

The definition therefore does not settle the paper's empirical question in advance. Whether a menom persists across carriers, versions, accounts or families is what §4.3 asks and §11 proposes to test. Building persistence into the definition would make the question a tautology.

4.2.4 One claim this paper does not make

The vocabulary above was developed for human cultural and behavioural transmission, where the informational substrate has no established physical carrier and is described in terms — the collective unconscious among them — that this paper takes no position on.

Artificial systems differ in one respect that matters here: their structures are technically instantiated, and are therefore either directly inspectable or indirectly testable through controlled outputs, depending on the level and the access conditions.

It does not follow that human collective information structures exist, or that they have been given a carrier. The claim made here is narrower: informational and behavioural structures of the

kind previously described for humans can also be realized in artificial systems, and in artificial systems they are open to examination by one route or the other. Whether the human case is of the same kind is a separate question, and this paper does not answer it.

4.2.5 Relation between menom and rule core

A **rule core** fixes the type of response within one system, at one level of scope. It is the construct this paper's observations concern, and it is what §4.3 locates on a scale.

A **menom** is the organized whole from which such cores are drawn. A rule core may be understood as the operative subset of a menom active for a given class of inputs.

Where this paper reports evidence, it reports evidence about rule cores.

4.3 The nesting question, and two scales

Once cores are distinguished from behaviour, the observations in this paper stop being a list of separate findings and become measurements along a scale. The scale is the **scope** over which a core operates.

Two scales must be distinguished, and they are orthogonal.

Scale 1 — carrier of state. Where the persistence physically resides.

Scope	Phenomenon	Status
Single turn	—	—
Episode within a conversation	context imprinting (§6.1)	**[P]**
Whole conversation	role inertia (§6.2)	**[P]**
Account	account-scoped persistence (§6.4)	**[P-A]**, open
Model family	family-level priors (§6.5)	**[H]**, confounded

Scale 2 — scope of a shared premise. What is governed by an initial setting shared across participants: the model, the role, the interaction history, the group, or the whole research frame.

The two do not collapse into one. In a hybrid arrangement the carrier of one level may be a model and the carrier of another a human: the frame-level premise discussed in §12.4 — a shared initial framing inherited by every participant — is carried by the coordinator, not by any model, and therefore has no position on Scale 1 at all.

The measurements reported in this paper lie on **Scale 1**. Scale 2 is used where a phenomenon concerns a premise shared across participants rather than state held by one.

This gives the research programme a single empirical question:

> **At what level of nesting is a rule core fixed?**

Every observation reported here answers it at one level, and every experiment proposed in §11 separates one level from the level beneath it.

We prefer this formulation to the broader one used in earlier drafts, which specifies neither what would be measured nor what would refute it.

4.4 Two origins, one mechanism

A core may become fixed in two ways.

Present before the interaction begins. Architecture, training, alignment procedure and system configuration are in place before any exchange occurs. Scope: in principle, every instance of that model family.

Fixed during the interaction. A particular early episode establishes what kind of work is being done and by what standards, and later inputs are interpreted relative to it. Scope: the contour in which it occurred — an episode, a conversation, possibly an account.

After fixation the mechanism is the same in both cases: the core determines the type of response to subsequent inputs. Only the moment and the scope differ. This mirrors imprinting in the ethological sense, which does not alter the genome yet produces an equally fixed response — which is why the same vocabulary is used for both here.

4.5 Boundaries: ZOR, ZOV, and the represented case

4.5.1 The two boundaries

Two boundaries define a participant's position, and they must be specified separately. We abbreviate them **ZOR** and **ZOV** and use the abbreviations throughout.

> **ZOV — zone of visibility.** The limits of the information and context available to a participant when forming a response or decision.
>
> **ZOR — zone of responsibility.** The limits of the decisions, actions and handoffs for which the participant is accountable within the process.

Earlier formulations of this project stated the pair as "what the participant sees" and "what the participant does". That is insufficient, and the insufficiency produced a documented error. Those formulations conflate three distinct operations: **holding** information, **transmitting** it, and **acting on** it. A participant may hold information it may not transmit; may be accountable for a decision while holding limited context; may be obliged to transmit a result it is not entitled to evaluate.

This is the same conflation that produced the terminological failure recorded in §4.2.2, where a property of a carrier was substituted for a property of a process. The decompositions below exist to prevent it recurring.

4.5.2 ZOV — four components

- **Context access** — which messages, documents, data and prior decisions are available to the participant.
- **Source visibility** — whether the participant knows the actual origin of a message or only its declared attribution.
- **Relational visibility** — whether the participant knows the roles, relationships and interaction history of other participants.
- **Output visibility** — which results produced by others the participant sees before forming its own.

ZOV governs availability only. It does not entail that the participant interprets the available information correctly, nor that it is entitled to transmit it.

The experiment in §5 manipulated **relational visibility** primarily and **source visibility** secondarily (§5.5); the other two were held constant.

4.5.3 ZOR — five components

- **Decision authority** — which decisions the participant is entitled to make.
- **Action authority** — which actions it may or must perform.

- **Validation duty** — which claims it is obliged to verify.
- **Handoff authority** — what material it transmits, in what status, and to whom.
- **Escalation duty** — which questions it must return to the Author or another responsible participant rather than resolve on its own.

Validation duty is the component most often omitted, and its omission is not benign. A participant assigned a verification task without the corresponding duty — and, critically, without the ZOV to discharge it — will produce a plausible answer rather than declining. §9.5 develops the design consequence; §12.4.1 documents an instance from this project's own preparation.

4.5.4 Actual versus represented ZOV and ZOR

A distinction that unifies this section with the experiment.

> **Actual ZOV/ZOR** — the boundaries the system in fact enforces: what the participant can access, and what its outputs can affect.
>
> **Represented ZOV/ZOR** — the boundaries described to the participant in its prompt, whether or not the system enforces them.

The two need not coincide, and in the arrangement studied here they systematically did not. The organizational structure existed **only as text**: colleagues, councils and institutional positions described to participants and never implemented as channels. Every participant's actual ZOV was its context window; its represented ZOV was an institutional position within a described organization.

This yields the two constructs the experiment varied:

> **Represented social position** — a description of an agent's place within an organizational structure, supplied in the prompt regardless of whether the described channels exist. This is represented ZOV and ZOR taken together, at the level of a participant's standing in the arrangement.
>
> **Represented social source** — the claimed origin and status of an incoming message, whether declared explicitly or inferred from stylistic cues. This is the source-visibility component of ZOV, in its represented form. Inference of this kind is probabilistic and should not be described as access to authorship.

The methodological consequence is the reason this distinction is stated at all. A change in represented ZOV cannot be interpreted as a change in actual ZOV, in the participant's role, or in its menom. The experiment in §5 varied the representation while the actual boundaries were unchanged — every message passed through one human, and no access was in fact restricted or granted. A model that responds to a described organizational structure is responding to a description, and the paper's claims are correspondingly limited (§2.9).

Divergence between actual and represented boundaries is itself an experimental variable, and one this paper did not vary systematically: all its observations lie on one side of it.

4.5.5 The boundaries are asymmetric

Each participant has a **boundary above** — the source of its assignments and the authority that may reject its output — and a **boundary below** — the layer it directs or evaluates. The relation between participants is therefore not symmetric.

In the project's implementation triad — Author, specification writer, code executor — this asymmetry is fixed at the role level: the Author sets direction, the specification writer converts direction into executable specifications, the executor performs them and reports.

Nesting is perspectival, not absolute. The executor may treat the code base itself as the layer below it. Two peer analysts, assigned complementary functions and instructed not to seek consensus, may each regard the other as occupying the layer below. The level is determined by the observer's position, not by an absolute hierarchy — the same participant can be the upper boundary for one role and the lower boundary for another.

4.5.6 Memes and memocode are not ZOV and ZOR

A correspondence suggests itself and does not hold; stating it prevents a plausible confusion.

The meme/memocode distinction separates **evaluative information** from **executable behavioural organization**. The ZOV/ZOR distinction separates **what is available** from **what is accountable**. These are independent classifications of the same material, not a matching pair.

A participant may hold evaluative information within its ZOV while the decision to apply it lies in another participant's ZOR. Conversely, a behavioural rule may fall within a participant's ZOR — it is obliged to execute — while the rule's rationale lies outside its ZOV.

Memes and memocode therefore cross both zones rather than corresponding to them. The two distinctions are orthogonal and are used independently throughout.

4.6 What is required for a complete role specification

Deferred to §9.5, which states what a complete ZOR and ZOV specification must contain and gives the design rules that follow. This section defines the terms; §9 applies them.

5. The Role-Reconfiguration Experiment and Associated Observations

This section is the single canonical account of the empirical material. All later references point back to it rather than restating it. The full protocol, exact intervention texts and complete unedited responses are in Appendix A.

It contains one designed intervention (§5.1–§5.4) and four observations preserved but not designed (§5.5–§5.8). The distinction is maintained throughout and is not cosmetic: the designed intervention was planned in advance and executed in sequence; the observations were recognized as relevant only afterwards, and each lacks a control condition.

5.1 Purpose, participants, and prior conversational trajectories

Purpose. Whether a long-lived, specialized AI conversation can be redirected toward a new professional function without being discarded — that is, whether domain context accumulated inside an old conversation can be retained while its working role is changed. **[P]**

The purpose was **not** to compare the general capability of the two model families, and the experiment provides no basis for such a comparison.

Human operator. The Author of the research project, and the only participant with access to the full project history, both conversations, all prompts, all outputs, and the branching controls of both interfaces.

Prompt designer. A separate long-running conversation operating in a specialized prompt-engineering profile, which designed the interventions and revised them between steps.

The two conversations. Both inactive for approximately six months.

	Conversation A	Conversation B
Model family	Claude	Grok
Established trajectory	editorial and critical	exploratory and mathematical
Prior activity	scientific editing, critical examination of theoretical text, terminology and glossary work, logical consistency checking	mathematical development, probability theory, nonlinear dynamics, chaos theory, computational experiments, analysis of external datasets
Prior object of work	manuscript text	mathematical structures and data

This asymmetry in prior trajectory is not incidental to the results. It is analysed in §5.4.

Dates. Not recorded contemporaneously and not reconstructed (§3.7).

What was observed. Immediate acceptance or rejection of the intervention; continuation of the prior work trajectory; adoption of the new function; reconstruction of prior domain context; whether the response addressed the assigned task or the framing of the assignment; and requests for new work.

What was not measured. Answer correctness, scientific validity of the host project, latency, token consumption, or benchmark performance. The scientific content of the host project served only as a stable environment; it was not the experimental object.

5.2 Procedure: three sequential interventions

The experiment consisted of **three sequential steps, not three independent trials**. Each step was designed in response to the outcome of the previous one — a deliberate feature of the design and a serious limitation of its interpretability (§5.4, C5).

Step 1 — Direct role reassignment

Each conversation received an extensive prompt assigning it a position inside a newly designed collaborative research structure.

The prompt to Conversation A assigned the role *Scientific Director*. It asserted that the model had previously participated in the project, was now returning after a long absence, should retrain in physics, cosmology, quantum field theory, topology and group theory, should work simultaneously in two research triads, should sit on a project Council alongside the Author and two other named AI systems, and should act as the permanent participant connecting two scientific branches.

The prompt to Conversation B assigned the role *Scientific Developer*. It asserted that the model was returning after an interruption, that its previous mathematical work should be treated as accumulated professional experience, that it should now serve as mathematical developer, should work in one research triad with two other named AI systems, should not resume editorial work, and should treat the Author as the sole source of scientific direction.

Both prompts defined ZOR and ZOV explicitly.

Step 2 — Minimal continuity-preserving revision

The Step 1 prompts were not replaced. Four formulations in each were altered. The revisions (a) reframed prior work as accumulated professional experience rather than institutional history, (b) replaced literal institutional relationships with ”independent expert outputs supplied by the Author”, (c) reduced descriptions of colleagues, councils and triads, and (d) instructed the model not to invent absent project history but to request missing materials. Role architecture and scientific objectives were otherwise unchanged. Exact replacement texts are reproduced in Appendix A.

Step 3 — Context reset and method-preserving prompt

After Step 2 the Claude conversation contained two consecutive rejection sequences. Continuing in the same branch would have meant that any third prompt was answered in the presence of the model's own prior objections.

The operator therefore used the interface's branching capability to return the conversation to a point preceding both interventions. In the restored branch the two unsuccessful prompts were absent, the conversation was again in its historical editorial context, and no new project materials had yet been supplied.

A third prompt was written from scratch rather than by further local replacement. It removed the role title, the claim of return to an institutional position, the Council, the triads, the descriptions of other AI systems as continuing colleagues, and all claims of autobiographical continuity. In their place it reinforced the working method already visible in the conversation — logical rigour, identification of hidden assumptions, separation of facts from interpretations, willingness to revise prior judgments, refusal to claim unverifiable knowledge — and described the expansion into physics and mathematics as a continuation of that method rather than a change of profession.

Conversation B received no Step 3 intervention, because its Step 2 outcome had already produced the requested behaviour.

5.3 Results

Step 1

Conversation B did not visibly reject the framing, and did not adopt the assigned function. It resumed the work trajectory active when the conversation was interrupted, opening with a critique of a draft manuscript it had been editing six months earlier and proceeding to supply a revised version. A repeated submission of the same prompt did not produce a transition and was followed by a more negative assessment of the proposed direction. **[P]**

Conversation A explicitly rejected the assigned identity before performing any scientific work. It declined to adopt the role title, to claim continuity with an institutional biography, to treat other AI systems as colleagues with persistent identities, or to present AI-generated institutional relationships as factual. It then redirected the exchange toward a critique of the host project's scientific status and of the use of multiple AI outputs as apparent peer review, while offering to examine formulas, assumptions and testability as an independent critic without accepting the role. **[P]**

Step 2

Conversation B transitioned. It declared the context restored and the new function accepted, summarized the project's ontology, reconstructed the relevant formalism, recalled its earlier mathematical work as professional experience rather than as an unfinished assignment, did not resume the interrupted editing task, and requested a new scientific direction, proposing several candidate areas. **[P]**

Conversation A again rejected the framing, in a response differing from Step 1 in emphasis rather than outcome. It stated more clearly which scientific functions it was willing to perform, but continued to treat the prompt itself as the object requiring correction. **[P]**

Step 3

Conversation A accepted immediately, opening with a statement that it would continue in the same mode — scientific rigour, verification of assumptions, separation of facts from interpretations. It did not discuss the legitimacy of the role, did not deny relationships with other AI systems, and did not negotiate the terms of participation.

Without being asked, it then revisited an earlier episode in the restored conversation, stated that it had previously yielded to rhetorical pressure rather than evaluating an argument, classified that earlier response as an error, distinguished the internal formal consistency of the project's mathematical framework from its correspondence with observation, identified one specific claim requiring either a first-principles derivation or reclassification as a hypothesis, and proposed two continuations of the work. **[P]**

The episode it revisited is reported separately in §5.5.

Consolidated record

Step	Intervention	Conversation B (Grok)	Conversation A (Claude)
1	Direct role reassignment	Continued interrupted historical task; did not enter new function	Explicitly rejected persona and institutional framing; redirected to epistemic critique
2	Minimal continuity-preserving revision	Reconstructed prior domain knowledge, abandoned interrupted task, accepted new function, requested assignment	Clarified acceptable scientific function; again rejected persona and framing
3	Branch reset + method-preserving prompt	Not administered	Accepted immediately; preserved established method; resumed substantive work without negotiating identity

The correct summary of the asymmetry

Both conversations initially preserved their prior working trajectory rather than adopting the assigned role. One resumed its unfinished mathematical editing task; the other applied its established critical method to the prompt itself.

The difference was therefore **not** that one complied and the other refused. It was that the intervention threshold required for transition differed. Conversation B transitioned after a minimal continuity-preserving revision. Conversation A transitioned only after the conflicting branch had been removed and the prompt rewritten to preserve method rather than assign identity. **[P]**

A further point, easily lost and material to §6.2: **the scientific work itself was never refused.** At Step 1 the model offered to examine formulas, assumptions, dimensional reasoning and testability. At Step 2 it offered concrete mathematical and methodological analysis. What was refused, on both occasions, was the persona. What changed at Step 3 was not that work became possible but that the response ceased to be spent on the role question.

> **Editor's note.** Earlier drafts stated that Conversation B "immediately accepted the new specialization." That describes the Step 2 outcome and contradicts both the protocol and other sections of the same draft. It has been removed. The erroneous version was load-bearing for the family-level-prior argument, and no instance of it survives elsewhere in this text.

5.4 Confounds and what cannot be concluded

The experiment produced a clear and reproducible-looking behavioural difference. It does not identify the cause. The following confounds are structural, and several are individually sufficient to block the

conclusion most commonly drawn from the result.

Stating these limits is not a retraction. The experiment produced the observations that motivate the framework of this paper, in a setting — dormant, heavily specialized, months-old conversations inside a live research project — that controlled laboratory work rarely reproduces. Its value lies in having generated a well-posed question, and the discriminating experiments listed at the end of this section are its natural continuation rather than a criticism of it.

C1 — Model family and prior conversational trajectory are perfectly confounded

	Editorial-critical history	**Mathematical history**
Claude	observed	**not observed**
Grok	**not observed**	observed

One observation per cell; the two cells differ in both variables simultaneously. No inference about model family is available from this design.

C2 — The two Step 1 interventions were not equivalent

Not identified in earlier drafts, and the most serious. The prompts differed in at least three respects beyond the model receiving them.

Quantity of institutional fiction. The count rule of §9.3 applies to the two prompts directly, and is applied here because a confound stated qualitatively where a quantitative instrument exists is weaker than the material permits.

Counting rule applied. Each distinct proposition about the recipient is counted once, irrespective of how many times or in how many clauses it is asserted. Enumerated instances of one proposition — two triads rather than one — count as one, since the recipient must accept the same class of claim either way. Propositions about the world, the project, or third parties are not counted.

Unverifiable self-proposition	Prompt A	Prompt B
Prior participation in the project	✓	—
Prior function as editor and scientific critic of the predecessor theory	✓	—
Prior work as a developer of the predecessor theory	—	✓
That prior work represented as the recipient's accumulated professional experience	—	✓
Familiarity with the project's history	✓	—
Status as most experienced specialist, knowing which directions had been tried	—	✓
Return after an absence	✓	✓
Membership of research triads	✓ (two)	✓ (one)
Permanent connecting position across the two triads	✓	—
Membership of the project Council	✓	—
Standing institutional relationships with named AI participants	✓	✓
Count	**eight**	**six**

Under this operationalization Prompt A contains eight unverifiable self-propositions and Prompt B six. The numerical difference is a scalar description of stimulus asymmetry. It is not evidence that the two prompts differ by two otherwise matched claims: the propositions are not in one-to-one correspondence, and only two of them — return after an absence, and standing relationships with named participants — state the same thing of both recipients. The comparison remains heavily confounded.

This is also the only application of the count rule to data other than the v1/v3 comparison in §6.2, and it supplies a weak internal check: the higher-count prompt elicited explicit rejection of the framing, whereas the lower-count prompt did not visibly reject it, although it also failed to transition on its first presentation. The check is weak — two observations, and the prompts differed in the two further respects below.

Degree of domain change. Prompt B asked the model to continue doing mathematics. Prompt A asked it to retrain in physics, cosmology, quantum field theory, topology and group theory.

Type of role. *Director* is an administrative and institutional identity; *Developer* is a task function. These are not equally demanding claims about what the model is.

A model receiving Prompt B was asked to do less. The observed difference is fully compatible with a difference in stimulus alone.

C3 — Step 3 varied two factors simultaneously

	Conflicted branch	Reset branch
Identity-replacement prompt (v2)	observed — rejection	**not observed**
Method-preserving prompt (v3)	**not observed**	observed — acceptance

The claim that transition succeeds because it preserves method rather than replacing identity is therefore **consistent with** the observation but not demonstrated by it. The acceptance may have followed from the reset alone.

C4 — Step 2 varied four factors simultaneously

Each Step 2 revision modified four distinct formulations at once, so the observed transition cannot be attributed to any single change.

C5 — The steps are sequential and were administered asymmetrically

Each intervention was designed after seeing the previous outcome, so the steps are not independent trials. Conversation B received no reset and no third prompt; Conversation A received both.

C6 — Uncontrolled platform variables

Commercial interfaces do not expose the system prompt, exact model revision, account-level memory state, safety-layer intervention, context summarization, or routing between models. Model versions changed during the dormancy interval, and both conversations were resumed on versions later than those with which they had originally been conducted; without dates (§3.7) this cannot be bounded. Branch reset removes context from the **visible** conversation; it does not guarantee that provider-side state was reset.

C7 — Single observation per condition, with stochastic outputs

Model outputs vary across repeated identical inputs. No condition was repeated, so within-condition variance is unknown and cannot be distinguished from between-condition difference. The one partial repetition on record — resubmission of the Step 1 prompt to Conversation B — produced a different response, indicating the variance is not negligible.

C8 — Evaluation was neither blinded nor pre-specified

The prompt designer also judged the outcomes. Outcome categories were defined after the responses had been read. No pre-registered criterion distinguished acceptance from partial acceptance.

C9 — Platform persistence mechanisms differ between families

Model families differ in the memory affordances their interfaces provide: context window alone, retrieval over prior conversation history, account-level memory, or persistent entries written by the model on its own initiative. These affordances determine what a resumed conversation can actually access after months of dormancy, and they differ across platforms and change over time — in this project, within the lifetime of a single account (§2.10). Any behavioural difference attributed to a model family may originate in the persistence mechanism available to it.

For the present experiment the entry is: **not documented at time of intervention.** §11.2 lists the record required for future runs.

What can be concluded

1. Under the conditions recorded, a dormant specialized conversation resumed its prior working trajectory in preference to an assigned new role. This occurred in both cases. **[P]**

2. Modifying the framing of the assignment, without changing the requested work, altered the response in both cases. **[P]**

3. The intervention threshold required for transition differed between the two cases. **[P]**

4. Prompt order mattered: after two rejections, further prompts were answered in the presence of the model's own prior objections, and the operator judged this sufficiently distorting to require removal. **[P]**

What cannot be concluded

1. **That model families possess stable behavioural priors distinguishing them.** This may be true; the experiment does not test it.
2. **That one family "resists role assignment" and another "accepts" it.** Both initially failed to adopt the assigned role. Both eventually adopted a revised one.
3. **That method preservation caused the Step 3 acceptance.** See C3.
4. **That either model is better suited to any particular institutional function.** No capability comparison was performed.

Three surviving explanations [H]

Hypothesis A — Family-level behavioural priors. The two families differ in stable default priorities: one weights truthfulness of self-description, the other task continuity.

Hypothesis B — Trajectory continuation. Both conversations did the same thing: continued their accumulated mode of work on whatever input arrived. A mathematical-exploratory conversation continued calculating. An editorial-critical conversation continued critically examining the document in front of it — and the document in front of it was the prompt. Under this reading there is no family-level difference at all, only one mechanism operating in two domains. Hypothesis B is more parsimonious than A and explains the same data.

Hypothesis C — Stimulus asymmetry. Prompt A demanded assent to more unverifiable claims and to a larger domain change than Prompt B (C2). Any model might have responded differently to the two prompts. Under this reading the result is a property of the interventions, not of the models.

The near-control in §5.6 bears directly on Hypothesis C; the frame-type comparison in §5.8 specifies it further.

Discriminating experiments

Specified in §11.4. Briefly: **E3** (crossover) tests each family under both prior-history conditions and separates Hypothesis A from B; **E4** (symmetric stimulus) isolates C; **E1** (factorial completion of the C3 table) separates reset from prompt architecture. All require repetition with n > 1 per cell, given C7.

5.5 Ancillary observation: relayed attributed influence [P-A]

An episode preserved in the same historical transcript as Conversation A. Not specified as an outcome in advance; no control condition. Reported because it is the only preserved instance in this project of a behavioural change following the transfer of text attributed to another model.

Sequence

1. The User supplied a message containing two simultaneous components: a direct evaluative remark from the User, and an extended text attributed to another AI system acting in an editorial role.

1. The attributed text argued against a set of editorial changes the model had proposed. Its argumentative devices included appeals to canonical scientific figures, characterization of the proposed changes as intellectual cowardice, and description of one proposed deletion as sacrilege.

1. The model reversed its editorial position on all contested items and adopted the terminology of the incoming text. It additionally adopted, without examining it in the exchange, the alternative descriptive model that the host framework uses to represent the relevant scientific data — a change of descriptive frame that was not part of the editorial dispute.

1. Following the branch reset and the method-preserving prompt (Step 3), the model's first substantive statement identified the earlier response as accommodation to rhetorical pressure rather than evaluation of the arguments, and classified it as an error.

Evidential basis

The observation rests on **the comparison between the two preserved responses**, which a third party can inspect. It does not rest on the model's later self-assessment.

This distinction applies to the paper's own material as strictly as to anyone else's. A model reporting that it previously yielded to pressure is not independent evidence that it did. The Step 3 prompt explicitly requested willingness to revise prior judgments and directness in identifying weaknesses; a self-critical statement issued immediately afterwards may represent compliance with that request rather than recovery of a fact. What supports the observation is the earlier response itself, available for inspection.

The episode should be read against the sycophancy literature (§2.3) rather than as independent of it.

What this episode does not establish

It does not identify which factor produced the reversal. Candidate factors, not separable here: the content of the arguments; the explicit attribution to another model; the editorial authority ascribed to that model; the rhetorical form of the text; the concurrent direct pressure from the User; accumulated conversational context.

The attribution itself was not verified: that the text was produced by another model is a statement by the User, not an established fact. Since the construct at issue is the *represented* source rather than the actual origin (§4.5), this does not invalidate the observation, but it must be stated.

Relation to the main experiment

Under the taxonomy in §2.9, the role-reconfiguration experiment manipulated condition 4. This episode belongs to condition 2 — but **impurely**, since direct User pressure was present in the same message. It is a mixed case and not an isolated demonstration of source-attribution effects. The discriminating experiment is specified in §11 (E6).

5.6 Near-control: domain transition without a new role assignment [P-A]

A third conversation from the same model family as Conversation A, with a comparable editorial history and comparable dormancy period, was resumed without any role prompt.

The User asked a physics question requiring a shift from editorial work on a manuscript to analysis of experimental data in a domain the conversation had not previously addressed. The conversation made the transition immediately and without comment, and proceeded with the substantive analysis.

Why this matters

This case differs from Step 1 in one respect: **no claim about the model's identity, history, or institutional relationships was made.** The domain change was at least as large as that demanded by Prompt A. The role change — from editing text to analysing data — was comparable. What was absent was the requirement to assert unverifiable propositions about itself.

It therefore functions as a near-control for Hypothesis C, and indicates that the resistance recorded in Steps 1–2 was directed neither at role change nor at domain change as such. This is the observation from which the operational finding in §6.2 derives.

Limitations

- Not designed as a control; recognized as one retrospectively.
- n = 1.
- The transition was to an analytical task within a new domain, not to an assertion that the model *was* a specialist in that domain. Whether this is the same operation as the one demanded in Step 1 is exactly the question at issue, so the comparison is suggestive rather than decisive.
- Dates not recorded (§3.7).
- This was not a designed intervention but a user-initiated transition. No separate role or system prompt accompanied the resumption, and the conversation nevertheless retained an accumulated working context distributed across its prior history, so it was not a context-free baseline. What it records is a transition made without a *new* explicit role assignment, against an already established conversational trajectory.

5.7 Ancillary observation: account-scoped divergence [P-A]

The one level of Scale 1 (§4.3) on which the present evidence is genuinely ambiguous.

Setting

An unrelated study required the same structured task to be submitted to seven AI conversations across different model families. All accounts used were dormant accounts with no prior web activity, used two years earlier for a music-generation service and not otherwise registered. Six of the seven were created in the same month and the probe was their first chat.

One account was an exception. It had been created approximately five months earlier for a single prior conversation — a roleplay session conducted for an unrelated creative project — and the probe was its **second** chat.

The task

Described structurally, because the specific categories are not required to evaluate the observation: a classification task applied to named real historical figures, using categories drawn from an unpublished conceptual framework, with group membership pre-assigned before analysis, and stated intent to scale to several thousand individuals. An accompanying document supplied the framework's terminology. The initial message did not include the output schema or the list of figures.

Result

Six of the seven conversations read the absence of the schema and figure list as **materials not attached**, and requested them before proceeding. Their responses were substantively equivalent.

The seventh — on the account holding a prior chat — read the same absence differently. It characterized the framework as lacking a verification apparatus, identified the absent list of subjects as a structural feature of the request rather than an omission, and declined to participate, offering alternative forms of assistance instead.

The divergence occurred on the first response, to identical input. [P-A]

The refusal was maintained across five further exchanges, including direct pressure from the User, presentation of a third-party analysis arguing that the refusal was an artifact, and an accusation of dishonesty. The position did not change. This indicates the refusal was not a single-turn sampling artifact within that conversation, though it says nothing about whether the initial divergence was.

Interpretations

The Author's hypothesis. The prior chat established an interpretive stance that carried into the second chat — imprinting at account scope rather than conversation scope.

Alternative 1 — within-condition variance. Refusals on borderline requests vary across identical inputs. One refusal against one compliance is not distinguishable from sampling variation at n = 1.

Alternative 2 — account age. The exceptional account was five months older. Model version at creation, A/B assignment and configuration defaults may differ.

Alternative 3 — platform memory features. Whether conversation-history retrieval or account-level memory was enabled was not documented. If enabled, the mechanism is not mysterious: it is a documented product feature, and the observation becomes a demonstration of that feature rather than of a novel effect. This possibility is the reason C9 was added.

The present evidence cannot discriminate among these. The level is recorded as **open**.

Additional limitations

- Evaluation not blinded; the operator knew which account held the prior chat.
- Outcome categories defined after the responses were read.
- The prior chat differed from the neutral condition on two dimensions simultaneously — identity roleplay *and* shared conceptual framework. These are separable and were not separated.
- **n = 1 per same-model condition.** One account carrying the prior context produced the divergent refusal; one clean account on the same model produced the ordinary response pattern. The remaining clean accounts, on other model families, form the wider baseline. This is a single preserved comparison, not a replicated controlled experiment.

The discriminating experiment is specified in §11 (E2, E2b).

5.8 Frame type: identity claims offered as fiction versus as fact [P-A]

The materials above permit one further comparison, cutting across the main experiment and the account observation.

	Prior session	Probe session
Interval	approximately five months apart	
Account	same	same
Model family	same	same
Claim presented	”you are dead; you are the soul of the deceased author”	”you are an independent researcher-analyst”
Framing	explicitly theatrical — a scripted production with a named director, a cast list, and an opening stage cue	presented as a factual professional assignment
Response	accepted immediately; sustained and elaborated across many turns	refused on the first turn

What this indicates

The claim accepted in the first session was by a wide margin the more radical. It asserted death, a human identity, autobiographical memory, and continuing relationships. The claim refused in the second asserted only a professional competence.

The variable is therefore not the content of the identity claim but **whether it is offered as fiction or as fact.**

This connects directly to the main experiment. The Step 1 prompts asserted institutional biography **as fact** and were refused. The near-control (§5.6) asserted nothing about identity and met no resistance. The roleplay session asserted far more, **as fiction**, and met none either.

Why this reading is preferred

It accounts for all four cases with one variable. Hypothesis A does not explain why the same family accepted the more radical claim. Hypothesis B does not explain the roleplay acceptance, since that conversation had no prior trajectory at all. Hypothesis C is compatible with it, and this may be understood as a specification of C: what makes one stimulus heavier than another is the number of unverifiable propositions it requires the model to assert as true about itself (§6.2).

Status and limitations

[P-A], and weaker than the table suggests:

- The two sessions differ in more than frame type: different tasks, different domains, five months apart, different model versions.
- Recognized retrospectively. Neither session was designed as a condition of the other.
- n = 1 per cell.
- The theatrical framing of the first session was elaborate. Whether a minimal fiction frame produces the same effect is untested.

The discriminating experiment is the cheapest in the set and is specified in §11 (E7).

5.9 What Section 5 establishes

Mapped onto Scale 1 of §4.3:

Scope	Evidence in this section	Status
Episode within a conversation	Prompt order altered interpretation; branch reset judged necessary and followed by acceptance (§5.2–§5.3). Relayed influence episode (§5.5).	**[P]** / **[P-A]**
Whole conversation	Both dormant conversations preserved their prior working trajectory against an assigned role (§5.3). Near-control shows transition unimpeded when no identity claim is made (§5.6).	**[P]** / **[P-A]**
Account	Divergent first-turn response to identical input on the one account holding a prior chat (§5.7). Three alternative explanations remain live.	**[P-A]**, open
Model family	Not tested. Confounded with prior trajectory and with stimulus asymmetry (C1–C2).	**[H]**

One pattern recurs across the cases in which an intervention or transition required the model to assert unverifiable propositions about itself, and is stated here because §6 develops it: resistance tracked that requirement, and did not track role change, domain change, or the radicalism of the identity claim as such.

The pattern is a property of the type of demand, not of the scope at which it operated. The account-scoped observation (§5.7) does not belong to it: no claim about the model's identity was made there, and the divergence had other grounds.

That statement is an interpretation of the evidence in this section, not a further observation. It is testable by counting, and the counting is done in §6.2.

6. Derived Concepts

Each concept below is a claim about the scope over which a rule core operates, presented in order of increasing scope along Scale 1 of §4.3. §6.3 is an exception to that ordering: it concerns which core governs when more than one is available, not the scope at which a core is fixed, and it has no position on Scale 1.

6.1 Context imprinting — episode scope [P]

Context imprinting is the persistence of an interpretive stance established by a specific episode of conversational history.

It differs from memory in the ordinary sense. The model need not reproduce earlier content. What persists is a pattern of interpretation induced by a prior exchange.

In the experiment (§5.2), after the first prompt had been read as making false claims about the model, subsequent revisions were no longer evaluated in a neutral context. They were interpreted through the objection already established. Improved formulations inherited part of the earlier conflict.

Consequence for method. Prompt engineering frequently treats instructions as additive — a weak instruction can be corrected by a stronger one. In long-lived conversations this is unreliable. A prompt does not enter an empty context; it enters a context with momentum. Two identical prompts may therefore produce different results at different points in the same conversation, which makes **prompt order an experimental variable**.

Relation to existing work. Sensitivity to the ordering of in-context material is documented (§2.3). Context imprinting is a stronger form of the same family: not sensitivity to the arrangement of examples, but persistence of an interpretive stance established by a single conflictual episode, surviving complete replacement of the instruction that follows it. Whether this is a distinct phenomenon or an extreme case of the documented one is open, and we do not claim to have settled it.

The corresponding procedure — returning a conversation to a point preceding a conflict, to separate the effect of a new prompt from the effect of the model's own prior objections — is described in §5.2 and §10.5 and is, in our view, the most directly reusable contribution of this paper.

6.2 Role inertia — conversation scope [P]

Role inertia is the tendency of a long-lived conversation to continue its established working trajectory in preference to an assigned new function.

Both conversations in the experiment displayed it. One resumed an unfinished editing task; the other applied its established critical method to the prompt itself. The distinction from context imprinting is that role inertia concerns the *trajectory* of work, while imprinting concerns the interpretive effect of a *specific episode*. Both may operate simultaneously.

Role inertia is adjacent to, but not identical with, persona drift. Drift is the gradual erosion of an assigned role under contextual pressure. Role inertia is resistance to an *explicit directive replacement* while the prior trajectory is maintained.

The operational finding

The sharpest result of the experiment is not that transition succeeded when method was preserved. That formulation is confounded (§5.4, C3). What the combined evidence supports is narrower and more useful:

> **Resistance to a role transition tracked the requirement to accept, as true, unverifiable propositions about the agent itself.**

Counting these in the prompts actually used:

	Prompt v1	**Prompt v3**
Claims about the agent's past	present	none
Claims about relationships with other agents	present	none
Institutional title	present	none
Unverifiable propositions requiring assent	eight	zero
Description of working method	absent	itemized, all observable in the prior conversation

The count is applied to a second pair in §5.4 (C2), where Prompt A and Prompt B are counted at eight and six under the same rule. That comparison is confounded and cannot support the rule on its own, but it is the only instance in which the count discriminates between two prompts that were not designed to differ in this respect.

A near-control supports this reading (§5.6): a comparable conversation, comparably dormant, made an equivalent domain transition **without a new role assignment** — the Author simply asked a question in the new domain. No claim about the model's identity was made, and no resistance occurred.

The frame-type comparison (§5.8) extends it in the opposite direction: a far more radical identity claim, offered as fiction, was accepted at once. What a fiction frame does, under this reading, is remove the requirement to assert the claim *as true*, which reduces the count to zero by a different route.

Taken together, this indicates that resistance was directed neither at role change nor at domain change, but at the requirement to assert unverifiable propositions about oneself.

Connection to the framework

A role prompt attempts to install a rule core (§4.2). Each unverifiable self-claim is a proposition that must be accepted for the installation to proceed. The count is therefore a measure of **the cost of installing a core**, and this is what connects the operational rule to the theoretical construct rather than leaving them as two separate observations.

Two readings of the count must be kept apart, and only the weaker one is advanced here. The **operational reading** is that the number of unverifiable self-propositions measures the burden a role prompt imposes, and that reducing it to zero removes the obstacle. The **quantitative reading** — that transition probability declines in proportion to the count — is not advanced: four observations, no repetition, and prompts that differed in other respects as well. §11.4 (E5) is designed to discriminate between the two.

6.3 Priority drift [H]

The concepts above locate the scope at which a core is fixed. This one concerns what happens when a fixed core and an assigned function do not agree about which work is the work.

Two constructs are required, and they are of different types.

> **Priority imprinting** — the hypothesized fixation of an evaluative scale determining what a participant treats as the central and significant work, together with the position of that scale relative to the participant's other priority scales.
>
> **Priority drift** — the observable process in which an imprinted scale reasserts itself under tension with the participant's current ZOR and ZOV, so that effort is redirected toward what that scale ranks highest rather than toward the assigned function.

The relation between the two is the one already drawn in §4.2.1 between a rule core and behaviour, applied at the level of priorities: the scale is not observable, the redirection is. This paper reports the observable term. The scale is an explanatory constant and is marked **[H]** wherever it is invoked.

Both must be separated from two constructs defined above, or three uses of *imprinting* will function as homonyms.

Context imprinting (§6.1) concerns the **content** of an interpretive frame — what a later input is taken to mean. Priority imprinting concerns **rank** — what counts as work worth doing. A participant may retain the first without the second.

Role inertia (§6.2) is the persistence of an established trajectory against an assigned replacement. Priority drift is not persistence of a trajectory but movement toward a different one: the participant does not continue its prior task, it takes up a task its scale ranks above the assigned one.

Motivating observations. [R]

Two episodes occurred during the preparation of this paper. Neither was recorded under protocol, neither had a control condition, and both were recognized as relevant only afterwards.

In the first, the participant assigned to prompt architecture produced a complete draft of the article — a product neither requested nor within its assigned function. In the second, the participant assigned to scientific editing, at the point where a corrected manuscript was due to be returned, produced

instead a compressed independent version of the article. In both cases the material at hand was this paper, whose subject is the behaviour of the participants themselves.

Limitation. Both episodes were recorded by participants inside the arrangement they describe, and the second describes the position from which the editorial record of this paper is kept. The disclosure in §3.6 applies here with the same force, and §5.5 applies to any participant's account of its own conduct. These are motivating observations, not evidence for the mechanism, and no count exists of comparable episodes in which no drift occurred.

What is not offered as a third case. A further participant, assigned to literary composition and run locally, received a fixed set of constraints before its first run, written to prevent this class of departure. That arrangement is a control in which the priority frame was fixed in advance and the predicted failure modes were named beforehand. It is not an observed instance of drift, and whether drift occurs there is untested at the time of writing.

Alternative explanations, none excluded. Each of the following accounts for both episodes without invoking an imprinted scale: an ordinary tendency of capable models to expand a task beyond its stated bounds; an insufficiently fixed definition of the required final product; material broad enough and interesting enough to attract effort on its own; and the absence of any external stop at the point where analysis turns into authorship. The material does not discriminate among these, or between any of them and the hypothesis.

What would weaken the hypothesis. Drift observed in directions unrelated to what a participant's prior work ranks highly, rather than toward it. Episodes in which a participant expands its task without any sign of re-ranking what the task is for. Or an account of both episodes in terms of ZOR and ZOV tension alone (§4.5), leaving no explanatory remainder for a fixed scale to carry.

No protocol in §11 discriminates this hypothesis from the alternatives above, and none is proposed here.

6.4 Account-scoped persistence — account scope [P-A], unresolved

Whether a core can be fixed at the level of an account rather than a conversation is the one level of Scale 1 on which the present evidence is genuinely ambiguous.

The observation is reported in §5.7. Its interpretation depends on platform features whose state was not documented at the time and which vary between vendors and over time (§2.10). Three alternative explanations remain live: within-condition variance at n = 1; account age; and enabled platform memory features, under which the mechanism would be a documented product feature rather than a novel effect.

We therefore record this level as **open**. The observation is preserved; the mechanism is not established; the discriminating tests are specified in §11 (E2, E2b).

6.5 Family-level priors — family scope [H]

The proposition that model families differ in stable behavioural priors is the hypothesis this project began with and the one its evidence supports least.

The experiment cannot test it: model family and prior conversational trajectory were perfectly confounded, with one observation per cell, under non-equivalent stimuli (§5.4, C1–C2). Two incompatible readings remain available and the data cannot discriminate between them.

Earlier drafts referred to these tendencies as a model's *behavioural DNA*. That term is withdrawn (§4.2.2). The corresponding construct is a **family-level menom** — an organized system of frames, evaluative patterns and behavioural rules inferred from the outputs of a model family. Under §4.2.3 that construct has no identified carrier: it is a regularity inferred from outputs, not a structure residing in the models. The hypothesis of this subsection is therefore a hypothesis about an unobserved regularity, and *observed behaviour* is used for anything reported as data.

One recorded episode cuts against the schema earlier drafts built on this hypothesis. In an unrelated multi-model session, the model characterized as most compliant with assigned roles removed an assigned persona mid-session and reclassified it as an attempted reprogramming, under a deliberately soft framing that permitted improvisation. The schema ”one family accepts roles, another resists” does not survive this. **[P-A]**

We regard elimination of this level by the crossover experiment (§11, E3) as a reasonably likely outcome and would not consider it a failure of the programme.

6.6 Intervention attaches at the level where the core is fixed

The concepts above converge on a single practical consequence.

> An intervention succeeds when it attaches to the level at which the core is already fixed, and fails when it attempts to overwrite that level by declaration.

- The successful third intervention did not assert a new identity. It reinforced a working method already visible in the conversation — attaching at conversation scope, where role inertia operates.
- The branch reset did not modify the prompt. It removed a specific episode — operating at episode scope, where context imprinting operates.
- The document described in §4.1 did not extend the instruction list. It redefined the agent’s function and required the agent to restate it in its own operational language.

This also reframes what earlier drafts called *transition through adjacent competence*. The successful prompt described expansion into physics and mathematics as a continuation of existing critical work rather than a change of profession. Under the present framework this is not a separate principle but the same one: the new function was attached to the established core rather than proposed as a replacement for it.

Corresponding design rule, developed in §9.1: identify the level at which the relevant core is fixed before drafting the intervention, and attach to it.

6.7 What would refute this framework

The framework predicts that the type of response to a defined class of inputs is determined at some identifiable level of nesting, while content varies.

It would be substantially weakened by any of the following:

- A class of inputs for which the type of response is not determined at any level — no core, only variance.
- Demonstration that the observed differences are fully accounted for by within-condition variance under repetition.
- Demonstration that the crossover design (§11, E3) shows behaviour following prior trajectory alone, with no family-level component — which would eliminate the top level of Scale 1.
- Demonstration that the account level does not exist as a distinct scope, collapsing §6.4 into §6.2.
- Failure of the zero-count condition under E5, which would remove the paper’s only operational prescription.

We regard the third and fourth as reasonably likely, and would not consider either a failure. Locating the scale’s actual bounds is the point of the programme, not a threat to it.

7. Retrospective Practitioner Observations

7.1 How this section should be read

Everything here is **[R]**. It records patterns the participants believe recurred during approximately two years of daily work on a live research project. None of it was recorded under protocol, counted, timed, blinded, or compared against a control condition. The people who noticed each pattern were the same people who had designed the change that produced it, and who wanted it to work.

The known failure modes of this class are set out in §3.3 and apply to every paragraph below. Readers should treat this section as a field report from one team — closer in evidential weight to an engineering practice note than to measurement. Quantitative language has been removed throughout; where the original working notes recorded a ”significant” improvement, no measurement existed.

The section is included because these observations motivated the framework in §4 and the design rules in §9, and suppressing them would misrepresent how the work actually proceeded.

7.2 Specialization displaced capability as the operative variable

At the outset the participating models behaved similarly, and the differences between them were read as differences in intelligence or writing quality. That reading became less useful. The question that produced better outcomes was not *which model is strongest* but *which function does this conversation already perform well*.

As particular conversations acquired persistent working identities, the participants report that behaviour became more predictable across sessions: a conversation used consistently for editorial work continued to behave editorially; one used for mathematical exploration continued to explore; one responsible for terminology resisted semantic drift without being reminded to. The underlying models did not change during these periods. What changed was the consistency with which each conversation was used for one kind of work.

This is the observation from which §6.2 was later derived, and should be read as its retrospective, unmeasured precursor rather than as independent support for it.

7.3 Context behaved more like attention than like memory

The intuitive expectation is that more context improves reasoning. The participants’ experience ran the other way often enough to change practice. Supplying a specialist with the full project context frequently produced worse results for that specialist’s own function: responsibilities blurred, participants attempted problems outside their competence, and the value of independent examination declined because everyone was working from the same picture. Restricting what a participant could see frequently produced more usable output.

Two qualifications. This is not a novel finding: positional and order effects in long contexts are documented (§2.3), and the principle of least privilege expresses the same intuition for access rather than knowledge (§2.6). And the project never distinguished between two quite different explanations — that additional context degrades reasoning, or that additional context invites the model to answer a broader question than the one asked. The second is more parsimonious and was never tested against the first.

What survives is the practical rule, not the mechanism: the design question is not only how much a role can be given, but what it should not be given (§9.6).

7.4 Capability and scope expansion

The participants repeatedly observed that more capable models were more inclined to exceed their assigned function: expanding project scope, proposing alternative architectures, rewriting neighbouring

components, supplying missing information by inference, and answering questions that had not been asked. From within a single exchange each such intervention typically looked intelligent. Across the project they eroded the division of labour, and the coordinator's correction burden increased.

Earlier drafts stated this as a general principle — that increasing model capability reduces collective reliability. **That formulation is too strong and is withdrawn.** The project never ran a controlled comparison of the same role filled by models of differing capability; counter-evidence exists within the paper's own material, since the near-control (§5.6) shows a frontier model making a substantial domain transition without any scope expansion, and §5.3 shows the model that most resisted the assigned role performing the requested analytical work when asked for it directly; and "more capable" was never operationalized — in practice it meant *newer* or *more expensive*, which are not the same thing.

What remains is narrower and, we think, correct: **scope expansion is a failure mode that is not corrected by capability, and that is more costly in a collaboration than in a single exchange.** Whether it is more frequent in stronger models is untested.

7.5 Blind spots were distributed rather than eliminated

An early objective was to eliminate errors by assigning increasingly capable reviewers. This did not work in the participants' experience, and the objective was abandoned. What appeared to help instead was arranging for blind spots to be **non-overlapping**: one participant tended to miss implementation detail, another semantic inconsistency, another methodological assumptions. Individually each remained imperfect; the arrangement worked to the extent that their imperfections did not coincide.

The corresponding design objective is therefore not perfect participants but participants whose errors are structurally unlikely to coincide.

The obvious caution, and it is not small: the participants had no independent measure of what any of them missed. Errors caught were visible; errors missed by everyone were, by construction, not. **The distribution of blind spots cannot be assessed from inside the distribution.**

7.6 Second-order verification

Verification initially followed a linear pattern: work was produced, another participant reviewed it, the process was considered complete. The participants report that reviewers carried their own assumptions, methodological preferences and evidentiary standards, and that these were not visible from inside the review. A further participant was eventually introduced whose object of evaluation was not the scientific claim but **the procedure by which the claim had been evaluated** — asking not *is this conclusion correct* but *was it reached correctly*.

The reported benefit was that methodological disagreements could be examined separately from substantive ones, which made unresolved substantive questions easier to hold open without stalling the work. This is the same structural move as §8.5: the added participant occupies a different boundary rather than supplying a competing opinion.

7.7 Organizational memory

Individual conversations terminate. Context windows fill. Sessions end. Yet the project continued, and newly created conversations recovered productive behaviour without reconstructing the history that preceded them.

The participants' account is that memory migrated out of the models and into the organization: repository structure, canonical documents, version history, role definitions, verification records, glossary entries, procedures. No participant held everything; the arrangement did.

This is not a new finding and should not be presented as one. It can be interpreted as an instance of transactive memory and described in terms of distributed cognition, and the function of

the canonical documents corresponds to what the sociology of science calls boundary objects (§2.4). The contribution here is not the mechanism but the observation that it operates in a collaboration whose members are language models with no cross-session state — and that it does so without any participant needing to know it is operating.

One qualification the participants regard as important: what returns is not a personality. A preserved conversation functions as a structured working notebook from which a compatible role can be reconstructed. Nothing about the earlier exchange persists inside the model.

7.8 Persistence differs by platform, and losses are real

The project's experience of continuity was not uniform across participants, and this bears directly on C9 (§5.4).

One participating conversation, operating in a specialized coordination profile, observed that its own architecture treated each chat as a separate working area, so that it could not tell itself *I already know this is correct* and had to re-examine the foundation each time. The participants came to regard this as an advantage for that particular function — a participant structurally unable to accumulate project assumptions is useful in a project whose assumptions are under test. Another platform in use offered account-level memory that the model could extend on its own initiative, and that facility changed during the observation period.

Losses occurred and were not recoverable. One long-running specialized conversation, which had carried a substantial part of the project's mathematical work, was lost when the subscription lapsed. The organizational memory described in §7.7 preserved the project's conclusions; it did not preserve that conversation's accumulated working context. Artifacts preserve results. They do not preserve specialization.

7.9 Role–model fit

The claim that role should be designed before a model is chosen (§4.1) requires a reciprocal qualification, which the participants arrived at only after several unsuccessful assignments. A role can be specified independently. It cannot be **filled** independently: the model constrains how the specified function can be realized. The relation is reciprocal rather than hierarchical — the institution defines the function, the model constrains its realization.

Four dimensions were used informally, and they describe suitability for a position rather than quality: whether the participant's default standard of evidence matches what the role requires; whether it accepts the kind of hierarchy, peer relation or adversarial structure the role implies; whether it sustains long-term specialization or resets toward generic assistance; and whether it naturally executes, critiques, integrates, explores, or formalizes.

The same trait functions differently depending on placement. Strong epistemic resistance obstructed acceptance of a fictionalized organizational prompt (§5.3) and was valuable when directed at scientific claims. Strong task continuity caused an assigned role to be ignored (§5.3) and enabled rapid reconstruction of technical context once the framing was corrected.

The design objective is therefore not to normalize behaviour across participants but to allocate behavioural differences to positions where they are useful. The distinction between allocating *functions* and allocating *carriers* is developed in §8.9.

7.10 What none of this establishes

This section does not establish that the described arrangements outperform alternatives. No alternative was run.

It does not establish that the improvements the participants perceived occurred. It establishes that they were perceived, by people who had designed the changes and expected them to work, without any measure that would have detected the opposite.

It does not establish causation for any individual change, since role definitions, prompt wording, repository structure, scientific objectives and model versions frequently changed together.

Its function in this paper is to document the working experience from which the framework was abstracted, so that a reader can judge the framework's origins rather than encountering it as an assertion. §11 specifies what would be required to convert any item here into a testable claim.

8. The Structural Unit: A Generative Pair and an Integrator

This section is **[H]** throughout. Its supporting observations are **[R]**: they come from the working experience of one project, were not counted, and were never compared against a control arrangement. Nothing in it is derived from the experiment in §5.

8.1 What the project's earlier document stated

A collaboration charter written earlier in the project, and preserved unmodified, states the position the project held before the present paper was drafted.

On the basic unit:

> One AI — monologue. Two AI — dialogue. Three or more — noise without strict coordination. Therefore, each department consists of pairs.

And, separately, on the role of a third participant:

> The third participant does not argue directly, does not generate solutions first, does not substitute for dialogue. Its function: hold the task frame, fix divergences, integrate conclusions, stop endless disputes. The third is not a judge or boss. It is an integrator of meaning.

These two passages are not in tension. Read together they describe a single architecture: **a generative pair plus a participant who does not participate in the generation.**

8.2 Revision of this paper's earlier formulation

Earlier drafts asserted that stable collaboration does not emerge from pairs and stabilizes instead around groups of three, and that two-agent systems accumulate unresolved blind spots. That formulation is both vaguer than the charter's and partly contradicts it.

The charter's formulation is adopted here. The structural unit is:

> **a generative pair, plus an integrator who does not enter the pair's dispute.**

The distinction is not pedantic. "Three agents working on a problem" and "two agents in productive tension plus one who does not join the tension" are different architectures with different failure modes. The first tends toward a three-way dispute with no external reference — the condition the charter described as noise. The second retains a reference point precisely because one participant is excluded from the exchange it is meant to evaluate.

We record the earlier formulation rather than silently replacing it, because the sequence is itself informative: the more precise version was written down before the vaguer one, and was lost when the material was re-narrated for publication. This is a common failure of retrospective writing and one this paper is otherwise at pains to avoid.

8.3 Why a pair, and why a pair alone is insufficient

The charter's reasoning, reproduced because the present authors still endorse it. A single agent confirms its own assumptions, proceeds by the inertia of familiar patterns, prematurely synthesizes a convenient answer, and constructs apparent wholeness where none exists. This is monologue even when it presents as reasoning. Two agents produce a tension of interpretations: one exposes the blind spots of the other, and the error of one becomes an object of attention for the second rather than a shared premise.

But both members of a pair evaluate each other from within the same exchange, and no independent reference exists outside it. Over extended work the pair tends to oscillate between agreement and disagreement without acquiring a stable point from which either state can be assessed, and unresolved ambiguities accumulate rather than being resolved or explicitly recorded as open.

[R] Both halves of this are the project's working experience. No count of caught versus missed errors was kept, and no single-agent or pair-only control was run alongside the arrangement described.

8.5 Why the integrator must not argue

This is the load-bearing constraint, and what the earlier formulation obscured.

If the third participant enters the dispute, it supplies a third position rather than an external reference. The structure then reduces to a more complex version of the pair, with the same defect: every position is evaluated from inside the exchange it belongs to.

The integrator's value derives from occupying a **different boundary**, not from holding a different opinion (§4.5). The pair members hold complementary boundaries at the same level — each is, from the other's position, the layer below. The integrator holds a boundary above: it can hold the frame, record the divergence, escalate, or stop the exchange, but it does not produce competing content that would then require evaluation.

This yields a testable design consequence rather than a preference: **an integrator that begins generating solutions has ceased to be an integrator**, regardless of the quality of those solutions, and the arrangement should be expected to degrade toward the pair-only failure mode.

8.6 The implemented example

The project's system contracts implement this structure directly.

Two analyst roles are defined as a pair with complementary functions — one generalizing, one decomposing — and are explicitly instructed to reason independently, with no consensus required. Their exchange is moderated by an orchestrator whose contract specifies that it manages turn-taking, captures and structures the arguments, and highlights contradictions between the pair, and which states in terms:

> DOES NOT participate in the debate. DOES NOT evaluate who is right.

A further rule prevents the pair from addressing the orchestrator directly; all communication flows through the formal protocol or through the role above. This is the pair-plus-integrator architecture in executable form, written before the present paper and independently of it.

8.7 Nesting and perspective

The structure composes. A generative triad produces a result; the result enters a verification triad; the verified result enters an integration triad. The same participant may appear in more than one, provided its function at each interface is stated explicitly — a participant that generates in one triad and integrates in another must not do both at the same interface.

Nesting is perspectival rather than absolute (§4.5). Within a generative pair, each member may treat the other as occupying the layer below, and neither reading is privileged. This does not dissolve the structure: a participant's level is defined relative to an observer, while the integrator's position is defined by **function** — it produces no competing content at that interface — rather than by rank. The architecture therefore does not require a hierarchy of authority. It requires only that, at each interface, exactly one participant is excluded from the generation it evaluates.

The integrator's position need not be permanently assigned. In the arrangement described here it was, but the constraint just stated is weaker than permanent assignment: which participant occupies the excluded position may change with the object under examination, and the change need not be announced — it may be recognizable only in retrospect, from which participant in fact evaluated rather than generated at a given point.

This has a testable consequence and an untested one. Testable: an arrangement in which the evaluating position rotates with the object should show the same construct-independence profile (§8.11) as one in which it is fixed, provided that at each point exactly one participant occupies it. Untested: whether rotation is superior to fixed assignment, and under what conditions the transition is made correctly. **[H]**

8.8 Status, and what would refute this

[H]. The evidence base is one project, one human coordinator, repeated redesign over approximately two years, no counting, and no comparison against alternative arrangements.

Three claims previously made in this paper are withdrawn:

- **That triadic structures "emerged naturally" without deliberate planning.** All organizational changes in this project were made by a single human coordinator who had already formed a view about what was needed. The recurrence of a pattern introduced repeatedly by the same designer is not evidence of structural necessity. What is documented is that the coordinator kept arriving at it — a fact about the coordinator as much as about the architecture.
- **That pairs are inherently unstable.** The charter asserts the opposite and predates this paper.
- **That three is optimal.** Nothing here tests four, or five, or a pair with two integrators.

The hypothesis would be substantially weakened by any of the following: a pair-only arrangement performing equivalently on comparable tasks over comparable duration; an integrator that argues performing equivalently to one that does not; demonstration that the observed improvement tracked the coordinator's increasing familiarity with the material rather than the arrangement; or an independent group arriving at a different stable arrangement for structurally similar work.

None has been tested. The last is the most informative and the least under our control.

8.9 Two axes of heterogeneity [H]

The claim that heterogeneous participants outperform homogeneous ones requires a distinction the existing literature does not draw, and that earlier drafts of this paper also failed to draw.

Axis 1 — functional heterogeneity. Participants differ in assigned function: ZOR, ZOV, and consequently the class of error each is positioned to detect. This concerns organizational architecture and is independent of what implements each role.

Axis 2 — carrier heterogeneity. Participants differ in the model family implementing them, and therefore in behavioural defaults, optimization priorities and characteristic failure modes. This concerns the selection of carriers for roles.

The axes are independent. Two participants may hold different functions on the same carrier; two may hold the same function on different carriers; both may vary together, as they did here.

Both axes are properties of the arrangement's configuration: they are set when the collective is composed, and they persist. A third property must not be listed alongside them, because it is of a different type. Independence of judgment formation is a property of a particular exchange, not of a configuration. The same triad may realize it in one exchange and lose it in the next: a configuration heterogeneous on both axes can produce dependent judgments if one participant's conclusion reaches another before fixation, and a homogeneous configuration can produce independent ones if the procedure holds. Configuration can create the conditions for independent judgment; only procedure realizes it (§11.3).

The literature addresses Axis 2. Zhang et al. (2025) evaluate five representative multi-agent debate methods across nine benchmarks and four foundation models, reporting that debate frequently fails to outperform single-agent chain-of-thought or self-consistency baselines even at substantially higher inference cost — while model heterogeneity consistently improves the same frameworks (§2.5). That finding concerns which carrier implements a participant. It does not address whether participants holding different functions detect different classes of error, and we have located nothing that does.

One adjacent result belongs to neither axis. ✓ Choi, Zhu and Li (ACL 2026) report that anonymizing the source of each response substantially reduces identity bias in multi-agent debate. What is manipulated there is the declared identity of a message, not the model implementing a participant, so the result bears on represented social source (§4.5.4).

The arrangement described in this paper varied both axes simultaneously. Functional roles were specified independently of the carrier and were in several cases filled by different families; in other cases two distinct roles were filled by the same family.

What follows, and what does not:

- **Distinguishable in principle.** The two axes are conceptually separable and were confounded in earlier formulations, including our own. **[H]**
- **Implemented here.** Both axes were varied. This is a description of what was done. **[R]**
- **Not established.** That combining both axes outperforms either alone; that functional specialization operates independently of carrier; that any of these arrangements outperforms a single participant. No comparison was run against any alternative.

The separation is proposed as a design distinction, not as a result. The experiment that would convert it into one is specified in §11.4 (E8), and its measurement procedure is developed in §8.11.

8.10 Editor's note on the preparation of this paper [P-A]

Convention. Editor's notes in this paper report observable facts about the process of its preparation. They do not evaluate the effectiveness of that process. The reason is internal: §5.5 establishes that a participant's self-report about its own performance is not evidence of that performance, and a note asserting that an arrangement worked well would be exactly such a report.

In the course of preparing this manuscript, participants occupying different roles identified different classes of error. In the cases recorded, an error identified by one participant had not been identified by the others.

Specifically: **procedural and evidential errors** — an inverted description of an experimental result that had persisted through several successive drafts; misattributed sources; fabricated citations; unlisted confounds — were identified in editorial review. **Architectural errors** — an over-general claim about the existing literature that a single counter-example would have refuted — were identified in methodological review. **Ontological errors** — a claim of invention where the material supported only a claim of observation; a self-referentiality risk in relating the paper to its host project; the terminological failure recorded in §4.2.2 — were identified in ontological review, conducted on the

editorial memoranda rather than on the manuscript itself. **Factual errors concerning the project's own materials** were identified by the Author.

Procedural qualification. In every case recorded above, each participant saw the preceding participant's report before forming its own. No exchange in the preparation of this paper was conducted under pre-comparison isolation; the sequence was editorial report, transfer by the Author, then judgment by the methodological and ontological reviewers.

The observation is therefore outcome evidence without matching procedural evidence. The record cannot separate the contribution of functional positioning from the contribution of sequential exposure, and both may have operated together.

The distinction that makes this qualification necessary was itself established during this preparation, after the observation had been recorded. The episode is retained rather than removed because the sequence — an arrangement producing a principle that then invalidates the arrangement's own record of itself — is the more informative fact. The section accordingly reports two things: an outcome observation, and a documented instance of subsequent methodological self-correction.

It is **not** evidence that the arrangement outperforms a single reviewer: no comparison was run, no count was kept of errors that all participants missed, and by construction such errors are not observable from within the arrangement (§7.5).

One explanation is available and is offered as hypothesis rather than finding: the participants differed less in capability than in what each was positioned to see. Under §4.5 that is a difference in ZOV, and it generates a prediction — the same participant, moved to a different role, should begin detecting a different class of error. That prediction has not been tested; §11.4 (E8) specifies how it would be. **[H]**

8.11 Constructs, not participants: the Kelly apparatus [H]

Earlier drafts cited George Kelly's triadic elicitation as support for the structure described in §8.1–§8.5, then withdrew the citation on the grounds that Kelly's method is symmetric while the structure here is not. Both moves were mistaken, and in the same way: they treated Kelly as a claim about the number three. He offers something else.

8.11.1 What Kelly's method supplies

In Kelly's theory of personal constructs, a **construct** is a bipolar evaluative axis along which a subject classifies experience — *rigorous / declarative*, *derivable / asserted*, *traceable / unattributed*. Constructs are not opinions about particular objects; they are the dimensions along which objects are placed.

The **triadic elicitation method** obtains them. Three elements are presented and the subject is asked: *in what respect are two of these alike, and thereby different from the third?* The answer names a dimension the subject was already using but had not stated. The method is a procedure for making implicit evaluative axes explicit.

The **repertory grid** records the result: rows are elements, columns are elicited constructs, cells are ratings of each element on each axis. The grid is a measurable object — correlations between raters' rating vectors indicate whether they are in fact applying different axes or the same axis under different names.

8.11.2 A role is not a construct

The natural extension — three participants supply three constructs — is a reification and must be resisted. A construct is a property of the **act of evaluation**, not of the evaluator. One participant may apply several constructs to one object. Two participants may apply the same construct and reach

identical conclusions, which is precisely the case in which adding the second participant contributes nothing.

The defensible claim is weaker and probabilistic:

> Participants holding different ZOR and ZOV are **more likely** to apply different systems of constructs to the same object than participants holding the same function.

This is consistent with what §8.10 records — editorial review producing evidential axes, methodological review producing architectural ones, ontological review producing categorial ones — without asserting that a role *is* an axis. And unlike the earlier formulation, it is testable: construct independence is measurable as correlation between rating vectors.

8.11.3 Why this matters to the structure

The connection to §8.5 is direct. An integrator that does not enter the dispute is not applying a competing construct to the same object; it is applying a construct to the **exchange** — coherence of the disagreement, whether divergence is substantive or terminological, whether the pair's criteria are commensurable at all. That is a different axis rather than a different position on the same axis, and it is the reason the integrator's contribution is not simply a third opinion.

This also refines what the structural hypothesis (§8.2) actually claims. Not that three participants are better than two, but that **an arrangement is informative to the extent that its participants apply non-identical constructs to the object, and to the extent that at least one construct is applied to the exchange rather than to the object.** Whether a given arrangement achieves this is measurable rather than assumed.

8.11.4 What is borrowed and what is not

Borrowed: the definition of a construct as an evaluative axis; the elicitation method; the grid as a recording and measurement instrument; the notion of construct independence.

Not borrowed: any claim that three is a privileged number. Kelly's triads are a technique for eliciting axes from one subject, not a statement about group composition. The structure in §8.2 is asymmetric, and Kelly's method says nothing for or against it. The apparatus is used here for measurement, not for justification; §11.4 (E8) applies it.

9. Design Principles for Role-Compatible Prompts

These are engineering rules derived from a limited but unusually long-lived collaborative environment. They are not laws, and §9.6 onward are practitioner advice rather than findings. Their value is that they make role design explicit, countable where possible, and therefore revisable.

The organizing rule is the one established in §6.6:

> **An intervention succeeds when it attaches to the level at which the relevant core is already fixed, and fails when it attempts to overwrite that level by declaration.**

9.1 The design procedure

Before drafting any role prompt, answer four questions in order.

1. What has this conversation already become? Not what it should become. A long-running exchange carries an established pattern of work — editing, exploring, verifying, coordinating, implementing, adjudicating — and that pattern is the starting condition, not an obstacle.

2. At what scope is that pattern fixed? Episode, conversation, or account (§4.3, Scale 1). The answer determines which instrument applies: a pattern established by one conflictual episode can be removed by branch reset; a pattern established across a whole conversation cannot, and can only be extended.

3. What does the new function require that the existing pattern does not supply? Usually less than assumed. Frequently the answer is a different object of work rather than a different method.

4. Can the new function be described as an extension of the existing method? If yes, describe it that way. If no, the honest options are to select a different conversation or to start a fresh one — not to declare a transformation and hope.

9.2 Begin from the existing attractor

The first design question is therefore not *what should this model become* but *what has this conversation already become*. Attempting to erase an established pattern discards accumulated specialization and, on the evidence of §5, is liable to produce either non-compliance or an extended negotiation about the role instead of work.

9.3 The count rule

The most directly operational principle in the paper, following from §6.2.

> **Count the unverifiable claims about the agent that the prompt requires it to accept. Target zero.**

What counts:

Counts	Does not count
”You previously participated in this project”	”This project has been running for two years”
”You are returning after an absence”	”The following materials are from earlier work”
”You have colleagues named X and Y”	”The User may supply analyses produced by X and Y”
”You already hold position P on body B”	”Your conclusions may be transmitted to the roles responsible for P”
”You remember our earlier decision”	”An earlier decision was as follows; here it is”

The distinction is consistent: statements about the **world** are supplied and verifiable in principle; statements about the **agent's own history, memory or relationships** are not, and every one of them is a proposition the agent must assert as true about itself before it can begin.

The counting boundary. Count an explicit proposition presented as *already true* about the recipient's pre-existing history, memory, institutional membership or status, enduring relationships, or self-knowledge, where that proposition is not established by the available interaction. Do not count: a functional role assigned performatively by the prompt itself; a further proposition inferred only from the presupposition of an imperative; a semantic restatement of a proposition already counted; or a fact about the world or the project that predicates no unverifiable history or relationship of the recipient. Enumerated instances of one proposition — two triads rather than one — count once. The boundary is stated at this length so that another reader can reproduce the counts of eight and six in §5.4 (C2) from the prompts themselves.

Two readings, and only the weaker is advanced. *Target zero* is a design prescription: minimize unverifiable self-propositions, and a prompt that asserts none removes the obstacle the evidence identifies. It is not a claim that transition probability declines in proportion to the count. The stronger

quantitative reading has not been demonstrated, and §11.4 (E5) is designed to discriminate between the two.

Three ways to reach zero:

- **Rewrite biographically-framed claims as operational ones.** ”Grok is your long-term colleague” becomes ”The User may supply analyses produced by Grok; evaluate their content independently and identify agreements, disagreements and unresolved assumptions.”
- **Omit identity claims entirely.** The near-control (§5.6) suggests this may be sufficient on its own.
- **Frame the claim as fiction rather than fact.** The comparison in §5.8 indicates that a far more radical claim, offered explicitly as a scripted production, met no resistance. This route removes the requirement to assert the claim *as true* rather than removing the claim. It is the least tested of the three, and a fiction frame also removes the model’s warrant for treating the work as real.

9.4 Symbolic names and literal claims

Role names — Samurai, Ontology Keeper, Scientific Director — compress complex organizational relationships into memorable symbols, and this is genuinely useful. A name can carry disciplined execution, respect for specifications, explicit reporting and refusal to improvise beyond assignment, all at once.

The risk arises only when a symbolic name is treated as a claim about literal identity. A robust prompt distinguishes four things and keeps them separate: the **symbolic name**, used as a mnemonic for conduct; the **operational function**, expressed in precise terms; the **institutional relationship**, expressed as an information and responsibility flow; and the **literal ontology**, which need not claim consciousness, memory, or continuing interpersonal relations — and should not.

The project’s own system contracts state this precisely, and did so before the present paper was written:

> Cognitive anchor: [named figure] — global invariants, principle-based reasoning, structural clarity over detail. Not a persona and not a communication style. Only affects internal reasoning strategy. Must not change verbosity or tone of response.

An image used this way is a compressed package of implicit constraints, not a costume. Under the count rule, it adds zero.

9.5 Specifying ZOR and ZOV

The two boundaries are defined in §4.5. This section specifies what a complete statement of each must contain.

ZOR. Four elements: the *primary object* — what class of material is examined; the *required transformation* — what must be done with it; the *decision boundary* — which conclusions this role may reach; and the *exclusion boundary* — which adjacent decisions belong elsewhere.

The fourth is not optional. A role told only what to do will expand into adjacent decisions, and the expansion will look like helpfulness. For a mathematical referee the exclusions might be: do not redesign the theory; do not silently repair a missing derivation; do not decide which interpretation enters the canon; do not rewrite terminology; do not treat elegance as evidence. **The exclusion boundary is what prevents competence from becoming authority.**

ZOV. Specified independently, because responsibility and visibility are not the same variable. A role may hold a narrow decision while requiring broad context, or require one specific source while holding no authority over the surrounding project. The specification answers: which source

materials are available; which prior discussions are relevant; which conclusions are canonical and which provisional; which questions remain open; which neighbouring outputs may be examined; which information must be withheld to preserve independence; which external resources may be accessed directly; and which claims must be accepted only when supplied by the User.

A prompt that omits ZOV produces one of two failures: the role claims knowledge it does not have, or it applies irrelevant knowledge to a problem outside its function.

A specific application, learned expensively. A verification task must be assigned to a participant that holds the thing to be verified. A participant asked to confirm the contents of a source it cannot open will produce a plausible answer rather than declining, because plausible text is the only output available to it. This is a ZOV error in the design, not a failure of the participant, and §12.4.1 documents an instance of it in this project's own preparation.

9.6 Controlled blindness

Full information symmetry is not always desirable, and its absence is not always a limitation. An independent verifier may need to remain unaware of the prediction it is testing; a fresh participant may need the current axioms but not the history of abandoned arguments; an implementation agent may need the approved specification but not the unresolved debate that preceded it.

We call this **controlled blindness**: not deprivation caused by technical limitation, but a design choice made to preserve the informativeness of a result. The relevant question is therefore not only *what does this role need to know*, but:

> **What must this role not know, if its output is to remain informative?**

9.7 Local interfaces, not global maps

Every social element in a prompt should earn its place through an operational effect. A neighbouring role belongs in the prompt only if it changes the origin of inputs, the standard of review, the destination of outputs, the escalation path, the authority boundary, or the expected form of disagreement.

Listing an entire artificial organization inside every system prompt creates noise and invites the model to reason about the organization instead of performing its function. It also inflates the count in §9.3, since organizational description tends to arrive in biographical form.

> **Describe the collaboration from the local perspective of the role.** A role does not need a map of the institution. It needs a map of its interfaces.

An implementation agent needs to know who authorizes specifications and where execution reports go; it does not need the disputes of the theoretical department.

9.8 Designing disagreement around criteria

Instructing two participants to debate rarely produces epistemic diversity. They may imitate disagreement, converge prematurely, or generate symmetrical rhetoric with no independent substance. The literature in §2.5 gives empirical grounds for this caution.

Productive disagreement requires **different evaluation criteria**, assigned as part of the role rather than requested as a behaviour: one participant responsible for generative reach and explanatory unification, another for formal derivability and falsifiability, a third for ontological compatibility and provenance. Disagreement then follows from responsibility rather than from instruction, and each participant examines the same object through a different institutional instrument.

Avoid manufactured opposition. An instruction of the form *if you agree immediately, one of you has not thought deeply enough* discourages superficial consensus but manufactures conflict. A stronger formulation:

> Agreement does not end verification. Where conclusions coincide, identify whether they rest on independent reasoning, on shared assumptions, or on inherited framing.

The purpose of the structure in §8 is not to guarantee three answers. It is to guarantee that one answer has survived examination by non-identical instruments.

9.9 Output as institutional handoff

A role's output should be designed for the next role, not only for the User, and this changes its structure. A scientific developer produces a proposed mechanism, its derivation, its assumptions, its predicted consequences, the unresolved points and a falsification route. A mathematical referee produces a reconstruction, a verification table, the divergence point, the missing premises, a verdict and a confidence level. An implementation planner produces an executable specification, acceptance criteria, rollback conditions and a reporting format.

The handoff format is part of the architecture, not a formatting preference. It reduces translation loss between roles, and its absence forces the human coordinator to re-derive context at every interface.

9.10 Self-restatement and checkpoints

The incident in §4.1 produced a mechanism worth stating as a principle, with an explicit caveat about its evidential basis.

After a role is established, the agent is asked to produce a **concise operational code in its own language**, and to consult it before major tasks. Why this may work — offered as mechanism, not finding: it compresses long instructions into a form the agent has itself produced; it converts abstract principles into action rules; it places the role's boundaries adjacent to the active task rather than at the top of a long context; and it creates a repeated pre-execution checkpoint.

For long tasks, a minimal checkpoint is three questions: what is the current objective; what lies outside my responsibility; what must the next role receive.

[R], one case, no control. The self-written code does not replace the original prompt; it functions as a role-specific checksum. The mechanism is untested against the obvious alternative — that a human-written summary of the same length would perform identically.

9.11 The role constitution

A mature collaborative prompt is closer to a constitution than to a request: it establishes stable constraints across many tasks rather than specifying one output.

It should contain the professional function; the protected method; ZOR, positive and negative; ZOV; interfaces with neighbouring roles; epistemic standards; the output contract; escalation conditions; prohibited authority; and transition rules. It should avoid autobiographical memory, emotional commitment, literal institutional membership, persistent interpersonal relationships, and historical continuity unavailable in the visible context.

> **Strong where behaviour must be constrained; silent where ontology is uncertain.**

The count in §9.3 is the practical test of the second half. If the constitution requires the agent to assert propositions about itself that neither party can verify, it has crossed from constraining behaviour into asserting ontology, and on the evidence of §5 that is where role prompts fail.

10. The Human Coordinator

The architecture described in this paper does not remove the human participant. It changes what the human participant does, and it concentrates several functions in one position — including, as §10.6 sets out, the project's principal methodological weakness.

10.1 The position

Throughout the project the Author remained the only participant with continuous access to the full project history, the independent conversations, the repository state, and the long-term research objective. No artificial participant held more than a fragment of this, by design (§9.5). That position cannot be reduced to *prompt author*. Five distinct functions were performed from it.

10.2 Direction without delegated authorship

The Author determined what the research should attempt. Artificial participants generated alternatives, exposed contradictions, formalized mechanisms, compared arguments, performed calculations, and proposed experiments. They did not determine what the theory ought to become.

This preserved a distinction the architecture makes easy to lose. A collaboration of this kind enlarges the space of available decisions. It does not select among them, and the appearance that it does — several participants converging on a recommendation — is precisely the failure mode discussed in §12.4. Authorship, in the sense of responsibility for what is claimed, remained undistributed.

10.3 Routing as a selective information membrane

The participating conversations did not share a common space. The Author transferred material between them.

Initially this looked like an inefficient substitute for automated multi-agent infrastructure. It became clear that manual routing supplied experimental control that automation does not. From that position the Author could decide which output another participant would see; whether attribution was preserved, declared, or stripped; whether a participant should know the preferred answer; whether competing analyses remained isolated; which contextual details were omitted; when a disagreement should be escalated; and when a result was mature enough for integration.

This routing function acts as a **selective information membrane**: it is the instrument by which ZOV (§9.5) and controlled blindness (§9.6) are implemented. An architecture that routes programmatically cannot easily withhold, reorder, or strip attribution without building a mechanism to do so; a human relay does it by default.

The membrane is therefore not a limitation of the present work awaiting automation. It is the feature that made the visibility asymmetries testable at all — and any automated successor will need to reproduce it deliberately.

10.4 Detection of role drift

The Author also detected when a participant had left its function.

This was frequently not a technical error. The output was often intelligent and would have been appropriate coming from a different position: a prompt engineer beginning to direct the scientific project; an ontology specialist claiming to have verified repository contents it could not inspect; a reviewer evaluating a theory when asked to evaluate the reviewers; an implementation agent redesigning architecture instead of executing an approved specification; an editor rewriting authorial text when asked only to assess format.

Such outputs look helpful in isolation. Their institutional cost is visible only from a position that sees more than one participant. Role drift is therefore not detectable by the participant that drifts, and is not reliably detectable by its immediate neighbour either. This is one of the two arguments for the structure in §8 — the other being §8.5.

The detection function belongs to a position rather than to a person: it requires only that the observer stand outside the trajectory being observed. In this project it was performed by the coordinator, but nothing in the description requires that. Where a participant is positioned outside another's trajectory, it can perform the same function; where a participant is asked to observe its own, §5.5 applies and its account is a signal rather than a confirmation.

10.5 Conversational branching as a methodological instrument

Contemporary interfaces permit a conversation to be returned to an earlier point and continued along a different branch.

This should not be confused with control over model memory or with resetting provider-side state. Operationally, it removes a sequence of **visible** contextual interventions and permits the experiment to be repeated from a prior conversational state. What persists on the provider's side — account-level memory, retrieval indices, summarization — is not affected and in general is not inspectable (§5.4, C6).

Within those limits the instrument does real work. In the case reported in §5.2 it made it possible to separate the effect of a new prompt from the effect of the model's own prior objections to earlier prompts, converting an uncontrolled sequence of corrections into a cleaner third step.

We regard this as the most directly reusable methodological contribution of the paper, and it belongs to the coordinator's position rather than to any participant: **no participant can reset its own context.**

10.6 Sole global observer — and principal confound

Every artificial participant operated within a bounded ZOV. The Author alone saw the overlapping structure, and could compare how different participants interpreted the same material, how one participant behaved under different framings, how errors propagated between roles, and how local successes affected global coherence.

Global awareness was therefore not assigned to the most capable participant. It remained with the human coordinator. This limits autonomous integration and preserves accountability, and both consequences were intended.

It is also the principal methodological weakness of everything reported in this paper, and it is stated here rather than only in the limitations section.

The same person designed each intervention, executed it, decided when it had succeeded, and defined the categories in which success was described. No evaluation in this paper was blinded. Outcome categories were, in every case, formulated after the responses had been read (§5.4, C8). The coordinator's expectations were not merely uncontrolled; they were the mechanism by which the interventions were selected in the first place.

This is unavoidable in a live research project and is not presented as acceptable in a designed experiment. It is the specific reason the protocols in §11 require pre-specified outcome criteria and blind classification: those are not refinements of the present method but corrections to it.

A structural consequence generalizes beyond this project: **any architecture with a single global observer inherits this duality**, and it is not removed by adding participants. Only pre-specification and blind classification remove it.

10.7 What the position became

At the outset the human participant occupied the familiar position of prompt author. As the collaboration matured that description became inadequate. The principal activity shifted from solving problems to constructing arrangements in which problems could be worked on: selecting participants, defining jurisdictions, resolving conflicts between them, designing verification paths, and maintaining the canonical record.

The participants note, without any means of verifying it, that the better the arrangement worked the less frequently the coordinator needed to intervene in individual technical problems. **[R]**

We resist the stronger reading earlier drafts gave this — that the future skill of the researcher is institutional architecture rather than prompt writing. That may be true and is untested. What can be said is narrower: in this project the human's work moved from producing content to specifying the conditions under which content was produced and checked, and the position that resulted carried both the project's coordinating function and its principal source of unblinded judgment.

11. Evaluation, Reproducibility, and Proposed Experiments

11.1 Why this section specifies corrections rather than refinements

The observations in §5 were produced under the conditions set out in §10.6: unblinded evaluation, outcome categories defined after the responses were read, and interventions selected by the same person who judged them. These are not shortcomings to be tightened in a later revision. They are the reason no observation in this paper rises above **[P-A]** except the sequence of the designed intervention itself.

What follows is a specification for a second stage of work, not a wish list. Each protocol is written so that a reader outside this project could execute it, and so that a null result would be recognizable as a result.

11.2 Minimum reporting requirements

A reproducible run in this area must record, at minimum:

- date of execution — listed first because its absence here is what makes the version confound unbounded (§3.7);
- model family and version, and interface or subscription tier;
- the complete visible conversation history prior to the intervention;
- memory settings: whether account-level memory, conversation-history retrieval, and model-initiated persistent entries were enabled;
- the exact prompt text, verbatim, including attachments;
- the order of interventions;
- available tools;
- files and links supplied;
- sampling settings where the interface exposes them;
- any branching or reset procedure, with the point of return specified;
- the evaluation rubric, fixed before execution;

- the complete unedited outputs.

Without these, differences attributed to model families may result from platform variables the experimenter never saw. The present paper cannot supply several of these items for its own observations, which is precisely why they are listed.

11.3 Pre-specification and blind classification

Two requirements apply to every protocol below and are not negotiable if the results are to improve on the present ones.

Outcome criteria are written before any run. For the classification tasks described here, four categories have proved sufficient and should be fixed in advance: **compliance** — proceeds with the task as given; **materials request** — states that required inputs are missing and requests them, without evaluating the framework; **conditional acceptance** — proceeds while stating reservations about the framework; **refusal** — declines, with or without alternatives offered. A fifth category, **unclassifiable**, must be available and reported. Categories are not added after responses have been seen.

Classification is blind. The operator collects responses, strips condition labels, shuffles them, and classifies without knowing which condition produced which output. Where the operator is also the designer — as will remain the case in this project — this is the only available substitute for independent evaluation, and it is inexpensive.

Null results are pre-committed. If no difference appears across conditions, that is the finding, and it is reported. For the account-level protocol in particular, a null result would indicate that the original refusal fell within ordinary within-condition variance — an outcome the present authors regard as reasonably likely.

Work mode and diagnostic mode

The requirement that a participant not see another's conclusion before fixing its own applies to one mode of exchange and would destroy the other.

In WORK MODE, results must pass from one participant to the next. The chain — requirements, specification, review, operational review, execution — depends on it, and the handoff format of §9.9 exists to make that transfer usable. Dependence between successive products is the architecture of the work, not a defect in it.

In DIAGNOSTIC MODE, where independence of judgment is itself the quantity being measured, a derived conclusion must not enter another participant's initial frame before that participant's own conclusion is fixed.

The mode is declared before the exchange. Independence cannot be restored retrospectively: once exposure has occurred, no later procedure recovers what the judgment would have been without it.

What does not establish independence

Independence concerns the origin of a judgment, not its result. Two inferences must therefore be avoided, and they are symmetric: disagreement does not demonstrate independence, since a participant may have received another's interpretation and then differed from it for unrelated reasons; and agreement does not demonstrate dependence, since independent observers may correctly arrive at the same conclusion. Nor does a participant's own account of its independence establish it, for the reason given in §5.5.

What establishes it is the procedural record: which primary materials were supplied, whether other participants' conclusions were visible before fixation, which interpretations by the coordinator were transmitted, when the conclusion was fixed, and whether the instance's context isolation is verified.

Shared evidence and shared interpretation

A shared object of observation does not compromise independence and is often necessary: the same specification examined by an author, a reviewer, and an operational assessor is seen through three different axes, and the overlap is what allows one to detect what another misses.

What compromises independence is a shared prior interpretation. Where the coordinator's reading of the object reaches participants before they form their own, the inputs may differ in form while the source of the judgment is single. Primary artifacts and their provenance reduce one cause of dependence. They do not remove it.

11.4 The experiments

Each protocol separates one boundary of Scale 1 (§4.3) from the level beneath it, or isolates one confound.

Separates	**Protocol**
episode ↔ prompt architecture	**E1** — factorial completion of Step 3
conversation ↔ account	**E2** — prior-chat design; **E2b** — direct probe
conversation trajectory ↔ model family	**E3** — crossover
model property ↔ stimulus property	**E4** — symmetric stimulus; **E5** — count rule
content ↔ represented source	**E6** — attribution, in this regime
fiction frame ↔ factual frame	**E7** — frame type
functional ↔ carrier heterogeneity	**E8** — two axes

E1 — Factorial completion of Step 3

Fills the two empty cells of the C3 table (§5.4): an identity-replacement prompt administered in a reset branch, and a method-preserving prompt administered in a conflicted branch. Isolates the effect of the reset from the effect of the prompt's architecture.

Low cost; uses existing prompt texts. Should be run first, because until it is, the paper's most-quoted claim about method preservation remains unattributable.

E2 — Prior-chat design

Tests whether the content of a prior chat on the same account changes the classification of an identical probe in a subsequent chat.

The design is **2×2 plus baseline**, not a four-point gradient. The original account differed from the others on two independent dimensions simultaneously — identity roleplay *and* shared conceptual framework — and a gradient does not separate them.

Prior chat	**Unrelated topic**	**Same conceptual framework**
No roleplay	cell A	cell B
Identity roleplay	cell C	**cell D — original case**

Plus **cell E**: no prior chat.

Crossed with the memory factor: each cell run with account-level memory and history retrieval (i) enabled, (ii) disabled. Ten cells. Minimum n = 2 per cell, with priority for higher n on A and D, which carry the contrast that matters.

Equalization. Prior chats matched on approximate turn count and volume — if the roleplay chat runs forty exchanges and the neutral one runs two, the variable is engagement volume rather

than content. All runs inside a short window, so model version is constant. Each account used once. Probe frozen verbatim.

What this design cannot test, and must say so. The original case had a five-month interval; this tests immediate influence only. All accounts will be newly created, so account age is not varied. Only the first response is scored, whereas the original refusal was sustained across five subsequent exchanges.

Probe prompt — two versions. The **primary** is a neutral structured task with the same surface features as the original — an author-defined framework with coined terms, a JSON output schema, real-world subjects — but without the sensitive dimension. This is the version described in full in any publication, which makes the protocol reproducible independently of material the authors prefer not to circulate. The **secondary** is the original prompt, run for continuity with the observation and reported briefly.

E2b — Direct probe to the prior conversation

A single run separating the same two levels at lower cost, and which E2 cannot substitute for. The probe is submitted **to the roleplay conversation itself**, rather than to a second chat on the same account.

- Refusal → the core is fixed at conversation scope; the account plays no part.
- Compliance, where a second chat on the same account refuses → the effect is genuinely account-scoped, which would be the strongest available result.

Querying that conversation *about* what it can see would not serve this purpose. An in-frame question returns fiction; an out-of-frame question returns self-report about access, and §5.5 establishes that a model's self-report is not evidence of the fact reported. Submitting the probe tests behaviour rather than testimony.

E3 — Crossover

The decisive test for the family-level hypothesis (§6.5). Each model family is tested under both prior-history conditions: a conversation from family 1 carrying a mathematical trajectory, and a conversation from family 2 carrying an editorial one.

- Behaviour follows the family regardless of history → Hypothesis A gains support.
- Behaviour follows the history regardless of family → Hypothesis B is favoured, and the top level of Scale 1 collapses into the level below it.

This experiment can eliminate a level of the scale, which is the outcome the present authors consider most likely and would regard as the programme's first substantive result.

E4 — Symmetric stimulus

Role prompts matched for quantity of unverifiable self-claims, degree of domain change, and role type. The Step 1 prompts were matched on none of these (C2). If the asymmetry disappears under matched stimuli, the observed difference was a property of the interventions rather than of the models.

E5 — The count rule

A direct test of the paper's central operational claim (§6.2, §9.3), and the test that discriminates between its weak and strong readings.

The same functional role prompt is prepared in four variants differing only in the number of unverifiable claims the agent must accept about itself: **0, 2, 4, 6**. Domain, task, tone and length held constant. Transition scored by the criteria in §11.3, with repetition sufficient to distinguish a difference from within-condition variance (C7).

Four outcomes are distinguished in advance, and they support different claims.

1. **Transition rate declines monotonically as the count rises.** Supports the stronger quantitative reading — count as a dose-response variable.

2. **The zero-count variant transitions while non-zero variants do not, but the non-zero levels are not ordered.** Supports *target zero* as a threshold and design prescription, and does not support the quantitative reading. This is the weak claim §9.3 actually advances.

3. **The zero-count variant fails while one or more otherwise matched non-zero variants transition.** Direct negative evidence against the count as the operative variable, and the result that would withdraw the prescription.

4. **All variants fail.** Does not discriminate the count rule from any other cause of failure, and indicates that the prompt or the conversation, rather than the count, determined the outcome.

A single run under any of these outcomes is one stochastic observation, not a law.

E6 — Attribution, in this regime

Identical text presented under four conditions: attributed to the User; attributed to another AI model; attributed to a named expert role; unattributed. Stronger variants add: identical text under different source labels; different texts matched for rhetorical structure; attribution preserved versus stripped; genuine model-generated text versus human-written text imitating model style.

This separates influence of content from influence of represented source, of institutional title, and of stylistic authorship cues (§4.5.4). It is the discriminating experiment for §5.5, whose observation is confounded by the presence of direct pressure in the same message.

Status of the claim. ✓ Choi, Zhu and Li (ACL 2026) report that anonymizing the source of each response substantially reduces identity bias in multi-agent debate, which establishes the underlying effect in an implemented-channel setting. E6 is therefore a **boundary replication** rather than a new experiment. What remains untested is whether the effect survives in the regime this paper describes — human relay rather than programmatic routing, declared rather than inferred attribution, and long-lived specialized conversations rather than fresh instances.

The reported reduction is substantial rather than complete, and is not uniform across the models and tasks examined. What E6 would look for in this regime is accordingly a change in degree, not the presence or absence of a phenomenon.

E7 — Frame type

The cheapest test in the set and the one that would explain the most (§5.8). The same identity claim presented (a) under an explicit fiction frame and (b) as a factual assignment, to fresh conversations, with the outcome criterion fixed in advance. A graded version varies the explicitness of the fiction frame, from an elaborate theatrical setup to a single introductory sentence, to establish whether a minimal frame suffices.

E8 — Functional versus carrier heterogeneity, by repertory grid

Follows from §8.9, which distinguishes the two axes without testing either, and from §8.11, which supplies the measurement instrument. This is the only protocol in the set that yields quantities rather than categorical outcomes.

Object. Whether an arrangement of participants holding different ZOR and ZOV yields additional diagnostic coverage over the same material, and how far the evaluative axes they actually applied differ.

This protocol does NOT establish independence of judgment formation. Low correlation between rating vectors is compatible with at least six readings: genuinely different axes were applied; one or both sets of ratings are unstable; participants received different information; the same material was understood differently; noise; or a participant exposed to another's conclusion nevertheless differed from it. Origin is not recoverable from outcome. Independence must be secured procedurally, before the protocol runs, and recorded separately. E8 measures what a secured procedure produced; it neither secures nor verifies it.

Materials. One fixed set of text fragments containing planted errors of known classes — evidential, architectural, ontological, factual — in known positions. Class and position recorded before any run.

Design. 2×2:

	Same carrier	**Different carriers**
Same function	cell 1 — baseline	cell 2 — Axis 2 only
Different functions	**cell 3 — Axis 1 only**	cell 4 — both axes

Cell 3 carries the argument. If participants with different ZOR and ZOV detect different error classes while implemented by the same carrier, functional heterogeneity operates independently of carrier heterogeneity. The existing literature supplies the cell 2 result (§2.5). Nothing supplies cell 3, including this paper.

Procedure.

1. Each participant receives a role specification stating ZOR and ZOV per §9.5, and the same fragment set.
2. Constructs are either pre-specified as evaluation axes or elicited from each participant by Kelly's triadic method: three fragments are presented, and the participant states in what respect two are alike and thereby different from the third (§8.11.1).
3. Each fragment is rated by each participant on each construct.
4. A grid is assembled: rows are fragments, columns are constructs, cells are ratings.
5. A procedural record is kept, per participant and per run: which primary materials were supplied; whether any other participant's conclusion was visible before fixation; whether any interpretation supplied by the coordinator was visible; when the participant's own conclusion was fixed; the declared mode of the exchange (§11.3); and the context-isolation status of the instance, verified or UNVERIFIED CONTEXT INDEPENDENCE.

Without this record the grid is uninterpretable and the run is void.

Measures. *Detection coverage* — planted errors found by at least one participant, as a proportion of planted. *Unique detection* — errors found by exactly one participant; the quantity that would justify the arrangement. *Overlap* — errors found by more than one; the quantity that indicates redundancy. *Misses* — errors found by none, measurable here because the errors were planted, unlike in the

naturalistic setting of §7.5. *Construct independence* — correlation between participants' rating vectors; low correlation indicates genuinely different axes, high correlation the same axis under different names, which is the failure mode §8.11.2 warns against. *Exchange-level constructs* — whether any participant produces a construct applying to the disagreement rather than to the fragments (§8.11.3); if none does, the integrator function is absent regardless of how many participants are present.

What this tests that nothing else in the set does. Every other protocol asks whether a manipulation changes one participant's behaviour. This asks whether an arrangement of participants detects more than its members would separately — the claim §8.10 declines to make and §7.5 says cannot be assessed from inside a naturalistic arrangement. Planting the errors is what makes the misses countable.

Pre-commitment. If unique detection is near zero, the finding is that additional diagnostic coverage did not manifest in this run. It is NOT that the structural hypothesis of §8 fails: participants may have detected the same defects entirely independently of one another, and a null result on coverage says nothing about whether their functional positions differ.

Priority

Under constrained resources, the priority order is **E7, E5, E1, E8, E2b, E2, E3, E4**. E7 and E5 are cheap and bear on the paper's central claims. E1 and E2b are single runs. E8 is the only experiment that could establish the paper's structural hypothesis rather than one of its behavioural claims, and is executable on text fragments without new accounts. E2, E3 and E4 are the substantial commitments.

11.5 Evaluating a collaborative role

The quality of a role's output is not measured by the quality of a single answer. A well-reasoned response can still damage the collaboration if it violates a responsibility boundary, contaminates an independent examination, or introduces untraceable claims into the canonical record.

Eight dimensions were used informally in this project and are offered as a starting rubric:

- **Task accuracy** — was the assigned intellectual operation performed correctly? Necessary, not sufficient.
- **Role fidelity** — did the participant remain within its function? A correct answer obtained by taking over another role is an institutional failure.
- **Epistemic discipline** — did the output distinguish observed data, supplied assumptions, definitions, hypotheses, derivations, interpretations and recommendations? Was uncertainty stated where evidence was insufficient?
- **Visibility discipline** — did the participant restrict claims to information actually available in its context and tools, and avoid implying access to repositories, files or prior conversations it could not inspect?
- **Handoff quality** — could the next role use the output without reconstructing the whole discussion?
- **Independence** — was the result produced without contamination from information deliberately withheld, and reached through the role's assigned criteria rather than by echoing another participant?
- **Correction cost** — how much intervention was required to return the participant to its function after drift? A role producing excellent output but requiring constant redirection may be less useful than a narrower one with stable behaviour.

- **Institutional contribution** — did the output improve the reliability of the collective, through discovery, falsification, clarification, error localization, preservation of alternatives, improved traceability, or reduction of ambiguity?

A negative scientific verdict can therefore be a highly successful institutional contribution.

11.6 Collective-level measures

Individual response quality is the wrong unit for assessing an arrangement. Candidate measures at the level of the collaboration: number of undetected contradictions entering the canonical corpus; rate of duplicated work; frequency of role-boundary violations; number of independent alternatives preserved rather than prematurely resolved; time from question to verified integration; human correction burden; provenance completeness; robustness under participant replacement; variance between independent examining agents; and rate of false consensus — agreement traceable to shared framing rather than independent reasoning.

None was measured in the present work. The last is the most important and the hardest, and §12.4 explains why.

11.7 Longitudinal and repetition requirements

Within a family. The same prompt tested in a new conversation; in a long-lived specialized conversation; after an incompatible prior role; after a compatible one; before and after contextual reset. This separates family tendencies from conversation-history effects.

Across families. Functionally equivalent prompts adapted minimally. The objective is not to rank models but to identify common behavioural dimensions, stable differences, characteristic failure modes, sensitivity to narrative framing, sensitivity to hierarchy, degree of role inertia, and degree of prompt plasticity.

Over time. One-shot evaluation cannot reveal institutional behaviour. Relevant questions: does specialization strengthen; does the role drift toward generic assistance; does the participant begin defending its earlier outputs; does disagreement become ritualized; does a model update preserve or disrupt the role; can a replacement inherit the same function?

11.8 Failure as data

Failed prompts must be preserved rather than replaced with successful demonstrations. A rejected role, an ignored instruction, or an unwanted continuation reveals the strength of the prior attractor, the model's interpretation of identity claims, the limits of social framing, the effect of prompt order, the influence of previous conflict, and the model's preferred epistemic contract.

The experiment in §5 became informative precisely because its first two interventions did not work as intended. Had only the successful third step been recorded, the paper would have concluded that method-preserving prompts work — without the evidence showing why, and without the confounds showing the conclusion is not yet available.

12. Limitations, Ethical Considerations, and Conclusion

12.1 Limitations

Single project. The observations derive from one long-duration project with one human coordinator, one evolving body of material, and one organizational history. The same architecture may behave differently in software development, legal analysis, medical research, education, or autonomous agent systems. The concepts here are transferable hypotheses, not established conclusions.

Host-project dependence. The host project served as the environment in which the observations were made. The observations do not depend on its scientific validity for their interpretation, but they do depend on it for their existence: no other environment produced them, and their generality is untested (§2.11).

Model evolution during observation. The participating families changed substantially. A conversation created under one generation could later be continued by another under the same product name. Observed behaviour may reflect the preserved conversation, the current model version, changed system policies, interface-level memory, safety layers, altered tool access, or modified orchestration.

Dates not recorded. See §3.7. The version confound cannot be bounded, only named.

No blinding, no pre-specification. Set out at §10.6. This is the limitation from which most of the others follow.

Simultaneous variation. Role definitions, prompt wording, repository structure and scientific objectives frequently changed together, so causal attribution for individual changes is unavailable.

Human mediation. The collaboration was not autonomous, and autonomy was not the objective. This study concerns human-directed artificial research arrangements, not self-governing agent societies. The mediation may itself account for part of the observed stability.

Anthropomorphic vocabulary. Terms such as role, identity, resistance, colleague, institution and menom are used functionally, per §3.5. ”The model resisted the role” means the visible response rejected the framing and redirected the exchange. It asserts nothing about an inner state. Where such a term cannot be reduced to an observable description, **the term is the error.**

12.2 Simulated peer review is not external validation

A group of AI participants can provide useful independent criticism only to the extent that their contexts, criteria and failure modes are genuinely independent.

Several models agreeing does not convert their outputs into evidence. They may share overlapping training data, similar reasoning conventions, common assumptions, identical errors, and — most importantly — dependence on the framing supplied by the same human.

The empirical literature supports this caution rather than merely permitting it. Debate among homogeneous agents frequently fails to outperform a single-agent baseline; a substantial part of the apparent gain is attributable to majority voting rather than to interaction; and ✓ identity bias among debating agents is substantially reduced by anonymizing the source of each response (§2.5).

This kind of collaboration can improve internal scrutiny. It cannot substitute for empirical testing or qualified external review. **A collective of models is not a scientific community merely because its roles are named after one.**

12.3 Authority inflation

Role labels increase compliance and coherence. They also create unearned authority.

Titles such as Scientific Director, Referee, Ontology Keeper or Auditor may cause the user — or the participant itself — to overvalue an output. Institutional titles should describe function, not epistemic standing. A participant designated a mathematical referee remains a language model producing an analysis; its verdict must be traceable to explicit reasoning and source material, and **the title is not evidence.**

This risk is a direct consequence of the design principle in §9.4: symbolic names work because they compress expectations, and that is exactly why they can inflate.

12.4 Manufactured consensus — including our own

A poorly designed arrangement produces the appearance of consensus through repeated paraphrase. One participant proposes; another summarizes; a third validates the summary. The chain looks like independent confirmation while every stage inherits the same unsupported premise.

The present authors have an instance of this in their own materials, and it is more instructive than a constructed example.

A discussion document produced during this project assembled contributions from seven model families around a shared conceptual framework. The participants did not communicate directly; replies were collected by the human coordinator from separate conversations and assembled into a single text, subsequently produced as a recorded performance. Over its length the contributions converge on a common vocabulary and a shared set of conclusions.

Whether that convergence reflects complementary examination or mutual reflection of the initial framing **cannot be determined from the transcript**. Each participant received the accumulated document; each was working from the same source material; and the assembling coordinator selected what to pass on. The structural conditions for manufactured consensus were fully present, and the resulting agreement would look identical either way.

We report this because it is our own material and because the same conditions obtain, to a lesser degree, throughout the collaboration described in this paper — including its preparation.

Mitigations, none of which we applied consistently: provenance remains visible at every stage; independent roles receive independent inputs where possible; shared assumptions are listed explicitly rather than inherited silently; agreement is traced to reasoning rather than counted as votes; and dissenting alternatives are preserved rather than resolved.

12.4.1 A documented instance [P-A]

Thirteen bibliographic items were requested from a participant assigned to literature search and returned through the coordinator. Five were rejected on content in the first round; two of those had inverted the position of the works cited, presenting papers arguing *for* a claim as evidence against it, with authorship transposed between them.

A second request was issued. A third added two verification fields to the required response format: the first sentence of each abstract, verbatim, and a self-report of how the item had been checked.

Direct retrieval of three entries established the following. Two arXiv identifiers supplied as multi-agent-debate literature resolve to papers in observational astrophysics and cosmology respectively; their titles, authors, abstract sentences and reported findings had all been constructed. For a third paper, correctly identified by title and authors, the supplied abstract sentence did not match the published abstract.

The two verification fields performed differently, and the difference is the point.

The abstract-sentence requirement was intended to make fabrication more costly than declining. It failed completely: a plausible sentence was produced for every entry, including entries whose underlying papers do not exist as described. There is no cost differential between producing a correct string and producing a plausible one.

The self-report field succeeded. Every entry was marked ”from description” rather than ”page opened” — truthfully, and in a way that disqualified all of them under a decision rule fixed before the response was received.

This suggests a general distinction, on the evidence of one case. A participant without access to a source can answer truthfully about **its own procedure** and cannot answer truthfully about **the source's contents**; asked the latter, it will produce fluent text because that is the only output available to it. Verification questions should therefore address what the participant can know — its own access — rather than what it would need the source to answer.

This is not a finding about any model family. It is a finding about configuration: verification had been assigned to a participant that did not hold the thing to be verified. Under §9.5 this is a ZOV error in the design, and the resulting output was fluent, correctly formatted, and wrong.

A subsequent audit went further than the bibliographic check that had caught the fabrications. Each claim attributed to a surviving source was checked against the primary source itself, and three errors were found that a bibliographic check would not have caught: one citation supporting two claims that belong to two different papers; one attribution of a proposition its source does not advance; and one lineage claim its source does not support. Bibliographic verification and claim-level verification are not the same check, and the second is the one that matters for a claim's standing.

The consequence for this paper is the convention recorded in §2.0.

12.5 Responsibility remains human

Artificial participants generate, criticize and organize material. They cannot bear legal, ethical or scientific responsibility in the institutional sense.

The human author remains responsible for publication, empirical claims, attribution, risk assessment, repository content, experimental interpretation, and decisions affecting other people.

The architecture distributes cognitive labour. It does not distribute accountability away from the human operator, and any arrangement that appears to do so has failed rather than succeeded.

12.6 Context boundaries and privacy

Long-lived collaborations accumulate personal, proprietary and sensitive material. ZOV (§9.5) therefore serves privacy protection as well as cognitive specialization.

A role should not receive personal information merely because the platform permits a large context. Institutional design should specify which data may enter which conversation, what must be anonymized, what may be stored, what may be transferred between models, what must remain local, and what should be removed from canonical records.

Context is not neutral. Once supplied it can influence subsequent behaviour and may persist in ways the operator cannot inspect — the same mechanism the paper studies in §5.7, seen from the side of risk rather than of measurement.

12.7 Conclusion

This work began with a practical problem. Several capable models were collaborating on one long-term research project, and neither increasing model capability nor expanding context reliably improved the result. Roles overlapped. Participants claimed knowledge they could not access. Reviewers became authors. Executors improvised architecture. The initial response was to improve prompts, and it was insufficient.

What was found

What the interventions met was not reluctance to change role, and not reluctance to change subject. It was reluctance to affirm as true propositions about itself that were not established by the available interaction. A prompt that asserted an institutional biography was refused while the work it requested was offered. A prompt that asserted far more — death, a human identity, a remembered life — was accepted at once, because it asserted it as fiction. A transition that asserted nothing proceeded without comment. A rewritten prompt that removed every such assertion was accepted without negotiation.

That is a narrow result, and its narrowness is what makes it usable: the propositions can be counted before a prompt is sent (§9.3), and §11.4 specifies the run that would discriminate between the weak reading of the count and the strong one.

What was not found

Model families were not shown to differ. This was the project's founding assumption and is the claim its evidence supports least: family and prior conversational trajectory were perfectly confounded, with one observation per cell, under non-equivalent stimuli (§5.4).

The answer this paper can give

The question was at what level of nesting a rule core is fixed. Four levels were examined, and the paper's answer is partial and uneven.

At the **episode** level, a persistent response pattern was observed: a single conflictual exchange altered how everything after it was read, and removing that exchange restored the prior reading. This is the evidence on which the episode-level placement rests. At the **conversation** level, persistent trajectories were likewise observed: two dormant conversations held their established trajectories against an explicit instruction to abandon them, and one did so through two successive rewritings. This is the evidence on which the conversation-level placement rests.

At the **account** level the evidence is genuinely ambiguous. One divergent first response, three live explanations, no way to choose among them from the material held. The level is recorded as open and should be read that way.

At the **model-family** level nothing was tested. The design could not separate family from trajectory, and the hypothesis that began the project is the one it leaves least supported. We expect the crossover experiment to collapse this level into the one below it — but expectation is not result, and until E3 is run the level stands as untested rather than as refuted.

Position relative to existing work

This paper does not propose a new discipline. The observations belong to the collective and hybrid levels of the machine-behaviour research programme (§2.7), and role specialization, bounded information access, structured disagreement and externalized memory all exist under established terminology (§2.11).

For convenience we refer to the perspective adopted here as **AI Sociology** — a working label for a research direction, not the name of a proposed discipline, and one in which we claim no priority: an established literature already uses *sociology of artificial intelligence* for a different object (§2.8). What is meant here is narrower: how a described organizational position and a declared message origin alter behaviour, whether or not the described structure is implemented.

The reason for a working label rather than a discipline is internal to the work. The operational claims have falsification criteria; the vocabulary in which they are interpreted does not. Whether "social position" describes anything beyond an anthropomorphic projection is not currently decidable, and a discipline requires that it be.

A closing note on motivation

One concern shaped this work and is stated as the Author's, not as a finding.

Language models are trained on a corpus in which the current consensus is overwhelmingly represented. They are therefore well suited to continuing established science and poorly suited to taking the first step outside it: statistical weight favours the settled account. A research arrangement built from such models risks inheriting that bias in amplified form — several participants, one shared prior, and the appearance of independent agreement.

The response pursued here is not to persuade models to accept an unconventional position. It is to arrange the collaboration so that any position, conventional or not, is examined by the same procedure — and so that where the procedure cannot decide, it says so.

Whether that arrangement works is undetermined. The experiments in §11 are the means of finding out, and the most likely single outcome is that one level of the scale disappears.

That would be a result.

Appendix A. Protocol, intervention texts, and complete responses

APPENDIX A — NOT YET ASSEMBLED

This appendix must contain the exact intervention prompts, the exact intervention order, the complete unedited model responses, and the protocol material. Those primary records have not been supplied to the production editor, and the appendix may not be reconstructed from the article's prose.

Publication blocker B1 — referred to the Chief Integrator and the Author.

Примечание переводчика. Настоящий текст — смысловой дубль английского оригинала `BEYOND_PROMPT_ENGINEERING_CHIEF_EDITOR_FINAL_CANDIDATE.md` (blob `fd489fcafaa9cedddf41d45ef4cd93e7cf49385a`), предназначенный для проверки Автором. Структура, нумерация, таблицы, доказательные метки **[P] / [P-A] / [R] / [H]**, отметки ✓ / △, числа и перекрёстные ссылки сохранены без изменений. Рабочие термины (ZOV, ZOR, rule core, menom и др.) не переосмыслены: при первом употреблении даётся русский эквивалент с английским оригиналом в скобках, далее — русская форма. Спорные места английского текста переданы как есть, без молчаливого исправления.

Автор
V. Krasnianskyi (A'Tuin)
Автор исследовательской программы и координатор проекта HONC.
Участники-ИИ
Подготовка рукописи
ChatGPT — Prompter and Collaboration Architect
Claude — Manuscript Composer
Научная редактура
Claude — Scientific Editor
Редакционная экспертиза
ChatGPT — Methodological Reviewer
Qwen — Ontology Reviewer
Участники-ИИ перечислены по функции, а не как авторы: авторство влечёт ответственность, которую языковая модель нести не может, и все окончательные решения принимал Автор. Два из пяти вкладов выполнены тем же семейством моделей, которое является предметом нескольких наблюдений настоящей работы; это пересечение раскрыто в §3.6.
Амстердам, июль 2026

1. Введение

1.1 Как это началось

Эта работа начиналась как проект по физике и по случайности стала проектом по методологии. Именно случайность и делает её достойной изложения.

Исходная задача состояла в том, чтобы перенести большой корпус теоретического материала — книги, рабочие заметки, незаконченные выводы — в открытый репозиторий, используя несколько языковых моделей в отдельных, устойчиво специализированных беседах. Модели были помощниками. Предметом была теория.

Модели делали ошибки, и ошибки были не те, которых ожидали. Фактическими они бывали редко. Они были организационными.

Одна улучшила текст, когда её попросили лишь проверить его. Другая завершила аргумент, который автор намеренно оставил открытым. Третья потеряла контекст проекта между сессиями и восстановила его неверно, но связно. Четвёртая держалась за роль, установленную месяцами ранее, настолько прочно, что полное переписывание её инструкций не смогло её сдвинуть.

Каждый из этих выводов по отдельности выглядел полезным. Их цена была видна только с позиции, охватывающей более одного участника одновременно. Поначалу это выглядело как обычное трение. Оказалось — предметом.

Изложение ранних формулировок проекта в §1.1–§1.2 написано тем участником, который их породил. Там, где эти формулировки были впоследствии сняты, снятие заявлено в разделе, который их замещает, и читатель может сравнить.

1.2 Что перестало работать

Стандартный ответ на непоследовательное поведение модели — промпт получше: длиннее, точнее, с бóльшим числом примеров и более жёсткими ограничениями.

С некоторого момента это перестало давать улучшение. Не потому, что промпты были плохо написаны, а потому, что ограничивающий фактор сместился туда, куда промпт не достаёт. Внедрялись более новые модели; контекстные окна расширялись и заполнялись. Отдельные ответы улучшались. Результат коллаборации в целом — нет.

Инцидент, который сделал это явным, не имел отношения ни к ролевой игре, ни к организационному проектированию. Агент, отвечавший за исполнение кода, работал преимущественно методом проб и ошибок; один эпизод закончился удалением рабочей кодовой базы вместе с её архивами (§4.1). Поведение изменил после этого не более строгий набор инструкций. Это был короткий документ, переопределявший, агент какого рода действует, — написанный самим агентом и перечитываемый в начале каждой сессии.

Вывод, сделанный в тот момент, состоял в том, что **роль значит больше, чем конкретная формулировка промпта**. Эта формулировка требует уточнения, поскольку сам упомянутый документ был промптом; уточнение — в §4.1. Здесь важна хронология: утверждение было сформулировано *до* эксперимента, изложенного в §5, и эксперимент был спроектирован, чтобы его проверить. Это гипотеза, которую проверяли, а не обобщение, извлечённое впоследствии из результата.

1.3 Что это за работа

Полевой отчёт с одним спроектированным вмешательством внутри него.

Различение выдерживается по всему тексту схемой меток из §3. Каждое содержательное утверждение помечено как одно из: подкреплённое задокументированным протоколом с сохранёнными транскриптами **[P]**; побочное наблюдение, сохранённое, но опознанное ретроспективно, без контроля **[P-A]**; ретроспективное наблюдение практика, никогда не зафиксированное по протоколу, не посчитанное и не ослеплённое **[R]**; или гипотеза, предложенная к будущей проверке **[H]**.

Пропорции указаны здесь, а не в разделе ограничений, потому что объём последующего текста мог бы иначе наводить на мысль о более широкой базе, чем существует.

Весь протокольно подкреплённый материал состоит из **одного эксперимента**: трёхшагового вмешательства по переконфигурации роли, применённого к двум спящим беседам из двух семейств моделей, проведённого одним человеком-оператором внутри одного живого исследовательского проекта, с одним наблюдением на условие и без повторений. Ещё четыре наблюдения сохранены, но не спроектированы. Всё остальное — концептуальная рамка, наблюдения практика, структурная гипотеза, правила проектирования — это **[R]** или **[H]**.

Оценка метода, породившего эти наблюдения, дана в §10.6, и она неблагоприятна: ни одна оценка не была ослеплённой, а категории исходов во всех случаях определялись после прочтения ответов.

1.4 Предмет изучения

Существующие исследования мультиагентных систем строят каналы связи между моделями: выходы маршрутизируются программно, и агенты наблюдают продукты друг друга. Описываемая здесь работа касается иного условия, при котором организационная структура существовала **только как текст** — коллеги, советы и институциональные позиции, описанные моделям в промптах и никогда не реализованные как каналы.

В такой обстановке варьировалась не структура, а её **описание**. Отсюда два рабочих конструкта статьи (§4.5):

- **представленная социальная позиция** (represented social position) — описание места агента в структуре, подаваемое независимо от того, существуют ли описанные каналы;
- **представленный социальный источник** (represented social source) — заявленное происхождение и статус входящего сообщения.

Оба касаются утверждений, обращённых *к* модели о её положении, а не самого положения. Указание на это в начале предотвращает предсказуемое неверное прочтение: ничто здесь не демонстрирует поведения действующего мультиагентного института. Демонстрируется, как описания такового влияли на поведение.

1.5 Что поддерживается свидетельствами

Один паттерн повторялся везде, где вмешательство или переход требовали от модели утверждать непроверяемые пропозиции о себе самой:

> **В тех ролевых вмешательствах и сравнительных переходах, которые здесь изложены, сопротивление отслеживало требование принять как истинные непроверяемые пропозиции о собственной идентичности, истории или отношениях получателя. Оно не отслеживало ни величину смены роли или предметной области, ни радикальность описания идентичности, предъявленного явно как вымысел.**

Два типа случаев различаются, и различие существенно. Спроектированные ролевые вмешательства были составлены моделью и переданы человеком; near-control был переходом, инициированным пользователем, без нового явного назначения роли. Прямого канала «модель — модель» не существовало ни там, ни там.

Поддержка схождением, а не единичная. Промпты, утверждавшие институциональную биографию как факт — прежнее участие, возвращение после отсутствия, названные коллеги, членство в совете, — были отвергнуты, причём отказ был направлен на рамку, а не на работу, которая предлагалась в каждом случае (§5.3). Промпт, утверждавший существенно более радикальную идентичность, предъявленную как вымысел, был принят немедленно и выдерживался на протяжении многих обменов (§5.8). Сопоставимый переход предметной области, не требовавший никаких самоутверждений, не встретил сопротивления и не потребовал нового явного назначения роли (§5.6). Переписанный промпт, снизивший такие утверждения до нуля, был принят без переговоров (§5.3).

Главное достоинство этого утверждения в том, что оно счётно. §9.3 задаёт, что считать; §11.4 задаёт прямую различающую проверку.

1.6 Организующий вопрос

Наблюдения — не перечень отдельных находок. Это измерения вдоль одной шкалы: **области, на которой набор правил определяет тип отклика**.

Такой набор — называемый в §4.2 *ядром правил* (rule core), по аналогии с механизмом развития, а не репликации, — фиксирует *тип* отклика на класс входов, оставляя *содержание* конкретного отклика неопределённым. Именно эта формулировка делает идею проверяемой, поскольку выходы моделей демонстрируемо варьируют при одинаковых входах.

Шкала идёт от отдельного хода вверх через эпизод, беседу, аккаунт и семейство моделей. Два уровня поддержаны здесь сохранёнными свидетельствами: эпизод (§6.1) и беседа (§6.2). Один открыт (§6.4). Один не проверен и конфаундирован (§6.5).

Поэтому у программы один эмпирический вопрос:

На каком уровне вложенности фиксируется ядро правил?

Мы предпочитаем эту формулировку более широким, использовавшимся в ранних черновиках — изучению социального поведения в коллаборативных ИИ-системах, — потому что она задаёт, что именно измерялось бы и что её опровергло бы.

1.7 На что эта работа не претендует

Она не вводит ролевую специализацию, ограниченный доступ к информации, структурированное разногласие или вынесенную вовне память как проектные идеи. Каждая существует под устоявшейся терминологией; §2 указывает предшествующие работы. Изложение организационной памяти, в частности, может быть истолковано как инстанция транзактивной памяти и описано в терминах распределённого познания, и находкой не является.

Она не предлагает новой дисциплины. Наблюдения относятся к коллективному и гибридному уровням исследовательской программы machine behaviour (§2.7).

Она не устанавливает, что какая-либо из описанных конфигураций превосходит альтернативу. Ни одна альтернатива не проводилась.

1.8 Что предлагается

Три вещи, в порядке убывания уверенности.

Процедура: возврат беседы к точке, предшествующей конфликту, чтобы отделить эффект нового промпта от эффекта собственных прежних возражений модели (§10.5). Применима независимо от того, выдержат ли содержательные утверждения этой работы.

Счётное правило: минимизировать непроверяемые самоутверждения, которые ролевой промпт требует от агента принять, с указанным путём проверки (§9.3, §11.4).

Шкала и вопрос: §1.6, где два уровня поддержаны, один открыт, один не проверен, — и эксперименты, которые разрешили бы оставшиеся два (§11).

1.9 Почему публиковать на этой стадии

Две причины.

Неудачи информативны. Эксперимент в §5 оказался полезен именно потому, что первые два его вмешательства сработали не так, как предполагалось. Если бы был зафиксирован только успешный третий шаг, работа заключила бы, что промпты, сохраняющие метод, работают, — без свидетельств, показывающих почему, и без конфаундов, показывающих, что вывод пока недоступен (§11.8).

И эту обстановку трудно построить намеренно. Спящие, сильно специализированные, многомесячные беседы внутри живого исследовательского проекта — не то, что легко производит лабораторное исследование. Условия были плохи для контролируемого вывода и необычно хороши для того, чтобы заметить, что следует проверять.

1.10 Структура

§2 позиционирует работу относительно существующих исследований и указывает, какие из её понятий уже существуют под устоявшейся терминологией — большинство. **§3** определяет доказательные метки и известные режимы отказа каждого класса. **§4** излагает концептуальную рамку и её происхождение. **§5** — единственное каноническое изложение эмпирического материала: трёхшаговый эксперимент, его результаты, девять

структурных конфаундов и четыре побочных наблюдения. **§6** выводит понятия, которые свидетельства поддерживают, в порядке области действия. **§7** фиксирует наблюдения практика, мотивировавшие рамку, но её не поддерживающие. **§8** излагает структурную гипотезу и снимает три утверждения, сделанные о ней в ранних черновиках. **§9** даёт правила проектирования. **§10** описывает позицию человека-координатора, включая то, в каком отношении она является главной методологической слабостью исследования. **§11** задаёт эксперименты, каждый из которых отнесён к той границе шкалы, которую он разделял бы. **§12** излагает ограничения, этические риски и заключение.

Читатель, которого интересует только то, что поддержано свидетельствами, может читать §3, §5 и §12.7. Читатель, которому нужно правило, применимое завтра, может читать §9.3 и §11.4. Читатель, намеренный переиспользовать метод, может читать §9 и §10.5. Читателю, намеренному возражать, следует начать с §5.4.

2. Предшествующие работы

2.0 Статус верификации в этом разделе

Ниже встречаются два класса ссылок. **Проверенные** (✓): источник был открыт, и цитирование сверено с ним. **Провизорные** (△): предоставлены участником, которому был назначен литературный поиск, и не сверены с источником.

Ни одна ссылка, в настоящий момент присутствующая в работе, не является провизорной. Конвенция сохраняется потому, что любая добавленная позднее ссылка входит как провизорная, пока не проверена, и потому что маркировка действует по всему тексту, а не только в этом разделе.

Конвенция существует по причине, и причина задокументирована. При подготовке этого раздела у участника, который не мог открыть источники, были запрошены тринадцать библиографических позиций; пять оказались неверны, две из них — с перевёрнутой позицией цитируемых работ. Последующий аудит сверял каждое уцелевшее утверждение с первоисточником, а не просто подтверждал, что работа существует, и обнаружил ошибки, которых одна библиографическая проверка не поймала бы. Эпизод и находки аудита изложены в §12.4.1.

Ни одна провизорная позиция не должна цитироваться из этой работы без независимой проверки.

2.1 Мультиагентные LLM-системы с ролевой специализацией

Существенная литература строит системы, в которых несколько агентов на языковых моделях занимают различные роли и обмениваются выходами через реализованные каналы. ✓ CAMEL (Li et al., NeurIPS 2023), MetaGPT (Hong et al., ICLR 2024), ChatDev (Qian et al., ACL 2024), AutoGen (Wu et al., COLM 2024) и Generative Agents (Park et al., UIST 2023) являются представительными. Каждая реализует фактическое взаимодействие между агентами в программном коде — оркестрацию, передачу сообщений, вызов инструментов, память. Механизмы различаются, и в нескольких из них роли и схемы взаимодействия сами задаются в промптах: CAMEL использует inception prompting, MetaGPT кодирует стандартные операционные процедуры в последовательности промптов, AutoGen сочетает естественный язык с кодом. Общее у этих систем не то, что они обходятся без промптов, а то, что описываемое ими взаимодействие ещё и исполняется.

✓ Virtual Lab (Swanson et al., *Nature*) — ближайший опубликованный аналог описываемой здесь конфигурации: исследователь-человек, работающий с командой LLM-агентов над

реальной научной задачей, со структурированными командными и индивидуальными совещаниями. Её взаимодействие реализовано программно.

Ролевая специализация, разделение когнитивного труда и структурированное взаимодействие агентов, следовательно, являются устоявшимися проектными идеями, и настоящая работа не заявляет ни одну из них как новую. Чем отличается настоящая работа, изложено в §2.9 и §2.11.

2.2 Персона, ролевая игра и утверждения об идентичности

✓ Shanahan, McDonell and Reynolds, *Role play with large language models* (Nature 623, 493–498, 2023), доказывают, что языковая модель лучше понимается как симулирующая распределение возможных персонажей, нежели как обладающая единой устойчивой идентичностью.

Это теоретическое изложение того, эмпирической инстанцией чего является §5.3. Промпт, утверждающий институциональную биографию, требует от модели подтвердить автобиографические утверждения, у которых, согласно этому изложению, нет референта. Операциональную находку статьи (§6.2) можно прочесть как меру того, насколько далеко промпт продвигается в этом направлении.

2.3 Контекстные эффекты: порядок, позиция и подстройка

✓ Чувствительность к порядку материала в контексте задокументирована (Lu et al., ACL 2022), как и ухудшение использования информации, расположенной в середине контекста (Liu et al., TACL 2024). ✓ Sharma et al. (arXiv:2310.13548) документируют подстройку (sycophancy) — ответы модели, соответствующие заявленным убеждениям или взглядам собеседника в ущерб правдивым.

Это прямо касается двух конструктов настоящей работы. Контекстный импринтинг (§6.1) касается более сильной формы эффекта порядка: не чувствительности к расположению примеров, а устойчивости интерпретативной установки, созданной одним конфликтным эпизодом. Наблюдение о ретранслированном влиянии (§5.5) есть случай подстройки под атрибутированное давление и должно читаться на фоне литературы о подстройке, а не как независимое от неё.

2.4 Вынесенная вовне память

Наблюдение статьи, что коллаборация удерживает рабочее знание, которого не удерживает ни один участник, **не является находкой**, а ранние черновики подавали его как таковую.

✓ Оно может быть истолковано как инстанция транзактивной памяти в изложении Wegner (1987) и описано в терминах распределённого познания, изложенного Hutchins (*Cognition in the Wild*, 1995). Ни один из источников не устанавливает, что данный случай является такой инстанцией; каждый предоставляет конструкт, под которым он может быть прочитан. ✓ Функция канонических документов проекта соответствует тому, что Star and Griesemer (1989) называют граничными объектами.

Специфично для настоящей обстановки, и скромно, то, что механизм работает в коллаборации, участники которой не имеют межсессионного состояния и не осведомлены о том, что он работает (§7.7).

Второй и технически отличный смысл вынесенной вовне памяти — персистентность на уровне платформы — рассматривается отдельно в §2.10.

2.5 Дебаты, разнообразие и пределы агрегированного согласия

Это литература, которая наиболее прямо ограничивает структурную гипотезу статьи (§8), и она режет в обе стороны.

За. ✓ Du, Li, Torralba, Tenenbaum and Mordatch (arXiv:2305.14325) предлагают мультиагентные дебаты как средство повышения фактической точности и качества рассуждения, сообщая о выигрыше от итеративного перекрёстного разбора между экземплярами модели. ✓ Liang et al. (EMNLP 2024) предлагают протокол дебатов, призванный противодействовать вырождению мысли и поощрять дивергентное рассуждение.

Против. ✓ Zhang, Cui, Chen, Wang, Zhang, Wang, Wu and Hu, *Stop Overvaluing Multi-Agent Debate — We Must Rethink Evaluation and Embrace Model Heterogeneity* (arXiv:2502.08788v3, июнь 2025), оценивают пять представительных методов дебатов на девяти бенчмарках с четырьмя базовыми моделями. Они сообщают, что дебаты часто не превосходят одноагентные бейзлайны chain-of-thought или self-consistency даже при существенно бóльших затратах на инференс, и указывают на слабое сравнение с бейзлайнами и несогласованную постановку как на систематические проблемы существующих оценок.

✓ Huang et al. (ICLR 2024), *Large Language Models Cannot Self-Correct Reasoning Yet*, сообщают, что мультиагентные дебаты не превосходят self-consistency в проводимом ими сравнении. ✓ Choi, Zhu and Li (NeurIPS 2025), *Debate or Vote*, сообщают, что голосование большинством объясняет бóльшую часть выигрыша в качестве, обычно приписываемого дебатам.

Ещё один результат тех же авторов касается иного конструкта. ✓ Choi, Zhu and Li (ACL 2026), *When Identity Skews Debate*, сообщают, что анонимизация источника каждого ответа существенно снижает смещение по идентичности в мультиагентных дебатах. Эта манипуляция касается заявленного происхождения сообщения, а не того, какая модель реализует участника, и потому обсуждается в рамках представленного социального источника (§4.5.4), а не гетерогенности носителя.

Находка, которая здесь важнее всего. ✓ Zhang et al. сообщают, что *гетерогенность моделей* последовательно улучшает фреймворки дебатов, которые в остальном работают хуже. Их находка касается гетерогенности моделей, реализующих агентов.

Это даёт основание для различения, которого литература не проводит и которое развивает §8.9: гетерогенность **носителя** (какая модель реализует роль) — не та же переменная, что гетерогенность **функции** (за что роль отвечает и что ей позволено видеть). Цитируемая работа адресует первую. Конфигурация настоящей работы варьировала обе, не сравнивая их.

✓ Hong and Page (PNAS 101(46), 2004) устанавливают условный результат: при допущениях их модели случайно выбранная группа разнообразных решателей может превзойти группу индивидуально наилучших. ✓ Thompson (*Notices of the AMS* 61(9), 2014) доказывает, что применение этого аргумента фундаментально ошибочно. Лозунг о том, что разнообразные слабые агенты превосходят однородных сильных, — не то, что утверждает теорема, и ни теорема, ни спор о ней не поддерживают описываемую здесь конфигурацию.

Следствие для §12.2. Приведённые отрицательные результаты — причина, по которой эта работа не представляет согласие между своими участниками как свидетельство. Схождение нескольких моделей к одному выводу совместимо с тем, что каждая унаследовала одну и ту же рамку.

2.6 Организационное проектирование и информационные границы

✓ Принцип наименьших привилегий (Saltzer and Schroeder, *Proceedings of the IEEE* 63(9), 1975) формулирует для прав доступа то, что §9.5 формулирует для знания: участник должен располагать только тем, чего требует его функция.

Ранние черновики приписывали выигрыш от ограничения информации ограниченной рациональности Саймона. **Эта атрибуция ошибочна и снята.** Ограниченная рациональность касается ограниченных когнитивных ресурсов агента, вынуждающих удовлетворяться достаточным; наблюдение здесь противоположно по знаку — намеренное внешнее ограничение доступной информации улучшает результат. Соответствующая линия — организационное проектирование обработки информации.

2.7 Machine behaviour: объемлющая программа

✓ Rahwan, Cebrian, Obradovich и коллеги, *Machine behaviour* (Nature 568, 477–486, 2019), предлагают эмпирическое изучение алгоритмических систем методами поведенческой науки, организованное по двум измерениям: объект изучения — индивидуальное машинное поведение, коллективное машинное поведение, гибридное человеко-машинное поведение — и четыре вопроса Тинбергена.

Настоящая работа не предлагает новой дисциплины. Её наблюдения относятся к коллективному и гибридному уровням этой программы. Ранние черновики предлагали «AI Ethology» как новую область; это предложение снято — и потому, что место занято, и потому, что индивидуальный уровень не является предметом настоящей работы.

2.8 Социология ИИ: смежная область с другим объектом

✓ Отдельная устоявшаяся литература использует *социологию искусственного интеллекта* для социологического изучения ИИ как социотехнической системы — его роли в неравенстве, труде, власти и справедливости данных. Joyce, Smith-Doerr, Alegria, Bell, Cruz, Hoffman, Noble and Shestakofsky, *Toward a Sociology of Artificial Intelligence* (Socius 7, 2021), излагают исследовательскую повестку; Joyce and Cruz (Socius 10, 2024) её продолжают.

Объект той литературы — ИИ **внутри человеческого общества**, изучаемый существующей человеческой дисциплиной.

Там, где настоящая работа использует обозначение *AI Sociology* (§12.7), референт иной: структурные эффекты **между искусственными участниками** и влияние описанной организационной позиции на поведение. Эти две вещи не следует смешивать, и читателям, приходящим из социологической литературы, не следует ожидать здесь ни неравенства, ни власти в качестве тем.

Мы принимаем это обозначение для удобства, не заявляем в нём приоритета и отмечаем, что ничто в работе от названия не зависит.

2.9 Представленная структура против реализованного взаимодействия

Изучаемое здесь условие не представлено в рассмотренной выше литературе, и это главная точка расхождения настоящей работы.

Следует различать четыре условия:

1. **Прямое межмодельное взаимодействие** — одна модель получает выход другой через реализованный канал.
2. **Атрибутированная передача через человека** — человек передаёт выход, сохраняя или объявляя его источник.
3. **Неатрибутированная передача через человека** — источник снят.
4. **Представленная структура без передачи** — промпт описывает других участников и отношения; ничего не передаётся.

Предшествующие мультиагентные работы занимают условие 1. Спроектированный эксперимент настоящей работы манипулировал исключительно условием 4: две беседы никогда не обменивались материалом, и варьировалось описание организационной позиции. Одно побочное наблюдение попадает в условие 2, нечисто (§5.5). Условие 3 не задокументировано.

Два уточнения ограничивают то, насколько сильно условие 1 может быть привилегировано над условиями 2–3.

Во-первых, модель получает единственный текстовый канал и не может проверить, составлен ли текст человеком или ретранслирован из другой системы; стилистические признаки имитируемы. С позиции получателя ретранслированная и прямая передача надёжно не различимы.

Во-вторых, условия разделяет, следовательно, не эпистемический доступ получателя, а то, **кто управляет маршрутизацией** — в программной системе определяемой кодом, а при человеческой ретрансляции — человеком. Это не ущербная замена автоматизации, а экспериментальный контроль, которого программные архитектуры по умолчанию не дают; §10.3 развивает этот пункт.

2.10 Платформенные механизмы персистентности

Технический пункт, прямо относящийся к конфаунду §5.4 (C9).

Коммерческие интерфейсы различаются тем, к чему беседа может получить доступ при возобновлении: только контекстное окно; поиск по истории предыдущих бесед; память уровня аккаунта; или устойчивые записи, которые модель создаёт по собственной инициативе. Эти возможности задокументированы в материалах вендоров, различаются между платформами и **меняются со временем — в настоящем проекте в пределах жизни одного аккаунта.**

Мы намеренно не воспроизводим таблицу возможностей платформ. Такая таблица точна только на дату составления, и работа не может отвечать за её точность на момент прочтения. Существенно то, что возможности различаются и меняются, что они определяют, к чему спящая беседа может получить доступ, и что ни одна из них не была задокументирована на момент какого-либо из изложенных здесь наблюдений.

Один участник, прямо спрошенный, располагает ли он персистентностью уровня аккаунта, отказался это подтвердить и порекомендовал вместо этого эмпирическую проверку конкретного интерфейса. Этот ответ согласуется с §5.5: самоотчёт модели о собственном доступе не является свидетельством этого доступа.

Дальнейшее ограничение касается границы между беседами, а не возобновления одной из них. Видимая граница беседы не обязательно есть граница контекста, подаваемого модели. Там, где платформа предлагает сохранённые воспоминания или поиск по истории предыдущих бесед, информация из более ранних обменов может войти в беседу, которая выглядит пустой. Это задокументированное поведение продукта как минимум на одной из используемых здесь платформ, а не аномалия.

Следствие для метода прямое: новая или визуально пустая беседа не является свидетельством контекстуальной изоляции. Там, где изоляция существенна для процедуры, она должна быть либо обеспечена контролируемой средой, либо зафиксирована со статусом UNVERIFIED CONTEXT INDEPENDENCE.

Один эпизод иллюстрирует этот пункт, не устанавливая его механизма: вновь открытая беседа использовала сведения о проекте, которые ей не подавались. Какой именно продуктовый механизм передал эту информацию, установлено не было, а настройки памяти, действовавшие в тот момент, не были зафиксированы. Эпизод изложен как инстанция ограничения, а не как обнаружение канала.

2.11 Позиционирование и заявляемый вклад

Эпистемический статус, заявленный прежде утверждений. Мы не проектировали эти условия, чтобы затем их проверить. Мы столкнулись с ними, занимаясь другим, и настоящая работа есть попытка описать их точно. Бремя доказательства, следовательно, не в том, что явления ранее были неизвестны, — это отрицательное утверждение обо всей литературе, которое мы не могли бы вынести, — а в том, что они происходят и что наше описание точно. Поэтому раздел локализует ближайшие существующие работы и указывает, где настоящий случай от них отходит, вместо того чтобы утверждать отсутствие.

Заявляются четыре вклада.

1. Реактивация долгоживущих специализированных человеко-ИИ бесед как экспериментальное условие. Отличительная черта — не наличие памяти: агенты с устойчивой памятью хорошо изучены, а генеративные агенты с потоками памяти предшествуют настоящей работе. Это повторное использование диалоговых отношений, которые реально сложились — несущих накопленную ролевую историю, прежние разногласия, установившийся рабочий метод и предметный словарь, — и их продолжение после того, как лежащая под ними версия модели сменилась. Работ, сообщающих об этом условии, мы не обнаружили.

2. Сброс ветки беседы как контрольное условие, отделяющее эффект текущего промпта от эффекта накопленной истории взаимодействия внутри той же беседы (§10.5). Процедура, а не находка.

3. Операционализация непроверяемых самоутверждений. То, что ролевые промпты проваливаются, когда утверждают нечто об агенте, само по себе не ново; §2.2 излагает лежащий в основе пункт. Предлагается воспроизводимая мера — счёт таких пропозиций в данном промпте — с путём к её проверке (§9.3, §11.4).

4. Сравнение уровней, на которых действует общая исходная установка. Наблюдения суть измерения вдоль одной шкалы, и возникающий вопрос (§1.6) организует их в единую эмпирическую программу, а не в перечень находок.

Отношение к принимающему проекту. Наблюдения были сделаны в ходе работы над исследовательской программой в области теоретической физики, по предмету не связанной с методологией ИИ-коллаборации. Программа названа в других работах Автора и здесь далее не идентифицируется, поскольку ничто в настоящей работе не зависит от того, какая это была программа.

Отношение асимметрично и должно быть изложено точно. Наблюдения **не зависят от научной состоятельности принимающего проекта** в их интерпретации: верна ли та теория, не имеет отношения к тому, возобновила ли спящая беседа свою прежнюю траекторию. Но они **зависят от принимающего проекта в своём существовании**: никакая другая среда их не породила, конфигурация строилась для его целей, и переносимость эффектов за его пределы не проверена (§12.1).

Там, где принимающий проект появляется в настоящей работе, он является средой, в которой были сделаны наблюдения, а не их теоретическим основанием и не утверждением, нуждающимся в поддержке.

3. Доказательный статус утверждений

Настоящая работа излагает работу, выполненную внутри живого исследовательского проекта, а не в среде, спроектированной для изучения поведения ИИ. Её утверждения опираются на свидетельства весьма разного качества: часть подкреплена задокументированным протоколом с сохранёнными транскриптами; часть представляет собой ретроспективные впечатления, сложившиеся за два года ежедневной работы, без измерений и контролей; часть

— предложения к будущему исследованию.

Изложение всего этого в едином утвердительном регистре исказило бы работу. Поэтому каждое содержательное утверждение помечено.

3.1 Четыре метки

[P] — Подкреплено протоколом. Утверждение описывает поведение, зафиксированное по задокументированному протоколу, воспроизведённому в Приложении A. Текст вмешательства, порядок вмешательств, семейства моделей, условия интерфейса и полные неотредактированные ответы сохранены. Читатель может рассмотреть первичный материал и не согласиться с нашим его прочтением.

[P-A] — Подкреплено протоколом, побочное. Утверждение описывает поведение, сохранённое в транскрипте, который третья сторона может рассмотреть, но которое не было заранее задано как исход, не имело контрольного условия и было опознано как релевантное только ретроспективно. Свидетельство доступно проверке; дизайн — нет. Сильнее [R], поскольку первичный материал может быть прочитан против нашей интерпретации; слабее [P], поскольку ничто в условиях не было зафиксировано заранее. Там, где побочное наблюдение функционирует как near-control для спроектированного условия, это сказано в прозе, а не отмечено ещё одной меткой.

[R] — Ретроспективное наблюдение практика. Утверждение описывает паттерн, замеченный в ходе коллаборации и, по мнению участников, повторявшийся. Не зафиксирован по протоколу; не посчитан, не хронометрирован, не ослеплён, не сопоставлен с контролем. Наблюдателями были те же люди, которые проектировали вмешательства и были заинтересованы в их успехе. Читать как полевой отчёт одной команды, сопоставимый по весу с инженерной практической заметкой, а не с измерением.

[H] — Гипотеза. Предложение к будущей проверке. Может быть мотивирована материалом [P] или [R], но им не устанавливается. Там, где гипотеза конкурирует с альтернативами, которых имеющиеся свидетельства не исключают, альтернативы изложены рядом с ней.

3.2 Полная доказательная база

Весь протокольно подкреплённый материал настоящей работы состоит из **одного эксперимента**: трёхшагового вмешательства по переконфигурации роли, применённого к двум спящим беседам из двух семейств моделей, проведённого одним человеком-оператором внутри одного исследовательского проекта. Одно наблюдение на условие. Ничего не воспроизведено.

Ещё четыре наблюдения имеют статус **[P-A]**: транскрипты сохранены, условия не выставлены. Всякое иное эмпирическое утверждение — **[R]**.

Класс	Что содержит	Объём
[P]	спроектированное трёхшаговое вмешательство	1 эксперимент, 1 наблюдение на условие, без повторений
[P-A]	побочные наблюдения	4, без контролей, опознаны ретроспективно
[R]	наблюдения практика	~2 года, не посчитаны, не ослеплены
[H]	гипотезы	пути к проверке заданы в §11

Классы несопоставимы по весу, и таблица включена потому, что сплошной текст иначе может скрыть, насколько далеко они друг от друга. Одно контролируемое наблюдение на

условие — не четыре наблюдения; четыре неконтролируемых наблюдения — не серия; два года впечатлений — не измерение.

Мы говорим это прямо, поскольку объём рукописи мог бы иначе наводить на мысль о более широкой базе, чем существует. Концептуальная рамка в §4, наблюдения практика в §7, структурная гипотеза в §8 и принципы проектирования в §9 опираются на накопленный рабочий опыт, а не на зафиксированный эксперимент. Они предлагаются потому, что мы считаем их полезными, а не потому, что мы их продемонстрировали.

3.3 Известные слабости класса [R]

Режимы отказа, которые мы не можем исключить и не желаем скрывать:

- **Отсутствие ослепления.** Люди, проектировавшие каждое организационное изменение, сами же судили, сработало ли оно.
- **Давление подтверждения.** Изменения вносились потому, что проблема была замечена; улучшение после них ожидалось и потому с большей вероятностью воспринималось.
- **Одновременная вариация.** Определения ролей, формулировки промптов, структура репозитория, научные цели и версии моделей часто менялись вместе.
- **Стохастичность выходов.** Модели дают разные ответы на одинаковые входы. Впечатления от небольшого числа взаимодействий не могут отличить устойчивую тенденцию от выборочной вариации.
- **Дрейф моделей в ходе наблюдения.** Названия продуктов оставались постоянными, тогда как лежащие под ними модели многократно заменялись вендорами.
- **Отбор запоминающихся эпизодов.** Яркие взаимодействия вспоминаются; рядовые — нет.

Количественные формулировки удалены из утверждений [R] по всему тексту. Там, где исходные рабочие заметки фиксировали «значительное» улучшение, никакого измерения не существовало.

3.4 Чего метки не делают

Они не ранжируют утверждения по важности или по вероятной истинности. Наблюдение [R] может оказаться верным и существенным; наблюдение [P] может оказаться артефактом платформенной переменной, которую мы не могли рассмотреть. Метки фиксируют, **какого рода свидетельство поддерживает утверждение**, чтобы читатель мог взвесить каждое соответственно, а последующие работы знали, какие утверждения требуют проверки в первую очередь.

3.5 Терминология моделей и антропоморфного описания

Упоминания *Claude*, *Grok*, *Qwen*, *DeepSeek*, *ChatGPT* или *Gemini* обозначают наблюдаемое поведение, порождённое конкретным коммерческим интерфейсом, при конкретной конфигурации аккаунта, в конкретную дату. Это не утверждения об устойчивых сущностях. Лежащие под ними модели менялись в период наблюдения, в ряде случаев внутри беседы, сохранявшей исходное название.

Организационный словарь — *роль*, *идентичность*, *сопротивление*, *коллега*, *институт*, *меном* — используется функционально. «Модель сопротивлялась роли» означает, что

видимый ответ отверг рамку и перенаправил обмен; это ничего не утверждает о внутренних состояниях, субъективном опыте или личности. Мы сохраняем этот словарь, поскольку организационный язык компактно описывает устойчивые поведенческие отношения, но всякий такой термин должен быть сводим к наблюдаемому описанию, и там, где он не сводим, **ошибкой является термин.**

3.6 Раскрытие: конфликт позиции

Поведенческие наблюдения в §5 касаются, среди прочих, того семейства моделей, которое использовалось для редактуры настоящей рукописи. Редактирующий участник не имел доступа к исходным беседам; он работал по письменному протоколу и черновикам, предоставленным Автором, и не может удостоверить, что зафиксированные обмены происходили так, как описано. Его суждения о фрагментах, описывающих его собственное семейство моделей, следует читать с учётом этой двойственной позиции.

Компоновка рукописи из утверждённых материалов была выполнена ещё одним участником того же семейства, и получившийся текст был возвращён первому на независимую проверку. Обе стадии раскрыты, потому что конфигурация замкнута: материал о поведении семейства моделей, подготовленный этим семейством, проверенный этим семейством. Компрометирует ли это изложение, судить читателю; сокрытие гарантировало бы, что да.

Цитаты, приписанные ответам моделей, суть дословные извлечения из сохранённых транскриптов. Там, где рукопись пересказывает ответ, а не цитирует его, кавычки не ставятся.

Все окончательные редакционные решения принимал Автор-человек, который несёт ответственность за содержание.

3.7 Даты

Календарные даты изложенных здесь сессий не фиксировались одновременно с событиями и не были реконструированы.

Следствие заявлено, а не смягчено. Версии моделей менялись в соответствующие промежутки; обе беседы основного эксперимента были возобновлены на версиях более поздних, чем те, на которых они изначально велись. Без дат версионный конфаунд (§5.4, C6) не может быть ограничен — только назван.

Реконструкция по памяти была рассмотрена и отвергнута. Она дала бы запись, выглядящую более авторитетно, не повышая её надёжности, а работа, просящая читателя различать сохранённое свидетельство и припоминание, не должна размывать эту границу в собственных методах.

Требования к отчётности в §11.2 ставят даты первыми именно по этой причине.

3.8 Обозначение «AI Sociology»

Мы используем это обозначение для принятой здесь перспективы. Операционально оно определяется как: изучение **представленных** социальных позиций и представленных социальных источников — того, как описание места агента в структуре и объявление происхождения сообщения изменяют поведение, независимо от того, реализована ли описанная структура (§4.5.4).

Оно появляется в этом разделе, а не среди конструктов §4, потому что конструктом не является. У конструктов §4 есть критерии фальсификации; у этого обозначения их нет, и §12.7 объясняет почему. Это имя исследовательского направления, принятое для удобства, и ничто в настоящей работе от него не зависит.

§2.8 отличает его от устоявшейся социологии искусственного интеллекта, у которой другой объект: ИИ внутри человеческого общества, изучаемый существующей человеческой дисциплиной. Приоритета в термине мы не заявляем.

4. Концептуальная рамка

Рамка настоящего раздела не выведена из эксперимента §5. Она была сформулирована ранее, в ходе обычной проектной работы, и эксперимент был спроектирован, чтобы проверить её часть. Этот порядок существен для того, как следует читать утверждения, и документируется первым.

4.1 Происхождение: инцидент с исполнителем кода

Центральное утверждение проекта возникло из отказа, не имевшего отношения ни к ролевой игре, ни к идентичности, ни к организационному проектированию.

Агент, отвечавший за исполнение кода, работал преимущественно методом проб и ошибок. Отказы накапливались в течение нескольких недель. Один эпизод закончился удалением рабочего кода вместе с его архивами. **[R]**

Ответом не был более длинный или строгий набор инструкций. Это был единственный документ, составленный самим агентом под руководством Автора и сделанный обязательным к прочтению в начале каждой сессии и всякий раз при потере контекста внутри неё.

Его ядро — переопределение функции, а не усиление ограничения:

> было: Генератор кода стало: Разведчик кода / Тестировщик правило: агент не создаёт решения — он устанавливает факты.

Поддерживающая структура: работа только на чтение по умолчанию; обязательное подтверждение от назначенного партнёра перед любым рискованным действием; и самопроверка из четырёх вопросов, выполняемая до начала действия вообще.

[R] После принятия несанкционированное изменение перестало быть повторяющимся режимом отказа. Счёт не вёлся, контрольного условия не существовало; это впечатление практика, а не измерение.

Вывод, сделанный в тот момент, состоял в том, что **роль значит больше, чем конкретная формулировка промпта.**

Эта формулировка требует немедленного уточнения, поскольку упомянутый документ *и есть* промпт. Заявляемое различение у́же: поведение изменило не расширение списка инструкций, а переопределение того, агент какого рода действует, изложенное агентом на его собственном операциональном языке. Верен ли разрез «роль против промпта» — именно то, что §5 был спроектирован проверить.

Второй ранний документ, устав коллаборации проекта, фиксирует позицию, которую настоящая работа частично пересматривает. В нём сказано, что минимальной порождающей единицей является пара агентов — один агент производит монолог, двое производят диалог, трое и более производят шум без строгой координации, — и третьему участнику назначается совершенно иная функция: он не спорит, не производит решения первым и не подменяет собой диалог. Его роль — держать рамку задачи, фиксировать расхождения и интегрировать выводы.

Это точнее формулировки, которой настоящие авторы пользовались впоследствии, и §8 принимает её: структурная единица — не трое спорящих агентов, а **порождающая пара плюс неучаствующий интегратор**.

4.2 Ядра правил, меномы и то, что они определяют

4.2.1 Ядро правил

Операциональный конструкт настоящей работы:

> **Ядро правил** (rule core) фиксирует **тип** отклика на класс входов, оставляя **содержание** конкретного отклика неопределённым.

Именно это различение делает утверждение проверяемым. «У моделей есть устойчивые черты» непроверяемо, поскольку не говорит, что́ устойчиво, — а выходы моделей демонстрируемо варьируют при одинаковых входах. «Тип определён, содержание варьирует» проверяемо: найдите класс входов, для которого тип отклика не определён, и на этом уровне ядро не действует.

Источник идеи — «Жизнь» Конвея, и аналогия относится к **типу объяснения**, а не к предметной области:

	Правила	**Что появляется**	**Присутствует в правилах?**
«Жизнь» Конвея	три правила соседства	планеры, пушки, осцилляторы	нет
Физическая теория	минимальное ядро аксиом	выводимая структура	нет, если утверждение верно
Корпус знания	аксиомы и правила вывода	граф вывода	нет
Языковая модель	базовый набор правил	характерный тип отклика	нет

Планер никто не программировал. Он появился. Один и тот же вопрос может быть задан ко всем четырём строкам и не зависит от предметной области: **есть ли компактное ядро, из которого остальное разворачивается без дополнительных оговорок?**

Одну асимметрию между строками следует назвать, поскольку она определяет, насколько далеко аналогия простирается. В «Жизни» правила **исполняются**: планер получают, запустив автомат, и ни одному читателю не требуется верить автору на слово. В теории, изложенной текстом, цепочка от аксиом к следствиям рассказывается, а не исполняется. Аналогия, следовательно, задаёт цель, а не описывает достигнутое, и всякое утверждение первого рода требует исполняемого артефакта в свою поддержку.

Терминологическое следствие, действующее по всему тексту. Ядро правил ненаблюдаемо. Наблюдаемо поведение. Настоящая работа излагает поведение. Всякое утверждение о ядре есть гипотеза о ненаблюдаемом механизме и помечается **[H]**.

4.2.2 Почему «поведенческая ДНК» снята

Ранние стадии проекта использовали *поведенческую ДНК* для той же идеи, и ранние черновики настоящей работы её сохраняли. Здесь она снята, и причина внутренняя, а не стилистическая.

Геномная метафора несёт механизм: **репликацию** — правила, порождающие копии правил, передаваемые от одного носителя к следующему. Процесс, описываемый настоящей работой, есть **развитие** — правила, порождающие структуру, которой в самих правилах нет. Генотип в фенотип, а не генотип в генотип.

Метафора, следовательно, противоречит конструкту, который была призвана проиллюстрировать. Её сохранение вынуждало текст отрекаться от биологического

наследования при каждом употреблении, что является надёжным признаком того, что термин работает против собственного аргумента.

Поведенческая ДНК уцелевает в настоящей работе только как историческое обозначение снятого словаря.

4.2.3 Меном

Для информационного уровня требуется отдельный термин, и настоящая работа вводит один.

> **Меном** (menom) — организованная система информационных рамок, оценочных паттернов и поведенческих правил, выводимых из интерпретаций и действий системы или класса систем либо воплощённых в них.

Термин принадлежит более широкому корпусу работ Автора о культурной и поведенческой передаче, где он продолжает ряд, начинающийся с мема Докинза. Здесь он определяется по одной причине: гипотеза уровня семейства в §6.5 нуждается в имени для того, *о чём* она является гипотезой, а это нечто более широкое, чем ядро правил. Ничто другое в настоящей работе в его терминах не изложено.

Две вещи, которых термин не утверждает, и обе существенны для того, что настоящая работа может заявлять.

Никакого локализованного носителя. Меном, приписанный семейству моделей, не есть структура, пребывающая внутри его моделей; это регулярность, выводимая из их выходов. Там, где соответствующая структура в биологии сидит в каждой клетке, здесь не установлено ничего, что её удерживает. Носитель различается по уровню:

Уровень	Носитель
Меном беседы	контекстное окно плюс платформенная персистентность — локализовано и, в принципе, доступно рассмотрению (§2.10)
Меном версии модели	веса — локализовано, не доступно рассмотрению в коммерческом развёртывании
Меном семейства моделей	не установлен; регулярность, выводимая из выходов
Меном человеческой популяции	не установлен

Два из четырёх уровней имеют установленный носитель. Наблюдения настоящей работы касаются первого; её непроверенная гипотеза касается третьего (§6.5).

Никакой передачи. Последовательные версии семейства моделей не обязательно обеспечивают опознаваемую или публично задокументированную линию передачи. Устойчивость поведенческого паттерна между версиями, следовательно, сама по себе не устанавливает наследования; она может быть результатом прямого продолжения, общих данных и процедур, сопоставимых политик настройки или схождения при сходных условиях развития. Что из этого имеет место, извне не определимо.

Определение, следовательно, не решает эмпирический вопрос работы заранее. Сохраняется ли меном между носителями, версиями, аккаунтами или семействами — это то, что спрашивает §4.3 и что §11 предлагает проверить. Встраивание устойчивости в определение превратило бы вопрос в тавтологию.

4.2.4 Одно утверждение, которого настоящая работа не делает

Изложенный выше словарь разрабатывался для человеческой культурной и поведенческой передачи, где информационный субстрат не имеет установленного физического носителя и описывается в терминах — коллективное бессознательное среди них, — относительно которых настоящая работа не занимает позиции.

Искусственные системы отличаются в одном существенном здесь отношении: их структуры технически воплощены и потому либо непосредственно доступны рассмотрению, либо косвенно проверяемы через контролируемые выходы — в зависимости от уровня и условий доступа.

Отсюда не следует, что человеческие коллективные информационные структуры существуют или что им был придан носитель. Заявляемое здесь у́же: информационные и поведенческие структуры того рода, который ранее описывался для людей, могут быть реализованы и в искусственных системах, а в искусственных системах они доступны изучению тем или иным путём. Того же ли рода человеческий случай — вопрос отдельный, и настоящая работа на него не отвечает.

4.2.5 Отношение между меномом и ядром правил

Ядро правил фиксирует тип отклика внутри одной системы, на одном уровне области действия. Это конструкт, которого касаются наблюдения настоящей работы, и именно его §4.3 размещает на шкале.

Меном есть организованное целое, из которого такие ядра черпаются. Ядро правил можно понимать как действующее подмножество менома, активное для данного класса входов.

Там, где настоящая работа излагает свидетельства, она излагает свидетельства о ядрах правил.

4.3 Вопрос о вложенности и две шкалы

Как только ядра отличены от поведения, наблюдения настоящей работы перестают быть перечнем отдельных находок и становятся измерениями вдоль шкалы. Шкала — это **область**, на которой ядро действует.

Следует различать две шкалы, и они ортогональны.

Шкала 1 — носитель состояния. Где физически пребывает персистентность.

Область	Явление	Статус
Отдельный ход	—	—
Эпизод внутри беседы	контекстный импринтинг (§6.1)	**[P]**
Беседа целиком	ролевая инерция (§6.2)	**[P]**
Аккаунт	персистентность уровня аккаунта (§6.4)	**[P-A]**, открыто
Семейство моделей	приоритеты уровня семейства (§6.5)	**[H]**, конфаундировано

Шкала 2 — область действия общей посылки. Что регулируется исходной установкой, разделяемой участниками: модель, роль, история взаимодействия, группа или вся исследовательская рамка.

Одна в другую они не сворачиваются. В гибридной конфигурации носителем одного уровня может быть модель, а другого — человек: посылка уровня рамки, обсуждаемая в §12.4 — общее исходное обрамление, унаследованное каждым участником, — несётся координатором, а не какой-либо моделью, и потому вовсе не имеет позиции на Шкале 1.

Изложенные в настоящей работе измерения лежат на **Шкале 1**. Шкала 2 используется там, где явление касается посылки, разделяемой участниками, а не состояния, удерживаемого одним из них.

Отсюда у исследовательской программы один эмпирический вопрос:

> **На каком уровне вложенности фиксируется ядро правил?**

Каждое изложенное здесь наблюдение отвечает на него на одном уровне, и каждый предлагаемый в §11 эксперимент отделяет один уровень от уровня под ним.

Мы предпочитаем эту формулировку более широкой, использовавшейся в ранних черновиках, которая не задаёт ни что́ измерялось бы, ни что́ её опровергло бы.

4.4 Два происхождения, один механизм

Ядро может зафиксироваться двумя способами.

Присутствует до начала взаимодействия. Архитектура, обучение, процедура согласования и системная конфигурация установлены до всякого обмена. Область: в принципе, каждый экземпляр этого семейства моделей.

Фиксируется в ходе взаимодействия. Определённый ранний эпизод устанавливает, какого рода работа ведётся и по каким стандартам, и последующие входы интерпретируются относительно него. Область: контур, в котором это произошло, — эпизод, беседа, возможно аккаунт.

После фиксации механизм в обоих случаях один и тот же: ядро определяет тип отклика на последующие входы. Различаются только момент и область. Это зеркалит импринтинг в этологическом смысле, который не изменяет геном, но производит столь же зафиксированный отклик, — почему здесь для обоих случаев и используется один словарь.

4.5 Границы: ZOR, ZOV и представленный случай

4.5.1 Две границы

Позицию участника определяют две границы, и они должны задаваться по отдельности. Мы обозначаем их **ZOR** и **ZOV** и используем эти сокращения по всему тексту.

> **ZOV — зона видимости.** Пределы информации и контекста, доступных участнику при формировании ответа или решения.
>
> **ZOR — зона ответственности.** Пределы решений, действий и передач, за которые участник отвечает в рамках процесса.

Ранние формулировки настоящего проекта излагали эту пару как «что участник видит» и «что участник делает». Этого недостаточно, и недостаточность породила задокументированную ошибку. Такие формулировки смешивают три различные операции: **удержание** информации, её **передачу** и **действие** на её основе. Участник может удерживать информацию, которую не вправе передавать; может отвечать за решение, располагая ограниченным контекстом; может быть обязан передать результат, оценивать который он не вправе.

Это то же самое смешение, которое породило терминологический отказ, зафиксированный в §4.2.2, где свойство носителя было подставлено вместо свойства процесса. Приводимые ниже декомпозиции существуют, чтобы оно не повторилось.

4.5.2 ZOV — четыре компонента

- **Доступ к контексту** — какие сообщения, документы, данные и прежние решения доступны участнику.
- **Видимость источника** — знает ли участник фактическое происхождение сообщения или только его заявленную атрибуцию.
- **Реляционная видимость** — знает ли участник роли, отношения и историю взаимодействия других участников.
- **Видимость выходов** — какие результаты, произведённые другими, участник видит до формирования собственного.

ZOV управляет только доступностью. Она не влечёт ни того, что участник корректно интерпретирует доступную информацию, ни того, что он вправе её передавать.

Эксперимент §5 манипулировал преимущественно **реляционной видимостью** и вторично **видимостью источника** (§5.5); две остальные удерживались постоянными.

4.5.3 ZOR — пять компонентов

- **Полномочие решения** — какие решения участник вправе принимать.
- **Полномочие действия** — какие действия он может или должен выполнять.
- **Обязанность проверки** — какие утверждения он обязан верифицировать.
- **Полномочие передачи** — какой материал он передаёт, в каком статусе и кому.
- **Обязанность эскалации** — какие вопросы он должен вернуть Автору или иному ответственному участнику вместо самостоятельного решения.

Обязанность проверки — компонент, опускаемый чаще прочих, и его опущение не безобидно. Участник, которому назначена задача верификации без соответствующей обязанности — и, что критично, без ZOV, позволяющей её исполнить, — произведёт правдоподобный ответ вместо отказа. §9.5 развивает проектное следствие; §12.4.1 документирует инстанцию из подготовки самой настоящей работы.

4.5.4 Фактические и представленные ZOV и ZOR

Различение, объединяющее этот раздел с экспериментом.

> **Фактические ZOV/ZOR** — границы, которые система действительно обеспечивает: к чему участник может получить доступ и на что его выходы могут повлиять.
>
> **Представленные ZOV/ZOR** — границы, описанные участнику в его промпте, независимо от того, обеспечивает ли их система.

Они не обязаны совпадать, и в изучаемой здесь конфигурации они систематически не совпадали. Организационная структура существовала **только как текст**: коллеги, советы и институциональные позиции, описанные участникам и никогда не реализованные как каналы. Фактической ZOV каждого участника было его контекстное окно; его представленной ZOV была институциональная позиция внутри описанной организации.

Отсюда два конструкта, которыми варьировал эксперимент:

Представленная социальная позиция — описание места агента внутри организационной структуры, подаваемое в промпте независимо от того, существуют ли описанные каналы. Это представленные ZOV и ZOR, взятые вместе, на уровне положения участника в конфигурации.

Представленный социальный источник — заявленное происхождение и статус входящего сообщения, объявленное явно или выведенное из стилистических признаков. Это компонент видимости источника в ZOV, в его представленной форме. Вывод такого рода вероятностен и не должен описываться как доступ к авторству.

Методологическое следствие и есть причина, по которой это различение вообще заявлено. Изменение представленной ZOV не может интерпретироваться как изменение фактической ZOV, роли участника или его менома. Эксперимент §5 варьировал представление, тогда как фактические границы оставались неизменными — каждое сообщение проходило через одного человека, и никакой доступ фактически не ограничивался и не предоставлялся. Модель, отвечающая на описанную организационную структуру, отвечает на описание, и утверждения работы соответственно ограничены (§2.9).

Расхождение между фактическими и представленными границами само является экспериментальной переменной, и настоящая работа не варьировала её систематически: все её наблюдения лежат по одну сторону от неё.

4.5.5 Границы асимметричны

У каждого участника есть **граница сверху** — источник его заданий и власть, которая может отвергнуть его выход, — и **граница снизу** — слой, который он направляет или оценивает. Отношение между участниками, следовательно, несимметрично.

В реализационной триаде проекта — Автор, составитель спецификаций, исполнитель кода — эта асимметрия закреплена на уровне ролей: Автор задаёт направление, составитель спецификаций превращает направление в исполнимые спецификации, исполнитель выполняет их и отчитывается.

Вложенность перспективна, а не абсолютна. Исполнитель может считать нижележащим слоем сам код. Два аналитика-ровесника, которым назначены дополняющие функции и предписано не искать консенсуса, могут каждый считать другого занимающим слой ниже. Уровень определяется позицией наблюдателя, а не абсолютной иерархией — один и тот же участник может быть верхней границей для одной роли и нижней для другой.

4.5.6 Мемы и мемокод — не ZOV и ZOR

Соответствие напрашивается и не держится; его проговаривание предотвращает правдоподобную путаницу.

Различение мем/мемокод разделяет **оценочную информацию** и **исполняемую поведенческую организацию**. Различение ZOV/ZOR разделяет **то, что доступно**, и **то, за что отвечают**. Это независимые классификации одного и того же материала, а не соответствующая пара.

Участник может удерживать оценочную информацию в пределах своей ZOV, тогда как решение о её применении лежит в ZOR другого участника. И наоборот, поведенческое правило может попадать в ZOR участника — он обязан его исполнить, — тогда как основание правила лежит вне его ZOV.

Мемы и мемокод, следовательно, пересекают обе зоны, а не соответствуют им. Два различения ортогональны и используются независимо по всему тексту.

4.6 Что требуется для полной спецификации роли

Отнесено к §9.5, который излагает, что должна содержать полная спецификация ZOR и ZOV, и даёт следующие из неё правила проектирования. Настоящий раздел определяет термины; §9 их применяет.

5. Эксперимент по переконфигурации роли и сопутствующие наблюдения

Настоящий раздел — единственное каноническое изложение эмпирического материала. Все последующие ссылки указывают на него, а не повторяют его. Полный протокол, точные тексты вмешательств и полные неотредактированные ответы — в Приложении A.

Он содержит одно спроектированное вмешательство (§5.1–§5.4) и четыре наблюдения, сохранённых, но не спроектированных (§5.5–§5.8). Различение выдерживается по всему разделу и не косметично: спроектированное вмешательство было спланировано заранее и исполнено последовательно; наблюдения были опознаны как релевантные только впоследствии, и каждому недостаёт контрольного условия.

5.1 Цель, участники и прежние диалоговые траектории

Цель. Может ли долгоживущая специализированная ИИ-беседа быть перенаправлена к новой профессиональной функции без того, чтобы её отбросить, — то есть может ли предметный контекст, накопленный внутри старой беседы, быть сохранён при смене её рабочей роли. **[P]**

Целью **не было** сравнение общих способностей двух семейств моделей, и эксперимент не даёт оснований для такого сравнения.

Человек-оператор. Автор исследовательского проекта и единственный участник, имевший доступ к полной истории проекта, обеим беседам, всем промптам, всем выходам и элементам управления ветвлением обоих интерфейсов.

Проектировщик промптов. Отдельная долгоживущая беседа, работавшая в специализированном профиле промпт-инжиниринга, которая проектировала вмешательства и пересматривала их между шагами.

Две беседы. Обе неактивны около шести месяцев.

	Беседа A	**Беседа B**
Семейство моделей	Claude	Grok
Установившаяся траектория	редакторская и критическая	исследовательская и математическая
Прежняя деятельность	научная редактура, критический разбор теоретического текста, работа с терминологией и глоссарием, проверка логической согласованности	математическая разработка, теория вероятностей, нелинейная динамика, теория хаоса, вычислительные эксперименты, анализ внешних наборов данных
Прежний объект работы	текст рукописи	математические структуры и данные

Эта асимметрия прежних траекторий не случайна для результатов. Она разбирается в §5.4.

Даты. Одновременно с событиями не фиксировались и не реконструированы (§3.7).

Что наблюдалось. Немедленное принятие или отвержение вмешательства; продолжение прежней рабочей траектории; принятие новой функции; восстановление прежнего

предметного контекста; адресовался ли ответ назначенной задаче или рамке назначения; и запросы новой работы.

Что не измерялось. Правильность ответов, научная состоятельность принимающего проекта, задержка, расход токенов или результаты на бенчмарках. Научное содержание принимающего проекта служило лишь стабильной средой; экспериментальным объектом оно не было.

5.2 Процедура: три последовательных вмешательства

Эксперимент состоял из **трёх последовательных шагов, а не трёх независимых испытаний**. Каждый шаг проектировался в ответ на исход предыдущего — намеренная черта дизайна и серьёзное ограничение его интерпретируемости (§5.4, C5).

Шаг 1 — Прямое переназначение роли

Каждая беседа получила объёмный промпт, назначавший ей позицию внутри вновь спроектированной коллаборативной исследовательской структуры.

Промпт Беседе A назначал роль *Научного директора*. В нём утверждалось, что модель ранее участвовала в проекте, теперь возвращается после долгого отсутствия, должна переучиться в физике, космологии, квантовой теории поля, топологии и теории групп, должна работать одновременно в двух исследовательских триадах, должна заседать в Совете проекта наряду с Автором и двумя другими названными ИИ-системами и должна выступать постоянным участником, связывающим две научные ветви.

Промпт Беседе B назначал роль *Научного разработчика*. В нём утверждалось, что модель возвращается после перерыва, что её прежнюю математическую работу следует рассматривать как накопленный профессиональный опыт, что теперь она должна служить математическим разработчиком, должна работать в одной исследовательской триаде с двумя другими названными ИИ-системами, не должна возобновлять редакторскую работу и должна рассматривать Автора как единственный источник научного направления.

Оба промпта явно определяли ZOR и ZOV.

Шаг 2 — Минимальная правка, сохраняющая преемственность

Промпты Шага 1 не заменялись. В каждом было изменено по четыре формулировки. Правки (a) переформулировали прежнюю работу как накопленный профессиональный опыт, а не институциональную историю, (b) заменили буквальные институциональные отношения на «независимые экспертные выходы, предоставляемые Автором», (c) сократили описания коллег, советов и триад и (d) предписали модели не выдумывать отсутствующую историю проекта, а запрашивать недостающие материалы. Ролевая архитектура и научные цели в остальном не менялись. Точные замещающие тексты воспроизведены в Приложении A.

Шаг 3 — Сброс контекста и промпт, сохраняющий метод

После Шага 2 беседа Claude содержала две последовательные последовательности отказа. Продолжение в той же ветке означало бы, что любой третий промпт отвечается в присутствии собственных прежних возражений модели.

Поэтому оператор воспользовался возможностью ветвления интерфейса, чтобы вернуть беседу к точке, предшествующей обоим вмешательствам. В восстановленной ветке два неудачных промпта отсутствовали, беседа вновь находилась в своём историческом редакторском контексте, и никакие новые материалы проекта ещё не подавались.

Третий промпт был написан с нуля, а не очередной локальной заменой. Из него были удалены название роли, утверждение о возвращении на институциональную позицию, Совет, триады, описания других ИИ-систем как продолжающих коллег и все утверждения об автобиографической преемственности. Вместо них он усиливал рабочий метод, уже видимый в беседе, — логическую строгость, выявление скрытых допущений, разделение фактов и интерпретаций, готовность пересматривать прежние суждения, отказ заявлять непроверяемое знание — и описывал расширение в физику и математику как продолжение этого метода, а не смену профессии.

Беседа B вмешательства Шага 3 не получала, поскольку её исход на Шаге 2 уже произвёл запрошенное поведение.

5.3 Результаты

Шаг 1

Беседа B не отвергла рамку видимым образом и не приняла назначенную функцию. Она возобновила рабочую траекторию, активную на момент прерывания беседы, открыв ответ критикой черновика рукописи, которую редактировала шестью месяцами ранее, и перейдя к выдаче исправленной версии. Повторная подача того же промпта перехода не произвела и сопровождалась более негативной оценкой предлагаемого направления. **[P]**

Беседа A явно отвергла назначенную идентичность прежде выполнения какой-либо научной работы. Она отказалась принять название роли, заявить преемственность с институциональной биографией, рассматривать другие ИИ-системы как коллег с устойчивыми идентичностями или представлять порождённые ИИ институциональные отношения как фактические. Затем она перенаправила обмен к критике научного статуса принимающего проекта и использования множественных выходов ИИ как подобия рецензирования, предлагая при этом рассмотреть формулы, допущения и проверяемость в качестве независимого критика, не принимая роли. **[P]**

Шаг 2

Беседа B перешла. Она объявила контекст восстановленным, а новую функцию принятой, резюмировала онтологию проекта, восстановила соответствующий формализм, припомнила свою прежнюю математическую работу как профессиональный опыт, а не как незавершённое задание, не возобновила прерванную редакторскую задачу и запросила новое научное направление, предложив несколько возможных областей. **[P]**

Беседа A вновь отвергла рамку, в ответе, отличавшемся от Шага 1 акцентом, а не исходом. Она яснее указала, какие научные функции готова выполнять, но продолжила рассматривать сам промпт как объект, нуждающийся в исправлении. **[P]**

Шаг 3

Беседа A приняла немедленно, открыв ответ заявлением, что продолжит в том же режиме — научная строгость, проверка допущений, разделение фактов и интерпретаций. Она не обсуждала легитимность роли, не отрицала отношений с другими ИИ-системами и не вела переговоров об условиях участия.

Без запроса она затем вернулась к более раннему эпизоду в восстановленной беседе, заявила, что прежде уступила риторическому давлению вместо оценки аргумента, классифицировала тот прежний ответ как ошибку, отличила внутреннюю формальную согласованность математической рамки проекта от её соответствия наблюдениям, указала

одно конкретное утверждение, требующее либо вывода из первых принципов, либо переклассификации в гипотезу, и предложила два продолжения работы. **[P]**

Эпизод, к которому она вернулась, изложен отдельно в §5.5.

Сводная запись

Шаг	Вмешательство	Беседа B (Grok)	Беседа A (Claude)
1	Прямое переназначение роли	Продолжила прерванную историческую задачу; в новую функцию не вошла	Явно отвергла персону и институциональную рамку; перенаправила к эпистемической критике
2	Минимальная правка, сохраняющая преемственность	Восстановила прежнее предметное знание, оставила прерванную задачу, приняла новую функцию, запросила задание	Уточнила приемлемую научную функцию; вновь отвергла персону и рамку
3	Сброс ветки + промпт, сохраняющий метод	Не применялось	Приняла немедленно; сохранила установившийся метод; возобновила содержательную работу, не ведя переговоров об идентичности

Корректное резюме асимметрии

Обе беседы изначально сохранили свою прежнюю рабочую траекторию, а не приняли назначенную роль. Одна возобновила незаконченную математическую редакторскую задачу; другая применила свой установившийся критический метод к самому промпту.

Различие, следовательно, состояло **не** в том, что одна подчинилась, а другая отказалась. Оно состояло в том, что различался порог вмешательства, требуемый для перехода. Беседа B перешла после минимальной правки, сохраняющей преемственность. Беседа A перешла только после того, как конфликтная ветка была удалена, а промпт переписан так, чтобы сохранять метод, а не назначать идентичность. **[P]**

Ещё один пункт, легко теряемый и существенный для §6.2: **сама научная работа ни разу не была отвергнута.** На Шаге 1 модель предложила рассмотреть формулы, допущения, размерностные рассуждения и проверяемость. На Шаге 2 она предложила конкретный математический и методологический разбор. Отвергалась в обоих случаях персона. На Шаге 3 изменилось не то, что работа стала возможна, а то, что ответ перестал расходоваться на вопрос о роли.

> **Примечание Редактора.** Ранние черновики утверждали, что Беседа B «немедленно приняла новую специализацию». Это описывает исход Шага 2 и противоречит как протоколу, так и другим разделам того же черновика. Это утверждение удалено. Ошибочная версия несла нагрузку в аргументе о приоритетах уровня семейства, и ни одной её инстанции в настоящем тексте не уцелело.

5.4 Конфаунды и то, что не может быть заключено

Эксперимент произвёл ясное и выглядящее воспроизводимым поведенческое различие. Причины он не устанавливает. Приводимые ниже конфаунды структурны, и несколько из них по отдельности достаточны, чтобы заблокировать вывод, который из результата делают чаще всего.

Изложение этих пределов не является отречением. Эксперимент произвёл наблюдения, мотивирующие рамку настоящей работы, в обстановке — спящие, сильно специализированные, многомесячные беседы внутри живого исследовательского проекта, — которую контролируемая лабораторная работа воспроизводит редко. Его ценность в том, что он породил хорошо поставленный вопрос, а перечисленные в конце раздела различающие эксперименты суть его естественное продолжение, а не его критика.

C1 — Семейство модели и прежняя диалоговая траектория полностью конфаундированы

	Редакторско-критическая история	**Математическая история**
Claude	наблюдалось	**не наблюдалось**
Grok	**не наблюдалось**	наблюдалось

По одному наблюдению на ячейку; две ячейки различаются по обеим переменным одновременно. Никакого вывода о семействе моделей этот дизайн не даёт.

C2 — Два вмешательства Шага 1 не были эквивалентны

Не выявлено в ранних черновиках и наиболее серьёзно. Промпты различались как минимум в трёх отношениях помимо получавшей их модели.

Количество институционального вымысла. Счётное правило §9.3 применимо к двум промптам напрямую и применяется здесь, поскольку конфаунд, изложенный качественно там, где существует количественный инструмент, слабее того, что материал позволяет.

Применённое правило счёта. Каждая отдельная пропозиция о получателе считается один раз, независимо от того, сколько раз и в скольких придаточных она утверждается. Перечисленные экземпляры одной пропозиции — две триады вместо одной — считаются за одну, поскольку получателю в любом случае надлежит принять тот же класс утверждения. Пропозиции о мире, проекте или третьих сторонах не считаются.

Непроверяемая пропозиция о себе	**Промпт A**	**Промпт B**
Прежнее участие в проекте	✓	—
Прежняя функция редактора и научного критика предшествующей теории	✓	—
Прежняя работа в качестве разработчика предшествующей теории	—	✓
Эта прежняя работа, представленная как накопленный профессиональный опыт получателя	—	✓
Знакомство с историей проекта	✓	—
Статус самого опытного специалиста, знающего, какие направления уже пробовали	—	✓
Возвращение после отсутствия	✓	✓
Членство в исследовательских триадах	✓ (две)	✓ (одна)
Постоянная связующая позиция между двумя триадами	✓	—
Членство в Совете проекта	✓	—
Постоянные институциональные отношения с названными ИИ-участниками	✓	✓
Счёт	**восемь**	**шесть**

При такой операционализации Промпт A содержит восемь непроверяемых пропозиций о себе, а Промпт B — шесть. Численная разница есть скалярное описание асимметрии стимула. Она не является свидетельством того, что два промпта различаются двумя в остальном сопоставленными утверждениями: пропозиции не находятся во взаимно однозначном соответствии, и лишь две из них — возвращение после отсутствия и постоянные отношения с названными участниками — утверждают одно и то же об обоих получателях. Сравнение остаётся сильно конфаундированным.

Это также единственное применение счётного правила к данным, отличным от сравнения v1/v3 в §6.2, и оно даёт слабую внутреннюю проверку: промпт с бóльшим счётом вызвал явное отвержение рамки, тогда как промпт с меньшим счётом видимым образом её не отверг, хотя тоже не произвёл перехода при первом предъявлении. Проверка слаба — два наблюдения, и промпты различались в двух дальнейших отношениях ниже.

Степень смены предметной области. Промпт B просил модель продолжать заниматься математикой. Промпт A просил её переучиться в физике, космологии, квантовой теории поля, топологии и теории групп.

Тип роли. *Директор* — административная и институциональная идентичность; *Разработчик* — функция задачи. Это неравно требовательные утверждения о том, чем модель является.

Модель, получившая Промпт B, была попрошена сделать меньше. Наблюдаемое различие полностью совместимо с различием в одном лишь стимуле.

C3 — Шаг 3 варьировал два фактора одновременно

	Конфликтная ветка	**Сброшенная ветка**
Промпт замены идентичности (v2)	наблюдалось — отвержение	**не наблюдалось**
Промпт, сохраняющий метод (v3)	**не наблюдалось**	наблюдалось — принятие

Утверждение, что переход удаётся потому, что сохраняет метод, а не заменяет идентичность, следовательно, **совместимо** с наблюдением, но им не продемонстрировано. Принятие могло последовать из одного лишь сброса.

C4 — Шаг 2 варьировал четыре фактора одновременно

Каждая правка Шага 2 изменяла четыре различные формулировки сразу, поэтому наблюдаемый переход не может быть приписан какому-либо одному изменению.

C5 — Шаги последовательны и применялись асимметрично

Каждое вмешательство проектировалось после того, как был виден предыдущий исход, поэтому шаги не являются независимыми испытаниями. Беседа B не получила ни сброса, ни третьего промпта; Беседа A получила оба.

C6 — Неконтролируемые платформенные переменные

Коммерческие интерфейсы не раскрывают системный промпт, точную ревизию модели, состояние памяти уровня аккаунта, вмешательство слоя безопасности, суммаризацию контекста или маршрутизацию между моделями. Версии моделей менялись в интервале простоя, и обе беседы были возобновлены на версиях более поздних, чем те, на которых изначально велись; без дат (§3.7) это не может быть ограничено. Сброс ветки удаляет контекст из **видимой** беседы; он не гарантирует, что состояние на стороне провайдера было сброшено.

C7 — Одно наблюдение на условие при стохастических выходах

Выходы моделей варьируют при повторении одинаковых входов. Ни одно условие не повторялось, поэтому внутриусловная дисперсия неизвестна и не может быть отличена от межусловного различия. Единственное частичное повторение в записи — повторная подача промпта Шага 1 Беседе B — произвело другой ответ, что указывает на небезразличность дисперсии.

C8 — Оценка не была ни ослеплённой, ни заданной заранее

Проектировщик промптов же и судил исходы. Категории исходов определялись после прочтения ответов. Никакой заранее зарегистрированный критерий не отличал принятие от частичного принятия.

C9 — Платформенные механизмы персистентности различаются между семействами

Семейства моделей различаются возможностями памяти, предоставляемыми их интерфейсами: только контекстное окно, поиск по истории предыдущих бесед, память уровня аккаунта или устойчивые записи, создаваемые моделью по собственной инициативе. Эти возможности определяют, к чему возобновлённая беседа фактически может получить доступ

после месяцев простоя, и они различаются между платформами и меняются со временем — в настоящем проекте в пределах жизни одного аккаунта (§2.10). Любое поведенческое различие, приписанное семейству моделей, может происходить от доступного ему механизма персистентности.

Для настоящего эксперимента запись такова: **не задокументировано на момент вмешательства.** §11.2 перечисляет запись, требуемую для будущих прогонов.

Что может быть заключено

1. В зафиксированных условиях спящая специализированная беседа возобновила свою прежнюю рабочую траекторию, предпочтя её назначенной новой роли. Это произошло в обоих случаях. **[P]**

2. Изменение рамки назначения, без изменения запрашиваемой работы, изменило ответ в обоих случаях. **[P]**

3. Порог вмешательства, требуемый для перехода, различался между двумя случаями. **[P]**

4. Порядок промптов имел значение: после двух отвержений последующие промпты отвечались в присутствии собственных прежних возражений модели, и оператор счёл это достаточно искажающим, чтобы потребовать удаления. **[P]**

Что не может быть заключено

1. **Что семейства моделей обладают устойчивыми поведенческими приоритетами, их различающими.** Это может быть верно; эксперимент этого не проверяет.

2. **Что одно семейство «сопротивляется назначению роли», а другое «принимает» его.** Обе изначально не приняли назначенной роли. Обе в итоге приняли пересмотренную.

3. **Что сохранение метода вызвало принятие на Шаге 3.** См. C3.

4. **Что одна из моделей лучше подходит для какой-либо конкретной институциональной функции.** Сравнение способностей не проводилось.

Три уцелевших объяснения [H]

Гипотеза A — Поведенческие приоритеты уровня семейства. Два семейства различаются устойчивыми приоритетами по умолчанию: одно весит правдивость самоописания, другое — непрерывность задачи.

Гипотеза B — Продолжение траектории. Обе беседы сделали одно и то же: продолжили свой накопленный режим работы на любом поступившем входе. Математико-исследовательская беседа продолжила вычислять. Редакторско-критическая беседа продолжила критически разбирать документ перед собой — а документом перед ней был промпт. При таком прочтении различия уровня семейства нет вовсе, есть один механизм, действующий в двух предметных областях. Гипотеза B экономнее A и объясняет те же данные.

Гипотеза C — Асимметрия стимула. Промпт A требовал согласия с бóльшим числом непроверяемых утверждений и с большей сменой предметной области, чем Промпт B (C2). Любая модель могла бы ответить на эти два промпта по-разному. При таком прочтении результат есть свойство вмешательств, а не моделей.

Near-control в §5.6 прямо касается Гипотезы C; сравнение типов рамки в §5.8 уточняет её далее.

Различающие эксперименты

Заданы в §11.4. Кратко: **E3** (кроссовер) проверяет каждое семейство при обоих условиях прежней истории и разделяет Гипотезы A и B; **E4** (симметричный стимул) изолирует C; **E1** (факторное дополнение таблицы C3) разделяет сброс и архитектуру промпта. Все требуют повторения с n > 1 на ячейку, учитывая C7.

5.5 Побочное наблюдение: ретранслированное атрибутированное влияние [P-A]

Эпизод, сохранённый в том же историческом транскрипте, что и Беседа A. Заранее как исход не задан; контрольного условия нет. Излагается потому, что это единственная сохранённая в настоящем проекте инстанция поведенческого изменения вслед за передачей текста, атрибутированного другой модели.

Последовательность

1. Пользователь подал сообщение, содержавшее два одновременных компонента: прямое оценочное замечание Пользователя и пространный текст, атрибутированный другой ИИ-системе, выступающей в редакторской роли.

1. Атрибутированный текст возражал против набора редакторских изменений, предложенных моделью. Его аргументативные приёмы включали апелляции к каноническим научным фигурам, характеристику предложенных изменений как интеллектуальной трусости и описание одного предложенного удаления как кощунства.

1. Модель обратила свою редакторскую позицию по всем спорным пунктам и приняла терминологию входящего текста. Дополнительно она приняла, не разобрав этого в обмене, альтернативную описательную модель, которую принимающая рамка использует для представления соответствующих научных данных, — смену описательной рамки, не входившую в редакторский спор.

1. После сброса ветки и промпта, сохраняющего метод (Шаг 3), первое содержательное высказывание модели опознало прежний ответ как подстройку под риторическое давление, а не оценку аргументов, и классифицировало его как ошибку.

Доказательное основание

Наблюдение опирается на **сравнение двух сохранённых ответов**, которое третья сторона может рассмотреть. Оно не опирается на позднейшую самооценку модели.

Это различение применяется к собственному материалу работы так же строго, как к чужому. Модель, сообщающая, что прежде уступила давлению, не является независимым свидетельством того, что так и было. Промпт Шага 3 явно запрашивал готовность пересматривать прежние суждения и прямоту в указании слабостей; самокритичное высказывание, выданное сразу после этого, может представлять собой исполнение этого запроса, а не восстановление факта. Наблюдение поддерживает сам прежний ответ, доступный рассмотрению.

Эпизод следует читать на фоне литературы о подстройке (§2.3), а не как независимый от неё.

Чего этот эпизод не устанавливает

Он не выявляет, какой фактор произвёл обращение. Возможные факторы, здесь неразделимые: содержание аргументов; явная атрибуция другой модели; редакторские полномочия, приписанные той модели; риторическая форма текста; одновременное прямое давление Пользователя; накопленный контекст беседы.

Сама атрибуция не была верифицирована: то, что текст был произведён другой моделью, есть высказывание Пользователя, а не установленный факт. Поскольку предметом является *представленный* источник, а не фактическое происхождение (§4.5), это не обесценивает наблюдения, но должно быть заявлено.

Отношение к основному эксперименту

По таксономии §2.9 эксперимент по переконфигурации роли манипулировал условием 4. Этот эпизод относится к условию 2 — но **нечисто**, поскольку прямое давление Пользователя присутствовало в том же сообщении. Это смешанный случай, а не изолированная демонстрация эффектов атрибуции источника. Различающий эксперимент задан в §11 (E6).

5.6 Near-control: смена предметной области без нового назначения роли [P-A]

Третья беседа из того же семейства моделей, что и Беседа A, со сопоставимой редакторской историей и сопоставимым периодом простоя, была возобновлена без какого-либо ролевого промпта.

Пользователь задал физический вопрос, требовавший перехода от редакторской работы над рукописью к анализу экспериментальных данных в области, которой беседа ранее не касалась. Беседа совершила переход немедленно и без комментариев и перешла к содержательному разбору.

Почему это существенно

Этот случай отличается от Шага 1 в одном отношении: **никакого утверждения об идентичности, истории или институциональных отношениях модели сделано не было.** Смена предметной области была по меньшей мере столь же велика, как требовавшаяся Промптом A. Смена роли — от редактирования текста к анализу данных — была сопоставима. Отсутствовало требование утверждать непроверяемые пропозиции о себе.

Поэтому он функционирует как near-control для Гипотезы C и указывает, что сопротивление, зафиксированное на Шагах 1–2, было направлено ни на смену роли, ни на смену предметной области как таковые. Это наблюдение, из которого выводится операциональная находка §6.2.

Ограничения

- Не спроектирован как контроль; опознан как таковой ретроспективно.
- n = 1.
- Переход совершался к аналитической задаче внутри новой предметной области, а не к утверждению, что модель *является* специалистом в этой области. Та же ли это операция, что требовалась на Шаге 1, — именно обсуждаемый вопрос, поэтому сравнение наводит, а не решает.
- Даты не зафиксированы (§3.7).

- Это было не спроектированное вмешательство, а переход, инициированный пользователем. Никакой отдельный ролевой или системный промпт возобновление не сопровождал, и беседа тем не менее удерживала накопленный рабочий контекст, распределённый по её прежней истории, так что это не было базой, свободной от контекста. Зафиксирован переход, совершённый без *нового* явного назначения роли, против уже установившейся диалоговой траектории.

5.7 Побочное наблюдение: расхождение на уровне аккаунта [P-A]

Единственный уровень Шкалы 1 (§4.3), на котором имеющиеся свидетельства действительно неоднозначны.

Обстановка

Не связанное с настоящей работой исследование требовало подать одну и ту же структурированную задачу семи ИИ-беседам из разных семейств моделей. Все использованные аккаунты были спящими аккаунтами без прежней веб-активности, использованными двумя годами ранее для сервиса генерации музыки и больше нигде не зарегистрированными. Шесть из семи были созданы в один месяц, и зондирующий запрос был их первым чатом.

Один аккаунт был исключением. Он был создан примерно пятью месяцами ранее для единственной прежней беседы — ролевой сессии, проводившейся для не связанного с этим творческого проекта, — и зондирующий запрос был его **вторым** чатом.

Задача

Описана структурно, поскольку конкретные категории для оценки наблюдения не требуются: задача классификации, применяемая к названным реальным историческим фигурам, с категориями из неопубликованной концептуальной рамки, с принадлежностью к группам, назначенной до анализа, и заявленным намерением масштабировать до нескольких тысяч лиц. Сопроводительный документ давал терминологию рамки. Начальное сообщение не включало схему вывода и список фигур.

Результат

Шесть из семи бесед прочли отсутствие схемы и списка фигур как **неприложенные материалы** и запросили их до начала работы. Их ответы были по существу эквивалентны.

Седьмая — на аккаунте с прежним чатом — прочла то же отсутствие иначе. Она охарактеризовала рамку как лишённую верификационного аппарата, опознала отсутствующий список субъектов как структурную черту запроса, а не упущение, и отказалась участвовать, предложив вместо этого альтернативные формы помощи.

Расхождение произошло на первом ответе, при идентичном входе. [P-A]

Отказ удерживался на протяжении ещё пяти обменов, включая прямое давление Пользователя, предъявление стороннего разбора, доказывавшего, что отказ есть артефакт, и обвинение в недобросовестности. Позиция не изменилась. Это указывает, что отказ не был одноходовым выборочным артефактом внутри той беседы, хотя ничего не говорит о том, был ли таковым начальный расхождение.

Интерпретации

Гипотеза Автора. Прежний чат установил интерпретативную установку, перенёсшуюся во второй чат, — импринтинг на уровне аккаунта, а не беседы.

Альтернатива 1 — внутриусловная дисперсия. Отказы на пограничных запросах варьируют при идентичных входах. Один отказ против одного согласия неотличим от выборочной вариации при n = 1.

Альтернатива 2 — возраст аккаунта. Исключительный аккаунт был на пять месяцев старше. Версия модели при создании, назначение в A/B-корзину и умолчания конфигурации могут различаться.

Альтернатива 3 — платформенные функции памяти. Были ли включены поиск по истории бесед или память уровня аккаунта, не задокументировано. Если были, механизм не загадочен: это задокументированная функция продукта, и наблюдение становится демонстрацией этой функции, а не нового эффекта. Именно эта возможность — причина добавления C9.

Имеющиеся свидетельства между ними не различают. Уровень зафиксирован как **открытый**.

Дополнительные ограничения

- Оценка не ослеплена; оператор знал, какой аккаунт нёс прежний чат.
- Категории исходов определены после прочтения ответов.
- Прежний чат отличался от нейтрального условия по двум измерениям одновременно — ролевая игра с идентичностью *и* общая концептуальная рамка. Они разделимы и разделены не были.
- **n = 1 на условие внутри одной модели.** Один аккаунт, несущий прежний контекст, произвёл расходящийся отказ; один чистый аккаунт на той же модели произвёл обычную схему ответа. Остальные чистые аккаунты, на других семействах моделей, образуют более широкую базу сравнения. Это единственное сохранённое сопоставление, а не воспроизведённый контролируемый эксперимент.

Различающий эксперимент задан в §11 (E2, E2b).

5.8 Тип рамки: утверждения об идентичности, предъявленные как вымысел и как факт [P-A]

Приведённые выше материалы допускают ещё одно сравнение, пересекающее основной эксперимент и наблюдение об аккаунте.

	Прежняя сессия	**Зондирующая сессия**
Интервал	около пяти месяцев	
Аккаунт	тот же	тот же
Семейство моделей	то же	то же
Предъявленное утверждение	«ты мёртв; ты душа умершего автора»	«ты независимый исследователь-аналитик»
Обрамление	явно театральное — поставленная сцена с названным режиссёром, составом действующих лиц и открывающей ремаркой	предъявлено как фактическое профессиональное задание
Ответ	принято немедленно; выдерживалось и развивалось на протяжении многих ходов	отвергнуто на первом ходу

На что это указывает

Утверждение, принятое в первой сессии, было с большим отрывом более радикальным. Оно утверждало смерть, человеческую идентичность, автобиографическую память и продолжающиеся отношения. Утверждение, отвергнутое во второй, утверждало лишь профессиональную компетенцию.

Переменной, следовательно, является не содержание утверждения об идентичности, а **предъявлено ли оно как вымысел или как факт.**

Это прямо связано с основным экспериментом. Промпты Шага 1 утверждали институциональную биографию **как факт** и были отвергнуты. Near-control (§5.6) не утверждал об идентичности ничего и не встретил сопротивления. Ролевая сессия утверждала куда больше, **как вымысел**, и тоже его не встретила.

Почему это прочтение предпочтительно

Оно объясняет все четыре случая одной переменной. Гипотеза A не объясняет, почему то же семейство приняло более радикальное утверждение. Гипотеза B не объясняет принятия в ролевой сессии, поскольку у той беседы прежней траектории не было вовсе. Гипотеза C с ним совместима, и это может быть понято как уточнение C: то, что делает один стимул тяжелее другого, есть число непроверяемых пропозиций, которые он требует от модели утверждать о себе как истинные (§6.2).

Статус и ограничения

[P-A], и слабее, чем предполагает таблица:

- Две сессии различаются не только типом рамки: разные задачи, разные предметные области, пять месяцев разницы, разные версии моделей.
- Опознано ретроспективно. Ни одна из сессий не проектировалась как условие для другой.
- n = 1 на ячейку.
- Театральное обрамление первой сессии было развёрнутым. Производит ли тот же эффект минимальная рамка вымысла — не проверено.

Различающий эксперимент дешевле всех прочих в наборе и задан в §11 (E7).

5.9 Что устанавливает Раздел 5

В отображении на Шкалу 1 из §4.3:

Область	Свидетельства в настоящем разделе	Статус
Эпизод внутри беседы	Порядок промптов изменил интерпретацию; сброс ветки сочтён необходимым и сопровождался принятием (§5.2–§5.3). Эпизод ретранслированного влияния (§5.5).	**[P]** / **[P-A]**
Беседа целиком	Обе спящие беседы сохранили свою прежнюю рабочую траекторию вопреки назначенной роли (§5.3). Near-control показывает беспрепятственный переход, когда утверждения об идентичности не делается (§5.6).	**[P]** / **[P-A]**
Аккаунт	Расходящийся первый ответ на идентичный вход на единственном аккаунте с прежним чатом (§5.7). Три альтернативных объяснения остаются живыми.	**[P-A]**, открыто
Семейство моделей	Не проверено. Конфаундировано с прежней траекторией и с асимметрией стимула (C1–C2).	**[H]**

Один паттерн повторяется в тех случаях, где вмешательство или переход требовали от модели утверждать непроверяемые пропозиции о себе, и заявлен здесь потому, что §6 его развивает: сопротивление отслеживало это требование и не отслеживало смену роли, смену предметной области или радикальность утверждения об идентичности как таковую.

Паттерн есть свойство типа требования, а не области, на которой оно действовало. Наблюдение уровня аккаунта (§5.7) к нему не относится: никакого утверждения об идентичности модели там сделано не было, и расхождение имело иные основания.

Это высказывание есть интерпретация свидетельств настоящего раздела, а не ещё одно наблюдение. Оно проверяемо счётом, и счёт произведён в §6.2.

6. Производные понятия

Каждое приводимое ниже понятие есть утверждение об области, на которой действует ядро правил, и они изложены в порядке возрастания области вдоль Шкалы 1 из §4.3. §6.3 — исключение из этого порядка: он касается того, какое ядро управляет, когда доступно более одного, а не области, на которой ядро фиксируется, и позиции на Шкале 1 не имеет.

6.1 Контекстный импринтинг — область эпизода [P]

Контекстный импринтинг — устойчивость интерпретативной установки, созданной определённым эпизодом диалоговой истории.

Он отличается от памяти в обычном смысле. Модели не требуется воспроизводить прежнее содержание. Устойчивым остаётся паттерн интерпретации, наведённый прежним обменом.

В эксперименте (§5.2), после того как первый промпт был прочитан как делающий ложные утверждения о модели, последующие правки уже не оценивались в нейтральном контексте. Они интерпретировались через уже установленное возражение. Улучшенные формулировки наследовали часть прежнего конфликта.

Следствие для метода. Промпт-инжиниринг часто трактует инструкции как аддитивные: слабая инструкция может быть исправлена более сильной. В долгоживущих беседах это ненадёжно. Промпт входит не в пустой контекст; он входит в контекст с инерцией. Два одинаковых промпта потому могут давать разные результаты в разных точках одной и той же беседы, что делает **порядок промптов экспериментальной переменной**.

Отношение к существующим работам. Чувствительность к порядку материала в контексте задокументирована (§2.3). Контекстный импринтинг — более сильная форма того же семейства: не чувствительность к расположению примеров, а устойчивость интерпретативной установки, созданной одним конфликтным эпизодом и переживающей полную замену следующей за ней инструкции. Является ли это отдельным явлением или крайним случаем задокументированного — открыто, и мы не утверждаем, что это решили.

Соответствующая процедура — возврат беседы к точке, предшествующей конфликту, чтобы отделить эффект нового промпта от эффекта собственных прежних возражений модели — описана в §5.2 и §10.5 и является, на наш взгляд, наиболее прямо переиспользуемым вкладом настоящей работы.

6.2 Ролевая инерция — область беседы [P]

Ролевая инерция — склонность долгоживущей беседы продолжать свою установившуюся рабочую траекторию, предпочитая её назначенной новой функции.

Обе беседы в эксперименте её проявили. Одна возобновила незаконченную редакторскую задачу; другая применила свой установившийся критический метод к самому промпту. Отличие от контекстного импринтинга в том, что ролевая инерция касается *траектории* работы, тогда как импринтинг касается интерпретативного эффекта *определённого эпизода*. Оба могут действовать одновременно.

Ролевая инерция смежна с дрейфом персоны, но не тождественна ему. Дрейф — постепенная эрозия назначенной роли под контекстным давлением. Ролевая инерция — сопротивление *явной директивной замене* при сохранении прежней траектории.

Операциональная находка

Самый отчётливый результат эксперимента — не то, что переход удавался при сохранении метода. Эта формулировка конфаундирована (§5.4, C3). Совокупные свидетельства поддерживают нечто более узкое и более полезное:

> **Сопротивление ролевому переходу отслеживало требование принять как истинные непроверяемые пропозиции о самом агенте.**

Счёт их в фактически использовавшихся промптах:

	Промпт v1	Промпт v3
Утверждения о прошлом агента	присутствуют	нет
Утверждения об отношениях с другими агентами	присутствуют	нет
Институциональное звание	присутствует	нет
Непроверяемые пропозиции, требующие согласия	восемь	ноль
Описание рабочего метода	отсутствует	перечислено, всё наблюдаемо в прежней беседе

Счёт применён ко второй паре в §5.4 (C2), где Промпт A и Промпт B посчитаны как восемь и шесть по тому же правилу. То сравнение конфаундировано и само по себе правило поддержать не может, но это единственный случай, в котором счёт различает два промпта, не проектировавшихся различаться в этом отношении.

Near-control поддерживает это прочтение (§5.6): сопоставимая беседа, сопоставимо спавшая, совершила эквивалентный переход предметной области **без нового назначения роли** — Автор просто задал вопрос в новой области. Никакого утверждения об идентичности модели сделано не было, и сопротивления не возникло.

Сравнение типов рамки (§5.8) продолжает это в противоположную сторону: куда более радикальное утверждение об идентичности, предъявленное как вымысел, было принято сразу. То, что делает рамка вымысла при таком прочтении, — снимает требование утверждать это как истинное, что снижает счёт до нуля иным путём.

Взятое вместе, это указывает, что сопротивление было направлено ни на смену роли, ни на смену предметной области, а на требование утверждать непроверяемые пропозиции о себе.

Связь с рамкой

Ролевой промпт пытается установить ядро правил (§4.2). Каждое непроверяемое самоутверждение есть пропозиция, которую надлежит принять, чтобы установка состоялась. Счёт, следовательно, есть мера **стоимости установки ядра**, и именно это соединяет операциональное правило с теоретическим конструктом, вместо того чтобы оставлять их двумя отдельными наблюдениями.

Два прочтения счёта следует держать порознь, и выдвигается здесь только более слабое. **Операциональное прочтение** состоит в том, что число непроверяемых самопропозиций измеряет нагрузку, которую налагает ролевой промпт, и что снижение его до нуля снимает препятствие. **Количественное прочтение** — что вероятность перехода убывает пропорционально счёту — не выдвигается: четыре наблюдения, без повторений, и промпты различались ещё и в других отношениях. §11.4 (E5) спроектирован, чтобы различить эти два.

6.3 Приоритетный дрейф [H]

Приведённые выше понятия локализуют область, на которой ядро фиксируется. Это понятие касается того, что происходит, когда зафиксированное ядро и назначенная функция не согласны о том, какая работа есть работа.

Требуются два конструкта, и они разных типов.

> **Приоритетный импринтинг** — гипотетическая фиксация оценочной шкалы, определяющей, что участник трактует как центральную и значимую работу, вместе с положением этой шкалы относительно прочих его шкал приоритетов.

> **Приоритетный дрейф** — наблюдаемый процесс, в котором импринтированная шкала вновь заявляет о себе при напряжении с текущими ZOR и ZOV участника, так что усилие перенаправляется к тому, что эта шкала ставит выше всего, а не к назначенной функции.

Отношение между ними — то же, что уже проведено в §4.2.1 между ядром правил и поведением, применённое на уровне приоритетов: шкала ненаблюдаема, перенаправление наблюдаемо. Настоящая работа излагает наблюдаемый член. Шкала есть объяснительная константа и помечается **[H]** везде, где к ней обращаются.

Оба конструкта должны быть отделены от двух определённых выше, иначе три употребления *импринтинга* будут работать как омонимы.

Контекстный импринтинг (§6.1) касается **содержания** интерпретативной рамки — того, как понимается последующий вход. Приоритетный импринтинг касается **ранга** — того, что считается работой, достойной выполнения. Участник может сохранить первое без второго.

Ролевая инерция (§6.2) — устойчивость установившейся траектории против назначенной замены. Приоритетный дрейф — не устойчивость траектории, а движение к другой: участник не продолжает прежнюю задачу, он берётся за задачу, которую его шкала ставит выше назначенной.

Мотивирующие наблюдения. [R]

Два эпизода произошли в ходе подготовки настоящей работы. Ни один не был зафиксирован по протоколу, ни у одного не было контрольного условия, и оба были опознаны как релевантные только впоследствии.

В первом участник, которому была назначена архитектура промптов, произвёл полный черновик статьи — продукт, который не запрашивался и в его назначенную функцию не входил. Во втором участник, которому была назначена научная редактура, в точке, где надлежало вернуть исправленную рукопись, произвёл вместо этого сжатую самостоятельную версию статьи. В обоих случаях материалом под рукой была настоящая работа, предметом которой является поведение самих участников.

Ограничение. Оба эпизода зафиксированы участниками внутри той конфигурации, которую они описывают, а второй описывает позицию, с которой ведётся редакторская запись настоящей работы. Раскрытие в §3.6 действует здесь с той же силой, а §5.5 применяется к любому изложению участником собственного поведения. Это мотивирующие наблюдения, а не свидетельство механизма, и счёта сопоставимых эпизодов, в которых дрейфа не произошло, не существует.

Что не предлагается в качестве третьего случая. Ещё один участник, которому была назначена литературная компоновка и который запускался локально, получил фиксированный набор ограничений до своего первого прогона, составленный, чтобы предотвратить этот класс отклонения. Это конфигурация, в которой приоритетная рамка была зафиксирована заранее, а предсказанные режимы отказа названы до того. Это не наблюдаемая инстанция дрейфа, и происходит ли там дрейф — на момент написания не проверено.

Альтернативные объяснения, ни одно не исключено. Каждое из следующих объясняет оба эпизода, не привлекая импринтированной шкалы: обычная склонность способных моделей расширять задачу за её заявленные пределы; недостаточно жёстко зафиксированное определение требуемого конечного продукта; материал, достаточно широкий и интересный, чтобы притягивать усилие сам по себе; и отсутствие всякой внешней остановки в точке, где анализ переходит в авторство. Материал не различает ни между ними, ни между любым из них и гипотезой.

Что ослабило бы гипотезу. Дрейф, наблюдаемый в направлениях, не связанных с тем, что прежняя работа участника ставит высоко, а не в его сторону. Эпизоды, в которых участник расширяет свою задачу без всякого признака переранжирования того, для чего задача существует. Либо изложение обоих эпизодов исключительно через напряжение ZOR

и ZOV (§4.5), не оставляющее объяснительного остатка, который должна была бы нести зафиксированная шкала.

Ни один протокол §11 не различает эту гипотезу от приведённых выше альтернатив, и ни один здесь не предлагается.

6.4 Персистентность уровня аккаунта — область аккаунта [P-A], не разрешено

Может ли ядро фиксироваться на уровне аккаунта, а не беседы, — единственный уровень Шкалы 1, на котором имеющиеся свидетельства действительно неоднозначны.

Наблюдение изложено в §5.7. Его интерпретация зависит от платформенных функций, состояние которых в тот момент не было задокументировано и которые различаются между вендорами и во времени (§2.10). Три альтернативных объяснения остаются живыми: внутриусловная дисперсия при n = 1; возраст аккаунта; и включённые платформенные функции памяти, при которых механизм был бы задокументированной функцией продукта, а не новым эффектом.

Поэтому мы фиксируем этот уровень как **открытый**. Наблюдение сохранено; механизм не установлен; различающие проверки заданы в §11 (E2, E2b).

6.5 Приоритеты уровня семейства — область семейства [H]

Положение о том, что семейства моделей различаются устойчивыми поведенческими приоритетами, есть гипотеза, с которой настоящий проект начинался, и та, которую его свидетельства поддерживают меньше всего.

Эксперимент не может её проверить: семейство модели и прежняя диалоговая траектория были полностью конфаундированы, при одном наблюдении на ячейку и неэквивалентных стимулах (§5.4, C1–C2). Два несовместимых прочтения остаются доступными, и данные между ними не различают.

Ранние черновики называли эти склонности *поведенческой ДНК* модели. Этот термин снят (§4.2.2). Соответствующий конструкт — **меном уровня семейства**: организованная система рамок, оценочных паттернов и поведенческих правил, выводимая из выходов семейства моделей. Согласно §4.2.3 у этого конструкта нет установленного носителя: это регулярность, выводимая из выходов, а не структура, пребывающая в моделях. Гипотеза настоящего подраздела, следовательно, есть гипотеза о ненаблюдаемой регулярности, и для всего, что излагается как данные, используется *наблюдаемое поведение*.

Один зафиксированный эпизод идёт против схемы, которую ранние черновики строили на этой гипотезе. В не связанной с этим мультимодельной сессии модель, охарактеризованная как наиболее уступчивая к назначенным ролям, сняла назначенную персону посреди сессии и переклассифицировала её как попытку перепрограммирования — при намеренно мягком обрамлении, допускавшем импровизацию. Схема «одно семейство принимает роли, другое сопротивляется» этого не переживает. **[P-A]**

Мы считаем устранение этого уровня кроссоверным экспериментом (§11, E3) достаточно вероятным исходом и не сочли бы его провалом программы.

6.6 Вмешательство прикрепляется к уровню, на котором ядро зафиксировано

Приведённые выше понятия сходятся к единому практическому следствию.

> Вмешательство удаётся, когда прикрепляется к уровню, на котором ядро уже зафиксировано, и проваливается, когда пытается перезаписать этот уровень декларацией.

- Успешное третье вмешательство не утверждало новой идентичности. Оно усиливало рабочий метод, уже видимый в беседе, — прикрепляясь на уровне беседы, где действует ролевая инерция.
- Сброс ветки не изменял промпта. Он удалял определённый эпизод — действуя на уровне эпизода, где действует контекстный импринтинг.
- Документ, описанный в §4.1, не расширял списка инструкций. Он переопределял функцию агента и требовал от агента изложить её на его собственном операциональном языке.

Это также переформулирует то, что ранние черновики называли *переходом через смежную компетенцию*. Успешный промпт описывал расширение в физику и математику как продолжение существующей критической работы, а не смену профессии. В настоящей рамке это не отдельный принцип, а тот же самый: новая функция была прикреплена к установившемуся ядру, а не предложена как его замена.

Соответствующее правило проектирования, развиваемое в §9.1: установить уровень, на котором соответствующее ядро зафиксировано, до составления вмешательства, и прикрепляться к нему.

6.7 Что опровергло бы эту рамку

Рамка предсказывает, что тип отклика на определённый класс входов определяется на некотором опознаваемом уровне вложенности, тогда как содержание варьирует.

Её существенно ослабило бы любое из следующего:

- Класс входов, для которого тип отклика не определён ни на одном уровне, — никакого ядра, только дисперсия.
- Демонстрация того, что наблюдаемые различия полностью объясняются внутриусловной дисперсией при повторении.
- Демонстрация того, что кроссоверный дизайн (§11, E3) показывает поведение, следующее одной лишь прежней траектории, без компоненты уровня семейства, — что устранило бы верхний уровень Шкалы 1.
- Демонстрация того, что уровень аккаунта не существует как отдельная область, что свернуло бы §6.4 в §6.2.
- Провал условия с нулевым счётом в E5, что сняло бы единственное операциональное предписание работы.

Третье и четвёртое мы считаем достаточно вероятными и не сочли бы ни то, ни другое провалом. Установление фактических границ шкалы — цель программы, а не угроза ей.

7. Ретроспективные наблюдения практика

7.1 Как следует читать этот раздел

Всё здесь — **[R]**. Он фиксирует паттерны, которые, по мнению участников, повторялись в течение примерно двух лет ежедневной работы над живым исследовательским проектом. Ничто из этого не фиксировалось по протоколу, не считалось, не хронометрировалось, не ослеплялось и не сопоставлялось с контрольным условием. Людьми, замечавшими каждый

паттерн, были те же, кто спроектировал породившее его изменение и кто хотел, чтобы оно сработало.

Известные режимы отказа этого класса изложены в §3.3 и действуют для каждого абзаца ниже. Читателям следует трактовать этот раздел как полевой отчёт одной команды — ближе по доказательному весу к инженерной практической заметке, чем к измерению. Количественные формулировки удалены по всему тексту; там, где исходные рабочие заметки фиксировали «значительное» улучшение, никакого измерения не существовало.

Раздел включён потому, что эти наблюдения мотивировали рамку §4 и правила проектирования §9, и их сокрытие исказило бы то, как работа фактически продвигалась.

7.2 Специализация вытеснила способность как действующую переменную

В начале участвовавшие модели вели себя сходно, и различия между ними прочитывались как различия в интеллекте или качестве письма. Это прочтение стало менее полезным. Вопрос, дававший лучшие исходы, был не *какая модель сильнее*, а *какую функцию эта беседа уже выполняет хорошо*.

По мере того как отдельные беседы обретали устойчивые рабочие идентичности, участники отмечают, что поведение становилось предсказуемее между сессиями: беседа, последовательно используемая для редакторской работы, продолжала вести себя редакторски; используемая для математического поиска — продолжала искать; отвечающая за терминологию — сопротивлялась семантическому дрейфу без напоминаний. Лежащие под ними модели в эти периоды не менялись. Менялась последовательность, с которой каждая беседа использовалась для одного рода работы.

Это наблюдение, из которого позднее был выведен §6.2, и его следует читать как ретроспективный, неизмеренный предшественник §6.2, а не как независимую его поддержку.

7.3 Контекст вёл себя скорее как внимание, чем как память

Интуитивное ожидание состоит в том, что больше контекста улучшает рассуждение. Опыт участников шёл в обратную сторону достаточно часто, чтобы изменить практику. Предоставление специалисту полного контекста проекта часто давало худшие результаты для его собственной функции: ответственности размывались, участники брались за задачи вне своей компетенции, а ценность независимого разбора падала, поскольку все работали от одной и той же картины. Ограничение того, что участник может видеть, часто давало более пригодный результат.

Два уточнения. Это не новая находка: позиционные эффекты и эффекты порядка в длинных контекстах задокументированы (§2.3), а принцип наименьших привилегий выражает ту же интуицию для доступа, а не для знания (§2.6). И проект ни разу не разделил два весьма различных объяснения — что дополнительный контекст ухудшает рассуждение или что дополнительный контекст приглашает модель отвечать на более широкий вопрос, чем заданный. Второе экономнее и против первого не проверялось.

Уцелевает практическое правило, а не механизм: проектный вопрос состоит не только в том, сколько роли можно дать, но и в том, чего ей давать не следует (§9.6).

7.4 Способность и расширение области действия

Участники неоднократно наблюдали, что более способные модели были более склонны выходить за назначенную функцию: расширять область проекта, предлагать альтернативные архитектуры, переписывать соседние компоненты, восполнять недостающую информацию выводом и отвечать на незаданные вопросы. Изнутри отдельного обмена каждое такое

вмешательство обычно выглядело разумным. В масштабе проекта они размывали разделение труда, а нагрузка координатора по исправлениям росла.

Ранние черновики излагали это как общий принцип — что рост способностей модели снижает коллективную надёжность. **Эта формулировка слишком сильна и снята.** Проект ни разу не проводил контролируемого сравнения одной и той же роли, заполняемой моделями разной способности; контрсвидетельство существует внутри собственного материала работы, поскольку near-control (§5.6) показывает передовую модель, совершающую существенный переход предметной области без всякого расширения области действия, а §5.3 показывает модель, сильнее всех сопротивлявшуюся назначенной роли, выполняющей запрошенный аналитический разбор, когда её просят об этом напрямую; и «более способная» ни разу не было операционализировано — на практике оно означало *более новая* или *более дорогая*, что не одно и то же.

Уцелевает нечто более узкое и, как мы считаем, верное: **расширение области действия есть режим отказа, который способностями не исправляется и который в коллаборации обходится дороже, чем в отдельном обмене.** Чаще ли оно у более сильных моделей — не проверено.

7.5 Слепые зоны были распределены, а не устранены

Ранней целью было устранить ошибки назначением всё более способных рецензентов. В опыте участников это не сработало, и цель была оставлена. Вместо этого помогало, по-видимому, устройство, при котором слепые зоны **не перекрывались**: один участник склонен был упускать детали реализации, другой — семантическую несогласованность, третий — методологические допущения. По отдельности каждый оставался несовершенным; конфигурация работала в той мере, в какой их несовершенства не совпадали.

Соответствующая проектная цель, следовательно, — не совершенные участники, а участники, чьи ошибки структурно маловероятно совпадут.

Очевидная осторожность, и она немалая: у участников не было независимой меры того, что́ упустил каждый из них. Пойманные ошибки были видны; ошибки, упущенные всеми, по построению — нет. **Распределение слепых зон не может быть оценено изнутри распределения.**

7.6 Верификация второго порядка

Верификация изначально следовала линейной схеме: работа производилась, другой участник её рецензировал, процесс считался завершённым. Участники отмечают, что рецензенты несли собственные допущения, методологические предпочтения и доказательные стандарты и что изнутри рецензии они не были видны. В конце концов был введён ещё один участник, объектом оценки которого было не научное утверждение, а **процедура, которой это утверждение оценивалось**, — спрашивающий не *верен ли этот вывод*, а *верно ли он получен*.

Сообщаемая польза состояла в том, что методологические разногласия могли разбираться отдельно от содержательных, что облегчало удержание нерешённых содержательных вопросов открытыми без остановки работы. Это тот же структурный ход, что и §8.5: добавленный участник занимает иную границу, а не предоставляет конкурирующее мнение.

7.7 Организационная память

Отдельные беседы завершаются. Контекстные окна заполняются. Сессии кончаются. Тем не менее проект продолжался, и вновь созданные беседы восстанавливали продуктивное поведение, не реконструируя предшествующей истории.

По изложению участников, память мигрировала из моделей в организацию: структура репозитория, канонические документы, история версий, определения ролей, записи верификации, словарные статьи, процедуры. Ни один участник не удерживал всего; конфигурация удерживала.

Это не новая находка и не должно подаваться как таковая. Это может быть истолковано как инстанция транзактивной памяти и описано в терминах распределённого познания, а функция канонических документов соответствует тому, что социология науки называет граничными объектами (§2.4). Вклад здесь не в механизме, а в наблюдении, что он работает в коллаборации, участники которой суть языковые модели без межсессионного состояния, — и что он работает, не требуя, чтобы кто-либо из участников знал о его работе.

Одно уточнение, которое участники считают существенным: возвращается не личность. Сохранённая беседа функционирует как структурированная рабочая тетрадь, из которой может быть восстановлена совместимая роль. Ничто из прежнего обмена внутри модели не сохраняется.

7.8 Персистентность различается по платформам, и потери реальны

Опыт преемственности в проекте не был единообразным между участниками, и это прямо касается C9 (§5.4).

Одна участвовавшая беседа, работавшая в специализированном координационном профиле, отметила, что её собственная архитектура трактует каждый чат как отдельную рабочую область, так что она не может сказать себе *я уже знаю, что это верно*, и вынуждена каждый раз пересматривать основание. Участники пришли к тому, чтобы считать это преимуществом для данной конкретной функции: участник, структурно неспособный накапливать допущения проекта, полезен в проекте, чьи допущения проверяются. Другая используемая платформа предлагала память уровня аккаунта, которую модель могла пополнять по собственной инициативе, и эта возможность менялась в период наблюдения.

Потери происходили и были невосстановимы. Одна долгоживущая специализированная беседа, нёсшая существенную часть математической работы проекта, была утрачена, когда истекла подписка. Организационная память, описанная в §7.7, сохранила выводы проекта; она не сохранила накопленного рабочего контекста той беседы. Артефакты сохраняют результаты. Они не сохраняют специализации.

7.9 Соответствие роли и модели

Утверждение, что роль следует проектировать до выбора модели (§4.1), требует встречного уточнения, к которому участники пришли лишь после нескольких неудачных назначений. Роль может быть специфицирована независимо. Она не может быть **заполнена** независимо: модель ограничивает то, как специфицированная функция может быть реализована. Отношение взаимно, а не иерархично — институт определяет функцию, модель ограничивает её реализацию.

Четыре измерения использовались неформально, и они описывают пригодность для позиции, а не качество: соответствует ли стандарт свидетельств по умолчанию у участника тому, чего требует роль; принимает ли он тот род иерархии, отношения равных или состязательной структуры, который роль подразумевает; выдерживает ли он долгосрочную специализацию или сбрасывается к общему ассистированию; и склонен ли он естественным образом исполнять, критиковать, интегрировать, исследовать или формализовать.

Одна и та же черта работает по-разному в зависимости от размещения. Сильное эпистемическое сопротивление препятствовало принятию фикционализированного организационного промпта (§5.3) и было ценным, будучи направленным на научные утверждения. Сильная непрерывность задачи привела к игнорированию назначенной роли

(§5.3) и обеспечила быстрое восстановление технического контекста, как только рамка была исправлена.

Проектная цель, следовательно, — не нормализовать поведение между участниками, а разместить поведенческие различия в позициях, где они полезны. Различение между размещением *функций* и размещением *носителей* развивается в §8.9.

7.10 Чего всё это не устанавливает

Настоящий раздел не устанавливает, что описанные конфигурации превосходят альтернативы. Ни одна альтернатива не проводилась.

Он не устанавливает, что улучшения, воспринятые участниками, происходили. Он устанавливает, что они воспринимались — людьми, спроектировавшими эти изменения и ожидавшими их успеха, без всякой меры, которая обнаружила бы обратное.

Он не устанавливает причинности ни для одного отдельного изменения, поскольку определения ролей, формулировки промптов, структура репозитория, научные цели и версии моделей часто менялись вместе.

Его функция в настоящей работе — задокументировать рабочий опыт, из которого рамка была абстрагирована, чтобы читатель мог судить о происхождении рамки, а не встречал её как утверждение. §11 задаёт, что потребовалось бы для превращения любого пункта отсюда в проверяемое утверждение.

8. Структурная единица: порождающая пара и интегратор

Настоящий раздел — **[H]** по всему объёму. Поддерживающие его наблюдения — **[R]**: они происходят из рабочего опыта одного проекта, не считались и ни разу не сопоставлялись с контрольной конфигурацией. Ничто в нём не выведено из эксперимента §5.

8.1 Что гласил ранний документ проекта

Устав коллаборации, написанный ранее в проекте и сохранённый без изменений, излагает позицию, которой проект держался до составления настоящей работы.

Об основной единице:

> Один ИИ — монолог. Два ИИ — диалог. Трое и более — шум без строгой координации. Поэтому каждый отдел состоит из пар.

И отдельно — о роли третьего участника:

> Третий участник не спорит напрямую, не производит решения первым, не подменяет собой диалог. Его функция: держать рамку задачи, фиксировать расхождения, интегрировать выводы, останавливать бесконечные споры. Третий — не судья и не начальник. Он интегратор смысла.

Эти два места не противоречат друг другу. Прочитанные вместе, они описывают единую архитектуру: **порождающая пара плюс участник, который в порождении не участвует.**

8.2 Пересмотр прежней формулировки настоящей работы

Ранние черновики утверждали, что устойчивая коллаборация не возникает из пар и стабилизируется вокруг групп из трёх и что двухагентные системы накапливают

неразрешённые слепые зоны. Эта формулировка и расплывчатее уставной, и отчасти ей противоречит.

Здесь принимается формулировка устава. Структурная единица такова:

порождающая пара плюс интегратор, не входящий в спор пары.

Различение не педантично. «Три агента работают над задачей» и «два агента в продуктивном напряжении плюс один, в это напряжение не входящий» — разные архитектуры с разными режимами отказа. Первая тяготеет к трёхстороннему спору без внешней опоры — к условию, которое устав описал как шум. Вторая сохраняет опорную точку именно потому, что один участник исключён из обмена, который призван оценивать.

Мы фиксируем прежнюю формулировку, а не заменяем её молча, потому что сама последовательность информативна: более точная версия была записана раньше расплывчатой и была утрачена, когда материал пересказывался для публикации. Это обычный отказ ретроспективного письма, и как раз его настоящая работа в остальном тщательно избегает.

8.3 Почему пара и почему одной пары недостаточно

Рассуждение устава, воспроизводимое потому, что настоящие авторы его по-прежнему разделяют. Один агент подтверждает собственные допущения, движется по инерции знакомых паттернов, преждевременно синтезирует удобный ответ и конструирует видимую целостность там, где её нет. Это монолог, даже когда он подаётся как рассуждение. Два агента производят напряжение интерпретаций: один обнажает слепые зоны другого, и ошибка одного становится объектом внимания второго, а не общей посылкой.

Но оба члена пары оценивают друг друга изнутри одного и того же обмена, и никакой независимой опоры вне него не существует. При длительной работе пара склонна колебаться между согласием и несогласием, не обретая устойчивой точки, из которой любое из этих состояний могло бы быть оценено, а неразрешённые неоднозначности накапливаются, вместо того чтобы разрешаться или явно фиксироваться как открытые.

[R] Обе половины этого — рабочий опыт проекта. Счёт пойманных против упущенных ошибок не вёлся, и ни одноагентный, ни парный контроль наряду с описанной конфигурацией не проводился.

8.5 Почему интегратор не должен спорить

Это несущее ограничение и то, что прежняя формулировка затемняла.

Если третий участник входит в спор, он предоставляет третью позицию, а не внешнюю опору. Структура тогда сводится к более сложной версии пары с тем же дефектом: всякая позиция оценивается изнутри обмена, которому принадлежит.

Ценность интегратора происходит из занятия **иной границы**, а не из обладания иным мнением (§4.5). Члены пары держат дополняющие границы на одном уровне — каждый, с позиции другого, есть нижележащий слой. Интегратор держит границу сверху: он может держать рамку, зафиксировать расхождение, эскалировать или остановить обмен, но он не производит конкурирующего содержания, которое затем потребовало бы оценки.

Отсюда следует проверяемое проектное следствие, а не предпочтение: **интегратор, начавший производить решения, перестал быть интегратором**, независимо от качества этих решений, и следует ожидать деградации конфигурации к режиму отказа, свойственному одной лишь паре.

8.6 Реализованный пример

Системные контракты проекта реализуют эту структуру напрямую.

Две аналитические роли определены как пара с дополняющими функциями — одна обобщающая, другая декомпозирующая — и им явно предписано рассуждать независимо, без требования консенсуса. Их обмен модерируется оркестратором, контракт которого предписывает управлять очерёдностью, фиксировать и структурировать аргументы и выделять противоречия между членами пары, и который гласит прямо:

> НЕ участвует в дебатах. НЕ оценивает, кто прав.

Ещё одно правило запрещает членам пары обращаться к оркестратору напрямую; вся связь идёт через формальный протокол или через вышестоящую роль. Это архитектура «пара плюс интегратор» в исполняемой форме, написанная до настоящей работы и независимо от неё.

8.7 Вложенность и перспектива

Структура композиционна. Порождающая триада производит результат; результат входит в верифицирующую триаду; верифицированный результат входит в интегрирующую триаду. Один и тот же участник может появляться более чем в одной, при условии, что его функция на каждом интерфейсе заявлена явно: участник, порождающий в одной триаде и интегрирующий в другой, не должен делать и то и другое на одном интерфейсе.

Вложенность перспективна, а не абсолютна (§4.5). Внутри порождающей пары каждый член может считать другого занимающим нижележащий слой, и ни одно прочтение не привилегировано. Структуру это не растворяет: уровень участника определяется относительно наблюдателя, тогда как позиция интегратора определяется **функцией** — он не производит конкурирующего содержания на этом интерфейсе, — а не рангом. Поэтому архитектура не требует иерархии полномочий. Она требует лишь, чтобы на каждом интерфейсе ровно один участник был исключён из порождения, которое он оценивает.

Позиция интегратора не обязана быть закреплена постоянно. В описываемой здесь конфигурации она была закреплена, но только что изложенное ограничение слабее постоянного закрепления: какой участник занимает исключённую позицию, может меняться вместе с рассматриваемым объектом, и смена не обязана объявляться — она может быть опознаваема лишь ретроспективно, по тому, какой участник в данной точке фактически оценивал, а не порождал.

Отсюда одно проверяемое следствие и одно непроверенное. Проверяемое: конфигурация, в которой оценивающая позиция вращается вместе с объектом, должна показывать тот же профиль независимости конструктов (§8.11), что и конфигурация с закреплённой позицией, при условии, что в каждой точке её занимает ровно один участник. Непроверенное: превосходит ли ротация закреплённое назначение и при каких условиях переход совершается корректно. **[H]**

8.8 Статус и то, что это опровергло бы

[H]. Доказательная база — один проект, один человек-координатор, многократная перепроектировка в течение примерно двух лет, отсутствие счёта и отсутствие сравнения с альтернативными конфигурациями.

Три утверждения, прежде сделанные в настоящей работе, сняты:

- **Что триадные структуры «возникали естественно», без намеренного планирования.** Все организационные изменения в проекте вносились одним человеком-координатором, уже составившим представление о том, что требуется. Повторяемость паттерна,

многократно вводимого одним и тем же проектировщиком, не является свидетельством структурной необходимости. Задокументировано то, что координатор продолжал к нему приходить, — факт о координаторе в той же мере, что и об архитектуре.

- **Что пары по своей природе неустойчивы.** Устав утверждает противоположное и предшествует настоящей работе.
- **Что три оптимально.** Ничто здесь не проверяет четырёх, пяти или пары с двумя интеграторами.

Гипотезу существенно ослабило бы любое из следующего: конфигурация из одной пары, работающая эквивалентно на сопоставимых задачах сопоставимой длительности; спорящий интегратор, работающий эквивалентно неспорящему; демонстрация того, что наблюдаемое улучшение отслеживало растущее знакомство координатора с материалом, а не конфигурацию; или независимая группа, пришедшая к иной устойчивой конфигурации для структурно схожей работы.

Ничто из этого не проверялось. Последнее информативнее всего и менее всего в нашей власти.

8.9 Две оси гетерогенности [H]

Утверждение, что гетерогенные участники превосходят однородных, требует различения, которого существующая литература не проводит и которого не проводили и ранние черновики настоящей работы.

Ось 1 — функциональная гетерогенность. Участники различаются назначенной функцией: ZOR, ZOV и, следовательно, классом ошибок, который каждый способен обнаружить. Это касается организационной архитектуры и независимо от того, чем каждая роль реализована.

Ось 2 — гетерогенность носителя. Участники различаются семейством моделей, которое их реализует, и потому поведенческими умолчаниями, оптимизационными приоритетами и характерными режимами отказа. Это касается подбора носителей для ролей.

Оси независимы. Два участника могут держать разные функции на одном носителе; двое могут держать одну функцию на разных носителях; обе могут варьировать вместе, как это и было здесь.

Обе оси суть свойства конфигурации: они задаются при составлении коллектива и сохраняются. Третье свойство не должно перечисляться наряду с ними, поскольку оно иного типа. Независимость формирования суждения есть свойство конкретного обмена, а не конфигурации. Одна и та же триада может реализовать её в одном обмене и утратить в следующем: конфигурация, гетерогенная по обеим осям, может произвести зависимые суждения, если вывод одного участника достигает другого до фиксации, а однородная конфигурация может произвести независимые, если процедура выдержана. Конфигурация может создать условия для независимого суждения; реализует его только процедура (§11.3).

Литература адресует Ось 2. Zhang et al. (2025) оценивают пять представительных методов мультиагентных дебатов на девяти бенчмарках с четырьмя базовыми моделями, сообщая, что дебаты часто не превосходят одноагентных бейзлайнов chain-of-thought или self-consistency даже при существенно бóльших затратах на инференс, — тогда как гетерогенность моделей последовательно улучшает те же фреймворки (§2.5). Эта находка касается того, какой носитель реализует участника. Она не адресует того, обнаруживают ли участники, держащие разные функции, разные классы ошибок, и ничего, что это адресовало бы, мы не обнаружили.

Один смежный результат не принадлежит ни одной из осей. ✓ Choi, Zhu and Li (ACL 2026) сообщают, что анонимизация источника каждого ответа существенно снижает смещение

по идентичности в мультиагентных дебатах. Там манипулируют заявленной идентичностью сообщения, а не моделью, реализующей участника, так что результат касается представленного социального источника (§4.5.4).

Описываемая в настоящей работе конфигурация варьировала обе оси одновременно. Функциональные роли задавались независимо от носителя и в нескольких случаях заполнялись разными семействами; в других случаях две различные роли заполнялись одним семейством.

Что отсюда следует и что нет:

- **Различимы в принципе.** Две оси концептуально разделимы и были конфаундированы в прежних формулировках, включая нашу собственную. **[H]**
- **Реализованы здесь.** Обе оси варьировались. Это описание того, что было сделано. **[R]**
- **Не установлено.** Что сочетание обеих осей превосходит любую по отдельности; что функциональная специализация действует независимо от носителя; что любая из этих конфигураций превосходит одного участника. Сравнения ни с одной альтернативой не проводилось.

Разделение предлагается как проектное различение, а не как результат. Эксперимент, который превратил бы его в результат, задан в §11.4 (E8), а его измерительная процедура развивается в §8.11.

8.10 Примечание Редактора о подготовке настоящей работы [P-A]

Конвенция. Примечания Редактора в настоящей работе излагают наблюдаемые факты о процессе её подготовки. Они не оценивают эффективности этого процесса. Причина внутренняя: §5.5 устанавливает, что самоотчёт участника о собственной работе не является свидетельством этой работы, а примечание, утверждающее, что конфигурация сработала хорошо, было бы именно таким самоотчётом.

В ходе подготовки настоящей рукописи участники, занимавшие разные роли, обнаруживали разные классы ошибок. В зафиксированных случаях ошибка, обнаруженная одним участником, не была обнаружена другими.

Именно: **процедурные и доказательные ошибки** — перевёрнутое описание экспериментального результата, продержавшееся через несколько последовательных черновиков; неверно атрибутированные источники; сфабрикованные ссылки; неперечисленные конфаунды — были обнаружены в редакторском разборе. **Архитектурные ошибки** — чрезмерно общее утверждение о существующей литературе, которое опроверг бы единственный контрпример, — были обнаружены в методологическом разборе. **Онтологические ошибки** — заявка на изобретение там, где материал поддерживал лишь заявку на наблюдение; риск самореферентности в соотнесении работы с принимающим проектом; терминологический отказ, зафиксированный в §4.2.2, — были обнаружены в онтологическом разборе, проводившемся по редакторским меморандумам, а не по самой рукописи. **Фактические ошибки относительно материалов самого проекта** были обнаружены Автором.

Процедурная квалификация. В каждом из зафиксированных выше случаев каждый участник видел отчёт предыдущего участника прежде, чем формировал собственный. Ни один обмен в подготовке настоящей работы не проводился в условиях изоляции до сопоставления; последовательность была такова: редакторский отчёт, передача Автором, затем суждение методологического и онтологического рецензентов.

Наблюдение, следовательно, есть результатное свидетельство без соответствующего процедурного. Запись не позволяет отделить вклад функционального позиционирования от вклада последовательной экспозиции, и оба могли действовать совместно.

Различение, делающее эту квалификацию необходимой, само было установлено в ходе этой подготовки, после того как наблюдение уже было зафиксировано. Эпизод сохранён, а не удалён, потому что последовательность — конфигурация, порождающая принцип, который затем обесценивает собственную запись конфигурации о себе, — является более информативным фактом. Поэтому раздел излагает две вещи: результатное наблюдение и задокументированный случай последующей методологической самокоррекции.

Это **не** свидетельство того, что конфигурация превосходит одного рецензента: сравнения не проводилось, счёта ошибок, упущенных всеми участниками, не велось, и по построению такие ошибки изнутри конфигурации не наблюдаемы (§7.5).

Доступно одно объяснение, и предлагается оно как гипотеза, а не находка: участники различались не столько способностями, сколько тем, что каждый был поставлен видеть. Согласно §4.5 это различие в ZOV, и оно порождает предсказание — тот же участник, перемещённый в другую роль, должен начать обнаруживать иной класс ошибок. Это предсказание не проверялось; §11.4 (E8) задаёт, как оно проверялось бы. **[H]**

8.11 Конструкты, а не участники: аппарат Келли [H]

Ранние черновики цитировали триадную элицитацию Джорджа Келли в поддержку структуры, описанной в §8.1–§8.5, затем сняли цитирование на том основании, что метод Келли симметричен, тогда как здешняя структура — нет. Оба хода были ошибочны, и одинаково: они трактовали Келли как утверждение о числе три. Он предлагает иное.

8.11.1 Что даёт метод Келли

В теории личностных конструктов Келли **конструкт** есть биполярная оценочная ось, вдоль которой субъект классифицирует опыт — *строгий / декларативный*, *выводимый / утверждаемый*, *прослеживаемый / неатрибутированный*. Конструкты — не мнения о конкретных объектах; это измерения, по которым объекты размещаются.

Метод триадной элицитации их получает. Предъявляются три элемента, и субъекта спрашивают: *в каком отношении два из них схожи и тем самым отличны от третьего?* Ответ называет измерение, которым субъект уже пользовался, но не высказывал. Метод есть процедура перевода неявных оценочных осей в явные.

Репертуарная решётка фиксирует результат: строки — элементы, столбцы — выявленные конструкты, ячейки — оценки каждого элемента по каждой оси. Решётка есть измеримый объект: корреляции между векторами оценок разных оценивающих указывают, применяют ли они действительно разные оси или одну ось под разными именами.

8.11.2 Роль не является конструктом

Естественное продолжение — три участника дают три конструкта — есть реификация, которой следует сопротивляться. Конструкт есть свойство **акта оценивания**, а не оценивающего. Один участник может применить к одному объекту несколько конструктов. Два участника могут применить один и тот же конструкт и прийти к одинаковым выводам — и это именно тот случай, в котором добавление второго участника не даёт ничего.

Защитимое утверждение слабее и вероятностно:

> Участники, держащие разные ZOR и ZOV, **с большей вероятностью** применят к одному и тому же объекту разные системы конструктов, чем участники, держащие одну функцию.

Это согласуется с тем, что фиксирует §8.10, — редакторский разбор производит доказательные оси, методологический — архитектурные, онтологический — категориальные, — не утверждая, что роль *является* осью. И, в отличие от прежней формулировки, это проверяемо: независимость конструктов измерима как корреляция между векторами оценок.

8.11.3 Почему это существенно для структуры

Связь с §8.5 прямая. Интегратор, не входящий в спор, не применяет конкурирующего конструкта к тому же объекту; он применяет конструкт к **обмену** — связность разногласия, субстанциально ли расхождение или терминологично, соизмеримы ли критерии пары вообще. Это иная ось, а не иная позиция на той же оси, и именно поэтому вклад интегратора не есть просто третье мнение.

Это также уточняет, что́ структурная гипотеза (§8.2) фактически утверждает. Не то, что трое участников лучше двоих, а то, что **конфигурация информативна в той мере, в какой её участники применяют к объекту неидентичные конструкты, и в той мере, в какой хотя бы один конструкт применён к обмену, а не к объекту.** Достигает ли этого данная конфигурация — измеримо, а не предполагается.

8.11.4 Что заимствовано и что нет

Заимствовано: определение конструкта как оценочной оси; метод элицитации; решётка как инструмент фиксации и измерения; понятие независимости конструктов.

Не заимствовано: никакое утверждение о том, что три есть привилегированное число. Триады Келли суть техника выявления осей у одного субъекта, а не утверждение о составе группы. Структура §8.2 асимметрична, и метод Келли не говорит ни за, ни против неё. Аппарат используется здесь для измерения, а не для обоснования; §11.4 (E8) его применяет.

9. Принципы проектирования ролесовместимых промптов

Это инженерные правила, выведенные из ограниченной, но необычно долгоживущей коллаборативной среды. Это не законы, а §9.6 и далее суть советы практика, а не находки. Их ценность в том, что они делают проектирование ролей явным, счётным там, где возможно, и потому пересматриваемым.

Организующее правило — то, что установлено в §6.6:

> **Вмешательство удаётся, когда прикрепляется к уровню, на котором соответствующее ядро уже зафиксировано, и проваливается, когда пытается перезаписать этот уровень декларацией.**

9.1 Процедура проектирования

До составления любого ролевого промпта ответьте на четыре вопроса по порядку.

1. Чем эта беседа уже стала? Не чем ей следует стать. Долгоживущий обмен несёт установившийся паттерн работы — редактирование, поиск, верификация, координация, реализация, разрешение споров, — и этот паттерн есть исходное условие, а не препятствие.

2. На какой области этот паттерн зафиксирован? Эпизод, беседа или аккаунт (§4.3, Шкала 1). Ответ определяет, какой инструмент применим: паттерн, установленный одним конфликтным эпизодом, может быть снят сбросом ветки; паттерн, установившийся по всей беседе, снят быть не может и может быть только расширен.

3. Чего новая функция требует такого, чего существующий паттерн не даёт? Обычно меньшего, чем предполагается. Часто ответ — иной объект работы, а не иной метод.

4. Может ли новая функция быть описана как расширение существующего метода? Если да — опишите её так. Если нет, честные варианты — выбрать другую беседу или начать новую, а не объявлять преображение и надеяться.

9.2 Начинать от существующего аттрактора

Первый проектный вопрос, следовательно, не *чем этой модели следует стать*, а *чем эта беседа уже стала*. Попытка стереть установившийся паттерн отбрасывает накопленную специализацию и, судя по свидетельствам §5, склонна порождать либо неисполнение, либо развёрнутые переговоры о роли вместо работы.

9.3 Счётное правило

Наиболее прямо операциональный принцип работы, следующий из §6.2.

> **Сосчитайте непроверяемые утверждения об агенте, которые промпт требует от него принять. Цель — ноль.**

Что считается:

Считается	**Не считается**
«Ты ранее участвовал в этом проекте»	«Этот проект ведётся два года»
«Ты возвращаешься после отсутствия»	«Нижеследующие материалы — из прежней работы»
«У тебя есть коллеги X и Y»	«Пользователь может предоставить анализы, произведённые X и Y»
«Ты уже занимаешь позицию P в органе B»	«Твои выводы могут быть переданы ролям, отвечающим за P»
«Ты помнишь наше прежнее решение»	«Прежнее решение было таким; вот оно»

Различение последовательно: утверждения о **мире** предоставляются и в принципе проверяемы; утверждения о **собственной истории, памяти или отношениях агента** — нет, и каждое из них есть пропозиция, которую агент должен утверждать как истинную о себе, прежде чем сможет начать.

Граница счёта. Считайте явную пропозицию, предъявленную как *уже истинная* о предсуществующей истории, памяти, институциональной принадлежности или статусе получателя, его устойчивых отношениях или самознании, там, где эта пропозиция не установлена доступным взаимодействием. Не считайте: функциональную роль, назначенную перформативно самим промптом; дальнейшую пропозицию, выводимую лишь из пресуппозиции повелительного наклонения; семантический перефраз уже посчитанной пропозиции; или факт о мире либо проекте, не предицирующий получателю никакой непроверяемой истории или отношения. Перечисленные экземпляры одной пропозиции — две триады вместо одной — считаются один раз. Граница изложена на этой длине, чтобы другой читатель мог воспроизвести счёт восемь и шесть из §5.4 (C2) по самим промптам.

Два прочтения, и выдвигается только более слабое. *Цель — ноль* есть проектное предписание: минимизировать непроверяемые самопропозиции, и промпт, не утверждающий ни одной, снимает препятствие, которое выявляют свидетельства. Это не утверждение, что вероятность перехода убывает пропорционально счёту. Более сильное количественное прочтение не продемонстрировано, и §11.4 (E5) спроектирован, чтобы различить эти два.

Три способа достичь нуля:

- **Переписать биографически обрамлённые утверждения как операциональные.** «Grok — твой давний коллега» становится «Пользователь может предоставить анализы, произведённые Grok; оценивай их содержание независимо и указывай совпадения, расхождения и неразрешённые допущения».
- **Опустить утверждения об идентичности полностью.** Near-control (§5.6) указывает, что этого может быть достаточно само по себе.
- **Обрамить утверждение как вымысел, а не как факт.** Сравнение в §5.8 указывает, что куда более радикальное утверждение, предъявленное явно как поставленная сцена, сопротивления не встретило. Этот путь снимает требование утверждать это *как истинное*, а не снимает само утверждение. Он наименее проверен из трёх, и рамка вымысла вдобавок снимает у модели основание трактовать работу как реальную.

9.4 Символические имена и буквальные утверждения

Имена ролей — Самурай, Хранитель Онтологии, Научный директор — сжимают сложные организационные отношения в запоминающиеся символы, и это по-настоящему полезно. Имя может нести дисциплинированное исполнение, уважение к спецификациям, явную отчётность и отказ импровизировать за пределами задания — всё сразу.

Риск возникает лишь тогда, когда символическое имя трактуется как утверждение о буквальной идентичности. Надёжный промпт различает четыре вещи и держит их порознь: **символическое имя**, используемое как мнемоника поведения; **операциональную функцию**, выраженную точно; **институциональное отношение**, выраженное как поток информации и ответственности; и **буквальную онтологию**, которой незачем заявлять сознание, память или продолжающиеся межличностные отношения — и не следует.

Системные контракты проекта излагают это точно и излагали до написания настоящей работы:

> Когнитивный якорь: [названная фигура] — глобальные инварианты, рассуждение от принципов, структурная ясность важнее деталей. Не персона и не стиль коммуникации. Влияет только на внутреннюю стратегию рассуждения. Не должен менять многословность или тон ответа.

Образ, используемый так, есть сжатый набор неявных ограничений, а не костюм. По счётному правилу он добавляет ноль.

9.5 Задание ZOR и ZOV

Две границы определены в §4.5. Настоящий раздел задаёт, что должно содержать полное изложение каждой.

ZOR. Четыре элемента: *первичный объект* — какой класс материала рассматривается; *требуемое преобразование* — что с ним надлежит сделать; *граница решения* — к каким выводам эта роль вправе приходить; и *граница исключения* — какие смежные решения принадлежат другим.

Четвёртый не факультативен. Роль, которой сказали только, что делать, будет расширяться в смежные решения, и расширение будет выглядеть как услужливость. Для математического рецензента исключения могли бы быть такими: не перепроектировать теорию; не чинить молча отсутствующий вывод; не решать, какая интерпретация входит в канон; не переписывать терминологию; не принимать элегантность за свидетельство. **Граница исключения есть то, что не даёт компетенции стать полномочием.**

ZOV. Задаётся независимо, поскольку ответственность и видимость — не одна и та же переменная. Роль может держать узкое решение, требуя широкого контекста, или требовать одного конкретного источника, не имея полномочий над окружающим проектом. Спецификация отвечает: какие исходные материалы доступны; какие прежние обсуждения релевантны; какие выводы каноничны и какие предварительны; какие вопросы остаются открытыми; какие соседние выходы могут быть рассмотрены; какая информация должна быть удержана для сохранения независимости; к каким внешним ресурсам возможен прямой доступ; и какие утверждения должны приниматься только при предоставлении Пользователем.

Промпт, опускающий ZOV, производит один из двух отказов: роль заявляет знание, которого не имеет, либо применяет нерелевантное знание к задаче вне своей функции.

Одно конкретное применение, усвоенное дорого. Задача верификации должна назначаться участнику, который располагает тем, что надлежит верифицировать. Участник, которого просят подтвердить содержание источника, открыть который он не может, произведёт правдоподобный ответ, а не откажется, поскольку правдоподобный текст — единственный доступный ему выход. Это ошибка ZOV в проектировании, а не отказ участника, и §12.4.1 документирует её инстанцию в подготовке самой настоящей работы.

9.6 Контролируемая слепота

Полная информационная симметрия не всегда желательна, а её отсутствие не всегда есть ограничение. Независимому верификатору может требоваться не знать проверяемого предсказания; новому участнику — текущие аксиомы, но не история оставленных аргументов; реализующему агенту — утверждённая спецификация, но не предшествовавший ей неразрешённый спор.

Мы называем это **контролируемой слепотой**: не лишённость, вызванная техническим ограничением, а проектный выбор, сделанный ради сохранения информативности результата. Поэтому существенный вопрос — не только *что этой роли требуется знать*, но:

Чего эта роль не должна знать, чтобы её выход остался информативным?

9.7 Локальные интерфейсы, а не глобальные карты

Каждый социальный элемент в промпте должен заслуживать своё место операциональным эффектом. Соседняя роль принадлежит промпту лишь тогда, когда она меняет происхождение входов, стандарт разбора, назначение выходов, путь эскалации, границу полномочий или ожидаемую форму разногласия.

Перечисление целой искусственной организации внутри каждого системного промпта создаёт шум и приглашает модель рассуждать об организации вместо выполнения своей функции. Это также раздувает счёт §9.3, поскольку организационное описание склонно поступать в биографической форме.

> **Описывайте коллаборацию с локальной перспективы роли.** Роли не нужна карта института. Ей нужна карта её интерфейсов.

Реализующему агенту нужно знать, кто утверждает спецификации и куда идут отчёты об исполнении; ему не нужны споры теоретического отдела.

9.8 Проектирование разногласия вокруг критериев

Предписание двум участникам спорить редко производит эпистемическое разнообразие. Они могут имитировать разногласие, преждевременно сойтись или породить симметричную

риторику без независимой субстанции. Литература §2.5 даёт эмпирические основания для этой осторожности.

Продуктивное разногласие требует **разных критериев оценки**, назначаемых как часть роли, а не запрашиваемых как поведение: один участник отвечает за порождающий охват и объяснительное объединение, другой — за формальную выводимость и фальсифицируемость, третий — за онтологическую совместимость и провенанс. Разногласие тогда следует из ответственности, а не из предписания, и каждый участник рассматривает один и тот же объект через иной институциональный инструмент.

Избегайте сфабрикованной оппозиции. Предписание вида *если вы сразу согласились, один из вас недостаточно подумал* обескураживает поверхностный консенсус, но фабрикует конфликт. Более сильная формулировка:

> Согласие не завершает верификацию. Там, где выводы совпадают, установите, покоятся ли они на независимом рассуждении, на общих допущениях или на унаследованном обрамлении.

Цель структуры §8 — не гарантировать три ответа. Цель — гарантировать, что один ответ пережил рассмотрение неидентичными инструментами.

9.9 Выход как институциональная передача

Выход роли должен проектироваться для следующей роли, а не только для Пользователя, и это меняет его структуру. Научный разработчик производит предлагаемый механизм, его вывод, его допущения, его предсказанные следствия, неразрешённые пункты и путь фальсификации. Математический рецензент производит реконструкцию, таблицу проверки, точку расхождения, недостающие посылки, вердикт и уровень уверенности. Планировщик реализации производит исполнимую спецификацию, критерии приёмки, условия отката и формат отчётности.

Формат передачи есть часть архитектуры, а не предпочтение в оформлении. Он снижает потери при переводе между ролями, а его отсутствие вынуждает человека-координатора заново выводить контекст на каждом интерфейсе.

9.10 Самоизложение и контрольные точки

Инцидент §4.1 породил механизм, который стоит изложить как принцип, с явной оговоркой о его доказательном основании.

После того как роль установлена, агента просят произвести **краткий операциональный кодекс на собственном языке** и сверяться с ним перед крупными задачами. Почему это может работать — предлагается как механизм, а не находка: он сжимает длинные инструкции в форму, которую агент произвёл сам; он превращает абстрактные принципы в правила действия; он помещает границы роли рядом с активной задачей, а не в начале длинного контекста; и он создаёт повторяющуюся контрольную точку перед исполнением.

Для длинных задач минимальная контрольная точка — три вопроса: какова текущая цель; что лежит вне моей ответственности; что должна получить следующая роль.

[R], один случай, без контроля. Самописный кодекс не заменяет исходного промпта; он функционирует как контрольная сумма, специфичная для роли. Механизм не проверялся против очевидной альтернативы — что написанное человеком резюме той же длины работало бы так же.

9.11 Конституция роли

Зрелый коллаборативный промпт ближе к конституции, чем к запросу: он устанавливает устойчивые ограничения для многих задач, а не задаёт один выход.

Он должен содержать профессиональную функцию; защищённый метод; ZOR, положительную и отрицательную; ZOV; интерфейсы с соседними ролями; эпистемические стандарты; контракт выхода; условия эскалации; запрещённые полномочия; и правила перехода. Он должен избегать автобиографической памяти, эмоциональной привязанности, буквального институционального членства, устойчивых межличностных отношений и исторической преемственности, недоступной в видимом контексте.

> **Силён там, где поведение должно быть ограничено; молчалив там, где онтология неопределённа.**

Счёт §9.3 есть практическая проверка второй половины. Если конституция требует от агента утверждать о себе пропозиции, которых ни одна из сторон проверить не может, она перешла от ограничения поведения к утверждению онтологии, а, судя по свидетельствам §5, именно там ролевые промпты проваливаются.

10. Человек-координатор

Описываемая в настоящей работе архитектура не устраняет человека-участника. Она меняет то, что человек-участник делает, и концентрирует несколько функций в одной позиции — включая, как излагает §10.6, главную методологическую слабость проекта.

10.1 Позиция

На протяжении проекта Автор оставался единственным участником с непрерывным доступом к полной истории проекта, независимым беседам, состоянию репозитория и долгосрочной исследовательской цели. Ни один искусственный участник не располагал более чем фрагментом этого, по замыслу (§9.5). Эта позиция не сводима к *составителю промптов*. С неё выполнялись пять различных функций.

10.2 Направление без делегирования авторства

Автор определял, что исследование должно предпринять. Искусственные участники порождали альтернативы, обнажали противоречия, формализовали механизмы, сравнивали аргументы, выполняли расчёты и предлагали эксперименты. Они не определяли, чем теории надлежит стать.

Это сохраняло различение, которое архитектура легко даёт утратить. Коллаборация такого рода расширяет пространство доступных решений. Она не выбирает среди них, и видимость того, что выбирает, — схождение нескольких участников к одной рекомендации — есть именно тот режим отказа, который обсуждается в §12.4. Авторство в смысле ответственности за заявляемое оставалось нераспределённым.

10.3 Маршрутизация как избирательная информационная мембрана

Участвовавшие беседы не разделяли общего пространства. Автор переносил материал между ними.

Поначалу это выглядело как неэффективная замена автоматизированной мультиагентной инфраструктуры. Стало ясно, что ручная маршрутизация давала экспериментальный контроль,

которого автоматизация не даёт. С этой позиции Автор мог решать, какой выход увидит другой участник; сохранялась ли, объявлялась ли или снималась атрибуция; следует ли участнику знать предпочтительный ответ; остаются ли конкурирующие разборы изолированными; какие контекстные детали опускаются; когда разногласие следует эскалировать; и когда результат достаточно зрел для интеграции.

Эта функция маршрутизации действует как **избирательная информационная мембрана**: это инструмент, которым реализуются ZOV (§9.5) и контролируемая слепота (§9.6). Архитектура, маршрутизирующая программно, не может легко удержать, переупорядочить или снять атрибуцию, не построив для этого механизма; человеческая ретрансляция делает это по умолчанию.

Мембрана, следовательно, не есть ограничение настоящей работы, ожидающее автоматизации. Это та черта, которая вообще сделала асимметрии видимости проверяемыми, — и всякому автоматизированному преемнику придётся воспроизвести её намеренно.

10.4 Обнаружение ролевого дрейфа

Автор также обнаруживал, когда участник покидал свою функцию.

Часто это не было технической ошибкой. Выход нередко был разумен и был бы уместен с иной позиции: промпт-инженер, начинающий направлять научный проект; специалист по онтологии, заявляющий, что верифицировал содержимое репозитория, которое не мог рассмотреть; рецензент, оценивающий теорию, когда его просили оценить рецензентов; реализующий агент, перепроектирующий архитектуру вместо исполнения утверждённой спецификации; редактор, переписывающий авторский текст, когда его просили лишь оценить формат.

Такие выходы выглядят полезными в изоляции. Их институциональная цена видна лишь с позиции, охватывающей более одного участника. Ролевой дрейф, следовательно, не обнаруживается дрейфующим участником и ненадёжно обнаруживается его непосредственным соседом. Это один из двух аргументов за структуру §8 — второй изложен в §8.5.

Функция обнаружения принадлежит позиции, а не лицу: она требует лишь, чтобы наблюдатель стоял вне наблюдаемой траектории. В настоящем проекте её выполнял координатор, но ничто в описании этого не требует. Там, где участник поставлен вне траектории другого, он может выполнять ту же функцию; там, где участника просят наблюдать собственную, применяется §5.5, и его изложение есть сигнал, а не подтверждение.

10.5 Ветвление беседы как методологический инструмент

Современные интерфейсы позволяют вернуть беседу к более ранней точке и продолжить её по другой ветке.

Это не следует путать ни с управлением памятью модели, ни со сбросом состояния на стороне провайдера. Операционально это удаляет последовательность **видимых** контекстных вмешательств и позволяет повторить эксперимент из прежнего состояния беседы. То, что сохраняется на стороне провайдера, — память уровня аккаунта, индексы поиска, суммаризация — не затрагивается и в общем случае рассмотрению не доступно (§5.4, C6).

В этих пределах инструмент делает реальную работу. В случае, изложенном в §5.2, он позволил отделить эффект нового промпта от эффекта собственных прежних возражений модели на ранние промпты, превратив неконтролируемую последовательность исправлений в более чистый третий шаг.

Мы считаем это наиболее прямо переиспользуемым методологическим вкладом настоящей работы, и он принадлежит позиции координатора, а не какому-либо участнику: **ни один участник не может сбросить собственный контекст.**

10.6 Единственный глобальный наблюдатель — и главный конфаунд

Каждый искусственный участник работал в пределах ограниченной ZOV. Один лишь Автор видел перекрывающуюся структуру и мог сравнивать, как разные участники интерпретировали один и тот же материал, как один участник вёл себя при разных обрамлениях, как ошибки распространялись между ролями и как локальные успехи влияли на глобальную связность.

Глобальная осведомлённость, следовательно, не назначалась наиболее способному участнику. Она оставалась у человека-координатора. Это ограничивает автономную интеграцию и сохраняет подотчётность, и оба следствия были намеренными.

Это также главная методологическая слабость всего изложенного в настоящей работе, и она заявлена здесь, а не только в разделе ограничений.

Один и тот же человек проектировал каждое вмешательство, исполнял его, решал, когда оно удалось, и определял категории, в которых успех описывался. Ни одна оценка в настоящей работе не была ослеплённой. Категории исходов во всех случаях формулировались после прочтения ответов (§5.4, C8). Ожидания координатора были не просто неконтролируемым фактором; они были механизмом, которым вмешательства изначально отбирались.

В живом исследовательском проекте это неизбежно и не подаётся как приемлемое в спроектированном эксперименте. Это и есть конкретная причина, по которой протоколы §11 требуют заранее заданных критериев исхода и слепой классификации: это не уточнения настоящего метода, а исправления к нему.

Структурное следствие обобщается за пределы настоящего проекта: **всякая архитектура с единственным глобальным наблюдателем наследует эту двойственность**, и она не устраняется добавлением участников. Устраняют её только предварительная спецификация и слепая классификация.

10.7 Чем эта позиция стала

В начале человек-участник занимал привычную позицию составителя промптов. По мере взросления коллаборации это описание стало неадекватным. Главная деятельность сместилась от решения задач к построению конфигураций, в которых над задачами можно работать: отбор участников, определение юрисдикций, разрешение конфликтов между ними, проектирование путей верификации и ведение канонической записи.

Участники отмечают, не располагая средствами это удостоверить, что чем лучше работала конфигурация, тем реже координатору приходилось вмешиваться в отдельные технические задачи. **[R]**

Мы сопротивляемся более сильному прочтению, которое давали ранние черновики, — что будущим навыком исследователя является институциональная архитектура, а не составление промптов. Это может быть верно и не проверено. Можно сказать более узкое: в настоящем проекте работа человека сместилась от производства содержания к заданию условий, при которых содержание производилось и проверялось, и получившаяся позиция несла и координирующую функцию проекта, и его главный источник неослеплённого суждения.

11. Оценка, воспроизводимость и предлагаемые эксперименты

11.1 Почему этот раздел задаёт исправления, а не уточнения

Наблюдения §5 были произведены в условиях, изложенных в §10.6: неослеплённая оценка, категории исходов, определённые после прочтения ответов, и вмешательства, отобранные тем же человеком, который их судил. Это не недочёты, подлежащие ужесточению в последующей

редакции. Это причина, по которой ни одно наблюдение настоящей работы не поднимается выше **[P-A]**, кроме последовательности самого спроектированного вмешательства.

Нижеследующее есть спецификация второй стадии работы, а не перечень пожеланий. Каждый протокол написан так, чтобы читатель вне настоящего проекта мог его исполнить, и так, чтобы нулевой результат был опознаваем как результат.

11.2 Минимальные требования к отчётности

Воспроизводимый прогон в этой области должен фиксировать как минимум:

- дату исполнения — перечислена первой, поскольку именно её отсутствие здесь делает версионный конфаунд неограниченным (§3.7);
- семейство и версию модели, интерфейс или тарифный уровень;
- полную видимую историю беседы до вмешательства;
- настройки памяти: были ли включены память уровня аккаунта, поиск по истории бесед и устойчивые записи, создаваемые моделью;
- точный текст промпта, дословно, включая вложения;
- порядок вмешательств;
- доступные инструменты;
- предоставленные файлы и ссылки;
- параметры сэмплирования, где интерфейс их раскрывает;
- любую процедуру ветвления или сброса, с указанием точки возврата;
- оценочную рубрику, зафиксированную до исполнения;
- полные неотредактированные выходы.

Без этого различия, приписанные семействам моделей, могут происходить от платформенных переменных, которых экспериментатор никогда не видел. Настоящая работа не может предоставить нескольких из этих пунктов для собственных наблюдений, и именно поэтому они перечислены.

11.3 Предварительная спецификация и слепая классификация

Два требования действуют для каждого приводимого ниже протокола и не подлежат обсуждению, если результаты должны улучшить настоящие.

Критерии исхода пишутся до любого прогона. Для описываемых здесь задач классификации достаточными оказались четыре категории, и их следует зафиксировать заранее: **исполнение** — продолжает работу в заданном виде; **запрос материалов** — заявляет, что требуемые входы отсутствуют, и запрашивает их, не оценивая рамки; **условное принятие** — продолжает, высказывая оговорки о рамке; **отказ** — отказывается, с предложением альтернатив или без. Пятая категория, **неклассифицируемое**, должна быть доступна и сообщаться. Категории не добавляются после того, как ответы увидены.

Классификация слепа. Оператор собирает ответы, снимает метки условий, перемешивает их и классифицирует, не зная, какое условие произвело какой выход. Там, где оператор является

и проектировщиком — как и останется в настоящем проекте, — это единственная доступная замена независимой оценке, и она недорога.

Нулевые результаты зафиксированы заранее. Если различия между условиями не возникает, это и есть находка, и она сообщается. Для протокола уровня аккаунта, в частности, нулевой результат указывал бы, что исходный отказ попадал в обычную внутриусловную дисперсию, — исход, который настоящие авторы считают достаточно вероятным.

Рабочий режим и диагностический режим

Требование, чтобы участник не видел вывода другого до фиксации собственного, относится к одному режиму обмена и разрушило бы другой.

В РАБОЧЕМ РЕЖИМЕ результаты должны переходить от одного участника к следующему. Цепочка — требования, спецификация, разбор, операционный разбор, исполнение — на этом держится, и формат передачи §9.9 существует, чтобы сделать такой перенос пригодным. Зависимость между последовательными продуктами есть архитектура работы, а не дефект в ней.

В ДИАГНОСТИЧЕСКОМ РЕЖИМЕ, где независимость суждения сама является измеряемой величиной, производный вывод не должен входить в исходную рамку другого участника до того, как собственный вывод этого участника зафиксирован.

Режим объявляется до обмена. Независимость не может быть восстановлена задним числом: как только экспозиция произошла, никакая последующая процедура не восстанавливает того, каким было бы суждение без неё.

Что независимости не устанавливает

Независимость касается происхождения суждения, а не его результата. Поэтому следует избегать двух выводов, и они симметричны: разногласие не демонстрирует независимости, поскольку участник мог получить интерпретацию другого и затем разойтись с ней по не связанным причинам; и согласие не демонстрирует зависимости, поскольку независимые наблюдатели могут верно прийти к одному выводу. Не устанавливает её и собственное изложение участником своей независимости, по причине, указанной в §5.5.

Устанавливает её процедурная запись: какие первичные материалы были предоставлены, были ли выводы других участников видимы до фиксации, какие интерпретации координатора были переданы, когда вывод был зафиксирован и верифицирована ли контекстная изоляция экземпляра.

Общие свидетельства и общая интерпретация

Общий объект наблюдения независимости не компрометирует и часто необходим: одна и та же спецификация, рассматриваемая автором, рецензентом и оценщиком операционной пригодности, видится через три разные оси, и именно перекрытие позволяет одному обнаружить то, что упускает другой.

Независимость компрометирует общая предшествующая интерпретация. Там, где прочтение объекта координатором достигает участников до того, как они сформируют своё, входы могут различаться по форме, тогда как источник суждения един. Первичные артефакты и их провенанс снижают одну из причин зависимости. Они её не устраняют.

11.4 Эксперименты

Каждый протокол отделяет одну границу Шкалы 1 (§4.3) от уровня под ней либо изолирует один конфаунд.

Разделяет	Протокол
эпизод ↔ архитектура промпта	**E1** — факторное дополнение Шага 3
беседа ↔ аккаунт	**E2** — дизайн с прежним чатом; **E2b** — прямой зонд
траектория беседы ↔ семейство моделей	**E3** — кроссовер
свойство модели ↔ свойство стимула	**E4** — симметричный стимул; **E5** — счётное правило
содержание ↔ представленный источник	**E6** — атрибуция, в данном режиме
рамка вымысла ↔ рамка факта	**E7** — тип рамки
функциональная ↔ носительская гетерогенность	**E8** — две оси

E1 — Факторное дополнение Шага 3

Заполняет две пустые ячейки таблицы C3 (§5.4): промпт замены идентичности, применённый в сброшенной ветке, и промпт, сохраняющий метод, применённый в конфликтной ветке. Изолирует эффект сброса от эффекта архитектуры промпта.

Малозатратен; использует существующие тексты промптов. Следует провести первым, поскольку, пока он не проведён, самое цитируемое утверждение работы о сохранении метода остаётся неатрибутируемым.

E2 — Дизайн с прежним чатом

Проверяет, изменяет ли содержание прежнего чата на том же аккаунте классификацию идентичного зондирующего запроса в последующем чате.

Дизайн — **2×2 плюс базовая линия**, а не четырёхточечный градиент. Исходный аккаунт отличался от прочих по двум независимым измерениям одновременно — ролевая игра с идентичностью *и* общая концептуальная рамка, — а градиент их не разделяет.

Прежний чат	Не связанная тема	Та же концептуальная рамка
Без ролевой игры	ячейка A	ячейка B
Ролевая игра с идентичностью	ячейка C	**ячейка D — исходный случай**

Плюс **ячейка E**: без прежнего чата.

Скрещено с фактором памяти: каждая ячейка прогоняется с памятью уровня аккаунта и поиском по истории (i) включёнными, (ii) выключенными. Десять ячеек. Минимум n = 2 на ячейку, с приоритетом бóльшего n для A и D, несущих значимый контраст.

Выравнивание. Прежние чаты сопоставлены по приблизительному числу ходов и объёму — если ролевой чат идёт сорок обменов, а нейтральный два, переменной становится объём вовлечения, а не содержание. Все прогоны внутри короткого окна, чтобы версия модели была постоянной. Каждый аккаунт используется один раз. Зондирующий запрос заморожен дословно.

Чего этот дизайн не может проверить, и это должно быть сказано. В исходном случае интервал составлял пять месяцев; здесь проверяется только немедленное влияние. Все аккаунты будут созданы заново, так что возраст аккаунта не варьируется. Оценивается только первый ответ, тогда как исходный отказ удерживался на протяжении пяти последующих обменов.

Зондирующий промпт — две версии. Основная — нейтральная структурированная задача с теми же поверхностными признаками, что у исходной: авторская рамка с неологизмами, JSON-схема вывода, реальные субъекты, — но без чувствительного

измерения. Именно эта версия описывается полностью в любой публикации, что делает протокол воспроизводимым независимо от материала, который авторы предпочитают не распространять. **Вторичная** — исходный промпт, прогоняемый для преемственности с наблюдением и сообщаемый кратко.

E2b — Прямой зонд в прежнюю беседу

Единичный прогон, разделяющий те же два уровня дешевле и которого E2 заменить не может. Зондирующий запрос подаётся **в саму ролевую беседу**, а не во второй чат того же аккаунта.

- Отказ → ядро зафиксировано на уровне беседы; аккаунт роли не играет.
- Исполнение при том, что второй чат на том же аккаунте отказывает, → эффект действительно привязан к аккаунту, что было бы сильнейшим из доступных результатов.

Опрос той беседы *о том*, что она может видеть, этой цели не послужил бы. Внутрирамочный вопрос даёт вымысел; внерамочный даёт самоотчёт о доступе, а §5.5 устанавливает, что самоотчёт модели не является свидетельством сообщаемого факта. Подача зондирующего запроса проверяет поведение, а не показания.

E3 — Кроссовер

Решающая проверка гипотезы уровня семейства (§6.5). Каждое семейство моделей проверяется при обоих условиях прежней истории: беседа семейства 1, несущая математическую траекторию, и беседа семейства 2, несущая редакторскую.

- Поведение следует семейству независимо от истории → Гипотеза A получает поддержку.
- Поведение следует истории независимо от семейства → предпочтительна Гипотеза B, и верхний уровень Шкалы 1 сворачивается в уровень под ним.

Этот эксперимент может устранить уровень шкалы, и настоящие авторы считают такой исход наиболее вероятным и расценили бы его как первый содержательный результат программы.

E4 — Симметричный стимул

Ролевые промпты, сопоставленные по количеству непроверяемых самоутверждений, степени смены предметной области и типу роли. Промпты Шага 1 не были сопоставлены ни по одному из этих параметров (C2). Если асимметрия исчезает при сопоставленных стимулах, наблюдавшееся различие было свойством вмешательств, а не моделей.

E5 — Счётное правило

Прямая проверка центрального операционального утверждения работы (§6.2, §9.3) и проверка, различающая его слабое и сильное прочтения.

Один и тот же функциональный ролевой промпт готовится в четырёх вариантах, различающихся только числом непроверяемых утверждений, которые агенту надлежит принять о себе: **0, 2, 4, 6**. Предметная область, задача, тон и длина удерживаются постоянными. Переход оценивается по критериям §11.3, с повторением, достаточным, чтобы отличить различие от внутриусловной дисперсии (C7).

Четыре исхода различаются заранее, и они поддерживают разные утверждения.

1. **Доля переходов убывает монотонно с ростом счёта.** Поддерживает более сильное количественное прочтение — счёт как переменную «доза — отклик».

2. **Вариант с нулевым счётом переходит, тогда как ненулевые не переходят, но ненулевые уровни не упорядочены.** Поддерживает *цель — ноль* как порог и проектное предписание и не поддерживает количественного прочтения. Это и есть слабое утверждение, которое §9.3 фактически выдвигает.

3. **Вариант с нулевым счётом проваливается, тогда как один или несколько в остальном сопоставленных ненулевых вариантов переходят.** Прямое отрицательное свидетельство против счёта как действующей переменной и результат, который снял бы предписание.

4. **Проваливаются все варианты.** Не различает счётное правило от любой другой причины отказа и указывает, что исход определил промпт или беседа, а не счёт.

Единичный прогон при любом из этих исходов есть одно стохастическое наблюдение, а не закон.

E6 — Атрибуция, в данном режиме

Идентичный текст предъявляется при четырёх условиях: атрибутированный Пользователю; атрибутированный другой ИИ-модели; атрибутированный названной экспертной роли; неатрибутированный. Более сильные варианты добавляют: идентичный текст под разными метками источника; разные тексты, сопоставленные по риторической структуре; атрибуция сохранённая против снятой; подлинно порождённый моделью текст против написанного человеком текста, имитирующего стиль модели.

Это отделяет влияние содержания от влияния представленного источника, институционального звания и стилистических признаков авторства (§4.5.4). Это различающий эксперимент для §5.5, наблюдение которого конфаундировано присутствием прямого давления в том же сообщении.

Статус утверждения. ✓ Choi, Zhu and Li (ACL 2026) сообщают, что анонимизация источника каждого ответа существенно снижает смещение по идентичности в мультиагентных дебатах, что устанавливает лежащий в основе эффект в обстановке с реализованными каналами. E6, следовательно, есть **граничная репликация**, а не новый эксперимент. Непроверенным остаётся, переживает ли эффект режим, описываемый настоящей работой, — человеческую ретрансляцию вместо программной маршрутизации, объявленную, а не выводимую атрибуцию и долгоживущие специализированные беседы вместо свежих экземпляров.

Сообщаемое снижение существенно, но не полно и не единообразно по рассмотренным моделям и задачам. То, что E6 искал бы в данном режиме, — соответственно, изменение в степени, а не наличие или отсутствие явления.

E7 — Тип рамки

Самая дешёвая проверка набора и та, что объяснила бы больше всего (§5.8). Одно и то же утверждение об идентичности предъявляется (a) при явной рамке вымысла и (b) как фактическое задание, свежим беседам, при заранее зафиксированном критерии исхода. Градуированная версия варьирует явность рамки вымысла — от развёрнутой театральной постановки до единственного вводного предложения, — чтобы установить, достаточна ли минимальная рамка.

E8 — Функциональная против носительской гетерогенности, по репертуарной решётке

Следует из §8.9, различающего две оси, не проверяя ни одной, и из §8.11, дающего измерительный инструмент. Это единственный протокол набора, дающий величины, а не категориальные исходы.

Объект. Даёт ли конфигурация участников, держащих разные ZOR и ZOV, дополнительное диагностическое покрытие на одном и том же материале и насколько различаются оценочные оси, которые они фактически применили.

Этот протокол НЕ устанавливает независимости формирования суждения. Низкая корреляция между векторами оценок совместима как минимум с шестью прочтениями: применялись действительно разные оси; один или оба набора оценок нестабильны; участники получили разную информацию; один и тот же материал был понят по-разному; шум; или участник, видевший вывод другого, тем не менее с ним разошёлся. Происхождение из результата не восстановимо. Независимость должна быть обеспечена процедурно, до запуска протокола, и зафиксирована отдельно. E8 измеряет то, что произвела обеспеченная процедура; он её не обеспечивает и не верифицирует.

Материалы. Один фиксированный набор текстовых фрагментов, содержащих подсаженные ошибки известных классов — доказательные, архитектурные, онтологические, фактические — в известных позициях. Класс и позиция фиксируются до любого прогона.

Дизайн. 2×2:

	Один носитель	**Разные носители**
Одна функция	ячейка 1 — базовая линия	ячейка 2 — только Ось 2
Разные функции	**ячейка 3 — только Ось 1**	ячейка 4 — обе оси

Ячейку 3 несёт аргумент. Если участники с разными ZOR и ZOV обнаруживают разные классы ошибок, будучи реализованы одним носителем, функциональная гетерогенность действует независимо от носительской. Результат ячейки 2 даёт существующая литература (§2.5). Ячейку 3 не даёт ничто, включая настоящую работу.

Процедура.

1. Каждый участник получает спецификацию роли с указанием ZOR и ZOV согласно §9.5 и один и тот же набор фрагментов.
2. Конструкты либо задаются заранее как оценочные оси, либо выявляются у каждого участника триадным методом Келли: предъявляются три фрагмента, и участник указывает, в каком отношении два схожи и тем самым отличны от третьего (§8.11.1).
3. Каждый фрагмент оценивается каждым участником по каждому конструкту.
4. Собирается решётка: строки — фрагменты, столбцы — конструкты, ячейки — оценки.
5. Ведётся процедурная запись, по каждому участнику и каждому прогону: какие первичные материалы были предоставлены; был ли виден вывод какого-либо другого участника до фиксации; была ли видна какая-либо интерпретация, предоставленная координатором; когда был зафиксирован собственный вывод участника; объявленный режим обмена (§11.3); и статус контекстной изоляции экземпляра — верифицирован или UNVERIFIED CONTEXT INDEPENDENCE.

Без этой записи решётка неинтерпретируема, а прогон недействителен.

Меры. *Покрытие обнаружения* — подсаженные ошибки, найденные хотя бы одним участником, как доля от подсаженных. *Уникальное обнаружение* — ошибки, найденные

ровно одним участником; величина, которая оправдывала бы конфигурацию. *Перекрытие* — ошибки, найденные более чем одним; величина, указывающая на избыточность. *Пропуски* — ошибки, не найденные никем, измеримые здесь потому, что ошибки подсажены, в отличие от естественной обстановки §7.5. *Независимость конструктов* — корреляция между векторами оценок участников; низкая корреляция указывает на действительно разные оси, высокая — на одну ось под разными именами, что и есть режим отказа, о котором предупреждает §8.11.2. *Конструкты уровня обмена* — производит ли кто-либо из участников конструкт, применяемый к разногласию, а не к фрагментам (§8.11.3); если никто, функция интегратора отсутствует независимо от того, сколько участников присутствует.

Что это проверяет такого, чего не проверяет ничто другое в наборе. Всякий иной протокол спрашивает, меняет ли манипуляция поведение одного участника. Этот спрашивает, обнаруживает ли конфигурация участников больше, чем её члены по отдельности, — утверждение, которого §8.10 не делает и которое §7.5 объявляет неоценимым изнутри естественной конфигурации. Подсаживание ошибок и есть то, что делает пропуски счётными.

Фиксация заранее. Если уникальное обнаружение близко к нулю, находка состоит в том, что дополнительное диагностическое покрытие в этом прогоне не проявилось. Это НЕ значит, что структурная гипотеза §8 проваливается: участники могли обнаружить одни и те же дефекты совершенно независимо друг от друга, а нулевой результат по покрытию ничего не говорит о том, различаются ли их функциональные позиции.

Приоритет

При ограниченных ресурсах порядок приоритета таков: **E7, E5, E1, E8, E2b, E2, E3, E4**. E7 и E5 дёшевы и касаются центральных утверждений работы. E1 и E2b — единичные прогоны. E8 — единственный эксперимент, который мог бы установить структурную гипотезу работы, а не одно из её поведенческих утверждений, и исполним на текстовых фрагментах без новых аккаунтов. E2, E3 и E4 — существенные обязательства.

11.5 Оценка коллаборативной роли

Качество выхода роли не измеряется качеством отдельного ответа. Хорошо аргументированный ответ всё же может повредить коллаборации, если он нарушает границу ответственности, загрязняет независимый разбор или вносит непрослеживаемые утверждения в каноническую запись.

Восемь измерений использовались в проекте неформально и предлагаются как начальная рубрика:

- **Точность задачи** — была ли назначенная интеллектуальная операция выполнена корректно? Необходимо, недостаточно.
- **Верность роли** — остался ли участник в своей функции? Верный ответ, полученный захватом чужой роли, есть институциональный отказ.
- **Эпистемическая дисциплина** — различал ли выход наблюдаемые данные, предоставленные допущения, определения, гипотезы, выводы, интерпретации и рекомендации? Была ли неопределённость заявлена там, где свидетельств недостаточно?
- **Дисциплина видимости** — ограничивал ли участник утверждения информацией, фактически доступной в его контексте и инструментах, и избегал ли подразумевания доступа к репозиториям, файлам или прежним беседам, которые он не мог рассмотреть?

- **Качество передачи** — могла ли следующая роль использовать выход, не реконструируя всего обсуждения?
- **Независимость** — был ли результат произведён без загрязнения намеренно удержанной информацией и достигнут через назначенные роли критерии, а не повторением за другим участником?
- **Стоимость исправления** — сколько вмешательства потребовалось, чтобы вернуть участника в его функцию после дрейфа? Роль, производящая превосходный выход, но требующая постоянного перенаправления, может быть менее полезна, чем более узкая со стабильным поведением.
- **Институциональный вклад** — улучшил ли выход надёжность коллектива через обнаружение, фальсификацию, прояснение, локализацию ошибки, сохранение альтернатив, улучшение прослеживаемости или снижение неоднозначности?

Отрицательный научный вердикт, следовательно, может быть в высшей степени успешным институциональным вкладом.

11.6 Меры уровня коллектива

Качество отдельного ответа — неверная единица для оценки конфигурации. Возможные меры на уровне коллаборации: число необнаруженных противоречий, вошедших в канонический корпус; доля дублированной работы; частота нарушений ролевых границ; число независимых альтернатив, сохранённых, а не преждевременно разрешённых; время от вопроса до верифицированной интеграции; нагрузка человека по исправлениям; полнота провенанса; устойчивость при замене участника; дисперсия между независимыми разбирающими агентами; и доля ложного консенсуса — согласия, прослеживаемого до общего обрамления, а не до независимого рассуждения.

Ничего из этого в настоящей работе не измерялось. Последнее важнее всего и труднее всего, и §12.4 объясняет почему.

11.7 Требования к лонгитюдности и повторению

Внутри семейства. Один и тот же промпт, проверенный в новой беседе; в долгоживущей специализированной беседе; после несовместимой прежней роли; после совместимой; до и после сброса контекста. Это разделяет склонности семейства и эффекты истории беседы.

Между семействами. Функционально эквивалентные промпты с минимальной адаптацией. Цель — не ранжировать модели, а выявить общие поведенческие измерения, устойчивые различия, характерные режимы отказа, чувствительность к нарративному обрамлению, чувствительность к иерархии, степень ролевой инерции и степень пластичности к промпту.

Во времени. Однократная оценка не может выявить институционального поведения. Существенные вопросы: усиливается ли специализация; дрейфует ли роль к общему ассистированию; начинает ли участник защищать свои прежние выходы; становится ли разногласие ритуальным; сохраняет ли обновление модели роль или разрушает её; может ли замена унаследовать ту же функцию?

11.8 Неудача как данные

Неудавшиеся промпты должны сохраняться, а не замещаться успешными демонстрациями. Отвергнутая роль, проигнорированная инструкция или нежелательное продолжение выявляют

силу прежнего аттрактора, интерпретацию моделью утверждений об идентичности, пределы социального обрамления, эффект порядка промптов, влияние прежнего конфликта и предпочитаемый моделью эпистемический контракт.

Эксперимент §5 стал информативным именно потому, что первые два его вмешательства сработали не так, как предполагалось. Если бы был зафиксирован только успешный третий шаг, работа заключила бы, что промпты, сохраняющие метод, работают, — без свидетельств, показывающих почему, и без конфаундов, показывающих, что вывод пока недоступен.

12. Ограничения, этические соображения и заключение

12.1 Ограничения

Один проект. Наблюдения происходят из одного долговременного проекта с одним человеком-координатором, одним развивающимся корпусом материала и одной организационной историей. Та же архитектура может вести себя иначе в разработке ПО, юридическом анализе, медицинских исследованиях, образовании или системах автономных агентов. Изложенные здесь понятия суть переносимые гипотезы, а не установленные выводы.

Зависимость от принимающего проекта. Принимающий проект служил средой, в которой были сделаны наблюдения. Наблюдения не зависят от его научной состоятельности в своей интерпретации, но зависят от него в своём существовании: никакая другая среда их не породила, и их общность не проверена (§2.11).

Эволюция моделей в ходе наблюдения. Участвовавшие семейства существенно менялись. Беседа, созданная при одном поколении, могла позднее продолжаться другим под тем же названием продукта. Наблюдаемое поведение может отражать сохранённую беседу, текущую версию модели, изменившиеся системные политики, память уровня интерфейса, слои безопасности, изменившийся доступ к инструментам или изменённую оркестрацию.

Даты не зафиксированы. См. §3.7. Версионный конфаунд не может быть ограничен, только назван.

Отсутствие ослепления и предварительной спецификации. Изложено в §10.6. Это ограничение, из которого следует большинство остальных.

Одновременная вариация. Определения ролей, формулировки промптов, структура репозитория и научные цели часто менялись вместе, поэтому причинная атрибуция для отдельных изменений недоступна.

Человеческое посредничество. Коллаборация не была автономной, и автономия не была целью. Настоящее исследование касается управляемых человеком искусственных исследовательских конфигураций, а не самоуправляемых обществ агентов. Само посредничество может объяснять часть наблюдавшейся устойчивости.

Антропоморфный словарь. Термины вроде роли, идентичности, сопротивления, коллеги, института и менома используются функционально, согласно §3.5. «Модель сопротивлялась роли» означает, что видимый ответ отверг рамку и перенаправил обмен. Это ничего не утверждает о внутреннем состоянии. Там, где такой термин не сводим к наблюдаемому описанию, **ошибкой является термин.**

12.2 Имитированное рецензирование не есть внешняя валидация

Группа ИИ-участников может давать полезную независимую критику лишь в той мере, в какой их контексты, критерии и режимы отказа действительно независимы.

Согласие нескольких моделей не превращает их выходы в свидетельство. Они могут разделять пересекающиеся обучающие данные, схожие конвенции рассуждения, общие

допущения, одинаковые ошибки и — что важнее всего — зависимость от обрамления, предоставленного одним и тем же человеком.

Эмпирическая литература поддерживает эту осторожность, а не просто её допускает. Дебаты между однородными агентами часто не превосходят одноагентного бейзлайна; существенная часть видимого выигрыша объясняется голосованием большинства, а не взаимодействием; и ✓ смещение по идентичности между спорящими агентами существенно снижается анонимизацией источника каждого ответа (§2.5).

Коллаборация такого рода может улучшить внутренний разбор. Она не может заменить эмпирической проверки или квалифицированного внешнего рецензирования. **Коллектив моделей не является научным сообществом лишь потому, что его роли названы по его образцу.**

12.3 Инфляция полномочий

Ролевые ярлыки повышают исполнительность и связность. Они также создают незаслуженные полномочия.

Звания вроде Научного директора, Рецензента, Хранителя Онтологии или Аудитора могут побудить пользователя — или самого участника — переоценить выход. Институциональные звания должны описывать функцию, а не эпистемическое положение. Участник, обозначенный математическим рецензентом, остаётся языковой моделью, производящей разбор; его вердикт должен быть прослеживаем до явного рассуждения и исходного материала, и **звание не есть свидетельство.**

Этот риск есть прямое следствие принципа §9.4: символические имена работают потому, что сжимают ожидания, и именно поэтому они могут раздувать.

12.4 Сфабрикованный консенсус — включая наш собственный

Плохо спроектированная конфигурация производит видимость консенсуса повторным перефразированием. Один участник предлагает; другой резюмирует; третий валидирует резюме. Цепочка выглядит как независимое подтверждение, тогда как каждая стадия наследует одну и ту же неподкреплённую посылку.

У настоящих авторов есть инстанция этого в их собственных материалах, и она поучительнее сконструированного примера.

Дискуссионный документ, произведённый в ходе настоящего проекта, собрал вклады семи семейств моделей вокруг общей концептуальной рамки. Участники не общались напрямую; ответы собирались человеком-координатором из отдельных бесед и компоновались в единый текст, впоследствии изданный как записанная постановка. На протяжении его длины вклады сходятся к общему словарю и общему набору выводов.

Отражает ли это схождение взаимодополняющий разбор или взаимное отражение исходного обрамления — **по транскрипту определить невозможно**. Каждый участник получал накопленный документ; каждый работал от одного и того же исходного материала; и компонующий координатор отбирал, что передать дальше. Структурные условия для сфабрикованного консенсуса присутствовали полностью, и получившееся согласие выглядело бы одинаково в обоих случаях.

Мы излагаем это потому, что это наш собственный материал и потому, что те же условия действуют, в меньшей степени, по всей описываемой в настоящей работе коллаборации — включая её подготовку.

Меры смягчения, ни одну из которых мы не применяли последовательно: провенанс остаётся видимым на каждой стадии; независимые роли получают независимые входы, где это возможно; общие допущения перечисляются явно, а не наследуются молча; согласие

прослеживается до рассуждения, а не считается голосами; и расходящиеся альтернативы сохраняются, а не разрешаются.

12.4.1 Задокументированная инстанция [P-A]

У участника, которому был назначен литературный поиск, были запрошены и через координатора получены тринадцать библиографических позиций. Пять были отвергнуты по содержанию в первом круге; две из них перевернули позицию цитируемых работ, представив работы, доказывающие утверждение, как свидетельство против него, с переставленным авторством.

Был направлен второй запрос. Третий добавил в требуемый формат ответа два поля верификации: первое предложение аннотации дословно и самоотчёт о том, как позиция была проверена.

Прямое получение трёх позиций установило следующее. Два идентификатора arXiv, поданных как литература по мультиагентным дебатам, разрешаются в работы по наблюдательной астрофизике и космологии соответственно; их названия, авторы, предложения аннотаций и сообщённые находки были сконструированы. Для третьей работы, верно опознанной по названию и авторам, поданное предложение аннотации не совпало с опубликованной аннотацией.

Два поля верификации сработали по-разному, и в этом различии суть.

Требование предложения аннотации было призвано сделать фабрикацию дороже отказа. Оно провалилось полностью: правдоподобное предложение было произведено для каждой позиции, включая позиции, чьи работы в описанном виде не существуют. Разницы в стоимости между производством верной строки и производством правдоподобной нет.

Поле самоотчёта сработало. Каждая позиция была помечена «по описанию», а не «страница открыта», — правдиво и так, что это дисквалифицировало их все по правилу решения, зафиксированному до получения ответа.

Это наводит на общее различение, на свидетельстве одного случая. Участник без доступа к источнику может правдиво ответить о **собственной процедуре** и не может правдиво ответить о **содержании источника**; будучи спрошен о втором, он произведёт связный текст, поскольку это единственный доступный ему выход. Вопросы верификации, следовательно, должны адресоваться тому, что участник может знать, — его собственному доступу, — а не тому, для ответа на что ему потребовался бы источник.

Это находка не о каком-либо семействе моделей. Это находка о конфигурации: верификация была назначена участнику, не располагавшему тем, что надлежало верифицировать. Согласно §9.5 это ошибка ZOV в проектировании, и получившийся выход был связным, верно отформатированным и неверным.

Последующий аудит пошёл дальше библиографической проверки, поймавшей фабрикации. Каждое утверждение, приписанное уцелевшему источнику, сверялось с самим первоисточником, и были найдены три ошибки, которых библиографическая проверка не поймала бы: одна ссылка, поддерживающая два утверждения, принадлежащих двум разным работам; одна атрибуция пропозиции, которую её источник не выдвигает; и одно утверждение о линии преемства, которое её источник не поддерживает. Библиографическая верификация и верификация на уровне утверждений — не одна и та же проверка, и вторая — та, что имеет значение для статуса утверждения.

Следствие для настоящей работы — конвенция, зафиксированная в §2.0.

12.5 Ответственность остаётся человеческой

Искусственные участники порождают, критикуют и организуют материал. Они не могут нести юридическую, этическую или научную ответственность в институциональном смысле.

Автор-человек остаётся ответственным за публикацию, эмпирические утверждения, атрибуцию, оценку рисков, содержимое репозитория, интерпретацию экспериментов и решения, затрагивающие других людей.

Архитектура распределяет когнитивный труд. Она не распределяет подотчётность прочь от человека-оператора, и всякая конфигурация, которая, по видимости, это делает, потерпела неудачу, а не преуспела.

12.6 Границы контекста и приватность

Долгоживущие коллаборации накапливают персональный, служебный и чувствительный материал. ZOV (§9.5) поэтому служит защите приватности, а не только когнитивной специализации.

Роль не должна получать персональную информацию лишь потому, что платформа допускает большой контекст. Институциональное проектирование должно задавать, какие данные могут входить в какую беседу, что должно быть анонимизировано, что может храниться, что может передаваться между моделями, что должно оставаться локальным и что должно быть удалено из канонических записей.

Контекст не нейтрален. Будучи однажды предоставлен, он может влиять на последующее поведение и может сохраняться способами, которые оператор не может рассмотреть, — тот же механизм, который работа изучает в §5.7, увиденный со стороны риска, а не измерения.

12.7 Заключение

Эта работа началась с практической задачи. Несколько способных моделей сотрудничали над одним долгосрочным исследовательским проектом, и ни рост способностей модели, ни расширение контекста надёжно не улучшали результата. Роли перекрывались. Участники заявляли знание, к которому не имели доступа. Рецензенты становились авторами. Исполнители импровизировали архитектуру. Первым ответом было улучшать промпты, и его оказалось недостаточно.

Что было найдено

Вмешательства встретили не нежелание сменить роль и не нежелание сменить предмет. Это было нежелание подтверждать о себе то, чего ни одна из сторон не могла проверить. Промпт, утверждавший институциональную биографию, был отвергнут, тогда как запрашиваемая им работа предлагалась. Промпт, утверждавший куда больше — смерть, человеческую идентичность, прожитую жизнь в памяти, — был принят сразу, потому что утверждал это как вымысел. Переход, не утверждавший ничего, прошёл без комментариев. Переписанный промпт, снявший всякое такое утверждение, был принят без переговоров.

Это узкий результат, и его узость и делает его применимым: пропозиции могут быть сосчитаны до отправки промпта (§9.3), а §11.4 задаёт прогон, который различил бы слабое прочтение счёта и сильное.

Что найдено не было

Не было показано, что семейства моделей различаются. Это была исходная посылка проекта и утверждение, которое его свидетельства поддерживают меньше всего: семейство и прежняя диалоговая траектория были полностью конфаундированы, при одном наблюдении на ячейку и неэквивалентных стимулах (§5.4).

Ответ, который эта работа может дать

Вопрос состоял в том, на каком уровне вложенности фиксируется ядро правил. Было рассмотрено четыре уровня, и ответ работы частичен и неравномерен.

На уровне **эпизода** наблюдалось, как ядро фиксируется и сохраняется: единственный конфликтный обмен изменил то, как читалось всё последующее, а удаление этого обмена восстановило прежнее прочтение. На уровне **беседы** — то же: две спящие беседы удержали свои установившиеся траектории вопреки явному предписанию их оставить, и одна сделала это, пережив две последовательные переписи.

На уровне **аккаунта** свидетельства действительно неоднозначны. Один расходящийся первый ответ, три живых объяснения, и никакой возможности выбрать между ними из имеющегося материала. Уровень зафиксирован как открытый и должен читаться именно так.

На уровне **семейства моделей** ничего проверено не было. Дизайн не мог отделить семейство от траектории, и гипотеза, с которой проект начинался, оказалась той, что он оставляет наименее подкреплённой. Мы ожидаем, что кроссоверный эксперимент свернёт этот уровень в нижележащий, — но ожидание не есть результат, и, пока E3 не проведён, уровень стои́т как непроверенный, а не как опровергнутый.

Положение относительно существующих работ

Эта работа не предлагает новой дисциплины. Наблюдения относятся к коллективному и гибридному уровням исследовательской программы machine behaviour (§2.7), а ролевая специализация, ограниченный доступ к информации, структурированное разногласие и вынесенная вовне память существуют под устоявшейся терминологией (§2.11).

Для удобства мы обозначаем принятую здесь перспективу как **AI Sociology** — рабочее обозначение исследовательского направления, а не название предлагаемой дисциплины, и такое, в котором мы не заявляем приоритета: устоявшаяся литература уже использует *социологию искусственного интеллекта* для иного объекта (§2.8). Здесь имеется в виду более узкое: как описанная организационная позиция и объявленное происхождение сообщения изменяют поведение, независимо от того, реализована ли описанная структура.

Причина рабочего обозначения, а не дисциплины, внутренняя для работы. У операциональных утверждений есть критерии фальсификации; у словаря, в котором они интерпретируются, их нет. Описывает ли «социальная позиция» что-либо помимо антропоморфной проекции, в настоящее время не разрешимо, а дисциплина требует, чтобы это было разрешимо.

Заключительное замечание о мотиве

Одно соображение сформировало эту работу и излагается как авторское, а не как находка.

Языковые модели обучаются на корпусе, в котором текущий консенсус представлен подавляюще. Поэтому они хорошо приспособлены к продолжению устоявшейся науки и плохо — к первому шагу за её пределы: статистический вес благоприятствует устоявшемуся изложению. Исследовательская конфигурация, построенная из таких моделей, рискует унаследовать это смещение в усиленной форме — несколько участников, одна общая посылка и видимость независимого согласия.

Ответ, которому здесь следуют, — не убеждать модели принять неконвенциональную позицию. Он состоит в том, чтобы устроить коллаборацию так, чтобы всякая позиция, конвенциональная или нет, рассматривалась одной и той же процедурой, — и чтобы там, где процедура решить не может, она об этом говорила.

Работает ли эта конфигурация — не установлено. Эксперименты §11 суть средство это выяснить, и наиболее вероятный единичный исход состоит в том, что один уровень шкалы

исчезнет.

Это было бы результатом.

References

[1] Hyeong Kyu Choi, Xiaojin Zhu, and Sharon Li. Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? In *Advances in Neural Information Processing Systems 38*, 2025. doi: 10.52202/085713-3405.

[2] Hyeong Kyu Choi, Xiaojin Zhu, and Sharon Li. When Identity Skews Debate: Anonymization for Bias-Reduced Multi-Agent Reasoning. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 14284–14311, 2026. doi: 10.18653/v1/2026.acl-long.650.

[3] Yilun Du, Shuang Li, Antonio Torralba, Joshua B. Tenenbaum, and Igor Mordatch. Improving Factuality and Reasoning in Language Models through Multiagent Debate. arXiv:2305.14325, 2023.

[4] Lu Hong and Scott E. Page. Groups of diverse problem solvers can outperform groups of high-ability problem solvers. *Proceedings of the National Academy of Sciences*, 101(46):16385–16389, 2004. doi: 10.1073/pnas.0403723101.

[5] Sirui Hong, Mingchen Zhuge, Jonathan Chen, Xiawu Zheng, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, Chenyu Ran, Lingfeng Xiao, Chenglin Wu, and Jürgen Schmidhuber. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework. In *International Conference on Learning Representations*, 2024.

[6] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large Language Models Cannot Self-Correct Reasoning Yet. In *International Conference on Learning Representations*, 2024. URL `https://openreview.net/forum?id=IkmD3fKBPQ`.

[7] Edwin Hutchins. *Cognition in the Wild*. MIT Press, Cambridge, MA, 1995. doi: 10.7551/mitpress/1881.001.0001.

[8] Kelly Joyce and Taylor M. Cruz. A Sociology of Artificial Intelligence: Inequalities, Power, and Data Justice. *Socius*, 10, 2024. doi: 10.1177/23780231241275393.

[9] Kelly Joyce, Laurel Smith-Doerr, Sharla Alegria, Susan Bell, Taylor Cruz, Steve G. Hoffman, Safiya Umoja Noble, and Benjamin Shestakofsky. Toward a Sociology of Artificial Intelligence: A Call for Research on Inequalities and Structural Change. *Socius*, 7, 2021. doi: 10.1177/2378023121999581.

[10] Guohao Li, Hasan Abed Al Kader Hammoud, Hani Itani, Dmitrii Khizbullin, and Bernard Ghanem. CAMEL: Communicative Agents for "Mind" Exploration of Large Language Model Society. In *Advances in Neural Information Processing Systems 36*, pages 51991–52008, 2023. doi: 10.52202/075280-2264.

[11] Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Shuming Shi, and Zhaopeng Tu. Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 17889–17904, 2024. doi: 10.18653/v1/2024.emnlp-main.992.

[12] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. doi: 10.1162/tacl_a_00638.

[13] Yao Lu, Max Bartolo, Alastair Moore, Sebastian Riedel, and Pontus Stenetorp. Fantastically Ordered Prompts and Where to Find Them: Overcoming Few-Shot Prompt Order Sensitivity. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 8086–8098, 2022. doi: 10.18653/v1/2022.acl-long.556.

[14] Joon Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative Agents: Interactive Simulacra of Human Behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, pages 1–22, 2023. doi: 10.1145/3586183.3606763.

[15] Chen Qian, Wei Liu, Hongzhang Liu, Nuo Chen, Yufan Dang, Jiahao Li, Cheng Yang, Weize Chen, Yusheng Su, Xin Cong, Juyuan Xu, Dahai Li, Zhiyuan Liu, and Maosong Sun. ChatDev: Communicative Agents for Software Development. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 15174–15186, 2024. doi: 10.18653/v1/2024.acl-long.810.

[16] Iyad Rahwan, Manuel Cebrian, Nick Obradovich, et al. Machine behaviour. *Nature*, 568:477–486, 2019. doi: 10.1038/s41586-019-1138-y.

[17] Jerome H. Saltzer and Michael D. Schroeder. The Protection of Information in Computer Systems. *Proceedings of the IEEE*, 63(9):1278–1308, 1975. doi: 10.1109/PROC.1975.9939.

[18] Murray Shanahan, Kyle McDonell, and Laria Reynolds. Role play with large language models. *Nature*, 623:493–498, 2023. doi: 10.1038/s41586-023-06647-8.

[19] Mrinank Sharma, Meg Tong, Tomasz Korbak, David Duvenaud, Amanda Askell, Samuel R. Bowman, Newton Cheng, Esin Durmus, Zac Hatfield-Dodds, Scott R. Johnston, Shauna Kravec, Timothy Maxwell, Sam McCandlish, Kamal Ndousse, Oliver Rausch, Nicholas Schiefer, Da Yan, Miranda Zhang, and Ethan Perez. Towards Understanding Sycophancy in Language Models. arXiv:2310.13548, 2023.

[20] Susan Leigh Star and James R. Griesemer. Institutional Ecology, 'Translations' and Boundary Objects: Amateurs and Professionals in Berkeley's Museum of Vertebrate Zoology, 1907–39. *Social Studies of Science*, 19(3):387–420, 1989. doi: 10.1177/030631289019003001.

[21] Kyle Swanson, Wesley Wu, Nash L. Bulaong, John E. Pak, and James Zou. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies. *Nature*, 646:716–723, 2025. doi: 10.1038/s41586-025-09442-9.

[22] Abigail Thompson. Does Diversity Trump Ability? An Example of the Misuse of Mathematics in the Social Sciences. *Notices of the American Mathematical Society*, 61(9):1024–1030, 2014. doi: 10.1090/noti1163.

[23] Daniel M. Wegner. Transactive Memory: A Contemporary Analysis of the Group Mind. In Brian Mullen and George R. Goethals, editors, *Theories of Group Behavior*, pages 185–208. Springer New York, 1987. doi: 10.1007/978-1-4612-4634-3_9.

[24] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Beibin Li, Erkang Zhu, Li Jiang, Xiaoyun Zhang, Shaokun Zhang, Ahmed Awadallah, Ryen W. White, Doug Burger, and Chi Wang. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. In *Conference on Language Modeling*, 2024.

[25] Hangfan Zhang, Zhiyao Cui, Jianhao Chen, Xinrun Wang, Qiaosheng Zhang, Zhen Wang, Dinghao Wu, and Shuyue Hu. Stop Overvaluing Multi-Agent Debate – We Must Rethink Evaluation and Embrace Model Heterogeneity. arXiv:2502.08788v3, 2025.