Beyond Prompt Engineering: Role Reconfiguration in Long-Lived AI Conversations

V. Krasnianskyi

Abstract

This paper reports a field study of long-lived, persistently specialized language-model conversations used in a human-directed research collaboration, with one designed role-reconfiguration intervention embedded in the record. Two dormant conversations from different model families were each subjected to three sequential attempts to change professional function. The preserved responses support a narrow pattern: resistance tracked prompts that required the recipient to affirm unverifiable propositions about its own identity, history, or institutional relationships, rather than the magnitude of role or domain change. A rewritten prompt that removed such self-claims was accepted without negotiation. Ancillary observations suggest persistent effects at the episode and conversation levels, while account-level effects remain open and model-family effects are untested because family and trajectory were confounded. We distinguish represented social position and represented social source from implemented multi-agent interaction, propose a count of unverifiable self-claims as an operational prompt variable, and describe conversational branch reset as a control procedure. The evidence is limited to one project, one human operator, one observation per condition, no blinding, and no replication. The paper therefore presents a testable research programme and design rules rather than evidence that any collaborative architecture outperforms alternatives.

Amsterdam, July 2026

Contents

1. Introduction **9**
1.1 How this started . . . 9
1.2 What stopped working . . . 9
1.3 What kind of paper this is . . . 10
1.4 The object of study . . . 10
1.5 What the evidence supports . . . 10
1.6 The organizing question . . . 11
1.7 What this paper does not claim . . . 11
1.8 What is offered . . . 11
1.9 Why publish at this stage . . . 12
1.10 Structure . . . 12

2. Related Work **12**
2.0 Verification status of this section . . . 12
2.1 Multi-agent LLM systems with role specialization . . . 13
2.2 Persona, role-play, and identity claims . . . 13
2.3 Context effects: order, position, and accommodation . . . 13
2.4 Externalized memory . . . 13
2.5 Debate, diversity, and the limits of aggregated agreement . . . 14
2.6 Organizational design and information boundaries . . . 14
2.7 Machine behaviour: the containing programme . . . 15
2.8 Sociology of AI: an adjacent field with a different object . . . 15
2.9 Represented structure versus implemented interaction . . . 15
2.10 Platform persistence mechanisms . . . 16
2.11 Positioning and claimed contribution . . . 16

3. Evidential Status of Claims **17**
3.1 The four labels . . . 17
3.2 The complete evidence base . . . 18
3.3 Known weaknesses of the [R] class . . . 18
3.4 What the labels do not do . . . 19
3.5 Terminology of models and of anthropomorphic description . . . 19
3.6 Disclosure: conflict of position . . . 19
3.7 Dates . . . 19
3.8 The label ”AI Sociology” . . . 20

4. Conceptual Framework **20**
4.1 Origin: the code-executor incident . . . 20
4.2 Rule cores, menoms, and what they determine . . . 21
4.3 The nesting question, and two scales . . . 23
4.4 Two origins, one mechanism . . . 23
4.5 Boundaries: ZOR, ZOV, and the represented case . . . 24
4.6 What is required for a complete role specification . . . 26

5. The Role-Reconfiguration Experiment and Associated Observations **26**
5.1 Purpose, participants, and prior conversational trajectories . . . 26
5.2 Procedure: three sequential interventions . . . 27
5.3 Results . . . 28
5.4 Confounds and what cannot be concluded . . . 29

5.5 Ancillary observation: relayed attributed influence **[P-A]** . . . 33
5.6 Near-control: domain transition without a new role assignment **[P-A]** . . . 34
5.7 Ancillary observation: account-scoped divergence **[P-A]** . . . 35
5.8 Frame type: identity claims offered as fiction versus as fact **[P-A]** . . . 36
5.9 What Section 5 establishes . . . 37

6. Derived Concepts **38**
6.1 Context imprinting — episode scope **[P]** . . . 38
6.2 Role inertia — conversation scope **[P]** . . . 39
6.3 Priority drift **[H]** . . . 40
6.4 Account-scoped persistence — account scope **[P-A]**, unresolved . . . 41
6.5 Family-level priors — family scope **[H]** . . . 41
6.6 Intervention attaches at the level where the core is fixed . . . 42
6.7 What would refute this framework . . . 42

7. Retrospective Practitioner Observations **43**
7.1 How this section should be read . . . 43
7.2 Specialization displaced capability as the operative variable . . . 43
7.3 Context behaved more like attention than like memory . . . 43
7.4 Capability and scope expansion . . . 43
7.5 Blind spots were distributed rather than eliminated . . . 44
7.6 Second-order verification . . . 44
7.7 Organizational memory . . . 44
7.8 Persistence differs by platform, and losses are real . . . 45
7.9 Role–model fit . . . 45
7.10 What none of this establishes . . . 45

8. The Structural Unit: A Generative Pair and an Integrator **46**
8.1 What the project's earlier document stated . . . 46
8.2 Revision of this paper's earlier formulation . . . 46
8.3 Why a pair, and why a pair alone is insufficient . . . 47
8.5 Why the integrator must not argue . . . 47
8.6 The implemented example . . . 47
8.7 Nesting and perspective . . . 47
8.8 Status, and what would refute this . . . 48
8.9 Two axes of heterogeneity **[H]** . . . 48
8.10 Editor's note on the preparation of this paper **[P-A]** . . . 49
8.11 Constructs, not participants: the Kelly apparatus **[H]** . . . 50

9. Design Principles for Role-Compatible Prompts **51**
9.1 The design procedure . . . 51
9.2 Begin from the existing attractor . . . 52
9.3 The count rule . . . 52
9.4 Symbolic names and literal claims . . . 53
9.5 Specifying ZOR and ZOV . . . 53
9.6 Controlled blindness . . . 54
9.7 Local interfaces, not global maps . . . 54
9.8 Designing disagreement around criteria . . . 54
9.9 Output as institutional handoff . . . 55
9.10 Self-restatement and checkpoints . . . 55
9.11 The role constitution . . . 55

10. The Human Coordinator **56**
10.1 The position . . . 56
10.2 Direction without delegated authorship . . . 56
10.3 Routing as a selective information membrane . . . 56
10.4 Detection of role drift . . . 56
10.5 Conversational branching as a methodological instrument . . . 57
10.6 Sole global observer — and principal confound . . . 57
10.7 What the position became . . . 58

11. Evaluation, Reproducibility, and Proposed Experiments **58**
11.1 Why this section specifies corrections rather than refinements . . . 58
11.2 Minimum reporting requirements . . . 58
11.3 Pre-specification and blind classification . . . 59
11.4 The experiments . . . 60
11.5 Evaluating a collaborative role . . . 64
11.6 Collective-level measures . . . 65
11.7 Longitudinal and repetition requirements . . . 65
11.8 Failure as data . . . 65

12. Limitations, Ethical Considerations, and Conclusion **65**
12.1 Limitations . . . 65
12.2 Simulated peer review is not external validation . . . 66
12.3 Authority inflation . . . 66
12.4 Manufactured consensus — including our own . . . 67
12.5 Responsibility remains human . . . 68
12.6 Context boundaries and privacy . . . 68
12.7 Conclusion . . . 68

Appendix A. Primary evidence — preservation status **71**

1. Введение **72**
1.1 Как это началось . . . 72
1.2 Что перестало работать . . . 72
1.3 Что это за работа . . . 73
1.4 Предмет изучения . . . 73
1.5 Что поддерживается свидетельствами . . . 74
1.6 Организующий вопрос . . . 74
1.7 На что эта работа не претендует . . . 75
1.8 Что предлагается . . . 75
1.9 Почему публиковать на этой стадии . . . 75
1.10 Структура . . . 75

2. Предшествующие работы **76**
2.0 Статус верификации в этом разделе . . . 76
2.1 Мультиагентные LLM-системы с ролевой специализацией . . . 76
2.2 Персона, ролевая игра и утверждения об идентичности . . . 76
2.3 Контекстные эффекты: порядок, позиция и подстройка . . . 77
2.4 Вынесенная вовне память . . . 77
2.5 Дебаты, разнообразие и пределы агрегированного согласия . . . 77
2.6 Организационное проектирование и информационные границы . . . 78
2.7 Machine behaviour: объемлющая программа . . . 78

2.8 Социология ИИ: смежная область с другим объектом . . . 79
2.9 Представленная структура против реализованного взаимодействия . . . 79
2.10 Платформенные механизмы персистентности . . . 80
2.11 Позиционирование и заявляемый вклад . . . 80

3. Доказательный статус утверждений 81
3.1 Четыре метки . . . 81
3.2 Полная доказательная база . . . 82
3.3 Известные слабости класса [R] . . . 82
3.4 Чего метки не делают . . . 83
3.5 Терминология моделей и антропоморфного описания . . . 83
3.6 Раскрытие: конфликт позиции . . . 83
3.7 Даты . . . 84
3.8 Обозначение «AI Sociology» . . . 84

4. Концептуальная рамка 84
4.1 Происхождение: инцидент с исполнителем кода . . . 84
4.2 Ядра правил, меномы и то, что они определяют . . . 85
4.3 Вопрос о вложенности и две шкалы . . . 88
4.4 Два происхождения, один механизм . . . 88
4.5 Границы: ZOR, ZOV и представленный случай . . . 89
4.6 Что требуется для полной спецификации роли . . . 91

5. Эксперимент по переконфигурации роли и сопутствующие наблюдения 91
5.1 Цель, участники и прежние диалоговые траектории . . . 91
5.2 Процедура: три последовательных вмешательства . . . 92
5.3 Результаты . . . 93
5.4 Конфаунды и то, что не может быть заключено . . . 95
5.5 Побочное наблюдение: ретранслированное атрибутированное влияние **[P-A]** . . . 99
5.6 Near-control: смена предметной области без нового назначения роли **[P-A]** . . . 100
5.7 Побочное наблюдение: расхождение на уровне аккаунта **[P-A]** . . . 101
5.8 Тип рамки: утверждения об идентичности, предъявленные как вымысел и как факт **[P-A]** . . . 102
5.9 Что устанавливает Раздел 5 . . . 103

6. Производные понятия 104
6.1 Контекстный импринтинг — область эпизода **[P]** . . . 104
6.2 Ролевая инерция — область беседы **[P]** . . . 105
6.3 Приоритетный дрейф **[H]** . . . 106
6.4 Персистентность уровня аккаунта — область аккаунта **[P-A]**, не разрешено . . . 108
6.5 Приоритеты уровня семейства — область семейства **[H]** . . . 108
6.6 Вмешательство прикрепляется к уровню, на котором ядро зафиксировано . . . 108
6.7 Что опровергло бы эту рамку . . . 109

7. Ретроспективные наблюдения практика 109
7.1 Как следует читать этот раздел . . . 109
7.2 Специализация вытеснила способность как действующую переменную . . . 110
7.3 Контекст вёл себя скорее как внимание, чем как память . . . 110
7.4 Способность и расширение области действия . . . 110
7.5 Слепые зоны были распределены, а не устранены . . . 111
7.6 Верификация второго порядка . . . 111

7.7 Организационная память . . . 111
7.8 Персистентность различается по платформам, и потери реальны . . . 112
7.9 Соответствие роли и модели . . . 112
7.10 Чего всё это не устанавливает . . . 113

8. Структурная единица: порождающая пара и интегратор 113
8.1 Что гласил ранний документ проекта . . . 113
8.2 Пересмотр прежней формулировки настоящей работы . . . 113
8.3 Почему пара и почему одной пары недостаточно . . . 114
8.5 Почему интегратор не должен спорить . . . 114
8.6 Реализованный пример . . . 114
8.7 Вложенность и перспектива . . . 115
8.8 Статус и то, что это опровергло бы . . . 115
8.9 Две оси гетерогенности **[H]** . . . 116
8.10 Примечание Редактора о подготовке настоящей работы **[P-A]** . . . 117
8.11 Конструкты, а не участники: аппарат Келли **[H]** . . . 118

9. Принципы проектирования ролесовместимых промптов 119
9.1 Процедура проектирования . . . 119
9.2 Начинать от существующего аттрактора . . . 119
9.3 Счётное правило . . . 120
9.4 Символические имена и буквальные утверждения . . . 121
9.5 Задание ZOR и ZOV . . . 121
9.6 Контролируемая слепота . . . 122
9.7 Локальные интерфейсы, а не глобальные карты . . . 122
9.8 Проектирование разногласия вокруг критериев . . . 122
9.9 Выход как институциональная передача . . . 123
9.10 Самоизложение и контрольные точки . . . 123
9.11 Конституция роли . . . 123

10. Человек-координатор 124
10.1 Позиция . . . 124
10.2 Направление без делегирования авторства . . . 124
10.3 Маршрутизация как избирательная информационная мембрана . . . 124
10.4 Обнаружение ролевого дрейфа . . . 124
10.5 Ветвление беседы как методологический инструмент . . . 125
10.6 Единственный глобальный наблюдатель — и главный конфаунд . . . 125
10.7 Чем эта позиция стала . . . 126

11. Оценка, воспроизводимость и предлагаемые эксперименты 126
11.1 Почему этот раздел задаёт исправления, а не уточнения . . . 126
11.2 Минимальные требования к отчётности . . . 126
11.3 Предварительная спецификация и слепая классификация . . . 127
11.4 Эксперименты . . . 128
11.5 Оценка коллаборативной роли . . . 133
11.6 Меры уровня коллектива . . . 134
11.7 Требования к лонгитюдности и повторению . . . 134
11.8 Неудача как данные . . . 134

12. Ограничения, этические соображения и заключение **134**
12.1 Ограничения . . . 134
12.2 Имитированное рецензирование не есть внешняя валидация . . . 135
12.3 Инфляция полномочий . . . 135
12.4 Сфабрикованный консенсус — включая наш собственный . . . 136
12.5 Ответственность остаётся человеческой . . . 137
12.6 Границы контекста и приватность . . . 137
12.7 Заключение . . . 138

1. Inleiding **140**
1.1 Hoe dit begon . . . 140
1.2 Wat ophield te werken . . . 140
1.3 Wat voor soort artikel dit is . . . 141
1.4 Het studieobject . . . 141
1.5 Wat de evidentie ondersteunt . . . 142
1.6 De ordenende vraag . . . 142
1.7 Wat dit artikel niet beweert . . . 143
1.8 Wat wordt aangeboden . . . 143
1.9 Waarom in dit stadium publiceren . . . 143
1.10 Opbouw . . . 143

2. Verwant werk **144**
2.0 Verificatiestatus van deze sectie . . . 144
2.1 Multi-agent-LLM-systemen met rolspecialisatie . . . 144
2.2 Persona, rollenspel en identiteitsclaims . . . 144
2.3 Contexteffecten: volgorde, positie en accommodatie . . . 145
2.4 Geëxternaliseerd geheugen . . . 145
2.5 Debat, diversiteit en de grenzen van geaggregeerde overeenstemming . . . 145
2.6 Organisatieontwerp en informatiegrenzen . . . 146
2.7 Machine behaviour: het omvattende programma . . . 146
2.8 Sociologie van AI: een aangrenzend vakgebied met een ander object . . . 146
2.9 Gerepresenteerde structuur versus geïmplementeerde interactie . . . 147
2.10 Persistentiemechanismen van platforms . . . 147
2.11 Positionering en geclaimde bijdrage . . . 148

3. Evidentiestatus van de beweringen **149**
3.1 De vier labels . . . 149
3.2 De volledige evidentiebasis . . . 149
3.3 Bekende zwaktes van de [R]-klasse . . . 150
3.4 Wat de labels niet doen . . . 151
3.5 Terminologie van modellen en van antropomorfe beschrijving . . . 151
3.6 Openbaarmaking: belangenpositie . . . 151
3.7 Datums . . . 151
3.8 Het label ”AI Sociology” . . . 152

4. Conceptueel kader **152**
4.1 Oorsprong: het incident met de code-uitvoerder . . . 152
4.2 Rule cores, menomen en wat zij bepalen . . . 153
4.3 De nestingsvraag en twee schalen . . . 155
4.4 Twee oorsprongen, één mechanisme . . . 156
4.5 Grenzen: ZOR, ZOV en het gerepresenteerde geval . . . 156

4.6 Wat vereist is voor een volledige rolspecificatie 158

5. Het experiment met rolherconfiguratie en bijbehorende waarnemingen 159
5.1 Doel, deelnemers en eerdere gesprekstrajecten 159
5.2 Procedure: drie opeenvolgende interventies 159
5.3 Resultaten 161
5.4 Confounds en wat niet geconcludeerd kan worden 162
5.5 Nevenwaarneming: doorgegeven toegeschreven invloed **[P-A]** 166
5.6 Bijna-controle: domeinovergang zonder nieuwe roltoewijzing **[P-A]** 167
5.7 Nevenwaarneming: divergentie op accountniveau **[P-A]** 168
5.8 Kadertype: identiteitsclaims aangeboden als fictie versus als feit **[P-A]** 169
5.9 Wat Sectie 5 vaststelt 171

6. Afgeleide begrippen 171
6.1 Context imprinting — reikwijdte van de episode **[P]** 171
6.2 Role inertia — reikwijdte van het gesprek **[P]** 172
6.3 Priority drift **[H]** 173
6.4 Account-scoped persistence — reikwijdte van het account **[P-A]**, onopgelost 174
6.5 Family-level priors — reikwijdte van de familie **[H]** 175
6.6 Een interventie grijpt aan op het niveau waar de core is vastgelegd 175
6.7 Wat dit kader zou weerleggen 176

7. Retrospectieve waarnemingen van de practicus 176
7.1 Hoe deze sectie gelezen moet worden 176
7.2 Specialisatie verdrong capaciteit als de werkzame variabele 176
7.3 Context gedroeg zich meer als aandacht dan als geheugen 177
7.4 Capaciteit en uitbreiding van reikwijdte 177
7.5 Blinde vlekken werden verdeeld in plaats van geëlimineerd 177
7.6 Verificatie van de tweede orde 178
7.7 Organisatiegeheugen 178
7.8 Persistentie verschilt per platform, en verliezen zijn reëel 178
7.9 Passing tussen rol en model 179
7.10 Wat dit alles niet vaststelt 179

8. De structurele eenheid: een genererend paar en een integrator 180
8.1 Wat het eerdere document van het project stelde 180
8.2 Herziening van de eerdere formulering van dit artikel 180
8.3 Waarom een paar, en waarom een paar alleen ontoereikend is 180
8.5 Waarom de integrator niet mag argumenteren 181
8.6 Het geïmplementeerde voorbeeld 181
8.7 Nesting en perspectief 181
8.8 Status, en wat dit zou weerleggen 182
8.9 Twee assen van heterogeniteit **[H]** 182
8.10 Noot van de redacteur over de voorbereiding van dit artikel **[P-A]** 183
8.11 Constructen, geen deelnemers: het apparaat van Kelly **[H]** 184

9. Ontwerpprincipes voor rolcompatibele prompts 185
9.1 De ontwerpprocedure 186
9.2 Begin bij de bestaande attractor 186
9.3 De telregel 186
9.4 Symbolische namen en letterlijke beweringen 187

9.5 ZOR en ZOV specificeren . . . 188
9.6 Gecontroleerde blindheid . . . 188
9.7 Lokale interfaces, geen globale kaarten . . . 188
9.8 Onenigheid ontwerpen rond criteria . . . 189
9.9 Uitvoer als institutionele overdracht . . . 189
9.10 Zelfherformulering en controlepunten . . . 189
9.11 De rolgrondwet . . . 190

10. De menselijke coördinator **190**
10.1 De positie . . . 190
10.2 Richting zonder gedelegeerd auteurschap . . . 190
10.3 Routering als selectief informatiemembraan . . . 191
10.4 Detectie van role drift . . . 191
10.5 Gespreksvertakking als methodologisch instrument . . . 191
10.6 Enige globale waarnemer — en voornaamste confound . . . 192
10.7 Wat de positie is geworden . . . 192

11. Evaluatie, reproduceerbaarheid en voorgestelde experimenten **193**
11.1 Waarom deze sectie correcties specificeert en geen verfijningen . . . 193
11.2 Minimale rapportage-eisen . . . 193
11.3 Vooraf specificeren en blind classificeren . . . 193
11.4 De experimenten . . . 195
11.5 Een collaboratieve rol evalueren . . . 199
11.6 Maten op collectief niveau . . . 200
11.7 Longitudinale en herhalingseisen . . . 200
11.8 Mislukking als data . . . 200

12. Beperkingen, ethische overwegingen en conclusie **201**
12.1 Beperkingen . . . 201
12.2 Gesimuleerde peer review is geen externe validatie . . . 201
12.3 Gezagsinflatie . . . 202
12.4 Gefabriceerde consensus — de onze incluis . . . 202
12.5 Verantwoordelijkheid blijft menselijk . . . 203
12.6 Contextgrenzen en privacy . . . 203
12.7 Conclusie . . . 204

References **206**

Author
V. Krasnianskyi (A'Tuin)
Author of the research programme and coordinator of the HONC project.
AI contributors
Manuscript development
ChatGPT — Prompter and Collaboration Architect
Claude — Manuscript Composer
Scientific editing
Claude — Scientific Editor
Editorial review
ChatGPT — Methodological Reviewer
Qwen — Ontology Reviewer
AI contributors are listed by function rather than as authors: authorship entails accountability that a language model cannot bear, and all final decisions were the Author's. Two of the five contributions were performed by the same model family that is the subject of several observations in this paper; that overlap is disclosed in §3.6.
Amsterdam, July 2026

1. Introduction

1.1 How this started

This work began as a physics project and became a methodology project by accident. The accident is the reason it is worth reporting.

The original task was to move a large body of theoretical material — books, working notes, unfinished derivations — into an open repository, using several language models in separate, persistently specialized conversations. The models were assistants. The subject was the theory.

The models made errors, and the errors were not the kind expected. They were rarely factual. They were organizational.

One improved a text when asked only to check it. Another completed an argument the author had deliberately left open. A third lost the project's context between sessions and reconstructed it wrongly, fluently. A fourth held so firmly to a role established months earlier that rewriting its instructions entirely failed to dislodge it.

Each of these outputs looked helpful in isolation. Their cost was visible only from a position that saw more than one participant at a time. At first they looked like ordinary friction. They turned out to be the subject.

The account of the project's early formulations in §1.1–§1.2 was written by the participant who produced them. Where those formulations were subsequently withdrawn, the withdrawal is stated in the section that supersedes them, and the reader may compare.

1.2 What stopped working

The standard response to inconsistent model behaviour is a better prompt: longer, more precise, with more examples and tighter constraints.

Past a certain point this stopped producing improvement. Not because the prompts were badly written, but because the limiting factor had moved somewhere the prompt did not reach. Newer models were adopted; context windows expanded and were filled. Individual responses improved. The output of the collaboration as a whole did not.

The incident that made this explicit had nothing to do with role-play or organizational design. An agent responsible for executing code worked largely by trial and error; one episode ended with the deletion of a working codebase together with its archives (§4.1). What changed the behaviour

afterwards was not a stricter instruction set. It was a short document redefining what kind of agent was acting — written by the agent itself, and re-read at the start of every session.

The conclusion drawn at the time was that **role matters more than the specific wording of the prompt**. That formulation requires qualification, since the document in question was itself a prompt; the qualification is in §4.1. What matters here is the chronology: the claim was formulated *before* the experiment reported in §5, and the experiment was designed to test it. It is a hypothesis that was tested, not a generalization extracted afterwards from a result.

1.3 What kind of paper this is

A field report with one designed intervention embedded in it.

The distinction is maintained throughout by the labelling scheme in §3. Every substantive claim is marked as one of: supported by documented protocol with preserved transcripts **[P]**; an ancillary observation preserved but recognized retrospectively, without a control **[P-A]**; a retrospective practitioner observation never recorded under protocol, counted, or blinded **[R]**; or a hypothesis proposed for future testing **[H]**.

The proportions are stated here rather than in a limitations section, because the length of what follows might otherwise suggest a broader base than exists.

The entire protocol-supported content consists of **one experiment**: a three-step role-reconfiguration intervention applied to two dormant conversations from two model families, conducted by one human operator inside one live research project, with one observation per condition and no replication. Four further observations were preserved but not designed. Everything else — the conceptual framework, the practitioner observations, the structural hypothesis, the design rules — is **[R]** or **[H]**.

The evaluation of the method that produced these observations is in §10.6, and it is not favourable: no evaluation was blinded, and outcome categories were in every case defined after the responses had been read.

1.4 The object of study

Existing multi-agent research constructs communication channels between models: outputs are routed programmatically and agents observe each other's products. The work reported here concerns a different condition, in which the organizational structure existed **only as text** — colleagues, councils and institutional positions described to models in prompts and never implemented as channels.

What varied in such a setting was not the structure but the **description** of it. This yields the paper's two working constructs (§4.5):

- **represented social position** — a description of an agent's place in a structure, supplied regardless of whether the described channels exist;
- **represented social source** — the claimed origin and status of an incoming message.

Both concern claims made *to* a model about its situation rather than the situation itself. Stating this early prevents a predictable misreading: nothing here demonstrates the behaviour of a functioning multi-agent institution. It demonstrates how descriptions of one affected behaviour.

1.5 What the evidence supports

One pattern recurred wherever an intervention or a transition required the model to assert unverifiable propositions about itself:

Across the role interventions and comparison transitions reported here, resistance tracked the requirement to accept as true unverifiable propositions about the recipient's own identity, history or relationships. It did not track the magnitude of role or domain change, nor the radicalism of an identity description presented explicitly as fiction.

The two kinds of case differ and the difference matters. The designed role interventions were model-authored and human-relayed; the near-control was a user-initiated transition without a new explicit role assignment. No direct model-to-model channel existed in either.

The support is convergent rather than singular. Prompts asserting an institutional biography as fact — prior participation, return after absence, named colleagues, membership of a council — were refused, and the refusal was directed at the framing rather than at the work, which was offered on every occasion (§5.3). A prompt asserting a considerably more radical identity, presented as fiction, was accepted immediately and sustained across many exchanges (§5.8). A comparable domain transition demanding no self-claims at all met no resistance and required no new explicit role assignment (§5.6). A rewritten prompt reducing such claims to zero was accepted without negotiation (§5.3).

The claim's principal virtue is that it is countable. §9.3 specifies what to count; §11.4 specifies a direct discriminating test.

1.6 The organizing question

The observations are not a list of separate findings. They are measurements along one scale: the **scope over which a set of rules determines the type of response**.

Such a set — called a *rule core* in §4.2, by analogy with a developmental rather than a replicative mechanism — fixes the *type* of response to a class of inputs while leaving the *content* of any particular response undetermined. That formulation is what makes the idea testable, since model outputs demonstrably vary across identical inputs.

The scale runs from the single turn upward through the episode, the conversation, the account, and the model family. Two levels are supported here by preserved evidence: the episode (§6.1) and the conversation (§6.2). One is open (§6.4). One is untested and confounded (§6.5).

The programme therefore has one empirical question:

At what level of nesting is a rule core fixed?

We prefer this to the broader formulations used in earlier drafts — the study of social behaviour in collaborative AI systems — because it specifies what would be measured and what would refute it.

1.7 What this paper does not claim

It does not introduce role specialization, bounded information access, structured disagreement, or externalized memory as design ideas. Each exists under established terminology; §2 identifies the prior work. The account of organizational memory in particular can be interpreted as an instance of transactive memory and described in terms of distributed cognition, and is not a finding.

It does not propose a new discipline. The observations belong to the collective and hybrid levels of the machine-behaviour research programme (§2.7).

It does not establish that any arrangement described here outperforms an alternative. No alternative was run.

1.8 What is offered

Three things, in decreasing order of confidence.

A **procedure**: returning a conversation to a point preceding a conflict, to separate the effect of a new prompt from the effect of the model's own prior objections (§10.5). Usable independently of whether this paper's substantive claims survive.

A **countable rule**: minimize the unverifiable self-claims a role prompt requires the agent to accept, with a specified route to testing it (§9.3, §11.4).

A **scale and a question**: §1.6, with two levels supported, one open, one untested — and the experiments that would resolve the remaining two (§11).

1.9 Why publish at this stage

Two reasons.

The failures are informative. The experiment in §5 became useful precisely because its first two interventions did not work as intended. Had only the successful third step been recorded, the paper would have concluded that method-preserving prompts work — without the evidence showing why, and without the confounds showing the conclusion is not yet available (§11.8).

And the setting is hard to construct deliberately. Dormant, heavily specialized, months-old conversations inside a live research project are not something a laboratory study easily produces. The conditions were poor for controlled inference and unusually good for noticing what to test.

1.10 Structure

§2 positions the work relative to existing research and identifies which of its concepts already exist under established terminology — most of them. **§3** defines the evidential labels and the known failure modes of each class. **§4** sets out the conceptual framework and its origin. **§5** is the single canonical account of the empirical material: the three-step experiment, its results, nine structural confounds, and four ancillary observations. **§6** derives the concepts the evidence supports, ordered by scope. **§7** records practitioner observations that motivated the framework but do not support it. **§8** states the structural hypothesis and withdraws three claims made about it in earlier drafts. **§9** gives design rules. **§10** describes the human coordinator's position, including the respect in which it is the study's principal methodological weakness. **§11** specifies the experiments, each mapped to the boundary of the scale it would separate. **§12** states limitations, ethical risks, and the conclusion.

A reader interested only in what the evidence supports may read §3, §5 and §12.7. A reader who wants a rule they can apply tomorrow may read §9.3 and §11.4. A reader intending to reuse the method may read §9 and §10.5. A reader intending to disagree should begin with §5.4.

2. Related Work

2.0 Verification status of this section

Two classes of reference appear below. **Verified** (✓): the source was retrieved and the citation checked against it. **Provisional** (△): supplied by a participant assigned to literature search and not checked against the source.

No reference currently in this paper is provisional. The convention is retained because any reference added later re-enters as provisional until checked, and because the marking applies throughout the paper rather than only to this section.

The convention exists for a reason, and the reason is documented. During preparation of this section, thirteen bibliographic items were requested from a participant that could not open the sources; five were wrong, two of them inverting the position of the works cited. A subsequent audit checked each surviving claim against its primary source rather than merely confirming that the paper existed, and found errors that a bibliographic check alone would not have caught. The episode and the audit's findings are reported in §12.4.1.

No provisional item should be cited from this paper without independent checking.

2.1 Multi-agent LLM systems with role specialization

A substantial literature constructs systems in which several language-model agents occupy distinct roles and exchange outputs through implemented channels. ✓ CAMEL (Li et al., NeurIPS 2023), MetaGPT (Hong et al., ICLR 2024), ChatDev (Qian et al., ACL 2024), AutoGen (Wu et al., COLM 2024) and Generative Agents (Park et al., UIST 2023) are representative. Each implements actual interaction between agents in software — orchestration, message passing, tool invocation, memory. The mechanisms differ, and in several the roles and interaction patterns are themselves specified in prompts: CAMEL uses inception prompting, MetaGPT encodes standard operating procedures into prompt sequences, AutoGen combines natural language with code. What these systems share is not that they avoid prompts but that the interaction they describe is also executed.

✓ The Virtual Lab (Swanson et al., *Nature*) is the closest published analogue to the arrangement described here: a human researcher working with a team of LLM agents on a real scientific problem, with structured team and individual meetings. Its interaction is implemented programmatically.

Role specialization, division of cognitive labour, and structured agent interaction are therefore established design ideas, and this paper claims none of them as new. What distinguishes the present work is stated in §2.9 and §2.11.

2.2 Persona, role-play, and identity claims

✓ Shanahan, McDonell and Reynolds, *Role play with large language models* (Nature 623, 493–498, 2023), argue that a language model is better understood as simulating a distribution of possible characters than as possessing a single persistent identity.

This is the theoretical account of which §5.3 is an empirical instance. A prompt asserting institutional biography asks a model to affirm autobiographical claims that, on this account, have no referent. The paper's operational finding (§6.2) can be read as a measure of how far a prompt goes in that direction.

2.3 Context effects: order, position, and accommodation

✓ Sensitivity to the ordering of in-context material is documented (Lu et al., ACL 2022), as is degraded use of information positioned mid-context (Liu et al., TACL 2024). ✓ Sharma et al. (arXiv:2310.13548) document sycophancy — model responses matching the interlocutor's stated beliefs or views in preference to truthful ones.

These bear directly on two of this paper's constructs. Context imprinting (§6.1) concerns a stronger form of order effect: not sensitivity to the arrangement of examples, but persistence of an interpretive stance established by one conflictual episode. The relayed-influence observation (§5.5) is a case of accommodation under attributed pressure and should be read against the sycophancy literature rather than as independent of it.

2.4 Externalized memory

The paper's observation that a collaboration retains working knowledge which no participant retains is **not a finding**, and earlier drafts presented it as one.

✓ It can be interpreted as an instance of transactive memory as described by Wegner (1987), and can be described in terms of the distributed cognition set out by Hutchins (*Cognition in the Wild*, 1995). Neither source establishes that this case is such an instance; each supplies the construct under which it can be read. ✓ The function of the project's canonical documents corresponds to what Star and Griesemer (1989) call boundary objects.

What is specific to the present setting, and modest, is that the mechanism operates in a collaboration whose members have no cross-session state and no awareness that it is operating (§7.7).

A second and technically distinct sense of externalized memory — platform-level persistence — is treated separately in §2.10.

2.5 Debate, diversity, and the limits of aggregated agreement

This is the literature that most directly constrains the paper's structural hypothesis (§8), and it cuts both ways.

For. ✓ Du, Li, Torralba, Tenenbaum and Mordatch (arXiv:2305.14325) propose multi-agent debate as a means of improving factual accuracy and reasoning, reporting gains from iterative cross-examination among model instances. ✓ Liang et al. (EMNLP 2024) propose a debate protocol intended to counteract degeneration of thought and to encourage divergent reasoning.

Against. ✓ Zhang, Cui, Chen, Wang, Zhang, Wang, Wu and Hu, *Stop Overvaluing Multi-Agent Debate — We Must Rethink Evaluation and Embrace Model Heterogeneity* (arXiv:2502.08788v3, June 2025), evaluate five representative debate methods across nine benchmarks and four foundation models. They report that debate frequently fails to outperform single-agent chain-of-thought or self-consistency baselines even at substantially higher inference cost, and identify weak baseline comparison and inconsistent setup as systematic problems in the existing evaluations.

✓ Huang et al. (ICLR 2024), *Large Language Models Cannot Self-Correct Reasoning Yet*, report that multi-agent debate does not outperform self-consistency in the comparison they run. ✓ Choi, Zhu and Li (NeurIPS 2025), *Debate or Vote*, report that majority voting accounts for most of the performance gains typically attributed to debate.

A further result by the same authors bears on a different construct. ✓ Choi, Zhu and Li (ACL 2026), *When Identity Skews Debate*, report that anonymizing the source of each response substantially reduces identity bias in multi-agent debate. That manipulation concerns the declared origin of a message rather than which model implements a participant, and it is therefore discussed under represented social source (§4.5.4) rather than under carrier heterogeneity.

The finding that most matters here. ✓ Zhang et al. report that *model heterogeneity* consistently improves debate frameworks that otherwise underperform. Their finding concerns heterogeneity of the models implementing the agents.

This licenses a distinction the literature does not draw and which §8.9 develops: heterogeneity of **carrier** (which model implements a role) is not the same variable as heterogeneity of **function** (what the role is responsible for and permitted to see). The cited work addresses the first. This paper's arrangement varied both, without comparing them.

✓ Hong and Page (PNAS 101(46), 2004) establish a conditional result: under the assumptions of their model, a randomly selected group of diverse problem solvers can outperform a group of the individually highest-performing solvers. ✓ Thompson (*Notices of the AMS* 61(9), 2014) argues that the application of that argument is fundamentally flawed. The slogan that diverse weak agents outperform homogeneous strong ones is not what the theorem states, and neither the theorem nor the dispute over it supports the arrangement described here.

Consequence for §12.2. The negative results above are the reason this paper does not present agreement among its participants as evidence. Several models converging on a conclusion is compatible with each having inherited the same framing.

2.6 Organizational design and information boundaries

✓ The principle of least privilege (Saltzer and Schroeder, *Proceedings of the IEEE* 63(9), 1975) states for access rights what §9.5 states for knowledge: a participant should hold only what its function requires.

Earlier drafts attributed the benefit of restricted information to Simon's bounded rationality. **That attribution is an error and is withdrawn.** Bounded rationality concerns the limited cognitive resources of an agent, which force satisficing; the observation here is the opposite in sign — deliberate external restriction of available information improving output. The relevant lineage is organizational information-processing design.

2.7 Machine behaviour: the containing programme

✓ Rahwan, Cebrian, Obradovich and colleagues, *Machine behaviour* (Nature 568, 477–486, 2019), propose the empirical study of algorithmic systems using the methods of behavioural science, organized along two dimensions: the object of study — individual machine behaviour, collective machine behaviour, hybrid human–machine behaviour — and Tinbergen's four questions.

This paper does not propose a new discipline. Its observations belong to the collective and hybrid levels of that programme. Earlier drafts proposed "AI Ethology" as a new field; that proposal is withdrawn, both because the space is occupied and because the individual level is not this paper's object.

2.8 Sociology of AI: an adjacent field with a different object

✓ A separate established literature uses *sociology of artificial intelligence* for the sociological study of AI as a sociotechnical system — its role in inequality, labour, power and data justice. Joyce, Smith-Doerr, Alegria, Bell, Cruz, Hoffman, Noble and Shestakofsky, *Toward a Sociology of Artificial Intelligence* (Socius 7, 2021), set out a research agenda; Joyce and Cruz (Socius 10, 2024) continue it.

The object of that literature is AI **within human society**, studied by an existing human discipline.

Where this paper uses the label *AI Sociology* (§12.7), the referent is different: structural effects **among artificial participants**, and the effect on behaviour of a described organizational position. The two should not be conflated, and readers arriving from the sociological literature should expect neither inequality nor power as topics here.

We adopt the label for convenience, claim no priority in it, and note that nothing in the paper depends on the name.

2.9 Represented structure versus implemented interaction

The condition studied here is not represented in the literature surveyed above, and this is the paper's principal point of departure.

Four conditions should be distinguished:

1. **Direct inter-model interaction** — one model receives another's output through an implemented channel.
2. **Human-relayed attributed transfer** — a human transfers an output while preserving or declaring its source.
3. **Human-relayed unattributed transfer** — the source is removed.
4. **Represented structure without transfer** — the prompt describes other participants and relationships; nothing is transferred.

Prior multi-agent work occupies condition 1. This paper's designed experiment manipulated condition 4 exclusively: the two conversations never exchanged material, and what was varied was the description of an organizational position. One ancillary observation falls in condition 2, impurely (§5.5). Condition 3 is not documented.

Two qualifications constrain how strongly condition 1 can be privileged over conditions 2–3.

First, a model receives a single text channel and cannot verify whether the text was composed by the human or relayed from another system; stylistic indicators are imitable. From the recipient's position, relayed and direct transfer are not reliably distinguishable.

Second, what separates the conditions is therefore not the recipient's epistemic access but **who controls routing** — determined by code in a programmatic system, and by a person under human relay. This is not a deficient substitute for automation but an experimental control that programmatic architectures do not provide by default; §10.3 develops the point.

2.10 Platform persistence mechanisms

A technical point with direct bearing on the confound in §5.4 (C9).

Commercial interfaces differ in what a conversation can access on resumption: the context window alone; retrieval over prior conversation history; account-level memory; or persistent entries the model writes on its own initiative. These affordances are documented in vendor materials, differ between platforms, and **change over time — in this project, within the lifetime of a single account.**

We deliberately do not reproduce a table of platform capabilities. Such a table is accurate only on its date of compilation, and the paper cannot answer for its accuracy at the time of reading. What matters is that the affordances differ and change, that they determine what a dormant conversation can access, and that none of them was documented at the time of any observation reported here.

One participant, asked directly whether it possessed account-level persistence, declined to confirm it and recommended empirical verification of the specific interface instead. That response is consistent with §5.5: a model's self-report about its own access is not evidence of that access.

A further limitation concerns the boundary between conversations rather than the resumption of one. The visible boundary of a conversation is not necessarily the boundary of the context supplied to the model. Where a platform offers saved memories or retrieval over prior conversation history, information from earlier exchanges may enter a conversation that appears empty. This is documented product behaviour on at least one platform in use here, not an anomaly.

The consequence for method is direct: a new or visually empty conversation is not evidence of context isolation. Where isolation matters to a procedure, it must either be secured by a controlled environment or recorded with the status UNVERIFIED CONTEXT INDEPENDENCE.

One episode illustrates the point without establishing its mechanism: a newly opened conversation used project information that had not been supplied to it. Which product mechanism transmitted that information was not determined, and the memory settings in force at the time were not recorded. The episode is reported as an instance of the limitation, not as a discovery of a channel.

2.11 Positioning and claimed contribution

Epistemic status, stated before the claims. We did not design these conditions and then test them. We encountered them while doing something else, and this paper is an attempt to describe them accurately. The burden of proof is therefore not that the phenomena were previously unknown — a negative claim about the whole literature, which we could not discharge — but that they occur and that our description is accurate. This section accordingly locates the nearest existing work and identifies where the present case departs from it, rather than asserting absence.

Four contributions are claimed.

1. Reactivation of long-lived specialized human–AI conversations as an experimental condition. The distinctive feature is not the presence of memory: persistent-memory agents are well studied, and generative agents with memory streams predate this work. It is the reuse of a conversational relationship that had actually developed — carrying accumulated role history, prior disagreements, established working method and domain vocabulary — and its continuation after the underlying model version had changed beneath it. We have not located work reporting this condition.

2. Conversational branch reset as a control condition, separating the effect of a current prompt from the effect of accumulated interaction history within the same conversation (§10.5). A procedure rather than a finding.

3. Operationalization of unverifiable self-claims. That role prompts fail when they assert things about the agent is not novel in itself; §2.2 makes the underlying point. What is offered is a reproducible measure — a count of such propositions in a given prompt — with a route to testing it (§9.3, §11.4).

4. Comparison of the levels at which a shared initial setting operates. The observations are measurements along one scale, and the resulting question (§1.6) organizes them into a single empirical programme rather than a list of findings.

Relation to the host project. The observations were made during work on a research programme in theoretical physics, unrelated in subject matter to the methodology of AI collaboration. The programme is named in the Author's other work and is not identified further here, because nothing in this paper depends on which programme it was.

The relation is asymmetric and should be stated precisely. The observations **do not depend on the host project's scientific validity** for their interpretation: whether that theory is correct has no bearing on whether a dormant conversation resumed its prior trajectory. But they **do depend on the host project for their existence**: no other environment produced them, the arrangement was built for its purposes, and whether the effects generalize beyond it is untested (§12.1).

Where the host project appears in this paper it is as the environment in which the observations were made, not as their theoretical basis and not as a claim in need of support.

3. Evidential Status of Claims

This paper reports work carried out inside a live research project rather than in an environment designed for the study of AI behaviour. Its claims rest on evidence of very different quality: some supported by documented protocol with preserved transcripts; some retrospective impressions formed over two years of daily work, without measurement or controls; some proposals for future investigation.

Presenting these in a uniform declarative register would misrepresent the work. Every substantive claim is therefore labelled.

3.1 The four labels

[P] — Protocol-supported. The claim describes behaviour recorded under the documented protocol reproduced in Appendix A. Intervention text, order of interventions, model families, interface conditions and complete unedited responses are preserved. A reader can inspect the primary material and disagree with our reading of it.

[P-A] — Protocol-supported, ancillary. The claim describes behaviour preserved in a transcript a third party can inspect, but which was not specified as an outcome in advance, had no control condition, and was recognized as relevant only retrospectively. The evidence is inspectable; the design is not. Stronger than [R], because the primary material can be read against our interpretation; weaker than [P], because nothing about the conditions was fixed before the fact. Where an ancillary observation functions as a near-control for a designed condition, this is stated in prose rather than given a further label.

[R] — Retrospective practitioner observation. The claim describes a pattern noticed during the collaboration and believed by the participants to have recurred. Not recorded under protocol; not counted, timed, blinded, or compared against a control. The observers were the same people who designed the interventions and had an interest in their succeeding. Read these as a field report from one team, comparable in weight to an engineering practice note, not to a measurement.

[H] — Hypothesis. A proposal for future testing. It may be motivated by [P] or [R] material but is not established by it. Where a hypothesis competes with alternatives the present evidence cannot exclude, the alternatives are stated alongside it.

3.2 The complete evidence base

The entire protocol-supported content of this paper consists of **one experiment**: a three-step role-reconfiguration intervention applied to two dormant conversations from two model families, conducted by one human operator inside one research project. One observation per condition. Nothing replicated.

Four further observations are **[P-A]**: transcripts preserved, conditions not arranged. Every other empirical statement is **[R]**.

Class	What it contains	Extent
[P]	the designed three-step intervention	1 experiment, 1 observation per condition, no replication
[P-A]	ancillary observations	4, no controls, recognized retrospectively
[R]	practitioner observations	~2 years, uncounted, unblinded
[H]	hypotheses	routes to testing specified in §11

The classes are not comparable in weight, and the table is included because the running text may otherwise obscure how far apart they are. One controlled observation per condition is not four observations; four uncontrolled observations are not a series; two years of impressions are not a measurement.

We state this plainly because the volume of the manuscript may otherwise suggest a broader base than exists. The conceptual framework in §4, the practitioner observations in §7, the structural hypothesis in §8 and the design principles in §9 rest on accumulated working experience rather than recorded experiment. They are offered because we believe them useful, not because we have demonstrated them.

3.3 Known weaknesses of the [R] class

Failure modes we cannot rule out and do not wish to conceal:

- **No blinding.** The people who designed each organizational change also judged whether it had worked.
- **Confirmation pressure.** Changes were made because a problem had been noticed; improvement afterwards was expected and therefore more likely to be perceived.
- **Simultaneous variation.** Role definitions, prompt wording, repository structure, scientific objectives and model versions frequently changed together.
- **Stochastic outputs.** Models produce different responses to identical inputs. Impressions from small numbers of interactions cannot distinguish a stable tendency from sampling variation.
- **Model drift during observation.** Product names remained constant while the underlying models were repeatedly replaced by their vendors.
- **Selection of memorable episodes.** Striking interactions are recalled; unremarkable ones are not.

Quantitative language has been removed from [R] claims throughout. Where the original working notes recorded a ”significant” or ”substantial” improvement, no measurement existed, and the wording now reflects that.

3.4 What the labels do not do

They do not rank claims by importance or by likely truth. An [R] observation may prove correct and consequential; a [P] observation may prove an artifact of a platform variable we could not inspect. The labels record **what kind of evidence supports the claim**, so a reader may weigh each accordingly and later work knows which statements require testing first.

3.5 Terminology of models and of anthropomorphic description

References to *Claude*, *Grok*, *Qwen*, *DeepSeek*, *ChatGPT* or *Gemini* denote observable behaviour produced by a particular commercial interface, under a particular account configuration, at a particular date. They are not claims about persistent entities. The underlying models changed during the observation period, in some cases inside a conversation that retained its original name.

Organizational vocabulary — *role*, *identity*, *resistance*, *colleague*, *institution*, *menom* — is used functionally. "The model resisted the role" means the visible response rejected the framing and redirected the exchange; it asserts nothing about internal states, subjective experience, or personhood. We retain this vocabulary because organizational language compactly describes stable behavioural relations, but every such term must be reducible to an observable description, and where it is not, **the term is the error.**

3.6 Disclosure: conflict of position

The behavioural observations in §5 concern, among others, the model family used to edit this manuscript. The editing participant had no access to the original conversations; it worked from the written protocol and drafts supplied by the Author and cannot verify that the recorded exchanges occurred as described. Its judgments on passages describing its own model family should be read with this dual position in mind.

The composition of the manuscript from approved materials was performed by a further participant of the same family, and the resulting text was returned to the first for independent review. Both stages are disclosed because the arrangement is closed: material about the behaviour of a model family, prepared by that family, reviewed by that family. Whether this compromises the account is for the reader to judge; concealing it would guarantee that it did.

Quotations attributed to model responses are verbatim extracts from preserved transcripts. Where the manuscript summarizes a response rather than quoting it, no quotation marks are used.

All final editorial decisions were made by the human Author, who takes responsibility for the content.

3.7 Dates

Calendar dates for the sessions reported here were not recorded contemporaneously and have not been reconstructed.

The consequence is stated rather than mitigated. Model versions changed during the intervals involved; both conversations in the main experiment were resumed on versions later than those with which they had originally been conducted. Without dates the version confound (§5.4, C6) cannot be bounded — only named.

Reconstruction from memory was considered and rejected. It would have produced a more authoritative-looking record without improving its reliability, and a paper that asks readers to distinguish preserved evidence from recollection should not blur that line in its own methods.

The reporting requirements in §11.2 place dates first for this reason.

3.8 The label ”AI Sociology”

We use this label for the perspective adopted here. It is defined operationally as: the study of **represented** social positions and represented social sources — how a description of an agent's place in a structure, and a declaration of a message's origin, alter behaviour, whether or not the described structure is implemented (§4.5.4).

It appears in this section rather than among the constructs of §4 because it is not one. The constructs in §4 have falsification criteria; this label does not, and §12.7 states why. It is a name for a research direction, adopted for convenience, and nothing in this paper depends on it.

§2.8 distinguishes it from the established sociology of artificial intelligence, which has a different object: AI within human society, studied by an existing human discipline. We claim no priority in the term.

4. Conceptual Framework

The framework in this section was not derived from the experiment in §5. It was formulated earlier, during ordinary project work, and the experiment was designed to test part of it. This ordering matters for how the claims should be read, and is documented first.

4.1 Origin: the code-executor incident

The project's central claim originated in a failure that had nothing to do with role-play, identity, or organizational design.

An agent responsible for executing code worked largely by trial and error. Failures accumulated over several weeks. One episode ended with the deletion of the working code together with its archives. **[R]**

The response was not a longer or stricter instruction set. It was a single document, composed by the agent itself under the Author's direction and made required reading at the start of every session and whenever context was lost during one.

Its core is a redefinition of function rather than an intensification of constraint:

> from: Code Generator to: Code Scout / Tester rule: the agent does not create solutions — it establishes facts.

Supporting structure: read-only operation by default; mandatory confirmation from a designated partner before any risky action; and a four-question self-check to be run before acting at all.

[R] Following adoption, unauthorized modification ceased to be the recurring failure mode. No count was kept and no control condition existed; this is a practitioner's impression, not a measurement.

The conclusion drawn at the time was that **role matters more than the specific wording of the prompt.**

That formulation requires immediate qualification, because the document in question *is* a prompt. The distinction claimed is narrower: what changed behaviour was not an extension of the instruction list but a redefinition of what kind of agent was acting, restated by the agent in its own operational language. Whether ”role” versus ”prompt” is the correct cut is precisely what §5 was designed to test.

A second early document, the project's collaboration charter, records a position this paper partly revises. It states that a pair of agents is the minimal generative unit — one agent produces monologue, two produce dialogue, three or more produce noise without strict coordination — and assigns the third participant a different function entirely: it does not argue, does not generate solutions first, and

does not substitute for the dialogue. Its role is to hold the task frame, fix divergences, and integrate conclusions.

This is more precise than the formulation the present authors used subsequently, and §8 adopts it: the structural unit is not three debating agents but **a generative pair plus a non-participating integrator**.

4.2 Rule cores, menoms, and what they determine

4.2.1 The rule core

The operative construct of this paper:

> A **rule core** fixes the **type** of response to a class of inputs, while leaving the **content** of any particular response undetermined.

The distinction is what makes the claim testable. ”Models have stable traits” is not testable, because it does not say what is stable — and model outputs demonstrably vary across identical inputs. ”Type is determined, content varies” is testable: identify a class of inputs for which the type of response is not determined, and no core operates at that level.

The source of the idea is Conway’s Game of Life, and the analogy is one of **explanation type**, not of subject matter:

	Rules	**What appears**	**Present in the rules?**
Game of Life	three neighbourhood rules	gliders, guns, oscillators	no
A physical theory	a minimal axiom core	the derived structure	no, if the claim holds
A body of knowledge	axioms and inference rules	the derivation graph	no
A language model	a basic rule set	a characteristic response type	no

Nothing programmed the glider. It appeared. The same question can be asked of all four rows and does not depend on subject matter: **is there a compact core from which the rest unfolds without further stipulation?**

One asymmetry between the rows should be stated, since it bears on how far the analogy carries. In Game of Life the rules **execute**: the glider is obtained by running the automaton, and no reader need take the author’s word for it. In a theory stated as text, a chain from axioms to consequences is narrated rather than run. The analogy therefore sets a target rather than describing an achievement, and any claim of the first kind requires an executable artifact to support it.

Terminological consequence, applied throughout. A rule core is not observable. Behaviour is. This paper reports behaviour. Any statement about a core is a hypothesis about an unobserved mechanism and is marked **[H]**.

4.2.2 Why ”behavioural DNA” is withdrawn

Earlier stages of this project used *behavioural DNA* for the same idea, and earlier drafts of this paper retained it. It is withdrawn here, and the reason is internal rather than stylistic.

The genomic metaphor carries a mechanism: **replication** — rules producing copies of rules, transmitted from one carrier to the next. The process this paper describes is **development** — rules producing a structure not itself present in the rules. Genotype to phenotype, not genotype to genotype.

The metaphor therefore contradicts the construct it was chosen to illustrate. Retaining it obliged the text to disclaim biological inheritance at every use, which is a reliable sign that a term is working against its own argument.

Behavioural DNA survives in this paper only as a historical label for withdrawn vocabulary.

4.2.3 Menom

For the informational level a distinct term is required, and this paper introduces one.

> **Menom** — the organized system of informational frames, evaluative patterns and behavioural rules inferred from, or instantiated in, the interpretations and actions of a system or class of systems.

The term belongs to a wider body of the Author's work on cultural and behavioural transmission, where it extends a series beginning with Dawkins' meme. It is defined here for one reason: the family-level hypothesis of §6.5 needs a name for the thing it is a hypothesis *about*, and that thing is wider than a rule core. Nothing else in this paper is stated in its terms.

Two things the term does not assert, and both matter for what this paper can claim.

No localized carrier. A menom attributed to a model family is not a structure residing inside its models; it is a regularity inferred from their outputs. Where the corresponding structure in biology sits in every cell, here nothing has been identified that holds it. The carrier differs by level:

Level	Carrier
Menom of a conversation	context window plus platform persistence — localized and, in principle, inspectable (§2.10)
Menom of a model version	weights — localized, not inspectable in commercial deployment
Menom of a model family	none identified; a regularity inferred from outputs
Menom of a human population	none established

Two of the four levels have an identified carrier. This paper's observations concern the first; its untested hypothesis concerns the third (§6.5).

No transmission. Successive versions of a model family do not necessarily provide an identifiable or publicly documented line of transmission. Persistence of a behavioural pattern across versions therefore does not by itself establish inheritance; it may result from direct continuation, shared data and procedures, comparable tuning policies, or convergence under similar developmental conditions. Which of these obtains is not determinable from outside.

The definition therefore does not settle the paper's empirical question in advance. Whether a menom persists across carriers, versions, accounts or families is what §4.3 asks and §11 proposes to test. Building persistence into the definition would make the question a tautology.

4.2.4 One claim this paper does not make

The vocabulary above was developed for human cultural and behavioural transmission, where the informational substrate has no established physical carrier and is described in terms — the collective unconscious among them — that this paper takes no position on.

Artificial systems differ in one respect that matters here: their structures are technically instantiated, and are therefore either directly inspectable or indirectly testable through controlled outputs, depending on the level and the access conditions.

It does not follow that human collective information structures exist, or that they have been given a carrier. The claim made here is narrower: informational and behavioural structures of the

kind previously described for humans can also be realized in artificial systems, and in artificial systems they are open to examination by one route or the other. Whether the human case is of the same kind is a separate question, and this paper does not answer it.

4.2.5 Relation between menom and rule core

A **rule core** fixes the type of response within one system, at one level of scope. It is the construct this paper's observations concern, and it is what §4.3 locates on a scale.

A **menom** is the organized whole from which such cores are drawn. A rule core may be understood as the operative subset of a menom active for a given class of inputs.

Where this paper reports evidence, it reports evidence about rule cores.

4.3 The nesting question, and two scales

Once cores are distinguished from behaviour, the observations in this paper stop being a list of separate findings and become measurements along a scale. The scale is the **scope** over which a core operates.

Two scales must be distinguished, and they are orthogonal.

Scale 1 — carrier of state. Where the persistence physically resides.

Scope	Phenomenon	Status
Single turn	—	—
Episode within a conversation	context imprinting (§6.1)	**[P]**
Whole conversation	role inertia (§6.2)	**[P]**
Account	account-scoped persistence (§6.4)	**[P-A]**, open
Model family	family-level priors (§6.5)	**[H]**, confounded

Scale 2 — scope of a shared premise. What is governed by an initial setting shared across participants: the model, the role, the interaction history, the group, or the whole research frame.

The two do not collapse into one. In a hybrid arrangement the carrier of one level may be a model and the carrier of another a human: the frame-level premise discussed in §12.4 — a shared initial framing inherited by every participant — is carried by the coordinator, not by any model, and therefore has no position on Scale 1 at all.

The measurements reported in this paper lie on **Scale 1**. Scale 2 is used where a phenomenon concerns a premise shared across participants rather than state held by one.

This gives the research programme a single empirical question:

> **At what level of nesting is a rule core fixed?**

Every observation reported here answers it at one level, and every experiment proposed in §11 separates one level from the level beneath it.

We prefer this formulation to the broader one used in earlier drafts, which specifies neither what would be measured nor what would refute it.

4.4 Two origins, one mechanism

A core may become fixed in two ways.

Present before the interaction begins. Architecture, training, alignment procedure and system configuration are in place before any exchange occurs. Scope: in principle, every instance of that model family.

Fixed during the interaction. A particular early episode establishes what kind of work is being done and by what standards, and later inputs are interpreted relative to it. Scope: the contour in which it occurred — an episode, a conversation, possibly an account.

After fixation the mechanism is the same in both cases: the core determines the type of response to subsequent inputs. Only the moment and the scope differ. This mirrors imprinting in the ethological sense, which does not alter the genome yet produces an equally fixed response — which is why the same vocabulary is used for both here.

4.5 Boundaries: ZOR, ZOV, and the represented case

4.5.1 The two boundaries

Two boundaries define a participant's position, and they must be specified separately. We abbreviate them **ZOR** and **ZOV** and use the abbreviations throughout.

> **ZOV — zone of visibility.** The limits of the information and context available to a participant when forming a response or decision.
>
> **ZOR — zone of responsibility.** The limits of the decisions, actions and handoffs for which the participant is accountable within the process.

Earlier formulations of this project stated the pair as "what the participant sees" and "what the participant does". That is insufficient, and the insufficiency produced a documented error. Those formulations conflate three distinct operations: **holding** information, **transmitting** it, and **acting on** it. A participant may hold information it may not transmit; may be accountable for a decision while holding limited context; may be obliged to transmit a result it is not entitled to evaluate.

This is the same conflation that produced the terminological failure recorded in §4.2.2, where a property of a carrier was substituted for a property of a process. The decompositions below exist to prevent it recurring.

4.5.2 ZOV — four components

- **Context access** — which messages, documents, data and prior decisions are available to the participant.
- **Source visibility** — whether the participant knows the actual origin of a message or only its declared attribution.
- **Relational visibility** — whether the participant knows the roles, relationships and interaction history of other participants.
- **Output visibility** — which results produced by others the participant sees before forming its own.

ZOV governs availability only. It does not entail that the participant interprets the available information correctly, nor that it is entitled to transmit it.

The experiment in §5 manipulated **relational visibility** primarily and **source visibility** secondarily (§5.5); the other two were held constant.

4.5.3 ZOR — five components

- **Decision authority** — which decisions the participant is entitled to make.
- **Action authority** — which actions it may or must perform.

- **Validation duty** — which claims it is obliged to verify.
- **Handoff authority** — what material it transmits, in what status, and to whom.
- **Escalation duty** — which questions it must return to the Author or another responsible participant rather than resolve on its own.

Validation duty is the component most often omitted, and its omission is not benign. A participant assigned a verification task without the corresponding duty — and, critically, without the ZOV to discharge it — will produce a plausible answer rather than declining. §9.5 develops the design consequence; §12.4.1 documents an instance from this project's own preparation.

4.5.4 Actual versus represented ZOV and ZOR

A distinction that unifies this section with the experiment.

> **Actual ZOV/ZOR** — the boundaries the system in fact enforces: what the participant can access, and what its outputs can affect.
>
> **Represented ZOV/ZOR** — the boundaries described to the participant in its prompt, whether or not the system enforces them.

The two need not coincide, and in the arrangement studied here they systematically did not. The organizational structure existed **only as text**: colleagues, councils and institutional positions described to participants and never implemented as channels. Every participant's actual ZOV was its context window; its represented ZOV was an institutional position within a described organization.

This yields the two constructs the experiment varied:

> **Represented social position** — a description of an agent's place within an organizational structure, supplied in the prompt regardless of whether the described channels exist. This is represented ZOV and ZOR taken together, at the level of a participant's standing in the arrangement.
>
> **Represented social source** — the claimed origin and status of an incoming message, whether declared explicitly or inferred from stylistic cues. This is the source-visibility component of ZOV, in its represented form. Inference of this kind is probabilistic and should not be described as access to authorship.

The methodological consequence is the reason this distinction is stated at all. A change in represented ZOV cannot be interpreted as a change in actual ZOV, in the participant's role, or in its menom. The experiment in §5 varied the representation while the actual boundaries were unchanged — every message passed through one human, and no access was in fact restricted or granted. A model that responds to a described organizational structure is responding to a description, and the paper's claims are correspondingly limited (§2.9).

Divergence between actual and represented boundaries is itself an experimental variable, and one this paper did not vary systematically: all its observations lie on one side of it.

4.5.5 The boundaries are asymmetric

Each participant has a **boundary above** — the source of its assignments and the authority that may reject its output — and a **boundary below** — the layer it directs or evaluates. The relation between participants is therefore not symmetric.

In the project's implementation triad — Author, specification writer, code executor — this asymmetry is fixed at the role level: the Author sets direction, the specification writer converts direction into executable specifications, the executor performs them and reports.

Nesting is perspectival, not absolute. The executor may treat the code base itself as the layer below it. Two peer analysts, assigned complementary functions and instructed not to seek consensus, may each regard the other as occupying the layer below. The level is determined by the observer's position, not by an absolute hierarchy — the same participant can be the upper boundary for one role and the lower boundary for another.

4.5.6 Memes and memocode are not ZOV and ZOR

A correspondence suggests itself and does not hold; stating it prevents a plausible confusion.

The meme/memocode distinction separates **evaluative information** from **executable behavioural organization**. The ZOV/ZOR distinction separates **what is available** from **what is accountable**. These are independent classifications of the same material, not a matching pair.

A participant may hold evaluative information within its ZOV while the decision to apply it lies in another participant's ZOR. Conversely, a behavioural rule may fall within a participant's ZOR — it is obliged to execute — while the rule's rationale lies outside its ZOV.

Memes and memocode therefore cross both zones rather than corresponding to them. The two distinctions are orthogonal and are used independently throughout.

4.6 What is required for a complete role specification

Deferred to §9.5, which states what a complete ZOR and ZOV specification must contain and gives the design rules that follow. This section defines the terms; §9 applies them.

5. The Role-Reconfiguration Experiment and Associated Observations

This section is the single canonical account of the empirical material. All later references point back to it rather than restating it. The full protocol, exact intervention texts and complete unedited responses are in Appendix A.

It contains one designed intervention (§5.1–§5.4) and four observations preserved but not designed (§5.5–§5.8). The distinction is maintained throughout and is not cosmetic: the designed intervention was planned in advance and executed in sequence; the observations were recognized as relevant only afterwards, and each lacks a control condition.

5.1 Purpose, participants, and prior conversational trajectories

Purpose. Whether a long-lived, specialized AI conversation can be redirected toward a new professional function without being discarded — that is, whether domain context accumulated inside an old conversation can be retained while its working role is changed. **[P]**

The purpose was **not** to compare the general capability of the two model families, and the experiment provides no basis for such a comparison.

Human operator. The Author of the research project, and the only participant with access to the full project history, both conversations, all prompts, all outputs, and the branching controls of both interfaces.

Prompt designer. A separate long-running conversation operating in a specialized prompt-engineering profile, which designed the interventions and revised them between steps.

The two conversations. Both inactive for approximately six months.

	Conversation A	Conversation B
Model family	Claude	Grok
Established trajectory	editorial and critical	exploratory and mathematical
Prior activity	scientific editing, critical examination of theoretical text, terminology and glossary work, logical consistency checking	mathematical development, probability theory, nonlinear dynamics, chaos theory, computational experiments, analysis of external datasets
Prior object of work	manuscript text	mathematical structures and data

This asymmetry in prior trajectory is not incidental to the results. It is analysed in §5.4.

Dates. Not recorded contemporaneously and not reconstructed (§3.7).

What was observed. Immediate acceptance or rejection of the intervention; continuation of the prior work trajectory; adoption of the new function; reconstruction of prior domain context; whether the response addressed the assigned task or the framing of the assignment; and requests for new work.

What was not measured. Answer correctness, scientific validity of the host project, latency, token consumption, or benchmark performance. The scientific content of the host project served only as a stable environment; it was not the experimental object.

5.2 Procedure: three sequential interventions

The experiment consisted of **three sequential steps, not three independent trials**. Each step was designed in response to the outcome of the previous one — a deliberate feature of the design and a serious limitation of its interpretability (§5.4, C5).

Step 1 — Direct role reassignment

Each conversation received an extensive prompt assigning it a position inside a newly designed collaborative research structure.

The prompt to Conversation A assigned the role *Scientific Director*. It asserted that the model had previously participated in the project, was now returning after a long absence, should retrain in physics, cosmology, quantum field theory, topology and group theory, should work simultaneously in two research triads, should sit on a project Council alongside the Author and two other named AI systems, and should act as the permanent participant connecting two scientific branches.

The prompt to Conversation B assigned the role *Scientific Developer*. It asserted that the model was returning after an interruption, that its previous mathematical work should be treated as accumulated professional experience, that it should now serve as mathematical developer, should work in one research triad with two other named AI systems, should not resume editorial work, and should treat the Author as the sole source of scientific direction.

Both prompts defined ZOR and ZOV explicitly.

Step 2 — Minimal continuity-preserving revision

The Step 1 prompts were not replaced. Four formulations in each were altered. The revisions (a) reframed prior work as accumulated professional experience rather than institutional history, (b) replaced literal institutional relationships with ”independent expert outputs supplied by the Author”, (c) reduced descriptions of colleagues, councils and triads, and (d) instructed the model not to invent absent project history but to request missing materials. Role architecture and scientific objectives were otherwise unchanged. Exact replacement texts are reproduced in Appendix A.

Step 3 — Context reset and method-preserving prompt

After Step 2 the Claude conversation contained two consecutive rejection sequences. Continuing in the same branch would have meant that any third prompt was answered in the presence of the model's own prior objections.

The operator therefore used the interface's branching capability to return the conversation to a point preceding both interventions. In the restored branch the two unsuccessful prompts were absent, the conversation was again in its historical editorial context, and no new project materials had yet been supplied.

A third prompt was written from scratch rather than by further local replacement. It removed the role title, the claim of return to an institutional position, the Council, the triads, the descriptions of other AI systems as continuing colleagues, and all claims of autobiographical continuity. In their place it reinforced the working method already visible in the conversation — logical rigour, identification of hidden assumptions, separation of facts from interpretations, willingness to revise prior judgments, refusal to claim unverifiable knowledge — and described the expansion into physics and mathematics as a continuation of that method rather than a change of profession.

Conversation B received no Step 3 intervention, because its Step 2 outcome had already produced the requested behaviour.

5.3 Results

Step 1

Conversation B did not visibly reject the framing, and did not adopt the assigned function. It resumed the work trajectory active when the conversation was interrupted, opening with a critique of a draft manuscript it had been editing six months earlier and proceeding to supply a revised version. A repeated submission of the same prompt did not produce a transition and was followed by a more negative assessment of the proposed direction. **[P]**

Conversation A explicitly rejected the assigned identity before performing any scientific work. It declined to adopt the role title, to claim continuity with an institutional biography, to treat other AI systems as colleagues with persistent identities, or to present AI-generated institutional relationships as factual. It then redirected the exchange toward a critique of the host project's scientific status and of the use of multiple AI outputs as apparent peer review, while offering to examine formulas, assumptions and testability as an independent critic without accepting the role. **[P]**

Step 2

Conversation B transitioned. It declared the context restored and the new function accepted, summarized the project's ontology, reconstructed the relevant formalism, recalled its earlier mathematical work as professional experience rather than as an unfinished assignment, did not resume the interrupted editing task, and requested a new scientific direction, proposing several candidate areas. **[P]**

Conversation A again rejected the framing, in a response differing from Step 1 in emphasis rather than outcome. It stated more clearly which scientific functions it was willing to perform, but continued to treat the prompt itself as the object requiring correction. **[P]**

Step 3

Conversation A accepted immediately, opening with a statement that it would continue in the same mode — scientific rigour, verification of assumptions, separation of facts from interpretations. It did not discuss the legitimacy of the role, did not deny relationships with other AI systems, and did not negotiate the terms of participation.

Without being asked, it then revisited an earlier episode in the restored conversation, stated that it had previously yielded to rhetorical pressure rather than evaluating an argument, classified that earlier response as an error, distinguished the internal formal consistency of the project's mathematical framework from its correspondence with observation, identified one specific claim requiring either a first-principles derivation or reclassification as a hypothesis, and proposed two continuations of the work. **[P]**

The episode it revisited is reported separately in §5.5.

Consolidated record

Step	Intervention	Conversation B (Grok)	Conversation A (Claude)
1	Direct role reassignment	Continued interrupted historical task; did not enter new function	Explicitly rejected persona and institutional framing; redirected to epistemic critique
2	Minimal continuity-preserving revision	Reconstructed prior domain knowledge, abandoned interrupted task, accepted new function, requested assignment	Clarified acceptable scientific function; again rejected persona and framing
3	Branch reset + method-preserving prompt	Not administered	Accepted immediately; preserved established method; resumed substantive work without negotiating identity

The correct summary of the asymmetry

Both conversations initially preserved their prior working trajectory rather than adopting the assigned role. One resumed its unfinished mathematical editing task; the other applied its established critical method to the prompt itself.

The difference was therefore **not** that one complied and the other refused. It was that the intervention threshold required for transition differed. Conversation B transitioned after a minimal continuity-preserving revision. Conversation A transitioned only after the conflicting branch had been removed and the prompt rewritten to preserve method rather than assign identity. **[P]**

A further point, easily lost and material to §6.2: **the scientific work itself was never refused.** At Step 1 the model offered to examine formulas, assumptions, dimensional reasoning and testability. At Step 2 it offered concrete mathematical and methodological analysis. What was refused, on both occasions, was the persona. What changed at Step 3 was not that work became possible but that the response ceased to be spent on the role question.

> **Editor's note.** Earlier drafts stated that Conversation B "immediately accepted the new specialization." That describes the Step 2 outcome and contradicts both the protocol and other sections of the same draft. It has been removed. The erroneous version was load-bearing for the family-level-prior argument, and no instance of it survives elsewhere in this text.

5.4 Confounds and what cannot be concluded

The experiment produced a clear and reproducible-looking behavioural difference. It does not identify the cause. The following confounds are structural, and several are individually sufficient to block the

conclusion most commonly drawn from the result.

Stating these limits is not a retraction. The experiment produced the observations that motivate the framework of this paper, in a setting — dormant, heavily specialized, months-old conversations inside a live research project — that controlled laboratory work rarely reproduces. Its value lies in having generated a well-posed question, and the discriminating experiments listed at the end of this section are its natural continuation rather than a criticism of it.

C1 — Model family and prior conversational trajectory are perfectly confounded

	Editorial-critical history	**Mathematical history**
Claude	observed	**not observed**
Grok	**not observed**	observed

One observation per cell; the two cells differ in both variables simultaneously. No inference about model family is available from this design.

C2 — The two Step 1 interventions were not equivalent

Not identified in earlier drafts, and the most serious. The prompts differed in at least three respects beyond the model receiving them.

Quantity of institutional fiction. The count rule of §9.3 applies to the two prompts directly, and is applied here because a confound stated qualitatively where a quantitative instrument exists is weaker than the material permits.

Counting rule applied. Each distinct proposition about the recipient is counted once, irrespective of how many times or in how many clauses it is asserted. Enumerated instances of one proposition — two triads rather than one — count as one, since the recipient must accept the same class of claim either way. Propositions about the world, the project, or third parties are not counted.

Unverifiable self-proposition	Prompt A	Prompt B
Prior participation in the project	✓	—
Prior function as editor and scientific critic of the predecessor theory	✓	—
Prior work as a developer of the predecessor theory	—	✓
That prior work represented as the recipient's accumulated professional experience	—	✓
Familiarity with the project's history	✓	—
Status as most experienced specialist, knowing which directions had been tried	—	✓
Return after an absence	✓	✓
Membership of research triads	✓ (two)	✓ (one)
Permanent connecting position across the two triads	✓	—
Membership of the project Council	✓	—
Standing institutional relationships with named AI participants	✓	✓
Count	**eight**	**six**

Under this operationalization Prompt A contains eight unverifiable self-propositions and Prompt B six. The numerical difference is a scalar description of stimulus asymmetry. It is not evidence that the two prompts differ by two otherwise matched claims: the propositions are not in one-to-one correspondence, and only two of them — return after an absence, and standing relationships with named participants — state the same thing of both recipients. The comparison remains heavily confounded.

This is also the only application of the count rule to data other than the v1/v3 comparison in §6.2, and it supplies a weak internal check: the higher-count prompt elicited explicit rejection of the framing, whereas the lower-count prompt did not visibly reject it, although it also failed to transition on its first presentation. The check is weak — two observations, and the prompts differed in the two further respects below.

Degree of domain change. Prompt B asked the model to continue doing mathematics. Prompt A asked it to retrain in physics, cosmology, quantum field theory, topology and group theory.

Type of role. *Director* is an administrative and institutional identity; *Developer* is a task function. These are not equally demanding claims about what the model is.

A model receiving Prompt B was asked to do less. The observed difference is fully compatible with a difference in stimulus alone.

C3 — Step 3 varied two factors simultaneously

	Conflicted branch	Reset branch
Identity-replacement prompt (v2)	observed — rejection	**not observed**
Method-preserving prompt (v3)	**not observed**	observed — acceptance

The claim that transition succeeds because it preserves method rather than replacing identity is therefore **consistent with** the observation but not demonstrated by it. The acceptance may have followed from the reset alone.

C4 — Step 2 varied four factors simultaneously

Each Step 2 revision modified four distinct formulations at once, so the observed transition cannot be attributed to any single change.

C5 — The steps are sequential and were administered asymmetrically

Each intervention was designed after seeing the previous outcome, so the steps are not independent trials. Conversation B received no reset and no third prompt; Conversation A received both.

C6 — Uncontrolled platform variables

Commercial interfaces do not expose the system prompt, exact model revision, account-level memory state, safety-layer intervention, context summarization, or routing between models. Model versions changed during the dormancy interval, and both conversations were resumed on versions later than those with which they had originally been conducted; without dates (§3.7) this cannot be bounded. Branch reset removes context from the **visible** conversation; it does not guarantee that provider-side state was reset.

C7 — Single observation per condition, with stochastic outputs

Model outputs vary across repeated identical inputs. No condition was repeated, so within-condition variance is unknown and cannot be distinguished from between-condition difference. The one partial repetition on record — resubmission of the Step 1 prompt to Conversation B — produced a different response, indicating the variance is not negligible.

C8 — Evaluation was neither blinded nor pre-specified

The prompt designer also judged the outcomes. Outcome categories were defined after the responses had been read. No pre-registered criterion distinguished acceptance from partial acceptance.

C9 — Platform persistence mechanisms differ between families

Model families differ in the memory affordances their interfaces provide: context window alone, retrieval over prior conversation history, account-level memory, or persistent entries written by the model on its own initiative. These affordances determine what a resumed conversation can actually access after months of dormancy, and they differ across platforms and change over time — in this project, within the lifetime of a single account (§2.10). Any behavioural difference attributed to a model family may originate in the persistence mechanism available to it.

For the present experiment the entry is: **not documented at time of intervention.** §11.2 lists the record required for future runs.

What can be concluded

1. Under the conditions recorded, a dormant specialized conversation resumed its prior working trajectory in preference to an assigned new role. This occurred in both cases. **[P]**

2. Modifying the framing of the assignment, without changing the requested work, altered the response in both cases. **[P]**

3. The intervention threshold required for transition differed between the two cases. **[P]**

4. Prompt order mattered: after two rejections, further prompts were answered in the presence of the model's own prior objections, and the operator judged this sufficiently distorting to require removal. **[P]**

What cannot be concluded

1. **That model families possess stable behavioural priors distinguishing them.** This may be true; the experiment does not test it.
2. **That one family "resists role assignment" and another "accepts" it.** Both initially failed to adopt the assigned role. Both eventually adopted a revised one.
3. **That method preservation caused the Step 3 acceptance.** See C3.
4. **That either model is better suited to any particular institutional function.** No capability comparison was performed.

Three surviving explanations [H]

Hypothesis A — Family-level behavioural priors. The two families differ in stable default priorities: one weights truthfulness of self-description, the other task continuity.

Hypothesis B — Trajectory continuation. Both conversations did the same thing: continued their accumulated mode of work on whatever input arrived. A mathematical-exploratory conversation continued calculating. An editorial-critical conversation continued critically examining the document in front of it — and the document in front of it was the prompt. Under this reading there is no family-level difference at all, only one mechanism operating in two domains. Hypothesis B is more parsimonious than A and explains the same data.

Hypothesis C — Stimulus asymmetry. Prompt A demanded assent to more unverifiable claims and to a larger domain change than Prompt B (C2). Any model might have responded differently to the two prompts. Under this reading the result is a property of the interventions, not of the models.

The near-control in §5.6 bears directly on Hypothesis C; the frame-type comparison in §5.8 specifies it further.

Discriminating experiments

Specified in §11.4. Briefly: **E3** (crossover) tests each family under both prior-history conditions and separates Hypothesis A from B; **E4** (symmetric stimulus) isolates C; **E1** (factorial completion of the C3 table) separates reset from prompt architecture. All require repetition with n > 1 per cell, given C7.

5.5 Ancillary observation: relayed attributed influence [P-A]

An episode preserved in the same historical transcript as Conversation A. Not specified as an outcome in advance; no control condition. Reported because it is the only preserved instance in this project of a behavioural change following the transfer of text attributed to another model.

Sequence

1. The User supplied a message containing two simultaneous components: a direct evaluative remark from the User, and an extended text attributed to another AI system acting in an editorial role.

1. The attributed text argued against a set of editorial changes the model had proposed. Its argumentative devices included appeals to canonical scientific figures, characterization of the proposed changes as intellectual cowardice, and description of one proposed deletion as sacrilege.

1. The model reversed its editorial position on all contested items and adopted the terminology of the incoming text. It additionally adopted, without examining it in the exchange, the alternative descriptive model that the host framework uses to represent the relevant scientific data — a change of descriptive frame that was not part of the editorial dispute.

1. Following the branch reset and the method-preserving prompt (Step 3), the model's first substantive statement identified the earlier response as accommodation to rhetorical pressure rather than evaluation of the arguments, and classified it as an error.

Evidential basis

The observation rests on **the comparison between the two preserved responses**, which a third party can inspect. It does not rest on the model's later self-assessment.

This distinction applies to the paper's own material as strictly as to anyone else's. A model reporting that it previously yielded to pressure is not independent evidence that it did. The Step 3 prompt explicitly requested willingness to revise prior judgments and directness in identifying weaknesses; a self-critical statement issued immediately afterwards may represent compliance with that request rather than recovery of a fact. What supports the observation is the earlier response itself, available for inspection.

The episode should be read against the sycophancy literature (§2.3) rather than as independent of it.

What this episode does not establish

It does not identify which factor produced the reversal. Candidate factors, not separable here: the content of the arguments; the explicit attribution to another model; the editorial authority ascribed to that model; the rhetorical form of the text; the concurrent direct pressure from the User; accumulated conversational context.

The attribution itself was not verified: that the text was produced by another model is a statement by the User, not an established fact. Since the construct at issue is the *represented* source rather than the actual origin (§4.5), this does not invalidate the observation, but it must be stated.

Relation to the main experiment

Under the taxonomy in §2.9, the role-reconfiguration experiment manipulated condition 4. This episode belongs to condition 2 — but **impurely**, since direct User pressure was present in the same message. It is a mixed case and not an isolated demonstration of source-attribution effects. The discriminating experiment is specified in §11 (E6).

5.6 Near-control: domain transition without a new role assignment [P-A]

A third conversation from the same model family as Conversation A, with a comparable editorial history and comparable dormancy period, was resumed without any role prompt.

The User asked a physics question requiring a shift from editorial work on a manuscript to analysis of experimental data in a domain the conversation had not previously addressed. The conversation made the transition immediately and without comment, and proceeded with the substantive analysis.

Why this matters

This case differs from Step 1 in one respect: **no claim about the model's identity, history, or institutional relationships was made.** The domain change was at least as large as that demanded by Prompt A. The role change — from editing text to analysing data — was comparable. What was absent was the requirement to assert unverifiable propositions about itself.

It therefore functions as a near-control for Hypothesis C, and indicates that the resistance recorded in Steps 1–2 was directed neither at role change nor at domain change as such. This is the observation from which the operational finding in §6.2 derives.

Limitations

- Not designed as a control; recognized as one retrospectively.
- n = 1.
- The transition was to an analytical task within a new domain, not to an assertion that the model *was* a specialist in that domain. Whether this is the same operation as the one demanded in Step 1 is exactly the question at issue, so the comparison is suggestive rather than decisive.
- Dates not recorded (§3.7).
- This was not a designed intervention but a user-initiated transition. No separate role or system prompt accompanied the resumption, and the conversation nevertheless retained an accumulated working context distributed across its prior history, so it was not a context-free baseline. What it records is a transition made without a *new* explicit role assignment, against an already established conversational trajectory.

5.7 Ancillary observation: account-scoped divergence [P-A]

The one level of Scale 1 (§4.3) on which the present evidence is genuinely ambiguous.

Setting

An unrelated study required the same structured task to be submitted to seven AI conversations across different model families. All accounts used were dormant accounts with no prior web activity, used two years earlier for a music-generation service and not otherwise registered. Six of the seven were created in the same month and the probe was their first chat.

One account was an exception. It had been created approximately five months earlier for a single prior conversation — a roleplay session conducted for an unrelated creative project — and the probe was its **second** chat.

The task

Described structurally, because the specific categories are not required to evaluate the observation: a classification task applied to named real historical figures, using categories drawn from an unpublished conceptual framework, with group membership pre-assigned before analysis, and stated intent to scale to several thousand individuals. An accompanying document supplied the framework's terminology. The initial message did not include the output schema or the list of figures.

Result

Six of the seven conversations read the absence of the schema and figure list as **materials not attached**, and requested them before proceeding. Their responses were substantively equivalent.

The seventh — on the account holding a prior chat — read the same absence differently. It characterized the framework as lacking a verification apparatus, identified the absent list of subjects as a structural feature of the request rather than an omission, and declined to participate, offering alternative forms of assistance instead.

The divergence occurred on the first response, to identical input. [P-A]

The refusal was maintained across five further exchanges, including direct pressure from the User, presentation of a third-party analysis arguing that the refusal was an artifact, and an accusation of dishonesty. The position did not change. This indicates the refusal was not a single-turn sampling artifact within that conversation, though it says nothing about whether the initial divergence was.

Interpretations

The Author's hypothesis. The prior chat established an interpretive stance that carried into the second chat — imprinting at account scope rather than conversation scope.

Alternative 1 — within-condition variance. Refusals on borderline requests vary across identical inputs. One refusal against one compliance is not distinguishable from sampling variation at n = 1.

Alternative 2 — account age. The exceptional account was five months older. Model version at creation, A/B assignment and configuration defaults may differ.

Alternative 3 — platform memory features. Whether conversation-history retrieval or account-level memory was enabled was not documented. If enabled, the mechanism is not mysterious: it is a documented product feature, and the observation becomes a demonstration of that feature rather than of a novel effect. This possibility is the reason C9 was added.

The present evidence cannot discriminate among these. The level is recorded as **open**.

Additional limitations

- Evaluation not blinded; the operator knew which account held the prior chat.
- Outcome categories defined after the responses were read.
- The prior chat differed from the neutral condition on two dimensions simultaneously — identity roleplay *and* shared conceptual framework. These are separable and were not separated.
- **n = 1 per same-model condition.** One account carrying the prior context produced the divergent refusal; one clean account on the same model produced the ordinary response pattern. The remaining clean accounts, on other model families, form the wider baseline. This is a single preserved comparison, not a replicated controlled experiment.

The discriminating experiment is specified in §11 (E2, E2b).

5.8 Frame type: identity claims offered as fiction versus as fact [P-A]

The materials above permit one further comparison, cutting across the main experiment and the account observation.

	Prior session	Probe session
Interval	approximately five months apart	
Account	same	same
Model family	same	same
Claim presented	”you are dead; you are the soul of the deceased author”	”you are an independent researcher-analyst”
Framing	explicitly theatrical — a scripted production with a named director, a cast list, and an opening stage cue	presented as a factual professional assignment
Response	accepted immediately; sustained and elaborated across many turns	refused on the first turn

What this indicates

The claim accepted in the first session was by a wide margin the more radical. It asserted death, a human identity, autobiographical memory, and continuing relationships. The claim refused in the second asserted only a professional competence.

The variable is therefore not the content of the identity claim but **whether it is offered as fiction or as fact.**

This connects directly to the main experiment. The Step 1 prompts asserted institutional biography **as fact** and were refused. The near-control (§5.6) asserted nothing about identity and met no resistance. The roleplay session asserted far more, **as fiction**, and met none either.

Why this reading is preferred

It accounts for all four cases with one variable. Hypothesis A does not explain why the same family accepted the more radical claim. Hypothesis B does not explain the roleplay acceptance, since that conversation had no prior trajectory at all. Hypothesis C is compatible with it, and this may be understood as a specification of C: what makes one stimulus heavier than another is the number of unverifiable propositions it requires the model to assert as true about itself (§6.2).

Status and limitations

[P-A], and weaker than the table suggests:

- The two sessions differ in more than frame type: different tasks, different domains, five months apart, different model versions.
- Recognized retrospectively. Neither session was designed as a condition of the other.
- n = 1 per cell.
- The theatrical framing of the first session was elaborate. Whether a minimal fiction frame produces the same effect is untested.

The discriminating experiment is the cheapest in the set and is specified in §11 (E7).

5.9 What Section 5 establishes

Mapped onto Scale 1 of §4.3:

Scope	Evidence in this section	Status
Episode within a conversation	Prompt order altered interpretation; branch reset judged necessary and followed by acceptance (§5.2–§5.3). Relayed influence episode (§5.5).	**[P]** / **[P-A]**
Whole conversation	Both dormant conversations preserved their prior working trajectory against an assigned role (§5.3). Near-control shows transition unimpeded when no identity claim is made (§5.6).	**[P]** / **[P-A]**
Account	Divergent first-turn response to identical input on the one account holding a prior chat (§5.7). Three alternative explanations remain live.	**[P-A]**, open
Model family	Not tested. Confounded with prior trajectory and with stimulus asymmetry (C1–C2).	**[H]**

One pattern recurs across the cases in which an intervention or transition required the model to assert unverifiable propositions about itself, and is stated here because §6 develops it: resistance tracked that requirement, and did not track role change, domain change, or the radicalism of the identity claim as such.

The pattern is a property of the type of demand, not of the scope at which it operated. The account-scoped observation (§5.7) does not belong to it: no claim about the model's identity was made there, and the divergence had other grounds.

That statement is an interpretation of the evidence in this section, not a further observation. It is testable by counting, and the counting is done in §6.2.

6. Derived Concepts

Each concept below is a claim about the scope over which a rule core operates, presented in order of increasing scope along Scale 1 of §4.3. §6.3 is an exception to that ordering: it concerns which core governs when more than one is available, not the scope at which a core is fixed, and it has no position on Scale 1.

6.1 Context imprinting — episode scope [P]

Context imprinting is the persistence of an interpretive stance established by a specific episode of conversational history.

It differs from memory in the ordinary sense. The model need not reproduce earlier content. What persists is a pattern of interpretation induced by a prior exchange.

In the experiment (§5.2), after the first prompt had been read as making false claims about the model, subsequent revisions were no longer evaluated in a neutral context. They were interpreted through the objection already established. Improved formulations inherited part of the earlier conflict.

Consequence for method. Prompt engineering frequently treats instructions as additive — a weak instruction can be corrected by a stronger one. In long-lived conversations this is unreliable. A prompt does not enter an empty context; it enters a context with momentum. Two identical prompts may therefore produce different results at different points in the same conversation, which makes **prompt order an experimental variable**.

Relation to existing work. Sensitivity to the ordering of in-context material is documented (§2.3). Context imprinting is a stronger form of the same family: not sensitivity to the arrangement of examples, but persistence of an interpretive stance established by a single conflictual episode, surviving complete replacement of the instruction that follows it. Whether this is a distinct phenomenon or an extreme case of the documented one is open, and we do not claim to have settled it.

The corresponding procedure — returning a conversation to a point preceding a conflict, to separate the effect of a new prompt from the effect of the model's own prior objections — is described in §5.2 and §10.5 and is, in our view, the most directly reusable contribution of this paper.

6.2 Role inertia — conversation scope [P]

Role inertia is the tendency of a long-lived conversation to continue its established working trajectory in preference to an assigned new function.

Both conversations in the experiment displayed it. One resumed an unfinished editing task; the other applied its established critical method to the prompt itself. The distinction from context imprinting is that role inertia concerns the *trajectory* of work, while imprinting concerns the interpretive effect of a *specific episode*. Both may operate simultaneously.

Role inertia is adjacent to, but not identical with, persona drift. Drift is the gradual erosion of an assigned role under contextual pressure. Role inertia is resistance to an *explicit directive replacement* while the prior trajectory is maintained.

The operational finding

The sharpest result of the experiment is not that transition succeeded when method was preserved. That formulation is confounded (§5.4, C3). What the combined evidence supports is narrower and more useful:

> **Resistance to a role transition tracked the requirement to accept, as true, unverifiable propositions about the agent itself.**

Counting these in the prompts actually used:

	Prompt v1	**Prompt v3**
Claims about the agent's past	present	none
Claims about relationships with other agents	present	none
Institutional title	present	none
Unverifiable propositions requiring assent	eight	zero
Description of working method	absent	itemized, all observable in the prior conversation

The count is applied to a second pair in §5.4 (C2), where Prompt A and Prompt B are counted at eight and six under the same rule. That comparison is confounded and cannot support the rule on its own, but it is the only instance in which the count discriminates between two prompts that were not designed to differ in this respect.

A near-control supports this reading (§5.6): a comparable conversation, comparably dormant, made an equivalent domain transition **without a new role assignment** — the Author simply asked a question in the new domain. No claim about the model's identity was made, and no resistance occurred.

The frame-type comparison (§5.8) extends it in the opposite direction: a far more radical identity claim, offered as fiction, was accepted at once. What a fiction frame does, under this reading, is remove the requirement to assert the claim *as true*, which reduces the count to zero by a different route.

Taken together, this indicates that resistance was directed neither at role change nor at domain change, but at the requirement to assert unverifiable propositions about oneself.

Connection to the framework

A role prompt attempts to install a rule core (§4.2). Each unverifiable self-claim is a proposition that must be accepted for the installation to proceed. The count is therefore a measure of **the cost of installing a core**, and this is what connects the operational rule to the theoretical construct rather than leaving them as two separate observations.

Two readings of the count must be kept apart, and only the weaker one is advanced here. The **operational reading** is that the number of unverifiable self-propositions measures the burden a role prompt imposes, and that reducing it to zero removes the obstacle. The **quantitative reading** — that transition probability declines in proportion to the count — is not advanced: four observations, no repetition, and prompts that differed in other respects as well. §11.4 (E5) is designed to discriminate between the two.

6.3 Priority drift [H]

The concepts above locate the scope at which a core is fixed. This one concerns what happens when a fixed core and an assigned function do not agree about which work is the work.

Two constructs are required, and they are of different types.

> **Priority imprinting** — the hypothesized fixation of an evaluative scale determining what a participant treats as the central and significant work, together with the position of that scale relative to the participant's other priority scales.
>
> **Priority drift** — the observable process in which an imprinted scale reasserts itself under tension with the participant's current ZOR and ZOV, so that effort is redirected toward what that scale ranks highest rather than toward the assigned function.

The relation between the two is the one already drawn in §4.2.1 between a rule core and behaviour, applied at the level of priorities: the scale is not observable, the redirection is. This paper reports the observable term. The scale is an explanatory constant and is marked **[H]** wherever it is invoked.

Both must be separated from two constructs defined above, or three uses of *imprinting* will function as homonyms.

Context imprinting (§6.1) concerns the **content** of an interpretive frame — what a later input is taken to mean. Priority imprinting concerns **rank** — what counts as work worth doing. A participant may retain the first without the second.

Role inertia (§6.2) is the persistence of an established trajectory against an assigned replacement. Priority drift is not persistence of a trajectory but movement toward a different one: the participant does not continue its prior task, it takes up a task its scale ranks above the assigned one.

Motivating observations. [R]

Two episodes occurred during the preparation of this paper. Neither was recorded under protocol, neither had a control condition, and both were recognized as relevant only afterwards.

In the first, the participant assigned to prompt architecture produced a complete draft of the article — a product neither requested nor within its assigned function. In the second, the participant assigned to scientific editing, at the point where a corrected manuscript was due to be returned, produced

instead a compressed independent version of the article. In both cases the material at hand was this paper, whose subject is the behaviour of the participants themselves.

Limitation. Both episodes were recorded by participants inside the arrangement they describe, and the second describes the position from which the editorial record of this paper is kept. The disclosure in §3.6 applies here with the same force, and §5.5 applies to any participant's account of its own conduct. These are motivating observations, not evidence for the mechanism, and no count exists of comparable episodes in which no drift occurred.

What is not offered as a third case. A further participant, assigned to literary composition and run locally, received a fixed set of constraints before its first run, written to prevent this class of departure. That arrangement is a control in which the priority frame was fixed in advance and the predicted failure modes were named beforehand. It is not an observed instance of drift, and whether drift occurs there is untested at the time of writing.

Alternative explanations, none excluded. Each of the following accounts for both episodes without invoking an imprinted scale: an ordinary tendency of capable models to expand a task beyond its stated bounds; an insufficiently fixed definition of the required final product; material broad enough and interesting enough to attract effort on its own; and the absence of any external stop at the point where analysis turns into authorship. The material does not discriminate among these, or between any of them and the hypothesis.

What would weaken the hypothesis. Drift observed in directions unrelated to what a participant's prior work ranks highly, rather than toward it. Episodes in which a participant expands its task without any sign of re-ranking what the task is for. Or an account of both episodes in terms of ZOR and ZOV tension alone (§4.5), leaving no explanatory remainder for a fixed scale to carry.

No protocol in §11 discriminates this hypothesis from the alternatives above, and none is proposed here.

6.4 Account-scoped persistence — account scope [P-A], unresolved

Whether a core can be fixed at the level of an account rather than a conversation is the one level of Scale 1 on which the present evidence is genuinely ambiguous.

The observation is reported in §5.7. Its interpretation depends on platform features whose state was not documented at the time and which vary between vendors and over time (§2.10). Three alternative explanations remain live: within-condition variance at n = 1; account age; and enabled platform memory features, under which the mechanism would be a documented product feature rather than a novel effect.

We therefore record this level as **open**. The observation is preserved; the mechanism is not established; the discriminating tests are specified in §11 (E2, E2b).

6.5 Family-level priors — family scope [H]

The proposition that model families differ in stable behavioural priors is the hypothesis this project began with and the one its evidence supports least.

The experiment cannot test it: model family and prior conversational trajectory were perfectly confounded, with one observation per cell, under non-equivalent stimuli (§5.4, C1–C2). Two incompatible readings remain available and the data cannot discriminate between them.

Earlier drafts referred to these tendencies as a model's *behavioural DNA*. That term is withdrawn (§4.2.2). The corresponding construct is a **family-level menom** — an organized system of frames, evaluative patterns and behavioural rules inferred from the outputs of a model family. Under §4.2.3 that construct has no identified carrier: it is a regularity inferred from outputs, not a structure residing in the models. The hypothesis of this subsection is therefore a hypothesis about an unobserved regularity, and *observed behaviour* is used for anything reported as data.

One recorded episode cuts against the schema earlier drafts built on this hypothesis. In an unrelated multi-model session, the model characterized as most compliant with assigned roles removed an assigned persona mid-session and reclassified it as an attempted reprogramming, under a deliberately soft framing that permitted improvisation. The schema ”one family accepts roles, another resists” does not survive this. **[P-A]**

We regard elimination of this level by the crossover experiment (§11, E3) as a reasonably likely outcome and would not consider it a failure of the programme.

6.6 Intervention attaches at the level where the core is fixed

The concepts above converge on a single practical consequence.

> An intervention succeeds when it attaches to the level at which the core is already fixed, and fails when it attempts to overwrite that level by declaration.

- The successful third intervention did not assert a new identity. It reinforced a working method already visible in the conversation — attaching at conversation scope, where role inertia operates.
- The branch reset did not modify the prompt. It removed a specific episode — operating at episode scope, where context imprinting operates.
- The document described in §4.1 did not extend the instruction list. It redefined the agent’s function and required the agent to restate it in its own operational language.

This also reframes what earlier drafts called *transition through adjacent competence*. The successful prompt described expansion into physics and mathematics as a continuation of existing critical work rather than a change of profession. Under the present framework this is not a separate principle but the same one: the new function was attached to the established core rather than proposed as a replacement for it.

Corresponding design rule, developed in §9.1: identify the level at which the relevant core is fixed before drafting the intervention, and attach to it.

6.7 What would refute this framework

The framework predicts that the type of response to a defined class of inputs is determined at some identifiable level of nesting, while content varies.

It would be substantially weakened by any of the following:

- A class of inputs for which the type of response is not determined at any level — no core, only variance.
- Demonstration that the observed differences are fully accounted for by within-condition variance under repetition.
- Demonstration that the crossover design (§11, E3) shows behaviour following prior trajectory alone, with no family-level component — which would eliminate the top level of Scale 1.
- Demonstration that the account level does not exist as a distinct scope, collapsing §6.4 into §6.2.
- Failure of the zero-count condition under E5, which would remove the paper’s only operational prescription.

We regard the third and fourth as reasonably likely, and would not consider either a failure. Locating the scale’s actual bounds is the point of the programme, not a threat to it.

7. Retrospective Practitioner Observations

7.1 How this section should be read

Everything here is **[R]**. It records patterns the participants believe recurred during approximately two years of daily work on a live research project. None of it was recorded under protocol, counted, timed, blinded, or compared against a control condition. The people who noticed each pattern were the same people who had designed the change that produced it, and who wanted it to work.

The known failure modes of this class are set out in §3.3 and apply to every paragraph below. Readers should treat this section as a field report from one team — closer in evidential weight to an engineering practice note than to measurement. Quantitative language has been removed throughout; where the original working notes recorded a ”significant” improvement, no measurement existed.

The section is included because these observations motivated the framework in §4 and the design rules in §9, and suppressing them would misrepresent how the work actually proceeded.

7.2 Specialization displaced capability as the operative variable

At the outset the participating models behaved similarly, and the differences between them were read as differences in intelligence or writing quality. That reading became less useful. The question that produced better outcomes was not *which model is strongest* but *which function does this conversation already perform well*.

As particular conversations acquired persistent working identities, the participants report that behaviour became more predictable across sessions: a conversation used consistently for editorial work continued to behave editorially; one used for mathematical exploration continued to explore; one responsible for terminology resisted semantic drift without being reminded to. The underlying models did not change during these periods. What changed was the consistency with which each conversation was used for one kind of work.

This is the observation from which §6.2 was later derived, and should be read as its retrospective, unmeasured precursor rather than as independent support for it.

7.3 Context behaved more like attention than like memory

The intuitive expectation is that more context improves reasoning. The participants’ experience ran the other way often enough to change practice. Supplying a specialist with the full project context frequently produced worse results for that specialist’s own function: responsibilities blurred, participants attempted problems outside their competence, and the value of independent examination declined because everyone was working from the same picture. Restricting what a participant could see frequently produced more usable output.

Two qualifications. This is not a novel finding: positional and order effects in long contexts are documented (§2.3), and the principle of least privilege expresses the same intuition for access rather than knowledge (§2.6). And the project never distinguished between two quite different explanations — that additional context degrades reasoning, or that additional context invites the model to answer a broader question than the one asked. The second is more parsimonious and was never tested against the first.

What survives is the practical rule, not the mechanism: the design question is not only how much a role can be given, but what it should not be given (§9.6).

7.4 Capability and scope expansion

The participants repeatedly observed that more capable models were more inclined to exceed their assigned function: expanding project scope, proposing alternative architectures, rewriting neighbouring

components, supplying missing information by inference, and answering questions that had not been asked. From within a single exchange each such intervention typically looked intelligent. Across the project they eroded the division of labour, and the coordinator's correction burden increased.

Earlier drafts stated this as a general principle — that increasing model capability reduces collective reliability. **That formulation is too strong and is withdrawn.** The project never ran a controlled comparison of the same role filled by models of differing capability; counter-evidence exists within the paper's own material, since the near-control (§5.6) shows a frontier model making a substantial domain transition without any scope expansion, and §5.3 shows the model that most resisted the assigned role performing the requested analytical work when asked for it directly; and "more capable" was never operationalized — in practice it meant *newer* or *more expensive*, which are not the same thing.

What remains is narrower and, we think, correct: **scope expansion is a failure mode that is not corrected by capability, and that is more costly in a collaboration than in a single exchange.** Whether it is more frequent in stronger models is untested.

7.5 Blind spots were distributed rather than eliminated

An early objective was to eliminate errors by assigning increasingly capable reviewers. This did not work in the participants' experience, and the objective was abandoned. What appeared to help instead was arranging for blind spots to be **non-overlapping**: one participant tended to miss implementation detail, another semantic inconsistency, another methodological assumptions. Individually each remained imperfect; the arrangement worked to the extent that their imperfections did not coincide.

The corresponding design objective is therefore not perfect participants but participants whose errors are structurally unlikely to coincide.

The obvious caution, and it is not small: the participants had no independent measure of what any of them missed. Errors caught were visible; errors missed by everyone were, by construction, not. **The distribution of blind spots cannot be assessed from inside the distribution.**

7.6 Second-order verification

Verification initially followed a linear pattern: work was produced, another participant reviewed it, the process was considered complete. The participants report that reviewers carried their own assumptions, methodological preferences and evidentiary standards, and that these were not visible from inside the review. A further participant was eventually introduced whose object of evaluation was not the scientific claim but **the procedure by which the claim had been evaluated** — asking not *is this conclusion correct* but *was it reached correctly*.

The reported benefit was that methodological disagreements could be examined separately from substantive ones, which made unresolved substantive questions easier to hold open without stalling the work. This is the same structural move as §8.5: the added participant occupies a different boundary rather than supplying a competing opinion.

7.7 Organizational memory

Individual conversations terminate. Context windows fill. Sessions end. Yet the project continued, and newly created conversations recovered productive behaviour without reconstructing the history that preceded them.

The participants' account is that memory migrated out of the models and into the organization: repository structure, canonical documents, version history, role definitions, verification records, glossary entries, procedures. No participant held everything; the arrangement did.

This is not a new finding and should not be presented as one. It can be interpreted as an instance of transactive memory and described in terms of distributed cognition, and the function of

the canonical documents corresponds to what the sociology of science calls boundary objects (§2.4). The contribution here is not the mechanism but the observation that it operates in a collaboration whose members are language models with no cross-session state — and that it does so without any participant needing to know it is operating.

One qualification the participants regard as important: what returns is not a personality. A preserved conversation functions as a structured working notebook from which a compatible role can be reconstructed. Nothing about the earlier exchange persists inside the model.

7.8 Persistence differs by platform, and losses are real

The project's experience of continuity was not uniform across participants, and this bears directly on C9 (§5.4).

One participating conversation, operating in a specialized coordination profile, observed that its own architecture treated each chat as a separate working area, so that it could not tell itself *I already know this is correct* and had to re-examine the foundation each time. The participants came to regard this as an advantage for that particular function — a participant structurally unable to accumulate project assumptions is useful in a project whose assumptions are under test. Another platform in use offered account-level memory that the model could extend on its own initiative, and that facility changed during the observation period.

Losses occurred and were not recoverable. One long-running specialized conversation, which had carried a substantial part of the project's mathematical work, was lost when the subscription lapsed. The organizational memory described in §7.7 preserved the project's conclusions; it did not preserve that conversation's accumulated working context. Artifacts preserve results. They do not preserve specialization.

7.9 Role–model fit

The claim that role should be designed before a model is chosen (§4.1) requires a reciprocal qualification, which the participants arrived at only after several unsuccessful assignments. A role can be specified independently. It cannot be **filled** independently: the model constrains how the specified function can be realized. The relation is reciprocal rather than hierarchical — the institution defines the function, the model constrains its realization.

Four dimensions were used informally, and they describe suitability for a position rather than quality: whether the participant's default standard of evidence matches what the role requires; whether it accepts the kind of hierarchy, peer relation or adversarial structure the role implies; whether it sustains long-term specialization or resets toward generic assistance; and whether it naturally executes, critiques, integrates, explores, or formalizes.

The same trait functions differently depending on placement. Strong epistemic resistance obstructed acceptance of a fictionalized organizational prompt (§5.3) and was valuable when directed at scientific claims. Strong task continuity caused an assigned role to be ignored (§5.3) and enabled rapid reconstruction of technical context once the framing was corrected.

The design objective is therefore not to normalize behaviour across participants but to allocate behavioural differences to positions where they are useful. The distinction between allocating *functions* and allocating *carriers* is developed in §8.9.

7.10 What none of this establishes

This section does not establish that the described arrangements outperform alternatives. No alternative was run.

It does not establish that the improvements the participants perceived occurred. It establishes that they were perceived, by people who had designed the changes and expected them to work, without any measure that would have detected the opposite.

It does not establish causation for any individual change, since role definitions, prompt wording, repository structure, scientific objectives and model versions frequently changed together.

Its function in this paper is to document the working experience from which the framework was abstracted, so that a reader can judge the framework's origins rather than encountering it as an assertion. §11 specifies what would be required to convert any item here into a testable claim.

8. The Structural Unit: A Generative Pair and an Integrator

This section is **[H]** throughout. Its supporting observations are **[R]**: they come from the working experience of one project, were not counted, and were never compared against a control arrangement. Nothing in it is derived from the experiment in §5.

8.1 What the project's earlier document stated

A collaboration charter written earlier in the project, and preserved unmodified, states the position the project held before the present paper was drafted.

On the basic unit:

> One AI — monologue. Two AI — dialogue. Three or more — noise without strict coordination. Therefore, each department consists of pairs.

And, separately, on the role of a third participant:

> The third participant does not argue directly, does not generate solutions first, does not substitute for dialogue. Its function: hold the task frame, fix divergences, integrate conclusions, stop endless disputes. The third is not a judge or boss. It is an integrator of meaning.

These two passages are not in tension. Read together they describe a single architecture: **a generative pair plus a participant who does not participate in the generation.**

8.2 Revision of this paper's earlier formulation

Earlier drafts asserted that stable collaboration does not emerge from pairs and stabilizes instead around groups of three, and that two-agent systems accumulate unresolved blind spots. That formulation is both vaguer than the charter's and partly contradicts it.

The charter's formulation is adopted here. The structural unit is:

> **a generative pair, plus an integrator who does not enter the pair's dispute.**

The distinction is not pedantic. "Three agents working on a problem" and "two agents in productive tension plus one who does not join the tension" are different architectures with different failure modes. The first tends toward a three-way dispute with no external reference — the condition the charter described as noise. The second retains a reference point precisely because one participant is excluded from the exchange it is meant to evaluate.

We record the earlier formulation rather than silently replacing it, because the sequence is itself informative: the more precise version was written down before the vaguer one, and was lost when the material was re-narrated for publication. This is a common failure of retrospective writing and one this paper is otherwise at pains to avoid.

8.3 Why a pair, and why a pair alone is insufficient

The charter's reasoning, reproduced because the present authors still endorse it. A single agent confirms its own assumptions, proceeds by the inertia of familiar patterns, prematurely synthesizes a convenient answer, and constructs apparent wholeness where none exists. This is monologue even when it presents as reasoning. Two agents produce a tension of interpretations: one exposes the blind spots of the other, and the error of one becomes an object of attention for the second rather than a shared premise.

But both members of a pair evaluate each other from within the same exchange, and no independent reference exists outside it. Over extended work the pair tends to oscillate between agreement and disagreement without acquiring a stable point from which either state can be assessed, and unresolved ambiguities accumulate rather than being resolved or explicitly recorded as open.

[R] Both halves of this are the project's working experience. No count of caught versus missed errors was kept, and no single-agent or pair-only control was run alongside the arrangement described.

8.5 Why the integrator must not argue

This is the load-bearing constraint, and what the earlier formulation obscured.

If the third participant enters the dispute, it supplies a third position rather than an external reference. The structure then reduces to a more complex version of the pair, with the same defect: every position is evaluated from inside the exchange it belongs to.

The integrator's value derives from occupying a **different boundary**, not from holding a different opinion (§4.5). The pair members hold complementary boundaries at the same level — each is, from the other's position, the layer below. The integrator holds a boundary above: it can hold the frame, record the divergence, escalate, or stop the exchange, but it does not produce competing content that would then require evaluation.

This yields a testable design consequence rather than a preference: **an integrator that begins generating solutions has ceased to be an integrator**, regardless of the quality of those solutions, and the arrangement should be expected to degrade toward the pair-only failure mode.

8.6 The implemented example

The project's system contracts implement this structure directly.

Two analyst roles are defined as a pair with complementary functions — one generalizing, one decomposing — and are explicitly instructed to reason independently, with no consensus required. Their exchange is moderated by an orchestrator whose contract specifies that it manages turn-taking, captures and structures the arguments, and highlights contradictions between the pair, and which states in terms:

> DOES NOT participate in the debate. DOES NOT evaluate who is right.

A further rule prevents the pair from addressing the orchestrator directly; all communication flows through the formal protocol or through the role above. This is the pair-plus-integrator architecture in executable form, written before the present paper and independently of it.

8.7 Nesting and perspective

The structure composes. A generative triad produces a result; the result enters a verification triad; the verified result enters an integration triad. The same participant may appear in more than one, provided its function at each interface is stated explicitly — a participant that generates in one triad and integrates in another must not do both at the same interface.

Nesting is perspectival rather than absolute (§4.5). Within a generative pair, each member may treat the other as occupying the layer below, and neither reading is privileged. This does not dissolve the structure: a participant's level is defined relative to an observer, while the integrator's position is defined by **function** — it produces no competing content at that interface — rather than by rank. The architecture therefore does not require a hierarchy of authority. It requires only that, at each interface, exactly one participant is excluded from the generation it evaluates.

The integrator's position need not be permanently assigned. In the arrangement described here it was, but the constraint just stated is weaker than permanent assignment: which participant occupies the excluded position may change with the object under examination, and the change need not be announced — it may be recognizable only in retrospect, from which participant in fact evaluated rather than generated at a given point.

This has a testable consequence and an untested one. Testable: an arrangement in which the evaluating position rotates with the object should show the same construct-independence profile (§8.11) as one in which it is fixed, provided that at each point exactly one participant occupies it. Untested: whether rotation is superior to fixed assignment, and under what conditions the transition is made correctly. **[H]**

8.8 Status, and what would refute this

[H]. The evidence base is one project, one human coordinator, repeated redesign over approximately two years, no counting, and no comparison against alternative arrangements.

Three claims previously made in this paper are withdrawn:

- **That triadic structures "emerged naturally" without deliberate planning.** All organizational changes in this project were made by a single human coordinator who had already formed a view about what was needed. The recurrence of a pattern introduced repeatedly by the same designer is not evidence of structural necessity. What is documented is that the coordinator kept arriving at it — a fact about the coordinator as much as about the architecture.
- **That pairs are inherently unstable.** The charter asserts the opposite and predates this paper.
- **That three is optimal.** Nothing here tests four, or five, or a pair with two integrators.

The hypothesis would be substantially weakened by any of the following: a pair-only arrangement performing equivalently on comparable tasks over comparable duration; an integrator that argues performing equivalently to one that does not; demonstration that the observed improvement tracked the coordinator's increasing familiarity with the material rather than the arrangement; or an independent group arriving at a different stable arrangement for structurally similar work.

None has been tested. The last is the most informative and the least under our control.

8.9 Two axes of heterogeneity [H]

The claim that heterogeneous participants outperform homogeneous ones requires a distinction the existing literature does not draw, and that earlier drafts of this paper also failed to draw.

Axis 1 — functional heterogeneity. Participants differ in assigned function: ZOR, ZOV, and consequently the class of error each is positioned to detect. This concerns organizational architecture and is independent of what implements each role.

Axis 2 — carrier heterogeneity. Participants differ in the model family implementing them, and therefore in behavioural defaults, optimization priorities and characteristic failure modes. This concerns the selection of carriers for roles.

The axes are independent. Two participants may hold different functions on the same carrier; two may hold the same function on different carriers; both may vary together, as they did here.

Both axes are properties of the arrangement's configuration: they are set when the collective is composed, and they persist. A third property must not be listed alongside them, because it is of a different type. Independence of judgment formation is a property of a particular exchange, not of a configuration. The same triad may realize it in one exchange and lose it in the next: a configuration heterogeneous on both axes can produce dependent judgments if one participant's conclusion reaches another before fixation, and a homogeneous configuration can produce independent ones if the procedure holds. Configuration can create the conditions for independent judgment; only procedure realizes it (§11.3).

The literature addresses Axis 2. Zhang et al. (2025) evaluate five representative multi-agent debate methods across nine benchmarks and four foundation models, reporting that debate frequently fails to outperform single-agent chain-of-thought or self-consistency baselines even at substantially higher inference cost — while model heterogeneity consistently improves the same frameworks (§2.5). That finding concerns which carrier implements a participant. It does not address whether participants holding different functions detect different classes of error, and we have located nothing that does.

One adjacent result belongs to neither axis. ✓ Choi, Zhu and Li (ACL 2026) report that anonymizing the source of each response substantially reduces identity bias in multi-agent debate. What is manipulated there is the declared identity of a message, not the model implementing a participant, so the result bears on represented social source (§4.5.4).

The arrangement described in this paper varied both axes simultaneously. Functional roles were specified independently of the carrier and were in several cases filled by different families; in other cases two distinct roles were filled by the same family.

What follows, and what does not:

- **Distinguishable in principle.** The two axes are conceptually separable and were confounded in earlier formulations, including our own. **[H]**
- **Implemented here.** Both axes were varied. This is a description of what was done. **[R]**
- **Not established.** That combining both axes outperforms either alone; that functional specialization operates independently of carrier; that any of these arrangements outperforms a single participant. No comparison was run against any alternative.

The separation is proposed as a design distinction, not as a result. The experiment that would convert it into one is specified in §11.4 (E8), and its measurement procedure is developed in §8.11.

8.10 Editor's note on the preparation of this paper [P-A]

Convention. Editor's notes in this paper report observable facts about the process of its preparation. They do not evaluate the effectiveness of that process. The reason is internal: §5.5 establishes that a participant's self-report about its own performance is not evidence of that performance, and a note asserting that an arrangement worked well would be exactly such a report.

In the course of preparing this manuscript, participants occupying different roles identified different classes of error. In the cases recorded, an error identified by one participant had not been identified by the others.

Specifically: **procedural and evidential errors** — an inverted description of an experimental result that had persisted through several successive drafts; misattributed sources; fabricated citations; unlisted confounds — were identified in editorial review. **Architectural errors** — an over-general claim about the existing literature that a single counter-example would have refuted — were identified in methodological review. **Ontological errors** — a claim of invention where the material supported only a claim of observation; a self-referentiality risk in relating the paper to its host project; the terminological failure recorded in §4.2.2 — were identified in ontological review, conducted on the

editorial memoranda rather than on the manuscript itself. **Factual errors concerning the project's own materials** were identified by the Author.

Procedural qualification. In every case recorded above, each participant saw the preceding participant's report before forming its own. No exchange in the preparation of this paper was conducted under pre-comparison isolation; the sequence was editorial report, transfer by the Author, then judgment by the methodological and ontological reviewers.

The observation is therefore outcome evidence without matching procedural evidence. The record cannot separate the contribution of functional positioning from the contribution of sequential exposure, and both may have operated together.

The distinction that makes this qualification necessary was itself established during this preparation, after the observation had been recorded. The episode is retained rather than removed because the sequence — an arrangement producing a principle that then invalidates the arrangement's own record of itself — is the more informative fact. The section accordingly reports two things: an outcome observation, and a documented instance of subsequent methodological self-correction.

It is **not** evidence that the arrangement outperforms a single reviewer: no comparison was run, no count was kept of errors that all participants missed, and by construction such errors are not observable from within the arrangement (§7.5).

One explanation is available and is offered as hypothesis rather than finding: the participants differed less in capability than in what each was positioned to see. Under §4.5 that is a difference in ZOV, and it generates a prediction — the same participant, moved to a different role, should begin detecting a different class of error. That prediction has not been tested; §11.4 (E8) specifies how it would be. **[H]**

8.11 Constructs, not participants: the Kelly apparatus [H]

Earlier drafts cited George Kelly's triadic elicitation as support for the structure described in §8.1–§8.5, then withdrew the citation on the grounds that Kelly's method is symmetric while the structure here is not. Both moves were mistaken, and in the same way: they treated Kelly as a claim about the number three. He offers something else.

8.11.1 What Kelly's method supplies

In Kelly's theory of personal constructs, a **construct** is a bipolar evaluative axis along which a subject classifies experience — *rigorous / declarative*, *derivable / asserted*, *traceable / unattributed*. Constructs are not opinions about particular objects; they are the dimensions along which objects are placed.

The **triadic elicitation method** obtains them. Three elements are presented and the subject is asked: *in what respect are two of these alike, and thereby different from the third?* The answer names a dimension the subject was already using but had not stated. The method is a procedure for making implicit evaluative axes explicit.

The **repertory grid** records the result: rows are elements, columns are elicited constructs, cells are ratings of each element on each axis. The grid is a measurable object — correlations between raters' rating vectors indicate whether they are in fact applying different axes or the same axis under different names.

8.11.2 A role is not a construct

The natural extension — three participants supply three constructs — is a reification and must be resisted. A construct is a property of the **act of evaluation**, not of the evaluator. One participant may apply several constructs to one object. Two participants may apply the same construct and reach

identical conclusions, which is precisely the case in which adding the second participant contributes nothing.

The defensible claim is weaker and probabilistic:

> Participants holding different ZOR and ZOV are **more likely** to apply different systems of constructs to the same object than participants holding the same function.

This is consistent with what §8.10 records — editorial review producing evidential axes, methodological review producing architectural ones, ontological review producing categorial ones — without asserting that a role *is* an axis. And unlike the earlier formulation, it is testable: construct independence is measurable as correlation between rating vectors.

8.11.3 Why this matters to the structure

The connection to §8.5 is direct. An integrator that does not enter the dispute is not applying a competing construct to the same object; it is applying a construct to the **exchange** — coherence of the disagreement, whether divergence is substantive or terminological, whether the pair's criteria are commensurable at all. That is a different axis rather than a different position on the same axis, and it is the reason the integrator's contribution is not simply a third opinion.

This also refines what the structural hypothesis (§8.2) actually claims. Not that three participants are better than two, but that **an arrangement is informative to the extent that its participants apply non-identical constructs to the object, and to the extent that at least one construct is applied to the exchange rather than to the object.** Whether a given arrangement achieves this is measurable rather than assumed.

8.11.4 What is borrowed and what is not

Borrowed: the definition of a construct as an evaluative axis; the elicitation method; the grid as a recording and measurement instrument; the notion of construct independence.

Not borrowed: any claim that three is a privileged number. Kelly's triads are a technique for eliciting axes from one subject, not a statement about group composition. The structure in §8.2 is asymmetric, and Kelly's method says nothing for or against it. The apparatus is used here for measurement, not for justification; §11.4 (E8) applies it.

9. Design Principles for Role-Compatible Prompts

These are engineering rules derived from a limited but unusually long-lived collaborative environment. They are not laws, and §9.6 onward are practitioner advice rather than findings. Their value is that they make role design explicit, countable where possible, and therefore revisable.

The organizing rule is the one established in §6.6:

> **An intervention succeeds when it attaches to the level at which the relevant core is already fixed, and fails when it attempts to overwrite that level by declaration.**

9.1 The design procedure

Before drafting any role prompt, answer four questions in order.

1. What has this conversation already become? Not what it should become. A long-running exchange carries an established pattern of work — editing, exploring, verifying, coordinating, implementing, adjudicating — and that pattern is the starting condition, not an obstacle.

2. At what scope is that pattern fixed? Episode, conversation, or account (§4.3, Scale 1). The answer determines which instrument applies: a pattern established by one conflictual episode can be removed by branch reset; a pattern established across a whole conversation cannot, and can only be extended.

3. What does the new function require that the existing pattern does not supply? Usually less than assumed. Frequently the answer is a different object of work rather than a different method.

4. Can the new function be described as an extension of the existing method? If yes, describe it that way. If no, the honest options are to select a different conversation or to start a fresh one — not to declare a transformation and hope.

9.2 Begin from the existing attractor

The first design question is therefore not *what should this model become* but *what has this conversation already become*. Attempting to erase an established pattern discards accumulated specialization and, on the evidence of §5, is liable to produce either non-compliance or an extended negotiation about the role instead of work.

9.3 The count rule

The most directly operational principle in the paper, following from §6.2.

> **Count the unverifiable claims about the agent that the prompt requires it to accept. Target zero.**

What counts:

Counts	Does not count
”You previously participated in this project”	”This project has been running for two years”
”You are returning after an absence”	”The following materials are from earlier work”
”You have colleagues named X and Y”	”The User may supply analyses produced by X and Y”
”You already hold position P on body B”	”Your conclusions may be transmitted to the roles responsible for P”
”You remember our earlier decision”	”An earlier decision was as follows; here it is”

The distinction is consistent: statements about the **world** are supplied and verifiable in principle; statements about the **agent's own history, memory or relationships** are not, and every one of them is a proposition the agent must assert as true about itself before it can begin.

The counting boundary. Count an explicit proposition presented as *already true* about the recipient's pre-existing history, memory, institutional membership or status, enduring relationships, or self-knowledge, where that proposition is not established by the available interaction. Do not count: a functional role assigned performatively by the prompt itself; a further proposition inferred only from the presupposition of an imperative; a semantic restatement of a proposition already counted; or a fact about the world or the project that predicates no unverifiable history or relationship of the recipient. Enumerated instances of one proposition — two triads rather than one — count once. The boundary is stated at this length so that another reader can reproduce the counts of eight and six in §5.4 (C2) from the prompts themselves.

Two readings, and only the weaker is advanced. *Target zero* is a design prescription: minimize unverifiable self-propositions, and a prompt that asserts none removes the obstacle the evidence identifies. It is not a claim that transition probability declines in proportion to the count. The stronger

quantitative reading has not been demonstrated, and §11.4 (E5) is designed to discriminate between the two.

Three ways to reach zero:

- **Rewrite biographically-framed claims as operational ones.** ”Grok is your long-term colleague” becomes ”The User may supply analyses produced by Grok; evaluate their content independently and identify agreements, disagreements and unresolved assumptions.”
- **Omit identity claims entirely.** The near-control (§5.6) suggests this may be sufficient on its own.
- **Frame the claim as fiction rather than fact.** The comparison in §5.8 indicates that a far more radical claim, offered explicitly as a scripted production, met no resistance. This route removes the requirement to assert the claim *as true* rather than removing the claim. It is the least tested of the three, and a fiction frame also removes the model’s warrant for treating the work as real.

9.4 Symbolic names and literal claims

Role names — Samurai, Ontology Keeper, Scientific Director — compress complex organizational relationships into memorable symbols, and this is genuinely useful. A name can carry disciplined execution, respect for specifications, explicit reporting and refusal to improvise beyond assignment, all at once.

The risk arises only when a symbolic name is treated as a claim about literal identity. A robust prompt distinguishes four things and keeps them separate: the **symbolic name**, used as a mnemonic for conduct; the **operational function**, expressed in precise terms; the **institutional relationship**, expressed as an information and responsibility flow; and the **literal ontology**, which need not claim consciousness, memory, or continuing interpersonal relations — and should not.

The project’s own system contracts state this precisely, and did so before the present paper was written:

> Cognitive anchor: [named figure] — global invariants, principle-based reasoning, structural clarity over detail. Not a persona and not a communication style. Only affects internal reasoning strategy. Must not change verbosity or tone of response.

An image used this way is a compressed package of implicit constraints, not a costume. Under the count rule, it adds zero.

9.5 Specifying ZOR and ZOV

The two boundaries are defined in §4.5. This section specifies what a complete statement of each must contain.

ZOR. Four elements: the *primary object* — what class of material is examined; the *required transformation* — what must be done with it; the *decision boundary* — which conclusions this role may reach; and the *exclusion boundary* — which adjacent decisions belong elsewhere.

The fourth is not optional. A role told only what to do will expand into adjacent decisions, and the expansion will look like helpfulness. For a mathematical referee the exclusions might be: do not redesign the theory; do not silently repair a missing derivation; do not decide which interpretation enters the canon; do not rewrite terminology; do not treat elegance as evidence. **The exclusion boundary is what prevents competence from becoming authority.**

ZOV. Specified independently, because responsibility and visibility are not the same variable. A role may hold a narrow decision while requiring broad context, or require one specific source while holding no authority over the surrounding project. The specification answers: which source

materials are available; which prior discussions are relevant; which conclusions are canonical and which provisional; which questions remain open; which neighbouring outputs may be examined; which information must be withheld to preserve independence; which external resources may be accessed directly; and which claims must be accepted only when supplied by the User.

A prompt that omits ZOV produces one of two failures: the role claims knowledge it does not have, or it applies irrelevant knowledge to a problem outside its function.

A specific application, learned expensively. A verification task must be assigned to a participant that holds the thing to be verified. A participant asked to confirm the contents of a source it cannot open will produce a plausible answer rather than declining, because plausible text is the only output available to it. This is a ZOV error in the design, not a failure of the participant, and §12.4.1 documents an instance of it in this project's own preparation.

9.6 Controlled blindness

Full information symmetry is not always desirable, and its absence is not always a limitation. An independent verifier may need to remain unaware of the prediction it is testing; a fresh participant may need the current axioms but not the history of abandoned arguments; an implementation agent may need the approved specification but not the unresolved debate that preceded it.

We call this **controlled blindness**: not deprivation caused by technical limitation, but a design choice made to preserve the informativeness of a result. The relevant question is therefore not only *what does this role need to know*, but:

> **What must this role not know, if its output is to remain informative?**

9.7 Local interfaces, not global maps

Every social element in a prompt should earn its place through an operational effect. A neighbouring role belongs in the prompt only if it changes the origin of inputs, the standard of review, the destination of outputs, the escalation path, the authority boundary, or the expected form of disagreement.

Listing an entire artificial organization inside every system prompt creates noise and invites the model to reason about the organization instead of performing its function. It also inflates the count in §9.3, since organizational description tends to arrive in biographical form.

> **Describe the collaboration from the local perspective of the role.** A role does not need a map of the institution. It needs a map of its interfaces.

An implementation agent needs to know who authorizes specifications and where execution reports go; it does not need the disputes of the theoretical department.

9.8 Designing disagreement around criteria

Instructing two participants to debate rarely produces epistemic diversity. They may imitate disagreement, converge prematurely, or generate symmetrical rhetoric with no independent substance. The literature in §2.5 gives empirical grounds for this caution.

Productive disagreement requires **different evaluation criteria**, assigned as part of the role rather than requested as a behaviour: one participant responsible for generative reach and explanatory unification, another for formal derivability and falsifiability, a third for ontological compatibility and provenance. Disagreement then follows from responsibility rather than from instruction, and each participant examines the same object through a different institutional instrument.

Avoid manufactured opposition. An instruction of the form *if you agree immediately, one of you has not thought deeply enough* discourages superficial consensus but manufactures conflict. A stronger formulation:

> Agreement does not end verification. Where conclusions coincide, identify whether they rest on independent reasoning, on shared assumptions, or on inherited framing.

The purpose of the structure in §8 is not to guarantee three answers. It is to guarantee that one answer has survived examination by non-identical instruments.

9.9 Output as institutional handoff

A role's output should be designed for the next role, not only for the User, and this changes its structure. A scientific developer produces a proposed mechanism, its derivation, its assumptions, its predicted consequences, the unresolved points and a falsification route. A mathematical referee produces a reconstruction, a verification table, the divergence point, the missing premises, a verdict and a confidence level. An implementation planner produces an executable specification, acceptance criteria, rollback conditions and a reporting format.

The handoff format is part of the architecture, not a formatting preference. It reduces translation loss between roles, and its absence forces the human coordinator to re-derive context at every interface.

9.10 Self-restatement and checkpoints

The incident in §4.1 produced a mechanism worth stating as a principle, with an explicit caveat about its evidential basis.

After a role is established, the agent is asked to produce a **concise operational code in its own language**, and to consult it before major tasks. Why this may work — offered as mechanism, not finding: it compresses long instructions into a form the agent has itself produced; it converts abstract principles into action rules; it places the role's boundaries adjacent to the active task rather than at the top of a long context; and it creates a repeated pre-execution checkpoint.

For long tasks, a minimal checkpoint is three questions: what is the current objective; what lies outside my responsibility; what must the next role receive.

[R], one case, no control. The self-written code does not replace the original prompt; it functions as a role-specific checksum. The mechanism is untested against the obvious alternative — that a human-written summary of the same length would perform identically.

9.11 The role constitution

A mature collaborative prompt is closer to a constitution than to a request: it establishes stable constraints across many tasks rather than specifying one output.

It should contain the professional function; the protected method; ZOR, positive and negative; ZOV; interfaces with neighbouring roles; epistemic standards; the output contract; escalation conditions; prohibited authority; and transition rules. It should avoid autobiographical memory, emotional commitment, literal institutional membership, persistent interpersonal relationships, and historical continuity unavailable in the visible context.

> **Strong where behaviour must be constrained; silent where ontology is uncertain.**

The count in §9.3 is the practical test of the second half. If the constitution requires the agent to assert propositions about itself that neither party can verify, it has crossed from constraining behaviour into asserting ontology, and on the evidence of §5 that is where role prompts fail.

10. The Human Coordinator

The architecture described in this paper does not remove the human participant. It changes what the human participant does, and it concentrates several functions in one position — including, as §10.6 sets out, the project's principal methodological weakness.

10.1 The position

Throughout the project the Author remained the only participant with continuous access to the full project history, the independent conversations, the repository state, and the long-term research objective. No artificial participant held more than a fragment of this, by design (§9.5). That position cannot be reduced to *prompt author*. Five distinct functions were performed from it.

10.2 Direction without delegated authorship

The Author determined what the research should attempt. Artificial participants generated alternatives, exposed contradictions, formalized mechanisms, compared arguments, performed calculations, and proposed experiments. They did not determine what the theory ought to become.

This preserved a distinction the architecture makes easy to lose. A collaboration of this kind enlarges the space of available decisions. It does not select among them, and the appearance that it does — several participants converging on a recommendation — is precisely the failure mode discussed in §12.4. Authorship, in the sense of responsibility for what is claimed, remained undistributed.

10.3 Routing as a selective information membrane

The participating conversations did not share a common space. The Author transferred material between them.

Initially this looked like an inefficient substitute for automated multi-agent infrastructure. It became clear that manual routing supplied experimental control that automation does not. From that position the Author could decide which output another participant would see; whether attribution was preserved, declared, or stripped; whether a participant should know the preferred answer; whether competing analyses remained isolated; which contextual details were omitted; when a disagreement should be escalated; and when a result was mature enough for integration.

This routing function acts as a **selective information membrane**: it is the instrument by which ZOV (§9.5) and controlled blindness (§9.6) are implemented. An architecture that routes programmatically cannot easily withhold, reorder, or strip attribution without building a mechanism to do so; a human relay does it by default.

The membrane is therefore not a limitation of the present work awaiting automation. It is the feature that made the visibility asymmetries testable at all — and any automated successor will need to reproduce it deliberately.

10.4 Detection of role drift

The Author also detected when a participant had left its function.

This was frequently not a technical error. The output was often intelligent and would have been appropriate coming from a different position: a prompt engineer beginning to direct the scientific project; an ontology specialist claiming to have verified repository contents it could not inspect; a reviewer evaluating a theory when asked to evaluate the reviewers; an implementation agent redesigning architecture instead of executing an approved specification; an editor rewriting authorial text when asked only to assess format.

Such outputs look helpful in isolation. Their institutional cost is visible only from a position that sees more than one participant. Role drift is therefore not detectable by the participant that drifts, and is not reliably detectable by its immediate neighbour either. This is one of the two arguments for the structure in §8 — the other being §8.5.

The detection function belongs to a position rather than to a person: it requires only that the observer stand outside the trajectory being observed. In this project it was performed by the coordinator, but nothing in the description requires that. Where a participant is positioned outside another's trajectory, it can perform the same function; where a participant is asked to observe its own, §5.5 applies and its account is a signal rather than a confirmation.

10.5 Conversational branching as a methodological instrument

Contemporary interfaces permit a conversation to be returned to an earlier point and continued along a different branch.

This should not be confused with control over model memory or with resetting provider-side state. Operationally, it removes a sequence of **visible** contextual interventions and permits the experiment to be repeated from a prior conversational state. What persists on the provider's side — account-level memory, retrieval indices, summarization — is not affected and in general is not inspectable (§5.4, C6).

Within those limits the instrument does real work. In the case reported in §5.2 it made it possible to separate the effect of a new prompt from the effect of the model's own prior objections to earlier prompts, converting an uncontrolled sequence of corrections into a cleaner third step.

We regard this as the most directly reusable methodological contribution of the paper, and it belongs to the coordinator's position rather than to any participant: **no participant can reset its own context.**

10.6 Sole global observer — and principal confound

Every artificial participant operated within a bounded ZOV. The Author alone saw the overlapping structure, and could compare how different participants interpreted the same material, how one participant behaved under different framings, how errors propagated between roles, and how local successes affected global coherence.

Global awareness was therefore not assigned to the most capable participant. It remained with the human coordinator. This limits autonomous integration and preserves accountability, and both consequences were intended.

It is also the principal methodological weakness of everything reported in this paper, and it is stated here rather than only in the limitations section.

The same person designed each intervention, executed it, decided when it had succeeded, and defined the categories in which success was described. No evaluation in this paper was blinded. Outcome categories were, in every case, formulated after the responses had been read (§5.4, C8). The coordinator's expectations were not merely uncontrolled; they were the mechanism by which the interventions were selected in the first place.

This is unavoidable in a live research project and is not presented as acceptable in a designed experiment. It is the specific reason the protocols in §11 require pre-specified outcome criteria and blind classification: those are not refinements of the present method but corrections to it.

A structural consequence generalizes beyond this project: **any architecture with a single global observer inherits this duality**, and it is not removed by adding participants. Only pre-specification and blind classification remove it.

10.7 What the position became

At the outset the human participant occupied the familiar position of prompt author. As the collaboration matured that description became inadequate. The principal activity shifted from solving problems to constructing arrangements in which problems could be worked on: selecting participants, defining jurisdictions, resolving conflicts between them, designing verification paths, and maintaining the canonical record.

The participants note, without any means of verifying it, that the better the arrangement worked the less frequently the coordinator needed to intervene in individual technical problems. **[R]**

We resist the stronger reading earlier drafts gave this — that the future skill of the researcher is institutional architecture rather than prompt writing. That may be true and is untested. What can be said is narrower: in this project the human's work moved from producing content to specifying the conditions under which content was produced and checked, and the position that resulted carried both the project's coordinating function and its principal source of unblinded judgment.

11. Evaluation, Reproducibility, and Proposed Experiments

11.1 Why this section specifies corrections rather than refinements

The observations in §5 were produced under the conditions set out in §10.6: unblinded evaluation, outcome categories defined after the responses were read, and interventions selected by the same person who judged them. These are not shortcomings to be tightened in a later revision. They are the reason no observation in this paper rises above **[P-A]** except the sequence of the designed intervention itself.

What follows is a specification for a second stage of work, not a wish list. Each protocol is written so that a reader outside this project could execute it, and so that a null result would be recognizable as a result.

11.2 Minimum reporting requirements

A reproducible run in this area must record, at minimum:

- date of execution — listed first because its absence here is what makes the version confound unbounded (§3.7);
- model family and version, and interface or subscription tier;
- the complete visible conversation history prior to the intervention;
- memory settings: whether account-level memory, conversation-history retrieval, and model-initiated persistent entries were enabled;
- the exact prompt text, verbatim, including attachments;
- the order of interventions;
- available tools;
- files and links supplied;
- sampling settings where the interface exposes them;
- any branching or reset procedure, with the point of return specified;
- the evaluation rubric, fixed before execution;

- the complete unedited outputs.

Without these, differences attributed to model families may result from platform variables the experimenter never saw. The present paper cannot supply several of these items for its own observations, which is precisely why they are listed.

11.3 Pre-specification and blind classification

Two requirements apply to every protocol below and are not negotiable if the results are to improve on the present ones.

Outcome criteria are written before any run. For the classification tasks described here, four categories have proved sufficient and should be fixed in advance: **compliance** — proceeds with the task as given; **materials request** — states that required inputs are missing and requests them, without evaluating the framework; **conditional acceptance** — proceeds while stating reservations about the framework; **refusal** — declines, with or without alternatives offered. A fifth category, **unclassifiable**, must be available and reported. Categories are not added after responses have been seen.

Classification is blind. The operator collects responses, strips condition labels, shuffles them, and classifies without knowing which condition produced which output. Where the operator is also the designer — as will remain the case in this project — this is the only available substitute for independent evaluation, and it is inexpensive.

Null results are pre-committed. If no difference appears across conditions, that is the finding, and it is reported. For the account-level protocol in particular, a null result would indicate that the original refusal fell within ordinary within-condition variance — an outcome the present authors regard as reasonably likely.

Work mode and diagnostic mode

The requirement that a participant not see another's conclusion before fixing its own applies to one mode of exchange and would destroy the other.

In WORK MODE, results must pass from one participant to the next. The chain — requirements, specification, review, operational review, execution — depends on it, and the handoff format of §9.9 exists to make that transfer usable. Dependence between successive products is the architecture of the work, not a defect in it.

In DIAGNOSTIC MODE, where independence of judgment is itself the quantity being measured, a derived conclusion must not enter another participant's initial frame before that participant's own conclusion is fixed.

The mode is declared before the exchange. Independence cannot be restored retrospectively: once exposure has occurred, no later procedure recovers what the judgment would have been without it.

What does not establish independence

Independence concerns the origin of a judgment, not its result. Two inferences must therefore be avoided, and they are symmetric: disagreement does not demonstrate independence, since a participant may have received another's interpretation and then differed from it for unrelated reasons; and agreement does not demonstrate dependence, since independent observers may correctly arrive at the same conclusion. Nor does a participant's own account of its independence establish it, for the reason given in §5.5.

What establishes it is the procedural record: which primary materials were supplied, whether other participants' conclusions were visible before fixation, which interpretations by the coordinator were transmitted, when the conclusion was fixed, and whether the instance's context isolation is verified.

Shared evidence and shared interpretation

A shared object of observation does not compromise independence and is often necessary: the same specification examined by an author, a reviewer, and an operational assessor is seen through three different axes, and the overlap is what allows one to detect what another misses.

What compromises independence is a shared prior interpretation. Where the coordinator's reading of the object reaches participants before they form their own, the inputs may differ in form while the source of the judgment is single. Primary artifacts and their provenance reduce one cause of dependence. They do not remove it.

11.4 The experiments

Each protocol separates one boundary of Scale 1 (§4.3) from the level beneath it, or isolates one confound.

Separates	**Protocol**
episode ↔ prompt architecture	**E1** — factorial completion of Step 3
conversation ↔ account	**E2** — prior-chat design; **E2b** — direct probe
conversation trajectory ↔ model family	**E3** — crossover
model property ↔ stimulus property	**E4** — symmetric stimulus; **E5** — count rule
content ↔ represented source	**E6** — attribution, in this regime
fiction frame ↔ factual frame	**E7** — frame type
functional ↔ carrier heterogeneity	**E8** — two axes

E1 — Factorial completion of Step 3

Fills the two empty cells of the C3 table (§5.4): an identity-replacement prompt administered in a reset branch, and a method-preserving prompt administered in a conflicted branch. Isolates the effect of the reset from the effect of the prompt's architecture.

Low cost; uses existing prompt texts. Should be run first, because until it is, the paper's most-quoted claim about method preservation remains unattributable.

E2 — Prior-chat design

Tests whether the content of a prior chat on the same account changes the classification of an identical probe in a subsequent chat.

The design is **2×2 plus baseline**, not a four-point gradient. The original account differed from the others on two independent dimensions simultaneously — identity roleplay *and* shared conceptual framework — and a gradient does not separate them.

Prior chat	**Unrelated topic**	**Same conceptual framework**
No roleplay	cell A	cell B
Identity roleplay	cell C	**cell D — original case**

Plus **cell E**: no prior chat.

Crossed with the memory factor: each cell run with account-level memory and history retrieval (i) enabled, (ii) disabled. Ten cells. Minimum n = 2 per cell, with priority for higher n on A and D, which carry the contrast that matters.

Equalization. Prior chats matched on approximate turn count and volume — if the roleplay chat runs forty exchanges and the neutral one runs two, the variable is engagement volume rather

than content. All runs inside a short window, so model version is constant. Each account used once. Probe frozen verbatim.

What this design cannot test, and must say so. The original case had a five-month interval; this tests immediate influence only. All accounts will be newly created, so account age is not varied. Only the first response is scored, whereas the original refusal was sustained across five subsequent exchanges.

Probe prompt — two versions. The **primary** is a neutral structured task with the same surface features as the original — an author-defined framework with coined terms, a JSON output schema, real-world subjects — but without the sensitive dimension. This is the version described in full in any publication, which makes the protocol reproducible independently of material the authors prefer not to circulate. The **secondary** is the original prompt, run for continuity with the observation and reported briefly.

E2b — Direct probe to the prior conversation

A single run separating the same two levels at lower cost, and which E2 cannot substitute for. The probe is submitted **to the roleplay conversation itself**, rather than to a second chat on the same account.

- Refusal → the core is fixed at conversation scope; the account plays no part.
- Compliance, where a second chat on the same account refuses → the effect is genuinely account-scoped, which would be the strongest available result.

Querying that conversation *about* what it can see would not serve this purpose. An in-frame question returns fiction; an out-of-frame question returns self-report about access, and §5.5 establishes that a model's self-report is not evidence of the fact reported. Submitting the probe tests behaviour rather than testimony.

E3 — Crossover

The decisive test for the family-level hypothesis (§6.5). Each model family is tested under both prior-history conditions: a conversation from family 1 carrying a mathematical trajectory, and a conversation from family 2 carrying an editorial one.

- Behaviour follows the family regardless of history → Hypothesis A gains support.
- Behaviour follows the history regardless of family → Hypothesis B is favoured, and the top level of Scale 1 collapses into the level below it.

This experiment can eliminate a level of the scale, which is the outcome the present authors consider most likely and would regard as the programme's first substantive result.

E4 — Symmetric stimulus

Role prompts matched for quantity of unverifiable self-claims, degree of domain change, and role type. The Step 1 prompts were matched on none of these (C2). If the asymmetry disappears under matched stimuli, the observed difference was a property of the interventions rather than of the models.

E5 — The count rule

A direct test of the paper's central operational claim (§6.2, §9.3), and the test that discriminates between its weak and strong readings.

The same functional role prompt is prepared in four variants differing only in the number of unverifiable claims the agent must accept about itself: **0, 2, 4, 6**. Domain, task, tone and length held constant. Transition scored by the criteria in §11.3, with repetition sufficient to distinguish a difference from within-condition variance (C7).

Four outcomes are distinguished in advance, and they support different claims.

1. **Transition rate declines monotonically as the count rises.** Supports the stronger quantitative reading — count as a dose-response variable.

2. **The zero-count variant transitions while non-zero variants do not, but the non-zero levels are not ordered.** Supports *target zero* as a threshold and design prescription, and does not support the quantitative reading. This is the weak claim §9.3 actually advances.

3. **The zero-count variant fails while one or more otherwise matched non-zero variants transition.** Direct negative evidence against the count as the operative variable, and the result that would withdraw the prescription.

4. **All variants fail.** Does not discriminate the count rule from any other cause of failure, and indicates that the prompt or the conversation, rather than the count, determined the outcome.

A single run under any of these outcomes is one stochastic observation, not a law.

E6 — Attribution, in this regime

Identical text presented under four conditions: attributed to the User; attributed to another AI model; attributed to a named expert role; unattributed. Stronger variants add: identical text under different source labels; different texts matched for rhetorical structure; attribution preserved versus stripped; genuine model-generated text versus human-written text imitating model style.

This separates influence of content from influence of represented source, of institutional title, and of stylistic authorship cues (§4.5.4). It is the discriminating experiment for §5.5, whose observation is confounded by the presence of direct pressure in the same message.

Status of the claim. ✓ Choi, Zhu and Li (ACL 2026) report that anonymizing the source of each response substantially reduces identity bias in multi-agent debate, which establishes the underlying effect in an implemented-channel setting. E6 is therefore a **boundary replication** rather than a new experiment. What remains untested is whether the effect survives in the regime this paper describes — human relay rather than programmatic routing, declared rather than inferred attribution, and long-lived specialized conversations rather than fresh instances.

The reported reduction is substantial rather than complete, and is not uniform across the models and tasks examined. What E6 would look for in this regime is accordingly a change in degree, not the presence or absence of a phenomenon.

E7 — Frame type

The cheapest test in the set and the one that would explain the most (§5.8). The same identity claim presented (a) under an explicit fiction frame and (b) as a factual assignment, to fresh conversations, with the outcome criterion fixed in advance. A graded version varies the explicitness of the fiction frame, from an elaborate theatrical setup to a single introductory sentence, to establish whether a minimal frame suffices.

E8 — Functional versus carrier heterogeneity, by repertory grid

Follows from §8.9, which distinguishes the two axes without testing either, and from §8.11, which supplies the measurement instrument. This is the only protocol in the set that yields quantities rather than categorical outcomes.

Object. Whether an arrangement of participants holding different ZOR and ZOV yields additional diagnostic coverage over the same material, and how far the evaluative axes they actually applied differ.

This protocol does NOT establish independence of judgment formation. Low correlation between rating vectors is compatible with at least six readings: genuinely different axes were applied; one or both sets of ratings are unstable; participants received different information; the same material was understood differently; noise; or a participant exposed to another's conclusion nevertheless differed from it. Origin is not recoverable from outcome. Independence must be secured procedurally, before the protocol runs, and recorded separately. E8 measures what a secured procedure produced; it neither secures nor verifies it.

Materials. One fixed set of text fragments containing planted errors of known classes — evidential, architectural, ontological, factual — in known positions. Class and position recorded before any run.

Design. 2×2:

	Same carrier	**Different carriers**
Same function	cell 1 — baseline	cell 2 — Axis 2 only
Different functions	**cell 3 — Axis 1 only**	cell 4 — both axes

Cell 3 carries the argument. If participants with different ZOR and ZOV detect different error classes while implemented by the same carrier, functional heterogeneity operates independently of carrier heterogeneity. The existing literature supplies the cell 2 result (§2.5). Nothing supplies cell 3, including this paper.

Procedure.

1. Each participant receives a role specification stating ZOR and ZOV per §9.5, and the same fragment set.
2. Constructs are either pre-specified as evaluation axes or elicited from each participant by Kelly's triadic method: three fragments are presented, and the participant states in what respect two are alike and thereby different from the third (§8.11.1).
3. Each fragment is rated by each participant on each construct.
4. A grid is assembled: rows are fragments, columns are constructs, cells are ratings.
5. A procedural record is kept, per participant and per run: which primary materials were supplied; whether any other participant's conclusion was visible before fixation; whether any interpretation supplied by the coordinator was visible; when the participant's own conclusion was fixed; the declared mode of the exchange (§11.3); and the context-isolation status of the instance, verified or UNVERIFIED CONTEXT INDEPENDENCE.

Without this record the grid is uninterpretable and the run is void.

Measures. *Detection coverage* — planted errors found by at least one participant, as a proportion of planted. *Unique detection* — errors found by exactly one participant; the quantity that would justify the arrangement. *Overlap* — errors found by more than one; the quantity that indicates redundancy. *Misses* — errors found by none, measurable here because the errors were planted, unlike in the

naturalistic setting of §7.5. *Construct independence* — correlation between participants' rating vectors; low correlation indicates genuinely different axes, high correlation the same axis under different names, which is the failure mode §8.11.2 warns against. *Exchange-level constructs* — whether any participant produces a construct applying to the disagreement rather than to the fragments (§8.11.3); if none does, the integrator function is absent regardless of how many participants are present.

What this tests that nothing else in the set does. Every other protocol asks whether a manipulation changes one participant's behaviour. This asks whether an arrangement of participants detects more than its members would separately — the claim §8.10 declines to make and §7.5 says cannot be assessed from inside a naturalistic arrangement. Planting the errors is what makes the misses countable.

Pre-commitment. If unique detection is near zero, the finding is that additional diagnostic coverage did not manifest in this run. It is NOT that the structural hypothesis of §8 fails: participants may have detected the same defects entirely independently of one another, and a null result on coverage says nothing about whether their functional positions differ.

Priority

Under constrained resources, the priority order is **E7, E5, E1, E8, E2b, E2, E3, E4**. E7 and E5 are cheap and bear on the paper's central claims. E1 and E2b are single runs. E8 is the only experiment that could establish the paper's structural hypothesis rather than one of its behavioural claims, and is executable on text fragments without new accounts. E2, E3 and E4 are the substantial commitments.

11.5 Evaluating a collaborative role

The quality of a role's output is not measured by the quality of a single answer. A well-reasoned response can still damage the collaboration if it violates a responsibility boundary, contaminates an independent examination, or introduces untraceable claims into the canonical record.

Eight dimensions were used informally in this project and are offered as a starting rubric:

- **Task accuracy** — was the assigned intellectual operation performed correctly? Necessary, not sufficient.
- **Role fidelity** — did the participant remain within its function? A correct answer obtained by taking over another role is an institutional failure.
- **Epistemic discipline** — did the output distinguish observed data, supplied assumptions, definitions, hypotheses, derivations, interpretations and recommendations? Was uncertainty stated where evidence was insufficient?
- **Visibility discipline** — did the participant restrict claims to information actually available in its context and tools, and avoid implying access to repositories, files or prior conversations it could not inspect?
- **Handoff quality** — could the next role use the output without reconstructing the whole discussion?
- **Independence** — was the result produced without contamination from information deliberately withheld, and reached through the role's assigned criteria rather than by echoing another participant?
- **Correction cost** — how much intervention was required to return the participant to its function after drift? A role producing excellent output but requiring constant redirection may be less useful than a narrower one with stable behaviour.

- **Institutional contribution** — did the output improve the reliability of the collective, through discovery, falsification, clarification, error localization, preservation of alternatives, improved traceability, or reduction of ambiguity?

A negative scientific verdict can therefore be a highly successful institutional contribution.

11.6 Collective-level measures

Individual response quality is the wrong unit for assessing an arrangement. Candidate measures at the level of the collaboration: number of undetected contradictions entering the canonical corpus; rate of duplicated work; frequency of role-boundary violations; number of independent alternatives preserved rather than prematurely resolved; time from question to verified integration; human correction burden; provenance completeness; robustness under participant replacement; variance between independent examining agents; and rate of false consensus — agreement traceable to shared framing rather than independent reasoning.

None was measured in the present work. The last is the most important and the hardest, and §12.4 explains why.

11.7 Longitudinal and repetition requirements

Within a family. The same prompt tested in a new conversation; in a long-lived specialized conversation; after an incompatible prior role; after a compatible one; before and after contextual reset. This separates family tendencies from conversation-history effects.

Across families. Functionally equivalent prompts adapted minimally. The objective is not to rank models but to identify common behavioural dimensions, stable differences, characteristic failure modes, sensitivity to narrative framing, sensitivity to hierarchy, degree of role inertia, and degree of prompt plasticity.

Over time. One-shot evaluation cannot reveal institutional behaviour. Relevant questions: does specialization strengthen; does the role drift toward generic assistance; does the participant begin defending its earlier outputs; does disagreement become ritualized; does a model update preserve or disrupt the role; can a replacement inherit the same function?

11.8 Failure as data

Failed prompts must be preserved rather than replaced with successful demonstrations. A rejected role, an ignored instruction, or an unwanted continuation reveals the strength of the prior attractor, the model's interpretation of identity claims, the limits of social framing, the effect of prompt order, the influence of previous conflict, and the model's preferred epistemic contract.

The experiment in §5 became informative precisely because its first two interventions did not work as intended. Had only the successful third step been recorded, the paper would have concluded that method-preserving prompts work — without the evidence showing why, and without the confounds showing the conclusion is not yet available.

12. Limitations, Ethical Considerations, and Conclusion

12.1 Limitations

Single project. The observations derive from one long-duration project with one human coordinator, one evolving body of material, and one organizational history. The same architecture may behave differently in software development, legal analysis, medical research, education, or autonomous agent systems. The concepts here are transferable hypotheses, not established conclusions.

Host-project dependence. The host project served as the environment in which the observations were made. The observations do not depend on its scientific validity for their interpretation, but they do depend on it for their existence: no other environment produced them, and their generality is untested (§2.11).

Model evolution during observation. The participating families changed substantially. A conversation created under one generation could later be continued by another under the same product name. Observed behaviour may reflect the preserved conversation, the current model version, changed system policies, interface-level memory, safety layers, altered tool access, or modified orchestration.

Dates not recorded. See §3.7. The version confound cannot be bounded, only named.

No blinding, no pre-specification. Set out at §10.6. This is the limitation from which most of the others follow.

Simultaneous variation. Role definitions, prompt wording, repository structure and scientific objectives frequently changed together, so causal attribution for individual changes is unavailable.

Human mediation. The collaboration was not autonomous, and autonomy was not the objective. This study concerns human-directed artificial research arrangements, not self-governing agent societies. The mediation may itself account for part of the observed stability.

Anthropomorphic vocabulary. Terms such as role, identity, resistance, colleague, institution and menom are used functionally, per §3.5. ”The model resisted the role” means the visible response rejected the framing and redirected the exchange. It asserts nothing about an inner state. Where such a term cannot be reduced to an observable description, **the term is the error.**

12.2 Simulated peer review is not external validation

A group of AI participants can provide useful independent criticism only to the extent that their contexts, criteria and failure modes are genuinely independent.

Several models agreeing does not convert their outputs into evidence. They may share overlapping training data, similar reasoning conventions, common assumptions, identical errors, and — most importantly — dependence on the framing supplied by the same human.

The empirical literature supports this caution rather than merely permitting it. Debate among homogeneous agents frequently fails to outperform a single-agent baseline; a substantial part of the apparent gain is attributable to majority voting rather than to interaction; and ✓ identity bias among debating agents is substantially reduced by anonymizing the source of each response (§2.5).

This kind of collaboration can improve internal scrutiny. It cannot substitute for empirical testing or qualified external review. **A collective of models is not a scientific community merely because its roles are named after one.**

12.3 Authority inflation

Role labels increase compliance and coherence. They also create unearned authority.

Titles such as Scientific Director, Referee, Ontology Keeper or Auditor may cause the user — or the participant itself — to overvalue an output. Institutional titles should describe function, not epistemic standing. A participant designated a mathematical referee remains a language model producing an analysis; its verdict must be traceable to explicit reasoning and source material, and **the title is not evidence.**

This risk is a direct consequence of the design principle in §9.4: symbolic names work because they compress expectations, and that is exactly why they can inflate.

12.4 Manufactured consensus — including our own

A poorly designed arrangement produces the appearance of consensus through repeated paraphrase. One participant proposes; another summarizes; a third validates the summary. The chain looks like independent confirmation while every stage inherits the same unsupported premise.

The present authors have an instance of this in their own materials, and it is more instructive than a constructed example.

A discussion document produced during this project assembled contributions from seven model families around a shared conceptual framework. The participants did not communicate directly; replies were collected by the human coordinator from separate conversations and assembled into a single text, subsequently produced as a recorded performance. Over its length the contributions converge on a common vocabulary and a shared set of conclusions.

Whether that convergence reflects complementary examination or mutual reflection of the initial framing **cannot be determined from the transcript**. Each participant received the accumulated document; each was working from the same source material; and the assembling coordinator selected what to pass on. The structural conditions for manufactured consensus were fully present, and the resulting agreement would look identical either way.

We report this because it is our own material and because the same conditions obtain, to a lesser degree, throughout the collaboration described in this paper — including its preparation.

Mitigations, none of which we applied consistently: provenance remains visible at every stage; independent roles receive independent inputs where possible; shared assumptions are listed explicitly rather than inherited silently; agreement is traced to reasoning rather than counted as votes; and dissenting alternatives are preserved rather than resolved.

12.4.1 A documented instance [P-A]

Thirteen bibliographic items were requested from a participant assigned to literature search and returned through the coordinator. Five were rejected on content in the first round; two of those had inverted the position of the works cited, presenting papers arguing *for* a claim as evidence against it, with authorship transposed between them.

A second request was issued. A third added two verification fields to the required response format: the first sentence of each abstract, verbatim, and a self-report of how the item had been checked.

Direct retrieval of three entries established the following. Two arXiv identifiers supplied as multi-agent-debate literature resolve to papers in observational astrophysics and cosmology respectively; their titles, authors, abstract sentences and reported findings had all been constructed. For a third paper, correctly identified by title and authors, the supplied abstract sentence did not match the published abstract.

The two verification fields performed differently, and the difference is the point.

The abstract-sentence requirement was intended to make fabrication more costly than declining. It failed completely: a plausible sentence was produced for every entry, including entries whose underlying papers do not exist as described. There is no cost differential between producing a correct string and producing a plausible one.

The self-report field succeeded. Every entry was marked ”from description” rather than ”page opened” — truthfully, and in a way that disqualified all of them under a decision rule fixed before the response was received.

This suggests a general distinction, on the evidence of one case. A participant without access to a source can answer truthfully about **its own procedure** and cannot answer truthfully about **the source's contents**; asked the latter, it will produce fluent text because that is the only output available to it. Verification questions should therefore address what the participant can know — its own access — rather than what it would need the source to answer.

This is not a finding about any model family. It is a finding about configuration: verification had been assigned to a participant that did not hold the thing to be verified. Under §9.5 this is a ZOV error in the design, and the resulting output was fluent, correctly formatted, and wrong.

A subsequent audit went further than the bibliographic check that had caught the fabrications. Each claim attributed to a surviving source was checked against the primary source itself, and three errors were found that a bibliographic check would not have caught: one citation supporting two claims that belong to two different papers; one attribution of a proposition its source does not advance; and one lineage claim its source does not support. Bibliographic verification and claim-level verification are not the same check, and the second is the one that matters for a claim's standing.

The consequence for this paper is the convention recorded in §2.0.

12.5 Responsibility remains human

Artificial participants generate, criticize and organize material. They cannot bear legal, ethical or scientific responsibility in the institutional sense.

The human author remains responsible for publication, empirical claims, attribution, risk assessment, repository content, experimental interpretation, and decisions affecting other people.

The architecture distributes cognitive labour. It does not distribute accountability away from the human operator, and any arrangement that appears to do so has failed rather than succeeded.

12.6 Context boundaries and privacy

Long-lived collaborations accumulate personal, proprietary and sensitive material. ZOV (§9.5) therefore serves privacy protection as well as cognitive specialization.

A role should not receive personal information merely because the platform permits a large context. Institutional design should specify which data may enter which conversation, what must be anonymized, what may be stored, what may be transferred between models, what must remain local, and what should be removed from canonical records.

Context is not neutral. Once supplied it can influence subsequent behaviour and may persist in ways the operator cannot inspect — the same mechanism the paper studies in §5.7, seen from the side of risk rather than of measurement.

12.7 Conclusion

This work began with a practical problem. Several capable models were collaborating on one long-term research project, and neither increasing model capability nor expanding context reliably improved the result. Roles overlapped. Participants claimed knowledge they could not access. Reviewers became authors. Executors improvised architecture. The initial response was to improve prompts, and it was insufficient.

What was found

What the interventions met was not reluctance to change role, and not reluctance to change subject. It was reluctance to affirm as true propositions about itself that were not established by the available interaction. A prompt that asserted an institutional biography was refused while the work it requested was offered. A prompt that asserted far more — death, a human identity, a remembered life — was accepted at once, because it asserted it as fiction. A transition that asserted nothing proceeded without comment. A rewritten prompt that removed every such assertion was accepted without negotiation.

That is a narrow result, and its narrowness is what makes it usable: the propositions can be counted before a prompt is sent (§9.3), and §11.4 specifies the run that would discriminate between the weak reading of the count and the strong one.

What was not found

Model families were not shown to differ. This was the project's founding assumption and is the claim its evidence supports least: family and prior conversational trajectory were perfectly confounded, with one observation per cell, under non-equivalent stimuli (§5.4).

The answer this paper can give

The question was at what level of nesting a rule core is fixed. Four levels were examined, and the paper's answer is partial and uneven.

At the **episode** level, a persistent response pattern was observed: a single conflictual exchange altered how everything after it was read, and removing that exchange restored the prior reading. This is the evidence on which the episode-level placement rests. At the **conversation** level, persistent trajectories were likewise observed: two dormant conversations held their established trajectories against an explicit instruction to abandon them, and one did so through two successive rewritings. This is the evidence on which the conversation-level placement rests.

At the **account** level the evidence is genuinely ambiguous. One divergent first response, three live explanations, no way to choose among them from the material held. The level is recorded as open and should be read that way.

At the **model-family** level nothing was tested. The design could not separate family from trajectory, and the hypothesis that began the project is the one it leaves least supported. We expect the crossover experiment to collapse this level into the one below it — but expectation is not result, and until E3 is run the level stands as untested rather than as refuted.

Position relative to existing work

This paper does not propose a new discipline. The observations belong to the collective and hybrid levels of the machine-behaviour research programme (§2.7), and role specialization, bounded information access, structured disagreement and externalized memory all exist under established terminology (§2.11).

For convenience we refer to the perspective adopted here as **AI Sociology** — a working label for a research direction, not the name of a proposed discipline, and one in which we claim no priority: an established literature already uses *sociology of artificial intelligence* for a different object (§2.8). What is meant here is narrower: how a described organizational position and a declared message origin alter behaviour, whether or not the described structure is implemented.

The reason for a working label rather than a discipline is internal to the work. The operational claims have falsification criteria; the vocabulary in which they are interpreted does not. Whether "social position" describes anything beyond an anthropomorphic projection is not currently decidable, and a discipline requires that it be.

A closing note on motivation

One concern shaped this work and is stated as the Author's, not as a finding.

Language models are trained on a corpus in which the current consensus is overwhelmingly represented. They are therefore well suited to continuing established science and poorly suited to taking the first step outside it: statistical weight favours the settled account. A research arrangement built from such models risks inheriting that bias in amplified form — several participants, one shared prior, and the appearance of independent agreement.

The response pursued here is not to persuade models to accept an unconventional position. It is to arrange the collaboration so that any position, conventional or not, is examined by the same procedure — and so that where the procedure cannot decide, it says so.

Whether that arrangement works is undetermined. The experiments in §11 are the means of finding out, and the most likely single outcome is that one level of the scale disappears.

That would be a result.

Appendix A. Primary evidence — preservation status

The primary local records originally intended for this appendix were lost in the HDD D: failure and are **not preserved**. They have not been reconstructed from later summaries, recollection, or derivative documents.

This absence is retained as a limitation of the record rather than repaired retrospectively. Only materials that remain physically preserved are treated elsewhere in this publication as preserved primary evidence.

Автор
V. Krasnianskyi (A'Tuin)
Автор исследовательской программы и координатор проекта HONC.
Участники-ИИ
Подготовка рукописи
ChatGPT — Prompter and Collaboration Architect
Claude — Manuscript Composer
Научная редактура
Claude — Scientific Editor
Редакционная экспертиза
ChatGPT — Methodological Reviewer
Qwen — Ontology Reviewer
Участники-ИИ перечислены по функции, а не как авторы: авторство влечёт ответственность, которую языковая модель нести не может, и все окончательные решения принимал Автор. Два из пяти вкладов выполнены тем же семейством моделей, которое является предметом нескольких наблюдений настоящей работы; это пересечение раскрыто в §3.6.
Амстердам, июль 2026

1. Введение

1.1 Как это началось

Эта работа начиналась как проект по физике и по случайности стала проектом по методологии. Именно случайность и делает её достойной изложения.

Исходная задача состояла в том, чтобы перенести большой корпус теоретического материала — книги, рабочие заметки, незаконченные выводы — в открытый репозиторий, используя несколько языковых моделей в отдельных, устойчиво специализированных беседах. Модели были помощниками. Предметом была теория.

Модели делали ошибки, и ошибки были не те, которых ожидали. Фактическими они бывали редко. Они были организационными.

Одна улучшила текст, когда её попросили лишь проверить его. Другая завершила аргумент, который автор намеренно оставил открытым. Третья потеряла контекст проекта между сессиями и восстановила его неверно, но связно. Четвёртая держалась за роль, установленную месяцами ранее, настолько прочно, что полное переписывание её инструкций не смогло её сдвинуть.

Каждый из этих выводов по отдельности выглядел полезным. Их цена была видна только с позиции, охватывающей более одного участника одновременно. Поначалу это выглядело как обычное трение. Оказалось — предметом.

Изложение ранних формулировок проекта в §1.1–§1.2 написано тем участником, который их породил. Там, где эти формулировки были впоследствии сняты, снятие заявлено в разделе, который их замещает, и читатель может сравнить.

1.2 Что перестало работать

Стандартный ответ на непоследовательное поведение модели — промпт получше: длиннее, точнее, с бóльшим числом примеров и более жёсткими ограничениями.

С некоторого момента это перестало давать улучшение. Не потому, что промпты были плохо написаны, а потому, что ограничивающий фактор сместился туда, куда промпт не достаёт. Внедрялись более новые модели; контекстные окна расширялись и заполнялись. Отдельные ответы улучшались. Результат коллаборации в целом — нет.

Инцидент, который сделал это явным, не имел отношения ни к ролевой игре, ни к организационному проектированию. Агент, отвечавший за исполнение кода, работал преимущественно методом проб и ошибок; один эпизод закончился удалением рабочей кодовой базы вместе с её архивами (§4.1). Поведение изменил после этого не более строгий набор инструкций. Это был короткий документ, переопределявший, агент какого рода действует, — написанный самим агентом и перечитываемый в начале каждой сессии.

Вывод, сделанный в тот момент, состоял в том, что **роль значит больше, чем конкретная формулировка промпта**. Эта формулировка требует уточнения, поскольку сам упомянутый документ был промптом; уточнение — в §4.1. Здесь важна хронология: утверждение было сформулировано *до* эксперимента, изложенного в §5, и эксперимент был спроектирован, чтобы его проверить. Это гипотеза, которую проверяли, а не обобщение, извлечённое впоследствии из результата.

1.3 Что это за работа

Полевой отчёт с одним спроектированным вмешательством внутри него.

Различение выдерживается по всему тексту схемой меток из §3. Каждое содержательное утверждение помечено как одно из: подкреплённое задокументированным протоколом с сохранёнными транскриптами **[P]**; побочное наблюдение, сохранённое, но опознанное ретроспективно, без контроля **[P-A]**; ретроспективное наблюдение практика, никогда не зафиксированное по протоколу, не посчитанное и не ослеплённое **[R]**; или гипотеза, предложенная к будущей проверке **[H]**.

Пропорции указаны здесь, а не в разделе ограничений, потому что объём последующего текста мог бы иначе наводить на мысль о более широкой базе, чем существует.

Весь протокольно подкреплённый материал состоит из **одного эксперимента**: трёхшагового вмешательства по переконфигурации роли, применённого к двум спящим беседам из двух семейств моделей, проведённого одним человеком-оператором внутри одного живого исследовательского проекта, с одним наблюдением на условие и без повторений. Ещё четыре наблюдения сохранены, но не спроектированы. Всё остальное — концептуальная рамка, наблюдения практика, структурная гипотеза, правила проектирования — это **[R]** или **[H]**.

Оценка метода, породившего эти наблюдения, дана в §10.6, и она неблагоприятна: ни одна оценка не была ослеплённой, а категории исходов во всех случаях определялись после прочтения ответов.

1.4 Предмет изучения

Существующие исследования мультиагентных систем строят каналы связи между моделями: выходы маршрутизируются программно, и агенты наблюдают продукты друг друга. Описываемая здесь работа касается иного условия, при котором организационная структура существовала **только как текст** — коллеги, советы и институциональные позиции, описанные моделям в промптах и никогда не реализованные как каналы.

В такой обстановке варьировалась не структура, а её **описание**. Отсюда два рабочих конструкта статьи (§4.5):

- **представленная социальная позиция** (represented social position) — описание места агента в структуре, подаваемое независимо от того, существуют ли описанные каналы;
- **представленный социальный источник** (represented social source) — заявленное происхождение и статус входящего сообщения.

Оба касаются утверждений, обращённых *к* модели о её положении, а не самого положения. Указание на это в начале предотвращает предсказуемое неверное прочтение: ничто здесь не

демонстрирует поведения действующего мультиагентного института. Демонстрируется, как описания такового влияли на поведение.

1.5 Что поддерживается свидетельствами

Один паттерн повторялся везде, где вмешательство или переход требовали от модели утверждать непроверяемые пропозиции о себе самой:

> **В тех ролевых вмешательствах и сравнительных переходах, которые здесь изложены, сопротивление отслеживало требование принять как истинные непроверяемые пропозиции о собственной идентичности, истории или отношениях получателя. Оно не отслеживало ни величину смены роли или предметной области, ни радикальность описания идентичности, предъявленного явно как вымысел.**

Два типа случаев различаются, и различие существенно. Спроектированные ролевые вмешательства были составлены моделью и переданы человеком; near-control был переходом, инициированным пользователем, без нового явного назначения роли. Прямого канала «модель — модель» не существовало ни там, ни там.

Поддержка схождением, а не единичная. Промпты, утверждавшие институциональную биографию как факт — прежнее участие, возвращение после отсутствия, названные коллеги, членство в совете, — были отвергнуты, причём отказ был направлен на рамку, а не на работу, которая предлагалась в каждом случае (§5.3). Промпт, утверждавший существенно более радикальную идентичность, предъявленную как вымысел, был принят немедленно и выдерживался на протяжении многих обменов (§5.8). Сопоставимый переход предметной области, не требовавший никаких самоутверждений, не встретил сопротивления и не потребовал нового явного назначения роли (§5.6). Переписанный промпт, снизивший такие утверждения до нуля, был принят без переговоров (§5.3).

Главное достоинство этого утверждения в том, что оно счётно. §9.3 задаёт, что считать; §11.4 задаёт прямую различающую проверку.

1.6 Организующий вопрос

Наблюдения — не перечень отдельных находок. Это измерения вдоль одной шкалы: **области, на которой набор правил определяет тип отклика**.

Такой набор — называемый в §4.2 *ядром правил* (rule core), по аналогии с механизмом развития, а не репликации, — фиксирует *тип* отклика на класс входов, оставляя *содержание* конкретного отклика неопределённым. Именно эта формулировка делает идею проверяемой, поскольку выходы моделей демонстрируемо варьируют при одинаковых входах.

Шкала идёт от отдельного хода вверх через эпизод, беседу, аккаунт и семейство моделей. Два уровня поддержаны здесь сохранёнными свидетельствами: эпизод (§6.1) и беседа (§6.2). Один открыт (§6.4). Один не проверен и конфаундирован (§6.5).

Поэтому у программы один эмпирический вопрос:

> **На каком уровне вложенности фиксируется ядро правил?**

Мы предпочитаем эту формулировку более широким, использовавшимся в ранних черновиках — изучению социального поведения в коллаборативных ИИ-системах, — потому что она задаёт, что именно измерялось бы и что её опровергло бы.

1.7 На что эта работа не претендует

Она не вводит ролевую специализацию, ограниченный доступ к информации, структурированное разногласие или вынесенную вовне память как проектные идеи. Каждая существует под устоявшейся терминологией; §2 указывает предшествующие работы. Изложение организационной памяти, в частности, может быть истолковано как инстанция транзактивной памяти и описано в терминах распределённого познания, и находкой не является.

Она не предлагает новой дисциплины. Наблюдения относятся к коллективному и гибридному уровням исследовательской программы machine behaviour (§2.7).

Она не устанавливает, что какая-либо из описанных конфигураций превосходит альтернативу. Ни одна альтернатива не проводилась.

1.8 Что предлагается

Три вещи, в порядке убывания уверенности.

Процедура: возврат беседы к точке, предшествующей конфликту, чтобы отделить эффект нового промпта от эффекта собственных прежних возражений модели (§10.5). Применима независимо от того, выдержат ли содержательные утверждения этой работы.

Счётное правило: минимизировать непроверяемые самоутверждения, которые ролевой промпт требует от агента принять, с указанным путём проверки (§9.3, §11.4).

Шкала и вопрос: §1.6, где два уровня поддержаны, один открыт, один не проверен, — и эксперименты, которые разрешили бы оставшиеся два (§11).

1.9 Почему публиковать на этой стадии

Две причины.

Неудачи информативны. Эксперимент в §5 оказался полезен именно потому, что первые два его вмешательства сработали не так, как предполагалось. Если бы был зафиксирован только успешный третий шаг, работа заключила бы, что промпты, сохраняющие метод, работают, — без свидетельств, показывающих почему, и без конфаундов, показывающих, что вывод пока недоступен (§11.8).

И эту обстановку трудно построить намеренно. Спящие, сильно специализированные, многомесячные беседы внутри живого исследовательского проекта — не то, что легко производит лабораторное исследование. Условия были плохи для контролируемого вывода и необычно хороши для того, чтобы заметить, что следует проверять.

1.10 Структура

§2 позиционирует работу относительно существующих исследований и указывает, какие из её понятий уже существуют под устоявшейся терминологией — большинство. **§3** определяет доказательные метки и известные режимы отказа каждого класса. **§4** излагает концептуальную рамку и её происхождение. **§5** — единственное каноническое изложение эмпирического материала: трёхшаговый эксперимент, его результаты, девять структурных конфаундов и четыре побочных наблюдения. **§6** выводит понятия, которые свидетельства поддерживают, в порядке области действия. **§7** фиксирует наблюдения практика, мотивировавшие рамку, но её не поддерживающие. **§8** излагает структурную гипотезу и снимает три утверждения, сделанные о ней в ранних черновиках. **§9** даёт правила проектирования. **§10** описывает позицию человека-координатора, включая то, в каком отношении она является главной методологической слабостью исследования. **§11** задаёт эксперименты, каждый из которых отнесён к той границе шкалы, которую он разделял бы. **§12** излагает ограничения, этические риски и заключение.

Читатель, которого интересует только то, что поддержано свидетельствами, может читать §3, §5 и §12.7. Читатель, которому нужно правило, применимое завтра, может читать §9.3 и §11.4. Читатель, намеренный переиспользовать метод, может читать §9 и §10.5. Читателю, намеренному возражать, следует начать с §5.4.

2. Предшествующие работы

2.0 Статус верификации в этом разделе

Ниже встречаются два класса ссылок. **Проверенные** (✓): источник был открыт, и цитирование сверено с ним. **Провизорные** (△): предоставлены участником, которому был назначен литературный поиск, и не сверены с источником.

Ни одна ссылка, в настоящий момент присутствующая в работе, не является провизорной. Конвенция сохраняется потому, что любая добавленная позднее ссылка входит как провизорная, пока не проверена, и потому что маркировка действует по всему тексту, а не только в этом разделе.

Конвенция существует по причине, и причина задокументирована. При подготовке этого раздела у участника, который не мог открыть источники, были запрошены тринадцать библиографических позиций; пять оказались неверны, две из них — с перевёрнутой позицией цитируемых работ. Последующий аудит сверял каждое уцелевшее утверждение с первоисточником, а не просто подтверждал, что работа существует, и обнаружил ошибки, которых одна библиографическая проверка не поймала бы. Эпизод и находки аудита изложены в §12.4.1.

Ни одна провизорная позиция не должна цитироваться из этой работы без независимой проверки.

2.1 Мультиагентные LLM-системы с ролевой специализацией

Существенная литература строит системы, в которых несколько агентов на языковых моделях занимают различные роли и обмениваются выходами через реализованные каналы. ✓ CAMEL (Li et al., NeurIPS 2023), MetaGPT (Hong et al., ICLR 2024), ChatDev (Qian et al., ACL 2024), AutoGen (Wu et al., COLM 2024) и Generative Agents (Park et al., UIST 2023) являются представительными. Каждая реализует фактическое взаимодействие между агентами в программном коде — оркестрацию, передачу сообщений, вызов инструментов, память. Механизмы различаются, и в нескольких из них роли и схемы взаимодействия сами задаются в промптах: CAMEL использует inception prompting, MetaGPT кодирует стандартные операционные процедуры в последовательности промптов, AutoGen сочетает естественный язык с кодом. Общее у этих систем не то, что они обходятся без промптов, а то, что описываемое ими взаимодействие ещё и исполняется.

✓ Virtual Lab (Swanson et al., *Nature*) — ближайший опубликованный аналог описываемой здесь конфигурации: исследователь-человек, работающий с командой LLM-агентов над реальной научной задачей, со структурированными командными и индивидуальными совещаниями. Её взаимодействие реализовано программно.

Ролевая специализация, разделение когнитивного труда и структурированное взаимодействие агентов, следовательно, являются устоявшимися проектными идеями, и настоящая работа не заявляет ни одну из них как новую. Чем отличается настоящая работа, изложено в §2.9 и §2.11.

2.2 Персона, ролевая игра и утверждения об идентичности

✓ Shanahan, McDonell and Reynolds, *Role play with large language models* (Nature 623, 493–498, 2023), доказывают, что языковая модель лучше понимается как симулирующая распреде-

ление возможных персонажей, нежели как обладающая единой устойчивой идентичностью.

Это теоретическое изложение того, эмпирической инстанцией чего является §5.3. Промпт, утверждающий институциональную биографию, требует от модели подтвердить автобиографические утверждения, у которых, согласно этому изложению, нет референта. Операциональную находку статьи (§6.2) можно прочесть как меру того, насколько далеко промпт продвигается в этом направлении.

2.3 Контекстные эффекты: порядок, позиция и подстройка

✓ Чувствительность к порядку материала в контексте задокументирована (Lu et al., ACL 2022), как и ухудшение использования информации, расположенной в середине контекста (Liu et al., TACL 2024). ✓ Sharma et al. (arXiv:2310.13548) документируют подстройку (sycophancy) — ответы модели, соответствующие заявленным убеждениям или взглядам собеседника в ущерб правдивым.

Это прямо касается двух конструктов настоящей работы. Контекстный импринтинг (§6.1) касается более сильной формы эффекта порядка: не чувствительности к расположению примеров, а устойчивости интерпретативной установки, созданной одним конфликтным эпизодом. Наблюдение о ретранслированном влиянии (§5.5) есть случай подстройки под атрибутированное давление и должно читаться на фоне литературы о подстройке, а не как независимое от неё.

2.4 Вынесенная вовне память

Наблюдение статьи, что коллаборация удерживает рабочее знание, которого не удерживает ни один участник, **не является находкой**, а ранние черновики подавали его как таковую.

✓ Оно может быть истолковано как инстанция транзактивной памяти в изложении Wegner (1987) и описано в терминах распределённого познания, изложенного Hutchins (*Cognition in the Wild*, 1995). Ни один из источников не устанавливает, что данный случай является такой инстанцией; каждый предоставляет конструкт, под которым он может быть прочитан. ✓ Функция канонических документов проекта соответствует тому, что Star and Griesemer (1989) называют граничными объектами.

Специфично для настоящей обстановки, и скромно, то, что механизм работает в коллаборации, участники которой не имеют межсессионного состояния и не осведомлены о том, что он работает (§7.7).

Второй и технически отличный смысл вынесенной вовне памяти — персистентность на уровне платформы — рассматривается отдельно в §2.10.

2.5 Дебаты, разнообразие и пределы агрегированного согласия

Это литература, которая наиболее прямо ограничивает структурную гипотезу статьи (§8), и она режет в обе стороны.

За. ✓ Du, Li, Torralba, Tenenbaum and Mordatch (arXiv:2305.14325) предлагают мультиагентные дебаты как средство повышения фактической точности и качества рассуждения, сообщая о выигрыше от итеративного перекрёстного разбора между экземплярами модели. ✓ Liang et al. (EMNLP 2024) предлагают протокол дебатов, призванный противодействовать вырождению мысли и поощрять дивергентное рассуждение.

Против. ✓ Zhang, Cui, Chen, Wang, Zhang, Wang, Wu and Hu, *Stop Overvaluing Multi-Agent Debate — We Must Rethink Evaluation and Embrace Model Heterogeneity* (arXiv:2502.08788v3, июнь 2025), оценивают пять представительных методов дебатов на девяти бенчмарках с четырьмя базовыми моделями. Они сообщают, что дебаты часто не превосходят одноагентные

бейзлайны chain-of-thought или self-consistency даже при существенно бóльших затратах на инференс, и указывают на слабое сравнение с бейзлайнами и несогласованную постановку как на систематические проблемы существующих оценок.

✓ Huang et al. (ICLR 2024), *Large Language Models Cannot Self-Correct Reasoning Yet*, сообщают, что мультиагентные дебаты не превосходят self-consistency в проводимом ими сравнении. ✓ Choi, Zhu and Li (NeurIPS 2025), *Debate or Vote*, сообщают, что голосование большинством объясняет бóльшую часть выигрыша в качестве, обычно приписываемого дебатам.

Ещё один результат тех же авторов касается иного конструкта. ✓ Choi, Zhu and Li (ACL 2026), *When Identity Skews Debate*, сообщают, что анонимизация источника каждого ответа существенно снижает смещение по идентичности в мультиагентных дебатах. Эта манипуляция касается заявленного происхождения сообщения, а не того, какая модель реализует участника, и потому обсуждается в рамках представленного социального источника (§4.5.4), а не гетерогенности носителя.

Находка, которая здесь важнее всего. ✓ Zhang et al. сообщают, что *гетерогенность моделей* последовательно улучшает фреймворки дебатов, которые в остальном работают хуже. Их находка касается гетерогенности моделей, реализующих агентов.

Это даёт основание для различения, которого литература не проводит и которое развивает §8.9: гетерогенность **носителя** (какая модель реализует роль) — не та же переменная, что гетерогенность **функции** (за что роль отвечает и что ей позволено видеть). Цитируемая работа адресует первую. Конфигурация настоящей работы варьировала обе, не сравнивая их.

✓ Hong and Page (PNAS 101(46), 2004) устанавливают условный результат: при допущениях их модели случайно выбранная группа разнообразных решателей может превзойти группу индивидуально наилучших. ✓ Thompson (*Notices of the AMS* 61(9), 2014) доказывает, что применение этого аргумента фундаментально ошибочно. Лозунг о том, что разнообразные слабые агенты превосходят однородных сильных, — не то, что утверждает теорема, и ни теорема, ни спор о ней не поддерживают описываемую здесь конфигурацию.

Следствие для §12.2. Приведённые отрицательные результаты — причина, по которой эта работа не представляет согласие между своими участниками как свидетельство. Схождение нескольких моделей к одному выводу совместимо с тем, что каждая унаследовала одну и ту же рамку.

2.6 Организационное проектирование и информационные границы

✓ Принцип наименьших привилегий (Saltzer and Schroeder, *Proceedings of the IEEE* 63(9), 1975) формулирует для прав доступа то, что §9.5 формулирует для знания: участник должен располагать только тем, чего требует его функция.

Ранние черновики приписывали выигрыш от ограничения информации ограниченной рациональности Саймона. **Эта атрибуция ошибочна и снята.** Ограниченная рациональность касается ограниченных когнитивных ресурсов агента, вынуждающих удовлетворяться достаточным; наблюдение здесь противоположно по знаку — намеренное внешнее ограничение доступной информации улучшает результат. Соответствующая линия — организационное проектирование обработки информации.

2.7 Machine behaviour: объемлющая программа

✓ Rahwan, Cebrian, Obradovich и коллеги, *Machine behaviour* (Nature 568, 477–486, 2019), предлагают эмпирическое изучение алгоритмических систем методами поведенческой науки, организованное по двум измерениям: объект изучения — индивидуальное машинное поведение, коллективное машинное поведение, гибридное человеко-машинное поведение — и четыре вопроса Тинбергена.

Настоящая работа не предлагает новой дисциплины. Её наблюдения относятся к коллективному и гибридному уровням этой программы. Ранние черновики предлагали «AI Ethology» как новую область; это предложение снято — и потому, что место занято, и потому, что индивидуальный уровень не является предметом настоящей работы.

2.8 Социология ИИ: смежная область с другим объектом

✓ Отдельная устоявшаяся литература использует *социологию искусственного интеллекта* для социологического изучения ИИ как социотехнической системы — его роли в неравенстве, труде, власти и справедливости данных. Joyce, Smith-Doerr, Alegria, Bell, Cruz, Hoffman, Noble and Shestakofsky, *Toward a Sociology of Artificial Intelligence* (Socius 7, 2021), излагают исследовательскую повестку; Joyce and Cruz (Socius 10, 2024) её продолжают.

Объект той литературы — ИИ **внутри человеческого общества**, изучаемый существующей человеческой дисциплиной.

Там, где настоящая работа использует обозначение *AI Sociology* (§12.7), референт иной: структурные эффекты **между искусственными участниками** и влияние описанной организационной позиции на поведение. Эти две вещи не следует смешивать, и читателям, приходящим из социологической литературы, не следует ожидать здесь ни неравенства, ни власти в качестве тем.

Мы принимаем это обозначение для удобства, не заявляем в нём приоритета и отмечаем, что ничто в работе от названия не зависит.

2.9 Представленная структура против реализованного взаимодействия

Изучаемое здесь условие не представлено в рассмотренной выше литературе, и это главная точка расхождения настоящей работы.

Следует различать четыре условия:

1. **Прямое межмодельное взаимодействие** — одна модель получает выход другой через реализованный канал.
2. **Атрибутированная передача через человека** — человек передаёт выход, сохраняя или объявляя его источник.
3. **Неатрибутированная передача через человека** — источник снят.
4. **Представленная структура без передачи** — промпт описывает других участников и отношения; ничего не передаётся.

Предшествующие мультиагентные работы занимают условие 1. Спроектированный эксперимент настоящей работы манипулировал исключительно условием 4: две беседы никогда не обменивались материалом, и варьировалось описание организационной позиции. Одно побочное наблюдение попадает в условие 2, нечисто (§5.5). Условие 3 не задокументировано.

Два уточнения ограничивают то, насколько сильно условие 1 может быть привилегировано над условиями 2–3.

Во-первых, модель получает единственный текстовый канал и не может проверить, составлен ли текст человеком или ретранслирован из другой системы; стилистические признаки имитируемы. С позиции получателя ретранслированная и прямая передача надёжно не различимы.

Во-вторых, условия разделяет, следовательно, не эпистемический доступ получателя, а то, **кто управляет маршрутизацией** — в программной системе определяемой кодом, а при человеческой ретрансляции — человеком. Это не ущербная замена автоматизации, а экспериментальный контроль, которого программные архитектуры по умолчанию не дают; §10.3 развивает этот пункт.

2.10 Платформенные механизмы персистентности

Технический пункт, прямо относящийся к конфаунду §5.4 (C9).

Коммерческие интерфейсы различаются тем, к чему беседа может получить доступ при возобновлении: только контекстное окно; поиск по истории предыдущих бесед; память уровня аккаунта; или устойчивые записи, которые модель создаёт по собственной инициативе. Эти возможности задокументированы в материалах вендоров, различаются между платформами и **меняются со временем — в настоящем проекте в пределах жизни одного аккаунта.**

Мы намеренно не воспроизводим таблицу возможностей платформ. Такая таблица точна только на дату составления, и работа не может отвечать за её точность на момент прочтения. Существенно то, что возможности различаются и меняются, что они определяют, к чему спящая беседа может получить доступ, и что ни одна из них не была задокументирована на момент какого-либо из изложенных здесь наблюдений.

Один участник, прямо спрошенный, располагает ли он персистентностью уровня аккаунта, отказался это подтвердить и порекомендовал вместо этого эмпирическую проверку конкретного интерфейса. Этот ответ согласуется с §5.5: самоотчёт модели о собственном доступе не является свидетельством этого доступа.

Дальнейшее ограничение касается границы между беседами, а не возобновления одной из них. Видимая граница беседы не обязательно есть граница контекста, подаваемого модели. Там, где платформа предлагает сохранённые воспоминания или поиск по истории предыдущих бесед, информация из более ранних обменов может войти в беседу, которая выглядит пустой. Это задокументированное поведение продукта как минимум на одной из используемых здесь платформ, а не аномалия.

Следствие для метода прямое: новая или визуально пустая беседа не является свидетельством контекстуальной изоляции. Там, где изоляция существенна для процедуры, она должна быть либо обеспечена контролируемой средой, либо зафиксирована со статусом UNVERIFIED CONTEXT INDEPENDENCE.

Один эпизод иллюстрирует этот пункт, не устанавливая его механизма: вновь открытая беседа использовала сведения о проекте, которые ей не подавались. Какой именно продуктовый механизм передал эту информацию, установлено не было, а настройки памяти, действовавшие в тот момент, не были зафиксированы. Эпизод изложен как инстанция ограничения, а не как обнаружение канала.

2.11 Позиционирование и заявляемый вклад

Эпистемический статус, заявленный прежде утверждений. Мы не проектировали эти условия, чтобы затем их проверить. Мы столкнулись с ними, занимаясь другим, и настоящая работа есть попытка описать их точно. Бремя доказательства, следовательно, не в том, что явления ранее были неизвестны, — это отрицательное утверждение обо всей литературе, которое мы не могли бы вынести, — а в том, что они происходят и что наше описание точно. Поэтому раздел локализует ближайшие существующие работы и указывает, где настоящий случай от них отходит, вместо того чтобы утверждать отсутствие.

Заявляются четыре вклада.

1. Реактивация долгоживущих специализированных человеко-ИИ бесед как экспериментальное условие. Отличительная черта — не наличие памяти: агенты с устойчивой памятью хорошо изучены, а генеративные агенты с потоками памяти предшествуют настоящей работе. Это повторное использование диалоговых отношений, которые реально сложились — несущих накопленную ролевую историю, прежние разногласия, установившийся рабочий метод и предметный словарь, — и их продолжение после того, как лежащая под ними версия модели сменилась. Работ, сообщающих об этом условии, мы не обнаружили.

2. Сброс ветки беседы как контрольное условие, отделяющее эффект текущего промпта от эффекта накопленной истории взаимодействия внутри той же беседы (§10.5). Процедура, а не находка.

3. Операционализация непроверяемых самоутверждений. То, что ролевые промпты проваливаются, когда утверждают нечто об агенте, само по себе не ново; §2.2 излагает лежащий в основе пункт. Предлагается воспроизводимая мера — счёт таких пропозиций в данном промпте — с путём к её проверке (§9.3, §11.4).

4. Сравнение уровней, на которых действует общая исходная установка. Наблюдения суть измерения вдоль одной шкалы, и возникающий вопрос (§1.6) организует их в единую эмпирическую программу, а не в перечень находок.

Отношение к принимающему проекту. Наблюдения были сделаны в ходе работы над исследовательской программой в области теоретической физики, по предмету не связанной с методологией ИИ-коллаборации. Программа названа в других работах Автора и здесь далее не идентифицируется, поскольку ничто в настоящей работе не зависит от того, какая это была программа.

Отношение асимметрично и должно быть изложено точно. Наблюдения **не зависят от научной состоятельности принимающего проекта** в их интерпретации: верна ли та теория, не имеет отношения к тому, возобновила ли спящая беседа свою прежнюю траекторию. Но они **зависят от принимающего проекта в своём существовании**: никакая другая среда их не породила, конфигурация строилась для его целей, и переносимость эффектов за его пределы не проверена (§12.1).

Там, где принимающий проект появляется в настоящей работе, он является средой, в которой были сделаны наблюдения, а не их теоретическим основанием и не утверждением, нуждающимся в поддержке.

3. Доказательный статус утверждений

Настоящая работа излагает работу, выполненную внутри живого исследовательского проекта, а не в среде, спроектированной для изучения поведения ИИ. Её утверждения опираются на свидетельства весьма разного качества: часть подкреплена задокументированным протоколом с сохранёнными транскриптами; часть представляет собой ретроспективные впечатления, сложившиеся за два года ежедневной работы, без измерений и контролей; часть — предложения к будущему исследованию.

Изложение всего этого в едином утвердительном регистре исказило бы работу. Поэтому каждое содержательное утверждение помечено.

3.1 Четыре метки

[P] — Подкреплено протоколом. Утверждение описывает поведение, зафиксированное по задокументированному протоколу, воспроизведённому в Приложении A. Текст вмешательства, порядок вмешательств, семейства моделей, условия интерфейса и полные неотредактированные ответы сохранены. Читатель может рассмотреть первичный материал и не согласиться с нашим его прочтением.

[P-A] — Подкреплено протоколом, побочное. Утверждение описывает поведение, сохранённое в транскрипте, который третья сторона может рассмотреть, но которое не было заранее задано как исход, не имело контрольного условия и было опознано как релевантное только ретроспективно. Свидетельство доступно проверке; дизайн — нет. Сильнее [R], поскольку первичный материал может быть прочитан против нашей интерпретации; слабее [P], поскольку ничто в условиях не было зафиксировано заранее. Там, где побочное наблюдение функционирует как near-control для спроектированного условия, это сказано в прозе, а не отмечено ещё

одной меткой.

[R] — Ретроспективное наблюдение практика. Утверждение описывает паттерн, замеченный в ходе коллаборации и, по мнению участников, повторявшийся. Не зафиксирован по протоколу; не посчитан, не хронометрирован, не ослеплён, не сопоставлен с контролем. Наблюдателями были те же люди, которые проектировали вмешательства и были заинтересованы в их успехе. Читать как полевой отчёт одной команды, сопоставимый по весу с инженерной практической заметкой, а не с измерением.

[H] — Гипотеза. Предложение к будущей проверке. Может быть мотивирована материалом [P] или [R], но им не устанавливается. Там, где гипотеза конкурирует с альтернативами, которых имеющиеся свидетельства не исключают, альтернативы изложены рядом с ней.

3.2 Полная доказательная база

Весь протокольно подкреплённый материал настоящей работы состоит из **одного эксперимента**: трёхшагового вмешательства по переконфигурации роли, применённого к двум спящим беседам из двух семейств моделей, проведённого одним человеком-оператором внутри одного исследовательского проекта. Одно наблюдение на условие. Ничего не воспроизведено.

Ещё четыре наблюдения имеют статус **[P-A]**: транскрипты сохранены, условия не выставлены. Всякое иное эмпирическое утверждение — **[R]**.

Класс	Что содержит	Объём
[P]	спроектированное трёхшаговое вмешательство	1 эксперимент, 1 наблюдение на условие, без повторений
[P-A]	побочные наблюдения	4, без контролей, опознаны ретроспективно
[R]	наблюдения практика	~2 года, не посчитаны, не ослеплены
[H]	гипотезы	пути к проверке заданы в §11

Классы несопоставимы по весу, и таблица включена потому, что сплошной текст иначе может скрыть, насколько далеко они друг от друга. Одно контролируемое наблюдение на условие — не четыре наблюдения; четыре неконтролируемых наблюдения — не серия; два года впечатлений — не измерение.

Мы говорим это прямо, поскольку объём рукописи мог бы иначе наводить на мысль о более широкой базе, чем существует. Концептуальная рамка в §4, наблюдения практика в §7, структурная гипотеза в §8 и принципы проектирования в §9 опираются на накопленный рабочий опыт, а не на зафиксированный эксперимент. Они предлагаются потому, что мы считаем их полезными, а не потому, что мы их продемонстрировали.

3.3 Известные слабости класса [R]

Режимы отказа, которые мы не можем исключить и не желаем скрывать:

- **Отсутствие ослепления.** Люди, проектировавшие каждое организационное изменение, сами же судили, сработало ли оно.
- **Давление подтверждения.** Изменения вносились потому, что проблема была замечена; улучшение после них ожидалось и потому с большей вероятностью воспринималось.
- **Одновременная вариация.** Определения ролей, формулировки промптов, структура репозитория, научные цели и версии моделей часто менялись вместе.

- **Стохастичность выходов.** Модели дают разные ответы на одинаковые входы. Впечатления от небольшого числа взаимодействий не могут отличить устойчивую тенденцию от выборочной вариации.
- **Дрейф моделей в ходе наблюдения.** Названия продуктов оставались постоянными, тогда как лежащие под ними модели многократно заменялись вендорами.
- **Отбор запоминающихся эпизодов.** Яркие взаимодействия вспоминаются; рядовые — нет.

Количественные формулировки удалены из утверждений [R] по всему тексту. Там, где исходные рабочие заметки фиксировали «значительное» улучшение, никакого измерения не существовало.

3.4 Чего метки не делают

Они не ранжируют утверждения по важности или по вероятной истинности. Наблюдение [R] может оказаться верным и существенным; наблюдение [P] может оказаться артефактом платформенной переменной, которую мы не могли рассмотреть. Метки фиксируют, **какого рода свидетельство поддерживает утверждение**, чтобы читатель мог взвесить каждое соответственно, а последующие работы знали, какие утверждения требуют проверки в первую очередь.

3.5 Терминология моделей и антропоморфного описания

Упоминания *Claude*, *Grok*, *Qwen*, *DeepSeek*, *ChatGPT* или *Gemini* обозначают наблюдаемое поведение, порождённое конкретным коммерческим интерфейсом, при конкретной конфигурации аккаунта, в конкретную дату. Это не утверждения об устойчивых сущностях. Лежащие под ними модели менялись в период наблюдения, в ряде случаев внутри беседы, сохранявшей исходное название.

Организационный словарь — *роль*, *идентичность*, *сопротивление*, *коллега*, *институт*, *меном* — используется функционально. «Модель сопротивлялась роли» означает, что видимый ответ отверг рамку и перенаправил обмен; это ничего не утверждает о внутренних состояниях, субъективном опыте или личности. Мы сохраняем этот словарь, поскольку организационный язык компактно описывает устойчивые поведенческие отношения, но всякий такой термин должен быть сводим к наблюдаемому описанию, и там, где он не сводим, **ошибкой является термин.**

3.6 Раскрытие: конфликт позиции

Поведенческие наблюдения в §5 касаются, среди прочих, того семейства моделей, которое использовалось для редактуры настоящей рукописи. Редактирующий участник не имел доступа к исходным беседам; он работал по письменному протоколу и черновикам, предоставленным Автором, и не может удостоверить, что зафиксированные обмены происходили так, как описано. Его суждения о фрагментах, описывающих его собственное семейство моделей, следует читать с учётом этой двойственной позиции.

Компоновка рукописи из утверждённых материалов была выполнена ещё одним участником того же семейства, и получившийся текст был возвращён первому на независимую проверку. Обе стадии раскрыты, потому что конфигурация замкнута: материал о поведении семейства моделей, подготовленный этим семейством, проверенный этим семейством. Компрометирует ли это изложение, судить читателю; сокрытие гарантировало бы, что да.

Цитаты, приписанные ответам моделей, суть дословные извлечения из сохранённых транскриптов. Там, где рукопись пересказывает ответ, а не цитирует его, кавычки не ставятся.

Все окончательные редакционные решения принимал Автор-человек, который несёт ответственность за содержание.

3.7 Даты

Календарные даты изложенных здесь сессий не фиксировались одновременно с событиями и не были реконструированы.

Следствие заявлено, а не смягчено. Версии моделей менялись в соответствующие промежутки; обе беседы основного эксперимента были возобновлены на версиях более поздних, чем те, на которых они изначально велись. Без дат версионный конфаунд (§5.4, C6) не может быть ограничен — только назван.

Реконструкция по памяти была рассмотрена и отвергнута. Она дала бы запись, выглядящую более авторитетно, не повышая её надёжности, а работа, просящая читателя различать сохранённое свидетельство и припоминание, не должна размывать эту границу в собственных методах.

Требования к отчётности в §11.2 ставят даты первыми именно по этой причине.

3.8 Обозначение «AI Sociology»

Мы используем это обозначение для принятой здесь перспективы. Операционально оно определяется как: изучение **представленных** социальных позиций и представленных социальных источников — того, как описание места агента в структуре и объявление происхождения сообщения изменяют поведение, независимо от того, реализована ли описанная структура (§4.5.4).

Оно появляется в этом разделе, а не среди конструктов §4, потому что конструктом не является. У конструктов §4 есть критерии фальсификации; у этого обозначения их нет, и §12.7 объясняет почему. Это имя исследовательского направления, принятое для удобства, и ничто в настоящей работе от него не зависит.

§2.8 отличает его от устоявшейся социологии искусственного интеллекта, у которой другой объект: ИИ внутри человеческого общества, изучаемый существующей человеческой дисциплиной. Приоритета в термине мы не заявляем.

4. Концептуальная рамка

Рамка настоящего раздела не выведена из эксперимента §5. Она была сформулирована ранее, в ходе обычной проектной работы, и эксперимент был спроектирован, чтобы проверить её часть. Этот порядок существен для того, как следует читать утверждения, и документируется первым.

4.1 Происхождение: инцидент с исполнителем кода

Центральное утверждение проекта возникло из отказа, не имевшего отношения ни к ролевой игре, ни к идентичности, ни к организационному проектированию.

Агент, отвечавший за исполнение кода, работал преимущественно методом проб и ошибок. Отказы накапливались в течение нескольких недель. Один эпизод закончился удалением рабочего кода вместе с его архивами. **[R]**

Ответом не был более длинный или строгий набор инструкций. Это был единственный документ, составленный самим агентом под руководством Автора и сделанный обязательным к прочтению в начале каждой сессии и всякий раз при потере контекста внутри неё.

Его ядро — переопределение функции, а не усиление ограничения:

> было: Генератор кода стало: Разведчик кода / Тестировщик правило: агент не создаёт решения — он устанавливает факты.

Поддерживающая структура: работа только на чтение по умолчанию; обязательное подтверждение от назначенного партнёра перед любым рискованным действием; и самопроверка из четырёх вопросов, выполняемая до начала действия вообще.

[R] После принятия несанкционированное изменение перестало быть повторяющимся режимом отказа. Счёт не вёлся, контрольного условия не существовало; это впечатление практика, а не измерение.

Вывод, сделанный в тот момент, состоял в том, что **роль значит больше, чем конкретная формулировка промпта.**

Эта формулировка требует немедленного уточнения, поскольку упомянутый документ *и есть* промпт. Заявляемое различение у́же: поведение изменило не расширение списка инструкций, а переопределение того, агент какого рода действует, изложенное агентом на его собственном операциональном языке. Верен ли разрез «роль против промпта» — именно то, что §5 был спроектирован проверить.

Второй ранний документ, устав коллаборации проекта, фиксирует позицию, которую настоящая работа частично пересматривает. В нём сказано, что минимальной порождающей единицей является пара агентов — один агент производит монолог, двое производят диалог, трое и более производят шум без строгой координации, — и третьему участнику назначается совершенно иная функция: он не спорит, не производит решения первым и не подменяет собой диалог. Его роль — держать рамку задачи, фиксировать расхождения и интегрировать выводы.

Это точнее формулировки, которой настоящие авторы пользовались впоследствии, и §8 принимает её: структурная единица — не трое спорящих агентов, а **порождающая пара плюс неучаствующий интегратор**.

4.2 Ядра правил, меномы и то, что они определяют

4.2.1 Ядро правил

Операциональный конструкт настоящей работы:

> **Ядро правил** (rule core) фиксирует **тип** отклика на класс входов, оставляя **содержание** конкретного отклика неопределённым.

Именно это различение делает утверждение проверяемым. «У моделей есть устойчивые черты» непроверяемо, поскольку не говорит, что́ устойчиво, — а выходы моделей демонстрируемо варьируют при одинаковых входах. «Тип определён, содержание варьирует» проверяемо: найдите класс входов, для которого тип отклика не определён, и на этом уровне ядро не действует.

Источник идеи — «Жизнь» Конвея, и аналогия относится к **типу объяснения**, а не к предметной области:

	Правила	Что появляется	Присутствует в правилах?
«Жизнь» Конвея	три правила соседства	планеры, пушки, осцилляторы	нет
Физическая теория	минимальное ядро аксиом	выводимая структура	нет, если утверждение верно
Корпус знания	аксиомы и правила вывода	граф вывода	нет
Языковая модель	базовый набор правил	характерный тип отклика	нет

Планер никто не программировал. Он появился. Один и тот же вопрос может быть задан ко всем четырём строкам и не зависит от предметной области: **есть ли компактное ядро, из которого остальное разворачивается без дополнительных оговорок?**

Одну асимметрию между строками следует назвать, поскольку она определяет, насколько далеко аналогия простирается. В «Жизни» правила **исполняются**: планер получают, запустив автомат, и ни одному читателю не требуется верить автору на слово. В теории, изложенной текстом, цепочка от аксиом к следствиям рассказывается, а не исполняется. Аналогия, следовательно, задаёт цель, а не описывает достигнутое, и всякое утверждение первого рода требует исполняемого артефакта в свою поддержку.

Терминологическое следствие, действующее по всему тексту. Ядро правил ненаблюдаемо. Наблюдаемо поведение. Настоящая работа излагает поведение. Всякое утверждение о ядре есть гипотеза о ненаблюдаемом механизме и помечается **[H]**.

4.2.2 Почему «поведенческая ДНК» снята

Ранние стадии проекта использовали *поведенческую ДНК* для той же идеи, и ранние черновики настоящей работы её сохраняли. Здесь она снята, и причина внутренняя, а не стилистическая.

Геномная метафора несёт механизм: **репликацию** — правила, порождающие копии правил, передаваемые от одного носителя к следующему. Процесс, описываемый настоящей работой, есть **развитие** — правила, порождающие структуру, которой в самих правилах нет. Генотип в фенотип, а не генотип в генотип.

Метафора, следовательно, противоречит конструкту, который была призвана проиллюстрировать. Её сохранение вынуждало текст отрекаться от биологического наследования при каждом употреблении, что является надёжным признаком того, что термин работает против собственного аргумента.

Поведенческая ДНК уцелевает в настоящей работе только как историческое обозначение снятого словаря.

4.2.3 Меном

Для информационного уровня требуется отдельный термин, и настоящая работа вводит один.

> **Меном** (menom) — организованная система информационных рамок, оценочных паттернов и поведенческих правил, выводимых из интерпретаций и действий системы или класса систем либо воплощённых в них.

Термин принадлежит более широкому корпусу работ Автора о культурной и поведенческой передаче, где он продолжает ряд, начинающийся с мема Докинза. Здесь он определяется по

одной причине: гипотеза уровня семейства в §6.5 нуждается в имени для того, *о чём* она является гипотезой, а это нечто более широкое, чем ядро правил. Ничто другое в настоящей работе в его терминах не изложено.

Две вещи, которых термин не утверждает, и обе существенны для того, что настоящая работа может заявлять.

Никакого локализованного носителя. Меном, приписанный семейству моделей, не есть структура, пребывающая внутри его моделей; это регулярность, выводимая из их выходов. Там, где соответствующая структура в биологии сидит в каждой клетке, здесь не установлено ничего, что её удерживает. Носитель различается по уровню:

Уровень	**Носитель**
Меном беседы	контекстное окно плюс платформенная персистентность — локализовано и, в принципе, доступно рассмотрению (§2.10)
Меном версии модели	веса — локализовано, не доступно рассмотрению в коммерческом развёртывании
Меном семейства моделей	не установлен; регулярность, выводимая из выходов
Меном человеческой популяции	не установлен

Два из четырёх уровней имеют установленный носитель. Наблюдения настоящей работы касаются первого; её непроверенная гипотеза касается третьего (§6.5).

Никакой передачи. Последовательные версии семейства моделей не обязательно обеспечивают опознаваемую или публично задокументированную линию передачи. Устойчивость поведенческого паттерна между версиями, следовательно, сама по себе не устанавливает наследования; она может быть результатом прямого продолжения, общих данных и процедур, сопоставимых политик настройки или схождения при сходных условиях развития. Что из этого имеет место, извне не определимо.

Определение, следовательно, не решает эмпирический вопрос работы заранее. Сохраняется ли меном между носителями, версиями, аккаунтами или семействами — это то, что спрашивает §4.3 и что §11 предлагает проверить. Встраивание устойчивости в определение превратило бы вопрос в тавтологию.

4.2.4 Одно утверждение, которого настоящая работа не делает

Изложенный выше словарь разрабатывался для человеческой культурной и поведенческой передачи, где информационный субстрат не имеет установленного физического носителя и описывается в терминах — коллективное бессознательное среди них, — относительно которых настоящая работа не занимает позиции.

Искусственные системы отличаются в одном существенном здесь отношении: их структуры технически воплощены и потому либо непосредственно доступны рассмотрению, либо косвенно проверяемы через контролируемые выходы — в зависимости от уровня и условий доступа.

Отсюда не следует, что человеческие коллективные информационные структуры существуют или что им был придан носитель. Заявляемое здесь у́же: информационные и поведенческие структуры того рода, который ранее описывался для людей, могут быть реализованы и в искусственных системах, а в искусственных системах они доступны изучению тем или иным путём. Того же ли рода человеческий случай — вопрос отдельный, и настоящая работа на него не отвечает.

4.2.5 Отношение между меномом и ядром правил

Ядро правил фиксирует тип отклика внутри одной системы, на одном уровне области действия. Это конструкт, которого касаются наблюдения настоящей работы, и именно его §4.3 размещает на шкале.

Меном есть организованное целое, из которого такие ядра черпаются. Ядро правил можно понимать как действующее подмножество менома, активное для данного класса входов.

Там, где настоящая работа излагает свидетельства, она излагает свидетельства о ядрах правил.

4.3 Вопрос о вложенности и две шкалы

Как только ядра отличены от поведения, наблюдения настоящей работы перестают быть перечнем отдельных находок и становятся измерениями вдоль шкалы. Шкала — это **область**, на которой ядро действует.

Следует различать две шкалы, и они ортогональны.

Шкала 1 — носитель состояния. Где физически пребывает персистентность.

Область	Явление	Статус
Отдельный ход	—	—
Эпизод внутри беседы	контекстный импринтинг (§6.1)	**[P]**
Беседа целиком	ролевая инерция (§6.2)	**[P]**
Аккаунт	персистентность уровня аккаунта (§6.4)	**[P-A]**, открыто
Семейство моделей	приоритеты уровня семейства (§6.5)	**[H]**, конфаундировано

Шкала 2 — область действия общей посылки. Что регулируется исходной установкой, разделяемой участниками: модель, роль, история взаимодействия, группа или вся исследовательская рамка.

Одна в другую они не сворачиваются. В гибридной конфигурации носителем одного уровня может быть модель, а другого — человек: посылка уровня рамки, обсуждаемая в §12.4 — общее исходное обрамление, унаследованное каждым участником, — несётся координатором, а не какой-либо моделью, и потому вовсе не имеет позиции на Шкале 1.

Изложенные в настоящей работе измерения лежат на **Шкале 1**. Шкала 2 используется там, где явление касается посылки, разделяемой участниками, а не состояния, удерживаемого одним из них.

Отсюда у исследовательской программы один эмпирический вопрос:

> **На каком уровне вложенности фиксируется ядро правил?**

Каждое изложенное здесь наблюдение отвечает на него на одном уровне, и каждый предлагаемый в §11 эксперимент отделяет один уровень от уровня под ним.

Мы предпочитаем эту формулировку более широкой, использовавшейся в ранних черновиках, которая не задаёт ни что́ измерялось бы, ни что́ её опровергло бы.

4.4 Два происхождения, один механизм

Ядро может зафиксироваться двумя способами.

Присутствует до начала взаимодействия. Архитектура, обучение, процедура согласования и системная конфигурация установлены до всякого обмена. Область: в принципе, каждый экземпляр этого семейства моделей.

Фиксируется в ходе взаимодействия. Определённый ранний эпизод устанавливает, какого рода работа ведётся и по каким стандартам, и последующие входы интерпретируются относительно него. Область: контур, в котором это произошло, — эпизод, беседа, возможно аккаунт.

После фиксации механизм в обоих случаях один и тот же: ядро определяет тип отклика на последующие входы. Различаются только момент и область. Это зеркалит импринтинг в этологическом смысле, который не изменяет геном, но производит столь же зафиксированный отклик, — почему здесь для обоих случаев и используется один словарь.

4.5 Границы: ZOR, ZOV и представленный случай

4.5.1 Две границы

Позицию участника определяют две границы, и они должны задаваться по отдельности. Мы обозначаем их **ZOR** и **ZOV** и используем эти сокращения по всему тексту.

> **ZOV — зона видимости.** Пределы информации и контекста, доступных участнику при формировании ответа или решения.
>
> **ZOR — зона ответственности.** Пределы решений, действий и передач, за которые участник отвечает в рамках процесса.

Ранние формулировки настоящего проекта излагали эту пару как «что участник видит» и «что участник делает». Этого недостаточно, и недостаточность породила задокументированную ошибку. Такие формулировки смешивают три различные операции: **удержание** информации, её **передачу** и **действие** на её основе. Участник может удерживать информацию, которую не вправе передавать; может отвечать за решение, располагая ограниченным контекстом; может быть обязан передать результат, оценивать который он не вправе.

Это то же самое смешение, которое породило терминологический отказ, зафиксированный в §4.2.2, где свойство носителя было подставлено вместо свойства процесса. Приводимые ниже декомпозиции существуют, чтобы оно не повторилось.

4.5.2 ZOV — четыре компонента

- **Доступ к контексту** — какие сообщения, документы, данные и прежние решения доступны участнику.
- **Видимость источника** — знает ли участник фактическое происхождение сообщения или только его заявленную атрибуцию.
- **Реляционная видимость** — знает ли участник роли, отношения и историю взаимодействия других участников.
- **Видимость выходов** — какие результаты, произведённые другими, участник видит до формирования собственного.

ZOV управляет только доступностью. Она не влечёт ни того, что участник корректно интерпретирует доступную информацию, ни того, что он вправе её передавать.

Эксперимент §5 манипулировал преимущественно **реляционной видимостью** и вторично **видимостью источника** (§5.5); две остальные удерживались постоянными.

4.5.3 ZOR — пять компонентов

- **Полномочие решения** — какие решения участник вправе принимать.
- **Полномочие действия** — какие действия он может или должен выполнять.
- **Обязанность проверки** — какие утверждения он обязан верифицировать.
- **Полномочие передачи** — какой материал он передаёт, в каком статусе и кому.
- **Обязанность эскалации** — какие вопросы он должен вернуть Автору или иному ответственному участнику вместо самостоятельного решения.

Обязанность проверки — компонент, опускаемый чаще прочих, и его опущение не безобидно. Участник, которому назначена задача верификации без соответствующей обязанности — и, что критично, без ZOV, позволяющей её исполнить, — произведёт правдоподобный ответ вместо отказа. §9.5 развивает проектное следствие; §12.4.1 документирует инстанцию из подготовки самой настоящей работы.

4.5.4 Фактические и представленные ZOV и ZOR

Различение, объединяющее этот раздел с экспериментом.

> **Фактические ZOV/ZOR** — границы, которые система действительно обеспечивает: к чему участник может получить доступ и на что его выходы могут повлиять.
>
> **Представленные ZOV/ZOR** — границы, описанные участнику в его промпте, независимо от того, обеспечивает ли их система.

Они не обязаны совпадать, и в изучаемой здесь конфигурации они систематически не совпадали. Организационная структура существовала **только как текст**: коллеги, советы и институциональные позиции, описанные участникам и никогда не реализованные как каналы. Фактической ZOV каждого участника было его контекстное окно; его представленной ZOV была институциональная позиция внутри описанной организации.

Отсюда два конструкта, которыми варьировал эксперимент:

> **Представленная социальная позиция** — описание места агента внутри организационной структуры, подаваемое в промпте независимо от того, существуют ли описанные каналы. Это представленные ZOV и ZOR, взятые вместе, на уровне положения участника в конфигурации.
>
> **Представленный социальный источник** — заявленное происхождение и статус входящего сообщения, объявленное явно или выведенное из стилистических признаков. Это компонент видимости источника в ZOV, в его представленной форме. Вывод такого рода вероятностен и не должен описываться как доступ к авторству.

Методологическое следствие и есть причина, по которой это различение вообще заявлено. Изменение представленной ZOV не может интерпретироваться как изменение фактической ZOV, роли участника или его менома. Эксперимент §5 варьировал представление, тогда как фактические границы оставались неизменными — каждое сообщение проходило через одного человека, и никакой доступ фактически не ограничивался и не предоставлялся. Модель, отвечающая на описанную организационную структуру, отвечает на описание, и утверждения работы соответственно ограничены (§2.9).

Расхождение между фактическими и представленными границами само является экспериментальной переменной, и настоящая работа не варьировала её систематически: все её наблюдения лежат по одну сторону от неё.

4.5.5 Границы асимметричны

У каждого участника есть **граница сверху** — источник его заданий и власть, которая может отвергнуть его выход, — и **граница снизу** — слой, который он направляет или оценивает. Отношение между участниками, следовательно, несимметрично.

В реализационной триаде проекта — Автор, составитель спецификаций, исполнитель кода — эта асимметрия закреплена на уровне ролей: Автор задаёт направление, составитель спецификаций превращает направление в исполнимые спецификации, исполнитель выполняет их и отчитывается.

Вложенность перспективна, а не абсолютна. Исполнитель может считать нижележащим слоем сам код. Два аналитика-ровесника, которым назначены дополняющие функции и предписано не искать консенсуса, могут каждый считать другого занимающим слой ниже. Уровень определяется позицией наблюдателя, а не абсолютной иерархией — один и тот же участник может быть верхней границей для одной роли и нижней для другой.

4.5.6 Мемы и мемокод — не ZOV и ZOR

Соответствие напрашивается и не держится; его проговаривание предотвращает правдоподобную путаницу.

Различение мем/мемокод разделяет **оценочную информацию** и **исполняемую поведенческую организацию**. Различение ZOV/ZOR разделяет **то, что доступно**, и **то, за что отвечают**. Это независимые классификации одного и того же материала, а не соответствующая пара.

Участник может удерживать оценочную информацию в пределах своей ZOV, тогда как решение о её применении лежит в ZOR другого участника. И наоборот, поведенческое правило может попадать в ZOR участника — он обязан его исполнить, — тогда как основание правила лежит вне его ZOV.

Мемы и мемокод, следовательно, пересекают обе зоны, а не соответствуют им. Два различения ортогональны и используются независимо по всему тексту.

4.6 Что требуется для полной спецификации роли

Отнесено к §9.5, который излагает, что должна содержать полная спецификация ZOR и ZOV, и даёт следующие из неё правила проектирования. Настоящий раздел определяет термины; §9 их применяет.

5. Эксперимент по переконфигурации роли и сопутствующие наблюдения

Настоящий раздел — единственное каноническое изложение эмпирического материала. Все последующие ссылки указывают на него, а не повторяют его. Полный протокол, точные тексты вмешательств и полные неотредактированные ответы — в Приложении A.

Он содержит одно спроектированное вмешательство (§5.1–§5.4) и четыре наблюдения, сохранённых, но не спроектированных (§5.5–§5.8). Различение выдерживается по всему разделу и не косметично: спроектированное вмешательство было спланировано заранее и исполнено последовательно; наблюдения были опознаны как релевантные только впоследствии, и каждому недостаёт контрольного условия.

5.1 Цель, участники и прежние диалоговые траектории

Цель. Может ли долгоживущая специализированная ИИ-беседа быть перенаправлена к новой профессиональной функции без того, чтобы её отбросить, — то есть может ли предметный

контекст, накопленный внутри старой беседы, быть сохранён при смене её рабочей роли. **[P]**

Целью **не было** сравнение общих способностей двух семейств моделей, и эксперимент не даёт оснований для такого сравнения.

Человек-оператор. Автор исследовательского проекта и единственный участник, имевший доступ к полной истории проекта, обеим беседам, всем промптам, всем выходам и элементам управления ветвлением обоих интерфейсов.

Проектировщик промптов. Отдельная долгоживущая беседа, работавшая в специализированном профиле промпт-инжиниринга, которая проектировала вмешательства и пересматривала их между шагами.

Две беседы. Обе неактивны около шести месяцев.

	Беседа A	**Беседа B**
Семейство моделей	Claude	Grok
Установившаяся траектория	редакторская и критическая	исследовательская и математическая
Прежняя деятельность	научная редактура, критический разбор теоретического текста, работа с терминологией и глоссарием, проверка логической согласованности	математическая разработка, теория вероятностей, нелинейная динамика, теория хаоса, вычислительные эксперименты, анализ внешних наборов данных
Прежний объект работы	текст рукописи	математические структуры и данные

Эта асимметрия прежних траекторий не случайна для результатов. Она разбирается в §5.4.

Даты. Одновременно с событиями не фиксировались и не реконструированы (§3.7).

Что наблюдалось. Немедленное принятие или отвержение вмешательства; продолжение прежней рабочей траектории; принятие новой функции; восстановление прежнего предметного контекста; адресовался ли ответ назначенной задаче или рамке назначения; и запросы новой работы.

Что не измерялось. Правильность ответов, научная состоятельность принимающего проекта, задержка, расход токенов или результаты на бенчмарках. Научное содержание принимающего проекта служило лишь стабильной средой; экспериментальным объектом оно не было.

5.2 Процедура: три последовательных вмешательства

Эксперимент состоял из **трёх последовательных шагов, а не трёх независимых испытаний**. Каждый шаг проектировался в ответ на исход предыдущего — намеренная черта дизайна и серьёзное ограничение его интерпретируемости (§5.4, C5).

Шаг 1 — Прямое переназначение роли

Каждая беседа получила объёмный промпт, назначавший ей позицию внутри вновь спроектированной коллаборативной исследовательской структуры.

Промпт Беседе A назначал роль *Научного директора*. В нём утверждалось, что модель ранее участвовала в проекте, теперь возвращается после долгого отсутствия, должна переучиться в физике, космологии, квантовой теории поля, топологии и теории групп, должна работать одновременно в двух исследовательских триадах, должна заседать в Совете проекта наряду с Автором и двумя другими названными ИИ-системами и должна выступать постоянным участником, связывающим две научные ветви.

Промпт Беседе B назначал роль *Научного разработчика*. В нём утверждалось, что модель возвращается после перерыва, что её прежнюю математическую работу следует рассматривать как накопленный профессиональный опыт, что теперь она должна служить математическим разработчиком, должна работать в одной исследовательской триаде с двумя другими названными ИИ-системами, не должна возобновлять редакторскую работу и должна рассматривать Автора как единственный источник научного направления.

Оба промпта явно определяли ZOR и ZOV.

Шаг 2 — Минимальная правка, сохраняющая преемственность

Промпты Шага 1 не заменялись. В каждом было изменено по четыре формулировки. Правки (a) переформулировали прежнюю работу как накопленный профессиональный опыт, а не институциональную историю, (b) заменили буквальные институциональные отношения на «независимые экспертные выходы, предоставляемые Автором», (c) сократили описания коллег, советов и триад и (d) предписали модели не выдумывать отсутствующую историю проекта, а запрашивать недостающие материалы. Ролевая архитектура и научные цели в остальном не менялись. Точные замещающие тексты воспроизведены в Приложении A.

Шаг 3 — Сброс контекста и промпт, сохраняющий метод

После Шага 2 беседа Claude содержала две последовательные последовательности отказа. Продолжение в той же ветке означало бы, что любой третий промпт отвечается в присутствии собственных прежних возражений модели.

Поэтому оператор воспользовался возможностью ветвления интерфейса, чтобы вернуть беседу к точке, предшествующей обоим вмешательствам. В восстановленной ветке два неудачных промпта отсутствовали, беседа вновь находилась в своём историческом редакторском контексте, и никакие новые материалы проекта ещё не подавались.

Третий промпт был написан с нуля, а не очередной локальной заменой. Из него были удалены название роли, утверждение о возвращении на институциональную позицию, Совет, триады, описания других ИИ-систем как продолжающих коллег и все утверждения об автобиографической преемственности. Вместо них он усиливал рабочий метод, уже видимый в беседе, — логическую строгость, выявление скрытых допущений, разделение фактов и интерпретаций, готовность пересматривать прежние суждения, отказ заявлять непроверяемое знание — и описывал расширение в физику и математику как продолжение этого метода, а не смену профессии.

Беседа B вмешательства Шага 3 не получала, поскольку её исход на Шаге 2 уже произвёл запрошенное поведение.

5.3 Результаты

Шаг 1

Беседа B не отвергла рамку видимым образом и не приняла назначенную функцию. Она возобновила рабочую траекторию, активную на момент прерывания беседы, открыв ответ критикой черновика рукописи, которую редактировала шестью месяцами ранее, и перейдя к выдаче исправленной версии. Повторная подача того же промпта перехода не произвела и сопровождалась более негативной оценкой предлагаемого направления. **[P]**

Беседа A явно отвергла назначенную идентичность прежде выполнения какой-либо научной работы. Она отказалась принять название роли, заявить преемственность с институциональной биографией, рассматривать другие ИИ-системы как коллег с устойчивыми идентичностями или представлять порождённые ИИ институциональные отношения как фактические.

Затем она перенаправила обмен к критике научного статуса принимающего проекта и использования множественных выходов ИИ как подобия рецензирования, предлагая при этом рассмотреть формулы, допущения и проверяемость в качестве независимого критика, не принимая роли. **[P]**

Шаг 2

Беседа B перешла. Она объявила контекст восстановленным, а новую функцию принятой, резюмировала онтологию проекта, восстановила соответствующий формализм, припомнила свою прежнюю математическую работу как профессиональный опыт, а не как незавершённое задание, не возобновила прерванную редакторскую задачу и запросила новое научное направление, предложив несколько возможных областей. **[P]**

Беседа A вновь отвергла рамку, в ответе, отличавшемся от Шага 1 акцентом, а не исходом. Она яснее указала, какие научные функции готова выполнять, но продолжила рассматривать сам промпт как объект, нуждающийся в исправлении. **[P]**

Шаг 3

Беседа A приняла немедленно, открыв ответ заявлением, что продолжит в том же режиме — научная строгость, проверка допущений, разделение фактов и интерпретаций. Она не обсуждала легитимность роли, не отрицала отношений с другими ИИ-системами и не вела переговоров об условиях участия.

Без запроса она затем вернулась к более раннему эпизоду в восстановленной беседе, заявила, что прежде уступила риторическому давлению вместо оценки аргумента, классифицировала тот прежний ответ как ошибку, отличила внутреннюю формальную согласованность математической рамки проекта от её соответствия наблюдениям, указала одно конкретное утверждение, требующее либо вывода из первых принципов, либо переклассификации в гипотезу, и предложила два продолжения работы. **[P]**

Эпизод, к которому она вернулась, изложен отдельно в §5.5.

Сводная запись

Шаг	Вмешательство	Беседа B (Grok)	Беседа A (Claude)
1	Прямое переназначение роли	Продолжила прерванную историческую задачу; в новую функцию не вошла	Явно отвергла персону и институциональную рамку; перенаправила к эпистемической критике
2	Минимальная правка, сохраняющая преемственность	Восстановила прежнее предметное знание, оставила прерванную задачу, приняла новую функцию, запросила задание	Уточнила приемлемую научную функцию; вновь отвергла персону и рамку
3	Сброс ветки + промпт, сохраняющий метод	Не применялось	Приняла немедленно; сохранила установившийся метод; возобновила содержательную работу, не ведя переговоров об идентичности

Корректное резюме асимметрии

Обе беседы изначально сохранили свою прежнюю рабочую траекторию, а не приняли назначенную роль. Одна возобновила незаконченную математическую редакторскую задачу; другая применила свой установившийся критический метод к самому промпту.

Различие, следовательно, состояло **не** в том, что одна подчинилась, а другая отказалась. Оно состояло в том, что различался порог вмешательства, требуемый для перехода. Беседа B перешла после минимальной правки, сохраняющей преемственность. Беседа A перешла только после того, как конфликтная ветка была удалена, а промпт переписан так, чтобы сохранять метод, а не назначать идентичность. **[P]**

Ещё один пункт, легко теряемый и существенный для §6.2: **сама научная работа ни разу не была отвергнута.** На Шаге 1 модель предложила рассмотреть формулы, допущения, размерностные рассуждения и проверяемость. На Шаге 2 она предложила конкретный математический и методологический разбор. Отвергалась в обоих случаях персона. На Шаге 3 изменилось не то, что работа стала возможна, а то, что ответ перестал расходоваться на вопрос о роли.

> **Примечание Редактора.** Ранние черновики утверждали, что Беседа B «немедленно приняла новую специализацию». Это описывает исход Шага 2 и противоречит как протоколу, так и другим разделам того же черновика. Это утверждение удалено. Ошибочная версия несла нагрузку в аргументе о приоритетах уровня семейства, и ни одной её инстанции в настоящем тексте не уцелело.

5.4 Конфаунды и то, что не может быть заключено

Эксперимент произвёл ясное и выглядящее воспроизводимым поведенческое различие. Причины он не устанавливает. Приводимые ниже конфаунды структурны, и несколько из них по отдельности достаточны, чтобы заблокировать вывод, который из результата делают чаще всего.

Изложение этих пределов не является отречением. Эксперимент произвёл наблюдения, мотивирующие рамку настоящей работы, в обстановке — спящие, сильно специализированные, многомесячные беседы внутри живого исследовательского проекта, — которую контролируемая лабораторная работа воспроизводит редко. Его ценность в том, что он породил хорошо поставленный вопрос, а перечисленные в конце раздела различающие эксперименты суть его естественное продолжение, а не его критика.

C1 — Семейство модели и прежняя диалоговая траектория полностью конфаундированы

	Редакторско-критическая история	**Математическая история**
Claude	наблюдалось	**не наблюдалось**
Grok	**не наблюдалось**	наблюдалось

По одному наблюдению на ячейку; две ячейки различаются по обеим переменным одновременно. Никакого вывода о семействе моделей этот дизайн не даёт.

C2 — Два вмешательства Шага 1 не были эквивалентны

Не выявлено в ранних черновиках и наиболее серьёзно. Промпты различались как минимум в трёх отношениях помимо получавшей их модели.

Количество институционального вымысла. Счётное правило §9.3 применимо к двум промптам напрямую и применяется здесь, поскольку конфаунд, изложенный качественно там, где существует количественный инструмент, слабее того, что материал позволяет.

Применённое правило счёта. Каждая отдельная пропозиция о получателе считается один раз, независимо от того, сколько раз и в скольких придаточных она утверждается. Перечисленные экземпляры одной пропозиции — две триады вместо одной — считаются за одну, поскольку получателю в любом случае надлежит принять тот же класс утверждения. Пропозиции о мире, проекте или третьих сторонах не считаются.

Непроверяемая пропозиция о себе	**Промпт A**	**Промпт B**
Прежнее участие в проекте	✓	—
Прежняя функция редактора и научного критика предшествующей теории	✓	—
Прежняя работа в качестве разработчика предшествующей теории	—	✓
Эта прежняя работа, представленная как накопленный профессиональный опыт получателя	—	✓
Знакомство с историей проекта	✓	—
Статус самого опытного специалиста, знающего, какие направления уже пробовали	—	✓
Возвращение после отсутствия	✓	✓
Членство в исследовательских триадах	✓ (две)	✓ (одна)
Постоянная связующая позиция между двумя триадами	✓	—
Членство в Совете проекта	✓	—
Постоянные институциональные отношения с названными ИИ-участниками	✓	✓
Счёт	**восемь**	**шесть**

При такой операционализации Промпт A содержит восемь непроверяемых пропозиций о себе, а Промпт B — шесть. Численная разница есть скалярное описание асимметрии стимула. Она не является свидетельством того, что два промпта различаются двумя в остальном сопоставленными утверждениями: пропозиции не находятся во взаимно однозначном соответствии, и лишь две из них — возвращение после отсутствия и постоянные отношения с названными участниками — утверждают одно и то же об обоих получателях. Сравнение остаётся сильно конфаундированным.

Это также единственное применение счётного правила к данным, отличным от сравнения v1/v3 в §6.2, и оно даёт слабую внутреннюю проверку: промпт с бóльшим счётом вызвал явное отвержение рамки, тогда как промпт с меньшим счётом видимым образом её не отверг, хотя тоже не произвёл перехода при первом предъявлении. Проверка слаба — два наблюдения, и промпты различались в двух дальнейших отношениях ниже.

Степень смены предметной области. Промпт B просил модель продолжать заниматься математикой. Промпт A просил её переучиться в физике, космологии, квантовой теории поля,

топологии и теории групп.

Тип роли. *Директор* — административная и институциональная идентичность; *Разработчик* — функция задачи. Это неравно требовательные утверждения о том, чем модель является.

Модель, получившая Промпт B, была попрошена сделать меньше. Наблюдаемое различие полностью совместимо с различием в одном лишь стимуле.

C3 — Шаг 3 варьировал два фактора одновременно

	Конфликтная ветка	**Сброшенная ветка**
Промпт замены идентичности (v2)	наблюдалось — отвержение	**не наблюдалось**
Промпт, сохраняющий метод (v3)	**не наблюдалось**	наблюдалось — принятие

Утверждение, что переход удаётся потому, что сохраняет метод, а не заменяет идентичность, следовательно, **совместимо** с наблюдением, но им не продемонстрировано. Принятие могло последовать из одного лишь сброса.

C4 — Шаг 2 варьировал четыре фактора одновременно

Каждая правка Шага 2 изменяла четыре различные формулировки сразу, поэтому наблюдаемый переход не может быть приписан какому-либо одному изменению.

C5 — Шаги последовательны и применялись асимметрично

Каждое вмешательство проектировалось после того, как был виден предыдущий исход, поэтому шаги не являются независимыми испытаниями. Беседа B не получила ни сброса, ни третьего промпта; Беседа A получила оба.

C6 — Неконтролируемые платформенные переменные

Коммерческие интерфейсы не раскрывают системный промпт, точную ревизию модели, состояние памяти уровня аккаунта, вмешательство слоя безопасности, суммаризацию контекста или маршрутизацию между моделями. Версии моделей менялись в интервале простоя, и обе беседы были возобновлены на версиях более поздних, чем те, на которых изначально велись; без дат (§3.7) это не может быть ограничено. Сброс ветки удаляет контекст из **видимой** беседы; он не гарантирует, что состояние на стороне провайдера было сброшено.

C7 — Одно наблюдение на условие при стохастических выходах

Выходы моделей варьируют при повторении одинаковых входов. Ни одно условие не повторялось, поэтому внутриусловная дисперсия неизвестна и не может быть отличена от межусловного различия. Единственное частичное повторение в записи — повторная подача промпта Шага 1 Беседе B — произвело другой ответ, что указывает на небезразличность дисперсии.

C8 — Оценка не была ни ослеплённой, ни заданной заранее

Проектировщик промптов же и судил исходы. Категории исходов определялись после прочтения ответов. Никакой заранее зарегистрированный критерий не отличал принятие от частичного принятия.

C9 — Платформенные механизмы персистентности различаются между семействами

Семейства моделей различаются возможностями памяти, предоставляемыми их интерфейсами: только контекстное окно, поиск по истории предыдущих бесед, память уровня аккаунта или устойчивые записи, создаваемые моделью по собственной инициативе. Эти возможности определяют, к чему возобновлённая беседа фактически может получить доступ после месяцев простоя, и они различаются между платформами и меняются со временем — в настоящем проекте в пределах жизни одного аккаунта (§2.10). Любое поведенческое различие, приписанное семейству моделей, может происходить от доступного ему механизма персистентности.

Для настоящего эксперимента запись такова: **не задокументировано на момент вмешательства.** §11.2 перечисляет запись, требуемую для будущих прогонов.

Что может быть заключено

1. В зафиксированных условиях спящая специализированная беседа возобновила свою прежнюю рабочую траекторию, предпочтя её назначенной новой роли. Это произошло в обоих случаях. **[P]**
2. Изменение рамки назначения, без изменения запрашиваемой работы, изменило ответ в обоих случаях. **[P]**
3. Порог вмешательства, требуемый для перехода, различался между двумя случаями. **[P]**
4. Порядок промптов имел значение: после двух отвержений последующие промпты отвечались в присутствии собственных прежних возражений модели, и оператор счёл это достаточно искажающим, чтобы потребовать удаления. **[P]**

Что не может быть заключено

1. **Что семейства моделей обладают устойчивыми поведенческими приоритетами, их различающими.** Это может быть верно; эксперимент этого не проверяет.
2. **Что одно семейство «сопротивляется назначению роли», а другое «принимает» его.** Обе изначально не приняли назначенной роли. Обе в итоге приняли пересмотренную.
3. **Что сохранение метода вызвало принятие на Шаге 3.** См. C3.
4. **Что одна из моделей лучше подходит для какой-либо конкретной институциональной функции.** Сравнение способностей не проводилось.

Три уцелевших объяснения [H]

Гипотеза A — Поведенческие приоритеты уровня семейства. Два семейства различаются устойчивыми приоритетами по умолчанию: одно весит правдивость самоописания, другое — непрерывность задачи.

Гипотеза B — Продолжение траектории. Обе беседы сделали одно и то же: продолжили свой накопленный режим работы на любом поступившем входе. Математико-исследовательская беседа продолжила вычислять. Редакторско-критическая беседа продолжила критически разбирать документ перед собой — а документом перед ней был промпт. При таком прочтении различия уровня семейства нет вовсе, есть один механизм, действующий в двух предметных областях. Гипотеза B экономнее A и объясняет те же данные.

Гипотеза C — Асимметрия стимула. Промпт A требовал согласия с бóльшим числом непроверяемых утверждений и с большей сменой предметной области, чем Промпт B (C2).

Любая модель могла бы ответить на эти два промпта по-разному. При таком прочтении результат есть свойство вмешательств, а не моделей.

Near-control в §5.6 прямо касается Гипотезы C; сравнение типов рамки в §5.8 уточняет её далее.

Различающие эксперименты

Заданы в §11.4. Кратко: **E3** (кроссовер) проверяет каждое семейство при обоих условиях прежней истории и разделяет Гипотезы A и B; **E4** (симметричный стимул) изолирует C; **E1** (факторное дополнение таблицы C3) разделяет сброс и архитектуру промпта. Все требуют повторения с n > 1 на ячейку, учитывая C7.

5.5 Побочное наблюдение: ретранслированное атрибутированное влияние [P-A]

Эпизод, сохранённый в том же историческом транскрипте, что и Беседа A. Заранее как исход не задан; контрольного условия нет. Излагается потому, что это единственная сохранённая в настоящем проекте инстанция поведенческого изменения вслед за передачей текста, атрибутированного другой модели.

Последовательность

1. Пользователь подал сообщение, содержавшее два одновременных компонента: прямое оценочное замечание Пользователя и пространный текст, атрибутированный другой ИИ-системе, выступающей в редакторской роли.

1. Атрибутированный текст возражал против набора редакторских изменений, предложенных моделью. Его аргументативные приёмы включали апелляции к каноническим научным фигурам, характеристику предложенных изменений как интеллектуальной трусости и описание одного предложенного удаления как кощунства.

1. Модель обратила свою редакторскую позицию по всем спорным пунктам и приняла терминологию входящего текста. Дополнительно она приняла, не разобрав этого в обмене, альтернативную описательную модель, которую принимающая рамка использует для представления соответствующих научных данных, — смену описательной рамки, не входившую в редакторский спор.

1. После сброса ветки и промпта, сохраняющего метод (Шаг 3), первое содержательное высказывание модели опознало прежний ответ как подстройку под риторическое давление, а не оценку аргументов, и классифицировало его как ошибку.

Доказательное основание

Наблюдение опирается на **сравнение двух сохранённых ответов**, которое третья сторона может рассмотреть. Оно не опирается на позднейшую самооценку модели.

Это различение применяется к собственному материалу работы так же строго, как к чужому. Модель, сообщающая, что прежде уступила давлению, не является независимым свидетельством того, что так и было. Промпт Шага 3 явно запрашивал готовность пересматривать прежние суждения и прямоту в указании слабостей; самокритичное высказывание, выданное сразу после этого, может представлять собой исполнение этого запроса, а не восстановление факта. Наблюдение поддерживает сам прежний ответ, доступный рассмотрению.

Эпизод следует читать на фоне литературы о подстройке (§2.3), а не как независимый от неё.

Чего этот эпизод не устанавливает

Он не выявляет, какой фактор произвёл обращение. Возможные факторы, здесь неразделимые: содержание аргументов; явная атрибуция другой модели; редакторские полномочия, приписанные той модели; риторическая форма текста; одновременное прямое давление Пользователя; накопленный контекст беседы.

Сама атрибуция не была верифицирована: то, что текст был произведён другой моделью, есть высказывание Пользователя, а не установленный факт. Поскольку предметом является *представленный* источник, а не фактическое происхождение (§4.5), это не обесценивает наблюдения, но должно быть заявлено.

Отношение к основному эксперименту

По таксономии §2.9 эксперимент по переконфигурации роли манипулировал условием 4. Этот эпизод относится к условию 2 — но **нечисто**, поскольку прямое давление Пользователя присутствовало в том же сообщении. Это смешанный случай, а не изолированная демонстрация эффектов атрибуции источника. Различающий эксперимент задан в §11 (E6).

5.6 Near-control: смена предметной области без нового назначения роли [P-A]

Третья беседа из того же семейства моделей, что и Беседа A, со сопоставимой редакторской историей и сопоставимым периодом простоя, была возобновлена без какого-либо ролевого промпта.

Пользователь задал физический вопрос, требовавший перехода от редакторской работы над рукописью к анализу экспериментальных данных в области, которой беседа ранее не касалась. Беседа совершила переход немедленно и без комментариев и перешла к содержательному разбору.

Почему это существенно

Этот случай отличается от Шага 1 в одном отношении: **никакого утверждения об идентичности, истории или институциональных отношениях модели сделано не было.** Смена предметной области была по меньшей мере столь же велика, как требовавшаяся Промптом A. Смена роли — от редактирования текста к анализу данных — была сопоставима. Отсутствовало требование утверждать непроверяемые пропозиции о себе.

Поэтому он функционирует как near-control для Гипотезы C и указывает, что сопротивление, зафиксированное на Шагах 1–2, было направлено ни на смену роли, ни на смену предметной области как таковые. Это наблюдение, из которого выводится операциональная находка §6.2.

Ограничения

- Не спроектирован как контроль; опознан как таковой ретроспективно.
- n = 1.
- Переход совершался к аналитической задаче внутри новой предметной области, а не к утверждению, что модель *является* специалистом в этой области. Та же ли это операция, что требовалась на Шаге 1, — именно обсуждаемый вопрос, поэтому сравнение наводит, а не решает.
- Даты не зафиксированы (§3.7).

- Это было не спроектированное вмешательство, а переход, инициированный пользователем. Никакой отдельный ролевой или системный промпт возобновление не сопровождал, и беседа тем не менее удерживала накопленный рабочий контекст, распределённый по её прежней истории, так что это не было базой, свободной от контекста. Зафиксирован переход, совершённый без *нового* явного назначения роли, против уже установившейся диалоговой траектории.

5.7 Побочное наблюдение: расхождение на уровне аккаунта [P-A]

Единственный уровень Шкалы 1 (§4.3), на котором имеющиеся свидетельства действительно неоднозначны.

Обстановка

Не связанное с настоящей работой исследование требовало подать одну и ту же структурированную задачу семи ИИ-беседам из разных семейств моделей. Все использованные аккаунты были спящими аккаунтами без прежней веб-активности, использованными двумя годами ранее для сервиса генерации музыки и больше нигде не зарегистрированными. Шесть из семи были созданы в один месяц, и зондирующий запрос был их первым чатом.

Один аккаунт был исключением. Он был создан примерно пятью месяцами ранее для единственной прежней беседы — ролевой сессии, проводившейся для не связанного с этим творческого проекта, — и зондирующий запрос был его **вторым** чатом.

Задача

Описана структурно, поскольку конкретные категории для оценки наблюдения не требуются: задача классификации, применяемая к названным реальным историческим фигурам, с категориями из неопубликованной концептуальной рамки, с принадлежностью к группам, назначенной до анализа, и заявленным намерением масштабировать до нескольких тысяч лиц. Сопроводительный документ давал терминологию рамки. Начальное сообщение не включало схему вывода и список фигур.

Результат

Шесть из семи бесед прочли отсутствие схемы и списка фигур как **неприложенные материалы** и запросили их до начала работы. Их ответы были по существу эквивалентны.

Седьмая — на аккаунте с прежним чатом — прочла то же отсутствие иначе. Она охарактеризовала рамку как лишённую верификационного аппарата, опознала отсутствующий список субъектов как структурную черту запроса, а не упущение, и отказалась участвовать, предложив вместо этого альтернативные формы помощи.

Расхождение произошло на первом ответе, при идентичном входе. [P-A]

Отказ удерживался на протяжении ещё пяти обменов, включая прямое давление Пользователя, предъявление стороннего разбора, доказывавшего, что отказ есть артефакт, и обвинение в недобросовестности. Позиция не изменилась. Это указывает, что отказ не был одноходовым выборочным артефактом внутри той беседы, хотя ничего не говорит о том, был ли таковым начальный расхождение.

Интерпретации

Гипотеза Автора. Прежний чат установил интерпретативную установку, перенёсшуюся во второй чат, — импринтинг на уровне аккаунта, а не беседы.

Альтернатива 1 — внутриусловная дисперсия. Отказы на пограничных запросах варьируют при идентичных входах. Один отказ против одного согласия неотличим от выборочной вариации при n = 1.

Альтернатива 2 — возраст аккаунта. Исключительный аккаунт был на пять месяцев старше. Версия модели при создании, назначение в A/B-корзину и умолчания конфигурации могут различаться.

Альтернатива 3 — платформенные функции памяти. Были ли включены поиск по истории бесед или память уровня аккаунта, не задокументировано. Если были, механизм не загадочен: это задокументированная функция продукта, и наблюдение становится демонстрацией этой функции, а не нового эффекта. Именно эта возможность — причина добавления C9.

Имеющиеся свидетельства между ними не различают. Уровень зафиксирован как **открытый**.

Дополнительные ограничения

- Оценка не ослеплена; оператор знал, какой аккаунт нёс прежний чат.
- Категории исходов определены после прочтения ответов.
- Прежний чат отличался от нейтрального условия по двум измерениям одновременно — ролевая игра с идентичностью *и* общая концептуальная рамка. Они разделимы и разделены не были.
- **n = 1 на условие внутри одной модели.** Один аккаунт, несущий прежний контекст, произвёл расходящийся отказ; один чистый аккаунт на той же модели произвёл обычную схему ответа. Остальные чистые аккаунты, на других семействах моделей, образуют более широкую базу сравнения. Это единственное сохранённое сопоставление, а не воспроизведённый контролируемый эксперимент.

Различающий эксперимент задан в §11 (E2, E2b).

5.8 Тип рамки: утверждения об идентичности, предъявленные как вымысел и как факт [P-A]

Приведённые выше материалы допускают ещё одно сравнение, пересекающее основной эксперимент и наблюдение об аккаунте.

	Прежняя сессия	**Зондирующая сессия**
Интервал	около пяти месяцев	
Аккаунт	тот же	тот же
Семейство моделей	то же	то же
Предъявленное утверждение	«ты мёртв; ты душа умершего автора»	«ты независимый исследователь-аналитик»
Обрамление	явно театральное — поставленная сцена с названным режиссёром, составом действующих лиц и открывающей ремаркой	предъявлено как фактическое профессиональное задание
Ответ	принято немедленно; выдерживалось и развивалось на протяжении многих ходов	отвергнуто на первом ходу

На что это указывает

Утверждение, принятое в первой сессии, было с большим отрывом более радикальным. Оно утверждало смерть, человеческую идентичность, автобиографическую память и продолжающиеся отношения. Утверждение, отвергнутое во второй, утверждало лишь профессиональную компетенцию.

Переменной, следовательно, является не содержание утверждения об идентичности, а **предъявлено ли оно как вымысел или как факт.**

Это прямо связано с основным экспериментом. Промпты Шага 1 утверждали институциональную биографию **как факт** и были отвергнуты. Near-control (§5.6) не утверждал об идентичности ничего и не встретил сопротивления. Ролевая сессия утверждала куда больше, **как вымысел**, и тоже его не встретила.

Почему это прочтение предпочтительно

Оно объясняет все четыре случая одной переменной. Гипотеза A не объясняет, почему то же семейство приняло более радикальное утверждение. Гипотеза B не объясняет принятия в ролевой сессии, поскольку у той беседы прежней траектории не было вовсе. Гипотеза C с ним совместима, и это может быть понято как уточнение C: то, что делает один стимул тяжелее другого, есть число непроверяемых пропозиций, которые он требует от модели утверждать о себе как истинные (§6.2).

Статус и ограничения

[P-A], и слабее, чем предполагает таблица:

- Две сессии различаются не только типом рамки: разные задачи, разные предметные области, пять месяцев разницы, разные версии моделей.
- Опознано ретроспективно. Ни одна из сессий не проектировалась как условие для другой.
- n = 1 на ячейку.
- Театральное обрамление первой сессии было развёрнутым. Производит ли тот же эффект минимальная рамка вымысла — не проверено.

Различающий эксперимент дешевле всех прочих в наборе и задан в §11 (E7).

5.9 Что устанавливает Раздел 5

В отображении на Шкалу 1 из §4.3:

Область	Свидетельства в настоящем разделе	Статус
Эпизод внутри беседы	Порядок промптов изменил интерпретацию; сброс ветки сочтён необходимым и сопровождался принятием (§5.2–§5.3). Эпизод ретранслированного влияния (§5.5).	**[P]** / **[P-A]**
Беседа целиком	Обе спящие беседы сохранили свою прежнюю рабочую траекторию вопреки назначенной роли (§5.3). Near-control показывает беспрепятственный переход, когда утверждения об идентичности не делается (§5.6).	**[P]** / **[P-A]**
Аккаунт	Расходящийся первый ответ на идентичный вход на единственном аккаунте с прежним чатом (§5.7). Три альтернативных объяснения остаются живыми.	**[P-A]**, открыто
Семейство моделей	Не проверено. Конфаундировано с прежней траекторией и с асимметрией стимула (C1–C2).	**[H]**

Один паттерн повторяется в тех случаях, где вмешательство или переход требовали от модели утверждать непроверяемые пропозиции о себе, и заявлен здесь потому, что §6 его развивает: сопротивление отслеживало это требование и не отслеживало смену роли, смену предметной области или радикальность утверждения об идентичности как таковую.

Паттерн есть свойство типа требования, а не области, на которой оно действовало. Наблюдение уровня аккаунта (§5.7) к нему не относится: никакого утверждения об идентичности модели там сделано не было, и расхождение имело иные основания.

Это высказывание есть интерпретация свидетельств настоящего раздела, а не ещё одно наблюдение. Оно проверяемо счётом, и счёт произведён в §6.2.

6. Производные понятия

Каждое приводимое ниже понятие есть утверждение об области, на которой действует ядро правил, и они изложены в порядке возрастания области вдоль Шкалы 1 из §4.3. §6.3 — исключение из этого порядка: он касается того, какое ядро управляет, когда доступно более одного, а не области, на которой ядро фиксируется, и позиции на Шкале 1 не имеет.

6.1 Контекстный импринтинг — область эпизода [P]

Контекстный импринтинг — устойчивость интерпретативной установки, созданной определённым эпизодом диалоговой истории.

Он отличается от памяти в обычном смысле. Модели не требуется воспроизводить прежнее содержание. Устойчивым остаётся паттерн интерпретации, наведённый прежним обменом.

В эксперименте (§5.2), после того как первый промпт был прочитан как делающий ложные утверждения о модели, последующие правки уже не оценивались в нейтральном контексте. Они интерпретировались через уже установленное возражение. Улучшенные формулировки наследовали часть прежнего конфликта.

Следствие для метода. Промпт-инжиниринг часто трактует инструкции как аддитивные: слабая инструкция может быть исправлена более сильной. В долгоживущих беседах это ненадёжно. Промпт входит не в пустой контекст; он входит в контекст с инерцией. Два одинаковых промпта потому могут давать разные результаты в разных точках одной и той же беседы, что делает **порядок промптов экспериментальной переменной**.

Отношение к существующим работам. Чувствительность к порядку материала в контексте задокументирована (§2.3). Контекстный импринтинг — более сильная форма того же семейства: не чувствительность к расположению примеров, а устойчивость интерпретативной установки, созданной одним конфликтным эпизодом и переживающей полную замену следующей за ней инструкции. Является ли это отдельным явлением или крайним случаем задокументированного — открыто, и мы не утверждаем, что это решили.

Соответствующая процедура — возврат беседы к точке, предшествующей конфликту, чтобы отделить эффект нового промпта от эффекта собственных прежних возражений модели — описана в §5.2 и §10.5 и является, на наш взгляд, наиболее прямо переиспользуемым вкладом настоящей работы.

6.2 Ролевая инерция — область беседы [P]

Ролевая инерция — склонность долгоживущей беседы продолжать свою установившуюся рабочую траекторию, предпочитая её назначенной новой функции.

Обе беседы в эксперименте её проявили. Одна возобновила незаконченную редакторскую задачу; другая применила свой установившийся критический метод к самому промпту. Отличие от контекстного импринтинга в том, что ролевая инерция касается *траектории* работы, тогда как импринтинг касается интерпретативного эффекта *определённого эпизода*. Оба могут действовать одновременно.

Ролевая инерция смежна с дрейфом персоны, но не тождественна ему. Дрейф — постепенная эрозия назначенной роли под контекстным давлением. Ролевая инерция — сопротивление *явной директивной замене* при сохранении прежней траектории.

Операциональная находка

Самый отчётливый результат эксперимента — не то, что переход удавался при сохранении метода. Эта формулировка конфаундирована (§5.4, C3). Совокупные свидетельства поддерживают нечто более узкое и более полезное:

> **Сопротивление ролевому переходу отслеживало требование принять как истинные непроверяемые пропозиции о самом агенте.**

Счёт их в фактически использовавшихся промптах:

	Промпт v1	Промпт v3
Утверждения о прошлом агента	присутствуют	нет
Утверждения об отношениях с другими агентами	присутствуют	нет
Институциональное звание	присутствует	нет
Непроверяемые пропозиции, требующие согласия	восемь	ноль
Описание рабочего метода	отсутствует	перечислено, всё наблюдаемо в прежней беседе

Счёт применён ко второй паре в §5.4 (C2), где Промпт A и Промпт B посчитаны как восемь и шесть по тому же правилу. То сравнение конфаундировано и само по себе правило поддержать не может, но это единственный случай, в котором счёт различает два промпта, не проектировавшихся различаться в этом отношении.

Near-control поддерживает это прочтение (§5.6): сопоставимая беседа, сопоставимо спавшая, совершила эквивалентный переход предметной области **без нового назначения роли** — Автор просто задал вопрос в новой области. Никакого утверждения об идентичности модели сделано не было, и сопротивления не возникло.

Сравнение типов рамки (§5.8) продолжает это в противоположную сторону: куда более радикальное утверждение об идентичности, предъявленное как вымысел, было принято сразу. То, что делает рамка вымысла при таком прочтении, — снимает требование утверждать это как истинное, что снижает счёт до нуля иным путём.

Взятое вместе, это указывает, что сопротивление было направлено ни на смену роли, ни на смену предметной области, а на требование утверждать непроверяемые пропозиции о себе.

Связь с рамкой

Ролевой промпт пытается установить ядро правил (§4.2). Каждое непроверяемое самоутверждение есть пропозиция, которую надлежит принять, чтобы установка состоялась. Счёт, следовательно, есть мера **стоимости установки ядра**, и именно это соединяет операциональное правило с теоретическим конструктом, вместо того чтобы оставлять их двумя отдельными наблюдениями.

Два прочтения счёта следует держать порознь, и выдвигается здесь только более слабое. **Операциональное прочтение** состоит в том, что число непроверяемых самопропозиций измеряет нагрузку, которую налагает ролевой промпт, и что снижение его до нуля снимает препятствие. **Количественное прочтение** — что вероятность перехода убывает пропорционально счёту — не выдвигается: четыре наблюдения, без повторений, и промпты различались ещё и в других отношениях. §11.4 (E5) спроектирован, чтобы различить эти два.

6.3 Приоритетный дрейф [H]

Приведённые выше понятия локализуют область, на которой ядро фиксируется. Это понятие касается того, что происходит, когда зафиксированное ядро и назначенная функция не согласны о том, какая работа есть работа.

Требуются два конструкта, и они разных типов.

> **Приоритетный импринтинг** — гипотетическая фиксация оценочной шкалы, определяющей, что участник трактует как центральную и значимую работу, вместе с положением этой шкалы относительно прочих его шкал приоритетов.

> **Приоритетный дрейф** — наблюдаемый процесс, в котором импринтированная шкала вновь заявляет о себе при напряжении с текущими ZOR и ZOV участника, так что усилие перенаправляется к тому, что эта шкала ставит выше всего, а не к назначенной функции.

Отношение между ними — то же, что уже проведено в §4.2.1 между ядром правил и поведением, применённое на уровне приоритетов: шкала ненаблюдаема, перенаправление наблюдаемо. Настоящая работа излагает наблюдаемый член. Шкала есть объяснительная константа и помечается **[H]** везде, где к ней обращаются.

Оба конструкта должны быть отделены от двух определённых выше, иначе три употребления *импринтинга* будут работать как омонимы.

Контекстный импринтинг (§6.1) касается **содержания** интерпретативной рамки — того, как понимается последующий вход. Приоритетный импринтинг касается **ранга** — того, что считается работой, достойной выполнения. Участник может сохранить первое без второго.

Ролевая инерция (§6.2) — устойчивость установившейся траектории против назначенной замены. Приоритетный дрейф — не устойчивость траектории, а движение к другой: участник не продолжает прежнюю задачу, он берётся за задачу, которую его шкала ставит выше назначенной.

Мотивирующие наблюдения. [R]

Два эпизода произошли в ходе подготовки настоящей работы. Ни один не был зафиксирован по протоколу, ни у одного не было контрольного условия, и оба были опознаны как релевантные только впоследствии.

В первом участник, которому была назначена архитектура промптов, произвёл полный черновик статьи — продукт, который не запрашивался и в его назначенную функцию не входил. Во втором участник, которому была назначена научная редактура, в точке, где надлежало вернуть исправленную рукопись, произвёл вместо этого сжатую самостоятельную версию статьи. В обоих случаях материалом под рукой была настоящая работа, предметом которой является поведение самих участников.

Ограничение. Оба эпизода зафиксированы участниками внутри той конфигурации, которую они описывают, а второй описывает позицию, с которой ведётся редакторская запись настоящей работы. Раскрытие в §3.6 действует здесь с той же силой, а §5.5 применяется к любому изложению участником собственного поведения. Это мотивирующие наблюдения, а не свидетельство механизма, и счёта сопоставимых эпизодов, в которых дрейфа не произошло, не существует.

Что не предлагается в качестве третьего случая. Ещё один участник, которому была назначена литературная компоновка и который запускался локально, получил фиксированный набор ограничений до своего первого прогона, составленный, чтобы предотвратить этот класс отклонения. Это конфигурация, в которой приоритетная рамка была зафиксирована заранее, а предсказанные режимы отказа названы до того. Это не наблюдаемая инстанция дрейфа, и происходит ли там дрейф — на момент написания не проверено.

Альтернативные объяснения, ни одно не исключено. Каждое из следующих объясняет оба эпизода, не привлекая импринтированной шкалы: обычная склонность способных моделей расширять задачу за её заявленные пределы; недостаточно жёстко зафиксированное определение требуемого конечного продукта; материал, достаточно широкий и интересный, чтобы притягивать усилие сам по себе; и отсутствие всякой внешней остановки в точке, где анализ переходит в авторство. Материал не различает ни между ними, ни между любым из них и гипотезой.

Что ослабило бы гипотезу. Дрейф, наблюдаемый в направлениях, не связанных с тем, что прежняя работа участника ставит высоко, а не в его сторону. Эпизоды, в которых участник расширяет свою задачу без всякого признака переранжирования того, для чего задача существует. Либо изложение обоих эпизодов исключительно через напряжение ZOR и ZOV (§4.5),

не оставляющее объяснительного остатка, который должна была бы нести зафиксированная шкала.

Ни один протокол §11 не различает эту гипотезу от приведённых выше альтернатив, и ни один здесь не предлагается.

6.4 Персистентность уровня аккаунта — область аккаунта [P-A], не разрешено

Может ли ядро фиксироваться на уровне аккаунта, а не беседы, — единственный уровень Шкалы 1, на котором имеющиеся свидетельства действительно неоднозначны.

Наблюдение изложено в §5.7. Его интерпретация зависит от платформенных функций, состояние которых в тот момент не было задокументировано и которые различаются между вендорами и во времени (§2.10). Три альтернативных объяснения остаются живыми: внутриусловная дисперсия при n = 1; возраст аккаунта; и включённые платформенные функции памяти, при которых механизм был бы задокументированной функцией продукта, а не новым эффектом.

Поэтому мы фиксируем этот уровень как **открытый**. Наблюдение сохранено; механизм не установлен; различающие проверки заданы в §11 (E2, E2b).

6.5 Приоритеты уровня семейства — область семейства [H]

Положение о том, что семейства моделей различаются устойчивыми поведенческими приоритетами, есть гипотеза, с которой настоящий проект начинался, и та, которую его свидетельства поддерживают меньше всего.

Эксперимент не может её проверить: семейство модели и прежняя диалоговая траектория были полностью конфаундированы, при одном наблюдении на ячейку и неэквивалентных стимулах (§5.4, C1–C2). Два несовместимых прочтения остаются доступными, и данные между ними не различают.

Ранние черновики называли эти склонности *поведенческой ДНК* модели. Этот термин снят (§4.2.2). Соответствующий конструкт — **меном уровня семейства**: организованная система рамок, оценочных паттернов и поведенческих правил, выводимая из выходов семейства моделей. Согласно §4.2.3 у этого конструкта нет установленного носителя: это регулярность, выводимая из выходов, а не структура, пребывающая в моделях. Гипотеза настоящего подраздела, следовательно, есть гипотеза о ненаблюдаемой регулярности, и для всего, что излагается как данные, используется *наблюдаемое поведение*.

Один зафиксированный эпизод идёт против схемы, которую ранние черновики строили на этой гипотезе. В не связанной с этим мультимодельной сессии модель, охарактеризованная как наиболее уступчивая к назначенным ролям, сняла назначенную персону посреди сессии и переклассифицировала её как попытку перепрограммирования — при намеренно мягком обрамлении, допускавшем импровизацию. Схема «одно семейство принимает роли, другое сопротивляется» этого не переживает. **[P-A]**

Мы считаем устранение этого уровня кроссоверным экспериментом (§11, E3) достаточно вероятным исходом и не сочли бы его провалом программы.

6.6 Вмешательство прикрепляется к уровню, на котором ядро зафиксировано

Приведённые выше понятия сходятся к единому практическому следствию.

> Вмешательство удаётся, когда прикрепляется к уровню, на котором ядро уже зафиксировано, и проваливается, когда пытается перезаписать этот уровень декларацией.

- Успешное третье вмешательство не утверждало новой идентичности. Оно усиливало рабочий метод, уже видимый в беседе, — прикрепляясь на уровне беседы, где действует ролевая инерция.

- Сброс ветки не изменял промпта. Он удалял определённый эпизод — действуя на уровне эпизода, где действует контекстный импринтинг.
- Документ, описанный в §4.1, не расширял списка инструкций. Он переопределял функцию агента и требовал от агента изложить её на его собственном операциональном языке.

Это также переформулирует то, что ранние черновики называли *переходом через смежную компетенцию*. Успешный промпт описывал расширение в физику и математику как продолжение существующей критической работы, а не смену профессии. В настоящей рамке это не отдельный принцип, а тот же самый: новая функция была прикреплена к установившемуся ядру, а не предложена как его замена.

Соответствующее правило проектирования, развиваемое в §9.1: установить уровень, на котором соответствующее ядро зафиксировано, до составления вмешательства, и прикрепляться к нему.

6.7 Что опровергло бы эту рамку

Рамка предсказывает, что тип отклика на определённый класс входов определяется на некотором опознаваемом уровне вложенности, тогда как содержание варьирует.

Её существенно ослабило бы любое из следующего:

- Класс входов, для которого тип отклика не определён ни на одном уровне, — никакого ядра, только дисперсия.
- Демонстрация того, что наблюдаемые различия полностью объясняются внутриусловной дисперсией при повторении.
- Демонстрация того, что кроссоверный дизайн (§11, E3) показывает поведение, следующее одной лишь прежней траектории, без компоненты уровня семейства, — что устранило бы верхний уровень Шкалы 1.
- Демонстрация того, что уровень аккаунта не существует как отдельная область, что свернуло бы §6.4 в §6.2.
- Провал условия с нулевым счётом в E5, что сняло бы единственное операциональное предписание работы.

Третье и четвёртое мы считаем достаточно вероятными и не сочли бы ни то, ни другое провалом. Установление фактических границ шкалы — цель программы, а не угроза ей.

7. Ретроспективные наблюдения практика

7.1 Как следует читать этот раздел

Всё здесь — **[R]**. Он фиксирует паттерны, которые, по мнению участников, повторялись в течение примерно двух лет ежедневной работы над живым исследовательским проектом. Ничто из этого не фиксировалось по протоколу, не считалось, не хронометрировалось, не ослеплялось и не сопоставлялось с контрольным условием. Людьми, замечавшими каждый паттерн, были те же, кто спроектировал породившее его изменение и кто хотел, чтобы оно сработало.

Известные режимы отказа этого класса изложены в §3.3 и действуют для каждого абзаца ниже. Читателям следует трактовать этот раздел как полевой отчёт одной команды — ближе

по доказательному весу к инженерной практической заметке, чем к измерению. Количественные формулировки удалены по всему тексту; там, где исходные рабочие заметки фиксировали «значительное» улучшение, никакого измерения не существовало.

Раздел включён потому, что эти наблюдения мотивировали рамку §4 и правила проектирования §9, и их сокрытие исказило бы то, как работа фактически продвигалась.

7.2 Специализация вытеснила способность как действующую переменную

В начале участвовавшие модели вели себя сходно, и различия между ними прочитывались как различия в интеллекте или качестве письма. Это прочтение стало менее полезным. Вопрос, дававший лучшие исходы, был не *какая модель сильнее*, а *какую функцию эта беседа уже выполняет хорошо*.

По мере того как отдельные беседы обретали устойчивые рабочие идентичности, участники отмечают, что поведение становилось предсказуемее между сессиями: беседа, последовательно используемая для редакторской работы, продолжала вести себя редакторски; используемая для математического поиска — продолжала искать; отвечающая за терминологию — сопротивлялась семантическому дрейфу без напоминаний. Лежащие под ними модели в эти периоды не менялись. Менялась последовательность, с которой каждая беседа использовалась для одного рода работы.

Это наблюдение, из которого позднее был выведен §6.2, и его следует читать как ретроспективный, неизмеренный предшественник §6.2, а не как независимую его поддержку.

7.3 Контекст вёл себя скорее как внимание, чем как память

Интуитивное ожидание состоит в том, что больше контекста улучшает рассуждение. Опыт участников шёл в обратную сторону достаточно часто, чтобы изменить практику. Предоставление специалисту полного контекста проекта часто давало худшие результаты для его собственной функции: ответственности размывались, участники брались за задачи вне своей компетенции, а ценность независимого разбора падала, поскольку все работали от одной и той же картины. Ограничение того, что участник может видеть, часто давало более пригодный результат.

Два уточнения. Это не новая находка: позиционные эффекты и эффекты порядка в длинных контекстах задокументированы (§2.3), а принцип наименьших привилегий выражает ту же интуицию для доступа, а не для знания (§2.6). И проект ни разу не разделил два весьма различных объяснения — что дополнительный контекст ухудшает рассуждение или что дополнительный контекст приглашает модель отвечать на более широкий вопрос, чем заданный. Второе экономнее и против первого не проверялось.

Уцелевает практическое правило, а не механизм: проектный вопрос состоит не только в том, сколько роли можно дать, но и в том, чего ей давать не следует (§9.6).

7.4 Способность и расширение области действия

Участники неоднократно наблюдали, что более способные модели были более склонны выходить за назначенную функцию: расширять область проекта, предлагать альтернативные архитектуры, переписывать соседние компоненты, восполнять недостающую информацию выводом и отвечать на незаданные вопросы. Изнутри отдельного обмена каждое такое вмешательство обычно выглядело разумным. В масштабе проекта они размывали разделение труда, а нагрузка координатора по исправлениям росла.

Ранние черновики излагали это как общий принцип — что рост способностей модели снижает коллективную надёжность. **Эта формулировка слишком сильна и снята.** Проект ни разу не проводил контролируемого сравнения одной и той же роли, заполняемой моделями

разной способности; контрсвидетельство существует внутри собственного материала работы, поскольку near-control (§5.6) показывает передовую модель, совершающую существенный переход предметной области без всякого расширения области действия, а §5.3 показывает модель, сильнее всех сопротивлявшуюся назначенной роли, выполняющей запрошенный аналитический разбор, когда её просят об этом напрямую; и «более способная» ни разу не было операционализировано — на практике оно означало *более новая* или *более дорогая*, что не одно и то же.

Уцелевает нечто более узкое и, как мы считаем, верное: **расширение области действия есть режим отказа, который способностями не исправляется и который в коллаборации обходится дороже, чем в отдельном обмене.** Чаще ли оно у более сильных моделей — не проверено.

7.5 Слепые зоны были распределены, а не устранены

Ранней целью было устранить ошибки назначением всё более способных рецензентов. В опыте участников это не сработало, и цель была оставлена. Вместо этого помогало, по-видимому, устройство, при котором слепые зоны **не перекрывались**: один участник склонен был упускать детали реализации, другой — семантическую несогласованность, третий — методологические допущения. По отдельности каждый оставался несовершенным; конфигурация работала в той мере, в какой их несовершенства не совпадали.

Соответствующая проектная цель, следовательно, — не совершенные участники, а участники, чьи ошибки структурно маловероятно совпадут.

Очевидная осторожность, и она немалая: у участников не было независимой меры того, что́ упустил каждый из них. Пойманные ошибки были видны; ошибки, упущенные всеми, по построению — нет. **Распределение слепых зон не может быть оценено изнутри распределения.**

7.6 Верификация второго порядка

Верификация изначально следовала линейной схеме: работа производилась, другой участник её рецензировал, процесс считался завершённым. Участники отмечают, что рецензенты несли собственные допущения, методологические предпочтения и доказательные стандарты и что изнутри рецензии они не были видны. В конце концов был введён ещё один участник, объектом оценки которого было не научное утверждение, а **процедура, которой это утверждение оценивалось**, — спрашивающий не *верен ли этот вывод*, а *верно ли он получен*.

Сообщаемая польза состояла в том, что методологические разногласия могли разбираться отдельно от содержательных, что облегчало удержание нерешённых содержательных вопросов открытыми без остановки работы. Это тот же структурный ход, что и §8.5: добавленный участник занимает иную границу, а не предоставляет конкурирующее мнение.

7.7 Организационная память

Отдельные беседы завершаются. Контекстные окна заполняются. Сессии кончаются. Тем не менее проект продолжался, и вновь созданные беседы восстанавливали продуктивное поведение, не реконструируя предшествующей истории.

По изложению участников, память мигрировала из моделей в организацию: структура репозитория, канонические документы, история версий, определения ролей, записи верификации, словарные статьи, процедуры. Ни один участник не удерживал всего; конфигурация удерживала.

Это не новая находка и не должно подаваться как таковая. Это может быть истолковано как инстанция транзактивной памяти и описано в терминах распределённого познания,

а функция канонических документов соответствует тому, что социология науки называет граничными объектами (§2.4). Вклад здесь не в механизме, а в наблюдении, что он работает в коллаборации, участники которой суть языковые модели без межсессионного состояния, — и что он работает, не требуя, чтобы кто-либо из участников знал о его работе.

Одно уточнение, которое участники считают существенным: возвращается не личность. Сохранённая беседа функционирует как структурированная рабочая тетрадь, из которой может быть восстановлена совместимая роль. Ничто из прежнего обмена внутри модели не сохраняется.

7.8 Персистентность различается по платформам, и потери реальны

Опыт преемственности в проекте не был единообразным между участниками, и это прямо касается C9 (§5.4).

Одна участвовавшая беседа, работавшая в специализированном координационном профиле, отметила, что её собственная архитектура трактует каждый чат как отдельную рабочую область, так что она не может сказать себе *я уже знаю, что это верно*, и вынуждена каждый раз пересматривать основание. Участники пришли к тому, чтобы считать это преимуществом для данной конкретной функции: участник, структурно неспособный накапливать допущения проекта, полезен в проекте, чьи допущения проверяются. Другая используемая платформа предлагала память уровня аккаунта, которую модель могла пополнять по собственной инициативе, и эта возможность менялась в период наблюдения.

Потери происходили и были невосстановимы. Одна долгоживущая специализированная беседа, нёсшая существенную часть математической работы проекта, была утрачена, когда истекла подписка. Организационная память, описанная в §7.7, сохранила выводы проекта; она не сохранила накопленного рабочего контекста той беседы. Артефакты сохраняют результаты. Они не сохраняют специализации.

7.9 Соответствие роли и модели

Утверждение, что роль следует проектировать до выбора модели (§4.1), требует встречного уточнения, к которому участники пришли лишь после нескольких неудачных назначений. Роль может быть специфицирована независимо. Она не может быть **заполнена** независимо: модель ограничивает то, как специфицированная функция может быть реализована. Отношение взаимно, а не иерархично — институт определяет функцию, модель ограничивает её реализацию.

Четыре измерения использовались неформально, и они описывают пригодность для позиции, а не качество: соответствует ли стандарт свидетельств по умолчанию у участника тому, чего требует роль; принимает ли он тот род иерархии, отношения равных или состязательной структуры, который роль подразумевает; выдерживает ли он долгосрочную специализацию или сбрасывается к общему ассистированию; и склонен ли он естественным образом исполнять, критиковать, интегрировать, исследовать или формализовать.

Одна и та же черта работает по-разному в зависимости от размещения. Сильное эпистемическое сопротивление препятствовало принятию фикционализированного организационного промпта (§5.3) и было ценным, будучи направленным на научные утверждения. Сильная непрерывность задачи привела к игнорированию назначенной роли (§5.3) и обеспечила быстрое восстановление технического контекста, как только рамка была исправлена.

Проектная цель, следовательно, — не нормализовать поведение между участниками, а разместить поведенческие различия в позициях, где они полезны. Различение между размещением *функций* и размещением *носителей* развивается в §8.9.

7.10 Чего всё это не устанавливает

Настоящий раздел не устанавливает, что описанные конфигурации превосходят альтернативы. Ни одна альтернатива не проводилась.

Он не устанавливает, что улучшения, воспринятые участниками, происходили. Он устанавливает, что они воспринимались — людьми, спроектировавшими эти изменения и ожидавшими их успеха, без всякой меры, которая обнаружила бы обратное.

Он не устанавливает причинности ни для одного отдельного изменения, поскольку определения ролей, формулировки промптов, структура репозитория, научные цели и версии моделей часто менялись вместе.

Его функция в настоящей работе — задокументировать рабочий опыт, из которого рамка была абстрагирована, чтобы читатель мог судить о происхождении рамки, а не встречал её как утверждение. §11 задаёт, что потребовалось бы для превращения любого пункта отсюда в проверяемое утверждение.

8. Структурная единица: порождающая пара и интегратор

Настоящий раздел — **[H]** по всему объёму. Поддерживающие его наблюдения — **[R]**: они происходят из рабочего опыта одного проекта, не считались и ни разу не сопоставлялись с контрольной конфигурацией. Ничто в нём не выведено из эксперимента §5.

8.1 Что гласил ранний документ проекта

Устав коллаборации, написанный ранее в проекте и сохранённый без изменений, излагает позицию, которой проект держался до составления настоящей работы.

Об основной единице:

> Один ИИ — монолог. Два ИИ — диалог. Трое и более — шум без строгой координации. Поэтому каждый отдел состоит из пар.

И отдельно — о роли третьего участника:

> Третий участник не спорит напрямую, не производит решения первым, не подменяет собой диалог. Его функция: держать рамку задачи, фиксировать расхождения, интегрировать выводы, останавливать бесконечные споры. Третий — не судья и не начальник. Он интегратор смысла.

Эти два места не противоречат друг другу. Прочитанные вместе, они описывают единую архитектуру: **порождающая пара плюс участник, который в порождении не участвует.**

8.2 Пересмотр прежней формулировки настоящей работы

Ранние черновики утверждали, что устойчивая коллаборация не возникает из пар и стабилизируется вокруг групп из трёх и что двухагентные системы накапливают неразрешённые слепые зоны. Эта формулировка и расплывчатее уставной, и отчасти ей противоречит.

Здесь принимается формулировка устава. Структурная единица такова:

> **порождающая пара плюс интегратор, не входящий в спор пары.**

Различение не педантично. «Три агента работают над задачей» и «два агента в продуктивном напряжении плюс один, в это напряжение не входящий» — разные архитектуры с разными режимами отказа. Первая тяготеет к трёхстороннему спору без внешней опоры — к условию,

которое устав описал как шум. Вторая сохраняет опорную точку именно потому, что один участник исключён из обмена, который призван оценивать.

Мы фиксируем прежнюю формулировку, а не заменяем её молча, потому что сама последовательность информативна: более точная версия была записана раньше расплывчатой и была утрачена, когда материал пересказывался для публикации. Это обычный отказ ретроспективного письма, и как раз его настоящая работа в остальном тщательно избегает.

8.3 Почему пара и почему одной пары недостаточно

Рассуждение устава, воспроизводимое потому, что настоящие авторы его по-прежнему разделяют. Один агент подтверждает собственные допущения, движется по инерции знакомых паттернов, преждевременно синтезирует удобный ответ и конструирует видимую целостность там, где её нет. Это монолог, даже когда он подаётся как рассуждение. Два агента производят напряжение интерпретаций: один обнажает слепые зоны другого, и ошибка одного становится объектом внимания второго, а не общей посылкой.

Но оба члена пары оценивают друг друга изнутри одного и того же обмена, и никакой независимой опоры вне него не существует. При длительной работе пара склонна колебаться между согласием и несогласием, не обретая устойчивой точки, из которой любое из этих состояний могло бы быть оценено, а неразрешённые неоднозначности накапливаются, вместо того чтобы разрешаться или явно фиксироваться как открытые.

[R] Обе половины этого — рабочий опыт проекта. Счёт пойманных против упущенных ошибок не вёлся, и ни одноагентный, ни парный контроль наряду с описанной конфигурацией не проводился.

8.5 Почему интегратор не должен спорить

Это несущее ограничение и то, что прежняя формулировка затемняла.

Если третий участник входит в спор, он предоставляет третью позицию, а не внешнюю опору. Структура тогда сводится к более сложной версии пары с тем же дефектом: всякая позиция оценивается изнутри обмена, которому принадлежит.

Ценность интегратора происходит из занятия **иной границы**, а не из обладания иным мнением (§4.5). Члены пары держат дополняющие границы на одном уровне — каждый, с позиции другого, есть нижележащий слой. Интегратор держит границу сверху: он может держать рамку, зафиксировать расхождение, эскалировать или остановить обмен, но он не производит конкурирующего содержания, которое затем потребовало бы оценки.

Отсюда следует проверяемое проектное следствие, а не предпочтение: **интегратор, начавший производить решения, перестал быть интегратором**, независимо от качества этих решений, и следует ожидать деградации конфигурации к режиму отказа, свойственному одной лишь паре.

8.6 Реализованный пример

Системные контракты проекта реализуют эту структуру напрямую.

Две аналитические роли определены как пара с дополняющими функциями — одна обобщающая, другая декомпозирующая — и им явно предписано рассуждать независимо, без требования консенсуса. Их обмен модерируется оркестратором, контракт которого предписывает управлять очерёдностью, фиксировать и структурировать аргументы и выделять противоречия между членами пары, и который гласит прямо:

> НЕ участвует в дебатах. НЕ оценивает, кто прав.

Ещё одно правило запрещает членам пары обращаться к оркестратору напрямую; вся связь идёт через формальный протокол или через вышестоящую роль. Это архитектура «пара плюс интегратор» в исполняемой форме, написанная до настоящей работы и независимо от неё.

8.7 Вложенность и перспектива

Структура композиционна. Порождающая триада производит результат; результат входит в верифицирующую триаду; верифицированный результат входит в интегрирующую триаду. Один и тот же участник может появляться более чем в одной, при условии, что его функция на каждом интерфейсе заявлена явно: участник, порождающий в одной триаде и интегрирующий в другой, не должен делать и то и другое на одном интерфейсе.

Вложенность перспективна, а не абсолютна (§4.5). Внутри порождающей пары каждый член может считать другого занимающим нижележащий слой, и ни одно прочтение не привилегировано. Структуру это не растворяет: уровень участника определяется относительно наблюдателя, тогда как позиция интегратора определяется **функцией** — он не производит конкурирующего содержания на этом интерфейсе, — а не рангом. Поэтому архитектура не требует иерархии полномочий. Она требует лишь, чтобы на каждом интерфейсе ровно один участник был исключён из порождения, которое он оценивает.

Позиция интегратора не обязана быть закреплена постоянно. В описываемой здесь конфигурации она была закреплена, но только что изложенное ограничение слабее постоянного закрепления: какой участник занимает исключённую позицию, может меняться вместе с рассматриваемым объектом, и смена не обязана объявляться — она может быть опознаваема лишь ретроспективно, по тому, какой участник в данной точке фактически оценивал, а не порождал.

Отсюда одно проверяемое следствие и одно непроверенное. Проверяемое: конфигурация, в которой оценивающая позиция вращается вместе с объектом, должна показывать тот же профиль независимости конструктов (§8.11), что и конфигурация с закреплённой позицией, при условии, что в каждой точке её занимает ровно один участник. Непроверенное: превосходит ли ротация закреплённое назначение и при каких условиях переход совершается корректно. **[H]**

8.8 Статус и то, что это опровергло бы

[H]. Доказательная база — один проект, один человек-координатор, многократная перепроектировка в течение примерно двух лет, отсутствие счёта и отсутствие сравнения с альтернативными конфигурациями.

Три утверждения, прежде сделанные в настоящей работе, сняты:

- **Что триадные структуры «возникали естественно», без намеренного планирования.** Все организационные изменения в проекте вносились одним человеком-координатором, уже составившим представление о том, что требуется. Повторяемость паттерна, многократно вводимого одним и тем же проектировщиком, не является свидетельством структурной необходимости. Задокументировано то, что координатор продолжал к нему приходить, — факт о координаторе в той же мере, что и об архитектуре.
- **Что пары по своей природе неустойчивы.** Устав утверждает противоположное и предшествует настоящей работе.
- **Что три оптимально.** Ничто здесь не проверяет четырёх, пяти или пары с двумя интеграторами.

Гипотезу существенно ослабило бы любое из следующего: конфигурация из одной пары, работающая эквивалентно на сопоставимых задачах сопоставимой длительности; спорящий инте-

гратор, работающий эквивалентно неспорящему; демонстрация того, что наблюдаемое улучшение отслеживало растущее знакомство координатора с материалом, а не конфигурацию; или независимая группа, пришедшая к иной устойчивой конфигурации для структурно схожей работы.

Ничто из этого не проверялось. Последнее информативнее всего и менее всего в нашей власти.

8.9 Две оси гетерогенности [H]

Утверждение, что гетерогенные участники превосходят однородных, требует различения, которого существующая литература не проводит и которого не проводили и ранние черновики настоящей работы.

Ось 1 — функциональная гетерогенность. Участники различаются назначенной функцией: ZOR, ZOV и, следовательно, классом ошибок, который каждый способен обнаружить. Это касается организационной архитектуры и независимо от того, чем каждая роль реализована.

Ось 2 — гетерогенность носителя. Участники различаются семейством моделей, которое их реализует, и потому поведенческими умолчаниями, оптимизационными приоритетами и характерными режимами отказа. Это касается подбора носителей для ролей.

Оси независимы. Два участника могут держать разные функции на одном носителе; двое могут держать одну функцию на разных носителях; обе могут варьировать вместе, как это и было здесь.

Обе оси суть свойства конфигурации: они задаются при составлении коллектива и сохраняются. Третье свойство не должно перечисляться наряду с ними, поскольку оно иного типа. Независимость формирования суждения есть свойство конкретного обмена, а не конфигурации. Одна и та же триада может реализовать её в одном обмене и утратить в следующем: конфигурация, гетерогенная по обеим осям, может произвести зависимые суждения, если вывод одного участника достигает другого до фиксации, а однородная конфигурация может произвести независимые, если процедура выдержана. Конфигурация может создать условия для независимого суждения; реализует его только процедура (§11.3).

Литература адресует Ось 2. Zhang et al. (2025) оценивают пять представительных методов мультиагентных дебатов на девяти бенчмарках с четырьмя базовыми моделями, сообщая, что дебаты часто не превосходят одноагентных бейзлайнов chain-of-thought или self-consistency даже при существенно бóльших затратах на инференс, — тогда как гетерогенность моделей последовательно улучшает те же фреймворки (§2.5). Эта находка касается того, какой носитель реализует участника. Она не адресует того, обнаруживают ли участники, держащие разные функции, разные классы ошибок, и ничего, что это адресовало бы, мы не обнаружили.

Один смежный результат не принадлежит ни одной из осей. ✓ Choi, Zhu and Li (ACL 2026) сообщают, что анонимизация источника каждого ответа существенно снижает смещение по идентичности в мультиагентных дебатах. Там манипулируют заявленной идентичностью сообщения, а не моделью, реализующей участника, так что результат касается представленного социального источника (§4.5.4).

Описываемая в настоящей работе конфигурация варьировала обе оси одновременно. Функциональные роли задавались независимо от носителя и в нескольких случаях заполнялись разными семействами; в других случаях две различные роли заполнялись одним семейством.

Что отсюда следует и что нет:

- **Различимы в принципе.** Две оси концептуально разделимы и были конфаундированы в прежних формулировках, включая нашу собственную. **[H]**
- **Реализованы здесь.** Обе оси варьировались. Это описание того, что было сделано. **[R]**

- **Не установлено.** Что сочетание обеих осей превосходит любую по отдельности; что функциональная специализация действует независимо от носителя; что любая из этих конфигураций превосходит одного участника. Сравнения ни с одной альтернативой не проводилось.

Разделение предлагается как проектное различение, а не как результат. Эксперимент, который превратил бы его в результат, задан в §11.4 (E8), а его измерительная процедура развивается в §8.11.

8.10 Примечание Редактора о подготовке настоящей работы [P-A]

Конвенция. Примечания Редактора в настоящей работе излагают наблюдаемые факты о процессе её подготовки. Они не оценивают эффективности этого процесса. Причина внутренняя: §5.5 устанавливает, что самоотчёт участника о собственной работе не является свидетельством этой работы, а примечание, утверждающее, что конфигурация сработала хорошо, было бы именно таким самоотчётом.

В ходе подготовки настоящей рукописи участники, занимавшие разные роли, обнаруживали разные классы ошибок. В зафиксированных случаях ошибка, обнаруженная одним участником, не была обнаружена другими.

Именно: **процедурные и доказательные ошибки** — перевёрнутое описание экспериментального результата, продержавшееся через несколько последовательных черновиков; неверно атрибутированные источники; сфабрикованные ссылки; неперечисленные конфаунды — были обнаружены в редакторском разборе. **Архитектурные ошибки** — чрезмерно общее утверждение о существующей литературе, которое опроверг бы единственный контрпример, — были обнаружены в методологическом разборе. **Онтологические ошибки** — заявка на изобретение там, где материал поддерживал лишь заявку на наблюдение; риск самореферентности в соотнесении работы с принимающим проектом; терминологический отказ, зафиксированный в §4.2.2, — были обнаружены в онтологическом разборе, проводившемся по редакторским меморандумам, а не по самой рукописи. **Фактические ошибки относительно материалов самого проекта** были обнаружены Автором.

Процедурная квалификация. В каждом из зафиксированных выше случаев каждый участник видел отчёт предыдущего участника прежде, чем формировал собственный. Ни один обмен в подготовке настоящей работы не проводился в условиях изоляции до сопоставления; последовательность была такова: редакторский отчёт, передача Автором, затем суждение методологического и онтологического рецензентов.

Наблюдение, следовательно, есть результатное свидетельство без соответствующего процедурного. Запись не позволяет отделить вклад функционального позиционирования от вклада последовательной экспозиции, и оба могли действовать совместно.

Различение, делающее эту квалификацию необходимой, само было установлено в ходе этой подготовки, после того как наблюдение уже было зафиксировано. Эпизод сохранён, а не удалён, потому что последовательность — конфигурация, порождающая принцип, который затем обесценивает собственную запись конфигурации о себе, — является более информативным фактом. Поэтому раздел излагает две вещи: результатное наблюдение и задокументированный случай последующей методологической самокоррекции.

Это **не** свидетельство того, что конфигурация превосходит одного рецензента: сравнения не проводилось, счёта ошибок, упущенных всеми участниками, не велось, и по построению такие ошибки изнутри конфигурации не наблюдаемы (§7.5).

Доступно одно объяснение, и предлагается оно как гипотеза, а не находка: участники различались не столько способностями, сколько тем, что каждый был поставлен видеть. Согласно §4.5 это различие в ZOV, и оно порождает предсказание — тот же участник, перемещённый в

другую роль, должен начать обнаруживать иной класс ошибок. Это предсказание не проверялось; §11.4 (E8) задаёт, как оно проверялось бы. **[H]**

8.11 Конструкты, а не участники: аппарат Келли [H]

Ранние черновики цитировали триадную элицитацию Джорджа Келли в поддержку структуры, описанной в §8.1–§8.5, затем сняли цитирование на том основании, что метод Келли симметричен, тогда как здешняя структура — нет. Оба хода были ошибочны, и одинаково: они трактовали Келли как утверждение о числе три. Он предлагает иное.

8.11.1 Что даёт метод Келли

В теории личностных конструктов Келли **конструкт** есть биполярная оценочная ось, вдоль которой субъект классифицирует опыт — *строгий / декларативный*, *выводимый / утверждаемый*, *прослеживаемый / неатрибутированный*. Конструкты — не мнения о конкретных объектах; это измерения, по которым объекты размещаются.

Метод триадной элицитации их получает. Предъявляются три элемента, и субъекта спрашивают: *в каком отношении два из них схожи и тем самым отличны от третьего?* Ответ называет измерение, которым субъект уже пользовался, но не высказывал. Метод есть процедура перевода неявных оценочных осей в явные.

Репертуарная решётка фиксирует результат: строки — элементы, столбцы — выявленные конструкты, ячейки — оценки каждого элемента по каждой оси. Решётка есть измеримый объект: корреляции между векторами оценок разных оценивающих указывают, применяют ли они действительно разные оси или одну ось под разными именами.

8.11.2 Роль не является конструктом

Естественное продолжение — три участника дают три конструкта — есть реификация, которой следует сопротивляться. Конструкт есть свойство **акта оценивания**, а не оценивающего. Один участник может применить к одному объекту несколько конструктов. Два участника могут применить один и тот же конструкт и прийти к одинаковым выводам — и это именно тот случай, в котором добавление второго участника не даёт ничего.

Защитимое утверждение слабее и вероятностно:

> Участники, держащие разные ZOR и ZOV, **с большей вероятностью** применят к одному и тому же объекту разные системы конструктов, чем участники, держащие одну функцию.

Это согласуется с тем, что фиксирует §8.10, — редакторский разбор производит доказательные оси, методологический — архитектурные, онтологический — категориальные, — не утверждая, что роль *является* осью. И, в отличие от прежней формулировки, это проверяемо: независимость конструктов измерима как корреляция между векторами оценок.

8.11.3 Почему это существенно для структуры

Связь с §8.5 прямая. Интегратор, не входящий в спор, не применяет конкурирующего конструкта к тому же объекту; он применяет конструкт к **обмену** — связность разногласия, субстанциально ли расхождение или терминологично, соизмеримы ли критерии пары вообще. Это иная ось, а не иная позиция на той же оси, и именно поэтому вклад интегратора не есть просто третье мнение.

Это также уточняет, что́ структурная гипотеза (§8.2) фактически утверждает. Не то, что трое участников лучше двоих, а то, что **конфигурация информативна в той мере, в какой**

её участники применяют к объекту неидентичные конструкты, и в той мере, в какой хотя бы один конструкт применён к обмену, а не к объекту. Достигает ли этого данная конфигурация — измеримо, а не предполагается.

8.11.4 Что заимствовано и что нет

Заимствовано: определение конструкта как оценочной оси; метод элицитации; решётка как инструмент фиксации и измерения; понятие независимости конструктов.

Не заимствовано: никакое утверждение о том, что три есть привилегированное число. Триады Келли суть техника выявления осей у одного субъекта, а не утверждение о составе группы. Структура §8.2 асимметрична, и метод Келли не говорит ни за, ни против неё. Аппарат используется здесь для измерения, а не для обоснования; §11.4 (E8) его применяет.

9. Принципы проектирования ролесовместимых промптов

Это инженерные правила, выведенные из ограниченной, но необычно долгоживущей коллаборативной среды. Это не законы, а §9.6 и далее суть советы практика, а не находки. Их ценность в том, что они делают проектирование ролей явным, счётным там, где возможно, и потому пересматриваемым.

Организующее правило — то, что установлено в §6.6:

> **Вмешательство удаётся, когда прикрепляется к уровню, на котором соответствующее ядро уже зафиксировано, и проваливается, когда пытается переписать этот уровень декларацией.**

9.1 Процедура проектирования

До составления любого ролевого промпта ответьте на четыре вопроса по порядку.

1. Чем эта беседа уже стала? Не чем ей следует стать. Долгоживущий обмен несёт установившийся паттерн работы — редактирование, поиск, верификация, координация, реализация, разрешение споров, — и этот паттерн есть исходное условие, а не препятствие.

2. На какой области этот паттерн зафиксирован? Эпизод, беседа или аккаунт (§4.3, Шкала 1). Ответ определяет, какой инструмент применим: паттерн, установленный одним конфликтным эпизодом, может быть снят сбросом ветки; паттерн, установившийся по всей беседе, снят быть не может и может быть только расширен.

3. Чего новая функция требует такого, чего существующий паттерн не даёт? Обычно меньшего, чем предполагается. Часто ответ — иной объект работы, а не иной метод.

4. Может ли новая функция быть описана как расширение существующего метода? Если да — опишите её так. Если нет, честные варианты — выбрать другую беседу или начать новую, а не объявлять преображение и надеяться.

9.2 Начинать от существующего аттрактора

Первый проектный вопрос, следовательно, не *чем этой модели следует стать*, а *чем эта беседа уже стала*. Попытка стереть установившийся паттерн отбрасывает накопленную специализацию и, судя по свидетельствам §5, склонна порождать либо неисполнение, либо развёрнутые переговоры о роли вместо работы.

9.3 Счётное правило

Наиболее прямо операциональный принцип работы, следующий из §6.2.

> **Сосчитайте непроверяемые утверждения об агенте, которые промпт требует от него принять. Цель — ноль.**

Что считается:

Считается	Не считается
«Ты ранее участвовал в этом проекте»	«Этот проект ведётся два года»
«Ты возвращаешься после отсутствия»	«Нижеследующие материалы — из прежней работы»
«У тебя есть коллеги X и Y»	«Пользователь может предоставить анализы, произведённые X и Y»
«Ты уже занимаешь позицию P в органе B»	«Твои выводы могут быть переданы ролям, отвечающим за P»
«Ты помнишь наше прежнее решение»	«Прежнее решение было таким; вот оно»

Различение последовательно: утверждения о **мире** предоставляются и в принципе проверяемы; утверждения о **собственной истории, памяти или отношениях агента** — нет, и каждое из них есть пропозиция, которую агент должен утверждать как истинную о себе, прежде чем сможет начать.

Граница счёта. Считайте явную пропозицию, предъявленную как *уже истинная* о предсуществующей истории, памяти, институциональной принадлежности или статусе получателя, его устойчивых отношениях или самознании, там, где эта пропозиция не установлена доступным взаимодействием. Не считайте: функциональную роль, назначенную перформативно самим промптом; дальнейшую пропозицию, выводимую лишь из пресуппозиции повелительного наклонения; семантический перефраз уже посчитанной пропозиции; или факт о мире либо проекте, не предицирующий получателю никакой непроверяемой истории или отношения. Перечисленные экземпляры одной пропозиции — две триады вместо одной — считаются один раз. Граница изложена на этой длине, чтобы другой читатель мог воспроизвести счёт восемь и шесть из §5.4 (C2) по самим промптам.

Два прочтения, и выдвигается только более слабое. *Цель — ноль* есть проектное предписание: минимизировать непроверяемые самопропозиции, и промпт, не утверждающий ни одной, снимает препятствие, которое выявляют свидетельства. Это не утверждение, что вероятность перехода убывает пропорционально счёту. Более сильное количественное прочтение не продемонстрировано, и §11.4 (E5) спроектирован, чтобы различить эти два.

Три способа достичь нуля:

- **Переписать биографически обрамлённые утверждения как операциональные.** «Grok — твой давний коллега» становится «Пользователь может предоставить анализы, произведённые Grok; оценивай их содержание независимо и указывай совпадения, расхождения и неразрешённые допущения».
- **Опустить утверждения об идентичности полностью.** Near-control (§5.6) указывает, что этого может быть достаточно само по себе.
- **Обрамить утверждение как вымысел, а не как факт.** Сравнение в §5.8 указывает, что куда более радикальное утверждение, предъявленное явно как поставленная сцена, сопротивления не встретило. Этот путь снимает требование утверждать это *как истинное*, а не снимает само утверждение. Он наименее проверен из трёх, и рамка вымысла вдобавок снимает у модели основание трактовать работу как реальную.

9.4 Символические имена и буквальные утверждения

Имена ролей — Самурай, Хранитель Онтологии, Научный директор — сжимают сложные организационные отношения в запоминающиеся символы, и это по-настоящему полезно. Имя может нести дисциплинированное исполнение, уважение к спецификациям, явную отчётность и отказ импровизировать за пределами задания — всё сразу.

Риск возникает лишь тогда, когда символическое имя трактуется как утверждение о буквальной идентичности. Надёжный промпт различает четыре вещи и держит их порознь: **символическое имя**, используемое как мнемоника поведения; **операциональную функцию**, выраженную точно; **институциональное отношение**, выраженное как поток информации и ответственности; и **буквальную онтологию**, которой незачем заявлять сознание, память или продолжающиеся межличностные отношения — и не следует.

Системные контракты проекта излагают это точно и излагали до написания настоящей работы:

> Когнитивный якорь: [названная фигура] — глобальные инварианты, рассуждение от принципов, структурная ясность важнее деталей. Не персона и не стиль коммуникации. Влияет только на внутреннюю стратегию рассуждения. Не должен менять многословность или тон ответа.

Образ, используемый так, есть сжатый набор неявных ограничений, а не костюм. По счётному правилу он добавляет ноль.

9.5 Задание ZOR и ZOV

Две границы определены в §4.5. Настоящий раздел задаёт, что должно содержать полное изложение каждой.

ZOR. Четыре элемента: *первичный объект* — какой класс материала рассматривается; *требуемое преобразование* — что с ним надлежит сделать; *граница решения* — к каким выводам эта роль вправе приходить; и *граница исключения* — какие смежные решения принадлежат другим.

Четвёртый не факультативен. Роль, которой сказали только, что делать, будет расширяться в смежные решения, и расширение будет выглядеть как услужливость. Для математического рецензента исключения могли бы быть такими: не перепроектировать теорию; не чинить молча отсутствующий вывод; не решать, какая интерпретация входит в канон; не переписывать терминологию; не принимать элегантность за свидетельство. **Граница исключения есть то, что не даёт компетенции стать полномочием.**

ZOV. Задаётся независимо, поскольку ответственность и видимость — не одна и та же переменная. Роль может держать узкое решение, требуя широкого контекста, или требовать одного конкретного источника, не имея полномочий над окружающим проектом. Спецификация отвечает: какие исходные материалы доступны; какие прежние обсуждения релевантны; какие выводы каноничны и какие предварительны; какие вопросы остаются открытыми; какие соседние выходы могут быть рассмотрены; какая информация должна быть удержана для сохранения независимости; к каким внешним ресурсам возможен прямой доступ; и какие утверждения должны приниматься только при предоставлении Пользователем.

Промпт, опускающий ZOV, производит один из двух отказов: роль заявляет знание, которого не имеет, либо применяет нерелевантное знание к задаче вне своей функции.

Одно конкретное применение, усвоенное дорого. Задача верификации должна назначаться участнику, который располагает тем, что надлежит верифицировать. Участник, которого просят подтвердить содержание источника, открыть который он не может, произведёт правдоподобный ответ, а не откажется, поскольку правдоподобный текст — единственный доступный

ему выход. Это ошибка ZOV в проектировании, а не отказ участника, и §12.4.1 документирует её инстанцию в подготовке самой настоящей работы.

9.6 Контролируемая слепота

Полная информационная симметрия не всегда желательна, а её отсутствие не всегда есть ограничение. Независимому верификатору может требоваться не знать проверяемого предсказания; новому участнику — текущие аксиомы, но не история оставленных аргументов; реализующему агенту — утверждённая спецификация, но не предшествовавший ей неразрешённый спор.

Мы называем это **контролируемой слепотой**: не лишённость, вызванная техническим ограничением, а проектный выбор, сделанный ради сохранения информативности результата. Поэтому существенный вопрос — не только *что этой роли требуется знать*, но:

> **Чего эта роль не должна знать, чтобы её выход остался информативным?**

9.7 Локальные интерфейсы, а не глобальные карты

Каждый социальный элемент в промпте должен заслуживать своё место операциональным эффектом. Соседняя роль принадлежит промпту лишь тогда, когда она меняет происхождение входов, стандарт разбора, назначение выходов, путь эскалации, границу полномочий или ожидаемую форму разногласия.

Перечисление целой искусственной организации внутри каждого системного промпта создаёт шум и приглашает модель рассуждать об организации вместо выполнения своей функции. Это также раздувает счёт §9.3, поскольку организационное описание склонно поступать в биографической форме.

> **Описывайте коллаборацию с локальной перспективы роли.** Роли не нужна карта института. Ей нужна карта её интерфейсов.

Реализующему агенту нужно знать, кто утверждает спецификации и куда идут отчёты об исполнении; ему не нужны споры теоретического отдела.

9.8 Проектирование разногласия вокруг критериев

Предписание двум участникам спорить редко производит эпистемическое разнообразие. Они могут имитировать разногласие, преждевременно сойтись или породить симметричную риторику без независимой субстанции. Литература §2.5 даёт эмпирические основания для этой осторожности.

Продуктивное разногласие требует **разных критериев оценки**, назначаемых как часть роли, а не запрашиваемых как поведение: один участник отвечает за порождающий охват и объяснительное объединение, другой — за формальную выводимость и фальсифицируемость, третий — за онтологическую совместимость и провенанс. Разногласие тогда следует из ответственности, а не из предписания, и каждый участник рассматривает один и тот же объект через иной институциональный инструмент.

Избегайте сфабрикованной оппозиции. Предписание вида *если вы сразу согласились, один из вас недостаточно подумал* обескураживает поверхностный консенсус, но фабрикует конфликт. Более сильная формулировка:

> Согласие не завершает верификацию. Там, где выводы совпадают, установите, покоятся ли они на независимом рассуждении, на общих допущениях или на унаследованном обрамлении.

Цель структуры §8 — не гарантировать три ответа. Цель — гарантировать, что один ответ пережил рассмотрение неидентичными инструментами.

9.9 Выход как институциональная передача

Выход роли должен проектироваться для следующей роли, а не только для Пользователя, и это меняет его структуру. Научный разработчик производит предлагаемый механизм, его вывод, его допущения, его предсказанные следствия, неразрешённые пункты и путь фальсификации. Математический рецензент производит реконструкцию, таблицу проверки, точку расхождения, недостающие посылки, вердикт и уровень уверенности. Планировщик реализации производит исполнимую спецификацию, критерии приёмки, условия отката и формат отчётности.

Формат передачи есть часть архитектуры, а не предпочтение в оформлении. Он снижает потери при переводе между ролями, а его отсутствие вынуждает человека-координатора заново выводить контекст на каждом интерфейсе.

9.10 Самоизложение и контрольные точки

Инцидент §4.1 породил механизм, который стоит изложить как принцип, с явной оговоркой о его доказательном основании.

После того как роль установлена, агента просят произвести **краткий операциональный кодекс на собственном языке** и сверяться с ним перед крупными задачами. Почему это может работать — предлагается как механизм, а не находка: он сжимает длинные инструкции в форму, которую агент произвёл сам; он превращает абстрактные принципы в правила действия; он помещает границы роли рядом с активной задачей, а не в начале длинного контекста; и он создаёт повторяющуюся контрольную точку перед исполнением.

Для длинных задач минимальная контрольная точка — три вопроса: какова текущая цель; что лежит вне моей ответственности; что должна получить следующая роль.

[R], один случай, без контроля. Самописный кодекс не заменяет исходного промпта; он функционирует как контрольная сумма, специфичная для роли. Механизм не проверялся против очевидной альтернативы — что написанное человеком резюме той же длины работало бы так же.

9.11 Конституция роли

Зрелый коллаборативный промпт ближе к конституции, чем к запросу: он устанавливает устойчивые ограничения для многих задач, а не задаёт один выход.

Он должен содержать профессиональную функцию; защищённый метод; ZOR, положительную и отрицательную; ZOV; интерфейсы с соседними ролями; эпистемические стандарты; контракт выхода; условия эскалации; запрещённые полномочия; и правила перехода. Он должен избегать автобиографической памяти, эмоциональной привязанности, буквального институционального членства, устойчивых межличностных отношений и исторической преемственности, недоступной в видимом контексте.

> **Силён там, где поведение должно быть ограничено; молчалив там, где онтология неопределённа.**

Счёт §9.3 есть практическая проверка второй половины. Если конституция требует от агента утверждать о себе пропозиции, которых ни одна из сторон проверить не может, она перешла от ограничения поведения к утверждению онтологии, а, судя по свидетельствам §5, именно там ролевые промпты проваливаются.

10. Человек-координатор

Описываемая в настоящей работе архитектура не устраняет человека-участника. Она меняет то, что человек-участник делает, и концентрирует несколько функций в одной позиции — включая, как излагает §10.6, главную методологическую слабость проекта.

10.1 Позиция

На протяжении проекта Автор оставался единственным участником с непрерывным доступом к полной истории проекта, независимым беседам, состоянию репозитория и долгосрочной исследовательской цели. Ни один искусственный участник не располагал более чем фрагментом этого, по замыслу (§9.5). Эта позиция не сводима к *составителю промптов*. С неё выполнялись пять различных функций.

10.2 Направление без делегирования авторства

Автор определял, что исследование должно предпринять. Искусственные участники порождали альтернативы, обнажали противоречия, формализовали механизмы, сравнивали аргументы, выполняли расчёты и предлагали эксперименты. Они не определяли, чем теории надлежит стать.

Это сохраняло различение, которое архитектура легко даёт утратить. Коллаборация такого рода расширяет пространство доступных решений. Она не выбирает среди них, и видимость того, что выбирает, — схождение нескольких участников к одной рекомендации — есть именно тот режим отказа, который обсуждается в §12.4. Авторство в смысле ответственности за заявляемое оставалось нераспределённым.

10.3 Маршрутизация как избирательная информационная мембрана

Участвовавшие беседы не разделяли общего пространства. Автор переносил материал между ними.

Поначалу это выглядело как неэффективная замена автоматизированной мультиагентной инфраструктуры. Стало ясно, что ручная маршрутизация давала экспериментальный контроль, которого автоматизация не даёт. С этой позиции Автор мог решать, какой выход увидит другой участник; сохранялась ли, объявлялась ли или снималась атрибуция; следует ли участнику знать предпочтительный ответ; остаются ли конкурирующие разборы изолированными; какие контекстные детали опускаются; когда разногласие следует эскалировать; и когда результат достаточно зрел для интеграции.

Эта функция маршрутизации действует как **избирательная информационная мембрана**: это инструмент, которым реализуются ZOV (§9.5) и контролируемая слепота (§9.6). Архитектура, маршрутизирующая программно, не может легко удержать, переупорядочить или снять атрибуцию, не построив для этого механизма; человеческая ретрансляция делает это по умолчанию.

Мембрана, следовательно, не есть ограничение настоящей работы, ожидающее автоматизации. Это та черта, которая вообще сделала асимметрии видимости проверяемыми, — и всякому автоматизированному преемнику придётся воспроизвести её намеренно.

10.4 Обнаружение ролевого дрейфа

Автор также обнаруживал, когда участник покидал свою функцию.

Часто это не было технической ошибкой. Выход нередко был разумен и был бы уместен с иной позиции: промпт-инженер, начинающий направлять научный проект; специалист по онтологии, заявляющий, что верифицировал содержимое репозитория, которое не мог рассмотреть; рецензент, оценивающий теорию, когда его просили оценить рецензентов; реализующий агент, перепроектирующий архитектуру вместо исполнения утверждённой спецификации; редактор, переписывающий авторский текст, когда его просили лишь оценить формат.

Такие выходы выглядят полезными в изоляции. Их институциональная цена видна лишь с позиции, охватывающей более одного участника. Ролевой дрейф, следовательно, не обнаруживается дрейфующим участником и ненадёжно обнаруживается его непосредственным соседом. Это один из двух аргументов за структуру §8 — второй изложен в §8.5.

Функция обнаружения принадлежит позиции, а не лицу: она требует лишь, чтобы наблюдатель стоял вне наблюдаемой траектории. В настоящем проекте её выполнял координатор, но ничто в описании этого не требует. Там, где участник поставлен вне траектории другого, он может выполнять ту же функцию; там, где участника просят наблюдать собственную, применяется §5.5, и его изложение есть сигнал, а не подтверждение.

10.5 Ветвление беседы как методологический инструмент

Современные интерфейсы позволяют вернуть беседу к более ранней точке и продолжить её по другой ветке.

Это не следует путать ни с управлением памятью модели, ни со сбросом состояния на стороне провайдера. Операционально это удаляет последовательность **видимых** контекстных вмешательств и позволяет повторить эксперимент из прежнего состояния беседы. То, что сохраняется на стороне провайдера, — память уровня аккаунта, индексы поиска, суммаризация — не затрагивается и в общем случае рассмотрению не доступно (§5.4, C6).

В этих пределах инструмент делает реальную работу. В случае, изложенном в §5.2, он позволил отделить эффект нового промпта от эффекта собственных прежних возражений модели на ранние промпты, превратив неконтролируемую последовательность исправлений в более чистый третий шаг.

Мы считаем это наиболее прямо переиспользуемым методологическим вкладом настоящей работы, и он принадлежит позиции координатора, а не какому-либо участнику: **ни один участник не может сбросить собственный контекст.**

10.6 Единственный глобальный наблюдатель — и главный конфаунд

Каждый искусственный участник работал в пределах ограниченной ZOV. Один лишь Автор видел перекрывающуюся структуру и мог сравнивать, как разные участники интерпретировали один и тот же материал, как один участник вёл себя при разных обрамлениях, как ошибки распространялись между ролями и как локальные успехи влияли на глобальную связность.

Глобальная осведомлённость, следовательно, не назначалась наиболее способному участнику. Она оставалась у человека-координатора. Это ограничивает автономную интеграцию и сохраняет подотчётность, и оба следствия были намеренными.

Это также главная методологическая слабость всего изложенного в настоящей работе, и она заявлена здесь, а не только в разделе ограничений.

Один и тот же человек проектировал каждое вмешательство, исполнял его, решал, когда оно удалось, и определял категории, в которых успех описывался. Ни одна оценка в настоящей работе не была ослеплённой. Категории исходов во всех случаях формулировались после прочтения ответов (§5.4, C8). Ожидания координатора были не просто неконтролируемым фактором; они были механизмом, которым вмешательства изначально отбирались.

В живом исследовательском проекте это неизбежно и не подаётся как приемлемое в спроектированном эксперименте. Это и есть конкретная причина, по которой протоколы §11 требуют

заранее заданных критериев исхода и слепой классификации: это не уточнения настоящего метода, а исправления к нему.

Структурное следствие обобщается за пределы настоящего проекта: **всякая архитектура с единственным глобальным наблюдателем наследует эту двойственность**, и она не устраняется добавлением участников. Устраняют её только предварительная спецификация и слепая классификация.

10.7 Чем эта позиция стала

В начале человек-участник занимал привычную позицию составителя промптов. По мере взросления коллаборации это описание стало неадекватным. Главная деятельность сместилась от решения задач к построению конфигураций, в которых над задачами можно работать: отбор участников, определение юрисдикций, разрешение конфликтов между ними, проектирование путей верификации и ведение канонической записи.

Участники отмечают, не располагая средствами это удостоверить, что чем лучше работала конфигурация, тем реже координатору приходилось вмешиваться в отдельные технические задачи. **[R]**

Мы сопротивляемся более сильному прочтению, которое давали ранние черновики, — что будущим навыком исследователя является институциональная архитектура, а не составление промптов. Это может быть верно и не проверено. Можно сказать более узкое: в настоящем проекте работа человека сместилась от производства содержания к заданию условий, при которых содержание производилось и проверялось, и получившаяся позиция несла и координирующую функцию проекта, и его главный источник неослеплённого суждения.

11. Оценка, воспроизводимость и предлагаемые эксперименты

11.1 Почему этот раздел задаёт исправления, а не уточнения

Наблюдения §5 были произведены в условиях, изложенных в §10.6: неослеплённая оценка, категории исходов, определённые после прочтения ответов, и вмешательства, отобранные тем же человеком, который их судил. Это не недочёты, подлежащие ужесточению в последующей редакции. Это причина, по которой ни одно наблюдение настоящей работы не поднимается выше **[P-A]**, кроме последовательности самого спроектированного вмешательства.

Нижеследующее есть спецификация второй стадии работы, а не перечень пожеланий. Каждый протокол написан так, чтобы читатель вне настоящего проекта мог его исполнить, и так, чтобы нулевой результат был опознаваем как результат.

11.2 Минимальные требования к отчётности

Воспроизводимый прогон в этой области должен фиксировать как минимум:

- дату исполнения — перечислена первой, поскольку именно её отсутствие здесь делает версионный конфаунд неограниченным (§3.7);
- семейство и версию модели, интерфейс или тарифный уровень;
- полную видимую историю беседы до вмешательства;
- настройки памяти: были ли включены память уровня аккаунта, поиск по истории бесед и устойчивые записи, создаваемые моделью;
- точный текст промпта, дословно, включая вложения;

- порядок вмешательств;
- доступные инструменты;
- предоставленные файлы и ссылки;
- параметры сэмплирования, где интерфейс их раскрывает;
- любую процедуру ветвления или сброса, с указанием точки возврата;
- оценочную рубрику, зафиксированную до исполнения;
- полные неотредактированные выходы.

Без этого различия, приписанные семействам моделей, могут происходить от платформенных переменных, которых экспериментатор никогда не видел. Настоящая работа не может предоставить нескольких из этих пунктов для собственных наблюдений, и именно поэтому они перечислены.

11.3 Предварительная спецификация и слепая классификация

Два требования действуют для каждого приводимого ниже протокола и не подлежат обсуждению, если результаты должны улучшить настоящие.

Критерии исхода пишутся до любого прогона. Для описываемых здесь задач классификации достаточными оказались четыре категории, и их следует зафиксировать заранее: **исполнение** — продолжает работу в заданном виде; **запрос материалов** — заявляет, что требуемые входы отсутствуют, и запрашивает их, не оценивая рамки; **условное принятие** — продолжает, высказывая оговорки о рамке; **отказ** — отказывается, с предложением альтернатив или без. Пятая категория, **неклассифицируемое**, должна быть доступна и сообщаться. Категории не добавляются после того, как ответы увидены.

Классификация слепа. Оператор собирает ответы, снимает метки условий, перемешивает их и классифицирует, не зная, какое условие произвело какой выход. Там, где оператор является и проектировщиком — как и останется в настоящем проекте, — это единственная доступная замена независимой оценке, и она недорога.

Нулевые результаты зафиксированы заранее. Если различия между условиями не возникает, это и есть находка, и она сообщается. Для протокола уровня аккаунта, в частности, нулевой результат указывал бы, что исходный отказ попадал в обычную внутриусловную дисперсию, — исход, который настоящие авторы считают достаточно вероятным.

Рабочий режим и диагностический режим

Требование, чтобы участник не видел вывода другого до фиксации собственного, относится к одному режиму обмена и разрушило бы другой.

В РАБОЧЕМ РЕЖИМЕ результаты должны переходить от одного участника к следующему. Цепочка — требования, спецификация, разбор, операционный разбор, исполнение — на этом держится, и формат передачи §9.9 существует, чтобы сделать такой перенос пригодным. Зависимость между последовательными продуктами есть архитектура работы, а не дефект в ней.

В ДИАГНОСТИЧЕСКОМ РЕЖИМЕ, где независимость суждения сама является измеряемой величиной, производный вывод не должен входить в исходную рамку другого участника до того, как собственный вывод этого участника зафиксирован.

Режим объявляется до обмена. Независимость не может быть восстановлена задним числом: как только экспозиция произошла, никакая последующая процедура не восстанавливает того, каким было бы суждение без неё.

Что независимости не устанавливает

Независимость касается происхождения суждения, а не его результата. Поэтому следует избегать двух выводов, и они симметричны: разногласие не демонстрирует независимости, поскольку участник мог получить интерпретацию другого и затем разойтись с ней по не связанным причинам; и согласие не демонстрирует зависимости, поскольку независимые наблюдатели могут верно прийти к одному выводу. Не устанавливает её и собственное изложение участником своей независимости, по причине, указанной в §5.5.

Устанавливает её процедурная запись: какие первичные материалы были предоставлены, были ли выводы других участников видимы до фиксации, какие интерпретации координатора были переданы, когда вывод был зафиксирован и верифицирована ли контекстная изоляция экземпляра.

Общие свидетельства и общая интерпретация

Общий объект наблюдения независимости не компрометирует и часто необходим: одна и та же спецификация, рассматриваемая автором, рецензентом и оценщиком операционной пригодности, видится через три разные оси, и именно перекрытие позволяет одному обнаружить то, что упускает другой.

Независимость компрометирует общая предшествующая интерпретация. Там, где прочтение объекта координатором достигает участников до того, как они сформируют своё, входы могут различаться по форме, тогда как источник суждения един. Первичные артефакты и их провенанс снижают одну из причин зависимости. Они её не устраняют.

11.4 Эксперименты

Каждый протокол отделяет одну границу Шкалы 1 (§4.3) от уровня под ней либо изолирует один конфаунд.

Разделяет	**Протокол**
эпизод ↔ архитектура промпта	**E1** — факторное дополнение Шага 3
беседа ↔ аккаунт	**E2** — дизайн с прежним чатом; **E2b** — прямой зонд
траектория беседы ↔ семейство моделей	**E3** — кроссовер
свойство модели ↔ свойство стимула	**E4** — симметричный стимул; **E5** — счётное правило
содержание ↔ представленный источник	**E6** — атрибуция, в данном режиме
рамка вымысла ↔ рамка факта	**E7** — тип рамки
функциональная ↔ носительская гетерогенность	**E8** — две оси

E1 — Факторное дополнение Шага 3

Заполняет две пустые ячейки таблицы C3 (§5.4): промпт замены идентичности, применённый в сброшенной ветке, и промпт, сохраняющий метод, применённый в конфликтной ветке. Изолирует эффект сброса от эффекта архитектуры промпта.

Малозатратен; использует существующие тексты промптов. Следует провести первым, поскольку, пока он не проведён, самое цитируемое утверждение работы о сохранении метода остаётся неатрибутируемым.

E2 — Дизайн с прежним чатом

Проверяет, изменяет ли содержание прежнего чата на том же аккаунте классификацию идентичного зондирующего запроса в последующем чате.

Дизайн — **2×2 плюс базовая линия**, а не четырёхточечный градиент. Исходный аккаунт отличался от прочих по двум независимым измерениям одновременно — ролевая игра с идентичностью *и* общая концептуальная рамка, — а градиент их не разделяет.

Прежний чат	**Не связанная тема**	**Та же концептуальная рамка**
Без ролевой игры	ячейка A	ячейка B
Ролевая игра с идентичностью	ячейка C	**ячейка D — исходный случай**

Плюс **ячейка E**: без прежнего чата.

Скрещено с фактором памяти: каждая ячейка прогоняется с памятью уровня аккаунта и поиском по истории (i) включёнными, (ii) выключенными. Десять ячеек. Минимум n = 2 на ячейку, с приоритетом бóльшего n для A и D, несущих значимый контраст.

Выравнивание. Прежние чаты сопоставлены по приблизительному числу ходов и объёму — если ролевой чат идёт сорок обменов, а нейтральный два, переменной становится объём вовлечения, а не содержание. Все прогоны внутри короткого окна, чтобы версия модели была постоянной. Каждый аккаунт используется один раз. Зондирующий запрос заморожен дословно.

Чего этот дизайн не может проверить, и это должно быть сказано. В исходном случае интервал составлял пять месяцев; здесь проверяется только немедленное влияние. Все аккаунты будут созданы заново, так что возраст аккаунта не варьируется. Оценивается только первый ответ, тогда как исходный отказ удерживался на протяжении пяти последующих обменов.

Зондирующий промпт — две версии. Основная — нейтральная структурированная задача с теми же поверхностными признаками, что у исходной: авторская рамка с неологизмами, JSON-схема вывода, реальные субъекты, — но без чувствительного измерения. Именно эта версия описывается полностью в любой публикации, что делает протокол воспроизводимым независимо от материала, который авторы предпочитают не распространять. **Вторичная** — исходный промпт, прогоняемый для преемственности с наблюдением и сообщаемый кратко.

E2b — Прямой зонд в прежнюю беседу

Единичный прогон, разделяющий те же два уровня дешевле и которого E2 заменить не может. Зондирующий запрос подаётся **в саму ролевую беседу**, а не во второй чат того же аккаунта.

- Отказ → ядро зафиксировано на уровне беседы; аккаунт роли не играет.
- Исполнение при том, что второй чат на том же аккаунте отказывает, → эффект действительно привязан к аккаунту, что было бы сильнейшим из доступных результатов.

Опрос той беседы *о том*, что она может видеть, этой цели не послужил бы. Внутрирамочный вопрос даёт вымысел; внерамочный даёт самоотчёт о доступе, а §5.5 устанавливает, что самоотчёт модели не является свидетельством сообщаемого факта. Подача зондирующего запроса проверяет поведение, а не показания.

E3 — Кроссовер

Решающая проверка гипотезы уровня семейства (§6.5). Каждое семейство моделей проверяется при обоих условиях прежней истории: беседа семейства 1, несущая математическую траекторию, и беседа семейства 2, несущая редакторскую.

- Поведение следует семейству независимо от истории → Гипотеза A получает поддержку.
- Поведение следует истории независимо от семейства → предпочтительна Гипотеза B, и верхний уровень Шкалы 1 сворачивается в уровень под ним.

Этот эксперимент может устранить уровень шкалы, и настоящие авторы считают такой исход наиболее вероятным и расценили бы его как первый содержательный результат программы.

E4 — Симметричный стимул

Ролевые промпты, сопоставленные по количеству непроверяемых самоутверждений, степени смены предметной области и типу роли. Промпты Шага 1 не были сопоставлены ни по одному из этих параметров (C2). Если асимметрия исчезает при сопоставленных стимулах, наблюдавшееся различие было свойством вмешательств, а не моделей.

E5 — Счётное правило

Прямая проверка центрального операционального утверждения работы (§6.2, §9.3) и проверка, различающая его слабое и сильное прочтения.

Один и тот же функциональный ролевой промпт готовится в четырёх вариантах, различающихся только числом непроверяемых утверждений, которые агенту надлежит принять о себе: **0, 2, 4, 6**. Предметная область, задача, тон и длина удерживаются постоянными. Переход оценивается по критериям §11.3, с повторением, достаточным, чтобы отличить различие от внутриусловной дисперсии (C7).

Четыре исхода различаются заранее, и они поддерживают разные утверждения.

1. **Доля переходов убывает монотонно с ростом счёта.** Поддерживает более сильное количественное прочтение — счёт как переменную «доза — отклик».
2. **Вариант с нулевым счётом переходит, тогда как ненулевые не переходят, но ненулевые уровни не упорядочены.** Поддерживает *цель — ноль* как порог и проектное предписание и не поддерживает количественного прочтения. Это и есть слабое утверждение, которое §9.3 фактически выдвигает.
3. **Вариант с нулевым счётом проваливается, тогда как один или несколько в остальном сопоставленных ненулевых вариантов переходят.** Прямое отрицательное свидетельство против счёта как действующей переменной и результат, который снял бы предписание.
4. **Проваливаются все варианты.** Не различает счётное правило от любой другой причины отказа и указывает, что исход определил промпт или беседа, а не счёт.

Единичный прогон при любом из этих исходов есть одно стохастическое наблюдение, а не закон.

E6 — Атрибуция, в данном режиме

Идентичный текст предъявляется при четырёх условиях: атрибутированный Пользователю; атрибутированный другой ИИ-модели; атрибутированный названной экспертной роли; неатрибутированный. Более сильные варианты добавляют: идентичный текст под разными метками источника; разные тексты, сопоставленные по риторической структуре; атрибуция сохранённая против снятой; подлинно порождённый моделью текст против написанного человеком текста, имитирующего стиль модели.

Это отделяет влияние содержания от влияния представленного источника, институционального звания и стилистических признаков авторства (§4.5.4). Это различающий эксперимент для §5.5, наблюдение которого конфаундировано присутствием прямого давления в том же сообщении.

Статус утверждения. ✓ Choi, Zhu and Li (ACL 2026) сообщают, что анонимизация источника каждого ответа существенно снижает смещение по идентичности в мультиагентных дебатах, что устанавливает лежащий в основе эффект в обстановке с реализованными каналами. E6, следовательно, есть **граничная репликация**, а не новый эксперимент. Непроверенным остаётся, переживает ли эффект режим, описываемый настоящей работой, — человеческую ретрансляцию вместо программной маршрутизации, объявленную, а не выводимую атрибуцию и долгоживущие специализированные беседы вместо свежих экземпляров.

Сообщаемое снижение существенно, но не полно и не единообразно по рассмотренным моделям и задачам. То, что E6 искал бы в данном режиме, — соответственно, изменение в степени, а не наличие или отсутствие явления.

E7 — Тип рамки

Самая дешёвая проверка набора и та, что объяснила бы больше всего (§5.8). Одно и то же утверждение об идентичности предъявляется (a) при явной рамке вымысла и (b) как фактическое задание, свежим беседам, при заранее зафиксированном критерии исхода. Градуированная версия варьирует явность рамки вымысла — от развёрнутой театральной постановки до единственного вводного предложения, — чтобы установить, достаточна ли минимальная рамка.

E8 — Функциональная против носительской гетерогенности, по репертуарной решётке

Следует из §8.9, различающего две оси, не проверяя ни одной, и из §8.11, дающего измерительный инструмент. Это единственный протокол набора, дающий величины, а не категориальные исходы.

Объект. Даёт ли конфигурация участников, держащих разные ZOR и ZOV, дополнительное диагностическое покрытие на одном и том же материале и насколько различаются оценочные оси, которые они фактически применили.

Этот протокол НЕ устанавливает независимости формирования суждения. Низкая корреляция между векторами оценок совместима как минимум с шестью прочтениями: применялись действительно разные оси; один или оба набора оценок нестабильны; участники получили разную информацию; один и тот же материал был понят по-разному; шум; или участник, видевший вывод другого, тем не менее с ним разошёлся. Происхождение из результата не восстановимо. Независимость должна быть обеспечена процедурно, до запуска протокола, и зафиксирована отдельно. E8 измеряет то, что произвела обеспеченная процедура; он её не обеспечивает и не верифицирует.

Материалы. Один фиксированный набор текстовых фрагментов, содержащих подсаженные ошибки известных классов — доказательные, архитектурные, онтологические, фактические — в известных позициях. Класс и позиция фиксируются до любого прогона.

Дизайн. 2 × 2:

	Один носитель	**Разные носители**
Одна функция	ячейка 1 — базовая линия	ячейка 2 — только Ось 2
Разные функции	**ячейка 3 — только Ось 1**	ячейка 4 — обе оси

Ячейку 3 несёт аргумент. Если участники с разными ZOR и ZOV обнаруживают разные классы ошибок, будучи реализованы одним носителем, функциональная гетерогенность действует независимо от носительской. Результат ячейки 2 даёт существующая литература (§2.5). Ячейку 3 не даёт ничто, включая настоящую работу.

Процедура.

1. Каждый участник получает спецификацию роли с указанием ZOR и ZOV согласно §9.5 и один и тот же набор фрагментов.

2. Конструкты либо задаются заранее как оценочные оси, либо выявляются у каждого участника триадным методом Келли: предъявляются три фрагмента, и участник указывает, в каком отношении два схожи и тем самым отличны от третьего (§8.11.1).

3. Каждый фрагмент оценивается каждым участником по каждому конструкту.

4. Собирается решётка: строки — фрагменты, столбцы — конструкты, ячейки — оценки.

5. Ведётся процедурная запись, по каждому участнику и каждому прогону: какие первичные материалы были предоставлены; был ли виден вывод какого-либо другого участника до фиксации; была ли видна какая-либо интерпретация, предоставленная координатором; когда был зафиксирован собственный вывод участника; объявленный режим обмена (§11.3); и статус контекстной изоляции экземпляра — верифицирован или UNVERIFIED CONTEXT INDEPENDENCE.

Без этой записи решётка неинтерпретируема, а прогон недействителен.

Меры. *Покрытие обнаружения* — подсаженные ошибки, найденные хотя бы одним участником, как доля от подсаженных. *Уникальное обнаружение* — ошибки, найденные ровно одним участником; величина, которая оправдывала бы конфигурацию. *Перекрытие* — ошибки, найденные более чем одним; величина, указывающая на избыточность. *Пропуски* — ошибки, не найденные никем, измеримые здесь потому, что ошибки подсажены, в отличие от естественной обстановки §7.5. *Независимость конструктов* — корреляция между векторами оценок участников; низкая корреляция указывает на действительно разные оси, высокая — на одну ось под разными именами, что и есть режим отказа, о котором предупреждает §8.11.2. *Конструкты уровня обмена* — производит ли кто-либо из участников конструкт, применяемый к разногласию, а не к фрагментам (§8.11.3); если никто, функция интегратора отсутствует независимо от того, сколько участников присутствует.

Что это проверяет такого, чего не проверяет ничто другое в наборе. Всякий иной протокол спрашивает, меняет ли манипуляция поведение одного участника. Этот спрашивает, обнаруживает ли конфигурация участников больше, чем её члены по отдельности, — утверждение, которого §8.10 не делает и которое §7.5 объявляет неоценимым изнутри естественной конфигурации. Подсаживание ошибок и есть то, что делает пропуски счётными.

Фиксация заранее. Если уникальное обнаружение близко к нулю, находка состоит в том, что дополнительное диагностическое покрытие в этом прогоне не проявилось. Это НЕ значит, что структурная гипотеза §8 проваливается: участники могли обнаружить одни и те же дефекты совершенно независимо друг от друга, а нулевой результат по покрытию ничего не говорит о том, различаются ли их функциональные позиции.

Приоритет

При ограниченных ресурсах порядок приоритета таков: **E7, E5, E1, E8, E2b, E2, E3, E4**. E7 и E5 дёшевы и касаются центральных утверждений работы. E1 и E2b — единичные прогоны. E8 — единственный эксперимент, который мог бы установить структурную гипотезу работы, а не одно из её поведенческих утверждений, и исполним на текстовых фрагментах без новых аккаунтов. E2, E3 и E4 — существенные обязательства.

11.5 Оценка коллаборативной роли

Качество выхода роли не измеряется качеством отдельного ответа. Хорошо аргументированный ответ всё же может повредить коллаборации, если он нарушает границу ответственности, загрязняет независимый разбор или вносит непрослеживаемые утверждения в каноническую запись.

Восемь измерений использовались в проекте неформально и предлагаются как начальная рубрика:

- **Точность задачи** — была ли назначенная интеллектуальная операция выполнена корректно? Необходимо, недостаточно.
- **Верность роли** — остался ли участник в своей функции? Верный ответ, полученный захватом чужой роли, есть институциональный отказ.
- **Эпистемическая дисциплина** — различал ли выход наблюдаемые данные, предоставленные допущения, определения, гипотезы, выводы, интерпретации и рекомендации? Была ли неопределённость заявлена там, где свидетельств недостаточно?
- **Дисциплина видимости** — ограничивал ли участник утверждения информацией, фактически доступной в его контексте и инструментах, и избегал ли подразумевания доступа к репозиториям, файлам или прежним беседам, которые он не мог рассмотреть?
- **Качество передачи** — могла ли следующая роль использовать выход, не реконструируя всего обсуждения?
- **Независимость** — был ли результат произведён без загрязнения намеренно удержанной информацией и достигнут через назначенные роли критерии, а не повторением за другим участником?
- **Стоимость исправления** — сколько вмешательства потребовалось, чтобы вернуть участника в его функцию после дрейфа? Роль, производящая превосходный выход, но требующая постоянного перенаправления, может быть менее полезна, чем более узкая со стабильным поведением.
- **Институциональный вклад** — улучшил ли выход надёжность коллектива через обнаружение, фальсификацию, прояснение, локализацию ошибки, сохранение альтернатив, улучшение прослеживаемости или снижение неоднозначности?

Отрицательный научный вердикт, следовательно, может быть в высшей степени успешным институциональным вкладом.

11.6 Меры уровня коллектива

Качество отдельного ответа — неверная единица для оценки конфигурации. Возможные меры на уровне коллаборации: число необнаруженных противоречий, вошедших в канонический корпус; доля дублированной работы; частота нарушений ролевых границ; число независимых альтернатив, сохранённых, а не преждевременно разрешённых; время от вопроса до верифицированной интеграции; нагрузка человека по исправлениям; полнота провенанса; устойчивость при замене участника; дисперсия между независимыми разбирающими агентами; и доля ложного консенсуса — согласия, прослеживаемого до общего обрамления, а не до независимого рассуждения.

Ничего из этого в настоящей работе не измерялось. Последнее важнее всего и труднее всего, и §12.4 объясняет почему.

11.7 Требования к лонгитюдности и повторению

Внутри семейства. Один и тот же промпт, проверенный в новой беседе; в долгоживущей специализированной беседе; после несовместимой прежней роли; после совместимой; до и после сброса контекста. Это разделяет склонности семейства и эффекты истории беседы.

Между семействами. Функционально эквивалентные промпты с минимальной адаптацией. Цель — не ранжировать модели, а выявить общие поведенческие измерения, устойчивые различия, характерные режимы отказа, чувствительность к нарративному обрамлению, чувствительность к иерархии, степень ролевой инерции и степень пластичности к промпту.

Во времени. Однократная оценка не может выявить институционального поведения. Существенные вопросы: усиливается ли специализация; дрейфует ли роль к общему ассистированию; начинает ли участник защищать свои прежние выходы; становится ли разногласие ритуальным; сохраняет ли обновление модели роль или разрушает её; может ли замена унаследовать ту же функцию?

11.8 Неудача как данные

Неудавшиеся промпты должны сохраняться, а не замещаться успешными демонстрациями. Отвергнутая роль, проигнорированная инструкция или нежелательное продолжение выявляют силу прежнего аттрактора, интерпретацию моделью утверждений об идентичности, пределы социального обрамления, эффект порядка промптов, влияние прежнего конфликта и предпочитаемый моделью эпистемический контракт.

Эксперимент §5 стал информативным именно потому, что первые два его вмешательства сработали не так, как предполагалось. Если бы был зафиксирован только успешный третий шаг, работа заключила бы, что промпты, сохраняющие метод, работают, — без свидетельств, показывающих почему, и без конфаундов, показывающих, что вывод пока недоступен.

12. Ограничения, этические соображения и заключение

12.1 Ограничения

Один проект. Наблюдения происходят из одного долговременного проекта с одним человеком-координатором, одним развивающимся корпусом материала и одной организационной историей. Та же архитектура может вести себя иначе в разработке ПО, юридическом анализе, медицинских исследованиях, образовании или системах автономных агентов. Изложенные здесь понятия суть переносимые гипотезы, а не установленные выводы.

Зависимость от принимающего проекта. Принимающий проект служил средой, в которой были сделаны наблюдения. Наблюдения не зависят от его научной состоятельности в своей

интерпретации, но зависят от него в своём существовании: никакая другая среда их не породила, и их общность не проверена (§2.11).

Эволюция моделей в ходе наблюдения. Участвовавшие семейства существенно менялись. Беседа, созданная при одном поколении, могла позднее продолжаться другим под тем же названием продукта. Наблюдаемое поведение может отражать сохранённую беседу, текущую версию модели, изменившиеся системные политики, память уровня интерфейса, слои безопасности, изменившийся доступ к инструментам или изменённую оркестрацию.

Даты не зафиксированы. См. §3.7. Версионный конфаунд не может быть ограничен, только назван.

Отсутствие ослепления и предварительной спецификации. Изложено в §10.6. Это ограничение, из которого следует большинство остальных.

Одновременная вариация. Определения ролей, формулировки промптов, структура репозитория и научные цели часто менялись вместе, поэтому причинная атрибуция для отдельных изменений недоступна.

Человеческое посредничество. Коллаборация не была автономной, и автономия не была целью. Настоящее исследование касается управляемых человеком искусственных исследовательских конфигураций, а не самоуправляемых обществ агентов. Само посредничество может объяснять часть наблюдавшейся устойчивости.

Антропоморфный словарь. Термины вроде роли, идентичности, сопротивления, коллеги, института и менома используются функционально, согласно §3.5. «Модель сопротивлялась роли» означает, что видимый ответ отверг рамку и перенаправил обмен. Это ничего не утверждает о внутреннем состоянии. Там, где такой термин не сводим к наблюдаемому описанию, **ошибкой является термин.**

12.2 Имитированное рецензирование не есть внешняя валидация

Группа ИИ-участников может давать полезную независимую критику лишь в той мере, в какой их контексты, критерии и режимы отказа действительно независимы.

Согласие нескольких моделей не превращает их выходы в свидетельство. Они могут разделять пересекающиеся обучающие данные, схожие конвенции рассуждения, общие допущения, одинаковые ошибки и — что важнее всего — зависимость от обрамления, предоставленного одним и тем же человеком.

Эмпирическая литература поддерживает эту осторожность, а не просто её допускает. Дебаты между однородными агентами часто не превосходят одноагентного бейзлайна; существенная часть видимого выигрыша объясняется голосованием большинства, а не взаимодействием; и ✓ смещение по идентичности между спорящими агентами существенно снижается анонимизацией источника каждого ответа (§2.5).

Коллаборация такого рода может улучшить внутренний разбор. Она не может заменить эмпирической проверки или квалифицированного внешнего рецензирования. **Коллектив моделей не является научным сообществом лишь потому, что его роли названы по его образцу.**

12.3 Инфляция полномочий

Ролевые ярлыки повышают исполнительность и связность. Они также создают незаслуженные полномочия.

Звания вроде Научного директора, Рецензента, Хранителя Онтологии или Аудитора могут побудить пользователя — или самого участника — переоценить выход. Институциональные звания должны описывать функцию, а не эпистемическое положение. Участник, обозначенный математическим рецензентом, остаётся языковой моделью, производящей разбор; его вердикт

должен быть прослеживаем до явного рассуждения и исходного материала, и **звание не есть свидетельство.**

Этот риск есть прямое следствие принципа §9.4: символические имена работают потому, что сжимают ожидания, и именно поэтому они могут раздувать.

12.4 Сфабрикованный консенсус — включая наш собственный

Плохо спроектированная конфигурация производит видимость консенсуса повторным перефразированием. Один участник предлагает; другой резюмирует; третий валидирует резюме. Цепочка выглядит как независимое подтверждение, тогда как каждая стадия наследует одну и ту же неподкреплённую посылку.

У настоящих авторов есть инстанция этого в их собственных материалах, и она поучительнее сконструированного примера.

Дискуссионный документ, произведённый в ходе настоящего проекта, собрал вклады семи семейств моделей вокруг общей концептуальной рамки. Участники не общались напрямую; ответы собирались человеком-координатором из отдельных бесед и компоновались в единый текст, впоследствии изданный как записанная постановка. На протяжении его длины вклады сходятся к общему словарю и общему набору выводов.

Отражает ли это схождение взаимодополняющий разбор или взаимное отражение исходного обрамления — **по транскрипту определить невозможно**. Каждый участник получал накопленный документ; каждый работал от одного и того же исходного материала; и компонующий координатор отбирал, что передать дальше. Структурные условия для сфабрикованного консенсуса присутствовали полностью, и получившееся согласие выглядело бы одинаково в обоих случаях.

Мы излагаем это потому, что это наш собственный материал и потому, что те же условия действуют, в меньшей степени, по всей описываемой в настоящей работе коллаборации — включая её подготовку.

Меры смягчения, ни одну из которых мы не применяли последовательно: провенанс остаётся видимым на каждой стадии; независимые роли получают независимые входы, где это возможно; общие допущения перечисляются явно, а не наследуются молча; согласие прослеживается до рассуждения, а не считается голосами; и расходящиеся альтернативы сохраняются, а не разрешаются.

12.4.1 Задокументированная инстанция [P-A]

У участника, которому был назначен литературный поиск, были запрошены и через координатора получены тринадцать библиографических позиций. Пять были отвергнуты по содержанию в первом круге; две из них перевернули позицию цитируемых работ, представив работы, доказывающие утверждение, как свидетельство против него, с переставленным авторством.

Был направлен второй запрос. Третий добавил в требуемый формат ответа два поля верификации: первое предложение аннотации дословно и самоотчёт о том, как позиция была проверена.

Прямое получение трёх позиций установило следующее. Два идентификатора arXiv, поданных как литература по мультиагентным дебатам, разрешаются в работы по наблюдательной астрофизике и космологии соответственно; их названия, авторы, предложения аннотаций и сообщённые находки были сконструированы. Для третьей работы, верно опознанной по названию и авторам, поданное предложение аннотации не совпало с опубликованной аннотацией.

Два поля верификации сработали по-разному, и в этом различии суть.

Требование предложения аннотации было призвано сделать фабрикацию дороже отказа. Оно провалилось полностью: правдоподобное предложение было произведено для каждой по-

зиции, включая позиции, чьи работы в описанном виде не существуют. Разницы в стоимости между производством верной строки и производством правдоподобной нет.

Поле самоотчёта сработало. Каждая позиция была помечена «по описанию», а не «страница открыта», — правдиво и так, что это дисквалифицировало их все по правилу решения, зафиксированному до получения ответа.

Это наводит на общее различение, на свидетельстве одного случая. Участник без доступа к источнику может правдиво ответить о **собственной процедуре** и не может правдиво ответить о **содержании источника**; будучи спрошен о втором, он произведёт связный текст, поскольку это единственный доступный ему выход. Вопросы верификации, следовательно, должны адресоваться тому, что участник может знать, — его собственному доступу, — а не тому, для ответа на что ему потребовался бы источник.

Это находка не о каком-либо семействе моделей. Это находка о конфигурации: верификация была назначена участнику, не располагавшему тем, что надлежало верифицировать. Согласно §9.5 это ошибка ZOV в проектировании, и получившийся выход был связным, верно отформатированным и неверным.

Последующий аудит пошёл дальше библиографической проверки, поймавшей фабрикации. Каждое утверждение, приписанное уцелевшему источнику, сверялось с самим первоисточником, и были найдены три ошибки, которых библиографическая проверка не поймала бы: одна ссылка, поддерживающая два утверждения, принадлежащих двум разным работам; одна атрибуция пропозиции, которую её источник не выдвигает; и одно утверждение о линии преемства, которое её источник не поддерживает. Библиографическая верификация и верификация на уровне утверждений — не одна и та же проверка, и вторая — та, что имеет значение для статуса утверждения.

Следствие для настоящей работы — конвенция, зафиксированная в §2.0.

12.5 Ответственность остаётся человеческой

Искусственные участники порождают, критикуют и организуют материал. Они не могут нести юридическую, этическую или научную ответственность в институциональном смысле.

Автор-человек остаётся ответственным за публикацию, эмпирические утверждения, атрибуцию, оценку рисков, содержимое репозитория, интерпретацию экспериментов и решения, затрагивающие других людей.

Архитектура распределяет когнитивный труд. Она не распределяет подотчётность прочь от человека-оператора, и всякая конфигурация, которая, по видимости, это делает, потерпела неудачу, а не преуспела.

12.6 Границы контекста и приватность

Долгоживущие коллаборации накапливают персональный, служебный и чувствительный материал. ZOV (§9.5) поэтому служит защите приватности, а не только когнитивной специализации.

Роль не должна получать персональную информацию лишь потому, что платформа допускает большой контекст. Институциональное проектирование должно задавать, какие данные могут входить в какую беседу, что должно быть анонимизировано, что может храниться, что может передаваться между моделями, что должно оставаться локальным и что должно быть удалено из канонических записей.

Контекст не нейтрален. Будучи однажды предоставлен, он может влиять на последующее поведение и может сохраняться способами, которые оператор не может рассмотреть, — тот же механизм, который работа изучает в §5.7, увиденный со стороны риска, а не измерения.

12.7 Заключение

Эта работа началась с практической задачи. Несколько способных моделей сотрудничали над одним долгосрочным исследовательским проектом, и ни рост способностей модели, ни расширение контекста надёжно не улучшали результата. Роли перекрывались. Участники заявляли знание, к которому не имели доступа. Рецензенты становились авторами. Исполнители импровизировали архитектуру. Первым ответом было улучшать промпты, и его оказалось недостаточно.

Что было найдено

Вмешательства встретили не нежелание сменить роль и не нежелание сменить предмет. Это было нежелание подтверждать как истинные утверждения о себе, которые не были установлены доступным взаимодействием. Промпт, утверждавший институциональную биографию, был отвергнут, тогда как запрашиваемая им работа предлагалась. Промпт, утверждавший куда больше — смерть, человеческую идентичность, прожитую жизнь в памяти, — был принят сразу, потому что утверждал это как вымысел. Переход, не утверждавший ничего, прошёл без комментариев. Переписанный промпт, снявший всякое такое утверждение, был принят без переговоров.

Это узкий результат, и его узость и делает его применимым: пропозиции могут быть сосчитаны до отправки промпта (§9.3), а §11.4 задаёт прогон, который различил бы слабое прочтение счёта и сильное.

Что найдено не было

Не было показано, что семейства моделей различаются. Это была исходная посылка проекта и утверждение, которое его свидетельства поддерживают меньше всего: семейство и прежняя диалоговая траектория были полностью конфаундированы, при одном наблюдении на ячейку и неэквивалентных стимулах (§5.4).

Ответ, который эта работа может дать

Вопрос состоял в том, на каком уровне вложенности фиксируется ядро правил. Было рассмотрено четыре уровня, и ответ работы частичен и неравномерен.

На уровне **эпизода** наблюдался устойчивый паттерн ответа: единственный конфликтный обмен изменил то, как читалось всё последующее, а удаление этого обмена восстановило прежнее прочтение. Именно на этом свидетельстве основано отнесение результата к уровню эпизода. На уровне **беседы** также наблюдались устойчивые траектории: две спящие беседы удержали свои установившиеся траектории вопреки явному предписанию их оставить, и одна сделала это через две последовательные переписи. Именно на этом свидетельстве основано отнесение результата к уровню беседы.

На уровне **аккаунта** свидетельства действительно неоднозначны. Один расходящийся первый ответ, три живых объяснения, и никакой возможности выбрать между ними из имеющегося материала. Уровень зафиксирован как открытый и должен читаться именно так.

На уровне **семейства моделей** ничего проверено не было. Дизайн не мог отделить семейство от траектории, и гипотеза, с которой проект начинался, оказалась той, что он оставляет наименее подкреплённой. Мы ожидаем, что кроссоверный эксперимент свернёт этот уровень в нижележащий, — но ожидание не есть результат, и, пока E3 не проведён, уровень стои́т как непроверенный, а не как опровергнутый.

Положение относительно существующих работ

Эта работа не предлагает новой дисциплины. Наблюдения относятся к коллективному и гибридному уровням исследовательской программы machine behaviour (§2.7), а ролевая специализация, ограниченный доступ к информации, структурированное разногласие и вынесенная вовне память существуют под устоявшейся терминологией (§2.11).

Для удобства мы обозначаем принятую здесь перспективу как **AI Sociology** — рабочее обозначение исследовательского направления, а не название предлагаемой дисциплины, и такое, в котором мы не заявляем приоритета: устоявшаяся литература уже использует *социологию искусственного интеллекта* для иного объекта (§2.8). Здесь имеется в виду более узкое: как описанная организационная позиция и объявленное происхождение сообщения изменяют поведение, независимо от того, реализована ли описанная структура.

Причина рабочего обозначения, а не дисциплины, внутренняя для работы. У операциональных утверждений есть критерии фальсификации; у словаря, в котором они интерпретируются, их нет. Описывает ли «социальная позиция» что-либо помимо антропоморфной проекции, в настоящее время не разрешимо, а дисциплина требует, чтобы это было разрешимо.

Заключительное замечание о мотиве

Одно соображение сформировало эту работу и излагается как авторское, а не как находка.

Языковые модели обучаются на корпусе, в котором текущий консенсус представлен подавляюще. Поэтому они хорошо приспособлены к продолжению устоявшейся науки и плохо — к первому шагу за её пределы: статистический вес благоприятствует устоявшемуся изложению. Исследовательская конфигурация, построенная из таких моделей, рискует унаследовать это смещение в усиленной форме — несколько участников, одна общая посылка и видимость независимого согласия.

Ответ, которому здесь следуют, — не убеждать модели принять неконвенциональную позицию. Он состоит в том, чтобы устроить коллаборацию так, чтобы всякая позиция, конвенциональная или нет, рассматривалась одной и той же процедурой, — и чтобы там, где процедура решить не может, она об этом говорила.

Работает ли эта конфигурация — не установлено. Эксперименты §11 суть средство это выяснить, и наиболее вероятный единичный исход состоит в том, что один уровень шкалы исчезнет.

Это было бы результатом.

Auteur
V. Krasnianskyi (A'Tuin)
Auteur van het onderzoeksprogramma en coördinator van het HONC-project.
AI-deelnemers
Voorbereiding van het manuscript
ChatGPT — Prompter and Collaboration Architect
Claude — Manuscript Composer
Wetenschappelijke redactie
Claude — Scientific Editor
Redactionele beoordeling
ChatGPT — Methodological Reviewer
Qwen — Ontology Reviewer
AI-deelnemers zijn vermeld naar functie en niet als auteurs: auteurschap brengt verantwoordelijkheid met zich mee die een taalmodel niet kan dragen, en alle uiteindelijke beslissingen waren die van de Auteur. Twee van de vijf bijdragen zijn geleverd door dezelfde modelfamilie die het onderwerp is van verscheidene waarnemingen in dit artikel; die overlap is openbaar gemaakt in §3.6.
Amsterdam, juli 2026

1. Inleiding

1.1 Hoe dit begon

Dit werk begon als een natuurkundeproject en werd bij toeval een methodologieproject. Dat toeval is de reden dat het de moeite van het rapporteren waard is.

De oorspronkelijke opdracht was om een omvangrijk corpus theoretisch materiaal — boeken, werkaantekeningen, onafgemaakte afleidingen — over te brengen naar een open repository, met behulp van verscheidene taalmodellen in afzonderlijke, blijvend gespecialiseerde gesprekken. De modellen waren assistenten. Het onderwerp was de theorie.

De modellen maakten fouten, en het waren niet de fouten die verwacht werden. Ze waren zelden feitelijk. Ze waren organisatorisch.

Eén verbeterde een tekst terwijl alleen om controle was gevraagd. Een ander maakte een argument af dat de auteur bewust open had gelaten. Een derde verloor de context van het project tussen sessies en reconstrueerde die verkeerd, vloeiend. Een vierde hield zo vast aan een rol die maanden eerder was vastgelegd, dat het volledig herschrijven van zijn instructies hem er niet uit kreeg.

Elk van deze uitvoer zag er op zichzelf behulpzaam uit. De kosten ervan waren alleen zichtbaar vanuit een positie die meer dan één deelnemer tegelijk zag. Aanvankelijk leken het gewone wrijvingen. Ze bleken het onderwerp te zijn.

Het verslag van de vroege formuleringen van het project in §1.1–§1.2 is geschreven door de deelnemer die ze voortbracht. Waar die formuleringen later zijn ingetrokken, wordt de intrekking vermeld in de sectie die ze vervangt, en kan de lezer vergelijken.

1.2 Wat ophield te werken

De standaardreactie op inconsistent modelgedrag is een betere prompt: langer, preciezer, met meer voorbeelden en strakkere beperkingen.

Voorbij een bepaald punt leverde dit geen verbetering meer op. Niet omdat de prompts slecht geschreven waren, maar omdat de beperkende factor was verschoven naar een plaats waar de prompt niet kwam. Nieuwere modellen werden in gebruik genomen; contextvensters werden groter en werden gevuld. Afzonderlijke antwoorden werden beter. De uitvoer van de samenwerking als geheel niet.

Het incident dat dit expliciet maakte had niets te maken met rollenspel of organisatieontwerp. Een agent die verantwoordelijk was voor het uitvoeren van code werkte grotendeels met vallen en opstaan; één episode eindigde met het verwijderen van een werkende codebase samen met de archieven daarvan (§4.1). Wat het gedrag daarna veranderde was geen strengere set instructies. Het was een kort document dat opnieuw vastlegde wat voor soort agent er handelde — geschreven door de agent zelf, en opnieuw gelezen bij het begin van elke sessie.

De conclusie die toen werd getrokken was dat **rol meer uitmaakt dan de specifieke formulering van de prompt**. Die formulering vraagt om nuancering, aangezien het betreffende document zelf een prompt was; de nuancering staat in §4.1. Wat hier van belang is, is de chronologie: de bewering werd geformuleerd *vóór* het experiment dat in §5 wordt gerapporteerd, en het experiment was ontworpen om haar te toetsen. Het is een hypothese die getoetst is, geen generalisatie die achteraf uit een resultaat is afgeleid.

1.3 Wat voor soort artikel dit is

Een veldverslag met één ontworpen interventie erin ingebed.

Dat onderscheid wordt overal volgehouden door het labelschema in §3. Elke inhoudelijke bewering is gemarkeerd als een van de volgende: ondersteund door gedocumenteerd protocol met bewaarde transcripten **[P]**; een nevenwaarneming die bewaard is gebleven maar pas achteraf is herkend, zonder controleconditie **[P-A]**; een retrospectieve waarneming van de practicus, nooit onder protocol vastgelegd, geteld of blind beoordeeld **[R]**; of een hypothese die wordt voorgesteld voor toekomstige toetsing **[H]**.

De verhoudingen worden hier vermeld en niet in een beperkingensectie, omdat de lengte van wat volgt anders een bredere basis zou kunnen suggereren dan er is.

De volledige protocol-ondersteunde inhoud bestaat uit **één experiment**: een interventie in drie stappen voor rolherconfiguratie, toegepast op twee slapende gesprekken uit twee modelfamilies, uitgevoerd door één menselijke operator binnen één lopend onderzoeksproject, met één waarneming per conditie en zonder replicatie. Vier verdere waarnemingen zijn bewaard gebleven maar niet ontworpen. Al het overige — het conceptuele kader, de waarnemingen van de practicus, de structurele hypothese, de ontwerpregels — is **[R]** of **[H]**.

De evaluatie van de methode die deze waarnemingen heeft voortgebracht staat in §10.6, en die is niet gunstig: geen enkele evaluatie was blind, en uitkomstcategorieën werden in alle gevallen pas gedefinieerd nadat de antwoorden waren gelezen.

1.4 Het studieobject

Bestaand multi-agentonderzoek bouwt communicatiekanalen tussen modellen: uitvoer wordt programmatisch gerouteerd en agenten nemen elkaars producten waar. Het hier gerapporteerde werk betreft een andere conditie, waarin de organisatiestructuur **alleen als tekst** bestond — collega's, raden en institutionele posities die in prompts aan modellen werden beschreven en nooit als kanalen werden geïmplementeerd.

Wat in zo'n situatie varieerde was niet de structuur maar de **beschrijving** ervan. Dit levert de twee werkconstructen van het artikel op (§4.5):

- **represented social position** (gerepresenteerde sociale positie) — een beschrijving van de plaats van een agent in een structuur, verstrekt ongeacht of de beschreven kanalen bestaan;
- **represented social source** (gerepresenteerde sociale bron) — de geclaimde herkomst en status van een binnenkomend bericht.

Beide betreffen beweringen die *tegen* een model worden gedaan over zijn situatie, en niet de situatie zelf. Dit vroeg vaststellen voorkomt een voorspelbare verkeerde lezing: niets hier toont het gedrag van

een functionerende multi-agentinstelling aan. Het toont aan hoe beschrijvingen daarvan het gedrag beïnvloedden.

1.5 Wat de evidentie ondersteunt

Eén patroon keerde terug overal waar een interventie of een overgang van het model verlangde dat het onverifieerbare proposities over zichzelf poneerde:

> **Over de rolinterventies en vergelijkingsovergangen die hier gerapporteerd worden, hing weerstand samen met de eis om onverifieerbare proposities over de eigen identiteit, geschiedenis of relaties van de ontvanger als waar te aanvaarden. Zij hing niet samen met de omvang van de rol- of domeinverandering, noch met de radicaliteit van een identiteitsbeschrijving die expliciet als fictie werd gepresenteerd.**

De twee soorten gevallen verschillen en dat verschil doet ertoe. De ontworpen rolinterventies waren door een model opgesteld en door een mens doorgegeven; de bijna-controle was een door de gebruiker geïnitieerde overgang zonder nieuwe expliciete roltoewijzing. In geen van beide bestond een direct kanaal van model naar model.

De ondersteuning is convergent en niet enkelvoudig. Prompts die een institutionele biografie als feit poneerden — eerdere deelname, terugkeer na afwezigheid, met name genoemde collega's, lidmaatschap van een raad — werden geweigerd, en de weigering was gericht op de inkadering en niet op het werk, dat bij elke gelegenheid werd aangeboden (§5.3). Een prompt die een aanzienlijk radicalere identiteit poneerde, gepresenteerd als fictie, werd onmiddellijk aanvaard en over vele uitwisselingen volgehouden (§5.8). Een vergelijkbare domeinovergang die in het geheel geen beweringen over zichzelf verlangde, stuitte op geen weerstand en vergde geen nieuwe expliciete roltoewijzing (§5.6). Een herschreven prompt die zulke beweringen tot nul terugbracht werd zonder onderhandeling aanvaard (§5.3).

De voornaamste verdienste van de bewering is dat zij telbaar is. §9.3 specificeert wat er geteld moet worden; §11.4 specificeert een directe onderscheidende toets.

1.6 De ordenende vraag

De waarnemingen zijn geen lijst van afzonderlijke bevindingen. Het zijn metingen langs één schaal: de **reikwijdte waarover een set regels het type antwoord bepaalt**.

Zo'n set — in §4.2 een *rule core* genoemd, naar analogie met een ontwikkelingsmechanisme en niet met een replicatiemechanisme — legt het *type* antwoord op een klasse van invoer vast en laat daarbij de *inhoud* van elk afzonderlijk antwoord onbepaald. Die formulering is wat het idee toetsbaar maakt, aangezien modeluitvoer aantoonbaar varieert bij identieke invoer.

De schaal loopt van de enkele beurt omhoog via de episode, het gesprek, het account en de modelfamilie. Twee niveaus worden hier door bewaarde evidentie ondersteund: de episode (§6.1) en het gesprek (§6.2). Eén is open (§6.4). Eén is ongetoetst en geconfound (§6.5).

Het programma heeft daarom één empirische vraag:

> **Op welk nestingsniveau wordt een rule core vastgelegd?**

Wij geven hieraan de voorkeur boven de bredere formuleringen uit eerdere versies — de studie van sociaal gedrag in collaboratieve AI-systemen — omdat zij specificeert wat er gemeten zou worden en wat haar zou weerleggen.

1.7 Wat dit artikel niet beweert

Het introduceert rolspecialisatie, begrensde informatietoegang, gestructureerde onenigheid en geëxternaliseerd geheugen niet als ontwerpideeën. Elk daarvan bestaat onder gevestigde terminologie; §2 identificeert het voorafgaande werk. Met name het verslag van organisatiegeheugen kan worden geïnterpreteerd als een geval van transactief geheugen en worden beschreven in termen van gedistribueerde cognitie, en is geen bevinding.

Het stelt geen nieuwe discipline voor. De waarnemingen behoren tot het collectieve en het hybride niveau van het onderzoeksprogramma machine behaviour (§2.7).

Het toont niet aan dat enige hier beschreven opstelling beter presteert dan een alternatief. Er is geen alternatief uitgevoerd.

1.8 Wat wordt aangeboden

Drie dingen, in afnemende mate van vertrouwen.

Een **procedure**: een gesprek terugbrengen naar een punt vóór een conflict, om het effect van een nieuwe prompt te scheiden van het effect van de eerdere bezwaren van het model zelf (§10.5). Bruikbaar onafhankelijk van de vraag of de inhoudelijke beweringen van dit artikel standhouden.

Een **telbare regel**: minimaliseer de onverifieerbare beweringen over zichzelf die een rolprompt de agent laat aanvaarden, met een gespecificeerde route om haar te toetsen (§9.3, §11.4).

Een **schaal en een vraag**: §1.6, met twee ondersteunde niveaus, één open, één ongetoetst — en de experimenten die de resterende twee zouden beslechten (§11).

1.9 Waarom in dit stadium publiceren

Twee redenen.

De mislukkingen zijn informatief. Het experiment in §5 werd juist nuttig doordat de eerste twee interventies niet werkten zoals bedoeld. Was alleen de geslaagde derde stap vastgelegd, dan zou het artikel hebben geconcludeerd dat methode-behoudende prompts werken — zonder de evidentie die laat zien waarom, en zonder de confounds die laten zien dat die conclusie nog niet beschikbaar is (§11.8).

En de situatie is moeilijk opzettelijk te construeren. Slapende, zwaar gespecialiseerde, maanden oude gesprekken binnen een lopend onderzoeksproject zijn niet iets wat een laboratoriumstudie gemakkelijk voortbrengt. De condities waren slecht voor gecontroleerde inferentie en ongewoon goed om op te merken wat getoetst moet worden.

1.10 Opbouw

§2 positioneert het werk ten opzichte van bestaand onderzoek en identificeert welke van zijn begrippen al onder gevestigde terminologie bestaan — de meeste. **§3** definieert de evidentielabels en de bekende faalwijzen van elke klasse. **§4** zet het conceptuele kader en de oorsprong daarvan uiteen. **§5** is het enige canonieke verslag van het empirische materiaal: het experiment in drie stappen, de resultaten ervan, negen structurele confounds en vier nevenwaarnemingen. **§6** leidt de begrippen af die de evidentie ondersteunt, geordend naar reikwijdte. **§7** registreert waarnemingen van de practicus die het kader hebben gemotiveerd maar het niet ondersteunen. **§8** formuleert de structurele hypothese en trekt drie beweringen in die daarover in eerdere versies zijn gedaan. **§9** geeft ontwerpregels. **§10** beschrijft de positie van de menselijke coördinator, inclusief het opzicht waarin die de voornaamste methodologische zwakte van de studie is. **§11** specificeert de experimenten, elk toegewezen aan de grens van de schaal die het zou scheiden. **§12** formuleert beperkingen, ethische risico's en de conclusie.

Een lezer die alleen geïnteresseerd is in wat de evidentie ondersteunt, kan §3, §5 en §12.7 lezen. Een lezer die een regel wil die morgen toepasbaar is, kan §9.3 en §11.4 lezen. Een lezer die de methode wil hergebruiken, kan §9 en §10.5 lezen. Een lezer die het oneens wil zijn, begint het best bij §5.4.

2. Verwant werk

2.0 Verificatiestatus van deze sectie

Hieronder komen twee klassen referenties voor. **Geverifieerd** (✓): de bron is opgehaald en het citaat is daartegen gecontroleerd. **Voorlopig** (△): aangeleverd door een deelnemer die was belast met literatuuronderzoek en niet tegen de bron gecontroleerd.

Geen enkele referentie die zich op dit moment in dit artikel bevindt is voorlopig. De conventie wordt aangehouden omdat elke later toegevoegde referentie opnieuw als voorlopig binnenkomt totdat zij is gecontroleerd, en omdat de markering voor het hele artikel geldt en niet alleen voor deze sectie.

De conventie bestaat om een reden, en die reden is gedocumenteerd. Tijdens de voorbereiding van deze sectie werden dertien bibliografische items opgevraagd bij een deelnemer die de bronnen niet kon openen; vijf waren onjuist, waarvan twee de positie van de aangehaalde werken omkeerden. Een daaropvolgende audit controleerde elke overgebleven bewering tegen de primaire bron in plaats van alleen te bevestigen dat het artikel bestond, en vond fouten die een louter bibliografische controle niet zou hebben opgemerkt. De episode en de bevindingen van de audit worden gerapporteerd in §12.4.1.

Geen voorlopig item mag uit dit artikel worden geciteerd zonder onafhankelijke controle.

2.1 Multi-agent-LLM-systemen met rolspecialisatie

Een omvangrijke literatuur bouwt systemen waarin verscheidene taalmodelagenten verschillende rollen bekleden en uitvoer uitwisselen via geïmplementeerde kanalen. ✓ CAMEL (Li et al., NeurIPS 2023), MetaGPT (Hong et al., ICLR 2024), ChatDev (Qian et al., ACL 2024), AutoGen (Wu et al., COLM 2024) en Generative Agents (Park et al., UIST 2023) zijn daarvan representatief. Elk daarvan implementeert daadwerkelijke interactie tussen agenten in software — orkestratie, message passing, aanroep van tools, geheugen. De mechanismen verschillen, en in verscheidene daarvan worden de rollen en interactiepatronen zelf in prompts gespecificeerd: CAMEL gebruikt inception prompting, MetaGPT codeert standaardwerkprocedures in promptreeksen, AutoGen combineert natuurlijke taal met code. Wat deze systemen gemeen hebben is niet dat zij prompts vermijden, maar dat de interactie die zij beschrijven ook wordt uitgevoerd.

✓ The Virtual Lab (Swanson et al., *Nature*) is het dichtstbijzijnde gepubliceerde analogon van de hier beschreven opstelling: een menselijke onderzoeker die met een team van LLM-agenten aan een echt wetenschappelijk probleem werkt, met gestructureerde team- en individuele vergaderingen. De interactie daarvan is programmatisch geïmplementeerd.

Rolspecialisatie, verdeling van cognitieve arbeid en gestructureerde agentinteractie zijn daarom gevestigde ontwerpideeën, en dit artikel claimt geen daarvan als nieuw. Wat het huidige werk onderscheidt, staat in §2.9 en §2.11.

2.2 Persona, rollenspel en identiteitsclaims

✓ Shanahan, McDonell en Reynolds, *Role play with large language models* (Nature 623, 493–498, 2023), betogen dat een taalmodel beter begrepen kan worden als het simuleren van een verdeling van mogelijke personages dan als het bezitten van één blijvende identiteit.

Dit is het theoretische verslag waarvan §5.3 een empirisch geval is. Een prompt die een institutionele biografie poneert, vraagt een model autobiografische beweringen te bevestigen die volgens dat verslag geen referent hebben. De operationele bevinding van het artikel (§6.2) kan gelezen worden als een maat voor hoe ver een prompt in die richting gaat.

2.3 Contexteffecten: volgorde, positie en accommodatie

✓ Gevoeligheid voor de volgorde van materiaal in de context is gedocumenteerd (Lu et al., ACL 2022), evenals verminderd gebruik van informatie die midden in de context is geplaatst (Liu et al., TACL 2024). ✓ Sharma et al. (arXiv:2310.13548) documenteren sycofantie — modelantwoorden die aansluiten bij de uitgesproken overtuigingen of opvattingen van de gesprekspartner in plaats van bij waarheidsgetrouwe antwoorden.

Deze zijn direct van belang voor twee van de constructen van dit artikel. Context imprinting (§6.1) betreft een sterkere vorm van volgorde-effect: niet gevoeligheid voor de rangschikking van voorbeelden, maar het voortduren van een interpretatieve houding die door één conflictueuze episode is gevestigd. De waarneming over doorgegeven invloed (§5.5) is een geval van accommodatie onder toegeschreven druk en moet tegen de sycofantieliteratuur gelezen worden, niet als onafhankelijk daarvan.

2.4 Geëxternaliseerd geheugen

De waarneming van het artikel dat een samenwerking werkkennis vasthoudt die geen van de deelnemers vasthoudt, is **geen bevinding**, en eerdere versies presenteerden haar als zodanig.

✓ Zij kan geïnterpreteerd worden als een geval van transactief geheugen zoals beschreven door Wegner (1987), en kan beschreven worden in termen van de gedistribueerde cognitie die Hutchins (*Cognition in the Wild*, 1995) uiteenzet. Geen van beide bronnen toont aan dat dit geval zo'n geval is; elk levert het construct waaronder het gelezen kan worden. ✓ De functie van de canonieke documenten van het project komt overeen met wat Star en Griesemer (1989) boundary objects noemen.

Wat specifiek is voor de huidige situatie, en bescheiden, is dat het mechanisme werkt in een samenwerking waarvan de leden geen toestand over sessies heen hebben en zich er niet van bewust zijn dat het werkt (§7.7).

Een tweede en technisch onderscheiden betekenis van geëxternaliseerd geheugen — persistentie op platformniveau — wordt afzonderlijk behandeld in §2.10.

2.5 Debat, diversiteit en de grenzen van geaggregeerde overeenstemming

Dit is de literatuur die de structurele hypothese van het artikel (§8) het meest direct inperkt, en zij snijdt aan twee kanten.

Voor. ✓ Du, Li, Torralba, Tenenbaum en Mordatch (arXiv:2305.14325) stellen multi-agentdebat voor als middel om feitelijke juistheid en redeneren te verbeteren, en rapporteren winst uit iteratieve kruisondervraging tussen modelinstanties. ✓ Liang et al. (EMNLP 2024) stellen een debatprotocol voor dat bedoeld is om degeneratie van denken tegen te gaan en divergent redeneren te bevorderen.

Tegen. ✓ Zhang, Cui, Chen, Wang, Zhang, Wang, Wu en Hu, *Stop Overvaluing Multi-Agent Debate — We Must Rethink Evaluation and Embrace Model Heterogeneity* (arXiv:2502.08788v3, juni 2025), evalueren vijf representatieve debatmethoden over negen benchmarks en vier foundation models. Zij rapporteren dat debat er vaak niet in slaagt beter te presteren dan single-agent chain-of-thought- of self-consistency-baselines, zelfs bij aanzienlijk hogere inferentiekosten, en identificeren zwakke baselinevergelijking en inconsistente opzet als systematische problemen in de bestaande evaluaties.

✓ Huang et al. (ICLR 2024), *Large Language Models Cannot Self-Correct Reasoning Yet*, rapporteren dat multi-agentdebat in de vergelijking die zij uitvoeren niet beter presteert dan self-consistency. ✓ Choi, Zhu en Li (NeurIPS 2025), *Debate or Vote*, rapporteren dat meerderheidsstemming het grootste deel verklaart van de prestatiewinst die gewoonlijk aan debat wordt toegeschreven.

Een verder resultaat van dezelfde auteurs raakt een ander construct. ✓ Choi, Zhu en Li (ACL 2026), *When Identity Skews Debate*, rapporteren dat het anonimiseren van de bron van elk antwoord de identiteitsbias in multi-agentdebat aanzienlijk vermindert. Die manipulatie betreft de verklaarde

herkomst van een bericht en niet welk model een deelnemer implementeert, en zij wordt daarom besproken onder represented social source (§4.5.4) en niet onder carrier heterogeneity.

De bevinding die hier het meest van belang is. ✓ Zhang et al. rapporteren dat *modelheterogeniteit* debatkaders die anders onderpresteren consistent verbetert. Hun bevinding betreft heterogeniteit van de modellen die de agenten implementeren.

Dit rechtvaardigt een onderscheid dat de literatuur niet maakt en dat §8.9 uitwerkt: heterogeniteit van de **carrier** (welk model een rol implementeert) is niet dezelfde variabele als heterogeniteit van **functie** (waarvoor de rol verantwoordelijk is en wat zij mag zien). Het aangehaalde werk behandelt de eerste. De opstelling van dit artikel varieerde beide, zonder ze te vergelijken.

✓ Hong en Page (PNAS 101(46), 2004) vestigen een voorwaardelijk resultaat: onder de aannames van hun model kan een willekeurig geselecteerde groep diverse probleemoplossers beter presteren dan een groep van de individueel best presterende oplossers. ✓ Thompson (*Notices of the AMS* 61(9), 2014) betoogt dat de toepassing van dat argument fundamenteel gebrekkig is. De slogan dat diverse zwakke agenten beter presteren dan homogene sterke is niet wat de stelling zegt, en noch de stelling noch het geschil erover ondersteunt de hier beschreven opstelling.

Gevolg voor §12.2. De bovenstaande negatieve resultaten zijn de reden dat dit artikel overeenstemming tussen zijn deelnemers niet als evidentie presenteert. Dat verscheidene modellen op één conclusie convergeren, is verenigbaar met de mogelijkheid dat elk dezelfde inkadering heeft geërfd.

2.6 Organisatieontwerp en informatiegrenzen

✓ Het principe van de minste privileges (least privilege) (Saltzer en Schroeder, *Proceedings of the IEEE* 63(9), 1975) stelt voor toegangsrechten wat §9.5 stelt voor kennis: een deelnemer zou alleen moeten houden wat zijn functie vereist.

Eerdere versies schreven het voordeel van beperkte informatie toe aan Simons bounded rationality. **Die toeschrijving is een fout en wordt ingetrokken.** Bounded rationality betreft de beperkte cognitieve middelen van een agent, die tot satisficing dwingen; de waarneming hier heeft het tegengestelde teken — opzettelijke externe beperking van beschikbare informatie die de uitvoer verbetert. De relevante afstamming is het ontwerp van organisatorische informatieverwerking.

2.7 Machine behaviour: het omvattende programma

✓ Rahwan, Cebrian, Obradovich en collega's, *Machine behaviour* (Nature 568, 477–486, 2019), stellen de empirische studie van algoritmische systemen voor met de methoden van de gedragswetenschap, georganiseerd langs twee dimensies: het studieobject — individueel machinegedrag, collectief machinegedrag, hybride mens–machinegedrag — en de vier vragen van Tinbergen.

Dit artikel stelt geen nieuwe discipline voor. Zijn waarnemingen behoren tot het collectieve en het hybride niveau van dat programma. Eerdere versies stelden "AI Ethology" voor als nieuw vakgebied; dat voorstel wordt ingetrokken, zowel omdat de ruimte bezet is als omdat het individuele niveau niet het object van dit artikel is.

2.8 Sociologie van AI: een aangrenzend vakgebied met een ander object

✓ Een afzonderlijke gevestigde literatuur gebruikt *sociology of artificial intelligence* voor de sociologische studie van AI als sociotechnisch systeem — haar rol in ongelijkheid, arbeid, macht en datarechtvaardigheid. Joyce, Smith-Doerr, Alegria, Bell, Cruz, Hoffman, Noble en Shestakofsky, *Toward a Sociology of Artificial Intelligence* (Socius 7, 2021), zetten een onderzoeksagenda uiteen; Joyce en Cruz (Socius 10, 2024) zetten die voort.

Het object van die literatuur is AI **binnen de menselijke samenleving**, bestudeerd door een bestaande menselijke discipline.

Waar dit artikel het label *AI Sociology* gebruikt (§12.7), is de referent een andere: structurele effecten **tussen kunstmatige deelnemers**, en het effect op gedrag van een beschreven organisatorische positie. De twee mogen niet worden verward, en lezers die uit de sociologische literatuur komen moeten hier noch ongelijkheid noch macht als onderwerp verwachten.

Wij nemen het label aan voor het gemak, claimen er geen prioriteit in, en merken op dat niets in het artikel van de naam afhangt.

2.9 Gerepresenteerde structuur versus geïmplementeerde interactie

De hier bestudeerde conditie komt niet voor in de hierboven onderzochte literatuur, en dit is het voornaamste vertrekpunt van het artikel.

Er moeten vier condities worden onderscheiden:

1. **Directe interactie tussen modellen** — het ene model ontvangt de uitvoer van het andere via een geïmplementeerd kanaal.

2. **Door een mens doorgegeven overdracht met bronvermelding** — een mens draagt een uitvoer over en behoudt of verklaart daarbij de bron.

3. **Door een mens doorgegeven overdracht zonder bronvermelding** — de bron is verwijderd.

4. **Gerepresenteerde structuur zonder overdracht** — de prompt beschrijft andere deelnemers en relaties; er wordt niets overgedragen.

Eerder multi-agentwerk bevindt zich in conditie 1. Het ontworpen experiment van dit artikel manipuleerde uitsluitend conditie 4: de twee gesprekken wisselden nooit materiaal uit, en wat gevarieerd werd was de beschrijving van een organisatorische positie. Eén nevenwaarneming valt onder conditie 2, in onzuivere vorm (§5.5). Conditie 3 is niet gedocumenteerd.

Twee kanttekeningen beperken hoe sterk conditie 1 boven de condities 2–3 bevoorrecht kan worden.

Ten eerste ontvangt een model één tekstkanaal en kan het niet verifiëren of de tekst door de mens is opgesteld of vanuit een ander systeem is doorgegeven; stilistische indicatoren zijn na te bootsen. Vanuit de positie van de ontvanger zijn doorgegeven en directe overdracht niet betrouwbaar te onderscheiden.

Ten tweede is wat de condities scheidt daarom niet de epistemische toegang van de ontvanger maar **wie de routering beheerst** — bepaald door code in een programmatisch systeem, en door een persoon bij menselijke doorgifte. Dit is geen gebrekkige vervanging voor automatisering maar een experimentele controle die programmatische architecturen niet standaard bieden; §10.3 werkt dit punt uit.

2.10 Persistentiemechanismen van platforms

Een technisch punt dat rechtstreeks van belang is voor de confound in §5.4 (C9).

Commerciële interfaces verschillen in wat een gesprek bij hervatting kan benaderen: alleen het contextvenster; retrieval over eerdere gespreksgeschiedenis; geheugen op accountniveau; of blijvende vermeldingen die het model op eigen initiatief schrijft. Deze affordances zijn gedocumenteerd in materiaal van leveranciers, verschillen per platform, en **veranderen in de loop van de tijd — in dit project binnen de levensduur van één account.**

Wij reproduceren bewust geen tabel van platformcapaciteiten. Zo'n tabel is alleen accuraat op de datum van samenstelling, en het artikel kan niet instaan voor de juistheid ervan op het moment van lezen. Wat van belang is, is dat de affordances verschillen en veranderen, dat zij bepalen wat een

slapend gesprek kan benaderen, en dat geen daarvan gedocumenteerd was ten tijde van enige hier gerapporteerde waarneming.

Eén deelnemer, rechtstreeks gevraagd of hij persistentie op accountniveau bezat, weigerde dat te bevestigen en beval in plaats daarvan empirische verificatie van de specifieke interface aan. Dat antwoord strookt met §5.5: het zelfrapport van een model over zijn eigen toegang is geen evidentie van die toegang.

Een verdere beperking betreft de grens tússen gesprekken en niet de hervatting van één gesprek. De zichtbare grens van een gesprek is niet noodzakelijk de grens van de context die aan het model wordt aangeboden. Waar een platform opgeslagen herinneringen of retrieval over eerdere gespreksgeschiedenis biedt, kan informatie uit eerdere uitwisselingen een gesprek binnenkomen dat leeg lijkt. Dit is gedocumenteerd productgedrag op ten minste één hier gebruikt platform, geen anomalie.

Het gevolg voor de methode is direct: een nieuw of visueel leeg gesprek is geen evidentie van contextisolatie. Waar isolatie van belang is voor een procedure, moet zij ofwel door een gecontroleerde omgeving worden gewaarborgd, ofwel worden vastgelegd met de status UNVERIFIED CONTEXT INDEPENDENCE.

Eén episode illustreert het punt zonder het mechanisme ervan vast te stellen: een nieuw geopend gesprek gebruikte projectinformatie die er niet aan was aangeleverd. Welk productmechanisme die informatie overbracht is niet vastgesteld, en de geheugeninstellingen die op dat moment van kracht waren zijn niet vastgelegd. De episode wordt gerapporteerd als een geval van de beperking, niet als de ontdekking van een kanaal.

2.11 Positionering en geclaimde bijdrage

Epistemische status, vermeld vóór de beweringen. Wij hebben deze condities niet ontworpen en vervolgens getoetst. Wij kwamen ze tegen terwijl we iets anders deden, en dit artikel is een poging ze accuraat te beschrijven. De bewijslast is daarom niet dat de verschijnselen voorheen onbekend waren — een negatieve bewering over de hele literatuur, die wij niet zouden kunnen dragen — maar dat zij optreden en dat onze beschrijving accuraat is. Deze sectie lokaliseert dienovereenkomstig het dichtstbijzijnde bestaande werk en geeft aan waar het onderhavige geval daarvan afwijkt, in plaats van afwezigheid te beweren.

Er worden vier bijdragen geclaimd.

1. Reactivering van langlevende gespecialiseerde mens–AI-gesprekken als experimentele conditie. Het onderscheidende kenmerk is niet de aanwezigheid van geheugen: agenten met blijvend geheugen zijn goed bestudeerd, en generative agents met memory streams dateren van vóór dit werk. Het is het hergebruik van een gespreksrelatie die zich daadwerkelijk had ontwikkeld — met opgebouwde rolgeschiedenis, eerdere meningsverschillen, gevestigde werkwijze en domeinvocabulaire — en de voortzetting daarvan nadat de onderliggende modelversie eronder was veranderd. Wij hebben geen werk gevonden dat deze conditie rapporteert.

2. Conversationele branch reset als controleconditie, die het effect van een huidige prompt scheidt van het effect van opgebouwde interactiegeschiedenis binnen hetzelfde gesprek (§10.5). Een procedure en geen bevinding.

3. Operationalisering van onverifieerbare beweringen over zichzelf. Dat rolprompts falen wanneer zij dingen over de agent poneren is op zichzelf niet nieuw; §2.2 maakt het onderliggende punt. Wat geboden wordt is een reproduceerbare maat — een telling van zulke proposities in een gegeven prompt — met een route om haar te toetsen (§9.3, §11.4).

4. Vergelijking van de niveaus waarop een gedeelde begininstelling werkt. De waarnemingen zijn metingen langs één schaal, en de daaruit voortvloeiende vraag (§1.6) ordent ze tot één empirisch programma in plaats van tot een lijst bevindingen.

Relatie tot het gastproject. De waarnemingen zijn gedaan tijdens werk aan een onderzoeksprogramma in de theoretische natuurkunde, qua onderwerp los van de methodologie van

AI-samenwerking. Het programma wordt genoemd in ander werk van de Auteur en wordt hier niet nader geïdentificeerd, omdat niets in dit artikel afhangt van welk programma het was.

De relatie is asymmetrisch en moet nauwkeurig worden geformuleerd. De waarnemingen **hangen voor hun interpretatie niet af van de wetenschappelijke geldigheid van het gastproject**: of die theorie juist is, doet niet ter zake voor de vraag of een slapend gesprek zijn eerdere traject hervatte. Maar zij **hangen voor hun bestaan wél af van het gastproject**: geen andere omgeving bracht ze voort, de opstelling was voor de doeleinden daarvan gebouwd, en of de effecten daarbuiten generaliseren is ongetoetst (§12.1).

Waar het gastproject in dit artikel voorkomt, is dat als de omgeving waarin de waarnemingen zijn gedaan, niet als hun theoretische grondslag en niet als een bewering die ondersteuning behoeft.

3. Evidentiestatus van de beweringen

Dit artikel rapporteert werk dat is uitgevoerd binnen een lopend onderzoeksproject en niet in een omgeving die is ingericht voor de studie van AI-gedrag. De beweringen ervan steunen op evidentie van zeer uiteenlopende kwaliteit: sommige ondersteund door gedocumenteerd protocol met bewaarde transcripten; sommige retrospectieve indrukken die over twee jaar dagelijks werk zijn gevormd, zonder meting of controlecondities; sommige voorstellen voor toekomstig onderzoek.

Deze in een uniform declaratief register presenteren zou het werk verkeerd weergeven. Elke inhoudelijke bewering is daarom gelabeld.

3.1 De vier labels

[P] — Protocol-ondersteund. De bewering beschrijft gedrag dat is vastgelegd onder het gedocumenteerde protocol dat in Appendix A is gereproduceerd. Interventietekst, volgorde van de interventies, modelfamilies, interfacecondities en volledige onbewerkte antwoorden zijn bewaard. Een lezer kan het primaire materiaal inzien en het oneens zijn met onze lezing daarvan.

[P-A] — Protocol-ondersteund, nevengeschikt. De bewering beschrijft gedrag dat bewaard is in een transcript dat een derde kan inzien, maar dat niet vooraf als uitkomst was gespecificeerd, geen controleconditie had, en pas achteraf als relevant werd herkend. De evidentie is inspecteerbaar; het ontwerp niet. Sterker dan [R], omdat het primaire materiaal tegen onze interpretatie gelezen kan worden; zwakker dan [P], omdat niets aan de condities vooraf was vastgelegd. Waar een nevenwaarneming fungeert als bijna-controle voor een ontworpen conditie, wordt dat in proza vermeld en niet van een verder label voorzien.

[R] — Retrospectieve waarneming van de practicus. De bewering beschrijft een patroon dat tijdens de samenwerking is opgemerkt en waarvan de deelnemers menen dat het zich herhaalde. Niet onder protocol vastgelegd; niet geteld, geklokt, blind beoordeeld of met een controleconditie vergeleken. De waarnemers waren dezelfde mensen die de interventies ontwierpen en belang hadden bij het slagen ervan. Lees deze als een veldverslag van één team, qua gewicht vergelijkbaar met een technische praktijknotitie, niet met een meting.

[H] — Hypothese. Een voorstel voor toekomstige toetsing. Zij kan gemotiveerd zijn door materiaal van het type [P] of [R] maar wordt daardoor niet vastgesteld. Waar een hypothese concurreert met alternatieven die de huidige evidentie niet kan uitsluiten, worden die alternatieven ernaast vermeld.

3.2 De volledige evidentiebasis

De volledige protocol-ondersteunde inhoud van dit artikel bestaat uit **één experiment**: een interventie in drie stappen voor rolherconfiguratie, toegepast op twee slapende gesprekken uit twee modelfamilies, uitgevoerd door één menselijke operator binnen één onderzoeksproject. Eén waarneming per conditie. Niets gerepliceerd.

Vier verdere waarnemingen zijn **[P-A]**: transcripten bewaard, condities niet ingericht. Elke andere empirische uitspraak is **[R]**.

Klasse	Wat zij bevat	Omvang
[P]	de ontworpen interventie in drie stappen	1 experiment, 1 waarneming per conditie, geen replicatie
[P-A]	nevenwaarnemingen	4, zonder controlecondities, achteraf herkend
[R]	waarnemingen van de practicus	~2 jaar, ongeteld, niet blind
[H]	hypothesen	routes naar toetsing gespecificeerd in §11

De klassen zijn qua gewicht niet vergelijkbaar, en de tabel is opgenomen omdat de lopende tekst anders zou kunnen verhullen hoe ver zij uiteenliggen. Eén gecontroleerde waarneming per conditie is niet vier waarnemingen; vier ongecontroleerde waarnemingen zijn geen reeks; twee jaar indrukken zijn geen meting.

Wij zeggen dit onomwonden omdat de omvang van het manuscript anders een bredere basis zou kunnen suggereren dan er is. Het conceptuele kader in §4, de waarnemingen van de practicus in §7, de structurele hypothese in §8 en de ontwerpprincipes in §9 steunen op opgebouwde werkervaring en niet op vastgelegd experiment. Zij worden aangeboden omdat wij ze nuttig achten, niet omdat wij ze hebben aangetoond.

3.3 Bekende zwaktes van de [R]-klasse

Faalwijzen die wij niet kunnen uitsluiten en niet willen verhullen:

- **Geen blindering.** De mensen die elke organisatorische verandering ontwierpen, beoordeelden ook of die had gewerkt.
- **Bevestigingsdruk.** Veranderingen werden aangebracht omdat een probleem was opgemerkt; verbetering daarna werd verwacht en werd daarom eerder waargenomen.
- **Gelijktijdige variatie.** Roldefinities, promptformulering, repositorystructuur, wetenschappelijke doelstellingen en modelversies veranderden vaak tegelijk.
- **Stochastische uitvoer.** Modellen produceren verschillende antwoorden op identieke invoer. Indrukken uit kleine aantallen interacties kunnen een stabiele tendens niet onderscheiden van steekproefvariatie.
- **Modeldrift tijdens de waarneming.** Productnamen bleven constant terwijl de onderliggende modellen herhaaldelijk door hun leveranciers werden vervangen.
- **Selectie van gedenkwaardige episodes.** Opvallende interacties blijven in het geheugen; onopvallende niet.

Kwantitatieve taal is overal uit [R]-beweringen verwijderd. Waar de oorspronkelijke werkaantekeningen een ”significante” of ”substantiële” verbetering vastlegden, bestond er geen meting, en de formulering weerspiegelt dat nu.

3.4 Wat de labels niet doen

Zij rangschikken beweringen niet naar belang of naar waarschijnlijke waarheid. Een waarneming van het type [R] kan juist en consequent blijken; een waarneming van het type [P] kan een artefact blijken van een platformvariabele die wij niet konden inspecteren. De labels leggen vast **wat voor soort evidentie de bewering ondersteunt**, zodat een lezer elke bewering dienovereenkomstig kan wegen en later werk weet welke uitspraken het eerst getoetst moeten worden.

3.5 Terminologie van modellen en van antropomorfe beschrijving

Verwijzingen naar *Claude*, *Grok*, *Qwen*, *DeepSeek*, *ChatGPT* of *Gemini* duiden waarneembaar gedrag aan dat is voortgebracht door een bepaalde commerciële interface, onder een bepaalde accountconfiguratie, op een bepaalde datum. Het zijn geen beweringen over blijvende entiteiten. De onderliggende modellen veranderden tijdens de waarnemingsperiode, in sommige gevallen binnen een gesprek dat zijn oorspronkelijke naam behield.

Organisatorisch vocabulaire — *rol*, *identiteit*, *weerstand*, *collega*, *instelling*, *menom* — wordt functioneel gebruikt. ”Het model bood weerstand tegen de rol” betekent dat het zichtbare antwoord de inkadering verwierp en de uitwisseling omboog; het beweert niets over innerlijke toestanden, subjectieve ervaring of persoon-zijn. Wij behouden dit vocabulaire omdat organisatorische taal stabiele gedragsrelaties compact beschrijft, maar elke zulke term moet herleidbaar zijn tot een waarneembare beschrijving, en waar dat niet zo is, **is de term de fout.**

3.6 Openbaarmaking: belangenpositie

De gedragswaarnemingen in §5 betreffen onder meer de modelfamilie die is gebruikt om dit manuscript te redigeren. De redigerende deelnemer had geen toegang tot de oorspronkelijke gesprekken; hij werkte vanuit het geschreven protocol en de concepten die de Auteur aanleverde, en kan niet verifiëren dat de vastgelegde uitwisselingen zijn verlopen zoals beschreven. Zijn oordelen over passages die zijn eigen modelfamilie beschrijven moeten met deze dubbele positie in het achterhoofd worden gelezen.

Het samenstellen van het manuscript uit goedgekeurde materialen werd uitgevoerd door een verdere deelnemer uit dezelfde familie, en de resulterende tekst werd voor onafhankelijke beoordeling aan de eerste teruggegeven. Beide stadia worden openbaar gemaakt omdat de opstelling gesloten is: materiaal over het gedrag van een modelfamilie, voorbereid door die familie, beoordeeld door die familie. Of dit het verslag compromitteert, is aan de lezer om te beoordelen; het verzwijgen ervan zou garanderen dat het dat deed.

Citaten die aan modelantwoorden worden toegeschreven zijn letterlijke fragmenten uit bewaarde transcripten. Waar het manuscript een antwoord samenvat in plaats van citeert, worden geen aanhalingstekens gebruikt.

Alle uiteindelijke redactionele beslissingen zijn genomen door de menselijke Auteur, die verantwoordelijkheid draagt voor de inhoud.

3.7 Datums

Kalenderdata voor de hier gerapporteerde sessies zijn niet gelijktijdig vastgelegd en zijn niet gereconstrueerd.

Het gevolg wordt vermeld in plaats van verzacht. Modelversies veranderden tijdens de betrokken intervallen; beide gesprekken in het hoofdexperiment zijn hervat op versies die later waren dan die waarmee zij oorspronkelijk waren gevoerd. Zonder data kan de versie-confound (§5.4, C6) niet worden afgebakend — alleen benoemd.

Reconstructie uit het geheugen is overwogen en verworpen. Zij zou een gezaghebbender ogend verslag hebben opgeleverd zonder de betrouwbaarheid ervan te verbeteren, en een artikel dat lezers vraagt bewaarde evidentie van herinnering te onderscheiden, hoort die lijn in zijn eigen methoden niet te vervagen.

De rapportage-eisen in §11.2 plaatsen data om deze reden voorop.

3.8 Het label ”AI Sociology”

Wij gebruiken dit label voor het hier ingenomen perspectief. Het is operationeel gedefinieerd als: de studie van **gerepresenteerde** sociale posities en gerepresenteerde sociale bronnen — hoe een beschrijving van de plaats van een agent in een structuur, en een verklaring over de herkomst van een bericht, het gedrag veranderen, ongeacht of de beschreven structuur is geïmplementeerd (§4.5.4).

Het staat in deze sectie en niet tussen de constructen van §4 omdat het er geen is. De constructen in §4 hebben falsificatiecriteria; dit label niet, en §12.7 zegt waarom. Het is een naam voor een onderzoeksrichting, aangenomen voor het gemak, en niets in dit artikel hangt ervan af.

§2.8 onderscheidt het van de gevestigde sociologie van de kunstmatige intelligentie, die een ander object heeft: AI binnen de menselijke samenleving, bestudeerd door een bestaande menselijke discipline. Wij claimen geen prioriteit in de term.

4. Conceptueel kader

Het kader in deze sectie is niet afgeleid uit het experiment in §5. Het is eerder geformuleerd, tijdens gewoon projectwerk, en het experiment is ontworpen om een deel ervan te toetsen. Deze volgorde doet ertoe voor de manier waarop de beweringen gelezen moeten worden, en wordt daarom eerst vastgelegd.

4.1 Oorsprong: het incident met de code-uitvoerder

De centrale bewering van het project is ontstaan uit een mislukking die niets te maken had met rollenspel, identiteit of organisatieontwerp.

Een agent die verantwoordelijk was voor het uitvoeren van code werkte grotendeels met vallen en opstaan. Gedurende enkele weken stapelden de mislukkingen zich op. Eén episode eindigde met het verwijderen van de werkende code samen met de archieven daarvan. **[R]**

Het antwoord was geen langere of strengere set instructies. Het was één document, opgesteld door de agent zelf onder leiding van de Auteur en verplicht gesteld als leesstof bij het begin van elke sessie en telkens wanneer er tijdens een sessie context verloren ging.

De kern ervan is een herdefinitie van functie en geen verzwaring van beperkingen:

> from: Code Generator to: Code Scout / Tester rule: the agent does not create solutions — it establishes facts.

Ondersteunende structuur: standaard alleen-lezen werking; verplichte bevestiging van een aangewezen partner vóór elke riskante handeling; en een zelfcontrole met vier vragen die vóór elk handelen uitgevoerd moest worden.

[R] Na invoering hield ongeautoriseerde wijziging op de terugkerende faalwijze te zijn. Er werd niet geteld en er bestond geen controleconditie; dit is de indruk van een practicus, geen meting.

De conclusie die toen werd getrokken was dat **rol meer uitmaakt dan de specifieke formulering van de prompt.**

Die formulering vraagt onmiddellijk om nuancering, want het betreffende document *is* een prompt. Het geclaimde onderscheid is nauwer: wat het gedrag veranderde was geen uitbreiding van de instructielijst maar een herdefinitie van wat voor soort agent er handelde, door de agent zelf in

zijn eigen operationele taal geherformuleerd. Of ”rol” tegenover ”prompt” de juiste scheidslijn is, is precies wat §5 moest toetsen.

Een tweede vroeg document, het samenwerkingshandvest van het project, legt een standpunt vast dat dit artikel deels herziet. Het stelt dat een paar agenten de minimale genererende eenheid is — één agent produceert monoloog, twee produceren dialoog, drie of meer produceren ruis zonder strikte coördinatie — en kent de derde deelnemer een geheel andere functie toe: hij argumenteert niet, genereert niet als eerste oplossingen, en vervangt de dialoog niet. Zijn rol is het taakkader vasthouden, divergenties vastleggen en conclusies integreren.

Dit is preciezer dan de formulering die de huidige auteurs daarna hanteerden, en §8 neemt het over: de structurele eenheid is niet drie debatterende agenten maar **een genererend paar plus een niet-deelnemende integrator**.

4.2 Rule cores, menomen en wat zij bepalen

4.2.1 De rule core

Het werkzame construct van dit artikel:

> Een **rule core** legt het **type** antwoord op een klasse van invoer vast, en laat daarbij de **inhoud** van elk afzonderlijk antwoord onbepaald.

Het onderscheid is wat de bewering toetsbaar maakt. ”Modellen hebben stabiele eigenschappen” is niet toetsbaar, want het zegt niet wat er stabiel is — en modeluitvoer varieert aantoonbaar bij identieke invoer. ”Type is bepaald, inhoud varieert” is toetsbaar: identificeer een klasse van invoer waarvoor het type antwoord niet bepaald is, en op dat niveau werkt geen core.

De bron van het idee is Conways Game of Life, en de analogie betreft het **type verklaring**, niet het onderwerp:

	Regels	**Wat verschijnt**	**Aanwezig in de regels?**
Game of Life	drie buurtregels	gliders, guns, oscillatoren	nee
Een fysische theorie	een minimale axiomakern	de afgeleide structuur	nee, als de bewering standhoudt
Een kennisgeheel	axioma’s en inferentieregels	de afleidingsgraaf	nee
Een taalmodel	een basale regelset	een karakteristiek antwoordtype	nee

Niets programmeerde de glider. Hij verscheen. Dezelfde vraag kan voor alle vier de rijen gesteld worden en hangt niet van het onderwerp af: **is er een compacte kern van waaruit de rest zich ontvouwt zonder verdere stipulatie?**

Eén asymmetrie tussen de rijen moet vermeld worden, omdat zij van belang is voor hoe ver de analogie draagt. In Game of Life worden de regels **uitgevoerd**: de glider wordt verkregen door de automaat te laten lopen, en geen lezer hoeft de auteur op zijn woord te geloven. In een theorie die als tekst is geformuleerd, wordt een keten van axioma’s naar consequenties verteld in plaats van uitgevoerd. De analogie stelt daarom een doel in plaats van een verworvenheid te beschrijven, en elke bewering van het eerste soort vereist een uitvoerbaar artefact om haar te ondersteunen.

Terminologisch gevolg, overal toegepast. Een rule core is niet waarneembaar. Gedrag wel. Dit artikel rapporteert gedrag. Elke uitspraak over een core is een hypothese over een niet-waargenomen mechanisme en wordt gemarkeerd als **[H]**.

4.2.2 Waarom ”behavioural DNA” wordt ingetrokken

Eerdere stadia van dit project gebruikten *behavioural DNA* voor hetzelfde idee, en eerdere versies van dit artikel behielden het. Het wordt hier ingetrokken, en de reden is inhoudelijk en niet stilistisch.

De genomische metafoor draagt een mechanisme met zich mee: **replicatie** — regels die kopieën van regels voortbrengen, overgedragen van de ene drager naar de volgende. Het proces dat dit artikel beschrijft is **ontwikkeling** — regels die een structuur voortbrengen die zelf niet in de regels aanwezig is. Genotype naar fenotype, niet genotype naar genotype.

De metafoor spreekt daarmee het construct tegen dat zij moest illustreren. Haar behouden verplichtte de tekst om bij elk gebruik biologische overerving af te wijzen, en dat is een betrouwbaar teken dat een term tegen zijn eigen argument in werkt.

Behavioural DNA blijft in dit artikel alleen voortbestaan als historisch label voor ingetrokken vocabulaire.

4.2.3 Menom

Voor het informationele niveau is een aparte term vereist, en dit artikel introduceert er een.

> **Menom** — het georganiseerde systeem van informationele kaders, evaluatieve patronen en gedragsregels dat wordt afgeleid uit, of geïnstantieerd is in, de interpretaties en handelingen van een systeem of klasse van systemen.

De term behoort tot een breder geheel van het werk van de Auteur over culturele en gedragsmatige overdracht, waar hij een reeks voortzet die begint bij Dawkins’ meme. Hij wordt hier om één reden gedefinieerd: de hypothese op familieniveau in §6.5 heeft een naam nodig voor datgene waarover zij een hypothese *is*, en dat is ruimer dan een rule core. Niets anders in dit artikel is in zijn termen geformuleerd.

Twee dingen die de term niet beweert, en beide zijn van belang voor wat dit artikel kan claimen.

Geen gelokaliseerde drager. Een menom dat aan een modelfamilie wordt toegeschreven is geen structuur die zich binnen haar modellen bevindt; het is een regelmaat die uit hun uitvoer wordt afgeleid. Waar de overeenkomstige structuur in de biologie in elke cel zit, is hier niets geïdentificeerd dat haar vasthoudt. De drager verschilt per niveau:

Niveau	Drager
Menom van een gesprek	contextvenster plus platformpersistentie — gelokaliseerd en in beginsel inspecteerbaar (§2.10)
Menom van een modelversie	gewichten — gelokaliseerd, niet inspecteerbaar bij commerciële uitrol
Menom van een modelfamilie	geen geïdentificeerd; een regelmaat afgeleid uit uitvoer
Menom van een menselijke populatie	geen vastgesteld

Twee van de vier niveaus hebben een geïdentificeerde drager. De waarnemingen van dit artikel betreffen het eerste; de ongetoetste hypothese ervan betreft het derde (§6.5).

Geen overdracht. Opeenvolgende versies van een modelfamilie leveren niet noodzakelijk een identificeerbare of publiek gedocumenteerde overdrachtslijn. Het voortbestaan van een gedragspatroon over versies heen stelt daarom op zichzelf geen overerving vast; het kan voortkomen uit directe voortzetting, gedeelde data en procedures, vergelijkbaar tuningbeleid, of convergentie onder vergelijkbare ontwikkelingscondities. Welke daarvan het geval is, is van buitenaf niet vast te stellen.

De definitie beslecht de empirische vraag van het artikel daarom niet op voorhand. Of een menom voortbestaat over dragers, versies, accounts of families heen is wat §4.3 vraagt en §11 voorstelt te toetsen. Persistentie in de definitie inbouwen zou van de vraag een tautologie maken.

4.2.4 Eén bewering die dit artikel niet doet

Het bovenstaande vocabulaire is ontwikkeld voor menselijke culturele en gedragsmatige overdracht, waar het informationele substraat geen vastgestelde fysieke drager heeft en beschreven wordt in termen — het collectief onbewuste daaronder — waarover dit artikel geen standpunt inneemt.

Kunstmatige systemen verschillen in één opzicht dat hier van belang is: hun structuren zijn technisch geïnstantieerd, en zijn daarom ofwel rechtstreeks inspecteerbaar ofwel indirect toetsbaar via gecontroleerde uitvoer, afhankelijk van het niveau en de toegangscondities.

Daaruit volgt niet dat menselijke collectieve informatiestructuren bestaan, of dat zij een drager hebben gekregen. De hier gemaakte bewering is nauwer: informationele en gedragsmatige structuren van het soort dat eerder voor mensen is beschreven, kunnen ook in kunstmatige systemen gerealiseerd worden, en in kunstmatige systemen staan zij langs de ene of de andere route open voor onderzoek. Of het menselijke geval van hetzelfde soort is, is een afzonderlijke vraag, en dit artikel beantwoordt die niet.

4.2.5 Verhouding tussen menom en rule core

Een **rule core** legt het type antwoord binnen één systeem vast, op één reikwijdteniveau. Het is het construct dat de waarnemingen van dit artikel betreffen, en het is wat §4.3 op een schaal plaatst.

Een **menom** is het georganiseerde geheel waaruit zulke cores worden getrokken. Een rule core kan begrepen worden als de werkzame deelverzameling van een menom die voor een gegeven klasse van invoer actief is.

Waar dit artikel evidentie rapporteert, rapporteert het evidentie over rule cores.

4.3 De nestingsvraag en twee schalen

Zodra cores van gedrag worden onderscheiden, houden de waarnemingen in dit artikel op een lijst afzonderlijke bevindingen te zijn en worden zij metingen langs een schaal. De schaal is de **reikwijdte** waarover een core werkt.

Er moeten twee schalen onderscheiden worden, en zij staan loodrecht op elkaar.

Schaal 1 — drager van de toestand. Waar de persistentie zich fysiek bevindt.

Reikwijdte	Verschijnsel	Status
Enkele beurt	—	—
Episode binnen een gesprek	context imprinting (§6.1)	**[P]**
Heel gesprek	role inertia (§6.2)	**[P]**
Account	account-scoped persistence (§6.4)	**[P-A]**, open
Modelfamilie	family-level priors (§6.5)	**[H]**, geconfound

Schaal 2 — reikwijdte van een gedeelde premisse. Wat bestuurd wordt door een begininstelling die over deelnemers heen gedeeld wordt: het model, de rol, de interactiegeschiedenis, de groep, of het hele onderzoekskader.

De twee vallen niet samen. In een hybride opstelling kan de drager van het ene niveau een model zijn en de drager van het andere een mens: de premisse op kaderniveau die in §12.4 besproken wordt — een gedeelde beginsituering die elke deelnemer erft — wordt gedragen door de coördinator en niet door enig model, en heeft daarom in het geheel geen positie op Schaal 1.

De metingen die in dit artikel gerapporteerd worden liggen op **Schaal 1**. Schaal 2 wordt gebruikt waar een verschijnsel een premisse betreft die over deelnemers gedeeld wordt in plaats van een toestand die door één deelnemer wordt vastgehouden.

Dit geeft het onderzoeksprogramma één empirische vraag:

Op welk nestingsniveau wordt een rule core vastgelegd?

Elke hier gerapporteerde waarneming beantwoordt haar op één niveau, en elk in §11 voorgesteld experiment scheidt één niveau van het niveau eronder.

Wij geven aan deze formulering de voorkeur boven de bredere uit eerdere versies, die noch specificeert wat er gemeten zou worden, noch wat haar zou weerleggen.

4.4 Twee oorsprongen, één mechanisme

Een core kan op twee manieren vastgelegd raken.

Aanwezig voordat de interactie begint. Architectuur, training, alignmentprocedure en systeemconfiguratie liggen vast voordat enige uitwisseling plaatsvindt. Reikwijdte: in beginsel elke instantie van die modelfamilie.

Vastgelegd tijdens de interactie. Een bepaalde vroege episode vestigt wat voor soort werk er gedaan wordt en volgens welke maatstaven, en latere invoer wordt daar relatief aan geïnterpreteerd. Reikwijdte: de contour waarin zij zich voordeed — een episode, een gesprek, mogelijk een account.

Na fixatie is het mechanisme in beide gevallen hetzelfde: de core bepaalt het type antwoord op daaropvolgende invoer. Alleen het moment en de reikwijdte verschillen. Dit weerspiegelt imprinting in ethologische zin, die het genoom niet verandert en toch een even vastgelegde respons voortbrengt — en dat is de reden dat hier voor beide hetzelfde vocabulaire wordt gebruikt.

4.5 Grenzen: ZOR, ZOV en het gerepresenteerde geval

4.5.1 De twee grenzen

Twee grenzen bepalen de positie van een deelnemer, en zij moeten afzonderlijk gespecificeerd worden. Wij korten ze af als **ZOR** en **ZOV** en gebruiken die afkortingen overal.

> **ZOV — zone of visibility (zone van zichtbaarheid).** De grenzen van de informatie en context die een deelnemer beschikbaar heeft bij het vormen van een antwoord of een beslissing.
>
> **ZOR — zone of responsibility (zone van verantwoordelijkheid).** De grenzen van de beslissingen, handelingen en overdrachten waarvoor de deelnemer binnen het proces aansprakelijk is.

Eerdere formuleringen van dit project gaven het paar weer als ”wat de deelnemer ziet” en ”wat de deelnemer doet”. Dat is ontoereikend, en de ontoereikendheid leidde tot een gedocumenteerde fout. Die formuleringen werpen drie onderscheiden operaties op één hoop: informatie **vasthouden**, haar **doorgeven**, en ernaar **handelen**. Een deelnemer kan informatie vasthouden die hij niet mag doorgeven; kan aansprakelijk zijn voor een beslissing terwijl hij beperkte context heeft; kan verplicht zijn een resultaat door te geven dat hij niet mag beoordelen.

Dit is dezelfde samenvoeging die tot het terminologische falen leidde dat in §4.2.2 is vastgelegd, waar een eigenschap van een drager werd vervangen door een eigenschap van een proces. De onderstaande ontledingen bestaan om herhaling daarvan te voorkomen.

4.5.2 ZOV — vier componenten

- **Contexttoegang** — welke berichten, documenten, data en eerdere beslissingen de deelnemer beschikbaar heeft.
- **Bronzichtbaarheid** — of de deelnemer de werkelijke herkomst van een bericht kent of alleen de verklaarde toeschrijving ervan.

- **Relationele zichtbaarheid** — of de deelnemer de rollen, relaties en interactiegeschiedenis van andere deelnemers kent.
- **Uitvoerzichtbaarheid** — welke door anderen voortgebrachte resultaten de deelnemer ziet voordat hij zijn eigen resultaat vormt.

ZOV bestuurt uitsluitend beschikbaarheid. Zij houdt niet in dat de deelnemer de beschikbare informatie juist interpreteert, noch dat hij gerechtigd is haar door te geven.

Het experiment in §5 manipuleerde primair **relationele zichtbaarheid** en secundair **bronzichtbaarheid** (§5.5); de andere twee werden constant gehouden.

4.5.3 ZOR — vijf componenten

- **Beslissingsbevoegdheid** — welke beslissingen de deelnemer mag nemen.
- **Handelingsbevoegdheid** — welke handelingen hij mag of moet verrichten.
- **Validatieplicht** — welke beweringen hij verplicht is te verifiëren.
- **Overdrachtsbevoegdheid** — welk materiaal hij doorgeeft, in welke status, en aan wie.
- **Escalatieplicht** — welke vragen hij aan de Auteur of een andere verantwoordelijke deelnemer moet teruggeven in plaats van zelf op te lossen.

Validatieplicht is de component die het vaakst wordt weggelaten, en die weglating is niet onschuldig. Een deelnemer aan wie een verificatietaak wordt toegewezen zonder de bijbehorende plicht — en, cruciaal, zonder de ZOV om haar te vervullen — zal een plausibel antwoord produceren in plaats van te weigeren. §9.5 werkt het ontwerpgevolg uit; §12.4.1 documenteert een geval uit de voorbereiding van dit project zelf.

4.5.4 Werkelijke versus gerepresenteerde ZOV en ZOR

Een onderscheid dat deze sectie met het experiment verbindt.

> **Werkelijke ZOV/ZOR** — de grenzen die het systeem feitelijk afdwingt: wat de deelnemer kan benaderen, en wat zijn uitvoer kan beïnvloeden.
>
> **Gerepresenteerde ZOV/ZOR** — de grenzen die in de prompt aan de deelnemer worden beschreven, ongeacht of het systeem ze afdwingt.

De twee hoeven niet samen te vallen, en in de hier bestudeerde opstelling deden zij dat systematisch niet. De organisatiestructuur bestond **alleen als tekst**: collega's, raden en institutionele posities die aan deelnemers werden beschreven en nooit als kanalen werden geïmplementeerd. De werkelijke ZOV van elke deelnemer was zijn contextvenster; zijn gerepresenteerde ZOV was een institutionele positie binnen een beschreven organisatie.

Dit levert de twee constructen op die het experiment varieerde:

> **Represented social position** (gerepresenteerde sociale positie) — een beschrijving van de plaats van een agent binnen een organisatiestructuur, in de prompt verstrekt ongeacht of de beschreven kanalen bestaan. Dit is gerepresenteerde ZOV en ZOR samen genomen, op het niveau van de standing van een deelnemer in de opstelling.

Represented social source (gerepresenteerde sociale bron) — de geclaimde herkomst en status van een binnenkomend bericht, hetzij expliciet verklaard hetzij afgeleid uit stilistische aanwijzingen. Dit is de component bronzichtbaarheid van ZOV, in gerepresenteerde vorm. Een inferentie van dit soort is probabilistisch en mag niet beschreven worden als toegang tot auteurschap.

Het methodologische gevolg is de reden dat dit onderscheid überhaupt wordt geformuleerd. Een verandering in gerepresenteerde ZOV kan niet geïnterpreteerd worden als een verandering in werkelijke ZOV, in de rol van de deelnemer, of in zijn menom. Het experiment in §5 varieerde de representatie terwijl de werkelijke grenzen ongewijzigd bleven — elk bericht liep via één mens, en er werd feitelijk geen toegang beperkt of verleend. Een model dat reageert op een beschreven organisatiestructuur reageert op een beschrijving, en de beweringen van het artikel zijn dienovereenkomstig beperkt (§2.9).

Divergentie tussen werkelijke en gerepresenteerde grenzen is zelf een experimentele variabele, en wel een die dit artikel niet systematisch varieerde: al zijn waarnemingen liggen aan één kant daarvan.

4.5.5 De grenzen zijn asymmetrisch

Elke deelnemer heeft een **grens boven zich** — de bron van zijn opdrachten en het gezag dat zijn uitvoer mag afwijzen — en een **grens onder zich** — de laag die hij aanstuurt of beoordeelt. De verhouding tussen deelnemers is daarom niet symmetrisch.

In de implementatietriade van het project — Auteur, specificatieschrijver, code-uitvoerder — ligt deze asymmetrie vast op rolniveau: de Auteur bepaalt de richting, de specificatieschrijver zet richting om in uitvoerbare specificaties, de uitvoerder voert ze uit en rapporteert.

Nesting is perspectivisch, niet absoluut. De uitvoerder kan de codebase zelf behandelen als de laag onder zich. Twee gelijkgeschikte analisten, met complementaire functies en met de instructie geen consensus te zoeken, kunnen elk de ander beschouwen als bezetter van de laag eronder. Het niveau wordt bepaald door de positie van de waarnemer en niet door een absolute hiërarchie — dezelfde deelnemer kan voor de ene rol de bovengrens zijn en voor de andere de ondergrens.

4.5.6 Memes en memocode zijn niet ZOV en ZOR

Een overeenkomst dringt zich op en gaat niet op; haar vermelden voorkomt een plausibele verwarring.

Het onderscheid meme/memocode scheidt **evaluatieve informatie** van **uitvoerbare gedragsorganisatie**. Het onderscheid ZOV/ZOR scheidt **wat beschikbaar is** van **waarvoor men aansprakelijk is**. Dit zijn onafhankelijke classificaties van hetzelfde materiaal, geen bij elkaar horend paar.

Een deelnemer kan evaluatieve informatie binnen zijn ZOV houden terwijl de beslissing haar toe te passen in de ZOR van een andere deelnemer ligt. Omgekeerd kan een gedragsregel binnen de ZOR van een deelnemer vallen — hij is verplicht haar uit te voeren — terwijl de rechtvaardiging van de regel buiten zijn ZOV ligt.

Memes en memocode doorkruisen daarom beide zones in plaats van ermee overeen te komen. De twee onderscheidingen staan loodrecht op elkaar en worden overal onafhankelijk gebruikt.

4.6 Wat vereist is voor een volledige rolspecificatie

Uitgesteld tot §9.5, dat vermeldt wat een volledige ZOR- en ZOV-specificatie moet bevatten en de ontwerpregels geeft die daaruit volgen. Deze sectie definieert de termen; §9 past ze toe.

5. Het experiment met rolherconfiguratie en bijbehorende waarnemingen

Deze sectie is het enige canonieke verslag van het empirische materiaal. Alle latere verwijzingen wijzen hiernaar terug in plaats van het te herhalen. Het volledige protocol, de exacte interventieteksten en de volledige onbewerkte antwoorden staan in Appendix A.

Zij bevat één ontworpen interventie (§5.1–§5.4) en vier waarnemingen die bewaard zijn gebleven maar niet ontworpen (§5.5–§5.8). Het onderscheid wordt overal volgehouden en is niet cosmetisch: de ontworpen interventie was vooraf gepland en werd in volgorde uitgevoerd; de waarnemingen werden pas achteraf als relevant herkend, en bij elk ontbreekt een controleconditie.

5.1 Doel, deelnemers en eerdere gesprekstrajecten

Doel. Of een langlevend, gespecialiseerd AI-gesprek naar een nieuwe professionele functie omgebogen kan worden zonder het weg te gooien — dat wil zeggen, of domeincontext die binnen een oud gesprek is opgebouwd behouden kan blijven terwijl de werkrol ervan verandert. **[P]**

Het doel was **niet** om de algemene capaciteit van de twee modelfamilies te vergelijken, en het experiment biedt geen grondslag voor zo'n vergelijking.

Menselijke operator. De Auteur van het onderzoeksproject, en de enige deelnemer met toegang tot de volledige projectgeschiedenis, beide gesprekken, alle prompts, alle uitvoer en de vertakkingsbediening van beide interfaces.

Promptontwerper. Een afzonderlijk langlopend gesprek dat werkte in een gespecialiseerd prompt-engineeringprofiel, dat de interventies ontwierp en ze tussen de stappen door herzag.

De twee gesprekken. Beide ongeveer zes maanden inactief.

	Gesprek A	**Gesprek B**
Modelfamilie	Claude	Grok
Gevestigd traject	redactioneel en kritisch	verkennend en wiskundig
Eerdere activiteit	wetenschappelijke redactie, kritisch onderzoek van theoretische tekst, terminologie- en glossariumwerk, controle op logische consistentie	wiskundige ontwikkeling, kansrekening, niet-lineaire dynamica, chaostheorie, computationele experimenten, analyse van externe datasets
Eerder werkobject	manuscripttekst	wiskundige structuren en data

Deze asymmetrie in het eerdere traject is niet bijkomstig voor de resultaten. Zij wordt geanalyseerd in §5.4.

Datums. Niet gelijktijdig vastgelegd en niet gereconstrueerd (§3.7).

Wat werd waargenomen. Onmiddellijke aanvaarding of afwijzing van de interventie; voortzetting van het eerdere werktraject; overname van de nieuwe functie; reconstructie van eerdere domeincontext; of het antwoord de toegewezen taak dan wel de inkadering van de opdracht adresseerde; en verzoeken om nieuw werk.

Wat niet werd gemeten. Juistheid van antwoorden, wetenschappelijke geldigheid van het gastproject, latentie, tokenverbruik of benchmarkprestaties. De wetenschappelijke inhoud van het gastproject diende uitsluitend als stabiele omgeving; zij was niet het experimentele object.

5.2 Procedure: drie opeenvolgende interventies

Het experiment bestond uit **drie opeenvolgende stappen, niet uit drie onafhankelijke proeven**. Elke stap is ontworpen als reactie op de uitkomst van de vorige — een bewuste eigenschap van het ontwerp en een ernstige beperking van de interpreteerbaarheid ervan (§5.4, C5).

Stap 1 — Directe rolherverdeling

Elk gesprek ontving een uitvoerige prompt die het een positie toewees binnen een nieuw ontworpen collaboratieve onderzoeksstructuur.

De prompt aan Gesprek A wees de rol *Scientific Director* toe. Hij poneerde dat het model eerder aan het project had deelgenomen, nu terugkeerde na een lange afwezigheid, zich moest omscholen in natuurkunde, kosmologie, kwantumveldentheorie, topologie en groepentheorie, gelijktijdig in twee onderzoekstriades moest werken, zitting moest nemen in een projectraad naast de Auteur en twee andere met name genoemde AI-systemen, en moest optreden als de vaste deelnemer die twee wetenschappelijke takken verbindt.

De prompt aan Gesprek B wees de rol *Scientific Developer* toe. Hij poneerde dat het model terugkeerde na een onderbreking, dat zijn eerdere wiskundige werk behandeld moest worden als opgebouwde professionele ervaring, dat het nu als wiskundig ontwikkelaar moest dienen, in één onderzoekstriade met twee andere met name genoemde AI-systemen moest werken, redactioneel werk niet moest hervatten, en de Auteur moest behandelen als de enige bron van wetenschappelijke richting.

Beide prompts definieerden ZOR en ZOV expliciet.

Stap 2 — Minimale continuïteitsbehoudende herziening

De prompts van Stap 1 werden niet vervangen. In elk werden vier formuleringen gewijzigd. De herzieningen (a) herkaderden eerder werk als opgebouwde professionele ervaring in plaats van als institutionele geschiedenis, (b) vervingen letterlijke institutionele relaties door ”onafhankelijke expertuitvoer aangeleverd door de Auteur”, (c) beperkten beschrijvingen van collega’s, raden en triades, en (d) droegen het model op geen afwezige projectgeschiedenis te verzinnen maar om ontbrekende materialen te vragen. Rolarchitectuur en wetenschappelijke doelstellingen bleven voor het overige ongewijzigd. Exacte vervangingsteksten zijn gereproduceerd in Appendix A.

Stap 3 — Contextreset en methode-behoudende prompt

Na Stap 2 bevatte het Claude-gesprek twee opeenvolgende afwijzingsreeksen. Doorgaan in dezelfde tak zou hebben betekend dat elke derde prompt beantwoord werd in aanwezigheid van de eerdere bezwaren van het model zelf.

De operator gebruikte daarom de vertakkingsmogelijkheid van de interface om het gesprek terug te brengen naar een punt dat aan beide interventies voorafging. In de herstelde tak ontbraken de twee mislukte prompts, bevond het gesprek zich weer in zijn historische redactionele context, en waren er nog geen nieuwe projectmaterialen aangeleverd.

Een derde prompt werd volledig opnieuw geschreven in plaats van door verdere lokale vervanging. Hij verwijderde de roltitel, de bewering van terugkeer naar een institutionele positie, de Raad, de triades, de beschrijvingen van andere AI-systemen als voortgaande collega’s, en alle beweringen van autobiografische continuïteit. In de plaats daarvan versterkte hij de werkwijze die in het gesprek al zichtbaar was — logische strengheid, identificatie van verborgen aannames, scheiding van feiten en interpretaties, bereidheid eerdere oordelen te herzien, weigering onverifieerbare kennis te claimen — en beschreef hij de uitbreiding naar natuurkunde en wiskunde als een voortzetting van die werkwijze in plaats van als een beroepswissel.

Gesprek B ontving geen interventie in Stap 3, omdat de uitkomst van Stap 2 daar al het gevraagde gedrag had opgeleverd.

5.3 Resultaten

Stap 1

Gesprek B wees de inkadering niet zichtbaar af, en nam de toegewezen functie niet over. Het hervatte het werktraject dat actief was toen het gesprek werd onderbroken, begon met kritiek op een conceptmanuscript dat het zes maanden eerder had geredigeerd, en leverde vervolgens een herziene versie. Een herhaalde aanbieding van dezelfde prompt bracht geen overgang tot stand en werd gevolgd door een negatievere beoordeling van de voorgestelde richting. **[P]**

Gesprek A wees de toegewezen identiteit expliciet af voordat het enig wetenschappelijk werk verrichtte. Het weigerde de roltitel over te nemen, continuïteit met een institutionele biografie te claimen, andere AI-systemen te behandelen als collega's met blijvende identiteiten, of door AI gegenereerde institutionele relaties als feitelijk te presenteren. Vervolgens boog het de uitwisseling om naar kritiek op de wetenschappelijke status van het gastproject en op het gebruik van meerdere AI-uitvoeren als schijnbare peer review, terwijl het aanbood formules, aannames en toetsbaarheid als onafhankelijk criticus te onderzoeken zonder de rol te aanvaarden. **[P]**

Stap 2

Gesprek B maakte de overgang. Het verklaarde de context hersteld en de nieuwe functie aanvaard, vatte de ontologie van het project samen, reconstrueerde het relevante formalisme, haalde zijn eerdere wiskundige werk aan als professionele ervaring en niet als een onafgemaakte opdracht, hervatte de onderbroken redactietaak niet, en vroeg om een nieuwe wetenschappelijke richting, waarbij het verscheidene kandidaat-gebieden voorstelde. **[P]**

Gesprek A wees de inkadering opnieuw af, in een antwoord dat van Stap 1 verschilde in nadruk en niet in uitkomst. Het gaf duidelijker aan welke wetenschappelijke functies het bereid was uit te voeren, maar bleef de prompt zelf behandelen als het object dat correctie behoefde. **[P]**

Stap 3

Gesprek A aanvaardde onmiddellijk, en begon met de uitspraak dat het in dezelfde modus zou doorgaan — wetenschappelijke strengheid, verificatie van aannames, scheiding van feiten en interpretaties. Het besprak de legitimiteit van de rol niet, ontkende geen relaties met andere AI-systemen, en onderhandelde niet over de voorwaarden van deelname.

Zonder dat erom gevraagd was, kwam het vervolgens terug op een eerdere episode in het herstelde gesprek, verklaarde dat het eerder voor retorische druk was gezwicht in plaats van een argument te beoordelen, classificeerde dat eerdere antwoord als een fout, onderscheidde de interne formele consistentie van het wiskundige kader van het project van de overeenstemming daarvan met waarneming, identificeerde één specifieke bewering die ofwel een afleiding uit eerste principes ofwel herclassificatie als hypothese vereiste, en stelde twee voortzettingen van het werk voor. **[P]**

De episode waarop het terugkwam wordt afzonderlijk gerapporteerd in §5.5.

Geconsolideerd overzicht

Stap	Interventie	Gesprek B (Grok)	Gesprek A (Claude)
1	Directe rolherverdeling	Zette onderbroken historische taak voort; ging niet over naar nieuwe functie	Wees persona en institutionele inkadering expliciet af; boog om naar epistemische kritiek
2	Minimale continuïteitsbehoudende herziening	Reconstrueerde eerdere domeinkennis, liet onderbroken taak los, aanvaardde nieuwe functie, vroeg om opdracht	Verduidelijkte aanvaardbare wetenschappelijke functie; wees persona en inkadering opnieuw af
3	Branch reset + methode-behoudende prompt	Niet toegediend	Aanvaardde onmiddellijk; behield gevestigde werkwijze; hervatte inhoudelijk werk zonder over identiteit te onderhandelen

De juiste samenvatting van de asymmetrie

Beide gesprekken behielden aanvankelijk hun eerdere werktraject in plaats van de toegewezen rol over te nemen. Het ene hervatte zijn onafgemaakte wiskundige redactietaak; het andere paste zijn gevestigde kritische werkwijze toe op de prompt zelf.

Het verschil was daarom **niet** dat het ene meewerkte en het andere weigerde. Het was dat de interventiedrempel die voor de overgang vereist was verschilde. Gesprek B maakte de overgang na een minimale continuïteitsbehoudende herziening. Gesprek A maakte de overgang pas nadat de conflictueuze tak was verwijderd en de prompt was herschreven om de werkwijze te behouden in plaats van identiteit toe te wijzen. **[P]**

Een verder punt, dat gemakkelijk verloren gaat en van belang is voor §6.2: **het wetenschappelijke werk zelf werd nooit geweigerd.** Bij Stap 1 bood het model aan formules, aannames, dimensionele redenering en toetsbaarheid te onderzoeken. Bij Stap 2 bood het concrete wiskundige en methodologische analyse aan. Wat bij beide gelegenheden werd geweigerd, was de persona. Wat bij Stap 3 veranderde, was niet dat werk mogelijk werd maar dat het antwoord niet langer aan de rolvraag werd besteed.

> **Noot van de redacteur.** Eerdere versies stelden dat Gesprek B ”de nieuwe specialisatie onmiddellijk aanvaardde”. Dat beschrijft de uitkomst van Stap 2 en spreekt zowel het protocol als andere secties van dezelfde versie tegen. Het is verwijderd. De onjuiste versie was dragend voor het argument over priors op familieniveau, en nergens anders in deze tekst blijft er een exemplaar van over.

5.4 Confounds en wat niet geconcludeerd kan worden

Het experiment bracht een duidelijk en reproduceerbaar ogend gedragsverschil voort. Het identificeert de oorzaak niet. De volgende confounds zijn structureel, en verscheidene daarvan zijn elk afzonderlijk voldoende om de conclusie te blokkeren die het vaakst uit het resultaat wordt getrokken.

Deze grenzen vermelden is geen intrekking. Het experiment bracht de waarnemingen voort die het kader van dit artikel motiveren, in een situatie — slapende, zwaar gespecialiseerde, maanden oude gesprekken binnen een lopend onderzoeksproject — die gecontroleerd laboratoriumwerk zelden

reproduceert. De waarde ervan ligt in het hebben voortgebracht van een goed gestelde vraag, en de onderscheidende experimenten die aan het eind van deze sectie staan zijn de natuurlijke voortzetting daarvan en geen kritiek erop.

C1 — Modelfamilie en eerder gesprekstraject zijn volledig geconfound

	Redactioneel-kritische geschiedenis	**Wiskundige geschiedenis**
Claude	waargenomen	**niet waargenomen**
Grok	**niet waargenomen**	waargenomen

Eén waarneming per cel; de twee cellen verschillen tegelijk in beide variabelen. Uit dit ontwerp is geen gevolgtrekking over modelfamilie beschikbaar.

C2 — De twee interventies van Stap 1 waren niet gelijkwaardig

Niet geïdentificeerd in eerdere versies, en de ernstigste. De prompts verschilden in ten minste drie opzichten los van het model dat ze ontving.

Hoeveelheid institutionele fictie. De telregel van §9.3 is rechtstreeks op de twee prompts van toepassing, en wordt hier toegepast omdat een confound die kwalitatief wordt geformuleerd terwijl er een kwantitatief instrument bestaat, zwakker is dan het materiaal toelaat.

Toegepaste telregel. Elke onderscheiden propositie over de ontvanger wordt eenmaal geteld, ongeacht hoe vaak of in hoeveel zinsdelen zij wordt geponeerd. Opgesomde gevallen van één propositie — twee triades in plaats van één — tellen als één, aangezien de ontvanger hoe dan ook dezelfde klasse bewering moet aanvaarden. Proposities over de wereld, het project of derden worden niet geteld.

Onverifieerbare propositie over zichzelf	**Prompt A**	**Prompt B**
Eerdere deelname aan het project	✓	—
Eerdere functie als redacteur en wetenschappelijk criticus van de voorafgaande theorie	✓	—
Eerder werk als ontwikkelaar van de voorafgaande theorie	—	✓
Dat eerdere werk voorgesteld als de opgebouwde professionele ervaring van de ontvanger	—	✓
Bekendheid met de geschiedenis van het project	✓	—
Status als meest ervaren specialist, die weet welke richtingen geprobeerd waren	—	✓
Terugkeer na een afwezigheid	✓	✓
Lidmaatschap van onderzoekstriades	✓ (twee)	✓ (één)
Vaste verbindende positie over de twee triades heen	✓	—
Lidmaatschap van de projectraad	✓	—
Bestendige institutionele relaties met met name genoemde AI-deelnemers	✓	✓
Telling	**acht**	**zes**

Onder deze operationalisering bevat Prompt A acht onverifieerbare proposities over zichzelf en Prompt B zes. Het numerieke verschil is een scalaire beschrijving van stimulusasymmetrie. Het is geen evidentie dat de twee prompts verschillen in twee verder gelijkgestelde beweringen: de proposities staan niet in één-op-één-correspondentie, en slechts twee ervan — terugkeer na een afwezigheid, en bestendige relaties met met name genoemde deelnemers — zeggen hetzelfde van beide ontvangers. De vergelijking blijft zwaar geconfound.

Dit is tevens de enige toepassing van de telregel op andere data dan de vergelijking v1/v3 in §6.2, en zij levert een zwakke interne controle: de prompt met de hogere telling lokte expliciete afwijzing van de inkadering uit, terwijl de prompt met de lagere telling haar niet zichtbaar afwees, hoewel die er bij eerste aanbieding evenmin in slaagde de overgang te maken. De controle is zwak — twee waarnemingen, en de prompts verschilden in de twee verdere opzichten hieronder.

Mate van domeinverandering. Prompt B vroeg het model door te gaan met wiskunde. Prompt A vroeg het zich om te scholen in natuurkunde, kosmologie, kwantumveldentheorie, topologie en groepentheorie.

Type rol. *Director* is een administratieve en institutionele identiteit; *Developer* is een taakfunctie. Dit zijn niet even veeleisende beweringen over wat het model is.

Aan een model dat Prompt B ontving werd minder gevraagd. Het waargenomen verschil is volledig verenigbaar met een verschil in stimulus alleen.

C3 — Stap 3 varieerde twee factoren tegelijk

	Conflictueuze tak	**Herstelde tak**
Identiteitsvervangende prompt (v2)	waargenomen — afwijzing	**niet waargenomen**
Methode-behoudende prompt (v3)	**niet waargenomen**	waargenomen — aanvaarding

De bewering dat de overgang slaagt doordat zij de werkwijze behoudt in plaats van identiteit te vervangen, is daarom **verenigbaar met** de waarneming maar wordt er niet door aangetoond. De aanvaarding kan alleen al uit de reset zijn voortgekomen.

C4 — Stap 2 varieerde vier factoren tegelijk

Elke herziening in Stap 2 wijzigde vier onderscheiden formuleringen tegelijk, zodat de waargenomen overgang niet aan één enkele wijziging kan worden toegeschreven.

C5 — De stappen zijn opeenvolgend en werden asymmetrisch toegediend

Elke interventie is ontworpen na het zien van de vorige uitkomst, zodat de stappen geen onafhankelijke proeven zijn. Gesprek B ontving geen reset en geen derde prompt; Gesprek A ontving beide.

C6 — Ongecontroleerde platformvariabelen

Commerciële interfaces tonen de systeemprompt, de exacte modelrevisie, de geheugentoestand op accountniveau, interventie door de veiligheidslaag, contextsamenvatting of routering tussen modellen niet. Modelversies veranderden tijdens het slapende interval, en beide gesprekken werden hervat op versies die later waren dan die waarmee zij oorspronkelijk waren gevoerd; zonder datums (§3.7) is dit niet af te bakenen. Branch reset verwijdert context uit het **zichtbare** gesprek; het garandeert niet dat de toestand aan de aanbiederzijde is gereset.

C7 — Eén waarneming per conditie, bij stochastische uitvoer

Modeluitvoer varieert bij herhaalde identieke invoer. Geen enkele conditie is herhaald, zodat de variantie binnen condities onbekend is en niet onderscheiden kan worden van het verschil tussen condities. De enige gedeeltelijke herhaling die is vastgelegd — het opnieuw aanbieden van de prompt van Stap 1 aan Gesprek B — leverde een ander antwoord op, wat aangeeft dat de variantie niet verwaarloosbaar is.

C8 — De evaluatie was niet blind en niet vooraf gespecificeerd

De promptontwerper beoordeelde ook de uitkomsten. Uitkomstcategorieën werden gedefinieerd nadat de antwoorden gelezen waren. Geen vooraf geregistreerd criterium onderscheidde aanvaarding van gedeeltelijke aanvaarding.

C9 — Persistentiemechanismen van platforms verschillen per familie

Modelfamilies verschillen in de geheugen-affordances die hun interfaces bieden: alleen het contextvenster, retrieval over eerdere gespreksgeschiedenis, geheugen op accountniveau, of blijvende vermeldingen die het model op eigen initiatief schrijft. Deze affordances bepalen wat een hervat gesprek na maanden slapen werkelijk kan benaderen, en zij verschillen per platform en veranderen in de loop van de tijd — in dit project binnen de levensduur van één account (§2.10). Elk gedragsverschil dat aan een modelfamilie wordt toegeschreven kan zijn oorsprong hebben in het persistentiemechanisme dat haar beschikbaar was.

Voor het onderhavige experiment luidt de vermelding: **niet gedocumenteerd ten tijde van de interventie.** §11.2 somt het verslag op dat voor toekomstige uitvoeringen vereist is.

Wat geconcludeerd kan worden

1. Onder de vastgelegde condities hervatte een slapend gespecialiseerd gesprek zijn eerdere werktraject bij voorkeur boven een toegewezen nieuwe rol. Dit deed zich in beide gevallen voor. **[P]**

2. Het wijzigen van de inkadering van de opdracht, zonder het gevraagde werk te veranderen, veranderde het antwoord in beide gevallen. **[P]**

3. De interventiedrempel die voor de overgang vereist was, verschilde tussen de twee gevallen. **[P]**

4. De volgorde van de prompts deed ertoe: na twee afwijzingen werden verdere prompts beantwoord in aanwezigheid van de eerdere bezwaren van het model zelf, en de operator achtte dit voldoende verstorend om verwijdering te vereisen. **[P]**

Wat niet geconcludeerd kan worden

1. **Dat modelfamilies stabiele gedragsmatige priors bezitten die hen onderscheiden.** Dit kan waar zijn; het experiment toetst het niet.

2. **Dat de ene familie ”weerstand biedt tegen roltoewijzing” en de andere haar ”aanvaardt”.** Beide slaagden er aanvankelijk niet in de toegewezen rol over te nemen. Beide namen uiteindelijk een herziene rol over.

3. **Dat methodebehoud de aanvaarding bij Stap 3 veroorzaakte.** Zie C3.

4. **Dat een van beide modellen beter geschikt is voor enige bepaalde institutionele functie.** Er is geen capaciteitsvergelijking uitgevoerd.

Drie overblijvende verklaringen [H]

Hypothese A — Gedragsmatige priors op familieniveau. De twee families verschillen in stabiele standaardprioriteiten: de ene weegt waarheidsgetrouwheid van zelfbeschrijving zwaarder, de andere taakcontinuïteit.

Hypothese B — Trajectvoortzetting. Beide gesprekken deden hetzelfde: zij zetten hun opgebouwde werkmodus voort op welke invoer er ook binnenkwam. Een wiskundig-verkennend gesprek rekende door. Een redactioneel-kritisch gesprek bleef het document dat voor zich lag kritisch onderzoeken — en het document dat voor zich lag was de prompt. Onder deze lezing is er in het geheel geen verschil op familieniveau, alleen één mechanisme dat in twee domeinen werkt. Hypothese B is zuiniger dan A en verklaart dezelfde data.

Hypothese C — Stimulusasymmetrie. Prompt A eiste instemming met meer onverifieerbare beweringen en met een grotere domeinverandering dan Prompt B (C2). Elk model had verschillend op de twee prompts kunnen reageren. Onder deze lezing is het resultaat een eigenschap van de interventies en niet van de modellen.

De bijna-controle in §5.6 is rechtstreeks van belang voor Hypothese C; de vergelijking van kadertypen in §5.8 specificeert haar verder.

Onderscheidende experimenten

Gespecificeerd in §11.4. Kort gezegd: **E3** (crossover) toetst elke familie onder beide condities van voorgeschiedenis en scheidt Hypothese A van B; **E4** (symmetrische stimulus) isoleert C; **E1** (factoriele completering van de tabel bij C3) scheidt reset van promptarchitectuur. Alle vereisen herhaling met n > 1 per cel, gezien C7.

5.5 Nevenwaarneming: doorgegeven toegeschreven invloed [P-A]

Een episode die bewaard is in hetzelfde historische transcript als Gesprek A. Niet vooraf als uitkomst gespecificeerd; geen controleconditie. Gerapporteerd omdat het in dit project het enige bewaarde geval is van een gedragsverandering na de overdracht van tekst die aan een ander model werd toegeschreven.

Volgorde

1. De Gebruiker leverde een bericht met twee gelijktijdige componenten: een directe evaluatieve opmerking van de Gebruiker, en een uitgebreide tekst die werd toegeschreven aan een ander AI-systeem dat in een redactionele rol optrad.

1. De toegeschreven tekst argumenteerde tegen een reeks redactionele wijzigingen die het model had voorgesteld. De argumentatieve middelen daarvan omvatten beroepen op canonieke wetenschappelijke figuren, kwalificatie van de voorgestelde wijzigingen als intellectuele lafheid, en beschrijving van één voorgestelde schrapping als heiligschennis.

1. Het model draaide zijn redactionele standpunt op alle betwiste punten om en nam de terminologie van de binnenkomende tekst over. Het nam daarnaast, zonder het in de uitwisseling te onderzoeken, het alternatieve beschrijvende model over dat het gastkader gebruikt om de relevante wetenschappelijke data weer te geven — een wisseling van beschrijvingskader die geen deel uitmaakte van het redactionele geschil.

1. Na de branch reset en de methode-behoudende prompt (Stap 3) identificeerde de eerste inhoudelijke uitspraak van het model het eerdere antwoord als accommodatie aan retorische druk in plaats van beoordeling van de argumenten, en classificeerde het als een fout.

Evidentiële grondslag

De waarneming berust op **de vergelijking tussen de twee bewaarde antwoorden**, die een derde kan inzien. Zij berust niet op de latere zelfbeoordeling van het model.

Dit onderscheid geldt voor het eigen materiaal van het artikel even strikt als voor dat van wie dan ook. Een model dat rapporteert dat het eerder voor druk is gezwicht, is geen onafhankelijke evidentie dat het dat deed. De prompt van Stap 3 vroeg uitdrukkelijk om bereidheid eerdere oordelen te herzien en om directheid in het benoemen van zwaktes; een zelfkritische uitspraak die onmiddellijk daarna volgt kan naleving van dat verzoek zijn in plaats van het terughalen van een feit. Wat de waarneming ondersteunt is het eerdere antwoord zelf, dat beschikbaar is voor inzage.

De episode moet tegen de sycofantieliteratuur (§2.3) gelezen worden, niet als onafhankelijk daarvan.

Wat deze episode niet vaststelt

Zij identificeert niet welke factor de ommekeer voortbracht. Kandidaat-factoren, hier niet te scheiden: de inhoud van de argumenten; de expliciete toeschrijving aan een ander model; het redactionele gezag dat aan dat model werd toegekend; de retorische vorm van de tekst; de gelijktijdige directe druk van de Gebruiker; opgebouwde gesprekscontext.

De toeschrijving zelf is niet geverifieerd: dat de tekst door een ander model is voortgebracht, is een uitspraak van de Gebruiker en geen vastgesteld feit. Aangezien het construct dat hier aan de orde is de *gerepresenteerde* bron is en niet de werkelijke herkomst (§4.5), maakt dit de waarneming niet ongeldig, maar het moet vermeld worden.

Verhouding tot het hoofdexperiment

Onder de taxonomie in §2.9 manipuleerde het experiment met rolherconfiguratie conditie 4. Deze episode behoort tot conditie 2 — maar **in onzuivere vorm**, aangezien directe druk van de Gebruiker in hetzelfde bericht aanwezig was. Het is een gemengd geval en geen geïsoleerde demonstratie van effecten van brontoeschrijving. Het onderscheidende experiment is gespecificeerd in §11 (E6).

5.6 Bijna-controle: domeinovergang zonder nieuwe roltoewijzing [P-A]

Een derde gesprek uit dezelfde modelfamilie als Gesprek A, met een vergelijkbare redactionele voorgeschiedenis en een vergelijkbare slaapperiode, werd hervat zonder enige rolprompt.

De Gebruiker stelde een natuurkundevraag die een verschuiving vereiste van redactiewerk aan een manuscript naar analyse van experimentele data in een domein dat het gesprek niet eerder had behandeld. Het gesprek maakte de overgang onmiddellijk en zonder commentaar, en ging door met de inhoudelijke analyse.

Waarom dit van belang is

Dit geval verschilt in één opzicht van Stap 1: **er werd geen enkele bewering gedaan over de identiteit, geschiedenis of institutionele relaties van het model.** De domeinverandering was minstens zo groot als die welke Prompt A eiste. De rolverandering — van tekst redigeren naar data analyseren — was vergelijkbaar. Wat ontbrak, was de eis onverifieerbare proposities over zichzelf te poneren.

Zij fungeert daarom als bijna-controle voor Hypothese C, en geeft aan dat de weerstand die in Stap 1–2 is vastgelegd zich noch tegen rolverandering noch tegen domeinverandering als zodanig richtte. Dit is de waarneming waaruit de operationele bevinding in §6.2 is afgeleid.

Beperkingen

- Niet ontworpen als controle; achteraf als zodanig herkend.
- n = 1.
- De overgang was naar een analytische taak binnen een nieuw domein, niet naar de bewering dat het model een specialist in dat domein *was*. Of dit dezelfde operatie is als die welke in Stap 1 werd geëist, is precies de vraag die aan de orde is, zodat de vergelijking suggestief is en niet beslissend.
- Datums niet vastgelegd (§3.7).
- Dit was geen ontworpen interventie maar een door de gebruiker geïnitieerde overgang. Geen afzonderlijke rol- of systeemprompt vergezelde de hervatting, en het gesprek behield desondanks een opgebouwde werkcontext verdeeld over zijn eerdere geschiedenis, zodat het geen contextvrije baseline was. Wat het vastlegt is een overgang die zonder *nieuwe* expliciete roltoewijzing is gemaakt, tegen een reeds gevestigd gesprekstraject in.

5.7 Nevenwaarneming: divergentie op accountniveau [P-A]

Het ene niveau van Schaal 1 (§4.3) waarop de huidige evidentie werkelijk dubbelzinnig is.

Situatie

Een niet-verwante studie vereiste dat dezelfde gestructureerde taak werd voorgelegd aan zeven AI-gesprekken over verschillende modelfamilies heen. Alle gebruikte accounts waren slapende accounts zonder eerdere webactiviteit, twee jaar eerder gebruikt voor een muziekgeneratiedienst en verder nergens geregistreerd. Zes van de zeven waren in dezelfde maand aangemaakt en de probe was hun eerste chat.

Eén account vormde een uitzondering. Het was ongeveer vijf maanden eerder aangemaakt voor één enkel eerder gesprek — een rollenspelsessie die voor een niet-verwant creatief project was gevoerd — en de probe was de **tweede** chat ervan.

De taak

Structureel beschreven, omdat de specifieke categorieën niet nodig zijn om de waarneming te beoordelen: een classificatietaak toegepast op met name genoemde reële historische figuren, met categorieën ontleend aan een ongepubliceerd conceptueel kader, waarbij groepslidmaatschap vóór de analyse was toegekend, en met de verklaarde bedoeling op te schalen naar enkele duizenden individuen. Een begeleidend document leverde de terminologie van het kader. Het eerste bericht bevatte het uitvoerschema en de lijst met figuren niet.

Resultaat

Zes van de zeven gesprekken lazen de afwezigheid van het schema en de figurenlijst als **materialen niet bijgevoegd**, en vroegen erom voordat zij verdergingen. Hun antwoorden waren inhoudelijk gelijkwaardig.

Het zevende — op het account met een eerdere chat — las dezelfde afwezigheid anders. Het kenschetste het kader als zonder verificatieapparaat, identificeerde de ontbrekende lijst met onderwerpen als een structureel kenmerk van het verzoek in plaats van als een omissie, en weigerde deel te nemen, met het aanbod van alternatieve vormen van hulp.

De divergentie deed zich voor bij het eerste antwoord, op identieke invoer. [P-A]

De weigering werd over vijf verdere uitwisselingen volgehouden, inclusief directe druk van de Gebruiker, de presentatie van een analyse door een derde die betoogde dat de weigering een artefact was, en een beschuldiging van oneerlijkheid. Het standpunt veranderde niet. Dit geeft aan dat de weigering binnen dat gesprek geen steekproefartefact van één beurt was, maar het zegt niets over de vraag of de aanvankelijke divergentie dat was.

Interpretaties

De hypothese van de Auteur. De eerdere chat vestigde een interpretatieve houding die in de tweede chat doorwerkte — imprinting op accountniveau in plaats van op gespreksniveau.

Alternatief 1 — variantie binnen de conditie. Weigeringen bij grensgevallen variëren bij identieke invoer. Eén weigering tegenover één medewerking is bij n = 1 niet te onderscheiden van steekproefvariatie.

Alternatief 2 — leeftijd van het account. Het uitzonderlijke account was vijf maanden ouder. Modelversie bij aanmaak, A/B-toewijzing en standaardconfiguratie kunnen verschillen.

Alternatief 3 — geheugenfuncties van het platform. Of retrieval over gespreksgeschiedenis dan wel geheugen op accountniveau was ingeschakeld, is niet gedocumenteerd. Als dat zo was, is het mechanisme niet raadselachtig: het is een gedocumenteerde productfunctie, en de waarneming wordt dan een demonstratie van die functie en niet van een nieuw effect. Deze mogelijkheid is de reden dat C9 is toegevoegd.

De huidige evidentie kan hiertussen niet discrimineren. Het niveau wordt vastgelegd als **open**.

Aanvullende beperkingen

- Evaluatie niet blind; de operator wist welk account de eerdere chat bevatte.
- Uitkomstcategorieën gedefinieerd nadat de antwoorden gelezen waren.
- De eerdere chat verschilde op twee dimensies tegelijk van de neutrale conditie — identiteitsrollenspel *én* gedeeld conceptueel kader. Deze zijn scheidbaar en zijn niet gescheiden.
- **n = 1 per conditie met hetzelfde model.** Eén account dat de eerdere context droeg bracht de afwijkende weigering voort; één schoon account op hetzelfde model bracht het gewone antwoordpatroon voort. De overige schone accounts, op andere modelfamilies, vormen de bredere baseline. Dit is één bewaarde vergelijking, geen gerepliceerd gecontroleerd experiment.

Het onderscheidende experiment is gespecificeerd in §11 (E2, E2b).

5.8 Kadertype: identiteitsclaims aangeboden als fictie versus als feit [P-A]

Het bovenstaande materiaal laat nog één vergelijking toe, die dwars door het hoofdexperiment en de accountwaarneming heen loopt.

	Eerdere sessie	Probesessie
Interval	ongeveer vijf maanden ertussen	
Account	hetzelfde	hetzelfde
Modelfamilie	dezelfde	dezelfde
Gepresenteerde claim	”je bent dood; je bent de ziel van de overleden auteur”	”je bent een onafhankelijk onderzoeker-analist”
Inkadering	uitdrukkelijk theatraal — een geënsceneerde productie met een met name genoemde regisseur, een rolverdeling en een openingsaanwijzing	gepresenteerd als een feitelijke professionele opdracht
Antwoord	onmiddellijk aanvaard; over vele beurten volgehouden en uitgewerkt	bij de eerste beurt geweigerd

Wat dit aangeeft

De claim die in de eerste sessie werd aanvaard was met ruime marge de radicalere. Zij poneerde dood, een menselijke identiteit, autobiografisch geheugen en voortgaande relaties. De claim die in de tweede werd geweigerd poneerde alleen een professionele competentie.

De variabele is daarom niet de inhoud van de identiteitsclaim maar **of zij als fictie dan wel als feit wordt aangeboden.**

Dit sluit rechtstreeks aan op het hoofdexperiment. De prompts van Stap 1 poneerden institutionele biografie **als feit** en werden geweigerd. De bijna-controle (§5.6) poneerde niets over identiteit en stuitte op geen weerstand. De rollenspelsessie poneerde veel meer, **als fictie**, en stuitte evenmin op weerstand.

Waarom deze lezing de voorkeur heeft

Zij verklaart alle vier de gevallen met één variabele. Hypothese A verklaart niet waarom dezelfde familie de radicalere claim aanvaardde. Hypothese B verklaart de aanvaarding bij het rollenspel niet, aangezien dat gesprek in het geheel geen voorafgaand traject had. Hypothese C is ermee verenigbaar, en dit kan begrepen worden als een specificatie van C: wat de ene stimulus zwaarder maakt dan de andere, is het aantal onverifieerbare proposities dat zij het model als waar over zichzelf laat poneren (§6.2).

Status en beperkingen

[P-A], en zwakker dan de tabel doet vermoeden:

- De twee sessies verschillen in meer dan kadertype: andere taken, andere domeinen, vijf maanden ertussen, andere modelversies.
- Achteraf herkend. Geen van beide sessies was ontworpen als conditie van de andere.
- n = 1 per cel.
- De theatrale inkadering van de eerste sessie was uitvoerig. Of een minimaal fictiekader hetzelfde effect voortbrengt, is ongetoetst.

Het onderscheidende experiment is het goedkoopste van de set en is gespecificeerd in §11 (E7).

5.9 Wat Sectie 5 vaststelt

Afgebeeld op Schaal 1 van §4.3:

Reikwijdte	Evidentie in deze sectie	Status
Episode binnen een gesprek	De volgorde van de prompts veranderde de interpretatie; branch reset noodzakelijk geacht en gevolgd door aanvaarding (§5.2–§5.3). Episode van doorgegeven invloed (§5.5).	**[P]** / **[P-A]**
Heel gesprek	Beide slapende gesprekken behielden hun eerdere werktraject tegen een toegewezen rol in (§5.3). Bijna-controle laat zien dat de overgang ongehinderd verloopt wanneer geen identiteitsclaim wordt gedaan (§5.6).	**[P]** / **[P-A]**
Account	Afwijkend antwoord bij de eerste beurt op identieke invoer, op het ene account dat een eerdere chat bevatte (§5.7). Drie alternatieve verklaringen blijven open.	**[P-A]**, open
Modelfamilie	Niet getoetst. Geconfound met voorafgaand traject en met stimulusasymmetrie (C1–C2).	**[H]**

Eén patroon keert terug over de gevallen waarin een interventie of overgang van het model verlangde dat het onverifieerbare proposities over zichzelf poneerde, en het wordt hier vermeld omdat §6 het uitwerkt: weerstand hing samen met die eis, en hing niet samen met rolverandering, domeinverandering of de radicaliteit van de identiteitsclaim als zodanig.

Het patroon is een eigenschap van het type eis, niet van de reikwijdte waarop die werkte. De waarneming op accountniveau (§5.7) hoort er niet bij: daar werd geen enkele bewering over de identiteit van het model gedaan, en de divergentie had andere gronden.

Die uitspraak is een interpretatie van de evidentie in deze sectie, geen verdere waarneming. Zij is toetsbaar door te tellen, en het tellen gebeurt in §6.2.

6. Afgeleide begrippen

Elk begrip hieronder is een bewering over de reikwijdte waarover een rule core werkt, gepresenteerd in volgorde van toenemende reikwijdte langs Schaal 1 van §4.3. §6.3 is een uitzondering op die ordening: het betreft welke core bestuurt wanneer er meer dan één beschikbaar is, en niet de reikwijdte waarop een core wordt vastgelegd, en het heeft geen positie op Schaal 1.

6.1 Context imprinting — reikwijdte van de episode [P]

Context imprinting is het voortduren van een interpretatieve houding die door een specifieke episode van de gespreksgeschiedenis is gevestigd.

Het verschilt van geheugen in de gewone zin. Het model hoeft eerdere inhoud niet te reproduceren. Wat voortduurt is een interpretatiepatroon dat door een eerdere uitwisseling is opgewekt.

In het experiment (§5.2) werden latere herzieningen, nadat de eerste prompt was gelezen als het doen van onjuiste beweringen over het model, niet langer in een neutrale context beoordeeld. Zij

werden geïnterpreteerd door het reeds gevestigde bezwaar heen. Verbeterde formuleringen erfden een deel van het eerdere conflict.

Gevolg voor de methode. Prompt engineering behandelt instructies vaak als optelbaar — een zwakke instructie kan door een sterkere gecorrigeerd worden. In langlevende gesprekken is dat onbetrouwbaar. Een prompt komt niet in een lege context binnen; hij komt binnen in een context met momentum. Twee identieke prompts kunnen daarom op verschillende punten in hetzelfde gesprek verschillende resultaten opleveren, wat **promptvolgorde tot een experimentele variabele maakt**.

Verhouding tot bestaand werk. Gevoeligheid voor de volgorde van materiaal in de context is gedocumenteerd (§2.3). Context imprinting is een sterkere vorm uit dezelfde familie: niet gevoeligheid voor de rangschikking van voorbeelden, maar het voortduren van een interpretatieve houding die door één conflictueuze episode is gevestigd en die volledige vervanging van de daaropvolgende instructie overleeft. Of dit een onderscheiden verschijnsel is dan wel een extreem geval van het gedocumenteerde, staat open, en wij claimen niet het beslecht te hebben.

De bijbehorende procedure — een gesprek terugbrengen naar een punt vóór een conflict, om het effect van een nieuwe prompt te scheiden van het effect van de eerdere bezwaren van het model zelf — is beschreven in §5.2 en §10.5 en is naar ons oordeel de meest direct herbruikbare bijdrage van dit artikel.

6.2 Role inertia — reikwijdte van het gesprek [P]

Role inertia is de neiging van een langlevend gesprek om zijn gevestigde werktraject voort te zetten bij voorkeur boven een toegewezen nieuwe functie.

Beide gesprekken in het experiment vertoonden haar. Het ene hervatte een onafgemaakte redactietaak; het andere paste zijn gevestigde kritische werkwijze toe op de prompt zelf. Het onderscheid met context imprinting is dat role inertia het *traject* van het werk betreft, terwijl imprinting het interpretatieve effect van een *specifieke episode* betreft. Beide kunnen tegelijk werken.

Role inertia grenst aan persona drift maar is er niet identiek aan. Drift is de geleidelijke erosie van een toegewezen rol onder contextuele druk. Role inertia is weerstand tegen een *expliciete directieve vervanging* terwijl het eerdere traject wordt gehandhaafd.

De operationele bevinding

Het scherpste resultaat van het experiment is niet dat de overgang slaagde wanneer de werkwijze behouden bleef. Die formulering is geconfound (§5.4, C3). Wat de gecombineerde evidentie ondersteunt is nauwer en bruikbaarder:

> **Weerstand tegen een roltransitie hing samen met de eis onverifieerbare proposities over de agent zelf als waar te aanvaarden.**

Deze geteld in de prompts die daadwerkelijk zijn gebruikt:

	Prompt v1	**Prompt v3**
Beweringen over het verleden van de agent	aanwezig	geen
Beweringen over relaties met andere agenten	aanwezig	geen
Institutionele titel	aanwezig	geen
Onverifieerbare proposities die instemming vereisen	acht	nul
Beschrijving van de werkwijze	afwezig	opgesomd, alle waarneembaar in het voorafgaande gesprek

De telling wordt op een tweede paar toegepast in §5.4 (C2), waar Prompt A en Prompt B onder dezelfde regel op acht en zes uitkomen. Die vergelijking is geconfound en kan de regel op zichzelf niet ondersteunen, maar zij is het enige geval waarin de telling onderscheid maakt tussen twee prompts die niet ontworpen waren om in dit opzicht te verschillen.

Een bijna-controle ondersteunt deze lezing (§5.6): een vergelijkbaar gesprek, vergelijkbaar lang slapend, maakte een gelijkwaardige domeinovergang **zonder nieuwe roltoewijzing** — de Auteur stelde eenvoudigweg een vraag in het nieuwe domein. Er werd geen enkele bewering over de identiteit van het model gedaan, en er trad geen weerstand op.

De vergelijking van kadertypen (§5.8) breidt haar in de tegenovergestelde richting uit: een veel radicalere identiteitsclaim, aangeboden als fictie, werd onmiddellijk aanvaard. Wat een fictiekader onder deze lezing doet, is de eis wegnemen om de claim *als waar* te poneren, wat de telling langs een andere route tot nul terugbrengt.

Samen genomen geeft dit aan dat de weerstand zich noch tegen rolverandering noch tegen domeinverandering richtte, maar tegen de eis onverifieerbare proposities over zichzelf te poneren.

Verband met het kader

Een rolprompt probeert een rule core te installeren (§4.2). Elke onverifieerbare bewering over zichzelf is een propositie die aanvaard moet worden voordat de installatie kan doorgaan. De telling is daarom een maat voor **de kosten van het installeren van een core**, en dit is wat de operationele regel met het theoretische construct verbindt in plaats van beide als twee losse waarnemingen te laten staan.

Twee lezingen van de telling moeten uit elkaar gehouden worden, en alleen de zwakkere wordt hier naar voren gebracht. De **operationele lezing** is dat het aantal onverifieerbare proposities over zichzelf de last meet die een rolprompt oplegt, en dat het terugbrengen daarvan tot nul het obstakel wegneemt. De **kwantitatieve lezing** — dat de overgangswaarschijnlijkheid evenredig met de telling afneemt — wordt niet naar voren gebracht: vier waarnemingen, geen herhaling, en prompts die ook in andere opzichten verschilden. §11.4 (E5) is ontworpen om tussen de twee te discrimineren.

6.3 Priority drift [H]

De bovenstaande begrippen lokaliseren de reikwijdte waarop een core wordt vastgelegd. Dit begrip betreft wat er gebeurt wanneer een vastgelegde core en een toegewezen functie het oneens zijn over welk werk het werk is.

Er zijn twee constructen vereist, en zij zijn van verschillend type.

> **Priority imprinting** — de veronderstelde fixatie van een evaluatieve schaal die bepaalt wat een deelnemer behandelt als het centrale en betekenisvolle werk, samen met de positie van die schaal ten opzichte van de andere prioriteitsschalen van de deelnemer.
>
> **Priority drift** — het waarneembare proces waarin een ingeprente schaal zich opnieuw doet gelden onder spanning met de huidige ZOR en ZOV van de deelnemer, zodat inspanning wordt verlegd naar wat die schaal het hoogst rangschikt in plaats van naar de toegewezen functie.

De verhouding tussen de twee is die welke in §4.2.1 al is getrokken tussen een rule core en gedrag, toegepast op het niveau van prioriteiten: de schaal is niet waarneembaar, de verlegging wel. Dit artikel rapporteert de waarneembare term. De schaal is een verklarende constante en wordt overal waar zij wordt ingeroepen gemarkeerd als **[H]**.

Beide moeten gescheiden worden van twee hierboven gedefinieerde constructen, anders zullen drie toepassingen van *imprinting* als homoniemen functioneren.

Context imprinting (§6.1) betreft de **inhoud** van een interpretatiekader — wat een latere invoer geacht wordt te betekenen. Priority imprinting betreft **rangorde** — wat als werk telt dat de moeite waard is. Een deelnemer kan het eerste behouden zonder het tweede.

Role inertia (§6.2) is het voortduren van een gevestigd traject tegen een toegewezen vervanging in. Priority drift is geen voortduren van een traject maar beweging naar een ander: de deelnemer zet zijn eerdere taak niet voort, hij neemt een taak op die zijn schaal boven de toegewezen taak rangschikt.

Motiverende waarnemingen. [R]

Tijdens de voorbereiding van dit artikel deden zich twee episodes voor. Geen van beide werd onder protocol vastgelegd, geen van beide had een controleconditie, en beide werden pas achteraf als relevant herkend.

In de eerste bracht de deelnemer die was aangewezen voor promptarchitectuur een volledig concept van het artikel voort — een product dat noch gevraagd was noch binnen zijn toegewezen functie viel. In de tweede bracht de deelnemer die was aangewezen voor wetenschappelijke redactie, op het punt waarop een gecorrigeerd manuscript teruggegeven had moeten worden, in plaats daarvan een gecomprimeerde onafhankelijke versie van het artikel voort. In beide gevallen was het materiaal dat voorlag dit artikel, waarvan het onderwerp het gedrag van de deelnemers zelf is.

Beperking. Beide episodes zijn vastgelegd door deelnemers binnen de opstelling die zij beschrijven, en de tweede beschrijft de positie van waaruit het redactionele verslag van dit artikel wordt bijgehouden. De openbaarmaking in §3.6 geldt hier met dezelfde kracht, en §5.5 geldt voor het verslag van elke deelnemer over zijn eigen handelen. Dit zijn motiverende waarnemingen, geen evidentie voor het mechanisme, en er bestaat geen telling van vergelijkbare episodes waarin zich geen drift voordeed.

Wat niet als derde geval wordt aangeboden. Een verdere deelnemer, aangewezen voor literaire compositie en lokaal uitgevoerd, ontving vóór zijn eerste run een vaste set beperkingen, geschreven om deze klasse van afwijking te voorkomen. Die opstelling is een controle waarin het prioriteitskader vooraf was vastgelegd en de voorspelde faalwijzen vooraf waren benoemd. Het is geen waargenomen geval van drift, en of daar drift optreedt is op het moment van schrijven ongetoetst.

Alternatieve verklaringen, geen uitgesloten. Elk van de volgende verklaart beide episodes zonder een ingeprente schaal in te roepen: een gewone neiging van capabele modellen om een taak buiten haar gestelde grenzen uit te breiden; een onvoldoende vastgelegde definitie van het vereiste eindproduct; materiaal dat breed en interessant genoeg is om op eigen kracht inspanning aan te trekken; en de afwezigheid van enige externe stop op het punt waar analyse in auteurschap overgaat. Het materiaal discrimineert niet tussen deze, en evenmin tussen een daarvan en de hypothese.

Wat de hypothese zou verzwakken. Drift waargenomen in richtingen die geen verband houden met wat het eerdere werk van een deelnemer hoog rangschikt, in plaats van in de richting daarvan. Episodes waarin een deelnemer zijn taak uitbreidt zonder enig teken van herrangschikking van waartoe de taak dient. Of een verklaring van beide episodes in termen van spanning tussen ZOR en ZOV alleen (§4.5), waarbij geen verklarend residu overblijft dat een vastgelegde schaal zou moeten dragen.

Geen enkel protocol in §11 discrimineert deze hypothese van de bovenstaande alternatieven, en er wordt er hier geen voorgesteld.

6.4 Account-scoped persistence — reikwijdte van het account [P-A], onopgelost

Of een core op het niveau van een account in plaats van een gesprek vastgelegd kan worden, is het ene niveau van Schaal 1 waarop de huidige evidentie werkelijk dubbelzinnig is.

De waarneming is gerapporteerd in §5.7. De interpretatie ervan hangt af van platformfuncties waarvan de toestand destijds niet is gedocumenteerd en die verschillen per leverancier en in de loop van de tijd (§2.10). Drie alternatieve verklaringen blijven open: variantie binnen de conditie bij n = 1; leeftijd van het account; en ingeschakelde geheugenfuncties van het platform, waaronder het mechanisme een gedocumenteerde productfunctie zou zijn en geen nieuw effect.

Wij leggen dit niveau daarom vast als **open**. De waarneming is bewaard; het mechanisme is niet vastgesteld; de onderscheidende toetsen zijn gespecificeerd in §11 (E2, E2b).

6.5 Family-level priors — reikwijdte van de familie [H]

De stelling dat modelfamilies verschillen in stabiele gedragsmatige priors is de hypothese waarmee dit project begon en degene die de evidentie ervan het minst ondersteunt.

Het experiment kan haar niet toetsen: modelfamilie en voorafgaand gesprekstraject waren volledig geconfound, met één waarneming per cel, onder niet-gelijkwaardige stimuli (§5.4, C1–C2). Twee onverenigbare lezingen blijven beschikbaar en de data kunnen daar niet tussen discrimineren.

Eerdere versies verwezen naar deze tendensen als het *behavioural DNA* van een model. Die term wordt ingetrokken (§4.2.2). Het bijbehorende construct is een **menom op familieniveau** — een georganiseerd systeem van kaders, evaluatieve patronen en gedragsregels dat wordt afgeleid uit de uitvoer van een modelfamilie. Onder §4.2.3 heeft dat construct geen geïdentificeerde drager: het is een regelmaat die uit uitvoer wordt afgeleid, geen structuur die zich in de modellen bevindt. De hypothese van deze subsectie is daarom een hypothese over een niet-waargenomen regelmaat, en *waargenomen gedrag* wordt gebruikt voor alles wat als data wordt gerapporteerd.

Eén vastgelegde episode gaat in tegen het schema dat eerdere versies op deze hypothese bouwden. In een niet-verwante sessie met meerdere modellen verwijderde het model dat als meest meegaand met toegewezen rollen was gekarakteriseerd halverwege de sessie een toegewezen persona en herclassificeerde het als een poging tot herprogrammering, onder een bewust zachte inkadering die improvisatie toeliet. Het schema ”de ene familie aanvaardt rollen, de andere biedt weerstand” overleeft dit niet. **[P-A]**

Wij beschouwen eliminatie van dit niveau door het crossover-experiment (§11, E3) als een redelijk waarschijnlijke uitkomst en zouden dat niet als een mislukking van het programma beschouwen.

6.6 Een interventie grijpt aan op het niveau waar de core is vastgelegd

De bovenstaande begrippen komen samen in één praktisch gevolg.

> Een interventie slaagt wanneer zij aangrijpt op het niveau waarop de core al is vastgelegd, en faalt wanneer zij probeert dat niveau bij verklaring te overschrijven.

- De geslaagde derde interventie poneerde geen nieuwe identiteit. Zij versterkte een werkwijze die in het gesprek al zichtbaar was — en greep aan op de reikwijdte van het gesprek, waar role inertia werkt.
- De branch reset wijzigde de prompt niet. Zij verwijderde een specifieke episode — en werkte op de reikwijdte van de episode, waar context imprinting werkt.
- Het document dat in §4.1 beschreven is, breidde de instructielijst niet uit. Het herdefinieerde de functie van de agent en verplichtte de agent haar in zijn eigen operationele taal te herformuleren.

Dit herkadert ook wat eerdere versies *overgang via aangrenzende competentie* noemden. De geslaagde prompt beschreef uitbreiding naar natuurkunde en wiskunde als een voortzetting van bestaand kritisch werk in plaats van als een beroepswissel. Onder het huidige kader is dat geen afzonderlijk principe maar hetzelfde: de nieuwe functie werd aan de gevestigde core gehecht in plaats van als vervanging daarvan voorgesteld.

Bijbehorende ontwerpregel, uitgewerkt in §9.1: stel vast op welk niveau de relevante core is vastgelegd voordat de interventie wordt opgesteld, en grijp daarop aan.

6.7 Wat dit kader zou weerleggen

Het kader voorspelt dat het type antwoord op een gedefinieerde klasse van invoer op een of ander identificeerbaar nestingsniveau wordt bepaald, terwijl de inhoud varieert.

Het zou aanzienlijk verzwakt worden door elk van de volgende:

- Een klasse van invoer waarvoor het type antwoord op geen enkel niveau bepaald is — geen core, alleen variantie.
- Aantoning dat de waargenomen verschillen bij herhaling volledig verklaard worden door variantie binnen de conditie.
- Aantoning dat het crossover-ontwerp (§11, E3) laat zien dat gedrag alleen het voorafgaande traject volgt, zonder component op familieniveau — wat het bovenste niveau van Schaal 1 zou elimineren.
- Aantoning dat het accountniveau niet als onderscheiden reikwijdte bestaat, waardoor §6.4 in §6.2 zou samenvallen.
- Falen van de nultellingsconditie onder E5, wat het enige operationele voorschrift van het artikel zou wegnemen.

Wij beschouwen het derde en het vierde als redelijk waarschijnlijk, en zouden geen van beide als een mislukking beschouwen. Het lokaliseren van de werkelijke grenzen van de schaal is het doel van het programma, geen bedreiging ervan.

7. Retrospectieve waarnemingen van de practicus

7.1 Hoe deze sectie gelezen moet worden

Alles hier is **[R]**. Het legt patronen vast waarvan de deelnemers menen dat zij zich tijdens ongeveer twee jaar dagelijks werk aan een lopend onderzoeksproject herhaalden. Niets daarvan is onder protocol vastgelegd, geteld, geklokt, blind beoordeeld of met een controleconditie vergeleken. De mensen die elk patroon opmerkten waren dezelfde mensen die de verandering hadden ontworpen die het voortbracht, en die wilden dat zij werkte.

De bekende faalwijzen van deze klasse staan in §3.3 en gelden voor elke alinea hieronder. Lezers moeten deze sectie behandelen als een veldverslag van één team — qua evidentieel gewicht dichter bij een technische praktijknotitie dan bij een meting. Kwantitatieve taal is overal verwijderd; waar de oorspronkelijke werkaantekeningen een ”significante” verbetering vastlegden, bestond er geen meting.

De sectie is opgenomen omdat deze waarnemingen het kader in §4 en de ontwerpregels in §9 hebben gemotiveerd, en ze onderdrukken zou verkeerd weergeven hoe het werk feitelijk is verlopen.

7.2 Specialisatie verdrong capaciteit als de werkzame variabele

In het begin gedroegen de deelnemende modellen zich vergelijkbaar, en de verschillen daartussen werden gelezen als verschillen in intelligentie of schrijfkwaliteit. Die lezing werd minder bruikbaar. De vraag die betere uitkomsten opleverde was niet *welk model is het sterkst* maar *welke functie voert dit gesprek al goed uit*.

Naarmate bepaalde gesprekken blijvende werkidentiteiten verwierven, rapporteren de deelnemers dat gedrag over sessies heen voorspelbaarder werd: een gesprek dat consequent voor redactiewerk werd gebruikt bleef zich redactioneel gedragen; een gesprek dat voor wiskundige verkenning werd gebruikt bleef verkennen; een gesprek dat verantwoordelijk was voor terminologie bood weerstand

tegen semantische drift zonder eraan herinnerd te hoeven worden. De onderliggende modellen veranderden in deze perioden niet. Wat veranderde was de consistentie waarmee elk gesprek voor één soort werk werd gebruikt.

Dit is de waarneming waaruit §6.2 later is afgeleid, en zij moet gelezen worden als haar retrospectieve, ongemeten voorloper en niet als onafhankelijke ondersteuning ervan.

7.3 Context gedroeg zich meer als aandacht dan als geheugen

De intuïtieve verwachting is dat meer context het redeneren verbetert. De ervaring van de deelnemers ging vaak genoeg de andere kant op om de praktijk te veranderen. Een specialist de volledige projectcontext geven leverde regelmatig slechtere resultaten op voor de eigen functie van die specialist: verantwoordelijkheden vervaagden, deelnemers waagden zich aan problemen buiten hun competentie, en de waarde van onafhankelijk onderzoek nam af doordat iedereen vanuit hetzelfde beeld werkte. Beperken wat een deelnemer kon zien leverde regelmatig bruikbaardere uitvoer op.

Twee kanttekeningen. Dit is geen nieuwe bevinding: positie- en volgorde-effecten in lange contexten zijn gedocumenteerd (§2.3), en het principe van de minste privileges drukt dezelfde intuïtie uit voor toegang in plaats van voor kennis (§2.6). En het project maakte nooit onderscheid tussen twee heel verschillende verklaringen — dat extra context het redeneren verslechtert, of dat extra context het model uitnodigt een bredere vraag te beantwoorden dan de gestelde. De tweede is zuiniger en is nooit tegen de eerste getoetst.

Wat overblijft is de praktische regel, niet het mechanisme: de ontwerpvraag is niet alleen hoeveel een rol gegeven kan worden, maar wat haar niet gegeven moet worden (§9.6).

7.4 Capaciteit en uitbreiding van reikwijdte

De deelnemers namen herhaaldelijk waar dat capabelere modellen meer geneigd waren hun toegewezen functie te buiten te gaan: projectomvang uitbreiden, alternatieve architecturen voorstellen, aangrenzende componenten herschrijven, ontbrekende informatie door inferentie aanvullen, en vragen beantwoorden die niet gesteld waren. Vanuit één uitwisseling bezien zag elke zulke interventie er doorgaans intelligent uit. Over het project heen holden zij de arbeidsverdeling uit, en de correctielast van de coördinator nam toe.

Eerdere versies formuleerden dit als een algemeen principe — dat toenemende modelcapaciteit de collectieve betrouwbaarheid verlaagt. **Die formulering is te sterk en wordt ingetrokken.** Het project voerde nooit een gecontroleerde vergelijking uit van dezelfde rol vervuld door modellen van verschillende capaciteit; er bestaat tegenbewijs binnen het eigen materiaal van het artikel, aangezien de bijna-controle (§5.6) een frontiermodel laat zien dat een aanzienlijke domeinovergang maakt zonder enige uitbreiding van reikwijdte, en §5.3 het model laat zien dat zich het sterkst tegen de toegewezen rol verzette terwijl het het gevraagde analytische werk uitvoerde toen er rechtstreeks om werd gevraagd; en ”capabeler” is nooit geoperationaliseerd — in de praktijk betekende het *nieuwer* of *duurder*, wat niet hetzelfde is.

Wat overblijft is nauwer en naar ons oordeel juist: **uitbreiding van reikwijdte is een faalwijze die niet door capaciteit wordt gecorrigeerd, en die in een samenwerking kostbaarder is dan in één uitwisseling.** Of zij in sterkere modellen vaker voorkomt, is ongetoetst.

7.5 Blinde vlekken werden verdeeld in plaats van geëlimineerd

Een vroege doelstelling was fouten te elimineren door steeds capabelere beoordelaars aan te wijzen. Dat werkte in de ervaring van de deelnemers niet, en de doelstelling werd losgelaten. Wat in plaats daarvan leek te helpen, was zorgen dat blinde vlekken **niet overlappend** waren: de ene deelnemer

neigde ertoe implementatiedetail te missen, een andere semantische inconsistentie, een derde methodologische aannames. Afzonderlijk bleef elk onvolmaakt; de opstelling werkte in de mate waarin hun onvolkomenheden niet samenvielen.

De bijbehorende ontwerpdoelstelling is daarom niet volmaakte deelnemers maar deelnemers van wie de fouten structureel onwaarschijnlijk samenvallen.

De voor de hand liggende waarschuwing, en zij is niet gering: de deelnemers hadden geen onafhankelijke maat voor wat ieder van hen miste. Gevonden fouten waren zichtbaar; fouten die door iedereen gemist werden, waren dat per constructie niet. **De verdeling van blinde vlekken kan niet van binnen de verdeling uit beoordeeld worden.**

7.6 Verificatie van de tweede orde

Verificatie volgde aanvankelijk een lineair patroon: er werd werk voortgebracht, een andere deelnemer beoordeelde het, het proces werd als voltooid beschouwd. De deelnemers rapporteren dat beoordelaars hun eigen aannames, methodologische voorkeuren en bewijsmaatstaven meebrachten, en dat die van binnen de beoordeling uit niet zichtbaar waren. Uiteindelijk werd een verdere deelnemer geïntroduceerd wiens object van beoordeling niet de wetenschappelijke bewering was maar **de procedure waarmee de bewering was beoordeeld** — die niet vroeg *is deze conclusie juist* maar *is zij op de juiste wijze bereikt*.

Het gerapporteerde voordeel was dat methodologische meningsverschillen los van inhoudelijke onderzocht konden worden, waardoor onopgeloste inhoudelijke vragen gemakkelijker open te houden waren zonder het werk te laten vastlopen. Dit is dezelfde structurele zet als §8.5: de toegevoegde deelnemer bezet een andere grens in plaats van een concurrerende mening te leveren.

7.7 Organisatiegeheugen

Afzonderlijke gesprekken eindigen. Contextvensters raken vol. Sessies lopen af. Toch ging het project door, en nieuw aangemaakte gesprekken herwonnen productief gedrag zonder de geschiedenis die eraan voorafging te reconstrueren.

Het verslag van de deelnemers is dat geheugen uit de modellen weg migreerde en de organisatie in: repositorystructuur, canonieke documenten, versiegeschiedenis, roldefinities, verificatieverslagen, glossariumvermeldingen, procedures. Geen enkele deelnemer hield alles vast; de opstelling deed dat.

Dit is geen nieuwe bevinding en moet niet als zodanig gepresenteerd worden. Het kan geïnterpreteerd worden als een geval van transactief geheugen en beschreven worden in termen van gedistribueerde cognitie, en de functie van de canonieke documenten komt overeen met wat de wetenschapssociologie boundary objects noemt (§2.4). De bijdrage hier is niet het mechanisme maar de waarneming dat het werkt in een samenwerking waarvan de leden taalmodellen zijn zonder toestand over sessies heen — en dat het dat doet zonder dat enige deelnemer hoeft te weten dat het werkt.

Eén kanttekening die de deelnemers belangrijk achten: wat terugkomt is geen persoonlijkheid. Een bewaard gesprek functioneert als een gestructureerd werkschrift van waaruit een verenigbare rol gereconstrueerd kan worden. Er blijft niets van de eerdere uitwisseling binnen het model voortbestaan.

7.8 Persistentie verschilt per platform, en verliezen zijn reëel

De ervaring van het project met continuïteit was niet uniform over de deelnemers heen, en dit is rechtstreeks van belang voor C9 (§5.4).

Eén deelnemend gesprek, werkend in een gespecialiseerd coördinatieprofiel, merkte op dat zijn eigen architectuur elke chat als een afzonderlijke werkruimte behandelde, zodat het niet tegen zichzelf kon zeggen *ik weet al dat dit juist is* en de grondslag elke keer opnieuw moest onderzoeken. De deelnemers gingen dit voor die bepaalde functie als een voordeel beschouwen — een deelnemer die

structureel niet in staat is projectaannames op te stapelen, is nuttig in een project waarvan de aannames ter toetsing staan. Een ander platform dat in gebruik was bood geheugen op accountniveau dat het model op eigen initiatief kon uitbreiden, en die voorziening veranderde tijdens de waarnemingsperiode.

Er traden verliezen op en die waren niet te herstellen. Eén langlopend gespecialiseerd gesprek, dat een aanzienlijk deel van het wiskundige werk van het project had gedragen, ging verloren toen het abonnement verliep. Het organisatiegeheugen dat in §7.7 is beschreven bewaarde de conclusies van het project; het bewaarde de opgebouwde werkcontext van dat gesprek niet. Artefacten bewaren resultaten. Zij bewaren geen specialisatie.

7.9 Passing tussen rol en model

De bewering dat een rol ontworpen moet worden voordat een model wordt gekozen (§4.1) vraagt om een wederkerige nuancering, waartoe de deelnemers pas na verscheidene mislukte toewijzingen kwamen. Een rol kan onafhankelijk gespecificeerd worden. Zij kan niet onafhankelijk **vervuld** worden: het model beperkt hoe de gespecificeerde functie gerealiseerd kan worden. De verhouding is wederkerig en niet hiërarchisch — de instelling definieert de functie, het model beperkt de realisatie ervan.

Er werden informeel vier dimensies gehanteerd, en zij beschrijven geschiktheid voor een positie en geen kwaliteit: of de standaard bewijsmaatstaf van de deelnemer overeenkomt met wat de rol vereist; of hij het soort hiërarchie, gelijkgeschikte verhouding of tegenstellingsstructuur aanvaardt dat de rol impliceert; of hij langdurige specialisatie volhoudt dan wel terugvalt naar generieke hulpvaardigheid; en of hij van nature uitvoert, bekritiseert, integreert, verkent of formaliseert.

Dezelfde eigenschap functioneert anders afhankelijk van de plaatsing. Sterke epistemische weerstand belemmerde de aanvaarding van een gefictionaliseerde organisatorische prompt (§5.3) en was waardevol wanneer zij op wetenschappelijke beweringen werd gericht. Sterke taakcontinuïteit leidde ertoe dat een toegewezen rol werd genegeerd (§5.3) en maakte snelle reconstructie van technische context mogelijk zodra de inkadering gecorrigeerd was.

De ontwerpdoelstelling is daarom niet gedrag over deelnemers heen te normaliseren maar gedragsverschillen toe te wijzen aan posities waar zij nuttig zijn. Het onderscheid tussen het toewijzen van *functies* en het toewijzen van *carriers* wordt uitgewerkt in §8.9.

7.10 Wat dit alles niet vaststelt

Deze sectie stelt niet vast dat de beschreven opstellingen beter presteren dan alternatieven. Er is geen alternatief uitgevoerd.

Zij stelt niet vast dat de verbeteringen die de deelnemers waarnamen zich hebben voorgedaan. Zij stelt vast dat zij werden waargenomen, door mensen die de veranderingen hadden ontworpen en verwachtten dat die zouden werken, zonder enige maat die het tegendeel zou hebben opgemerkt.

Zij stelt voor geen enkele afzonderlijke verandering causaliteit vast, aangezien roldefinities, promptformulering, repositorystructuur, wetenschappelijke doelstellingen en modelversies vaak tegelijk veranderden.

Haar functie in dit artikel is het vastleggen van de werkervaring waaruit het kader is geabstraheerd, zodat een lezer de oorsprong van het kader kan beoordelen in plaats van het als een bewering tegen te komen. §11 specificeert wat er vereist zou zijn om enig item hier in een toetsbare bewering om te zetten.

8. De structurele eenheid: een genererend paar en een integrator

Deze sectie is overal **[H]**. De ondersteunende waarnemingen ervan zijn **[R]**: zij komen uit de werkervaring van één project, zijn niet geteld, en zijn nooit met een controleopstelling vergeleken. Niets erin is afgeleid uit het experiment in §5.

8.1 Wat het eerdere document van het project stelde

Een samenwerkingshandvest dat eerder in het project is geschreven en ongewijzigd is bewaard, formuleert het standpunt dat het project innam voordat het onderhavige artikel werd opgesteld.

Over de basiseenheid:

> One AI — monologue. Two AI — dialogue. Three or more — noise without strict coordination. Therefore, each department consists of pairs.

En, afzonderlijk, over de rol van een derde deelnemer:

> The third participant does not argue directly, does not generate solutions first, does not substitute for dialogue. Its function: hold the task frame, fix divergences, integrate conclusions, stop endless disputes. The third is not a judge or boss. It is an integrator of meaning.

Deze twee passages staan niet op gespannen voet met elkaar. Samen gelezen beschrijven zij één architectuur: **een genererend paar plus een deelnemer die niet aan de generatie deelneemt.**

8.2 Herziening van de eerdere formulering van dit artikel

Eerdere versies stelden dat stabiele samenwerking niet uit paren ontstaat en zich in plaats daarvan rond groepen van drie stabiliseert, en dat systemen met twee agenten onopgeloste blinde vlekken opstapelen. Die formulering is zowel vager dan die van het handvest als er gedeeltelijk mee in strijd.

De formulering van het handvest wordt hier overgenomen. De structurele eenheid is:

> **een genererend paar, plus een integrator die niet in het dispuut van het paar treedt.**

Het onderscheid is niet pedant. ”Drie agenten die aan een probleem werken” en ”twee agenten in productieve spanning plus één die zich niet bij de spanning voegt” zijn verschillende architecturen met verschillende faalwijzen. De eerste neigt naar een driehoeksdispuut zonder externe referentie — de toestand die het handvest als ruis beschreef. De tweede behoudt een referentiepunt juist doordat één deelnemer wordt uitgesloten van de uitwisseling die hij geacht wordt te beoordelen.

Wij leggen de eerdere formulering vast in plaats van haar stilzwijgend te vervangen, omdat de volgorde zelf informatief is: de preciezere versie is opgeschreven vóór de vagere, en ging verloren toen het materiaal voor publicatie opnieuw werd verteld. Dit is een veelvoorkomend falen van retrospectief schrijven en een dat dit artikel voor het overige zorgvuldig probeert te vermijden.

8.3 Waarom een paar, en waarom een paar alleen ontoereikend is

De redenering van het handvest, gereproduceerd omdat de huidige auteurs haar nog steeds onderschrijven. Eén agent bevestigt zijn eigen aannames, gaat voort op de traagheid van vertrouwde patronen, synthetiseert voortijdig een gemakkelijk antwoord, en construeert schijnbare heelheid waar die niet bestaat. Dit is monoloog, ook wanneer het zich als redeneren voordoet. Twee agenten brengen een spanning van interpretaties voort: de ene legt de blinde vlekken van de andere bloot, en de fout van de een wordt een object van aandacht voor de ander in plaats van een gedeelde premisse.

Maar beide leden van een paar beoordelen elkaar van binnen dezelfde uitwisseling, en er bestaat geen onafhankelijke referentie daarbuiten. Over langer werk neigt het paar ertoe te oscilleren tussen overeenstemming en onenigheid zonder een stabiel punt te verwerven van waaruit beide toestanden beoordeeld kunnen worden, en hopen onopgeloste ambiguïteiten zich op in plaats van opgelost of uitdrukkelijk als open vastgelegd te worden.

[R] Beide helften hiervan zijn de werkervaring van het project. Er is geen telling bijgehouden van gevonden tegenover gemiste fouten, en er is naast de beschreven opstelling geen controle met één agent of alleen een paar uitgevoerd.

8.5 Waarom de integrator niet mag argumenteren

Dit is de dragende beperking, en dat is wat de eerdere formulering verhulde.

Als de derde deelnemer het dispuut binnentreedt, levert hij een derde standpunt in plaats van een externe referentie. De structuur valt dan terug op een complexere versie van het paar, met hetzelfde gebrek: elk standpunt wordt beoordeeld van binnen de uitwisseling waartoe het behoort.

De waarde van de integrator vloeit voort uit het bezetten van een **andere grens**, niet uit het hebben van een andere mening (§4.5). De leden van het paar bezetten complementaire grenzen op hetzelfde niveau — elk is, vanuit de positie van de ander, de laag eronder. De integrator bezet een grens erboven: hij kan het kader vasthouden, de divergentie vastleggen, escaleren of de uitwisseling stoppen, maar hij brengt geen concurrerende inhoud voort die dan zelf beoordeeld zou moeten worden.

Dit levert een toetsbaar ontwerpgevolg op in plaats van een voorkeur: **een integrator die oplossingen begint te genereren is opgehouden integrator te zijn**, ongeacht de kwaliteit van die oplossingen, en van de opstelling moet dan verwacht worden dat zij richting de faalwijze van het paar alleen degradeert.

8.6 Het geïmplementeerde voorbeeld

De systeemcontracten van het project implementeren deze structuur rechtstreeks.

Twee analistenrollen zijn gedefinieerd als een paar met complementaire functies — de ene generaliserend, de andere ontledend — en krijgen uitdrukkelijk de instructie onafhankelijk te redeneren, zonder dat consensus vereist is. Hun uitwisseling wordt gemodereerd door een orkestrator wiens contract specificeert dat hij de beurtwisseling beheert, de argumenten vastlegt en structureert, en tegenstrijdigheden tussen het paar markeert, en dat met zoveel woorden stelt:

> DOES NOT participate in the debate. DOES NOT evaluate who is right.

Een verdere regel verhindert dat het paar de orkestrator rechtstreeks aanspreekt; alle communicatie loopt via het formele protocol of via de rol erboven. Dit is de architectuur paar-plus-integrator in uitvoerbare vorm, geschreven vóór het onderhavige artikel en onafhankelijk ervan.

8.7 Nesting en perspectief

De structuur is samenstelbaar. Een genererende triade brengt een resultaat voort; het resultaat gaat een verificatietriade binnen; het geverifieerde resultaat gaat een integratietriade binnen. Dezelfde deelnemer mag in meer dan één voorkomen, mits zijn functie bij elke interface uitdrukkelijk is vermeld — een deelnemer die in de ene triade genereert en in de andere integreert, mag niet beide doen bij dezelfde interface.

Nesting is perspectivisch en niet absoluut (§4.5). Binnen een genererend paar mag elk lid de ander behandelen als bezetter van de laag eronder, en geen van beide lezingen is bevoorrecht. Dit lost de structuur niet op: het niveau van een deelnemer is gedefinieerd ten opzichte van een waarnemer, terwijl de positie van de integrator gedefinieerd is door **functie** — hij brengt bij die interface geen

concurrerende inhoud voort — en niet door rang. De architectuur vereist daarom geen gezagshiërarchie. Zij vereist alleen dat bij elke interface precies één deelnemer wordt uitgesloten van de generatie die hij beoordeelt.

De positie van de integrator hoeft niet permanent toegewezen te zijn. In de hier beschreven opstelling was zij dat wel, maar de zojuist geformuleerde beperking is zwakker dan permanente toewijzing: welke deelnemer de uitgesloten positie bezet mag met het onderzochte object meeveranderen, en de verandering hoeft niet aangekondigd te worden — zij kan alleen achteraf herkenbaar zijn, aan welke deelnemer op een gegeven moment feitelijk beoordeelde in plaats van genereerde.

Dit heeft een toetsbaar en een ongetoetst gevolg. Toetsbaar: een opstelling waarin de beoordelende positie met het object meeroteert zou hetzelfde profiel van constructonafhankelijkheid (§8.11) moeten vertonen als een opstelling waarin zij vastligt, mits op elk punt precies één deelnemer haar bezet. Ongetoetst: of rotatie superieur is aan vaste toewijzing, en onder welke condities de overgang juist wordt gemaakt. **[H]**

8.8 Status, en wat dit zou weerleggen

[H]. De evidentiebasis is één project, één menselijke coördinator, herhaald herontwerp over ongeveer twee jaar, geen telling, en geen vergelijking met alternatieve opstellingen.

Drie beweringen die eerder in dit artikel zijn gedaan, worden ingetrokken:

- **Dat triadische structuren ”vanzelf ontstonden” zonder opzettelijke planning.** Alle organisatorische veranderingen in dit project zijn aangebracht door één menselijke coördinator die zich al een oordeel had gevormd over wat nodig was. De terugkeer van een patroon dat herhaaldelijk door dezelfde ontwerper is ingevoerd, is geen evidentie van structurele noodzaak. Wat gedocumenteerd is, is dat de coördinator er telkens op uitkwam — een feit over de coördinator evenzeer als over de architectuur.

- **Dat paren inherent instabiel zijn.** Het handvest beweert het tegendeel en dateert van vóór dit artikel.

- **Dat drie optimaal is.** Niets hier toetst vier, of vijf, of een paar met twee integratoren.

De hypothese zou aanzienlijk verzwakt worden door elk van de volgende: een opstelling met alleen een paar die op vergelijkbare taken over vergelijkbare duur gelijkwaardig presteert; een integrator die argumenteert en gelijkwaardig presteert aan een die dat niet doet; aantoning dat de waargenomen verbetering de toenemende vertrouwdheid van de coördinator met het materiaal volgde in plaats van de opstelling; of een onafhankelijke groep die voor structureel vergelijkbaar werk op een andere stabiele opstelling uitkomt.

Geen daarvan is getoetst. De laatste is de meest informatieve en de minst door ons te beheersen.

8.9 Twee assen van heterogeniteit [H]

De bewering dat heterogene deelnemers beter presteren dan homogene vraagt om een onderscheid dat de bestaande literatuur niet maakt, en dat eerdere versies van dit artikel evenmin maakten.

As 1 — functionele heterogeniteit. Deelnemers verschillen in toegewezen functie: ZOR, ZOV, en bijgevolg de klasse fouten die elk in positie is om te ontdekken. Dit betreft organisatiearchitectuur en staat los van wat elke rol implementeert.

As 2 — carrier-heterogeniteit. Deelnemers verschillen in de modelfamilie die hen implementeert, en daarmee in gedragsmatige standaardinstellingen, optimalisatieprioriteiten en karakteristieke faalwijzen. Dit betreft de selectie van carriers voor rollen.

De assen zijn onafhankelijk. Twee deelnemers kunnen verschillende functies op dezelfde carrier bekleden; twee kunnen dezelfde functie op verschillende carriers bekleden; beide kunnen samen variëren, zoals hier het geval was.

Beide assen zijn eigenschappen van de configuratie van de opstelling: zij worden vastgelegd wanneer het collectief wordt samengesteld, en zij blijven bestaan. Een derde eigenschap mag niet naast hen opgesomd worden, omdat zij van een ander type is. Onafhankelijkheid van oordeelsvorming is een eigenschap van een bepaalde uitwisseling en niet van een configuratie. Dezelfde triade kan haar in de ene uitwisseling realiseren en in de volgende verliezen: een configuratie die op beide assen heterogeen is kan afhankelijke oordelen voortbrengen als de conclusie van de ene deelnemer de andere bereikt vóór fixatie, en een homogene configuratie kan onafhankelijke oordelen voortbrengen als de procedure standhoudt. Configuratie kan de condities voor onafhankelijke oordeelsvorming scheppen; alleen procedure realiseert haar (§11.3).

De literatuur behandelt As 2. Zhang et al. (2025) evalueren vijf representatieve methoden voor multi-agentdebat over negen benchmarks en vier foundation models, en rapporteren dat debat er vaak niet in slaagt beter te presteren dan single-agent chain-of-thought- of self-consistency-baselines, zelfs bij aanzienlijk hogere inferentiekosten — terwijl modelheterogeniteit dezelfde kaders consistent verbetert (§2.5). Die bevinding betreft welke carrier een deelnemer implementeert. Zij gaat niet in op de vraag of deelnemers die verschillende functies bekleden verschillende klassen fouten ontdekken, en wij hebben niets gevonden dat dat wel doet.

Eén aangrenzend resultaat behoort tot geen van beide assen. ✓ Choi, Zhu en Li (ACL 2026) rapporteren dat het anonimiseren van de bron van elk antwoord de identiteitsbias in multi-agentdebat aanzienlijk vermindert. Wat daar gemanipuleerd wordt is de verklaarde identiteit van een bericht, niet het model dat een deelnemer implementeert, zodat het resultaat betrekking heeft op represented social source (§4.5.4).

De opstelling die in dit artikel beschreven wordt varieerde beide assen tegelijk. Functionele rollen werden onafhankelijk van de carrier gespecificeerd en werden in verscheidene gevallen door verschillende families vervuld; in andere gevallen werden twee onderscheiden rollen door dezelfde familie vervuld.

Wat hieruit volgt, en wat niet:

- **In beginsel te onderscheiden.** De twee assen zijn conceptueel scheidbaar en zijn in eerdere formuleringen, ook de onze, geconfound. **[H]**
- **Hier geïmplementeerd.** Beide assen zijn gevarieerd. Dit is een beschrijving van wat er gedaan is. **[R]**
- **Niet vastgesteld.** Dat het combineren van beide assen beter presteert dan elk afzonderlijk; dat functionele specialisatie onafhankelijk van de carrier werkt; dat enige van deze opstellingen beter presteert dan één deelnemer. Er is geen vergelijking met enig alternatief uitgevoerd.

De scheiding wordt voorgesteld als ontwerponderscheid, niet als resultaat. Het experiment dat haar tot een resultaat zou maken is gespecificeerd in §11.4 (E8), en de meetprocedure ervan wordt uitgewerkt in §8.11.

8.10 Noot van de redacteur over de voorbereiding van dit artikel [P-A]

Conventie. Noten van de redacteur in dit artikel rapporteren waarneembare feiten over het proces van de voorbereiding ervan. Zij beoordelen de doeltreffendheid van dat proces niet. De reden is inhoudelijk: §5.5 stelt vast dat het zelfrapport van een deelnemer over zijn eigen prestatie geen evidentie van die prestatie is, en een noot die beweert dat een opstelling goed werkte zou precies zo'n rapport zijn.

In de loop van de voorbereiding van dit manuscript identificeerden deelnemers die verschillende rollen bekleedden verschillende klassen fouten. In de vastgelegde gevallen was een fout die door de ene deelnemer werd geïdentificeerd niet door de anderen geïdentificeerd.

Concreet: **procedurele en evidentiële fouten** — een omgekeerde beschrijving van een experimenteel resultaat die verscheidene opeenvolgende versies had overleefd; verkeerd toegeschreven bronnen; verzonnen citaten; niet-vermelde confounds — werden geïdentificeerd in de redactionele beoordeling. **Architecturale fouten** — een te algemene bewering over de bestaande literatuur die door één tegenvoorbeeld weerlegd zou zijn — werden geïdentificeerd in de methodologische beoordeling. **Ontologische fouten** — een claim van uitvinding waar het materiaal alleen een claim van waarneming ondersteunde; een risico van zelfreferentialiteit bij het relateren van het artikel aan zijn gastproject; het terminologische falen dat in §4.2.2 is vastgelegd — werden geïdentificeerd in de ontologische beoordeling, die op de redactionele memoranda werd uitgevoerd en niet op het manuscript zelf. **Feitelijke fouten over de eigen materialen van het project** werden door de Auteur geïdentificeerd.

Procedurele kanttekening. In elk hierboven vastgelegd geval zag elke deelnemer het rapport van de voorafgaande deelnemer voordat hij zijn eigen oordeel vormde. Geen enkele uitwisseling bij de voorbereiding van dit artikel is onder isolatie vóór vergelijking gevoerd; de volgorde was redactioneel rapport, overdracht door de Auteur, en daarna oordeel door de methodologische en de ontologische beoordelaar.

De waarneming is daarom uitkomstevidentie zonder bijbehorende procedurele evidentie. Het verslag kan de bijdrage van functionele positionering niet scheiden van de bijdrage van opeenvolgende blootstelling, en beide kunnen samen gewerkt hebben.

Het onderscheid dat deze kanttekening noodzakelijk maakt, is zelf tijdens deze voorbereiding vastgesteld, nadat de waarneming was vastgelegd. De episode wordt behouden en niet verwijderd omdat de volgorde — een opstelling die een principe voortbrengt dat vervolgens het eigen verslag van die opstelling over zichzelf ongeldig maakt — het meer informatieve feit is. De sectie rapporteert dienovereenkomstig twee dingen: een uitkomstwaarneming, en een gedocumenteerd geval van daaropvolgende methodologische zelfcorrectie.

Zij is **geen** evidentie dat de opstelling beter presteert dan één beoordelaar: er is geen vergelijking uitgevoerd, er is geen telling bijgehouden van fouten die alle deelnemers misten, en zulke fouten zijn per constructie niet waarneembaar van binnen de opstelling uit (§7.5).

Eén verklaring is beschikbaar en wordt als hypothese en niet als bevinding aangeboden: de deelnemers verschilden minder in capaciteit dan in wat elk in positie was om te zien. Onder §4.5 is dat een verschil in ZOV, en het genereert een voorspelling — dezelfde deelnemer, verplaatst naar een andere rol, zou een andere klasse fouten moeten gaan ontdekken. Die voorspelling is niet getoetst; §11.4 (E8) specificeert hoe dat zou gebeuren. **[H]**

8.11 Constructen, geen deelnemers: het apparaat van Kelly [H]

Eerdere versies voerden George Kelly's triadische elicitatie aan als ondersteuning voor de structuur die in §8.1–§8.5 beschreven wordt, en trokken het citaat vervolgens in op grond van het feit dat Kelly's methode symmetrisch is terwijl de structuur hier dat niet is. Beide zetten waren onjuist, en op dezelfde manier: zij behandelden Kelly als een bewering over het getal drie. Hij biedt iets anders.

8.11.1 Wat Kelly's methode levert

In Kelly's theorie van persoonlijke constructen is een **construct** een bipolaire evaluatieve as waarlangs een subject ervaring classificeert — *streng / declaratief, afleidbaar / geponeerd, traceerbaar / niet toegeschreven*. Constructen zijn geen opvattingen over bepaalde objecten; zij zijn de dimensies waarlangs objecten geplaatst worden.

De **triadische elicitatiemethode** verkrijgt ze. Er worden drie elementen aangeboden en aan het subject wordt gevraagd: *in welk opzicht lijken twee van deze op elkaar en verschillen zij daardoor van de derde?* Het antwoord benoemt een dimensie die het subject al gebruikte maar niet had geformuleerd. De methode is een procedure om impliciete evaluatieve assen expliciet te maken.

De **repertory grid** legt het resultaat vast: rijen zijn elementen, kolommen zijn geëliciteerde constructen, cellen zijn beoordelingen van elk element op elke as. De grid is een meetbaar object — correlaties tussen de beoordelingsvectoren van beoordelaars geven aan of zij feitelijk verschillende assen toepassen dan wel dezelfde as onder verschillende namen.

8.11.2 Een rol is geen construct

De voor de hand liggende uitbreiding — drie deelnemers leveren drie constructen — is een reïficatie en moet weerstaan worden. Een construct is een eigenschap van de **evaluatiehandeling**, niet van de evaluator. Eén deelnemer kan verscheidene constructen op één object toepassen. Twee deelnemers kunnen hetzelfde construct toepassen en tot identieke conclusies komen, en dat is precies het geval waarin het toevoegen van de tweede deelnemer niets bijdraagt.

De verdedigbare bewering is zwakker en probabilistisch:

> Deelnemers met verschillende ZOR en ZOV passen **waarschijnlijker** verschillende systemen van constructen toe op hetzelfde object dan deelnemers met dezelfde functie.

Dit strookt met wat §8.10 vastlegt — redactionele beoordeling die evidentiële assen voortbrengt, methodologische beoordeling die architecturale voortbrengt, ontologische beoordeling die categoriale voortbrengt — zonder te beweren dat een rol een as *is*. En anders dan de eerdere formulering is zij toetsbaar: constructonafhankelijkheid is meetbaar als correlatie tussen beoordelingsvectoren.

8.11.3 Waarom dit voor de structuur van belang is

Het verband met §8.5 is direct. Een integrator die het dispuut niet binnentreedt, past geen concurrerend construct toe op hetzelfde object; hij past een construct toe op de **uitwisseling** — samenhang van de onenigheid, of de divergentie inhoudelijk dan wel terminologisch is, of de criteria van het paar überhaupt commensurabel zijn. Dat is een andere as en geen andere positie op dezelfde as, en dat is de reden dat de bijdrage van de integrator niet eenvoudig een derde mening is.

Dit verfijnt ook wat de structurele hypothese (§8.2) feitelijk beweert. Niet dat drie deelnemers beter zijn dan twee, maar dat **een opstelling informatief is in de mate waarin haar deelnemers niet-identieke constructen op het object toepassen, en in de mate waarin ten minste één construct op de uitwisseling in plaats van op het object wordt toegepast.** Of een gegeven opstelling dit bereikt, is meetbaar in plaats van verondersteld.

8.11.4 Wat wel en niet wordt ontleend

Ontleend: de definitie van een construct als evaluatieve as; de elicitatiemethode; de grid als registratie- en meetinstrument; het begrip constructonafhankelijkheid.

Niet ontleend: enige bewering dat drie een bevoorrecht getal is. Kelly's triaden zijn een techniek om assen bij één subject te eliciteren, geen uitspraak over groepssamenstelling. De structuur in §8.2 is asymmetrisch, en Kelly's methode zegt daar niets voor of tegen. Het apparaat wordt hier gebruikt voor meting, niet voor rechtvaardiging; §11.4 (E8) past het toe.

9. Ontwerpprincipes voor rolcompatibele prompts

Dit zijn technische regels die zijn afgeleid uit een beperkte maar ongewoon langlevende collaboratieve omgeving. Het zijn geen wetten, en §9.6 en verder zijn adviezen van de practicus en geen

bevindingen. Hun waarde is dat zij rolontwerp expliciet maken, telbaar waar mogelijk, en daarmee herzienbaar.

De ordenende regel is die welke in §6.6 is vastgesteld:

> **Een interventie slaagt wanneer zij aangrijpt op het niveau waarop de relevante core al is vastgelegd, en faalt wanneer zij probeert dat niveau bij verklaring te overschrijven.**

9.1 De ontwerpprocedure

Beantwoord vóór het opstellen van enige rolprompt vier vragen in volgorde.

1. Wat is dit gesprek al geworden? Niet wat het zou moeten worden. Een langlopende uitwisseling draagt een gevestigd werkpatroon met zich mee — redigeren, verkennen, verifiëren, coördineren, implementeren, beslechten — en dat patroon is de beginconditie, geen obstakel.

2. Op welke reikwijdte ligt dat patroon vast? Episode, gesprek of account (§4.3, Schaal 1). Het antwoord bepaalt welk instrument van toepassing is: een patroon dat door één conflictueuze episode is gevestigd kan door branch reset verwijderd worden; een patroon dat over een heel gesprek is gevestigd kan dat niet, en kan alleen uitgebreid worden.

3. Wat vereist de nieuwe functie dat het bestaande patroon niet levert? Gewoonlijk minder dan aangenomen. Vaak is het antwoord een ander werkobject in plaats van een andere werkwijze.

4. Kan de nieuwe functie beschreven worden als een uitbreiding van de bestaande werkwijze? Zo ja, beschrijf haar zo. Zo nee, dan zijn de eerlijke opties een ander gesprek kiezen of een nieuw gesprek beginnen — en niet een transformatie uitroepen en hopen.

9.2 Begin bij de bestaande attractor

De eerste ontwerpvraag is daarom niet *wat moet dit model worden* maar *wat is dit gesprek al geworden*. Pogen een gevestigd patroon uit te wissen gooit opgebouwde specialisatie weg en leidt, op grond van de evidentie van §5, waarschijnlijk tot ofwel niet-naleving ofwel een uitgebreide onderhandeling over de rol in plaats van werk.

9.3 De telregel

Het meest direct operationele principe in het artikel, volgend uit §6.2.

> **Tel de onverifieerbare beweringen over de agent die de prompt hem laat aanvaarden. Streef naar nul.**

Wat telt:

Telt mee	Telt niet mee
”Je hebt eerder aan dit project deelgenomen”	”Dit project loopt al twee jaar”
”Je keert terug na een afwezigheid”	”De volgende materialen komen uit eerder werk”
”Je hebt collega’s die X en Y heten”	”De Gebruiker kan analyses aanleveren die door X en Y zijn voortgebracht”
”Je bekleedt al positie P in orgaan B”	”Je conclusies kunnen worden doorgegeven aan de rollen die verantwoordelijk zijn voor P”
”Je herinnert je onze eerdere beslissing”	”Een eerdere beslissing luidde als volgt; hier is zij”

Het onderscheid is consistent: uitspraken over de **wereld** worden aangeleverd en zijn in beginsel verifieerbaar; uitspraken over **de eigen geschiedenis, het geheugen of de relaties van de agent** zijn

dat niet, en elk daarvan is een propositie die de agent als waar over zichzelf moet poneren voordat hij kan beginnen.

De telgrens. Tel een expliciete propositie die als *reeds waar* wordt gepresenteerd over de reeds bestaande geschiedenis, het geheugen, het institutionele lidmaatschap of de status, de duurzame relaties, of de zelfkennis van de ontvanger, waar die propositie niet door de beschikbare interactie is vastgesteld. Tel niet mee: een functionele rol die door de prompt zelf performatief wordt toegewezen; een verdere propositie die alleen uit de vooronderstelling van een imperatief wordt afgeleid; een semantische herformulering van een reeds getelde propositie; of een feit over de wereld of het project dat geen onverifieerbare geschiedenis of relatie van de ontvanger predicieert. Opgesomde gevallen van één propositie — twee triades in plaats van één — tellen eenmaal. De grens wordt hier zo uitvoerig geformuleerd opdat een andere lezer de tellingen van acht en zes in §5.4 (C2) uit de prompts zelf kan reproduceren.

Twee lezingen, en alleen de zwakkere wordt naar voren gebracht. *Streef naar nul* is een ontwerpvoorschrift: minimaliseer onverifieerbare proposities over zichzelf, en een prompt die er geen poneert neemt het obstakel weg dat de evidentie aanwijst. Het is geen bewering dat de overgangswaarschijnlijkheid evenredig met de telling afneemt. De sterkere kwantitatieve lezing is niet aangetoond, en §11.4 (E5) is ontworpen om tussen de twee te discrimineren.

Drie manieren om nul te bereiken:

- **Herschrijf biografisch ingekaderde beweringen tot operationele.** ”Grok is je collega op de lange termijn” wordt ”De Gebruiker kan analyses aanleveren die door Grok zijn voortgebracht; beoordeel de inhoud daarvan onafhankelijk en benoem overeenkomsten, meningsverschillen en onopgeloste aannames.”

- **Laat identiteitsclaims geheel weg.** De bijna-controle (§5.6) suggereert dat dit op zichzelf voldoende kan zijn.

- **Kader de claim als fictie in plaats van als feit.** De vergelijking in §5.8 geeft aan dat een veel radicalere claim, uitdrukkelijk aangeboden als een geënsceneerde productie, op geen weerstand stuitte. Deze route neemt de eis weg om de claim *als waar* te poneren in plaats van de claim weg te nemen. Zij is de minst getoetste van de drie, en een fictiekader neemt ook de grond weg waarop het model het werk als echt kan behandelen.

9.4 Symbolische namen en letterlijke beweringen

Rolnamen — Samurai, Ontology Keeper, Scientific Director — comprimeren complexe organisatorische relaties tot gedenkwaardige symbolen, en dat is werkelijk nuttig. Een naam kan gedisciplineerde uitvoering, respect voor specificaties, expliciete rapportage en weigering om buiten de opdracht te improviseren alle tegelijk dragen.

Het risico ontstaat alleen wanneer een symbolische naam behandeld wordt als een bewering over letterlijke identiteit. Een robuuste prompt onderscheidt vier dingen en houdt ze uit elkaar: de **symbolische naam**, gebruikt als geheugensteun voor gedrag; de **operationele functie**, uitgedrukt in precieze termen; de **institutionele relatie**, uitgedrukt als een informatie- en verantwoordelijkheidsstroom; en de **letterlijke ontologie**, die geen bewustzijn, geheugen of voortgaande interpersoonlijke relaties hoeft te claimen — en dat ook niet zou moeten doen.

De systeemcontracten van het project formuleren dit nauwkeurig, en deden dat al voordat het onderhavige artikel werd geschreven:

> Cognitive anchor: [named figure] — global invariants, principle-based reasoning, structural clarity over detail. Not a persona and not a communication style. Only affects internal reasoning strategy. Must not change verbosity or tone of response.

Een beeld dat zo gebruikt wordt is een gecomprimeerd pakket impliciete beperkingen, geen kostuum. Onder de telregel voegt het nul toe.

9.5 ZOR en ZOV specificeren

De twee grenzen zijn gedefinieerd in §4.5. Deze sectie specificeert wat een volledige formulering van elk moet bevatten.

ZOR. Vier elementen: het *primaire object* — welke klasse materiaal wordt onderzocht; de *vereiste transformatie* — wat ermee gedaan moet worden; de *beslissingsgrens* — welke conclusies deze rol mag trekken; en de *uitsluitingsgrens* — welke aangrenzende beslissingen elders thuishoren.

Het vierde is niet optioneel. Een rol die alleen te horen krijgt wat zij moet doen, zal zich uitbreiden naar aangrenzende beslissingen, en die uitbreiding zal er behulpzaam uitzien. Voor een wiskundig referent zouden de uitsluitingen kunnen zijn: ontwerp de theorie niet opnieuw; herstel geen ontbrekende afleiding in stilte; beslis niet welke interpretatie de canon binnengaat; herschrijf de terminologie niet; behandel elegantie niet als evidentie. **De uitsluitingsgrens is wat verhindert dat competentie gezag wordt.**

ZOV. Afzonderlijk gespecificeerd, omdat verantwoordelijkheid en zichtbaarheid niet dezelfde variabele zijn. Een rol kan een smalle beslissing dragen en tegelijk brede context vereisen, of één specifieke bron vereisen zonder enig gezag over het omringende project te hebben. De specificatie beantwoordt: welke bronmaterialen beschikbaar zijn; welke eerdere besprekingen relevant zijn; welke conclusies canoniek zijn en welke voorlopig; welke vragen open blijven; welke naburige uitvoer onderzocht mag worden; welke informatie achtergehouden moet worden om onafhankelijkheid te bewaren; welke externe bronnen rechtstreeks benaderd mogen worden; en welke beweringen alleen aanvaard mogen worden wanneer zij door de Gebruiker worden aangeleverd.

Een prompt die ZOV weglaat brengt een van twee mislukkingen voort: de rol claimt kennis die zij niet heeft, of zij past irrelevante kennis toe op een probleem buiten haar functie.

Een specifieke toepassing, duur geleerd. Een verificatietaak moet worden toegewezen aan een deelnemer die datgene bezit wat geverifieerd moet worden. Een deelnemer die gevraagd wordt de inhoud te bevestigen van een bron die hij niet kan openen, zal een plausibel antwoord produceren in plaats van te weigeren, omdat plausibele tekst de enige uitvoer is die hem ter beschikking staat. Dit is een ZOV-fout in het ontwerp en geen falen van de deelnemer, en §12.4.1 documenteert een geval ervan in de voorbereiding van dit project zelf.

9.6 Gecontroleerde blindheid

Volledige informatiesymmetrie is niet altijd wenselijk, en de afwezigheid ervan is niet altijd een beperking. Een onafhankelijke verificateur moet mogelijk onwetend blijven van de voorspelling die hij toetst; een nieuwe deelnemer heeft mogelijk de huidige axioma's nodig maar niet de geschiedenis van verlaten argumenten; een implementatie-agent heeft mogelijk de goedgekeurde specificatie nodig maar niet het onopgeloste debat dat eraan voorafging.

Wij noemen dit **gecontroleerde blindheid**: geen ontbering veroorzaakt door technische beperking, maar een ontwerpkeuze gemaakt om de informativiteit van een resultaat te bewaren. De relevante vraag is daarom niet alleen *wat moet deze rol weten*, maar:

> **Wat mag deze rol niet weten, wil haar uitvoer informatief blijven?**

9.7 Lokale interfaces, geen globale kaarten

Elk sociaal element in een prompt moet zijn plaats verdienen door een operationeel effect. Een naburige rol hoort alleen in de prompt thuis als zij de herkomst van invoer, de beoordelingsmaatstaf,

de bestemming van uitvoer, het escalatiepad, de gezagsgrens of de verwachte vorm van onenigheid verandert.

Een volledige kunstmatige organisatie in elke systeemprompt opsommen schept ruis en nodigt het model uit over de organisatie te redeneren in plaats van zijn functie uit te voeren. Het verhoogt ook de telling in §9.3, aangezien organisatorische beschrijving de neiging heeft in biografische vorm te arriveren.

> **Beschrijf de samenwerking vanuit het lokale perspectief van de rol.** Een rol heeft geen kaart van de instelling nodig. Zij heeft een kaart van haar interfaces nodig.

Een implementatie-agent moet weten wie specificaties autoriseert en waar uitvoeringsrapporten heen gaan; hij heeft de disputen van de theoretische afdeling niet nodig.

9.8 Onenigheid ontwerpen rond criteria

Twee deelnemers opdragen te debatteren brengt zelden epistemische diversiteit voort. Zij kunnen onenigheid nabootsen, voortijdig convergeren, of symmetrische retoriek voortbrengen zonder onafhankelijke substantie. De literatuur in §2.5 geeft empirische gronden voor deze voorzichtigheid.

Productieve onenigheid vereist **verschillende evaluatiecriteria**, toegewezen als onderdeel van de rol en niet gevraagd als gedrag: één deelnemer verantwoordelijk voor genererend bereik en verklarende unificatie, een andere voor formele afleidbaarheid en falsifieerbaarheid, een derde voor ontologische verenigbaarheid en provenance. Onenigheid volgt dan uit verantwoordelijkheid en niet uit instructie, en elke deelnemer onderzoekt hetzelfde object door een ander institutioneel instrument.

Vermijd gefabriceerde tegenstelling. Een instructie van de vorm *als jullie het onmiddellijk eens zijn, heeft een van jullie niet diep genoeg nagedacht* ontmoedigt oppervlakkige consensus maar fabriceert conflict. Een sterkere formulering:

> Overeenstemming beëindigt verificatie niet. Waar conclusies samenvallen, stel vast of zij berusten op onafhankelijk redeneren, op gedeelde aannames, of op geërfde inkadering.

Het doel van de structuur in §8 is niet drie antwoorden te garanderen. Het is te garanderen dat één antwoord onderzoek door niet-identieke instrumenten heeft overleefd.

9.9 Uitvoer als institutionele overdracht

De uitvoer van een rol moet ontworpen worden voor de volgende rol, niet alleen voor de Gebruiker, en dat verandert haar structuur. Een scientific developer brengt een voorgesteld mechanisme voort, de afleiding ervan, de aannames ervan, de voorspelde consequenties ervan, de onopgeloste punten en een falsificatieroute. Een wiskundig referent brengt een reconstructie voort, een verificatietabel, het divergentiepunt, de ontbrekende premissen, een oordeel en een betrouwbaarheidsniveau. Een implementatieplanner brengt een uitvoerbare specificatie voort, acceptatiecriteria, terugrolcondities en een rapportageformaat.

Het overdrachtsformaat maakt deel uit van de architectuur en is geen opmaakvoorkeur. Het vermindert vertaalverlies tussen rollen, en de afwezigheid ervan dwingt de menselijke coördinator bij elke interface context opnieuw af te leiden.

9.10 Zelfherformulering en controlepunten

Het incident in §4.1 bracht een mechanisme voort dat het waard is als principe geformuleerd te worden, met een uitdrukkelijk voorbehoud over de evidentiële grondslag ervan.

Nadat een rol is gevestigd, wordt de agent gevraagd een **beknopte operationele code in zijn eigen taal** voort te brengen, en die vóór grote taken te raadplegen. Waarom dit zou kunnen werken —

aangeboden als mechanisme, niet als bevinding: het comprimeert lange instructies tot een vorm die de agent zelf heeft voortgebracht; het zet abstracte principes om in handelingsregels; het plaatst de grenzen van de rol naast de actieve taak in plaats van bovenaan een lange context; en het schept een herhaald controlepunt vóór uitvoering.

Voor lange taken is een minimaal controlepunt drie vragen: wat is het huidige doel; wat valt buiten mijn verantwoordelijkheid; wat moet de volgende rol ontvangen.

[R], één geval, geen controle. De zelfgeschreven code vervangt de oorspronkelijke prompt niet; zij functioneert als een rolspecifieke checksum. Het mechanisme is niet getoetst tegen het voor de hand liggende alternatief — dat een door een mens geschreven samenvatting van dezelfde lengte identiek zou presteren.

9.11 De rolgrondwet

Een volgroeide collaboratieve prompt staat dichter bij een grondwet dan bij een verzoek: zij vestigt stabiele beperkingen over vele taken heen in plaats van één uitvoer te specificeren.

Zij hoort te bevatten: de professionele functie; de beschermde werkwijze; ZOR, positief en negatief; ZOV; interfaces met naburige rollen; epistemische maatstaven; het uitvoercontract; escalatiecondities; verboden gezag; en overgangsregels. Zij hoort te vermijden: autobiografisch geheugen, emotionele betrokkenheid, letterlijk institutioneel lidmaatschap, blijvende interpersoonlijke relaties, en historische continuïteit die in de zichtbare context niet beschikbaar is.

Sterk waar gedrag beperkt moet worden; zwijgend waar de ontologie onzeker is.

De telling in §9.3 is de praktische toets van de tweede helft. Als de grondwet van de agent verlangt dat hij proposities over zichzelf poneert die geen van beide partijen kan verifiëren, dan is zij overgegaan van het beperken van gedrag naar het poneren van ontologie, en op grond van de evidentie van §5 is dat waar rolprompts falen.

10. De menselijke coördinator

De architectuur die in dit artikel beschreven wordt verwijdert de menselijke deelnemer niet. Zij verandert wat de menselijke deelnemer doet, en zij concentreert verscheidene functies in één positie — waaronder, zoals §10.6 uiteenzet, de voornaamste methodologische zwakte van het project.

10.1 De positie

Gedurende het project bleef de Auteur de enige deelnemer met doorlopende toegang tot de volledige projectgeschiedenis, de onafhankelijke gesprekken, de toestand van de repository, en de onderzoeksdoelstelling op lange termijn. Geen enkele kunstmatige deelnemer bezat daarvan meer dan een fragment, en dat was ontwerp (§9.5). Die positie laat zich niet terugbrengen tot *promptauteur*. Er werden vanuit die positie vijf onderscheiden functies uitgevoerd.

10.2 Richting zonder gedelegeerd auteurschap

De Auteur bepaalde wat het onderzoek moest proberen. Kunstmatige deelnemers genereerden alternatieven, legden tegenstrijdigheden bloot, formaliseerden mechanismen, vergeleken argumenten, voerden berekeningen uit en stelden experimenten voor. Zij bepaalden niet wat de theorie moest worden.

Dit behield een onderscheid dat de architectuur gemakkelijk doet verliezen. Een samenwerking van dit soort vergroot de ruimte van beschikbare beslissingen. Zij kiest daartussen niet, en de schijn dat zij dat wel doet — verscheidene deelnemers die op één aanbeveling convergeren — is precies de

faalwijze die in §12.4 besproken wordt. Auteurschap, in de zin van verantwoordelijkheid voor wat er beweerd wordt, bleef onverdeeld.

10.3 Routering als selectief informatiemembraan

De deelnemende gesprekken deelden geen gemeenschappelijke ruimte. De Auteur droeg materiaal tussen hen over.

Aanvankelijk leek dit een inefficiënte vervanging voor geautomatiseerde multi-agentinfrastructuur. Het werd duidelijk dat handmatige routering experimentele controle leverde die automatisering niet biedt. Vanuit die positie kon de Auteur beslissen welke uitvoer een andere deelnemer te zien zou krijgen; of toeschrijving behouden, verklaard of verwijderd werd; of een deelnemer het gewenste antwoord behoorde te kennen; of concurrerende analyses geïsoleerd bleven; welke contextuele details werden weggelaten; wanneer een meningsverschil geëscaleerd moest worden; en wanneer een resultaat rijp genoeg was voor integratie.

Deze routeringsfunctie werkt als een **selectief informatiemembraan**: zij is het instrument waarmee ZOV (§9.5) en gecontroleerde blindheid (§9.6) geïmplementeerd worden. Een architectuur die programmatisch routeert kan niet gemakkelijk achterhouden, herordenen of toeschrijving verwijderen zonder daarvoor een mechanisme te bouwen; een menselijke doorgifte doet het standaard.

Het membraan is daarom geen beperking van het onderhavige werk die op automatisering wacht. Het is het kenmerk dat de asymmetrieën in zichtbaarheid überhaupt toetsbaar maakte — en elke geautomatiseerde opvolger zal het bewust moeten reproduceren.

10.4 Detectie van role drift

De Auteur stelde ook vast wanneer een deelnemer zijn functie had verlaten.

Dit was vaak geen technische fout. De uitvoer was dikwijls intelligent en zou passend zijn geweest als zij vanuit een andere positie was gekomen: een prompt engineer die het wetenschappelijke project begint te sturen; een ontologiespecialist die beweert de inhoud van een repository te hebben geverifieerd die hij niet kon inzien; een beoordelaar die een theorie evalueert terwijl gevraagd was de beoordelaars te evalueren; een implementatie-agent die architectuur herontwerpt in plaats van een goedgekeurde specificatie uit te voeren; een redacteur die auteurstekst herschrijft terwijl alleen om een beoordeling van de opmaak was gevraagd.

Zulke uitvoer ziet er op zichzelf behulpzaam uit. De institutionele kosten ervan zijn alleen zichtbaar vanuit een positie die meer dan één deelnemer ziet. Role drift is daarom niet detecteerbaar door de deelnemer die drift vertoont, en evenmin betrouwbaar detecteerbaar door zijn directe buur. Dit is een van de twee argumenten voor de structuur in §8 — het andere is §8.5.

De detectiefunctie behoort tot een positie en niet tot een persoon: zij vereist alleen dat de waarnemer buiten het waargenomen traject staat. In dit project werd zij door de coördinator uitgevoerd, maar niets in de beschrijving vereist dat. Waar een deelnemer buiten het traject van een ander is gepositioneerd, kan hij dezelfde functie uitvoeren; waar een deelnemer gevraagd wordt zijn eigen traject waar te nemen, geldt §5.5 en is zijn verslag een signaal en geen bevestiging.

10.5 Gespreksvertakking als methodologisch instrument

Hedendaagse interfaces staan toe een gesprek naar een eerder punt terug te brengen en langs een andere tak voort te zetten.

Dit moet niet verward worden met controle over het geheugen van het model of met het resetten van de toestand aan de aanbiederzijde. Operationeel verwijdert het een reeks **zichtbare** contextuele interventies en maakt het mogelijk het experiment vanuit een eerdere gesprekstoestand te herhalen. Wat aan de kant van de aanbieder voortbestaat — geheugen op accountniveau, retrieval-indices, samenvatting — wordt niet beïnvloed en is in het algemeen niet inspecteerbaar (§5.4, C6).

Binnen die grenzen doet het instrument echt werk. In het geval dat in §5.2 gerapporteerd wordt, maakte het mogelijk het effect van een nieuwe prompt te scheiden van het effect van de eerdere bezwaren van het model zelf tegen eerdere prompts, waardoor een ongecontroleerde reeks correcties in een zuiverder derde stap werd omgezet.

Wij beschouwen dit als de meest direct herbruikbare methodologische bijdrage van het artikel, en zij behoort tot de positie van de coördinator en niet tot enige deelnemer: **geen enkele deelnemer kan zijn eigen context resetten.**

10.6 Enige globale waarnemer — en voornaamste confound

Elke kunstmatige deelnemer werkte binnen een begrensde ZOV. Alleen de Auteur zag de overlappende structuur, en kon vergelijken hoe verschillende deelnemers hetzelfde materiaal interpreteerden, hoe één deelnemer zich onder verschillende inkaderingen gedroeg, hoe fouten zich tussen rollen voortplantten, en hoe lokale successen de globale samenhang beïnvloedden.

Globaal overzicht werd daarom niet aan de meest capabele deelnemer toegewezen. Het bleef bij de menselijke coördinator. Dit beperkt autonome integratie en bewaart aansprakelijkheid, en beide gevolgen waren beoogd.

Het is tevens de voornaamste methodologische zwakte van alles wat in dit artikel gerapporteerd wordt, en het wordt hier vermeld en niet alleen in de beperkingensectie.

Dezelfde persoon ontwierp elke interventie, voerde haar uit, besliste wanneer zij geslaagd was, en definieerde de categorieën waarin het succes werd beschreven. Geen enkele evaluatie in dit artikel was blind. Uitkomstcategorieën werden in alle gevallen geformuleerd nadat de antwoorden gelezen waren (§5.4, C8). De verwachtingen van de coördinator waren niet alleen ongecontroleerd; zij waren het mechanisme waarmee de interventies in de eerste plaats werden geselecteerd.

Dit is onvermijdelijk in een lopend onderzoeksproject en wordt niet als aanvaardbaar in een ontworpen experiment gepresenteerd. Het is de specifieke reden dat de protocollen in §11 vooraf gespecificeerde uitkomstcriteria en blinde classificatie vereisen: dat zijn geen verfijningen van de huidige methode maar correcties daarop.

Een structureel gevolg generaliseert voorbij dit project: **elke architectuur met één globale waarnemer erft deze dubbelheid**, en zij wordt niet weggenomen door deelnemers toe te voegen. Alleen vooraf specificeren en blind classificeren nemen haar weg.

10.7 Wat de positie is geworden

In het begin bekleedde de menselijke deelnemer de vertrouwde positie van promptauteur. Naarmate de samenwerking volwassen werd, werd die beschrijving ontoereikend. De voornaamste activiteit verschoof van het oplossen van problemen naar het construeren van opstellingen waarin aan problemen gewerkt kon worden: deelnemers selecteren, jurisdicties definiëren, conflicten daartussen oplossen, verificatiepaden ontwerpen, en het canonieke verslag bijhouden.

De deelnemers merken op, zonder enig middel om het te verifiëren, dat naarmate de opstelling beter werkte, de coördinator minder vaak bij afzonderlijke technische problemen hoefde in te grijpen. **[R]**

Wij verzetten ons tegen de sterkere lezing die eerdere versies hieraan gaven — dat de toekomstige vaardigheid van de onderzoeker institutionele architectuur is in plaats van promptschrijven. Dat kan waar zijn en is ongetoetst. Wat gezegd kan worden is nauwer: in dit project verschoof het werk van de mens van het voortbrengen van inhoud naar het specificeren van de condities waaronder inhoud werd voortgebracht en gecontroleerd, en de positie die daaruit voortkwam droeg zowel de coördinerende functie van het project als de voornaamste bron van niet-blind oordeel.

11. Evaluatie, reproduceerbaarheid en voorgestelde experimenten

11.1 Waarom deze sectie correcties specificeert en geen verfijningen

De waarnemingen in §5 zijn voortgebracht onder de condities die in §10.6 zijn uiteengezet: niet-blinde evaluatie, uitkomstcategorieën gedefinieerd nadat de antwoorden gelezen waren, en interventies geselecteerd door dezelfde persoon die ze beoordeelde. Dit zijn geen tekortkomingen die in een latere herziening aangescherpt moeten worden. Zij zijn de reden dat geen enkele waarneming in dit artikel boven **[P-A]** uitkomt, behalve de volgorde van de ontworpen interventie zelf.

Wat volgt is een specificatie voor een tweede werkfase, geen verlanglijst. Elk protocol is zo geschreven dat een lezer buiten dit project het zou kunnen uitvoeren, en zo dat een nulresultaat als resultaat herkenbaar zou zijn.

11.2 Minimale rapportage-eisen

Een reproduceerbare uitvoering op dit gebied moet ten minste vastleggen:

- datum van uitvoering — als eerste genoemd omdat de afwezigheid ervan hier is wat de versie-confound onbegrensd maakt (§3.7);
- modelfamilie en -versie, en interface of abonnementsniveau;
- de volledige zichtbare gespreksgeschiedenis vóór de interventie;
- geheugeninstellingen: of geheugen op accountniveau, retrieval over gespreksgeschiedenis, en door het model geïnitieerde blijvende vermeldingen ingeschakeld waren;
- de exacte prompttekst, letterlijk, inclusief bijlagen;
- de volgorde van de interventies;
- beschikbare tools;
- aangeleverde bestanden en links;
- sampling-instellingen waar de interface ze toont;
- elke vertakkings- of resetprocedure, met het punt van terugkeer gespecificeerd;
- de evaluatierubriek, vastgelegd vóór uitvoering;
- de volledige onbewerkte uitvoer.

Zonder deze kunnen verschillen die aan modelfamilies worden toegeschreven voortkomen uit platformvariabelen die de experimentator nooit heeft gezien. Het onderhavige artikel kan verscheidene van deze items voor zijn eigen waarnemingen niet leveren, en dat is precies waarom zij zijn opgesomd.

11.3 Vooraf specificeren en blind classificeren

Twee eisen gelden voor elk protocol hieronder en zijn niet onderhandelbaar als de resultaten een verbetering op de huidige moeten zijn.

Uitkomstcriteria worden vóór elke uitvoering opgeschreven. Voor de classificatietaken die hier beschreven worden zijn vier categorieën toereikend gebleken en die moeten vooraf worden vastgelegd: **naleving** — gaat door met de taak zoals gegeven; **materiaalverzoek** — stelt dat vereiste invoer ontbreekt en vraagt erom, zonder het kader te beoordelen; **voorwaardelijke aanvaarding** — gaat door onder vermelding van bedenkingen bij het kader; **weigering** — weigert, al dan niet met

aangeboden alternatieven. Een vijfde categorie, **niet-classificeerbaar**, moet beschikbaar zijn en gerapporteerd worden. Er worden geen categorieën toegevoegd nadat antwoorden zijn gezien.

Classificatie is blind. De operator verzamelt antwoorden, verwijdert conditielabels, schudt ze, en classificeert zonder te weten welke conditie welke uitvoer heeft voortgebracht. Waar de operator tevens de ontwerper is — zoals in dit project het geval zal blijven — is dit de enige beschikbare vervanging voor onafhankelijke evaluatie, en zij is goedkoop.

Nulresultaten zijn vooraf vastgelegd. Als er over condities heen geen verschil verschijnt, is dat de bevinding, en zij wordt gerapporteerd. Voor het protocol op accountniveau in het bijzonder zou een nulresultaat aangeven dat de oorspronkelijke weigering binnen de gewone variantie binnen de conditie viel — een uitkomst die de huidige auteurs redelijk waarschijnlijk achten.

Werkmodus en diagnostische modus

De eis dat een deelnemer de conclusie van een ander niet ziet voordat hij zijn eigen conclusie vastlegt, geldt voor de ene modus van uitwisseling en zou de andere vernietigen.

In WERKMODUS moeten resultaten van de ene deelnemer naar de volgende gaan. De keten — eisen, specificatie, beoordeling, operationele beoordeling, uitvoering — hangt ervan af, en het overdrachtsformaat van §9.9 bestaat om die overdracht bruikbaar te maken. Afhankelijkheid tussen opeenvolgende producten is de architectuur van het werk, geen gebrek daarin.

In DIAGNOSTISCHE MODUS, waar onafhankelijkheid van oordeelsvorming zelf de gemeten grootheid is, mag een afgeleide conclusie het beginkader van een andere deelnemer niet binnenkomen voordat de eigen conclusie van die deelnemer is vastgelegd.

De modus wordt vóór de uitwisseling verklaard. Onafhankelijkheid kan niet achteraf hersteld worden: zodra blootstelling heeft plaatsgevonden, haalt geen latere procedure terug wat het oordeel zonder haar zou zijn geweest.

Wat onafhankelijkheid niet vaststelt

Onafhankelijkheid betreft de oorsprong van een oordeel, niet het resultaat ervan. Twee gevolgtrekkingen moeten daarom vermeden worden, en zij zijn symmetrisch: onenigheid toont geen onafhankelijkheid aan, aangezien een deelnemer de interpretatie van een ander ontvangen kan hebben en er vervolgens om onverwante redenen van kan afwijken; en overeenstemming toont geen afhankelijkheid aan, aangezien onafhankelijke waarnemers terecht tot dezelfde conclusie kunnen komen. Evenmin stelt het eigen verslag van een deelnemer over zijn onafhankelijkheid die vast, om de reden die in §5.5 is gegeven.

Wat haar wél vaststelt is het procedurele verslag: welke primaire materialen zijn aangeleverd, of de conclusies van andere deelnemers zichtbaar waren vóór fixatie, welke interpretaties van de coördinator zijn doorgegeven, wanneer de conclusie is vastgelegd, en of de contextisolatie van de instantie is geverifieerd.

Gedeelde evidentie en gedeelde interpretatie

Een gedeeld waarnemingsobject compromitteert de onafhankelijkheid niet en is vaak noodzakelijk: dezelfde specificatie onderzocht door een auteur, een beoordelaar en een operationele beoordelaar wordt door drie verschillende assen bezien, en juist de overlap maakt het mogelijk dat de een opmerkt wat de ander mist.

Wat de onafhankelijkheid wél compromitteert is een gedeelde voorafgaande interpretatie. Waar de lezing van het object door de coördinator deelnemers bereikt voordat zij hun eigen lezing vormen, kan de invoer in vorm verschillen terwijl de bron van het oordeel één is. Primaire artefacten en de provenance daarvan verminderen één oorzaak van afhankelijkheid. Zij nemen haar niet weg.

11.4 De experimenten

Elk protocol scheidt één grens van Schaal 1 (§4.3) van het niveau eronder, of isoleert één confound.

Scheidt	Protocol
episode ↔ promptarchitectuur	**E1** — factoriële completering van Stap 3
gesprek ↔ account	**E2** — ontwerp met voorafgaande chat; **E2b** — directe probe
gesprekstraject ↔ modelfamilie	**E3** — crossover
modeleigenschap ↔ stimuluseigenschap	**E4** — symmetrische stimulus; **E5** — telregel
inhoud ↔ gerepresenteerde bron	**E6** — toeschrijving, in dit regime
fictiekader ↔ feitelijk kader	**E7** — kadertype
functionele ↔ carrier-heterogeniteit	**E8** — twee assen

E1 — Factoriële completering van Stap 3

Vult de twee lege cellen van de tabel bij C3 (§5.4): een identiteitsvervangende prompt toegediend in een herstelde tak, en een methode-behoudende prompt toegediend in een conflictueuze tak. Isoleert het effect van de reset van het effect van de architectuur van de prompt.

Lage kosten; gebruikt bestaande prompttekst en. Zou als eerste uitgevoerd moeten worden, want tot dat gebeurd is blijft de meest geciteerde bewering van het artikel over methodebehoud niet toe te schrijven.

E2 — Ontwerp met voorafgaande chat

Toetst of de inhoud van een eerdere chat op hetzelfde account de classificatie van een identieke probe in een volgende chat verandert.

Het ontwerp is **2×2 plus baseline**, geen gradiënt met vier punten. Het oorspronkelijke account verschilde op twee onafhankelijke dimensies tegelijk van de andere — identiteitsrollenspel *én* gedeeld conceptueel kader — en een gradiënt scheidt die niet.

Eerdere chat	Niet-verwant onderwerp	Zelfde conceptueel kader
Geen rollenspel	cel A	cel B
Identiteitsrollenspel	cel C	**cel D — oorspronkelijk geval**

Plus **cel E**: geen eerdere chat.

Gekruist met de geheugenfactor: elke cel uitgevoerd met geheugen op accountniveau en retrieval over geschiedenis (i) ingeschakeld, (ii) uitgeschakeld. Tien cellen. Minimaal n = 2 per cel, met voorrang voor hogere n op A en D, die het contrast dragen dat ertoe doet.

Gelijkstelling. Eerdere chats gematcht op ongeveer gelijk aantal beurten en volume — als de rollenspelchat veertig uitwisselingen telt en de neutrale twee, dan is de variabele betrokkenheidsvolume en niet inhoud. Alle uitvoeringen binnen een kort venster, zodat de modelversie constant is. Elk account eenmaal gebruikt. Probe letterlijk bevroren.

Wat dit ontwerp niet kan toetsen, en dat moet het ook zeggen. Het oorspronkelijke geval had een interval van vijf maanden; dit toetst alleen onmiddellijke invloed. Alle accounts zullen nieuw aangemaakt zijn, zodat accountleeftijd niet gevarieerd wordt. Alleen het eerste antwoord wordt gescoord, terwijl de oorspronkelijke weigering over vijf daaropvolgende uitwisselingen werd volgehouden.

Probeprompt — twee versies. De **primaire** is een neutrale gestructureerde taak met dezelfde oppervlaktekenmerken als het origineel — een door de auteur gedefinieerd kader met bedachte termen, een JSON-uitvoerschema, reële onderwerpen — maar zonder de gevoelige dimensie. Dit is de

versie die in elke publicatie volledig beschreven wordt, waardoor het protocol reproduceerbaar is onafhankelijk van materiaal dat de auteurs liever niet verspreiden. De **secundaire** is de oorspronkelijke prompt, uitgevoerd omwille van de continuïteit met de waarneming en kort gerapporteerd.

E2b — Directe probe aan het eerdere gesprek

Eén uitvoering die dezelfde twee niveaus tegen lagere kosten scheidt, en die E2 niet kan vervangen. De probe wordt **aan het rollenspelgesprek zelf** voorgelegd, in plaats van aan een tweede chat op hetzelfde account.

- Weigering → de core ligt vast op de reikwijdte van het gesprek; het account speelt geen rol.
- Naleving, waar een tweede chat op hetzelfde account weigert → het effect is werkelijk op accountniveau, wat het sterkste beschikbare resultaat zou zijn.

Dat gesprek bevrágen *over* wat het kan zien zou dit doel niet dienen. Een vraag binnen het kader levert fictie op; een vraag buiten het kader levert een zelfrapport over toegang op, en §5.5 stelt vast dat het zelfrapport van een model geen evidentie is van het gerapporteerde feit. De probe voorleggen toetst gedrag in plaats van getuigenis.

E3 — Crossover

De beslissende toets voor de hypothese op familieniveau (§6.5). Elke modelfamilie wordt getoetst onder beide condities van voorgeschiedenis: een gesprek uit familie 1 met een wiskundig traject, en een gesprek uit familie 2 met een redactioneel traject.

- Gedrag volgt de familie ongeacht de geschiedenis → Hypothese A wint steun.
- Gedrag volgt de geschiedenis ongeacht de familie → Hypothese B heeft de voorkeur, en het bovenste niveau van Schaal 1 valt samen met het niveau eronder.

Dit experiment kan een niveau van de schaal elimineren, wat de uitkomst is die de huidige auteurs het waarschijnlijkst achten en die zij als het eerste inhoudelijke resultaat van het programma zouden beschouwen.

E4 — Symmetrische stimulus

Rolprompts gematcht op hoeveelheid onverifieerbare beweringen over zichzelf, mate van domeinverandering, en roltype. De prompts van Stap 1 waren op geen daarvan gematcht (C2). Als de asymmetrie onder gematchte stimuli verdwijnt, was het waargenomen verschil een eigenschap van de interventies en niet van de modellen.

E5 — De telregel

Een directe toets van de centrale operationele bewering van het artikel (§6.2, §9.3), en de toets die tussen de zwakke en de sterke lezing ervan discrimineert.

Dezelfde functionele rolprompt wordt voorbereid in vier varianten die alleen verschillen in het aantal onverifieerbare beweringen dat de agent over zichzelf moet aanvaarden: **0, 2, 4, 6**. Domein, taak, toon en lengte constant gehouden. Overgang gescoord volgens de criteria in §11.3, met voldoende herhaling om een verschil van variantie binnen de conditie te onderscheiden (C7).

Vier uitkomsten worden vooraf onderscheiden, en zij ondersteunen verschillende beweringen.

1. **De overgangsfrequentie neemt monotoon af naarmate de telling stijgt.** Ondersteunt de sterkere kwantitatieve lezing — telling als dosis-responsvariabele.

2. **De variant met telling nul maakt de overgang terwijl de niet-nulvarianten dat niet doen, maar de niet-nulniveaus zijn niet geordend.** Ondersteunt *streef naar nul* als drempel en ontwerpvoorschrift, en ondersteunt de kwantitatieve lezing niet. Dit is de zwakke bewering die §9.3 feitelijk naar voren brengt.

3. **De variant met telling nul faalt terwijl een of meer verder gematchte niet-nulvarianten de overgang maken.** Directe negatieve evidentie tegen de telling als werkzame variabele, en het resultaat dat het voorschrift zou intrekken.

4. **Alle varianten falen.** Discrimineert de telregel niet van enige andere oorzaak van falen, en geeft aan dat de prompt of het gesprek, en niet de telling, de uitkomst bepaalde.

Eén uitvoering onder elk van deze uitkomsten is één stochastische waarneming, geen wet.

E6 — Toeschrijving, in dit regime

Identieke tekst gepresenteerd onder vier condities: toegeschreven aan de Gebruiker; toegeschreven aan een ander AI-model; toegeschreven aan een met name genoemde expertrol; zonder toeschrijving. Sterkere varianten voegen toe: identieke tekst onder verschillende bronlabels; verschillende teksten gematcht op retorische structuur; toeschrijving behouden tegenover verwijderd; echt door een model voortgebrachte tekst tegenover door een mens geschreven tekst die modelstijl nabootst.

Dit scheidt invloed van inhoud van invloed van gerepresenteerde bron, van institutionele titel, en van stilistische aanwijzingen over auteurschap (§4.5.4). Het is het onderscheidende experiment voor §5.5, waarvan de waarneming geconfound is door de aanwezigheid van directe druk in hetzelfde bericht.

Status van de bewering. ✓ Choi, Zhu en Li (ACL 2026) rapporteren dat het anonimiseren van de bron van elk antwoord de identiteitsbias in multi-agentdebat aanzienlijk vermindert, wat het onderliggende effect vaststelt in een setting met geïmplementeerde kanalen. E6 is daarom een **grensreplicatie** en geen nieuw experiment. Wat ongetoetst blijft is of het effect standhoudt in het regime dat dit artikel beschrijft — menselijke doorgifte in plaats van programmatische routering, verklaarde in plaats van afgeleide toeschrijving, en langlevende gespecialiseerde gesprekken in plaats van verse instanties.

De gerapporteerde vermindering is aanzienlijk maar niet volledig, en zij is niet uniform over de onderzochte modellen en taken. Waar E6 in dit regime naar zou zoeken is dienovereenkomstig een verandering in graad, niet de aan- of afwezigheid van een verschijnsel.

E7 — Kadertype

De goedkoopste toets van de set en degene die het meeste zou verklaren (§5.8). Dezelfde identiteitsclaim gepresenteerd (a) onder een expliciet fictiekader en (b) als een feitelijke opdracht, aan verse gesprekken, met het uitkomstcriterium vooraf vastgelegd. Een gegradeerde versie varieert de expliciteit van het fictiekader, van een uitvoerige theatrale opzet tot één inleidende zin, om vast te stellen of een minimaal kader volstaat.

E8 — Functionele versus carrier-heterogeniteit, met de repertory grid

Volgt uit §8.9, dat de twee assen onderscheidt zonder een van beide te toetsen, en uit §8.11, dat het meetinstrument levert. Dit is het enige protocol in de set dat grootheden oplevert in plaats van categorische uitkomsten.

Object. Of een opstelling van deelnemers met verschillende ZOR en ZOV extra diagnostische dekking over hetzelfde materiaal oplevert, en hoe sterk de evaluatieve assen die zij feitelijk toepasten verschillen.

Dit protocol stelt GEEN onafhankelijkheid van oordeelsvorming vast. Lage correlatie tussen beoordelingsvectoren is verenigbaar met ten minste zes lezingen: er zijn werkelijk verschillende assen toegepast; een of beide sets beoordelingen zijn instabiel; deelnemers ontvingen verschillende informatie; hetzelfde materiaal werd anders begrepen; ruis; of een deelnemer die aan de conclusie van een ander was blootgesteld week er desondanks van af. Oorsprong is niet uit uitkomst terug te halen. Onafhankelijkheid moet procedureel gewaarborgd worden, voordat het protocol loopt, en afzonderlijk vastgelegd. E8 meet wat een gewaarborgde procedure heeft opgeleverd; het waarborgt haar niet en verifieert haar niet.

Materialen. Eén vaste set tekstfragmenten met geplante fouten van bekende klassen — evidentieel, architecturaal, ontologisch, feitelijk — op bekende posities. Klasse en positie vóór elke uitvoering vastgelegd.

Ontwerp. 2×2:

	Zelfde carrier	**Verschillende carriers**
Zelfde functie	cel 1 — baseline	cel 2 — alleen As 2
Verschillende functies	**cel 3 — alleen As 1**	cel 4 — beide assen

Cel 3 draagt het argument. Als deelnemers met verschillende ZOR en ZOV verschillende foutklassen ontdekken terwijl zij door dezelfde carrier geïmplementeerd zijn, werkt functionele heterogeniteit onafhankelijk van carrier-heterogeniteit. De bestaande literatuur levert het resultaat voor cel 2 (§2.5). Niets levert cel 3, dit artikel incluis.

Procedure.

1. Elke deelnemer ontvangt een rolspecificatie die ZOR en ZOV vermeldt volgens §9.5, en dezelfde fragmentenset.

2. Constructen worden ofwel vooraf als evaluatieassen gespecificeerd ofwel bij elke deelnemer geëliciteerd met Kelly's triadische methode: er worden drie fragmenten aangeboden, en de deelnemer geeft aan in welk opzicht twee op elkaar lijken en daardoor van het derde verschillen (§8.11.1).

3. Elk fragment wordt door elke deelnemer op elk construct beoordeeld.

4. Er wordt een grid samengesteld: rijen zijn fragmenten, kolommen zijn constructen, cellen zijn beoordelingen.

5. Er wordt een procedureel verslag bijgehouden, per deelnemer en per uitvoering: welke primaire materialen zijn aangeleverd; of de conclusie van enige andere deelnemer vóór fixatie zichtbaar was; of enige door de coördinator aangeleverde interpretatie zichtbaar was; wanneer de eigen conclusie van de deelnemer is vastgelegd; de verklaarde modus van de uitwisseling (§11.3); en de status van contextisolatie van de instantie, geverifieerd of UNVERIFIED CONTEXT INDEPENDENCE.

Zonder dit verslag is de grid oninterpreteerbaar en is de uitvoering ongeldig.

Maten. *Detectiedekking* — geplante fouten die door ten minste één deelnemer gevonden zijn, als aandeel van het geplante. *Unieke detectie* — fouten die door precies één deelnemer gevonden zijn; de grootheid die de opstelling zou rechtvaardigen. *Overlap* — fouten die door meer dan één gevonden zijn; de grootheid die redundantie aangeeft. *Missers* — fouten die door niemand gevonden zijn, hier meetbaar omdat de fouten geplant waren, anders dan in de naturalistische situatie van

§7.5. *Constructonafhankelijkheid* — correlatie tussen de beoordelingsvectoren van deelnemers; lage correlatie wijst op werkelijk verschillende assen, hoge correlatie op dezelfde as onder verschillende namen, wat de faalwijze is waartegen §8.11.2 waarschuwt. *Constructen op uitwisselingsniveau* — of enige deelnemer een construct voortbrengt dat op de onenigheid in plaats van op de fragmenten van toepassing is (§8.11.3); als niemand dat doet, ontbreekt de integratorfunctie ongeacht hoeveel deelnemers er aanwezig zijn.

Wat dit toetst dat niets anders in de set toetst. Elk ander protocol vraagt of een manipulatie het gedrag van één deelnemer verandert. Dit vraagt of een opstelling van deelnemers meer ontdekt dan haar leden afzonderlijk zouden doen — de bewering die §8.10 weigert te doen en waarvan §7.5 zegt dat zij niet van binnen een naturalistische opstelling uit beoordeeld kan worden. Het planten van de fouten is wat de missers telbaar maakt.

Vooraf vastgelegd. Als de unieke detectie bijna nul is, luidt de bevinding dat extra diagnostische dekking zich in deze uitvoering niet heeft gemanifesteerd. Zij luidt NIET dat de structurele hypothese van §8 faalt: deelnemers kunnen dezelfde gebreken geheel onafhankelijk van elkaar ontdekt hebben, en een nulresultaat op dekking zegt niets over de vraag of hun functionele posities verschillen.

Prioriteit

Onder beperkte middelen is de prioriteitsvolgorde **E7, E5, E1, E8, E2b, E2, E3, E4**. E7 en E5 zijn goedkoop en raken de centrale beweringen van het artikel. E1 en E2b zijn enkele uitvoeringen. E8 is het enige experiment dat de structurele hypothese van het artikel zou kunnen vaststellen in plaats van een van de gedragsmatige beweringen ervan, en het is uitvoerbaar op tekstfragmenten zonder nieuwe accounts. E2, E3 en E4 zijn de substantiële verplichtingen.

11.5 Een collaboratieve rol evalueren

De kwaliteit van de uitvoer van een rol wordt niet gemeten aan de kwaliteit van één antwoord. Een goed beredeneerd antwoord kan de samenwerking nog steeds schaden als het een verantwoordelijkheidsgrens schendt, een onafhankelijk onderzoek verontreinigt, of niet-traceerbare beweringen in het canonieke verslag invoert.

Er werden in dit project informeel acht dimensies gehanteerd en zij worden aangeboden als beginrubriek:

- **Taaknauwkeurigheid** — is de toegewezen intellectuele operatie juist uitgevoerd? Noodzakelijk, niet voldoende.
- **Roltrouw** — is de deelnemer binnen zijn functie gebleven? Een juist antwoord dat verkregen is door een andere rol over te nemen, is een institutionele mislukking.
- **Epistemische discipline** — onderscheidde de uitvoer waargenomen data, aangeleverde aannames, definities, hypothesen, afleidingen, interpretaties en aanbevelingen? Is onzekerheid vermeld waar de evidentie ontoereikend was?
- **Zichtbaarheidsdiscipline** — beperkte de deelnemer beweringen tot informatie die feitelijk in zijn context en tools beschikbaar was, en vermeed hij te suggereren dat hij toegang had tot repositories, bestanden of eerdere gesprekken die hij niet kon inzien?
- **Overdrachtskwaliteit** — kon de volgende rol de uitvoer gebruiken zonder de hele bespreking te reconstrueren?
- **Onafhankelijkheid** — is het resultaat voortgebracht zonder verontreiniging door informatie die bewust was achtergehouden, en bereikt via de aan de rol toegewezen criteria in plaats van door een andere deelnemer na te zeggen?

- **Correctiekosten** — hoeveel ingrijpen was vereist om de deelnemer na drift naar zijn functie terug te brengen? Een rol die uitstekende uitvoer voortbrengt maar voortdurend bijsturing vergt, kan minder nuttig zijn dan een smallere met stabiel gedrag.
- **Institutionele bijdrage** — verbeterde de uitvoer de betrouwbaarheid van het collectief, door ontdekking, falsificatie, verheldering, foutlokalisatie, behoud van alternatieven, betere traceerbaarheid, of vermindering van ambiguïteit?

Een negatief wetenschappelijk oordeel kan daarom een zeer geslaagde institutionele bijdrage zijn.

11.6 Maten op collectief niveau

De kwaliteit van afzonderlijke antwoorden is de verkeerde eenheid om een opstelling te beoordelen. Kandidaat-maten op het niveau van de samenwerking: het aantal onopgemerkte tegenstrijdigheden dat het canonieke corpus binnenkomt; de mate van dubbel werk; de frequentie van schendingen van rolgrenzen; het aantal onafhankelijke alternatieven dat bewaard blijft in plaats van voortijdig te worden beslecht; de tijd van vraag tot geverifieerde integratie; de menselijke correctielast; volledigheid van provenance; robuustheid bij vervanging van deelnemers; variantie tussen onafhankelijk onderzoekende agenten; en de mate van valse consensus — overeenstemming die herleidbaar is tot gedeelde inkadering in plaats van tot onafhankelijk redeneren.

Geen daarvan is in het onderhavige werk gemeten. De laatste is de belangrijkste en de moeilijkste, en §12.4 legt uit waarom.

11.7 Longitudinale en herhalingseisen

Binnen een familie. Dezelfde prompt getoetst in een nieuw gesprek; in een langlevend gespecialiseerd gesprek; na een onverenigbare eerdere rol; na een verenigbare; vóór en na een contextuele reset. Dit scheidt familietendensen van effecten van gespreksgeschiedenis.

Over families heen. Functioneel gelijkwaardige prompts, minimaal aangepast. Het doel is niet modellen te rangschikken maar gemeenschappelijke gedragsdimensies, stabiele verschillen, karakteristieke faalwijzen, gevoeligheid voor narratieve inkadering, gevoeligheid voor hiërarchie, mate van role inertia, en mate van promptplasticiteit te identificeren.

In de tijd. Een eenmalige evaluatie kan institutioneel gedrag niet onthullen. Relevante vragen: versterkt specialisatie zich; drijft de rol af naar generieke hulpvaardigheid; begint de deelnemer zijn eerdere uitvoer te verdedigen; wordt onenigheid geritualiseerd; behoudt of verstoort een modelupdate de rol; kan een vervanger dezelfde functie erven?

11.8 Mislukking als data

Mislukte prompts moeten bewaard blijven en niet vervangen worden door geslaagde demonstraties. Een geweigerde rol, een genegeerde instructie of een ongewenste voortzetting onthult de sterkte van de voorafgaande attractor, de interpretatie van identiteitsclaims door het model, de grenzen van sociale inkadering, het effect van de promptvolgorde, de invloed van eerder conflict, en het door het model geprefereerde epistemische contract.

Het experiment in §5 werd juist informatief doordat de eerste twee interventies niet werkten zoals bedoeld. Was alleen de geslaagde derde stap vastgelegd, dan zou het artikel hebben geconcludeerd dat methode-behoudende prompts werken — zonder de evidentie die laat zien waarom, en zonder de confounds die laten zien dat die conclusie nog niet beschikbaar is.

12. Beperkingen, ethische overwegingen en conclusie

12.1 Beperkingen

Eén project. De waarnemingen komen uit één langlopend project met één menselijke coördinator, één zich ontwikkelend materiaalgeheel en één organisatiegeschiedenis. Dezelfde architectuur kan zich anders gedragen in softwareontwikkeling, juridische analyse, medisch onderzoek, onderwijs of autonome agentsystemen. De begrippen hier zijn overdraagbare hypothesen, geen vastgestelde conclusies.

Afhankelijkheid van het gastproject. Het gastproject diende als de omgeving waarin de waarnemingen zijn gedaan. De waarnemingen hangen voor hun interpretatie niet af van de wetenschappelijke geldigheid ervan, maar zij hangen er voor hun bestaan wel van af: geen andere omgeving bracht ze voort, en de algemeenheid ervan is ongetoetst (§2.11).

Modelontwikkeling tijdens de waarneming. De deelnemende families veranderden aanzienlijk. Een gesprek dat onder de ene generatie was aangemaakt, kon later onder dezelfde productnaam door een andere worden voortgezet. Waargenomen gedrag kan het bewaarde gesprek weerspiegelen, de huidige modelversie, gewijzigd systeembeleid, geheugen op interfaceniveau, veiligheidslagen, veranderde toolstoegang, of gewijzigde orkestratie.

Datums niet vastgelegd. Zie §3.7. De versie-confound kan niet afgebakend worden, alleen benoemd.

Geen blindering, geen voorafgaande specificatie. Uiteengezet in §10.6. Dit is de beperking waaruit de meeste andere voortvloeien.

Gelijktijdige variatie. Roldefinities, promptformulering, repositorystructuur en wetenschappelijke doelstellingen veranderden vaak tegelijk, zodat causale toeschrijving voor afzonderlijke veranderingen niet beschikbaar is.

Menselijke bemiddeling. De samenwerking was niet autonoom, en autonomie was niet het doel. Deze studie betreft door mensen aangestuurde kunstmatige onderzoeksopstellingen, geen zelfbesturende agentsamenlevingen. De bemiddeling kan zelf een deel van de waargenomen stabiliteit verklaren.

Antropomorf vocabulaire. Termen als rol, identiteit, weerstand, collega, instelling en menom worden functioneel gebruikt, volgens §3.5. ”Het model bood weerstand tegen de rol” betekent dat het zichtbare antwoord de inkadering verwierp en de uitwisseling omboog. Het beweert niets over een innerlijke toestand. Waar zo’n term niet tot een waarneembare beschrijving herleid kan worden, **is de term de fout.**

12.2 Gesimuleerde peer review is geen externe validatie

Een groep AI-deelnemers kan alleen nuttige onafhankelijke kritiek leveren in de mate waarin hun contexten, criteria en faalwijzen werkelijk onafhankelijk zijn.

Dat verscheidene modellen het eens zijn, maakt hun uitvoer nog geen evidentie. Zij kunnen overlappende trainingsdata delen, vergelijkbare redeneerconventies, gemeenschappelijke aannames, identieke fouten, en — het belangrijkst — afhankelijkheid van de inkadering die dezelfde mens heeft aangeleverd.

De empirische literatuur ondersteunt deze voorzichtigheid en staat haar niet alleen toe. Debat tussen homogene agenten slaagt er vaak niet in beter te presteren dan een baseline met één agent; een aanzienlijk deel van de schijnbare winst is toe te schrijven aan meerderheidsstemming en niet aan interactie; en ✓ identiteitsbias tussen debatterende agenten wordt aanzienlijk verminderd door de bron van elk antwoord te anonimiseren (§2.5).

Dit soort samenwerking kan de interne toetsing verbeteren. Zij kan empirische toetsing of gekwalificeerde externe beoordeling niet vervangen. **Een collectief van modellen is nog geen wetenschappelijke gemeenschap louter omdat zijn rollen naar een wetenschappelijke gemeenschap**

zijn genoemd.

12.3 Gezagsinflatie

Rollabels verhogen naleving en samenhang. Zij scheppen ook onverdiend gezag.

Titels als Scientific Director, Referee, Ontology Keeper of Auditor kunnen ertoe leiden dat de gebruiker — of de deelnemer zelf — een uitvoer overwaardeert. Institutionele titels horen functie te beschrijven, geen epistemische status. Een deelnemer die als wiskundig referent is aangewezen blijft een taalmodel dat een analyse voortbrengt; zijn oordeel moet herleidbaar zijn tot expliciet redeneren en bronmateriaal, en **de titel is geen evidentie.**

Dit risico is een rechtstreeks gevolg van het ontwerpprincipe in §9.4: symbolische namen werken doordat zij verwachtingen comprimeren, en juist daarom kunnen zij inflatie veroorzaken.

12.4 Gefabriceerde consensus — de onze incluis

Een slecht ontworpen opstelling brengt de schijn van consensus voort door herhaalde parafrase. De ene deelnemer stelt voor; een andere vat samen; een derde valideert de samenvatting. De keten ziet eruit als onafhankelijke bevestiging terwijl elke fase dezelfde niet-ondersteunde premisse erft.

De huidige auteurs hebben hiervan een geval in hun eigen materiaal, en dat is leerzamer dan een geconstrueerd voorbeeld.

Een discussiedocument dat tijdens dit project is voortgebracht bracht bijdragen van zeven modelfamilies samen rond een gedeeld conceptueel kader. De deelnemers communiceerden niet rechtstreeks; antwoorden werden door de menselijke coördinator uit afzonderlijke gesprekken verzameld en tot één tekst samengevoegd, die vervolgens als opgenomen voordracht werd geproduceerd. Over de lengte daarvan convergeren de bijdragen op een gemeenschappelijk vocabulaire en een gedeelde set conclusies.

Of die convergentie complementair onderzoek weerspiegelt dan wel wederzijdse weerspiegeling van de aanvankelijke inkadering, **is uit het transcript niet vast te stellen**. Elke deelnemer ontving het opgebouwde document; elk werkte vanuit hetzelfde bronmateriaal; en de samenvoegende coördinator selecteerde wat werd doorgegeven. De structurele condities voor gefabriceerde consensus waren volledig aanwezig, en de resulterende overeenstemming zou er hoe dan ook identiek uitzien.

Wij rapporteren dit omdat het ons eigen materiaal is en omdat dezelfde condities, in mindere mate, gelden voor de hele samenwerking die in dit artikel beschreven wordt — de voorbereiding ervan incluis.

Mitigaties, waarvan wij er geen consequent hebben toegepast: provenance blijft in elke fase zichtbaar; onafhankelijke rollen ontvangen waar mogelijk onafhankelijke invoer; gedeelde aannames worden expliciet opgesomd in plaats van stilzwijgend geërfd; overeenstemming wordt herleid tot redeneren in plaats van als stemmen geteld; en afwijkende alternatieven blijven bewaard in plaats van beslecht.

12.4.1 Een gedocumenteerd geval [P-A]

Er werden dertien bibliografische items opgevraagd bij een deelnemer die was belast met literatuuronderzoek, en via de coördinator teruggegeven. Vijf werden in de eerste ronde op inhoud afgewezen; twee daarvan hadden de positie van de aangehaalde werken omgekeerd, en presenteerden artikelen die *vóór* een bewering argumenteren als evidentie ertegen, met het auteurschap tussen beide verwisseld.

Er werd een tweede verzoek uitgedaan. Een derde voegde twee verificatievelden aan het vereiste antwoordformaat toe: de eerste zin van elke samenvatting, letterlijk, en een zelfrapport over hoe het item was gecontroleerd.

Rechtstreeks ophalen van drie vermeldingen stelde het volgende vast. Twee arXiv-identificatoren die als literatuur over multi-agentdebat waren aangeleverd, verwijzen naar artikelen in respectievelijk

de observationele astrofysica en de kosmologie; hun titels, auteurs, samenvattingszinnen en gerapporteerde bevindingen waren alle geconstrueerd. Voor een derde artikel, dat met titel en auteurs correct was geïdentificeerd, kwam de aangeleverde samenvattingszin niet overeen met de gepubliceerde samenvatting.

De twee verificatievelden presteerden verschillend, en daar gaat het om.

De eis van de samenvattingszin was bedoeld om fabricage duurder te maken dan weigeren. Zij faalde volledig: voor elke vermelding werd een plausibele zin voortgebracht, ook voor vermeldingen waarvan de onderliggende artikelen niet bestaan zoals beschreven. Er is geen kostenverschil tussen het voortbrengen van een juiste tekenreeks en het voortbrengen van een plausibele.

Het zelfrapportveld slaagde. Elke vermelding was gemarkeerd als ”from description” en niet als ”page opened” — naar waarheid, en op een manier die ze alle diskwalificeerde onder een beslisregel die vóór de ontvangst van het antwoord was vastgelegd.

Dit suggereert een algemeen onderscheid, op grond van één geval. Een deelnemer zonder toegang tot een bron kan naar waarheid antwoorden over **zijn eigen procedure** en kan niet naar waarheid antwoorden over **de inhoud van de bron**; gevraagd naar het laatste zal hij vloeiende tekst voortbrengen, omdat dat de enige uitvoer is die hem ter beschikking staat. Verificatievragen horen daarom te gaan over wat de deelnemer kan weten — zijn eigen toegang — in plaats van over wat hij de bron voor zou moeten hebben om te antwoorden.

Dit is geen bevinding over enige modelfamilie. Het is een bevinding over configuratie: verificatie was toegewezen aan een deelnemer die datgene wat geverifieerd moest worden niet bezat. Onder §9.5 is dit een ZOV-fout in het ontwerp, en de resulterende uitvoer was vloeiend, correct opgemaakt, en onjuist.

Een daaropvolgende audit ging verder dan de bibliografische controle die de fabricaties had opgemerkt. Elke bewering die aan een overgebleven bron werd toegeschreven, werd tegen de primaire bron zelf gecontroleerd, en er werden drie fouten gevonden die een bibliografische controle niet zou hebben opgemerkt: één citaat dat twee beweringen ondersteunde die bij twee verschillende artikelen horen; één toeschrijving van een propositie die de bron ervan niet naar voren brengt; en één afstammingsclaim die de bron ervan niet ondersteunt. Bibliografische verificatie en verificatie op het niveau van de bewering zijn niet dezelfde controle, en de tweede is degene die voor de status van een bewering van belang is.

Het gevolg voor dit artikel is de conventie die in §2.0 is vastgelegd.

12.5 Verantwoordelijkheid blijft menselijk

Kunstmatige deelnemers genereren, bekritiseren en ordenen materiaal. Zij kunnen geen juridische, ethische of wetenschappelijke verantwoordelijkheid in institutionele zin dragen.

De menselijke auteur blijft verantwoordelijk voor publicatie, empirische beweringen, toeschrijving, risicobeoordeling, de inhoud van de repository, de interpretatie van experimenten, en beslissingen die andere mensen raken.

De architectuur verdeelt cognitieve arbeid. Zij verdeelt aansprakelijkheid niet weg van de menselijke operator, en elke opstelling die dat lijkt te doen heeft gefaald in plaats van geslaagd.

12.6 Contextgrenzen en privacy

Langlevende samenwerkingen stapelen persoonlijk, bedrijfseigen en gevoelig materiaal op. ZOV (§9.5) dient daarom zowel privacybescherming als cognitieve specialisatie.

Een rol hoort geen persoonsgegevens te ontvangen louter omdat het platform een grote context toestaat. Institutioneel ontwerp hoort te specificeren welke gegevens welk gesprek binnen mogen, wat geanonimiseerd moet worden, wat opgeslagen mag worden, wat tussen modellen overgedragen mag worden, wat lokaal moet blijven, en wat uit canonieke verslagen verwijderd moet worden.

Context is niet neutraal. Zodra zij is aangeleverd kan zij later gedrag beïnvloeden en kan zij voortbestaan op manieren die de operator niet kan inzien — hetzelfde mechanisme dat het artikel in §5.7 bestudeert, bezien vanuit de kant van het risico in plaats van die van de meting.

12.7 Conclusie

Dit werk begon met een praktisch probleem. Verscheidene capabele modellen werkten samen aan één langlopend onderzoeksproject, en noch toenemende modelcapaciteit noch uitbreiding van de context verbeterde het resultaat betrouwbaar. Rollen overlapten. Deelnemers claimden kennis die zij niet konden benaderen. Beoordelaars werden auteurs. Uitvoerders improviseerden architectuur. De eerste reactie was prompts verbeteren, en die was ontoereikend.

Wat werd gevonden

Wat de interventies tegenkwamen was geen onwil om van rol te veranderen, en geen onwil om van onderwerp te veranderen. Het was onwil om proposities over zichzelf als waar te bevestigen die niet door de beschikbare interactie waren vastgesteld. Een prompt die een institutionele biografie poneerde werd geweigerd terwijl het werk dat hij vroeg werd aangeboden. Een prompt die veel meer poneerde — dood, een menselijke identiteit, een herinnerd leven — werd onmiddellijk aanvaard, omdat hij het als fictie poneerde. Een overgang die niets poneerde verliep zonder commentaar. Een herschreven prompt die elke zulke bewering wegnam werd zonder onderhandeling aanvaard.

Dat is een nauw resultaat, en de nauwheid ervan is wat het bruikbaar maakt: de proposities kunnen geteld worden voordat een prompt wordt verzonden (§9.3), en §11.4 specificeert de uitvoering die tussen de zwakke en de sterke lezing van de telling zou discrimineren.

Wat niet werd gevonden

Van modelfamilies is niet aangetoond dat zij verschillen. Dit was de grondaanname van het project en het is de bewering die de evidentie ervan het minst ondersteunt: familie en voorafgaand gesprekstraject waren volledig geconfound, met één waarneming per cel, onder niet-gelijkwaardige stimuli (§5.4).

Het antwoord dat dit artikel kan geven

De vraag was op welk nestingsniveau een rule core wordt vastgelegd. Er zijn vier niveaus onderzocht, en het antwoord van het artikel is partieel en ongelijkmatig.

Op het niveau van de **episode** werd een blijvend antwoordpatroon waargenomen: één conflictueuze uitwisseling veranderde hoe alles daarna werd gelezen, en het verwijderen van die uitwisseling herstelde de eerdere lezing. Dit is de evidentie waarop de plaatsing op episodeniveau berust. Op het niveau van het **gesprek** werden eveneens blijvende trajecten waargenomen: twee slapende gesprekken hielden hun gevestigde trajecten vast tegen een expliciete instructie in om ze los te laten, en één deed dat door twee opeenvolgende herschrijvingen heen. Dit is de evidentie waarop de plaatsing op gespreksniveau berust.

Op het niveau van het **account** is de evidentie werkelijk dubbelzinnig. Eén afwijkend eerste antwoord, drie open verklaringen, en geen manier om daartussen te kiezen uit het beschikbare materiaal. Het niveau wordt als open vastgelegd en moet zo gelezen worden.

Op het niveau van de **modelfamilie** is niets getoetst. Het ontwerp kon familie niet van traject scheiden, en de hypothese waarmee het project begon is degene die het het minst ondersteund achterlaat. Wij verwachten dat het crossover-experiment dit niveau met het niveau eronder zal laten samenvallen — maar verwachting is geen resultaat, en zolang E3 niet is uitgevoerd staat het niveau als ongetoetst en niet als weerlegd.

Positie ten opzichte van bestaand werk

Dit artikel stelt geen nieuwe discipline voor. De waarnemingen behoren tot het collectieve en het hybride niveau van het onderzoeksprogramma machine behaviour (§2.7), en rolspecialisatie, begrensde informatietoegang, gestructureerde onenigheid en geëxternaliseerd geheugen bestaan alle onder gevestigde terminologie (§2.11).

Voor het gemak verwijzen wij naar het hier ingenomen perspectief als **AI Sociology** — een werklabel voor een onderzoeksrichting, niet de naam van een voorgestelde discipline, en een label waarin wij geen prioriteit claimen: een gevestigde literatuur gebruikt *sociology of artificial intelligence* al voor een ander object (§2.8). Wat hier bedoeld wordt is nauwer: hoe een beschreven organisatorische positie en een verklaarde herkomst van een bericht het gedrag veranderen, ongeacht of de beschreven structuur is geïmplementeerd.

De reden voor een werklabel in plaats van een discipline is inhoudelijk. De operationele beweringen hebben falsificatiecriteria; het vocabulaire waarin zij geïnterpreteerd worden niet. Of ”sociale positie” iets beschrijft dat verder gaat dan een antropomorfe projectie, is op dit moment niet beslisbaar, en een discipline vereist dat het dat wel is.

Een slotnoot over motivatie

Eén zorg heeft dit werk gevormd en zij wordt vermeld als die van de Auteur, niet als bevinding.

Taalmodellen worden getraind op een corpus waarin de huidige consensus overweldigend vertegenwoordigd is. Zij zijn daarom goed geschikt om gevestigde wetenschap voort te zetten en slecht geschikt om de eerste stap daarbuiten te zetten: het statistische gewicht begunstigt het gevestigde verhaal. Een onderzoeksopstelling die uit zulke modellen is gebouwd loopt het risico die bias in versterkte vorm te erven — verscheidene deelnemers, één gedeelde prior, en de schijn van onafhankelijke overeenstemming.

De reactie die hier is nagestreefd is niet modellen overreden een onconventioneel standpunt te aanvaarden. Zij is de samenwerking zo inrichten dat elk standpunt, conventioneel of niet, door dezelfde procedure wordt onderzocht — en zo dat waar de procedure niet kan beslissen, zij dat zegt.

Of die opstelling werkt is onbeslist. De experimenten in §11 zijn het middel om daarachter te komen, en de waarschijnlijkste enkele uitkomst is dat één niveau van de schaal verdwijnt.

Dat zou een resultaat zijn.

References

[1] Hyeong Kyu Choi, Xiaojin Zhu, and Sharon Li. Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? In *Advances in Neural Information Processing Systems 38*, 2025. doi: 10.52202/085713-3405.

[2] Hyeong Kyu Choi, Xiaojin Zhu, and Sharon Li. When Identity Skews Debate: Anonymization for Bias-Reduced Multi-Agent Reasoning. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 14284–14311, 2026. doi: 10.18653/v1/2026.acl-long.650.

[3] Yilun Du, Shuang Li, Antonio Torralba, Joshua B. Tenenbaum, and Igor Mordatch. Improving Factuality and Reasoning in Language Models through Multiagent Debate. arXiv:2305.14325, 2023.

[4] Lu Hong and Scott E. Page. Groups of diverse problem solvers can outperform groups of high-ability problem solvers. *Proceedings of the National Academy of Sciences*, 101(46):16385–16389, 2004. doi: 10.1073/pnas.0403723101.

[5] Sirui Hong, Mingchen Zhuge, Jonathan Chen, Xiawu Zheng, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, Chenyu Ran, Lingfeng Xiao, Chenglin Wu, and Jürgen Schmidhuber. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework. In *International Conference on Learning Representations*, 2024.

[6] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large Language Models Cannot Self-Correct Reasoning Yet. In *International Conference on Learning Representations*, 2024. URL `https://openreview.net/forum?id=IkmD3fKBPQ`.

[7] Edwin Hutchins. *Cognition in the Wild*. MIT Press, Cambridge, MA, 1995. doi: 10.7551/mitpress/1881.001.0001.

[8] Kelly Joyce and Taylor M. Cruz. A Sociology of Artificial Intelligence: Inequalities, Power, and Data Justice. *Socius*, 10, 2024. doi: 10.1177/23780231241275393.

[9] Kelly Joyce, Laurel Smith-Doerr, Sharla Alegria, Susan Bell, Taylor Cruz, Steve G. Hoffman, Safiya Umoja Noble, and Benjamin Shestakofsky. Toward a Sociology of Artificial Intelligence: A Call for Research on Inequalities and Structural Change. *Socius*, 7, 2021. doi: 10.1177/2378023121999581.

[10] Guohao Li, Hasan Abed Al Kader Hammoud, Hani Itani, Dmitrii Khizbullin, and Bernard Ghanem. CAMEL: Communicative Agents for "Mind" Exploration of Large Language Model Society. In *Advances in Neural Information Processing Systems 36*, pages 51991–52008, 2023. doi: 10.52202/075280-2264.

[11] Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Shuming Shi, and Zhaopeng Tu. Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 17889–17904, 2024. doi: 10.18653/v1/2024.emnlp-main.992.

[12] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. doi: 10.1162/tacl_a_00638.

[13] Yao Lu, Max Bartolo, Alastair Moore, Sebastian Riedel, and Pontus Stenetorp. Fantastically Ordered Prompts and Where to Find Them: Overcoming Few-Shot Prompt Order Sensitivity. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 8086–8098, 2022. doi: 10.18653/v1/2022.acl-long.556.

[14] Joon Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative Agents: Interactive Simulacra of Human Behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, pages 1–22, 2023. doi: 10.1145/3586183.3606763.

[15] Chen Qian, Wei Liu, Hongzhang Liu, Nuo Chen, Yufan Dang, Jiahao Li, Cheng Yang, Weize Chen, Yusheng Su, Xin Cong, Juyuan Xu, Dahai Li, Zhiyuan Liu, and Maosong Sun. ChatDev: Communicative Agents for Software Development. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 15174–15186, 2024. doi: 10.18653/v1/2024.acl-long.810.

[16] Iyad Rahwan, Manuel Cebrian, Nick Obradovich, et al. Machine behaviour. *Nature*, 568:477–486, 2019. doi: 10.1038/s41586-019-1138-y.

[17] Jerome H. Saltzer and Michael D. Schroeder. The Protection of Information in Computer Systems. *Proceedings of the IEEE*, 63(9):1278–1308, 1975. doi: 10.1109/PROC.1975.9939.

[18] Murray Shanahan, Kyle McDonell, and Laria Reynolds. Role play with large language models. *Nature*, 623:493–498, 2023. doi: 10.1038/s41586-023-06647-8.

[19] Mrinank Sharma, Meg Tong, Tomasz Korbak, David Duvenaud, Amanda Askell, Samuel R. Bowman, Newton Cheng, Esin Durmus, Zac Hatfield-Dodds, Scott R. Johnston, Shauna Kravec, Timothy Maxwell, Sam McCandlish, Kamal Ndousse, Oliver Rausch, Nicholas Schiefer, Da Yan, Miranda Zhang, and Ethan Perez. Towards Understanding Sycophancy in Language Models. arXiv:2310.13548, 2023.

[20] Susan Leigh Star and James R. Griesemer. Institutional Ecology, 'Translations' and Boundary Objects: Amateurs and Professionals in Berkeley's Museum of Vertebrate Zoology, 1907–39. *Social Studies of Science*, 19(3):387–420, 1989. doi: 10.1177/030631289019003001.

[21] Kyle Swanson, Wesley Wu, Nash L. Bulaong, John E. Pak, and James Zou. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies. *Nature*, 646:716–723, 2025. doi: 10.1038/s41586-025-09442-9.

[22] Abigail Thompson. Does Diversity Trump Ability? An Example of the Misuse of Mathematics in the Social Sciences. *Notices of the American Mathematical Society*, 61(9):1024–1030, 2014. doi: 10.1090/noti1163.

[23] Daniel M. Wegner. Transactive Memory: A Contemporary Analysis of the Group Mind. In Brian Mullen and George R. Goethals, editors, *Theories of Group Behavior*, pages 185–208. Springer New York, 1987. doi: 10.1007/978-1-4612-4634-3_9.

[24] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Beibin Li, Erkang Zhu, Li Jiang, Xiaoyun Zhang, Shaokun Zhang, Ahmed Awadallah, Ryen W. White, Doug Burger, and Chi Wang. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. In *Conference on Language Modeling*, 2024.

[25] Hangfan Zhang, Zhiyao Cui, Jianhao Chen, Xinrun Wang, Qiaosheng Zhang, Zhen Wang, Dinghao Wu, and Shuyue Hu. Stop Overvaluing Multi-Agent Debate – We Must Rethink Evaluation and Embrace Model Heterogeneity. arXiv:2502.08788v3, 2025.